

Các phương pháp nhân (Scholkopf và Smola) , (2002). Các phương pháp nhân khai thác cho thấy nhiều thuật toán tuyến tính có thể được biểu diễn hoàn toàn bằng các phép tính tích vô hướng. Sau đó, "thủ thuật nhân" cho phép chúng ta tính toán những điều này. Tích vô hướng được thể hiện ngầm trong một tính năng (có thể có chiều vô hạn) không gian, mà thậm chí không cần biết rõ ràng về không gian tính năng này. Điều này cho phép "Phi tuyến tính hóa". nhiều thuật toán được sử dụng trong học máy, chẳng hạn như Phương pháp kernel-PCA (Scholkopf et al. 1997) được sử dụng để giảm chiều dữ liệu. Các quá trình Gaussian (Rasmussen và Williams, 2006) cũng thuộc loại này. Các phương pháp kernel là những phương pháp tiên tiến nhất hiện nay trong hồi quy xác suất (phù hợp các đường cong với các điểm dữ liệu). Ý tưởng về kernel được khám phá. Xem thêm tại Chương 12.

Phép chiếu thường được sử dụng trong đồ họa máy tính, ví dụ như để tạo bóng. Trong tối ưu hóa, phép chiếu trực giao thường được sử dụng để (lặp đi lặp lại) Giảm thiểu sai số còn lại. Điều này cũng có ứng dụng trong học máy. Ví dụ, trong hồi quy tuyến tính, chúng ta muốn tìm một hàm (tuyến tính) mà giảm thiểu sai số dư, tức là độ dài của các phép chiếu trực giao của dữ liệu lên hàm tuyến tính (Bishop, 2006). Chúng ta sẽ nghiên cứu vấn đề này kỹ hơn trong Chương 9. PCA (Pearson, 1901; Hotelling, 1933) cũng Sử dụng phép chiếu để giảm chiều dữ liệu đa chiều. Chúng ta sẽ thảo luận chi tiết hơn về vấn đề này trong Chương 10.

Bài tập

3.1 Chứng minh rằng $\cdot, \cdot$ được xác định cho mọi $x = [x_1, x_2]$ trong $\mathbb{R}^2$ và $y = [y_1, y_2]$ trong $\mathbb{R}^2$ bởi

$$x, y := x_1 y_1 + (x_1 y_2 + x_2 y_1) + 2(x_2 y_2)$$

là một tích vô hướng.

3.2 Xét $\mathbb{R}^2$ với $\cdot, \cdot$ được định nghĩa cho mọi x và y trong $\mathbb{R}^2$ như sau:

$$x, y := \begin{pmatrix} 2 & 0 \\ x_1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ y_1 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ y_1 \end{pmatrix} = A$$

$\cdot, \cdot$ có phải là tích vô hướng không?

3.3 Tính khoảng cách giữa

$$x = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, y = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$$

Sử

dùng a. $x, y := x \cdot y$

b. $x, y := x \cdot A y, A := \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}$

3.4 Tính góc giữa

$$x = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, y = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Sử

dùng a. $x, y :=$

$x \cdot y$ b. $x, y := x \cdot B y, B := \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$

3.5 Xét không gian vectơ Euclid $\mathbb{R}^5$ với tích vô hướng. Một không gian con U của $\mathbb{R}^5$ và $x \in \mathbb{R}^5$ được cho bởi

$$U = \text{span} \left\{ \begin{pmatrix} 0 \\ 1 \\ 2 \\ 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 \\ -3 \\ 1 \\ 1 \\ 2 \end{pmatrix}, \begin{pmatrix} -3 \\ 4 \\ 1 \\ 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ -3 \\ 5 \\ 0 \\ 7 \end{pmatrix} \right\}, x = \begin{pmatrix} 1 \\ 9 \\ 4 \\ 4 \\ 1 \end{pmatrix}.$$

a. Xác định hình chiếu trực giao $\pi_U(x)$ của x lên U . b. Xác định khoảng cách $d(x, U)$

3.6 Xét $\mathbb{R}^3$ với tích vô hướng

$$x, y := x \cdot \begin{pmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{pmatrix} \cdot y.$$

Hơn nữa, chúng tôi định nghĩa e_1, e_2, e_3 là cơ sở chuẩn/chính tắc trong $\mathbb{R}^3$.

a. Xác định hình chiếu trực giao $\pi_U(e_2)$ của e_2 lên

$$U = \text{span}\{e_1, e_3\}.$$

Gợi ý: Tính trực giao được định nghĩa thông qua tích vô hướng. b. Tính khoảng cách $d(e_2,$

$U)$. c. Vẽ kịch bản: các vectơ cơ sở chuẩn và $\pi_U(e_2)$

3.7 Cho V là một không gian vectơ và π là một phép tự đồng cấu của V .

a. Chứng minh rằng π là một phép chiếu khi và chỉ khi $\text{id}_V - \pi$ là một phép chiếu, trong đó id_V là phép tự đồng cấu trên V .

b. Bây giờ giả sử π là một hình chiếu. Tính $\text{Im}(\text{id}_V - \pi)$ và $\ker(\text{id}_V - \pi)$ như một hàm của $\text{Im}(\pi)$ và $\ker(\pi)$.

3.8 Sử dụng phương pháp Gram-Schmidt, hãy chuyển cơ sở $B = (b_1, b_2)$ của một không gian con hai chiều $U \subset \mathbb{R}^3$ thành một ONB $C = (c_1, c_2)$ của U , trong đó

$$b_1 := \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \quad b_2 := \begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}.$$

3.9 Cho $n \in \mathbb{N}$ và $x_1, \dots, x_n > 0$ là n số thực dương sao cho $x_1 + \dots + x_n = 1$. Sử dụng bất đẳng thức Cauchy-Schwarz và chứng minh rằng

$$\sum_{i=1}^n \frac{x_i^2}{1 - x_i} \geq \frac{1}{n}.$$

Gợi ý: Hãy nghĩ về tích vô hướng trên $\mathbb{R}^n$. Sau đó, chọn các vectơ cụ thể $x, y \in \mathbb{R}^n$ và áp dụng bất đẳng thức Cauchy-Schwarz.

3.10 Xoay các vectơ


$$x_1 := \begin{pmatrix} 2 \\ 3 \end{pmatrix}, \quad x_2 := \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

ở 30°.



Trước tiên, chúng ta sẽ xem xét một phép toán tương tự như phép lấy căn bậc hai đối với các ma trận đối xứng, xác định dương, đó là phép phân tích Cholesky (Mục 4.3). Từ đây, chúng ta sẽ xem xét hai phương pháp liên quan để phân tích ma trận thành các dạng chính tắc. Phương pháp đầu tiên được gọi là chéo hóa ma trận (Mục 4.4), cho phép chúng ta biểu diễn ánh xạ tuyến tính bằng ma trận biến đổi chéo nếu chọn một cơ sở thích hợp. Phương pháp thứ hai, phân tích giá trị (Mục 4.5), mở rộng phép phân tích này cho các ma trận không vuông, và nó được coi là một trong những khái niệm cơ bản trong đại số tuyến tính. Các phép phân tích này rất hữu ích, vì các ma trận biểu diễn dữ liệu số thường rất lớn và khó phân tích. Chúng ta kết thúc chương này với một tổng quan có hệ thống về các loại ma trận và các thuộc tính đặc trưng phân biệt chúng dưới dạng phân loại ma trận (Mục 4.7).

Tài liệu này được Nhà xuất bản Đại học Cambridge xuất bản với tựa đề "Toán học cho Học máy" (Mathematics for Machine Learning) của Marc Peter Deisenroth, A. Aldo Faisal và Cheng Soon Ong (2020). Phiên bản này được phép xem và tải xuống miễn phí chỉ dành cho mục đích sử dụng cá nhân. Không được phép phân phối lại, bán lại hoặc sử dụng trong các tác phẩm phái sinh. © Bản quyền thuộc về MP Deisenroth, AA Faisal và CS Ong. 2024. <https://mml-book.com>.



Hình 4.1. Sơ đồ tư duy về các khái niệm được giới thiệu trong chương này, cùng với việc chúng được sử dụng ở những phần khác trong cuốn sách.

Cả trong các chương toán học tiếp theo, chẳng hạn như Chương 6, mà còn trong các chương ứng dụng, ví dụ như giảm chiều dữ liệu trong Chương 10 hoặc ước lượng mật độ trong Chương 11. Cấu trúc tổng thể của chương này được thể hiện trong sơ đồ tư duy của Hình 4.1.

4.1 Định thức và vết

Định thức là một khái niệm quan trọng trong đại số tuyến tính. Định thức là một đối tượng toán học trong việc phân tích và giải hệ phương trình tuyến tính. Định thức chỉ được định nghĩa cho các ma trận vuông $A \in \mathbb{R}^{n \times n}$, tức là các ma trận có cùng số hàng và số cột. Trong cuốn sách này, chúng ta viết định thức là $\det(A)$ hoặc đôi khi là $|A|$ để

Yếu tố quyết định
Ký hiệu $|A|$ không được nhầm lẫn.
với giá trị tuyệt đối.

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix} \quad (4.1)$$

Định thức của ma trận vuông $A \in \mathbb{R}^{n \times n}$ là một hàm ánh xạ định thức A .

trên một số thực. Trước khi đưa ra định nghĩa về định thức cho
Với ma trận $n \times n$ tổng quát, chúng ta hãy cùng xem xét một vài ví dụ minh họa.
và định nghĩa định thức cho một số ma trận đặc biệt.

Ví dụ 4.1 (Kiểm tra tính khả nghịch của ma trận)
Chúng ta hãy bắt đầu bằng việc xem xét liệu ma trận vuông A có khả nghịch hay không (xem
Mục 2.2.2). Đối với các trường hợp nhỏ nhất, chúng ta đã biết khi nào một ma trận...
Có thể đảo ngược. Nếu A là ma trận 1×1 , tức là nó là một số vô hướng, thì
 $A^{-1} = \frac{1}{a}$ Do đó, một $\frac{1}{a} = 1$ đúng khi và chỉ khi $a \neq 0$.
Đối với ma trận 2×2 , theo định nghĩa của ma trận nghịch đảo (Định nghĩa 2.3), chúng ta
biết rằng $AA^{-1} = I$. Sau đó, với (2.24), nghịch đảo của A là

$$A^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{pmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{pmatrix}. \tag{4.2}$$

Do đó, A khả nghịch khi và chỉ khi
 $a_{11}a_{22} - a_{12}a_{21} \neq 0$. (4.3)

Đại lượng này là định thức của A 2×2 , tức là,

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}. \tag{4.4}$$

Ví dụ 4.1 đã chỉ ra mối quan hệ giữa các yếu tố quyết định.
và sự tồn tại của ma trận nghịch đảo. Định lý tiếp theo cũng nêu điều tương tự.
Kết quả cho ma trận $n \times n$.

Định lý 4.1. Với mọi ma trận vuông A $n \times n$, ta có A khả nghịch
nếu và chỉ nếu $\det(A) \neq 0$.

Chúng ta có các biểu thức tường minh (dạng đóng) cho định thức của các số nhỏ.
các ma trận được biểu diễn theo các phần tử của ma trận. Đối với $n = 1$,

$$\det(A) = \det(a_{11}) = a_{11}. \tag{4.5}$$

Đối với $n = 2$,

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}, \tag{4.6}$$

như chúng ta đã quan sát thấy trong ví dụ trước đó.

Đối với $n = 3$ (được gọi là quy tắc Sarrus),

$$\begin{aligned} \det(A) &= \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} \\ &= a_{11}a_{22}a_{33} + a_{12}a_{32}a_{13} + a_{13}a_{23}a_{11} \\ &\quad - a_{13}a_{22}a_{31} - a_{11}a_{32}a_{23} - a_{12}a_{33}a_{21}. \end{aligned} \tag{4.7}$$

Để dễ nhớ các thuật ngữ tích trong quy tắc Sarrus, hãy thử theo dõi các phần tử của tích ba trong ma trận.

Ta gọi ma trận vuông T là ma trận tam giác trên nếu $T_{ij} = 0$ đối với ma trận tam giác trên. $i > j$, tức là ma trận có các phần tử bằng 0 ở dưới đường chéo chính. Tương tự, ta định nghĩa ma trận tam giác dưới là ma trận có các phần tử bằng 0 ở trên đường chéo chính. Đối với ma trận góc tam giác dưới ba phần tử, Định thức là tích của các phần tử trên đường chéo ma trận T $R^{n \times n}$, tức là,

$$\det(T) = \prod_{i=1}^N T_{ii}.$$

(4.8)

Ví dụ 4.2 (Các yếu tố quyết định được dùng làm thước đo thể tích)
Khái niệm về định thức trở nên tự nhiên khi ta xem xét nó như một ánh xạ từ một tập hợp n vectơ trải rộng một đối tượng trong R^n Hóa ra định thức $\det(A)$ là thể tích có dấu của một hình hộp chữ nhật n chiều được tạo thành từ các cột của ma trận A .

Với $n = 2$, các cột của ma trận tạo thành một hình bình hành; xem Hình 4.2. Khi góc giữa các vectơ nhỏ đi, diện tích của hình bình hành cũng giảm đi. Xét hai vectơ b, g tạo thành các cột của ma trận $A = [b, g]$. Khi đó, giá trị tuyệt đối của định thức của A là diện tích của hình bình hành có các đỉnh $0, b, g, b + g$. Đặc biệt, nếu b, g phụ thuộc tuyến tính sao cho $b = \lambda g$ với một số $\lambda \in R$, chúng không còn tạo thành một hình bình hành hai chiều nữa. Do đó, diện tích tương ứng là 0. Ngược lại, nếu b, g độc lập tuyến tính và là bội số của các vectơ cơ sở chính tắc e_1, e_2 sau đó có thể được viết là $b = \begin{pmatrix} b_1 \\ 0 \end{pmatrix}$ và $g = \begin{pmatrix} 0 \\ g_2 \end{pmatrix}$, và định thức là

$\det \begin{pmatrix} b_1 & 0 \\ 0 & g_2 \end{pmatrix} = b_1 g_2$ Dấu của $\det A = b_1 g_2$ $0 = b_1 g_2$.
Định thức cho biết hướng của các vectơ sinh b, g so với cơ sở chuẩn (e_1, e_2) . Trong hình của chúng ta, việc đảo thứ tự thành g, b sẽ hoán đổi các cột của A và đảo ngược hướng của vùng được tô bóng. Điều này trở thành công thức quen thuộc: diện tích = chiều cao $\times$ chiều dài. Trực giác này mở rộng đến các chiều cao hơn. Trong R^3 , ba vectơ $r, b, g \in R^3$ sinh ra các cạnh của một hình hộp chữ nhật, tức là một khối rắn có các mặt là các hình bình hành song song (xem Hình 4.3). Dấu của giá trị định thức của ma trận $3 \times 3 [r, b, g]$ là thể tích của khối rắn. Do đó, định thức hoạt động như một hàm đo thể tích có dấu được tạo thành bởi các vectơ cột được kết hợp trong một ma trận.


Xét ba vectơ độc lập tuyến tính $r, g, b \in R^3$ được cho như sau:

$$r = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}, \quad g = \begin{pmatrix} 6 \\ 1 \\ 0 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 4 \\ 1 \end{pmatrix}.$$


(4.9)

Định thức là thể tích có dấu của hình hộp chữ nhật được tạo thành bởi các cột của ma trận.

Hình 4.2 Diện tích của hình bình hành (vùng được tô bóng) được tạo bởi các vectơ b và g là $|\det([b, g])|$.



Hình 4.3 Thể tích của hình hộp chữ nhật (thể tích được tô bóng) được tạo bởi các vectơ r, b, g là $|\det([r, b, g])|$.



yếu tố xác định cho biết hướng của các vectơ trải rộng.

Viết các vectơ này dưới dạng các cột của một ma trận.

$$A = [r, g, b] = \begin{pmatrix} 2 & 6 & 1 \\ 0 & 1 & 4 \\ 8 & 0 & 1 \end{pmatrix}$$

(4.10)

cho phép chúng ta tính toán thể tích mong muốn như sau:

$$V = |\det(A)| = 186.$$

(4.11)

Việc tính định thức của ma trận $n \times n$ đòi hỏi một thuật toán tổng quát để giải quyết các trường hợp $n > 3$, điều mà chúng ta sẽ tìm hiểu trong phần tiếp theo. Định lý 4.2 dưới đây quy giản bài toán tính định thức của ma trận $n \times n$ thành bài toán tính định thức của ma trận $(n-1) \times (n-1)$. Bằng cách áp dụng khai triển Laplace một cách đệ quy (Định lý 4.2), chúng ta có thể tính định thức của ma trận $n \times n$ bằng cách cuối cùng tính định thức của ma trận 2×2 .

Khai triển Laplace

Định lý 4.2 (Khai triển Laplace). Xét ma trận $A \in \mathbb{R}^{n \times n}$. Khi đó, với mọi $j = 1, \dots, n$:

1. Sự giãn nở dọc theo cột j

$$\det(A) = \sum_{k=1}^n (-1)^{k+j} a_{kj} \det(A_{k,j}).$$

(4.12)

2. Khai triển dọc theo hàng j

$$\det(A) = \sum_{k=1}^n (-1)^{k+j} a_{jk} \det(A_{j,k}).$$

(4.13)

Ở đây, $A_{k,j} \in \mathbb{R}^{(n-1) \times (n-1)}$ là ma trận con của A mà ta thu được khi xóa hàng k và cột j .

$\det(A_{k,j})$ được gọi là định thức con và $(-1)^{k+j} \det(A_{k,j})$ một đồng yếu tố.

Ví dụ 4.3 (Khai triển Laplace)

Hãy tính định thức của

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 3 & 1 & 2 \\ 0 & 0 & 1 \end{pmatrix}$$

(4.14)

sử dụng phép khai triển Laplace dọc theo hàng đầu tiên. Áp dụng (4.13) ta được

$$\begin{pmatrix} 1 & 2 & 3 \\ 3 & 1 & 2 \\ 0 & 0 & 1 \end{pmatrix} = (-1)^{1+1} \cdot 1 \det \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix} + (-1)^{1+2} \cdot 2 \det \begin{pmatrix} 3 & 2 \\ 0 & 1 \end{pmatrix} + (-1)^{1+3} \cdot 3 \det \begin{pmatrix} 3 & 1 \\ 0 & 0 \end{pmatrix}.$$

(4.15)

Chúng tôi sử dụng (4.6) để tính định thức của tất cả các ma trận 2×2 và thu được

$$\det(A) = 1(1 \cdot 0) - 2(3 \cdot 0) + 3(0 \cdot 0) = 5.$$

(4.16)

Để hoàn thiện, chúng ta có thể so sánh kết quả này với việc tính định thức bằng quy tắc của Sarrus (4.7):

$$\det(A) = 1 \cdot 1 \cdot 1 + 3 \cdot 0 \cdot 2 - 0 \cdot 1 \cdot 3 - 1 \cdot 0 \cdot 2 - 3 \cdot 2 \cdot 1 = 1 - 6 = -5.$$

(4.17)

Đối với $A \in M_n(\mathbb{R})$, định thức thể hiện các tính chất sau:

- Định thức của tích ma trận là tích của các định thức tương ứng, $\det(AB) = \det(A)\det(B)$.
- Định thức không thay đổi khi chuyển vị, tức là $\det(A) = \det(A^T)$. Nếu $A \in M_n(\mathbb{R})$ là ma trận chính quy (khả nghịch), thì $\det(A^{-1}) = \frac{1}{\det(A)}$.
- $\det(A)$. Các ma trận tương tự (Định nghĩa 2.22) có cùng định thức. Do đó, đối với một ánh xạ tuyến tính $\phi: V \rightarrow V$, tất cả các ma trận biến đổi A_ϕ của ϕ đều có cùng định thức. Như vậy, định thức không thay đổi khi lựa chọn cơ sở của một ánh xạ tuyến tính.
- Việc cộng bội số của một cột/hàng với một cột/hàng khác không làm thay đổi $\det(A)$.
- Phép nhân một cột/hàng với $\lambda \in \mathbb{R}$ sẽ nhân $\det(A)$ với λ . Cụ thể, $\det(\lambda A) = \lambda^n \det(A)$.
- Hoán đổi hai hàng/cột sẽ thay đổi dấu của $\det(A)$.

Do ba tính chất cuối cùng, chúng ta có thể sử dụng phép khử Gauss (xem Phần 2.1) để tính $\det(A)$ bằng cách đưa A về dạng bậc thang hàng. Chúng ta có thể dùng phép khử Gauss khi ta có A ở dạng tam giác trong đó các phần tử bên dưới đường chéo đều bằng 0. Nhờ lại từ (4.8) rằng định thức của ma trận tam giác là tích của các phần tử đường chéo.

Định lý 4.3. Một ma trận vuông $A \in M_n(\mathbb{R})$ có $\det(A) \neq 0$ nếu và chỉ nếu $\text{rk}(A) = n$. Nói cách khác, A khả nghịch nếu và chỉ nếu nó có hạng đầy đủ.

Khi toán học chủ yếu được thực hiện bằng tay, việc tính định thức được coi là một phương pháp thiết yếu để phân tích tính khả nghịch của ma trận. Tuy nhiên, các phương pháp hiện đại trong học máy sử dụng các phương pháp số trực tiếp thay thế cho việc tính toán định thức một cách tường minh. Ví dụ, trong Chương 2, chúng ta đã học rằng ma trận nghịch đảo có thể được tính bằng phép khử Gauss. Do đó, phép khử Gauss có thể được sử dụng để tính định thức của một ma trận.

Định thức sẽ đóng vai trò lý thuyết quan trọng trong các phần tiếp theo, đặc biệt là khi chúng ta tìm hiểu về giá trị riêng và vectơ riêng (Phần 4.2) thông qua đa thức đặc trưng.

Định nghĩa 4.4. Vết của ma trận vuông $A \in M_n(\mathbb{R})$ được định nghĩa như sau:

đấu vết

104

Phân rã ma trận

$$\operatorname{tr}(A) := \sum_{i=1}^n a_{ii}, \tag{4.18}$$

tức là , Vết của ma trận là tổng các phần tử trên đường chéo của ma trận A.

Dấu vết thỏa mãn các thuộc tính sau:

- $\operatorname{tr}(A + B) = \operatorname{tr}(A) + \operatorname{tr}(B)$ với $A, B \in M_n(R)$
- $\operatorname{tr}(\alpha A) = \alpha \operatorname{tr}(A)$, $\alpha \in R$ với $A \in M_n(R)$
- $\operatorname{tr}(I_n) = n$
- $\operatorname{tr}(AB) = \operatorname{tr}(BA)$ đối với $A \in M_{n \times k}(R)$, $B \in M_{k \times n}(R)$

Có thể chứng minh rằng chỉ có một hàm thỏa mãn cả bốn tính chất này cùng một lúc - đó là hàm vết (Gohberg et al., 2012).

Các tính chất của vết tích ma trận có tính tổng quát hơn. Cụ thể-

Về mặt lý thuyết, vết tích không thay đổi dưới các phép hoán vị vòng, tức là,

$$\operatorname{tr}(AKL) = \operatorname{tr}(KLA) \tag{4.19}$$

đối với các ma trận $A \in M_{n \times k}(R)$, $K \in M_{k \times l}(R)$, $L \in M_{l \times n}(R)$. Tính chất này được khái quát hóa thành tích của một số lượng ma trận tùy ý. Là trường hợp đặc biệt của (4.19), nó
Từ đó suy ra rằng với hai vectơ $x, y \in R^n$

$$\operatorname{tr}(xy^T) = \operatorname{tr}(y^T x) = y^T x \in R. \tag{4.20}$$

Cho một ánh xạ tuyến tính $\Phi : V \rightarrow V$, trong đó V là một không gian vectơ, chúng ta
Xác định vết của bản đồ này bằng cách sử dụng vết của biểu diễn ma trận.
của Φ . Với một cơ sở cho trước, chúng ta có thể mô tả Φ bằng phép biến đổi-
của ma trận thông tin V là A , thì vết của Φ là vết của A . Đối với một cơ sở khác,
cơ sở của V , Điều đó cho rằng ma trận biến đổi tương ứng B của Φ
có thể thu được bằng cách thay đổi cơ sở dạng $S^{-1}AS$ đối với S thích hợp (xem
Mục 2.7.2). Đối với vết tương ứng của Φ , điều này có nghĩa là

$$\operatorname{tr}(B) = \operatorname{tr}(S^{-1}AS) \stackrel{(4.19)}{=} \operatorname{tr}(ASS^{-1}) = \operatorname{tr}(A). \tag{4.21}$$

Do đó, trong khi biểu diễn ma trận của các ánh xạ tuyến tính phụ thuộc vào cơ sở
thì vết của một ánh xạ tuyến tính Φ lại không phụ thuộc vào cơ sở.

Trong phần này, chúng ta đã tìm hiểu về định thức và vết (trace) như những hàm
đặc trưng cho ma trận vuông. Tổng hợp lại những hiểu biết của chúng ta về định
thức và vết, giờ đây chúng ta có thể định nghĩa một phương trình quan trọng mô tả...
ma trận A được biểu diễn dưới dạng một đa thức, mà chúng ta sẽ sử dụng rộng rãi trong phần tiếp theo.
các phần tiếp theo.

Định nghĩa 4.5 (Đa thức đặc trưng). Đối với $\lambda \in R$ và ma trận vuông $A \in M_n(R)$

$$p_A(\lambda) := \det(A - \lambda I) = c_0 + \tag{4.22a}$$

$$c_1 \lambda + c_2 \lambda^2 + \dots + c_{n-1} \lambda^{n-1} + c_n \lambda^n + (-1)^n \lambda^n, \tag{4.22b}$$

$c_0, \dots, c_{n-1} \in R$ là đa thức đặc trưng của A . Cụ thể,

4.2 Giá trị riêng và vectơ riêng

105

$$c_0 = \det(A),$$

(4.23)

$$c_{n-1} = (-1)^{n-1} \operatorname{tr}(A).$$

(4.24)

Đa thức đặc trưng (4.22a) sẽ cho phép chúng ta tính toán các giá trị riêng và vectơ riêng, được trình bày trong phần tiếp theo.

4.2 Giá trị riêng và vectơ riêng

Bây giờ chúng ta sẽ tìm hiểu một cách mới để mô tả ma trận và ánh xạ tuyến tính liên kết với nó. Hãy nhớ lại từ Mục 2.7.1 rằng mọi ánh xạ tuyến tính T có một ma trận biến đổi duy nhất khi được xác định trước một cơ sở có thứ tự. Chúng ta có thể diễn giải các ánh xạ tuyến tính và các ma trận biến đổi liên quan của chúng bằng cách thực hiện phân tích "giá trị riêng". Như chúng ta sẽ thấy, các giá trị riêng của một tuyến tính - Eigen là một thuật ngữ tiếng Đức. Việc lập bản đồ tại sẽ cho chúng ta biết một tập hợp các vectơ đặc biệt, các vectơ riêng, hoạt động như thế nào. được biến đổi bởi phép ánh xạ tuyến tính.

ý nghĩa của từ "đặc điểm", "bản thân", hoặc "của riêng".

Định nghĩa 4.6. Cho $A \in \mathbb{R}^{n \times n}$ là một ma trận vuông. Khi đó $\lambda \in \mathbb{R}$ là một ma trận vuông. Giá trị riêng của A và $x \in \mathbb{R}^n \setminus \{0\}$ là vectơ riêng tương ứng của A nếu

$$Ax = \lambda x.$$

(4.25)

giá trị riêng
vectơ riêng
phương trình giá trị riêng

Chúng tôi gọi (4.25) là phương trình giá trị riêng.

Lưu ý. Trong tài liệu và phần mềm về đại số tuyến tính, thường có quy ước rằng các giá trị riêng được sắp xếp theo thứ tự giảm dần, sao cho giá trị riêng lớn nhất đứng đầu. Giá trị riêng và vectơ riêng tương ứng được gọi là giá trị riêng thứ nhất và vectơ riêng tương ứng của nó, và giá trị lớn thứ hai được gọi là giá trị riêng thứ hai và vectơ riêng tương ứng của nó, v.v. Tuy nhiên, sách giáo khoa và Các ấn phẩm có thể có quan niệm khác nhau hoặc không có quan niệm nào về thứ tự sắp xếp. Chúng tôi không muốn Không nên mặc định rằng cuốn sách này có thứ tự sắp xếp nhất định nếu không được nêu rõ.

- Các phát biểu sau đây tương đương nhau:
- λ là một giá trị riêng của $A \in \mathbb{R}^{n \times n}$.
 - Tồn tại một $x \in \mathbb{R}^n \setminus \{0\}$ sao cho $Ax = \lambda x$, hay tương đương với $(A - \lambda I)x = 0$ có thể được giải một cách không tầm thường, tức là $x \neq 0$.
 - $\operatorname{rk}(A - \lambda I) < n$.
 - $\det(A - \lambda I) = 0$.

Định nghĩa 4.7 (Đồng tuyến và cùng hướng). Hai vectơ cùng chỉ vào một điểm. Các vectơ cùng hướng được gọi là cùng chiều. Hai vectơ được gọi là cùng phương nếu chúng cùng chiều. Chỉ theo cùng hướng hoặc hướng ngược lại.

thẳng hàng

Lưu ý (Tính không duy nhất của các vectơ riêng). Nếu x là một vectơ riêng của A liên quan đến giá trị riêng λ , thì với bất kỳ $c \in \mathbb{R} \setminus \{0\}$ nào, điều đó đúng rằng cx là một vectơ riêng của A có cùng giá trị riêng vì

$$A(cx) = cAx = c\lambda x = \lambda(cx).$$

(4.26)

Do đó, tất cả các vectơ cùng phương với x đều là vectơ riêng của A .

106

Phân rã ma trận

Định lý 4.8. $\lambda \in \mathbb{R}$ là giá trị riêng của $A \in \mathbb{R}^{n \times n}$ nếu và chỉ nếu λ là một nghiệm của đa thức đặc trưng $p_A(\lambda)$ của A .

bội số đại số

Định nghĩa 4.9. Cho ma trận vuông A có giá trị riêng λ_i . Đại số bội bậc của λ_i là số lần nghiệm xuất hiện trong đa thức đặc trưng.

không gian

riêng phổ riêng

quang phổ

Định nghĩa 4.10 (Không gian riêng và phổ riêng). Với $A \in \mathbb{R}^{n \times n}$, bộ tập hợp tất cả các vectơ riêng của A liên kết với một giá trị riêng λ tạo thành một không gian con của $\mathbb{R}^n$, được gọi là không gian con riêng của A đối với λ và được ký hiệu là E_λ . Tập hợp tất cả các giá trị riêng của A được gọi là phổ giá trị riêng, hoặc đơn giản là phổ, của A .

Nếu λ là giá trị riêng của $A \in \mathbb{R}^{n \times n}$, sau đó E_λ là không gian riêng tương ứng. E_λ là không gian nghiệm của hệ phương trình tuyến tính thuần nhất $(A - \lambda I)x = 0$. Về mặt hình học, vectơ riêng tương ứng với một giá trị khác không. Các điểm giá trị riêng nằm theo hướng bị kéo giãn bởi phép biến đổi tuyến tính. Giá trị riêng là hệ số mà nó được kéo giãn. Nếu giá trị riêng là Âm, hướng kéo giãn bị đảo ngược.

Ví dụ 4.4 (Trường hợp ma trận đơn vị)
Ma trận đơn vị $I \in \mathbb{R}^{n \times n}$ có đa thức đặc trưng $p_I(\lambda) = \det(I - \lambda I) = (1 - \lambda)^n = 0$, chỉ có một giá trị riêng $\lambda = 1$ xuất hiện n lần. Hơn nữa, $Ix = \lambda x = 1x$ đúng với mọi vectơ $x \in \mathbb{R}^n \setminus \{0\}$. Do đó, không gian riêng duy nhất E_1 của ma trận đơn vị trải rộng trên n chiều, và tất cả n vectơ cơ sở chuẩn của $\mathbb{R}^n$ đều là vectơ riêng của I .

Các tính chất hữu ích liên quan đến giá trị riêng và vectơ riêng bao gồm: tiếp theo:

- Ma trận A và ma trận chuyển vị của nó là A^T có cùng giá trị riêng, nhưng không phải nhất thiết phải có cùng các vectơ riêng.
- Không gian riêng E_λ là không gian rỗng của $A - \lambda I$ vì

$Ax = \lambda x \iff Ax - \lambda x = 0$

(4.27a)

$(A - \lambda I)x = 0 \iff x \in \ker(A - \lambda I).$

(4.27b)

- Các ma trận tương tự (xem Định nghĩa 2.22) có cùng các giá trị riêng. Do đó, một ánh xạ tuyến tính Φ có các giá trị riêng không phụ thuộc vào việc lựa chọn cơ sở của ma trận biến đổi của nó. Điều này tạo ra các giá trị riêng, Cùng với định thức và vết, đây là những tham số đặc trưng quan trọng của một phép ánh xạ tuyến tính vì chúng đều bất biến khi thay đổi cơ sở.
- Các ma trận đối xứng, xác định dương luôn có các giá trị riêng thực dương.

4.2 Giá trị riêng và vectơ riêng

107

Ví dụ 4.5 (Tính giá trị riêng, vectơ riêng và...)

Không gian riêng)

Hãy tìm các giá trị riêng và vectơ riêng của ma trận 2×2 .

$$A = \begin{pmatrix} 4 & 2 \\ 1 & 3 \end{pmatrix}. \quad (4.28)$$

Bước 1: Đa thức đặc trưng. Từ định nghĩa vectơ riêng $x \neq 0$ và giá trị riêng λ của A , sẽ có một vectơ sao cho

$Ax = \lambda x$, tức là $(A - \lambda I)x = 0$. Vì $x \neq 0$, điều này đòi hỏi hạt nhân phải như vậy.

(Không gian rỗng) của $A - \lambda I$ chứa nhiều phần tử hơn 0. Điều này có nghĩa là rằng $A - \lambda I$ không khả nghịch và do đó $\det(A - \lambda I) = 0$. Vì vậy, chúng ta cần tính các nghiệm của đa thức đặc trưng (4.22a) để tìm các giá trị riêng.

Bước 2: Giá trị riêng. Đa thức đặc trưng là

$$p_A(\lambda) = \det(A - \lambda I) \quad (4.29a)$$

$$= \text{xác định} \begin{vmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{vmatrix} = \begin{vmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{vmatrix} \quad (4.29b)$$

$$= (4 - \lambda)(3 - \lambda) - 2 \cdot 1. \quad (4.29c)$$

Chúng ta phân tích đa thức đặc trưng thành thừa số và thu được

$$p(\lambda) = (4 - \lambda)(3 - \lambda) - 2 \cdot 1 = 10 - 7\lambda + \lambda^2 = (\lambda - 2)(\lambda - 5) \quad (4.30)$$

Từ đó suy ra các nghiệm $\lambda_1 = 2$ và $\lambda_2 = 5$.

Bước 3: Vectơ riêng và không gian riêng. Chúng ta tìm các vectơ riêng thỏa mãn điều kiện sau: Tương ứng với các giá trị riêng này bằng cách xem xét các vectơ x sao cho

$$\begin{pmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{pmatrix} x = 0. \quad (4.31)$$

Với $\lambda = 5$, ta thu được

$$\begin{pmatrix} 4 - 5 & 2 \\ 1 & 3 - 5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -1 & 2 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 0. \quad (4.32)$$

Chúng ta giải hệ phương trình thuần nhất này và thu được không gian nghiệm.

$$E_5 = \text{span} \left\{ \begin{pmatrix} 2 \\ 1 \end{pmatrix} \right\}. \quad (4.33)$$

Không gian riêng này là không gian một chiều vì nó chỉ có một vectơ cơ sở.

Tương tự, ta tìm vectơ riêng cho $\lambda = 2$ bằng cách giải hệ phương trình thuần nhất.

$$\begin{pmatrix} 4 - 2 & 2 \\ 1 & 3 - 2 \end{pmatrix} x = \begin{pmatrix} 2 & 2 \\ 1 & 1 \end{pmatrix} x = 0. \quad (4.34)$$

Điều này có nghĩa là bất kỳ vectơ x nào = $\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$, trong đó $x_2 = x_1$, chẳng hạn như $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$, là một vectơ riêng với giá trị riêng là 2. Không gian riêng tương ứng được cho như sau:

$$E_2 = \text{span}\left\{\begin{pmatrix} 1 \\ 1 \end{pmatrix}\right\}. \tag{4.35}$$

Hai không gian con riêng E_1 và E_2 trong Ví dụ 4.5 là không gian một chiều vì mỗi không gian được tạo bởi một vectơ duy nhất. Tuy nhiên, trong các trường hợp khác, chúng ta có thể có nhiều giá trị riêng giống nhau (xem Định nghĩa 4.9) và không gian con riêng có thể có nhiều hơn một chiều.

Định nghĩa 4.11. Cho λ là một giá trị riêng của ma trận vuông A . Khi đó, bội số hình học của λ là số lượng các vectơ riêng độc lập tuyến tính liên kết với λ . Nói cách khác, đó là số chiều của không gian riêng được tạo bởi các vectơ riêng liên kết với λ .

Lưu ý: Bội số hình học của một giá trị riêng cụ thể phải ít nhất là một vì mỗi giá trị riêng đều có ít nhất một vectơ riêng tương ứng. Bội số hình học của một giá trị riêng không thể vượt quá bội số đại số của nó, nhưng có thể thấp hơn.

Ví dụ 4.6

Ma trận $A = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$ có hai giá trị riêng lặp lại $\lambda_1 = \lambda_2 = 2$ và một bội số đại số là 2. Tuy nhiên, giá trị riêng chỉ có một giá trị riêng biệt. Vectơ riêng đơn vị $x_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ và do đó, bội số hình học là 1.

Trực quan đồ họa trong không gian hai


chiều Hãy cùng tìm hiểu trực quan về định thức, vectơ riêng và giá trị riêng bằng cách sử dụng các phép ánh xạ tuyến tính khác nhau. Hình 4.4 mô tả năm ma trận biến đổi $A_1, \dots, A_5$ và tác động của chúng lên một lưới vuông các điểm, tâm nằm ở gốc tọa độ:

- $A_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ Hướng của hai vectơ riêng tương ứng với... vectơ cơ sở chính tắc trong $\mathbb{R}^2$, tức là, đối với hai trục chính. Trục dọc được mở rộng gấp 2 lần (giá trị riêng $\lambda_1 = 2$), và trục ngang bị thu hẹp đi một hệ số (giá trị riêng $\lambda_2 = \frac{1}{2}$). Phép ánh xạ này bảo toàn diện tích ($\det(A_1) = 1 = 2 \cdot \frac{1}{2}$).
- $A_2 = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$ Tương ứng với một phép biến đổi trượt, tức là nó trượt các điểm dọc theo trục ngang sang bên phải nếu chúng nằm trên trục dương.

Trong hình học, tính chất bảo toàn diện tích của kiểu biến dạng cắt song song với một trục này còn được gọi là nguyên lý Cavalieri về diện tích bằng nhau của hình bình hành (Katz, 2004).

4.2 Giá trị riêng và vectơ riêng

109



Hình 4.4 Các yếu tố quyết định và không gian riêng. Tổng quan về năm ánh xạ tuyến tính và phép biến đổi liên quan

Các ma trận A_i 2×2 chiều 400 điểm mẫu $\times$ 2 (cột bên trái) lên các điểm đích A_i (cột bên phải). Cột ở giữa mô tả vectơ riêng đầu tiên, được kéo giãn bởi hệ số của nó.

Có liên quan giá trị riêng λ_1 và giá trị riêng thứ hai λ_2 được kéo giãn bởi giá trị riêng λ_2 của nó. Mỗi hàng mô tả tác động của một trong năm phép biến đổi. Các ma trận A_i đối với cơ sở chuẩn.

một nửa trục dọc, và ngược lại về bên trái. Phép ánh xạ này bảo toàn diện tích ($\det(A_2) = 1$). Giá trị riêng $\lambda_1 = 1 = \lambda_2$ được lặp lại và các vectơ riêng thẳng hàng (được vẽ ở đây để nhấn mạnh theo hai hướng ngược nhau). Điều này cho thấy phép ánh xạ chỉ tác động dọc theo một hướng (trục ngang). $\sqrt{3}$ $\cos(\pi)$ $\sin(\pi)$ $\sqrt{3}$

- $A_3 = \begin{pmatrix} \cos(\pi/6) & -\sin(\pi/6) \\ \sin(\pi/6) & \cos(\pi/6) \end{pmatrix} = \begin{pmatrix} \sqrt{3}/2 & -1/2 \\ 1/2 & \sqrt{3}/2 \end{pmatrix}$ — Ma trận A_3 xoay điểm theo giá $\pi/6$ rad = 30° ngược chiều kim đồng hồ và chỉ có giá trị riêng phức. π , phản ánh rằng phép biến đổi là một phép quay (do đó, không có vectơ riêng nào được vẽ). Phép quay phải bảo toàn thể tích, và do đó định thức là 1. Để biết thêm chi tiết về phép quay, chúng tôi tham khảo Mục 3.9. $\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$

- $A_4 =$ biểu thị một ánh xạ trong cơ sở chuẩn mà... thu hẹp miền hai chiều xuống còn một chiều. Vì một giá trị riêng-

Khi giá trị là 0, không gian theo hướng của vectơ riêng (màu xanh) tương ứng với $\lambda_1 = 0$ bị thu hẹp, trong khi vectơ riêng vuông góc (màu đỏ) làm giãn không gian lên một hệ số $\lambda_2 = 2$. Do đó, diện tích của ảnh bằng 0.


■ $A_5 = \begin{pmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{pmatrix}$ Đây là một phép biến đổi biến dạng và kéo giãn giúp mở rộng không gian lên 75%.

vì $|\det(A_5)| = 1.5$ Nó kéo giãn không gian dọc theo vectơ riêng (màu đỏ) của λ_2 với hệ số 1,5 và nén nó dọc theo vectơ riêng vuông góc (màu xanh) với hệ số 0,5.

Ví dụ 4.7 (Phổ giá trị riêng của mạng nơ-ron sinh học)

Hình 4.5
Caenorhabditis
mạng lưới thần
kinh elegans (Kaiser và
Hilgetag,
2006). (a) Đối xứng

(b) Ma trận kết nối;
(b) Phổ giá trị riêng.



Các phương pháp phân tích và học hỏi từ dữ liệu mạng là một thành phần thiết yếu của các phương pháp học máy. Chìa khóa để hiểu mạng lưới nằm ở khả năng kết nối giữa các nút mạng, đặc biệt là việc hai nút có được kết nối với nhau hay không. Trong các ứng dụng khoa học dữ liệu, việc nghiên cứu ma trận thể hiện dữ liệu kết nối này thường rất hữu ích.

Chúng ta xây dựng ma trận kết nối/kề nhau $A \in \mathbb{R}^{277 \times 277}$ của toàn bộ mạng lưới thần kinh của giun C.Elegans. Mỗi hàng/cột đại diện cho một trong 277 tế bào thần kinh của não giun này. Ma trận kết nối A có giá trị $a_{ij} = 1$ nếu tế bào thần kinh i giao tiếp với tế bào thần kinh j thông qua một khớp thần kinh, và $a_{ij} = 0$ trong trường hợp ngược lại. Ma trận kết nối không đối xứng, điều này ngụ ý rằng các giá trị riêng có thể không phải là giá trị thực. Do đó, chúng ta tính toán a . Điều này

Phiên bản đối xứng hóa của ma trận kết nối là $Asym := A + A^T$. Ma trận mới $Asym$ được thể hiện trong Hình 4.5(a) và có giá trị khác 0 là a_{ij} nếu và chỉ nếu hai nơ-ron được kết nối (các pixel màu trắng), bất kể hướng kết nối. Trong Hình 4.5(b), chúng ta thể hiện phổ giá trị riêng tương ứng của $Asym$. Trục hoành thể hiện chỉ số của các giá trị riêng, được sắp xếp theo thứ tự giảm dần. Trục tung thể hiện giá trị riêng tương ứng. Hình dạng chữ S của phổ giá trị riêng này là điển hình cho nhiều mạng lưới thần kinh sinh học. Cơ chế cơ bản chịu trách nhiệm cho điều này là một lĩnh vực nghiên cứu khoa học thần kinh đang được tích cực nghiên cứu.

4.2 Giá trị riêng và vectơ riêng

111

Định lý 4.12. Các vectơ riêng $x_1, \dots, x_n$ của ma trận $A \in \mathbb{R}^{n \times n}$ với n giá trị riêng khác nhau $\lambda_1, \dots, \lambda_n$ là độc lập tuyến tính.

Định lý này phát biểu rằng các vectơ riêng của một ma trận có n giá trị riêng khác nhau tạo thành một cơ sở của $\mathbb{R}^n$.

Định nghĩa 4.13. Một ma trận vuông $A \in \mathbb{R}^{n \times n}$ được gọi là ma trận khiếm khuyết nếu nó có ít hơn n vectơ riêng độc lập tuyến tính bị khiếm khuyết.

Một ma trận không khiếm khuyết $A \in \mathbb{R}^{n \times n}$ không nhất thiết phải có n giá trị riêng khác nhau, nhưng nó yêu cầu các vectơ riêng tạo thành một cơ sở của $\mathbb{R}^n$. Khi xem xét các không gian riêng của một ma trận khiếm khuyết, ta thấy rằng tổng số chiều của các không gian riêng nhỏ hơn n . Cụ thể, một ma trận khiếm khuyết có ít nhất một giá trị riêng λ với bội số đại số $m > 1$ và bội số hình học nhỏ hơn m .

Lưu ý: Ma trận khiếm khuyết không thể có n giá trị riêng khác nhau, vì các giá trị riêng khác nhau có các vectơ riêng độc lập tuyến tính (Định lý 4.12).

Định lý 4.14. Cho ma trận $A \in \mathbb{R}^{m \times n}$, ta có ma trận $S \in \mathbb{R}^{n \times n}$, chúng ta luôn có thể đạt được một sự đối xứng-
trận bán xác định dương $S \in \mathbb{R}^{n \times n}$ bằng cách định nghĩa

$$S := A^T A. \quad (4.36)$$

Lưu ý. Nếu $\text{rk}(A) = n$, thì $S := A^T A$ là ma trận đối xứng, xác định dương. Hiểu

được lý do tại sao Định lý 4.14 đúng sẽ giúp chúng ta hiểu rõ hơn cách chúng ta có thể

sử dụng ma trận đối xứng: Tính đối xứng yêu cầu $S = S^T$ và bằng cách chèn
(4.36) ta thu được $S = A^T A = A^T A = (A^T A)^T$, tính bán $= S^T$. Xem thêm-
xác định dương (Mục 3.2.3) yêu cầu $x^T S x \geq 0$ và bằng cách chèn (4.36)
ta thu được $x^T S x = x^T A^T A x = (A x)^T (A x) = \|A x\|^2 \geq 0$, bởi vì
tích vô hướng tính tổng bình phương (bản thân chúng không âm).

Định lý 4.15 (Định lý phổ). Nếu $A \in \mathbb{R}^{n \times n}$ là đối xứng, thì tồn tại một cơ sở trực chuẩn của không gian vectơ tương ứng V bao gồm các vectơ riêng của A , và mỗi giá trị riêng đều là số thực. định lý phổ

Một hệ quả trực tiếp của định lý phổ là phép phân tích giá trị riêng của ma trận đối xứng A tồn tại (với các giá trị riêng thực), và ta có thể tìm được một tập hợp vectơ riêng (ONB) sao cho $A = P D P^T$, trong đó D là ma trận đường chéo và các cột của P chứa các vectơ riêng.

Ví dụ 4.8 Xét ma trận

$$A = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{pmatrix}. \quad (4.37)$$

Đa thức đặc trưng của A là

$$p_A(\lambda) = (\lambda - 1)^2 (\lambda - 7), \quad (4.38)$$

Để ta thu được các giá trị riêng $\lambda_1 = 1$ và $\lambda_2 = 7$, trong đó λ_1 là giá trị riêng lặp lại. Theo quy trình chuẩn của chúng tôi để tính toán các vectơ riêng, ta thu được các không gian riêng.

$$E_1 = \text{span} \left[\begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \right], \quad E_7 = \text{span} \left[\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \right]. \quad (4.39)$$

$\begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} =: x_1, \quad \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} =: x_2, \quad \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} =: x_3$

Ta thấy rằng x_3 vuông góc với cả x_1 và x_2 . Tuy nhiên, vì $x_1 \cdot x_2 = 1 \neq 0$, chúng không trực giao. Định lý phổ (Định lý 4.15) phát biểu rằng tồn tại một cơ sở trực giao, nhưng cơ sở chúng ta có không phải là trực giao. Tuy nhiên, chúng ta có thể xây dựng một cơ sở như vậy.

Để xây dựng cơ sở như vậy, chúng ta khai thác thực tế rằng x_1, x_2 là các vectơ riêng liên kết với cùng một giá trị riêng λ . Do đó, với bất kỳ $\alpha, \beta \in \mathbb{R}$ nào, điều sau đây đúng:

$$A(\alpha x_1 + \beta x_2) = A\alpha x_1 + A\beta x_2 = \lambda(\alpha x_1 + \beta x_2), \quad (4.40)$$

Tức là, bất kỳ tổ hợp tuyến tính nào của x_1 và x_2 cũng là một vectơ riêng của A liên kết với λ . Thuật toán Gram-Schmidt (Mục 3.8.3) là một phương pháp xây dựng lặp đi lặp lại một cơ sở trực giao/trực chuẩn từ một tập hợp các vectơ cơ sở bằng cách sử dụng các tổ hợp tuyến tính như vậy. Do đó, ngay cả khi x_1 và x_2 không trực giao, chúng ta vẫn có thể áp dụng thuật toán Gram-Schmidt và tìm các vectơ riêng liên kết với $\lambda_1 = 1$ mà trực giao với nhau (và với x_3). Trong ví dụ của chúng ta, chúng ta sẽ thu được

$$x_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad x_2 = \frac{1}{2} \begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix}, \quad (4.41)$$

Chúng vuông góc với nhau, vuông góc với x_3 và là các vectơ riêng của A liên kết với $\lambda_1 = 1$.

Trước khi kết thúc phần xem xét về giá trị riêng và vectơ riêng, điều hữu ích là liên kết các đặc tính ma trận này với các khái niệm về định thức và vết.


Định lý 4.16. Định thức của ma trận $A \in \mathbb{R}^{n \times n}$ là tích các giá trị riêng của nó, tức là,

$$\det(A) = \prod_{i=1}^n \lambda_i, \quad (4.42)$$

trong đó $\lambda_i \in \mathbb{C}$ là các giá trị riêng (có thể lặp lại) của A .

4.2 Giá trị riêng và vectơ riêng

113



Hình 4.6

Hình học

Giải thích các giá trị riêng. Các vectơ riêng của ma trận A bị kéo giãn bởi các giá trị riêng tương ứng. Diện tích của đơn vị khi bình phương thay đổi một lượng $|\lambda_1\lambda_2|$, chu vi thay đổi một hệ số là $\frac{1}{2}(|\lambda_1| + |\lambda_2|)$.

Định lý 4.17. Vết của ma trận A $n \times n$ là tổng các giá trị riêng của nó, tức là,

$$\text{tr}(A) = \sum_{i=1}^n \lambda_i, \quad (4.43)$$

trong đó λ_i là các giá trị riêng (có thể lặp lại) của A .

Chúng ta hãy cùng tìm hiểu trực quan về hình học của hai định lý này. Xét ma trận A 2×2 có hai vectơ riêng độc lập tuyến tính x_1, x_2 . Trong ví dụ này, ta giả sử (x_1, x_2) là một ONB của $\mathbb{R}^2$ sao cho chúng trực giao và diện tích của hình vuông mà chúng tạo thành là 1; xem Hình 4.6.

Từ Mục 4.1, chúng ta biết rằng định thức tính toán sự thay đổi diện tích của hình vuông đơn vị dưới phép biến đổi A . Trong ví dụ này, chúng ta có thể tính toán sự thay đổi diện tích một cách rõ ràng: Ánh xạ các vectơ riêng bằng A cho ta các vectơ $v_1 = Ax_1 = \lambda_1 x_1$ và $v_2 = Ax_2 = \lambda_2 x_2$, tức là, các vectơ mới là các phiên bản được nhân tỷ lệ của các vectơ riêng x_i và các hệ số nhân tỷ lệ là các giá trị riêng tương ứng λ_i . v_1, v_2 vẫn trực giao, và diện tích của hình chữ nhật mà chúng tạo thành là $|\lambda_1\lambda_2|$.

Vì x_1, x_2 (trong ví dụ của chúng ta) là các vectơ trực chuẩn, ta có thể tính trực tiếp chu vi của hình vuông đơn vị là $2(1 + 1)$. Ánh xạ các vectơ riêng bằng A tạo ra một hình chữ nhật có chu vi là $2(|\lambda_1| + |\lambda_2|)$.

Do đó, tổng các giá trị tuyệt đối của các giá trị riêng cho ta biết chu vi của hình vuông đơn vị thay đổi như thế nào dưới ma trận biến đổi A .

Ví dụ 4.9 (PageRank của Google - Các trang web như là vectơ riêng)

Google sử dụng vectơ riêng tương ứng với giá trị riêng lớn nhất của ma trận A để xác định thứ hạng của một trang web trong kết quả tìm kiếm. Ý tưởng cho thuật toán PageRank, được phát triển tại Đại học Stanford bởi Larry Page và Sergey Brin vào năm 1996, là tầm quan trọng của bất kỳ trang web nào có thể được ước tính bằng tầm quan trọng của các trang liên kết đến nó. Để làm được điều này, họ viết tất cả các trang web dưới dạng một đồ thị có hướng khổng lồ cho thấy trang nào liên kết đến trang nào. PageRank tính toán trọng số (tầm quan trọng) x_i của một trang web ai bằng cách đếm số lượng trang trỏ đến ai. Hơn nữa, PageRank cũng tính đến tầm quan trọng của các trang web liên kết đến ai. Hành vi điều hướng của người dùng sau đó được mô hình hóa bằng ma trận chuyển đổi A của đồ thị này, cho chúng ta biết xác suất (nhấp chuột) mà ai đó sẽ kết thúc ở đâu.

PageRank

trên một trang web khác. Ma trận A có thuộc tính là đối với bất kỳ vectơ hạng/độ quan trọng ban đầu x nào của một trang web, chuỗi $x, Ax, A^2x, \dots$ hội tụ về một vectơ x . Vectơ này được gọi là PageRank và thỏa mãn điều kiện sau: $Ax = x$. Tức là, nó là một vectơ riêng (với giá trị riêng tương ứng là 1) A . Sau khi chuẩn hóa x , sao cho $\sum x_i = 1$, ta có thể diễn giải các mục thành xác suất. Thông tin chi tiết hơn và các quan điểm khác nhau về PageRank có thể được tìm thấy trong báo cáo kỹ thuật gốc (Page et al., 1999).

4.3 Phân rã Cholesky

Phân rã
Cholesky

Phân
tích Cholesky

Có nhiều cách để phân tích các loại ma trận đặc biệt mà chúng ta thường gặp trong học máy. Trong tập số thực dương, ta có phép toán căn bậc hai, cho phép phân tích số thành các thành phần giống hệt nhau, ví dụ: $9 = 3 \cdot 3$. Đối với ma trận, ta cần cẩn thận khi thực hiện phép toán tương tự như căn bậc hai trên các đại lượng dương. Đối với các ma trận đối xứng, xác định dương (xem Mục 3.2.3), ta có thể chọn từ một số phép toán tương đương với căn bậc hai. Phép phân tích Cholesky/ phân tích thừa số Cholesky cung cấp một phép toán tương đương với căn bậc hai trên các ma trận đối xứng, xác định dương, rất hữu ích trong thực tế.

Định lý 4.18 (Phân tích Cholesky). Một ma trận đối xứng, xác định dương A có thể được phân tích thành tích $A = LL^T$, trong đó L là ma trận tam giác dưới với các phần tử đường chéo dương:

$$\begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & \dots & 0 \\ \vdots & \ddots & \vdots \\ l_{n1} & \dots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & \dots & l_{n1} \\ \vdots & \ddots & \vdots \\ 0 & \dots & l_{nn} \end{bmatrix} \quad (4.44)$$

Yếu tố Cholesky

L được gọi là thừa số Cholesky của A , và L là duy nhất.

Ví dụ 4.10 (Phân tích Cholesky)

Xét ma trận đối xứng, xác định dương $A \in \mathbb{R}^{3 \times 3}$. Chúng ta quan tâm đến việc tìm phân tích Cholesky của nó $A = LL^T$, tức là,

$$A = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = LL^T = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ 0 & l_{22} & l_{32} \\ 0 & 0 & l_{33} \end{bmatrix} \quad (4.45)$$

Nhân vế phải ra ta được

$$A = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix} \quad (4.46)$$

So sánh vế trái của (4.45) và vế phải của (4.46) cho thấy có một quy luật đơn giản trong các phần tử đường chéo lii:

$$l_{11} = \sqrt{a_{11}}, \quad l_{22} = \sqrt{a_{22} - l_{21}^2}, \quad l_{33} = \sqrt{a_{33} - (l_{31}^2 + l_{32}^2)}. \quad (4.47)$$

Tương tự, đối với các phần tử nằm dưới đường chéo (l_{ij} , trong đó $i > j$), cũng có một mô hình lặp lại:

$$l_{21} = \frac{1}{l_{11}} a_{21}, \quad l_{31} = \frac{1}{l_{11}} a_{31}, \quad l_{32} = \frac{1}{l_{22}} (a_{32} - l_{31} l_{21}). \quad (4.48)$$

Như vậy, chúng tôi đã xây dựng phép phân rã Cholesky cho bất kỳ ma trận 3×3 đối xứng, xác định dương nào. Điểm mấu chốt là chúng ta có thể tính toán ngược lại các thành phần l_{ij} của L , dựa trên các giá trị a_{ij} của A và các giá trị l_{ij} đã được tính toán trước đó.

Phép phân rã Cholesky là một công cụ quan trọng cho các phép tính số học làm nền tảng cho học máy. Ở đây, các ma trận đối xứng xác định dương cần được thao tác thường xuyên, ví dụ, ma trận hiệp phương sai của một biến ngẫu nhiên Gauss đa chiều (xem Phần 6.5) là đối xứng, xác định dương. Phép phân tích Cholesky của ma trận hiệp phương sai này cho phép chúng ta tạo ra các mẫu từ phân phối Gauss. Nó cũng cho phép chúng ta thực hiện phép biến đổi tuyến tính của các biến ngẫu nhiên, điều này được khai thác triệt để khi tính toán gradient trong các mô hình ngẫu nhiên sâu, chẳng hạn như bộ mã hóa tự động biến phân (Jimenez Rezende et al., 2014; Kingma và Welling, 2014). Phép phân rã Cholesky cũng cho phép chúng ta tính toán định thức một cách rất hiệu quả. Với phép phân rã Cholesky $A = LL^T$, ta biết rằng $\det(A) = \det(L)^2$. Vì L là một tam giác dưới, $\det(L) = \prod_{i=1}^n l_{ii}$, do đó $\det(A) = \prod_{i=1}^n l_{ii}^2$. Vì vậy, nhiều gói phần mềm tính toán số sử dụng phép phân rã Cholesky để thực hiện các phép tính hiệu quả hơn.

4.4 Phân tích giá trị riêng và chéo hóa

Ma trận chéo là ma trận có tất cả các phần tử ngoài đường chéo đều bằng 0, tức là chúng có dạng 1.

$$D = \begin{pmatrix} c_1 & & & 0 \\ & \ddots & & \\ & & \ddots & \\ 0 & & & c_n \end{pmatrix}. \quad (4.49)$$

Chúng ta cho phép tính toán nhanh các định thức, lũy thừa và ma trận nghịch đảo. Định thức là tích của các phần tử trên đường chéo chính, lũy thừa ma trận D^k được tính bằng mỗi phần tử trên đường chéo chính được nâng lên lũy thừa k , và ma trận nghịch đảo D^{-1} là nghịch đảo của các phần tử trên đường chéo chính nếu tất cả chúng đều khác 0.

Trong phần này, chúng ta sẽ thảo luận về cách chuyển đổi ma trận thành ma trận chéo.

Đây là một ứng dụng quan trọng của phép biến đổi cơ sở mà chúng ta đã thảo luận trong Phần 2.7.2 và các giá trị riêng từ Phần 4.2.

Nhớ lại rằng hai ma trận A , D được gọi là tương tự (Định nghĩa 2.22) nếu tồn tại một ma trận khả nghịch P , sao cho $D = P^{-1}AP$. Cụ thể hơn, chúng ta sẽ xem xét các ma trận A tương tự như các ma trận đường chéo D chứa các giá trị riêng của A trên đường chéo.

có thể chéo hóa

Định nghĩa 4.19 (Có thể chéo hóa). Một ma trận $A \in \mathbb{R}^{n \times n}$ được gọi là có thể chéo hóa nếu nó tương tự với một ma trận đường chéo, tức là, nếu tồn tại một ma trận khả nghịch $P \in \mathbb{R}^{n \times n}$ sao cho $D = P^{-1}AP$.

Trong phần tiếp theo, chúng ta sẽ thấy rằng việc chéo hóa ma trận $A \in \mathbb{R}^{n \times n}$ là một cách để biểu diễn cùng một ánh xạ tuyến tính nhưng trong một cơ sở khác (xem Mục 2.6.1), cơ sở này sẽ bao gồm các vectơ riêng của A .

Cho $A \in \mathbb{R}^{n \times n}$, $p_1, \dots, p_n$ là một tập hợp các vectơ trong $\mathbb{R}^n$. Ta định nghĩa $P := [p_1, \dots, p_n]$ và cho $D \in \mathbb{R}^{n \times n}$ là một ma trận đường chéo với các phần tử đường chéo là $\lambda_1, \dots, \lambda_n$. Khi đó ta có thể chứng minh rằng

$$AP = PD \quad (4.50)$$

Nếu và chỉ nếu $\lambda_1, \dots, \lambda_n$ là các giá trị riêng của A và $p_1, \dots, p_n$ là các vectơ riêng tương ứng của A .

Chúng ta có thể thấy rằng nhận định này đúng vì

$$AP = A[p_1, \dots, p_n] = [Ap_1, \dots, Ap_n], \quad (4.51)$$

$$PD = [p_1, \dots, p_n] \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix} = [\lambda_1 p_1, \dots, \lambda_n p_n]. \quad (4.52)$$

Do đó, (4.50) ngụ ý rằng

$$Ap_1 = \lambda_1 p_1 \quad (4.53)$$

$$\vdots$$

$$Ap_n = \lambda_n p_n. \quad (4.54)$$

Do đó, các cột của P phải là các vectơ riêng của A .


Định nghĩa về phép chéo hóa của chúng tôi yêu cầu ma trận $P \in \mathbb{R}^{n \times n}$ phải khả nghịch, tức là P có hạng đầy đủ (Định lý 4.3). Điều này đòi hỏi chúng ta phải có n vectơ riêng độc lập tuyến tính $p_1, \dots, p_n$, tức là các p_i tạo thành một cơ sở của $\mathbb{R}^n$.

Định lý 4.20 (Phân tích giá trị riêng). Một ma trận vuông $A \in \mathbb{R}^{n \times n}$ có thể được phân tích thành các thừa số riêng.

$$A = P D P^{-1}, \quad (4.55)$$

trong đó $P \in \mathbb{R}^{n \times n}$ và D là ma trận đường chéo có các phần tử trên đường chéo là các giá trị riêng của A , khi và chỉ khi các vectơ riêng của A tạo thành một cơ sở của $\mathbb{R}^n$.

4.4 Phân tích giá trị riêng và chéo hóa



Hình 4.7 Trục góc đẳng sau

Phân tích giá trị riêng như là các phép biến đổi tuần tự.

Từ trên cùng bên trái đến -1, từ dưới cùng bên trái: P

thực hiện thay đổi cơ sở (ở đây được vẽ trong R2 và được mô tả như một phép quay)

hoạt động) từ cơ sở tiêu chuẩn thành cơ sở riêng.

Góc dưới bên trái đến

Góc dưới bên phải: D

thực hiện phép co giãn dọc theo các vectơ riêng trực giao

được ánh xạ lại, được mô tả ở đây bằng một vòng tròn bị kéo giãn thành hình elip. Từ góc dưới bên phải lên góc trên bên phải: P đảo ngược cơ sở

thay đổi (được mô tả như một phép quay ngược) và khôi phục lại hệ tọa độ ban đầu.

Định lý 4.20 ngụ ý rằng chỉ những ma trận không bị lỗi mới có thể được chéo hóa và các cột của P là n vectơ riêng của A. Đối với các ma trận đối xứng, chúng ta có thể thu được kết quả mạnh mẽ hơn nữa cho việc phân tích giá trị riêng.

Định lý 4.21. Ma trận đối xứng S $R^{n \times n}$ luôn có thể được chéo hóa.

Định lý 4.21 suy ra trực tiếp từ định lý phổ 4.15. Hơn nữa, định lý phổ phát biểu rằng ta có thể tìm được một ONB của các vectơ riêng của R^n . Điều này làm cho P trở thành một ma trận trực giao sao cho $D = P^{-1}AP$. Lưu ý: Dạng chuẩn Jordan của một ma trận cấp n.

một phép phân rã hoạt động được cho các ma trận khiếm khuyết (Lang, 1987) nhưng nằm ngoài phạm vi của cuốn sách này.

Trục góc hình học về phép phân tích giá trị riêng Chúng

ta có thể diễn giải phép phân tích giá trị riêng của một ma trận như sau (xem thêm Hình 4.7): Cho A là ma trận biến đổi của một ánh xạ tuyến tính thực hiện một cơ sở Đối với cơ sở chuẩn e_i (mũi tên màu xanh). Ma trận P chuyển từ cơ sở chuẩn sang cơ sở riêng. Sau đó, ma trận đường chéo D nhân các vectơ dọc theo các trục này với các giá trị riêng λ_i . Cuối cùng, ma trận P biến đổi các vectơ đã được nhân này trở lại tọa độ chuẩn/chính tắc, thu được $\lambda_i p_i$.

Ví dụ 4.11 (Phân tích giá trị riêng)

Hãy tính phân tích giá trị riêng của $A = \begin{pmatrix} 5 & 2 \\ 2 & 5 \end{pmatrix}$.

Bước 1: Tính giá trị riêng và vectơ riêng. Đặc tính

Đa thức của A là

$$\det(A - \lambda I) = \det \begin{pmatrix} -\lambda & 1 \\ 5 & 2 - \lambda \end{pmatrix}$$

(4.56a)

$$= \left(-\frac{5}{2} - \lambda \right) (2 - \lambda) = \lambda^2 - 5\lambda + \frac{5}{2} = (\lambda - \frac{7}{2})(\lambda - \frac{3}{2}).$$

(4.56b)

Do đó, các giá trị riêng của A là $\lambda_1 =$ (nghiệm của đa thức bậc nhất) và $\lambda_2 =$ đa thức đặc các vectơ riêng (chuẩn hóa) tương ứng được thu được thông qua

$$A p_1 = \lambda_1 p_1, \quad A p_2 = \lambda_2 p_2$$

(4.57)

Điều này mang lại

$$p_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad p_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

(4.58)

Bước 2: Kiểm tra sự tồn tại. Các vectơ riêng p_1, p_2 tạo thành một cơ sở của $\mathbb{R}^2$.

Do đó, ma trận A có thể được chéo hóa.

Bước 3: Xây dựng ma trận P để chéo hóa ma trận A. Ta tập hợp các vectơ riêng của A vào P sao cho

$$P = [p_1, p_2] = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

(4.59)

Sau đó chúng ta thu được

$$P^{-1}AP = \begin{pmatrix} \frac{7}{2} & 0 \\ 0 & \frac{3}{2} \end{pmatrix} = D.$$

(4.60)

Tương đương, ta có được (bằng cách tận dụng $P^{-1}P = I$ vì các vectơ riêng p_1 và p_2 trong ví dụ này tạo thành một ONB)

$$\frac{1}{\sqrt{2}} \begin{pmatrix} 5 & 2 \\ 2 & 5 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} \frac{7}{2} & 0 \\ 0 & \frac{3}{2} \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

(4.61)

- Các ma trận đường chéo D có thể được nâng lên lũy thừa một cách hiệu quả. Do đó, ta có thể tìm lũy thừa ma trận cho một ma trận A $n \times n$ thông qua phép phân tích giá trị riêng (nếu tồn tại) sao cho

$$M^k = (P D P^{-1})^k = P D^k P^{-1}.$$

(4.62)

Việc tính toán D^k rất hiệu quả vì chúng ta áp dụng phép toán này riêng lẻ cho từng phần tử trên đường chéo chính.

- Giả sử phép phân tích giá trị riêng $A = P D P^{-1}$ tồn tại. Sau đó,

$$\det(A) = \det(P D P^{-1}) = \det(P) \det(D) \det(P^{-1})$$

(4.63a)

Hình 4.7 minh họa phép phân tích giá trị riêng của A = $\frac{1}{2} \begin{pmatrix} 5 & 2 \\ 2 & 5 \end{pmatrix}$ như một chuỗi phép biến đổi tuyến tính.

4.5 Phân tích giá trị đơn lẻ

119

$$= \det(D) = \prod_{i=1}^n d_{ii}$$

(4.63b)

cho phép tính toán định thức của ma trận A một cách hiệu quả.

Phân tích giá trị riêng yêu cầu ma trận vuông. Nó sẽ là việc phân rã ma trận tổng quát rất hữu ích. Trong phần tiếp theo, chúng ta sẽ giới thiệu một kỹ thuật phân rã ma trận tổng quát hơn, đó là...
Phân tích giá trị đơn lẻ.

4.5 Phân tích giá trị đơn lẻ

Phân tích giá trị riêng (SVD) của một ma trận là một ma trận trung tâm. Phương pháp phân rã trong đại số tuyến tính. Nó được gọi là “Định lý cơ bản của đại số tuyến tính” (Strang, 1993) bởi vì nó có thể áp dụng cho tất cả các ma trận, không chỉ ma trận vuông, và nó luôn tồn tại. Hơn nữa, như chúng ta sẽ tìm hiểu ở phần tiếp theo, phép phân tích giá trị riêng (SVD) của ma trận A, Biểu thức này, đại diện cho một ánh xạ tuyến tính $\Phi : V \rightarrow W$, định lượng sự thay đổi giữa hình học cơ bản của hai không gian vectơ này. Chúng tôi khuyến nghị công trình của Kalman (1996) và Roy và Banerjee (2014) để biết thêm chi tiết. Tổng quan sâu hơn về toán học của phép phân tích giá trị riêng (SVD).

Định lý SVD

Định lý 4.22 (Định lý SVD). Cho $A \in \mathbb{R}^{m \times n}$ là ma trận chữ nhật của hạng $r \in [0, \min(m, n)]$. Phân rã SVD của A là một phép phân rã có dạng

SVD
giá trị đơn lẻ
phân hủy

$$A = U \Sigma V^T$$

(4.64)

với ma trận trực giao $U \in \mathbb{R}^{m \times m}$ có các vectơ cột $u_i, i = 1, \dots, m$, và một ma trận trực giao $V \in \mathbb{R}^{n \times n}$ với các vectơ cột $v_j, j = 1, \dots, n$. Hơn nữa, Σ là một ma trận $m \times n$ với $\Sigma_{ii} = \sigma_i$ và $\Sigma_{ij} = 0, i \neq j$.


Các phần tử chéo $\sigma_i, i = 1, \dots, r$, của Σ được gọi là các giá trị riêng, các giá trị riêng u_i được gọi là các vectơ đơn lẻ bên trái, và v_j được gọi là các vectơ đơn lẻ bên phải. Theo quy ước, các giá trị riêng được sắp xếp theo thứ tự, tức là $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$.

số ít bên phải
vectơ

Ma trận giá trị riêng Σ là duy nhất, nhưng nó cần được chú ý. Giá trị riêng Hãy quan sát rằng $\Sigma \in \mathbb{R}^{m \times n}$ là hình chữ nhật. Đặc biệt, Σ có cùng kích thước kích thước bằng A. Điều này có nghĩa là Σ có một ma trận con đường chéo chứa các giá trị riêng lẻ và cần thêm phần đệm bằng số 0. Cụ thể, nếu $m > n$, Khi đó, ma trận Σ có cấu trúc đường chéo đến hàng n và bao gồm:

ma trận

Hình 4.8. Trục quan đẳg sau phép phân tích SVD của ma trận A R3x2 như các phép biến đổi tuần tự. Từ trên cùng bên trái xuống dưới cùng bên trái: V thực hiện phép đổi cơ sở trong R2. Từ dưới cùng bên trái đến dưới cùng bên phải: Σ mở rộng và ánh xạ từ R2 đến R3. Hình elíp ở dưới cùng bên phải nằm trong R3. Chiều thứ ba là vuông góc với bề mặt của đĩa hình elíp. Từ dưới cùng bên phải lên trên cùng bên phải: U thực hiện thay đổi cơ sở trong R3.



0 các vectơ hàng từ n + 1 đến m bên dưới sao cho

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & & \\ 0 & \ddots & 0 & & \\ & 0 & 0 & \sigma_n & \\ 0 & \dots & 0 & & \\ \vdots & & & & \vdots \\ 0 & \dots & 0 & & \end{pmatrix} \quad (4.65)$$

Nếu m < n, ma trận Σ có cấu trúc đường chéo đến cột m và các cột từ m + 1 đến n chỉ gồm toàn số 0 :

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & 0 & \dots & 0 \\ 0 & \ddots & 0 & \vdots & & \vdots \\ 0 & 0 & \sigma_m & 0 & \dots & 0 \end{pmatrix} \quad (4.66)$$

Lưu ý. Phân tích SVD tồn tại cho mọi ma trận A Rm×n .

4.5.1 Trục quan hình học cho SVD SVD cung cấp trục

quan hình học để mô tả ma trận biến đổi A. Trong phần tiếp theo, chúng ta sẽ thảo luận về SVD như là các phép biến đổi tuyến tính tuần tự được thực hiện trên các cơ sở. Trong Ví dụ 4.12, chúng ta sẽ áp dụng các ma trận biến đổi của SVD cho một tập hợp các vectơ trong R2 , điều này cho phép chúng ta hình dung rõ hơn tác động của mỗi phép biến đổi.

Phép phân tích SVD của một ma trận có thể được hiểu là sự phân rã của một ánh xạ tuyến tính tương ứng (nhớ lại Mục 2.7.1) $\Phi : R_n \rightarrow R_m$ thành ba phép toán; xem Hình 4.8. Trục giác về SVD thoát nhìn có cấu trúc tương tự như trục giác về phân tích giá trị riêng của chúng ta, xem Hình 4.7: Nói một cách tổng quát, SVD thực hiện thay đổi cơ sở thông qua V, tiếp theo là phép co giãn và tăng (hoặc giảm) chiều thông qua phép toán suy biến.

4.5 Phân tích giá trị đơn lẻ

121

ma trận giá trị Σ . Cuối cùng, nó thực hiện thay đổi cơ sở thứ hai thông qua U . Phân tích SVD bao gồm một số chi tiết và lưu ý quan trọng, đó là lý do tại sao chúng ta sẽ xem xét lại trực giác của mình một cách chi tiết hơn.

Giả sử ta được cho ma trận biến đổi của một ánh xạ tuyến tính $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$ đối với các cơ sở chuẩn B và C của $\mathbb{R}^n$ và $\mathbb{R}^m$ tương ứng. Hơn nữa, giả sử có cơ sở thứ hai B^* của $\mathbb{R}^n$ và C^* của $\mathbb{R}^m$. Khi đó: 1. Ma trận V thực hiện phép đổi cơ sở

trong miền $\mathbb{R}^n$ từ B^* (được biểu diễn bởi các vectơ màu đỏ và cam v_1 và v_2 ở góc trên bên trái của Hình 4.8) sang cơ sở chuẩn B . V thực hiện phép đổi cơ sở từ B sang B^* . Các vectơ màu đỏ và cam giờ đây được căn chỉnh với cơ sở chính tắc ở góc dưới bên trái của Hình 4.8.

2. Sau khi thay đổi hệ tọa độ sang B^* , Σ sẽ điều chỉnh tỷ lệ các tọa độ mới bằng các giá trị riêng σ_i (và thêm hoặc bớt chiều), tức là Σ là ma trận biến đổi của Φ đối với B^* và C^* , được biểu diễn bằng các vectơ màu đỏ và cam bị kéo giãn và nằm trong mặt phẳng e_1 - e_2 , hiện được nhúng trong chiều thứ ba ở góc dưới bên phải của Hình 4.8.

3. U thực hiện phép đổi cơ sở trong miền giá trị $\mathbb{R}^m$ từ C^* sang cơ sở chính tắc của $\mathbb{R}^m$, được biểu diễn bằng phép quay các vectơ màu đỏ và cam ra khỏi mặt phẳng e_1 - e_2 . Điều này được thể hiện ở góc trên bên phải của Hình 4.8.

Phép biến đổi SVD thể hiện sự thay đổi cơ sở trong cả miền xác định và miền giá trị. Điều này trái ngược với phép phân tích giá trị riêng hoạt động trong cùng không gian vectơ, nơi cùng một phép biến đổi cơ sở được áp dụng rồi đảo ngược. Điều làm cho SVD trở nên đặc biệt là hai cơ sở khác nhau này được liên kết đồng thời bởi ma trận giá trị riêng Σ .

Việc xem lại là rất hữu ích. các thay đổi cơ sở (Mục 2.7.2), ma trận trực giao (Định nghĩa 3.8) và cơ sở trực chuẩn (Mục 3.5).

Ví dụ 4.12 (Vectơ và phép phân tích SVD)

Xét phép ánh xạ một lưới vuông các vectơ $X \in \mathbb{R}^{2 \times 2}$ nằm gọn trong một hình chữ nhật có kích thước 2×2 , tâm đặt tại gốc tọa độ. Sử dụng cơ sở chuẩn, ta có thể ánh xạ các vectơ này bằng cách sử dụng

$$A = \begin{bmatrix} 1 & 0,8 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} = U\Sigma V$$

(4.67a)

$$= \begin{bmatrix} -0,79 & 0 & -0,62 & 1,62 \\ 0,38 & 0,78 & 0,49 & 0 \\ 0,48 & 0,62 & 0,62 & 0 \end{bmatrix} \begin{bmatrix} 1,0 & 0,78 & 0,62 \\ 0 & 1,0 & 0,78 \\ 0 & 0 & 1,0 & 0 \end{bmatrix}$$


(4.67b)

Chúng ta bắt đầu với một tập hợp các vectơ X (các chấm màu; xem bảng phía trên bên trái của Hình 4.9) được sắp xếp theo dạng lưới. Sau đó, chúng ta áp dụng $V \in \mathbb{R}^{2 \times 2}$ cho X . Các vectơ đã xoay được hiển thị trong bảng phía dưới bên trái của Hình 4.9. Bây giờ chúng ta ánh xạ các vectơ này bằng cách sử dụng ma trận giá trị Σ vào miền giá trị $\mathbb{R}^2$ (xem bảng phía dưới bên phải trong Hình 4.9). Lưu ý rằng tất cả các vectơ đều nằm trong

Mặt phẳng x_1 - x_2 . Tọa độ thứ ba luôn bằng 0. Các vectơ trong mặt phẳng x_1 - x_2 đã bị kéo giãn bởi các giá trị kỳ dị.

Phép ánh xạ trực tiếp các vectơ X bởi A đến miền giá trị R_3 tương đương với phép biến đổi X bởi $U\Sigma V$, trong đó, U thực hiện phép quay trong miền giá trị R_3 sao cho các vectơ được ánh xạ không còn bị giới hạn trong mặt phẳng x_1 - x_2 ; chúng vẫn nằm trên một mặt phẳng như được thể hiện trong hình 4.9 ở góc trên bên phải.

Hình 4.9 Phân tích SVD và ánh xạ vectơ (biểu diễn bằng các hình tròn). Các hình được sắp xếp theo chiều ngược kim đồng hồ. cấu trúc của Hình 4.8.



4.5.2 Xây dựng phép phân tích SVD Tiếp

theo, chúng ta sẽ thảo luận về lý do tồn tại của phép phân tích SVD và trình bày chi tiết cách tính toán nó. Phép phân tích SVD của một ma trận tổng quát có một số điểm tương đồng với phép phân tích giá trị riêng của một ma trận vuông.

Lưu ý. So sánh phép phân tích giá trị riêng của ma trận SPD.

$$S = S = P D P^T \quad (4.68)$$

4.5 Phân tích giá trị đơn lẻ

123

với SVD tương ứng

$$S = U\Sigma V^T. \quad (4.69)$$

Nếu chúng ta thiết lập

$$U = P = V, \quad D = \Sigma, \quad (4.70)$$

Ta thấy rằng phép phân tích SVD của ma trận SPD chính là phép phân tích giá trị

riêng của chúng. Trong phần tiếp theo, chúng ta sẽ tìm hiểu lý do tại sao Định lý 4.22 đúng và cách xây dựng phép phân tích SVD. Tính toán phép phân tích SVD của $A \in \mathbb{R}^{m \times n}$ tương đương với việc tìm hai tập hợp cơ sở trực chuẩn $U = \{u_1, \dots, u_m\}$ và $V = \{v_1, \dots, v_n\}$ của miền giá trị $\mathbb{R}^m$ và miền xác định $\mathbb{R}^n$ tương ứng. Từ các cơ sở được sắp xếp này, ta sẽ xây dựng các ma trận U và V .

Kế hoạch của chúng tôi là bắt đầu bằng việc xây dựng tập hợp trực chuẩn các vectơ đơn lẻ phải $v_1, \dots, v_n \in \mathbb{R}^n$. Sau đó, chúng tôi xây dựng tập hợp trực chuẩn các vectơ đơn lẻ trái $u_1, \dots, u_m \in \mathbb{R}^m$. Tiếp theo, chúng tôi sẽ liên kết hai tập hợp này và yêu cầu tính trực giao của các vectơ vì được bảo toàn dưới phép biến đổi của A . Điều này rất quan trọng vì chúng ta biết rằng các ảnh Av_i tạo thành một tập hợp các vectơ trực giao. Sau đó, chúng tôi sẽ chuẩn hóa các ảnh này bằng các hệ số vô hướng, chính là các giá trị đơn lẻ.

Chúng ta hãy bắt đầu bằng việc xây dựng các vectơ riêng bên phải. Định lý phổ (Định lý 4.15) cho chúng ta biết rằng các vectơ riêng của một ma trận đối xứng tạo thành một ma trận ONB, điều này cũng có nghĩa là nó có thể được chéo hóa. Hơn nữa, từ Định lý 4.14, chúng ta luôn có thể xây dựng một ma trận đối xứng, bán xác định dương $A \in \mathbb{R}^{n \times n}$ từ bất kỳ ma trận chữ nhật $A \in \mathbb{R}^{m \times n}$ nào. Do đó, chúng ta luôn có thể chéo hóa $A \in \mathbb{R}^{n \times n}$ và thu được

$$A \in \mathbb{R}^{n \times n} = P D P^T = P \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix} P^T, \quad (4.71)$$

trong đó P là ma trận trực giao, được cấu tạo từ cơ sở riêng trực chuẩn. $\lambda_i \geq 0$ là các giá trị riêng của $A \in \mathbb{R}^{n \times n}$. Giả sử SVD của A tồn tại và đưa (4.64) vào (4.71). Điều này dẫn đến $A = V \Sigma U^T = U \Sigma V^T$

$$A \in \mathbb{R}^{n \times n} = (U \Sigma V^T) (U \Sigma V^T) \quad \text{trong đó } U, V \text{ là các } \quad (4.72)$$

ma trận trực giao. Do đó, với $U = I$ ta thu được-

$$A \in \mathbb{R}^{n \times n} = V \Sigma \Sigma^T V^T = V \begin{pmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_n^2 \end{pmatrix} V^T. \quad (4.73)$$

So sánh (4.71) và (4.73) hiện tại, chúng ta xác định

$$V = P, \quad (4.74)$$

$$\sigma_i^2 = \lambda_i. \quad (4.75)$$

Do đó, các vectơ riêng của $A^T A$ tạo nên P là các vectơ kỳ dị bên phải V của A (xem (4.74)). Các giá trị riêng của $A^T A$ là các giá trị kỳ dị bình phương của Σ (xem (4.75)).

Để thu được các vectơ kỳ dị trái U , chúng ta thực hiện theo một quy trình tương tự.

Chúng ta bắt đầu bằng cách tính toán phân tích SVD của ma trận đối xứng AA^T

$R^{m \times m}$ (thay vì ma trận $A^T A$ $R^{n \times n}$ trước đó). Phân tích SVD của A

$$\text{cho kết quả } AA^T = (U \Sigma U^T) = U \Sigma V^T V \Sigma U^T \quad (4.76a)$$

$$= U \begin{pmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_m^2 \\ & & & 0 \end{pmatrix} U^T \quad (4.76b)$$

Định lý phổ cho ta biết rằng ma trận $AA^T = SDS^T$ có thể chéo hóa và ta có thể tìm được một tập hợp vectơ riêng trực chuẩn (ONB) của các vectơ riêng của AA^T . Các vectơ riêng trực chuẩn của AA^T là các vectơ kỳ dị trái U , và tạo thành một cơ sở trực chuẩn trong miền giá trị của phép phân tích SVD.

Điều này đặt ra câu hỏi về cấu trúc của ma trận Σ . Vì AA^T và $A^T A$ có cùng các giá trị riêng khác 0 (xem trang 106), nên các giá trị riêng khác 0 của phần tử của ma trận Σ trong phép phân tích SVD đối với cả hai trường hợp phải giống nhau.

Bước cuối cùng là liên kết tất cả các phần mà chúng ta đã đề cập đến cho đến nay. Chúng ta có một tập hợp các vectơ đơn lẻ phải trực chuẩn trong V . Để hoàn thành việc xây dựng SVD, chúng ta kết nối chúng với các vectơ trực chuẩn U . Để đạt được mục tiêu này, chúng ta sử dụng thực tế là ảnh của các vectơ vi dưới A cũng phải trực giao. Chúng ta có thể chứng minh điều này bằng cách sử dụng các kết quả từ Phần 3.4. Chúng tôi yêu cầu tích vô hướng giữa Av_i và Av_j phải bằng 0 đối với $i \neq j$. Đối với bất kỳ hai vectơ riêng trực giao vi và vj, ta có $v_i^T v_j = 0$,

$$(Av_i)^T (Av_j) = v_i^T (A^T A) v_j = v_i^T (\lambda_j v_j) = \lambda_j v_i^T v_j = 0. \quad (4.77)$$

Đối với trường hợp $m \geq r$, ta có $\{Av_1, \dots, Av_r\}$ là cơ sở của một không gian con r chiều của R^m .

Để hoàn thành việc xây dựng SVD, chúng ta cần các vectơ kỳ dị trái trực giao: Chúng ta chuẩn hóa ảnh của các vectơ kỳ dị phải Av_i và thu được

$$\frac{Av_i}{\|Av_i\|} = \frac{1}{\sqrt{\lambda_i}} Av_i = \frac{1}{\sigma_i} Av_i, \quad (4.78)$$

trong đó đẳng thức cuối cùng được thu được từ (4.75) và (4.76b), cho chúng ta thấy rằng các giá trị riêng của AA^T sao cho $\sigma_i^2 = \lambda_i$.

Do đó, các vectơ riêng của $A^T A$, mà chúng ta biết là vectơ riêng phải vectơ đơn vị, và ảnh chuẩn hóa của chúng dưới A , vectơ riêng trái vectơ u_i , tạo thành hai ONB tự nhất quán được kết nối thông qua ma trận giá trị riêng Σ .

Ta sắp xếp lại (4.78) để thu được phương trình giá trị riêng

$$Av_i = \sigma_i u_i, \quad i = 1, \dots, r. \quad (4.79)$$

4.5 Phân tích giá trị đơn lẻ

125

Phương trình này rất giống với phương trình giá trị riêng (4.25), nhưng các vectơ ở phía bên trái và phía bên phải không giống nhau.

Đối với $n < m$, (4.79) chỉ đúng với $i = 1, \dots, n$, nhưng (4.79) không nói gì về u_i đối với $i > n$. Tuy nhiên, theo cách xây dựng, chúng ta biết rằng chúng là trực chuẩn. Ngược lại, đối với $m < n$, (4.79) chỉ đúng với $i = 1, \dots, m$. Đối với $i > m$, ta có $Av_i = 0$ và ta vẫn biết rằng v_i tạo thành một tập trực chuẩn. Điều này có nghĩa là SVD cũng cung cấp một cơ sở trực chuẩn của hạt nhân (không gian rỗng) của A , tập hợp các vectơ x với $Ax = 0$ (xem Mục 2.7.3).

Nổi các v_i thành các cột của V và các u_i thành các cột của ma trận U

$$AV = U\Sigma$$

,

(4,80)

trong đó Σ có cùng kích thước với A và cấu trúc đường chéo cho các hàng $1, \dots, r$. Do đó, nhân từ phải với V , đó chính là phép phân tích SVD của A cho ta $A = U\Sigma V^T$,

Ví dụ 4.13 (Tính toán SVD)

Hãy tìm phân tích giá trị riêng của

$$A = \begin{bmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \end{bmatrix}$$

.

(4.81)

Phương pháp phân tích giá trị riêng (SVD) yêu cầu chúng ta tính toán các vectơ riêng bên phải v_j , các giá trị riêng σ_k và các vectơ riêng bên trái u_i .

Bước 1: Các vectơ kỳ dị bên phải được sử dụng làm cơ sở riêng của $A^T A$.

Chúng ta bắt đầu bằng cách tính toán

$$A^T A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 5 & 2 & 1 \\ 2 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

.

(4.82)

Chúng ta tính toán các giá trị riêng và vectơ riêng phải v_j thông qua phép phân tích giá trị riêng của $A^T A$, được cho bởi công

$$A^T A = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & \frac{1}{\sqrt{30}} \\ \frac{2}{\sqrt{2}} & \frac{1}{\sqrt{30}} & \frac{\sqrt{5}}{2} \\ \frac{1}{\sqrt{30}} & \frac{1}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix} \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & \frac{1}{\sqrt{30}} \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} \frac{5}{\sqrt{30}} & \frac{2}{\sqrt{2}} & \frac{1}{\sqrt{30}} \\ 0 & \frac{1}{\sqrt{5}} & \frac{1}{\sqrt{6}} \\ 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \end{bmatrix} = P \Lambda P^T$$

.

(4.83)

và ta thu được các vectơ kỳ dị bên phải dưới dạng các cột của P sao cho

$$V = P = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & \frac{1}{\sqrt{30}} \\ \frac{2}{\sqrt{2}} & \frac{1}{\sqrt{30}} & \frac{\sqrt{5}}{2} \\ \frac{1}{\sqrt{30}} & \frac{1}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix}$$

.

(4,84)

Bước 2: Ma trận giá trị đơn.

Vì các giá trị riêng σ_i là căn bậc hai của các giá trị riêng của

A. Chúng ta thu được chúng trực tiếp từ D. Vì $\text{rk}(A) = 2$, nên chỉ có hai giá trị kỳ dị khác 0: $\sigma_1 = \sqrt{6}$ và $\sigma_2 = 1$. Ma trận giá trị kỳ dị phải có cùng kích thước với A, và ta thu được

$$\Sigma = \begin{pmatrix} \sqrt{6} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}. \quad (4,85)$$

Bước 3: Các vectơ đơn lẻ bên trái được xem như ảnh chuẩn hóa của các vectơ đơn lẻ bên phải. Các vectơ riêng biệt.

Chúng ta tìm các vectơ kỳ dị bên trái bằng cách tính ảnh của các vectơ kỳ dị bên phải dưới tác động của A và chuẩn hóa chúng bằng cách chia cho giá trị kỳ dị tương ứng. Ta thu được

$$u_1 = \frac{1}{\sigma_1} A v_1 = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \end{pmatrix} \begin{pmatrix} \frac{5}{\sqrt{30}} \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{30}} \end{pmatrix} = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad (4,86)$$

$$u_2 = \frac{1}{\sigma_2} A v_2 = \frac{1}{1} \begin{pmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0 \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{5}} \end{pmatrix} = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad (4,87)$$

$$U = [u_1, u_2] = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}. \quad (4,88)$$

Lưu ý rằng trên máy tính, phương pháp được minh họa ở đây có hiệu suất số học kém, và phép phân tích SVD của A thường được tính toán mà không cần sử dụng phép phân tích giá trị riêng của A.

4.5.3 Phân tích giá trị riêng so với phân tích giá trị đơn

Hãy xem xét phép phân tích giá trị riêng $A = P D P^{-1}$ và SVD $A = U \Sigma V$ và xem lại các yếu tố cốt lõi của các phần trước.


- Phép phân tích giá trị riêng (SVD) luôn tồn tại đối với bất kỳ ma trận $R^{m \times n}$ nào. Phép phân tích giá trị riêng chỉ được định nghĩa cho các ma trận vuông $R^{n \times n}$ và chỉ tồn tại nếu ta có thể tìm được một cơ sở các vectơ riêng của R^n .
- Các vectơ trong ma trận phân tích giá trị riêng P không nhất thiết phải trực giao, tức là phép đổi cơ sở không chỉ đơn thuần là phép quay và phép co giãn. Mặt khác, các vectơ trong ma trận U và V trong phép phân tích SVD là trực chuẩn, do đó chúng biểu diễn các phép quay.
- Cả phép phân tích giá trị riêng (eigendecomposition) và phép phân tích giá trị riêng (SVD) đều là sự kết hợp của

ba phép ánh xạ tuyến tính: 1. Thay đổi cơ

sở trong miền xác định 2. Phép co giãn độc lập của mỗi vectơ cơ sở mới và ánh xạ từ miền xác định sang miền giá trị

3. Thay đổi cơ sở trong miền giá trị

4.5 Phân tích giá trị đơn lẻ



Hình 4.10 Phim xếp hạng ba người cho bốn phim và SVD của nó sự phân hủy.

Một điểm khác biệt quan trọng giữa phép phân tích giá trị riêng và phép phân tích SVD là: Trong phép phân tích giá trị riêng (SVD), miền xác định và miền giá trị có thể là các không gian vectơ khác nhau. kích thước.

- Trong phép phân tích SVD, các ma trận vectơ kỳ dị trái và phải U và V là Nhìn chung, chúng không phải là nghịch đảo của nhau (chúng thực hiện các phép biến đổi cơ sở trong các không gian vectơ khác nhau). Trong phép phân tích giá trị riêng, các phép biến đổi trices P và P¹ cơ sở có thể là nghịch đảo của nhau.
- Trong phép phân tích SVD, các phần tử trong ma trận đường chéo Σ đều là số thực và không âm, điều này thường không đúng đối với ma trận đường chéo trong phép tính SVD. Phân tích giá trị riêng.
- Phân tích giá trị riêng (SVD) và phân tích giá trị riêng có mối liên hệ chặt chẽ với nhau thông qua chúng. dự báo
 - Các vectơ kỳ dị bên trái của A là các vectơ riêng của AA
 - Các vectơ riêng phải của A là các vectơ riêng của A^T A.
 - Các giá trị riêng khác 0 của A là căn bậc hai của các giá trị riêng khác 0 Giá trị riêng của cả ma trận AA^T và A^T A.
- Đối với các ma trận đối xứng A^T = A, phân tích giá trị riêng và Các SVD là một và giống nhau, điều này xuất phát từ định lý phổ 4.15.

Ví dụ 4.14 (Tìm kiếm cấu trúc trong xếp hạng phim và hành vi người tiêu dùng)
Chúng ta hãy bổ sung thêm một cách diễn giải thực tiễn về SVD bằng cách phân tích dữ liệu về... mọi người và những bộ phim họ yêu thích. Hãy xem xét ba người xem (Ali, Beatrix, Chandra) đánh giá bốn bộ phim khác nhau (Star Wars, Blade Runner, Amelie, Cửa hàng thực phẩm cao cấp). Xếp hạng của chúng nằm trong khoảng từ 0 (tệ nhất) đến 5 (tốt nhất) và được mã hóa trong ma trận dữ liệu A^T = R⁴×³ như thể hiện trong Hình 4.10. Mỗi hàng Biểu thị một bộ phim và mỗi cột đại diện cho một người dùng. Do đó, các vectơ cột của Mỗi người xem sẽ có một đánh giá riêng, lần lượt là x_{Ali}, x_{Beatrix}, x_{Chandra}.

Phân tích nhân tử ma trận A bằng phương pháp phân tích giá trị đơn (SVD) cho phép chúng ta nắm bắt được mối quan hệ giữa cách mọi người đánh giá phim, đặc biệt là liệu có cấu trúc nào liên kết việc mọi người thích phim nào hay không. Việc áp dụng SVD vào ma trận dữ liệu A của chúng ta đòi hỏi một số giả định:

1. Tất cả người xem đều đánh giá phim một cách nhất quán bằng cách sử dụng cùng một phương pháp so sánh tuyến tính.
2. Không có lỗi hoặc nhiễu nào trong các đánh giá.
3. Chúng tôi diễn giải các vectơ đơn lẻ bên trái ui là các bộ phim mang tính rập khuôn và các vectơ đơn lẻ bên phải vj là những người xem mang tính rập khuôn.

Chúng ta giả định rằng sở thích xem phim cụ thể của bất kỳ người xem nào có thể được biểu diễn dưới dạng tổ hợp tuyến tính của v_j . Tương tự, mức độ yêu thích của bất kỳ bộ phim nào cũng có thể được biểu diễn dưới dạng tổ hợp tuyến tính của u_i . Do đó, một vectơ trong miền của SVD có thể được hiểu là một người xem trong “không gian” của những người xem điển hình, và một vectơ trong miền giá trị của SVD. Hai “không gian” này tương ứng là một bộ phim trong “không gian” của những bộ phim điển hình. Chúng ta hãy chỉ xem xét SVD của ma trận người dùng-phim của chúng ta. Vectơ đơn lẻ bên trái đầu tiên

u_1 có giá trị tuyệt đối lớn đối với hai bộ phim khoa học viễn tưởng và được bao phủ bởi giá trị đơn lẻ đầu tiên (vùng tô màu đỏ trong Hình 4.10). Do đó, điều này nhóm một loại dữ liệu người xem và phim tương ứng nếu người dùng có một tập hợp phim cụ thể (chủ đề khoa học viễn tưởng). Tương tự, bản thân dữ liệu bao phủ giá trị đơn lẻ bên phải đầu tiên v_1 cho thấy giá trị tuyệt đối lớn đối với Ali và Beatrix, những người có sự đa dạng đủ lớn khi đánh giá cao các bộ phim người yêu thích **khoa** học viễn tưởng (vùng tô màu xanh lá cây trong Hình 4.10). Số lượng người xem và điều này cho thấy v_1 phản ánh quan niệm về một học viễn tưởng.

phim.

Tương tự, u_2 dường như thể hiện chủ đề phim nghệ thuật Pháp, và v_2 cho thấy Chandra gần giống với hình mẫu lý tưởng về người yêu thích thể loại phim này. Một người yêu thích khoa học viễn tưởng lý tưởng là người theo chủ nghĩa thuần túy và chỉ yêu thích phim khoa học viễn tưởng, vì vậy một người yêu thích khoa học viễn tưởng v_1 sẽ chấm điểm 0 cho mọi thứ ngoại trừ phim có chủ đề khoa học viễn tưởng – logic này được ngụ ý bởi cấu trúc con đường chéo của ma trận giá trị riêng Σ . Do đó, một bộ phim cụ thể được biểu diễn bằng cách nó phân rã (tuyến tính) thành các bộ phim điển hình của nó. Tương tự, một người sẽ được biểu diễn bằng cách họ phân rã (thông qua tổ hợp tuyến tính) thành các chủ đề phim.

Cần thảo luận ngắn gọn về thuật ngữ và quy ước của SVD, vì có nhiều phiên bản khác nhau được sử dụng trong tài liệu. Mặc dù những khác biệt này có thể gây nhầm lẫn, nhưng bản chất toán học vẫn không thay đổi.

- Để thuận tiện cho việc ký hiệu và trừu tượng hóa, chúng tôi sử dụng ký hiệu SVD trong đó SVD được mô tả là có hai ma trận vectơ đơn lẻ trái và phải hình vuông, nhưng ma trận giá trị đơn lẻ không phải hình vuông. Định nghĩa của chúng tôi (4.64) cho SVD đôi khi được gọi là SVD đầy đủ.
- Một số tác giả định nghĩa SVD hơi khác và tập trung vào các ma trận vuông đơn vị. Khi đó, đối với $A \in \mathbb{R}^{m \times n}$ và $m, n \geq 1$,

$$A_{m \times n} = U_{m \times m} \Sigma_{n \times n} V_n^T \quad (4.89)$$

Đôi khi công thức này được gọi là SVD rút gọn (ví dụ: Datta (2010)) hoặc SVD (ví dụ: Press et al. (2007)). Định dạng thay thế này chỉ thay đổi cách xây dựng ma trận mà vẫn giữ nguyên cấu trúc toán học của SVD. Sự tiện lợi của công thức thay thế này là Σ là ma trận đường chéo, giống như trong phân tích giá trị riêng.

- Trong Phần 4.6, chúng ta sẽ tìm hiểu về các kỹ thuật xấp xỉ ma trận sử dụng SVD, còn được gọi là SVD cắt cụt. SVD bị cắt cụt
- Có thể định nghĩa phép phân tích giá trị đơn (SVD) của ma trận hạng r A sao cho U là ma trận $m \times r$, Σ là ma trận đường chéo $r \times r$ và V là ma trận $r \times n$. Cấu trúc này rất giống với định nghĩa của chúng ta và đảm bảo rằng ma trận đường chéo Σ chỉ có các phần tử khác 0 dọc theo đường chéo. Ưu điểm chính của ký hiệu thay thế này là Σ là ma trận đường chéo, giống như trong phép phân tích giá trị riêng.
- Giới hạn rằng phép phân tích SVD cho ma trận A chỉ áp dụng cho ma trận $m \times n$ với $m > n$ là thực tế không cần thiết. Khi $m < n$, phép phân tích SVD sẽ tạo ra ma trận Σ có nhiều cột bằng 0 hơn hàng và do đó, các giá trị riêng $\sigma_{m+1}, \dots, \sigma_n$ đều bằng 0.

Phân tích giá trị đơn (SVD) được sử dụng trong nhiều ứng dụng khác nhau trong học máy, từ các bài toán bình phương tối thiểu trong việc khớp đường cong đến việc giải hệ phương trình tuyến tính. Các ứng dụng này khai thác nhiều thuộc tính quan trọng của SVD, mối quan hệ của nó với hạng của ma trận, và khả năng xấp xỉ các ma trận có hạng nhất định bằng các ma trận có hạng thấp hơn. Việc thay thế một ma trận bằng SVD của nó thường có lợi thế là làm cho phép tính mạnh mẽ hơn đối với các lỗi làm tròn số. Như chúng ta sẽ tìm hiểu trong phần tiếp theo, khả năng của SVD trong việc xấp xỉ các ma trận bằng các ma trận "đơn giản" hơn một cách có nguyên tắc mở ra các ứng dụng học máy từ giảm chiều dữ liệu và mô hình hóa chủ đề đến nén dữ liệu và phân cụm.

4.6 Phép xấp xỉ ma trận

Chúng tôi xem xét phép phân tích giá trị kỳ dị (SVD) như một cách để phân tích ma trận $A = U \Sigma V^T$ thành tích của ba ma trận, trong đó U $R^{m \times m}$ và V $R^{n \times n}$ là trực giao và Σ chứa các giá trị kỳ dị trên đường chéo chính của nó. Thay vì thực hiện phép phân tích SVD đầy đủ, chúng tôi sẽ nghiên cứu cách SVD cho phép chúng ta biểu diễn ma trận A dưới dạng tổng của các ma trận đơn giản hơn (hạng thấp) A_i , điều này tạo điều kiện cho một lược đồ xấp xỉ ma trận có chi phí tính toán thấp hơn so với phép phân tích SVD đầy đủ.



Chúng ta xây dựng ma trận hạng 1 A_i $R^{m \times n}$ như sau:

$$A_i := u_i v_i^T,$$

(4.90)

được hình thành bởi tích ngoài của vectơ cột trực giao thứ i của U và V . Hình 4.11 cho thấy hình ảnh của Stonehenge, có thể được biểu diễn bằng ma trận A $R^{1432 \times 1910}$ và một số tích ngoài A_i được định nghĩa trong (4.90). BẢNG

Hình 4.11 Xử lý ảnh bằng SVD. (a) Ảnh xám gốc là ma trận giá trị 1.432×1.910 .






(a) Hình ảnh gốc A.

(b) A1, $\sigma_1 \approx 228, 052$.

(c) A2, $\sigma_2 \approx 40, 647$.

giữa 0 (đen) và 1 (trắng).
(b)-(f) Ma trận hạng 1 A5 và A1, . . . , các giá trị ứng σ_5 . riêng tương $\sigma_1, . . . ,$



(d) A3, $\sigma_3 \approx 26, 125$.

(e) A4, $\sigma_4 \approx 20, 232$.

(f) A5, $\sigma_5 \approx 15, 436$.

Cấu trúc dạng lưới của mỗi ma trận hạng 1 được tạo ra bởi tích ngoài của ma trận bên trái và

Các vectơ đơn lẻ bên phải.

Một ma trận A $R \times n$ có hạng r có thể được viết dưới dạng tổng của các ma trận hạng 1. Ai vậy nên

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T = \sum_{i=1}^r \sigma_i A_i, \tag{4.91}$$

trong đó các ma trận tích ngoài A_i được trọng số hóa bởi giá trị riêng thứ i σ_i . Chúng ta có thể thấy tại sao (4.91) đúng: Cấu trúc đường chéo của ma trận giá trị riêng Σ chỉ nhân với các giá trị riêng bên trái và bên phải khớp nhau. Các vectơ $u_i v_i^T$ và chia tỷ lệ cho chúng bằng giá trị riêng tương ứng σ_i . Tất cả $\Sigma_{ij} u_i v_j^T = 0$ nếu $i \neq j$ vì Σ là ma trận đường chéo. Bất kỳ thuật ngữ nào trong biến mất vì các giá trị kỳ dị tương ứng bằng 0.

Trong (4.90), chúng tôi đã giới thiệu các ma trận hạng 1 A_i . Chúng tôi đã cộng r ma trận hạng 1 riêng lẻ để thu được ma trận hạng r A ; xem (4.91). Nếu tổng không chạy trên tất cả các ma trận $A_i, i = 1, . . . , r$, mà chỉ đến một giá trị trung gian $k < r$, chúng ta sẽ thu được một xấp xỉ hạng k .

hạng k xấp xỉ

$$A(k) := \sum_{i=1}^k \sigma_i u_i v_i^T = \sum_{i=1}^k \sigma_i A_i \tag{4.92}$$

của A với $rk(A(k)) = k$. Hình 4.12 cho thấy các phép xấp xỉ hạng thấp $A(k)$ của ảnh gốc A của Stonehenge. Hình dạng của các tảng đá trở nên rõ ràng và dễ nhận biết hơn trong phép xấp xỉ hạng 5. Trong khi ảnh gốc yêu cầu $1.432 \cdot 1.910 = 2.735.120$ số, phép xấp xỉ hạng 5 chỉ yêu cầu chúng ta lưu trữ năm giá trị đơn lẻ và năm vectơ đơn lẻ trái và phải (mỗi vectơ có kích thước 1.432 và 1.910) với tổng số $5 \cdot (1.432 + 1.910 + 1) = 16.715$ số - chỉ hơn 0,6% so với ảnh gốc.


Để đo lường sự khác biệt (sai số) giữa A và phép xấp xỉ hạng k của nó $A(k)$, chúng ta cần khái niệm về chuẩn. Trong Phần 3.1, chúng ta đã sử dụng

4.6 Phép xấp xỉ ma trận


131



(a) Hình ảnh gốc A.



(b) Xấp xỉ hạng 1 A (1). (c) Xấp xỉ hạng 2 A (2).



(d) Xấp xỉ hạng 3 A (3). (e) Xấp xỉ hạng 4 A (4). (f) Xấp xỉ hạng 5 A (5).

Hình 4.12 Tái tạo hình ảnh bằng SVD. (a)

Hình ảnh gốc. (b)–(f) Tái tạo hình ảnh bằng cách sử dụng phép xấp xỉ

hạng thấp của SVD, trong đó hạng k

phép xấp xỉ được đưa ra bởi $A(k) = \sum_{i=1}^k \sigma_i A_i$.

Chuẩn mực trên vectơ dùng để đo độ dài của vectơ. Tương tự, ta cũng có thể định nghĩa chuẩn mực trên ma trận.

Định nghĩa 4.23 (Chuẩn phổ của ma trận). Đối với $x \in \mathbb{R}^n$, chuẩn phổ của ma trận $A \in \mathbb{R}^{m \times n}$ được định nghĩa như sau :

$$\|A\|_2 := \max_x \frac{\|Ax\|_2}{\|x\|_2}. \quad (4.93)$$

Chúng tôi giới thiệu ký hiệu chỉ số dưới trong chuẩn ma trận (bên trái), tương tự như chuẩn Euclidean cho vectơ (bên phải), có chỉ số dưới là 2. Chuẩn phổ (4.93) xác định độ dài tối đa mà bất kỳ vectơ x nào có thể đạt được khi nhân với A .

Định lý 4.24. Chuẩn phổ của A là giá trị riêng lớn nhất của nó $A^T A$.

Chúng tôi để phần chứng minh định lý này lại như một bài tập.

Định lý

Eckart-Young 4.25 (Định lý Eckart-Young (Eckart và Young, 1936)). Xét ma trận $A \in \mathbb{R}^{m \times n}$ hạng r và ma trận $B \in \mathbb{R}^{m \times n}$ hạng k . Với mọi $k \leq r$ sao cho $A(k) = \sum_{i=1}^k \sigma_i A_i$ thì ta có:

$$\|A - A(k)\|_2 = \arg\min_{B \text{ hạng } k} \|A - B\|_2, \quad (4.94)$$

$$\|A - A(k)\|_2 = \sigma_{k+1}. \quad (4.95)$$

Định lý Eckart-Young nêu rõ mức độ sai số mà chúng ta gây ra khi xấp xỉ ma trận A bằng phép xấp xỉ hạng k . Chúng ta có thể hiểu phép xấp xỉ hạng k thu được bằng phân tích giá trị riêng (SVD) như là phép chiếu ma trận hạng đầy đủ A lên không gian có chiều thấp hơn gồm các ma trận hạng tối đa k . Trong tất cả các phép chiếu có thể, SVD giảm thiểu sai số (đối với chuẩn phổ) giữa A và bất kỳ phép xấp xỉ hạng k nào.

Chúng ta có thể xem lại một số bước để hiểu tại sao (4.95) lại đúng.

Chúng tôi nhận thấy rằng sự khác biệt giữa A và $A(k)$ là một ma trận chứa tổng của các ma trận hạng 1 còn lại.

$$A - A(k) = \sum_{i=k+1}^r \sigma_i u_i u_i^T. \quad (4,96)$$

Theo Định lý 4.24, chúng ta ngay lập tức thu được $r-k+1$ là chuẩn phổ của ma trận hiệu. Hãy xem xét kỹ hơn (4.94). Nếu ta giả sử có một ma trận B khác với $rk(B) = k$, sao cho

$$A - B^2 < A - A(k)^2, \quad (4,97)$$

Khi đó tồn tại một không gian rỗng $Z \subset \mathbb{R}^n$ có kích thước ít nhất $(n - k)$, như là k chiều sao cho $x \in Z$ kéo theo $Bx = 0$. Từ đó suy ra rằng

$$Ax^2 = (A - B)x^2, \quad (4,98)$$

và bằng cách sử dụng một phiên bản của bất đẳng thức Cauchy-Schwartz (3.17) bao gồm các chuẩn của ma trận, chúng ta thu được

$$Ax^2 - A - B^2 x^2 < r-k+1 x^2. \quad (4,99)$$

Tuy nhiên, tồn tại một không gian con $(k+1)$ chiều trong đó $Ax^2 - r-k+1 x^2$, được tạo bởi các vectơ kỳ dị phải v_j , $j = k+1$ của A . Cộng tổng chiều của hai không gian này cho ra một số lớn hơn n , vì phải có một vectơ khác không trong cả hai không gian. Điều này mâu thuẫn với định lý hạng-không gian rỗng (Định lý 2.24) trong Mục 2.7.3.

Định lý Eckart-Young ngụ ý rằng chúng ta có thể sử dụng phân tích giá trị đơn (SVD) để giảm ma trận hạng r A xuống ma trận hạng k A' một cách có nguyên tắc và tối ưu (theo nghĩa chuẩn phổ). Chúng ta có thể diễn giải sự xấp xỉ của A bằng ma trận hạng k như một dạng nén mất mát. Do đó, sự xấp xỉ hạng thấp của một ma trận xuất hiện trong nhiều ứng dụng học máy, ví dụ như xử lý ảnh, lọc nhiễu và điều chỉnh các bài toán không xác định rõ. Hơn nữa, nó đóng vai trò quan trọng trong việc giảm chiều dữ liệu và phân tích thành phần chính, như chúng ta sẽ thấy trong Chương 10.

Ví dụ 4.15 (Tìm kiếm cấu trúc trong xếp hạng phim và người tiêu dùng (tiếp theo))

Quay trở lại ví dụ về xếp hạng phim, giờ đây chúng ta có thể áp dụng khái niệm xấp xỉ hạng thấp để xấp xỉ ma trận dữ liệu gốc.

Hãy nhớ rằng giá trị riêng đầu tiên của chúng ta thể hiện khái niệm về chủ đề khoa học viễn tưởng trong phim ảnh và đối với những người yêu thích khoa học viễn tưởng. Do đó, bằng cách chỉ sử dụng thuật ngữ giá trị riêng đầu tiên trong phép phân tích hạng 1 của ma trận xếp hạng phim, chúng ta thu được các xếp hạng dự đoán.

$$A_1 = u_1 v_1^T = \begin{pmatrix} -0,6710 \\ -0,7197 \\ -0,0939 \\ 0,1515 \end{pmatrix} \begin{pmatrix} 0,7367 & 0,6515 & 0,1811 & 0,100a \end{pmatrix} \quad (4,100a)$$

$$= \begin{pmatrix} 0.4943 & 0.4372 & 0.1215 \\ 0.5302 & 0.4689 & 0.1303 \\ 0.0692 & 0.0612 & 0.0170 \\ 0.1116 & 0.0987 & 0.0274 \end{pmatrix} \quad (4.100b)$$

Ước tính bậc 1 đầu tiên A1 này rất hữu ích: nó cho chúng ta biết rằng Ali và Beatrix thích phim khoa học viễn tưởng, chẳng hạn như Star Wars và Bladerunner (các mục có giá trị > 0,4), nhưng không thể hiện được xếp hạng của Chandra đối với các bộ phim khác. Điều này không đáng ngạc nhiên, vì loại phim mà Chandra thích không được thể hiện bởi giá trị riêng lẻ đầu tiên. Giá trị riêng lẻ thứ hai cung cấp cho chúng ta một ước tính bậc 1 tốt hơn cho những người yêu thích chủ đề phim:

$$A_2 = u_2 v_2^T = \begin{pmatrix} 0.0236 & 0.2054 & 0.0852 & 0.1762 & 0.9807 \\ -0.7705 & -0.6030 & 0.0020 & 0.0042 & 0.0231 \\ 0.0175 & 0.0362 & 0.2014 & 0.0656 & 0.1358 & 0.7556 \\ 0.0514 & 0.1063 & 0.5914 \end{pmatrix} \quad (4.101a)$$

$$= \begin{pmatrix} 0.0020 & 0.0042 & 0.0231 \\ 0.0175 & 0.0362 & 0.2014 \\ 0.0656 & 0.1358 & 0.7556 \\ 0.0514 & 0.1063 & 0.5914 \end{pmatrix} \quad (4.101b)$$

Trong phép xấp xỉ hạng 1 thứ hai A2 này, chúng ta nắm bắt tốt xếp hạng và thể loại phim của Chandra, nhưng không phải phim khoa học viễn tưởng. Điều này dẫn chúng ta đến việc xem xét phép xấp xỉ hạng 2 A (2), trong đó chúng ta kết hợp hai phép xấp xỉ hạng 1 đầu tiên


$$A(2) = \sigma_1 A_1 + \sigma_2 A_2 = \begin{pmatrix} 4.7801 & 4.2419 & 1.0244 \\ 5.2252 & 4.7522 & 0.0250 \\ 0.2493 & 0.2743 & 4.9724 \\ 0.7495 & 0.2756 & 4.0278 \end{pmatrix} \quad (4.102)$$

A (2) tương tự như bảng xếp hạng phim gốc

$$A = \begin{pmatrix} 5 & 4 & 1 \\ 5 & 5 & 0 \\ 0 & 0 & 5 \\ 1 & 0 & 4 \end{pmatrix} \quad (4.103)$$

Điều này cho thấy chúng ta có thể bỏ qua đóng góp của A3. Chúng ta có thể hiểu điều này như sau: trong bảng dữ liệu không có bằng chứng về một hạng mục chủ đề phim/người yêu phim thứ ba. Điều này cũng có nghĩa là toàn bộ không gian chủ đề phim/người yêu phim trong ví dụ của chúng ta là một không gian hai chiều được tạo thành từ phim khoa học viễn tưởng và phim nghệ thuật Pháp.

Hình 4.13 Một chức năng
cây phát sinh chủng
loài của ma trận
gặp phải trong học
máy.



4.7 Cây phát sinh ma trận

Trong Chương 2 và 3, chúng ta đã tìm hiểu những kiến thức cơ bản về đại số tuyến tính và hình học giải tích. Trong chương này, chúng ta đã xem xét các đặc điểm cơ bản của ma trận và các ánh xạ tuyến tính. Hình 4.13 mô tả cây phát sinh các mối quan hệ giữa các loại ma trận khác nhau (mũi tên đen chỉ "là tập con của") và các phép toán mà chúng ta có thể thực hiện trên chúng (màu xanh). Chúng ta xem xét tất cả các ma trận thực $A \in \mathbb{R}^{n \times m}$. Đối với các ma trận không vuông (trong đó $n \neq m$), phân tích SVD luôn tồn tại, như chúng ta đã thấy trong chương này. Tập trung vào các ma trận vuông $A \in \mathbb{R}^{n \times n}$, định thức cho chúng ta biết liệu một ma trận vuông có ma trận nghịch đảo hay không, tức là liệu nó có thuộc lớp các ma trận chính quy, khả nghịch hay không. Nếu ma trận vuông $n \times n$ có n vectơ riêng độc lập tuyến tính, thì ma trận đó không bị khiếm khuyết và tồn tại phép phân tích giá trị riêng (Định lý 4.12). Chúng ta biết rằng các giá trị riêng lặp lại có thể dẫn đến các ma trận khiếm khuyết, không thể chéo hóa được.

Ma trận không suy biến và ma trận không khiếm khuyết không giống nhau. Ví dụ, ma trận xoay sẽ khả nghịch (định thức khác 0) nhưng không thể chéo hóa trong tập số thực (các giá trị riêng không được đảm bảo là số thực).

Thuật ngữ
"phylogenetic" mô
tả cách chúng ta nắm
bắt mối quan
hệ giữa các cá thể hoặc
các nhóm và bắt nguồn từ
các từ tiếng Hy Lạp
có nghĩa là "bộ lạc".
và "nguồn".

Chúng ta sẽ đi sâu hơn vào nhánh ma trận vuông $n \times n$ không bị lỗi. Ma trận A được gọi là ma trận chuẩn nếu điều kiện $A^T A = AA^T$ được thỏa mãn. Hơn nữa, nếu điều kiện nghiêm ngặt hơn là $A^T A = AA^T = I$ được thỏa mãn, thì A được gọi là ma trận trực giao (xem Định nghĩa 3.8). Tập hợp các ma trận trực giao là một tập con của các ma trận chính quy (khả nghịch) và thỏa mãn $A^{-1} = A^T$.

Ma trận thông thường có một tập con thường gặp, đó là ma trận đối xứng. Các ma trận $S \in \mathbb{R}^{n \times n}$, thỏa mãn $S = S^T$. Ma trận đối xứng chỉ có... có các giá trị riêng thực. Một tập con của các ma trận đối xứng bao gồm các ma trận xác định dương P thỏa mãn điều kiện $x^T P x > 0$ cho tất cả $x \in \mathbb{R}^n \setminus \{0\}$. Trong trường hợp này, tồn tại một phép phân tích Cholesky duy nhất (Định lý 4.18). Các ma trận xác định dương chỉ có các giá trị riêng dương và luôn khả nghịch (tức là có định thức khác không).

Một tập hợp con khác của ma trận đối xứng bao gồm các ma trận đường chéo D . Ma trận đường chéo đóng kín dưới phép nhân và phép cộng, nhưng không nhất thiết tạo thành một nhóm (điều này chỉ đúng nếu tất cả các phần tử trên đường chéo đều khác 0 để ma trận có thể đảo được). Một ma trận đường chéo đặc biệt là ma trận đơn vị I .

4.8 Tài liệu tham khảo

thêm Phần lớn nội dung trong chương này thiết lập nền tảng toán học và kết nối chúng với các phương pháp nghiên cứu ánh xạ, nhiều trong số đó là cốt lõi của học máy ở cấp độ các giải pháp phần mềm nền tảng và các khối xây dựng cho hầu hết lý thuyết học máy. Việc mô tả ma trận bằng cách sử dụng định thức, phổ riêng và không gian riêng cung cấp các đặc điểm và điều kiện cơ bản để phân loại và phân tích ma trận. Điều này mở rộng đến tất cả các hình thức biểu diễn dữ liệu và ánh xạ liên quan đến dữ liệu, cũng như đánh giá tính ổn định số học của các phép toán tính toán trên các ma trận đó (Press và cộng sự, 2007).

Định thức là công cụ cơ bản để đảo ngược ma trận và tính toán giá trị riêng "thủ công". Tuy nhiên, đối với hầu hết các trường hợp, trừ những trường hợp nhỏ nhất, phép tính số bằng phương pháp khử Gauss cho kết quả tốt hơn định thức (Press và cộng sự, 2007). Mặc dù vậy, định thức vẫn là một khái niệm lý thuyết mạnh mẽ, ví dụ, để hiểu trực quan về hướng của một cơ sở dựa trên dấu của định thức. Vectơ riêng có thể được sử dụng để thực hiện các thay đổi cơ sở nhằm chuyển đổi dữ liệu thành tọa độ của các vectơ đặc trưng trực giao có ý nghĩa. Tương tự, các phương pháp phân rã ma trận, chẳng hạn như phân rã Cholesky, thường xuyên xuất hiện trở lại khi chúng ta tính toán hoặc mô phỏng các sự kiện ngẫu nhiên (Rubinstein và Kroese, 2016). Do đó, phân rã Cholesky cho phép chúng ta tính toán thủ thuật tái tham số hóa khi chúng ta muốn thực hiện phép vi phân liên tục trên các biến ngẫu nhiên, ví dụ, trong các bộ mã hóa tự động biến phân (Jimenez Rezende và cộng sự, 2014; Kingma và Welling, 2014).

Phân tích giá trị riêng là nền tảng giúp chúng ta trích xuất thông tin có ý nghĩa và dễ hiểu để mô tả các ánh xạ tuyến tính.

136

Phân rã ma trận

Do đó, phép phân tích giá trị riêng là nền tảng của một lớp máy móc tổng quát. Các thuật toán học máy được gọi là phương pháp phổ thực hiện phân tích giá trị riêng của một hạt nhân xác định dương. Các phương pháp phân tích phổ này bao gồm các phương pháp cổ điển trong phân tích dữ liệu thống kê, chẳng hạn như tiếp theo:

- Phân tích thành phần chính (PCA (Pearson, 1901), xem thêm Chương 10), Trong đó, người ta tìm kiếm một không gian con có chiều thấp, giải thích được phần lớn sự biến thiên trong dữ liệu.
- Phân tích phân biệt Fisher, nhằm mục đích xác định một siêu mặt phẳng phân tách để phân loại dữ liệu (Mika et al., 1999).
- Phương pháp phân tích đa chiều (MDS) (Carroll và Chang, 1970).

Hiệu quả tính toán của các phương pháp này thường đến từ việc tìm ra phép xấp xỉ hạng k tốt nhất cho một ma trận đối xứng, bán xác định dương. ma trận. Các ví dụ hiện đại hơn về phương pháp phổ có những đặc điểm khác nhau. nguồn gốc của chúng đều như nhau, nhưng mỗi nguồn gốc đều yêu cầu tính toán các vectơ riêng. và các giá trị riêng của một hạt nhân xác định dương, chẳng hạn như Isomap (Tenenbaum et al., 2000), bản đồ giá trị riêng Laplacian (Belkin và Niyogi, 2003), ma trận Hessian bản đồ riêng (Donoho và Grimes, 2003), và phân cụm phổ (Shi và Malik, 2000). Các phép tính cốt lõi của chúng thường dựa trên nền tảng... bằng các kỹ thuật xấp xỉ ma trận hạng thấp (Belabbas và Wolfe, 2009) như chúng ta đã gặp ở đây thông qua SVD.

Phương pháp SVD cho phép chúng ta khám phá một số thông tin tương tự như phân tích giá trị riêng. Tuy nhiên, phân tích SVD có tính ứng dụng tổng quát hơn. Đối với các ma trận không vuông và bảng dữ liệu. Các phương pháp phân tích ma trận này trở nên hữu ích bất cứ khi nào chúng ta muốn xác định tính không đồng nhất trong dữ liệu. khi chúng ta muốn thực hiện nén dữ liệu bằng phương pháp xấp xỉ, ví dụ, thay vì lưu trữ $n \times m$ giá trị thì chỉ lưu trữ $(n+m)k$ giá trị, hoặc khi chúng ta muốn để thực hiện tiền xử lý dữ liệu, ví dụ, để loại bỏ sự tương quan giữa các biến dự báo. một ma trận thiết kế (Ormoneit et al., 2001). Phương pháp SVD hoạt động trên các ma trận, mà chúng ta có thể hiểu là các mảng hình chữ nhật với hai chỉ số (hàng và) cột). Sự mở rộng cấu trúc giống ma trận lên chiều cao hơn Mảng được gọi là tensor. Hóa ra SVD là trường hợp đặc biệt của một họ phân rã tổng quát hơn hoạt động trên các tenxơ như vậy (Kolda và Bader, 2009). Các phép toán giống SVD và các phép xấp xỉ hạng thấp trên tensor, ví dụ như phép phân rã Tucker (Tucker, 1966). hoặc phép phân rã CP (Carroll và Chang, 1970).

Phương pháp xấp xỉ hạng thấp SVD thường được sử dụng trong học máy vì lý do hiệu quả tính toán. Điều này là do nó làm giảm... Lượng bộ nhớ và các phép toán có phép nhân khác 0 mà chúng ta cần để thực hiện trên các ma trận dữ liệu có thể rất lớn (Trefethen và Bau III, (1997). Hơn nữa, các phép xấp xỉ hạng thấp được sử dụng để thao tác trên các ma trận có thể chứa các giá trị bị thiếu cũng như cho các mục đích mất mát dữ liệu. nén và giảm kích thước (Moonen và De Moor, 1995; Markovsky, 2011).

Bài tập

4.1 Tính định thức bằng cách sử dụng khai triển Laplace (sử dụng hàng đầu tiên) và quy tắc Sarrus cho

$$A = \begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \\ 0 & 2 & 4 \end{pmatrix}.$$

4.2 Tính định thức sau một cách hiệu quả:

$$\begin{pmatrix} 2 & 0 & 1 & 2 & 0 \\ 2 & 1 & 0 & 1 & 0 \\ & 1 & 2 & & 1 \\ 2 & 0 & 2 & 1 & 2 & 0 & 0 \\ 2 & 1 & & & & & 1 \end{pmatrix}.$$

4.3 Tính các không gian con riêng của

Một:

$$A := \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}$$

b.

$$B := \begin{pmatrix} 2 & 2 \\ 2 & 1 \end{pmatrix}$$

4.4 Tính tất cả các không gian riêng của

$$A = \begin{pmatrix} 0 & 1 & 1 & & 1 \\ 1 & 1 & 2 & 3 & \\ 2 & 1 & 0 & 0 & \\ 1 & 1 & 1 & 0 & \end{pmatrix}.$$

4.5 Tính chéo hóa của ma trận không liên quan đến tính nghịch đảo của nó. Hãy xác định xem bốn ma trận sau có chéo hóa được và/hoặc nghịch đảo được hay không.

$$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}, \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}.$$

4.6 Tính các không gian riêng của các ma trận biến đổi sau. Chúng có thể chéo hóa được không?

a. Đối với

$$A = \begin{pmatrix} 2 & 3 & 0 \\ 1 & 4 & 3 \\ 0 & 0 & 1 \end{pmatrix}$$

b. Đối với

$$A = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

4.7 Các ma trận sau có chéo hóa được không? Nếu có, hãy xác định dạng chéo của chúng và cơ sở mà theo đó các ma trận biến đổi là ma trận chéo. Nếu không, hãy đưa ra lý do tại sao chúng không chéo hóa được.

a.

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 8 \end{pmatrix}$$

b.

$$A = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}$$

c.

$$A = \begin{pmatrix} 5 & 4 & 2 & 1 \\ 0 & 1 & 1 & 1 \\ 1 & 1 & 3 & 0 \\ 1 & 1 & 1 & 2 \end{pmatrix}$$

d.

$$A = \begin{pmatrix} 5 & 6 & 6 \\ 1 & 4 & 2 \\ 3 & 6 & 4 \end{pmatrix}$$

4.8 Tìm phân tích SVD của ma trận

$$A = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \end{pmatrix}.$$

4.9 Tìm phân tích giá trị của

$$A = \begin{pmatrix} 2 & 2 \\ 1 & 1 \end{pmatrix}.$$

4.10 Tìm giá trị xấp xỉ hạng 1 của

$$A = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \end{pmatrix}$$

4.11 Chứng minh rằng với mọi $A \in \mathbb{R}^{m \times n}$, các ma trận $A^T A$ và AA^T đều có cùng các giá trị riêng khác không.


4.12 Chứng minh rằng với $x \neq 0$ thì Định lý 4.24 đúng, tức là, chứng minh rằng

$$\max_{\|x\|=1} \frac{Ax \cdot x}{\|x\|^2} = \sigma_1,$$

trong đó σ_1 là giá trị riêng lớn nhất của $A^T A \in \mathbb{R}^{m \times n}$.


5

Giải tích vectơ




Nhiều thuật toán trong học máy tối ưu hóa một hàm mục tiêu liên quan đến một tập hợp các tham số mô hình mong muốn, kiểm soát mức độ giải thích dữ liệu của mô hình: Việc tìm kiếm các tham số tốt có thể được diễn đạt như một bài toán tối ưu hóa (xem Phần 8.2 và 8.3). Ví dụ bao gồm: (i) hồi quy tuyến tính (xem Chương 9), trong đó chúng ta xem xét các bài toán khớp đường cong và tối ưu hóa các tham số trọng số tuyến tính để tối đa hóa khả năng; (ii) bộ mã hóa tự động mạng nơ-ron để giảm chiều và nén dữ liệu, trong đó các tham số là trọng số và độ lệch của mỗi lớp, và chúng ta giảm thiểu lỗi tái tạo bằng cách áp dụng lặp đi lặp lại quy tắc chuỗi; và (iii) mô hình hỗn hợp Gaussian (xem Chương 11) để mô hình hóa phân bố dữ liệu, trong đó chúng ta tối ưu hóa các tham số vị trí và hình dạng của mỗi thành phần hỗn hợp để tối đa hóa khả năng của mô hình. Hình 5.1 minh họa một số bài toán này, mà chúng ta thường giải quyết bằng cách sử dụng các thuật toán tối ưu hóa khai thác thông tin gradient (Phần 7.1). Hình 5.2 cung cấp cái nhìn tổng quan về mối liên hệ giữa các khái niệm trong chương này và cách chúng được kết nối với các chương khác trong sách.

Khái niệm trọng tâm của chương này là hàm số. Hàm số f là một đại lượng liên hệ hai đại lượng với nhau. Trong cuốn sách này, các đại lượng đó thường là các giá trị đầu vào x và các giá trị đích (giá trị hàm số) $f(x)$, mà chúng ta giả định là các giá trị thực nếu không được nêu rõ khác. Ở đây, $\mathcal{X}$ là miền xác định của f , và các giá trị hàm số $f(x)$ là tập ảnh/tập giá trị của f . Hình 5.1 Phép tính vectơ đóng vai trò trung tâm trong (a) hồi quy (phù hợp đường cong) và (b) ước lượng mật độ, tức là mô hình hóa phân bố dữ liệu.




(a) Bài toán hồi quy: Tìm các tham số sao cho đường cong giải thích tốt các quan sát (điểm giao nhau).



(b) Ước lượng mật độ bằng mô hình hỗn hợp Gaussian: Tìm giá trị trung bình và hiệp phương sai sao cho dữ liệu (các chấm) có thể được giải thích tốt.

Hình 5.2. Sơ đồ tư duy về các khái niệm được giới thiệu trong chương này, cùng với thời điểm chúng được sử dụng trong các phần khác của cuốn sách.



Mục 2.7.3 trình bày chi tiết hơn nhiều trong ngữ cảnh của các hàm tuyến tính. Chúng ta thường viết

$$f : D \rightarrow \mathbb{R} \quad (5.1a)$$

$$x \mapsto f(x) \quad (5.1b)$$

để xác định một hàm, trong đó (5.1a) xác định rằng f là một ánh xạ từ D đến $\mathbb{R}$ và (5.1b) xác định việc gán rõ ràng một đầu vào x cho một giá trị hàm $f(x)$. Một hàm f gán cho mỗi đầu vào x chính xác một giá trị hàm $f(x)$.

Ví dụ 5.1 Nhớ

lại tích vô hướng như một trường hợp đặc biệt của tích trong (Mục 3.2).

Trong ký hiệu trước đó, hàm $f(x) = x^T x$ trên $\mathbb{R}^2$ sẽ được xác định như sau:


$$f : \mathbb{R}^2 \rightarrow \mathbb{R} \quad (5.2a)$$

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \mapsto x_1^2 + x_2^2 \quad (5.2b)$$

Trong chương này, chúng ta sẽ thảo luận về cách tính đạo hàm của các hàm số, điều này thường rất cần thiết để hỗ trợ quá trình học tập trong các mô hình máy học vì đạo hàm chỉ ra hướng dốc nhất. Do đó,

5.1 Vi phân của hàm một biến

141



Hình 5.3 Độ dốc trung bình của một hàm f giữa x_0 và $x_0 + \delta x$ là độ dốc của đường cát tuyến (màu xanh) đi qua $f(x_0)$ và $f(x_0 + \delta x)$ và được cho bởi $\delta y / \delta x$.

Giải tích vectơ là một trong những công cụ toán học cơ bản mà chúng ta cần trong học máy.

Xuyên suốt cuốn sách này, chúng ta giả định rằng các hàm số là khả vi. Với một số định nghĩa kỹ thuật bổ sung, mà chúng ta không đề cập ở đây, nhiều phương pháp được trình bày có thể được mở rộng cho các đạo hàm dưới (các hàm liên tục nhưng không khả vi tại một số điểm nhất định). Chúng ta sẽ xem xét phần mở rộng cho trường hợp các hàm có ràng buộc trong Chương 7.

5.1 Vi phân của hàm một biến

Trong phần tiếp theo, chúng ta sẽ xem xét lại ngắn gọn phép vi phân của một hàm một biến, một khái niệm có thể quen thuộc từ toán học trung học. Chúng ta bắt đầu với thương số sai phân của một hàm một biến $y = f(x)$, $x, y \in \mathbb{R}$, mà sau này chúng ta sẽ sử dụng để định nghĩa đạo hàm.

Định nghĩa 5.1 (Thương số sai phân). Thương số sai phân

thương số khác biệt

$$\frac{\delta y}{\delta x} := \frac{f(x + \delta x) - f(x)}{\delta x} \quad (5.3)$$

Hàm này tính độ dốc của đường cát tuyến đi qua hai điểm trên đồ thị của hàm f . Trong Hình 5.3, đó là các điểm có tọa độ x là x_0 và $x_0 + \delta x$.

Thương số sai phân cũng có thể được coi là độ dốc trung bình của f giữa x và $x + \delta x$ nếu ta giả sử f là một hàm tuyến tính. Trong giới hạn khi $\delta x \rightarrow 0$, ta thu được tiếp tuyến của f tại x , nếu f khả vi. Tiếp tuyến khi đó chính là đạo hàm của f tại x .

Định nghĩa 5.2 (Đạo hàm). Cụ thể hơn, đối với $h > 0$, đạo hàm của f tại x được định nghĩa là giới hạn

$$\frac{df}{dx} \Big|_{x=x_0} = \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h}, \quad (5.4)$$

và đường cát tuyến trong Hình 5.3 trở thành đường tiếp tuyến.

Đạo hàm của f chỉ theo hướng dốc nhất của f .

Ví dụ 5.2 (Đạo hàm của đa thức)

Chúng ta muốn tính đạo hàm của $f(x) = x^N$. Có thể chúng ta đã biết rằng đáp án sẽ là Nx^{N-1} nhưng chúng ta muốn chứng minh kết quả này bằng cách sử dụng định nghĩa đạo hàm là giới hạn của thương số sai phân.

Sử dụng định nghĩa đạo hàm trong (5.4), ta thu được

$$\frac{df}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

(5.5a)

$$= \lim_{h \rightarrow 0} \frac{h(x+h)^{N-1} + \dots + x^{N-1}h}{h}$$

(5.5b)

$$= \lim_{h \rightarrow 0} \frac{\sum_{i=0}^{N-1} x^i h^{N-i} + h^N}{h}$$

(5.5c)

Ta thấy rằng $x^N = \sum_{i=0}^N x^i h^{N-i}$. Bằng cách bắt đầu tổng từ 1, x^N - thuật ngữ bị hủy bỏ, và ta thu được

$$\frac{df}{dx} = \lim_{h \rightarrow 0} \frac{\sum_{i=1}^N x^i h^{N-i}}{h}$$

(5.6a)

$$= \lim_{h \rightarrow 0} \sum_{i=1}^N x^i h^{N-i-1}$$

(5.6b)

$$= \lim_{h \rightarrow 0} \left(x^{N-1} + \sum_{i=2}^N x^i h^{N-i-1} \right)$$

(5.6c)

$$= \frac{N!}{1!(N-1)!} x^{N-1} = Nx^{N-1}$$

(5.6d)

5.1.1 Dòng Taylor

Chuỗi Taylor là một biểu diễn của hàm f dưới dạng tổng vô hạn các số hạng. Các số hạng này được xác định bằng cách sử dụng các đạo hàm của f được tính tại x_0 .

Đa thức Taylor

Chúng ta định nghĩa $T_n(x) := \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$ là đa thức bậc n của hàm f tại x_0 .

Định nghĩa 5.3 (Đa thức Taylor). Đa thức Taylor bậc n của hàm $f : \mathbb{R} \rightarrow \mathbb{R}$ tại x_0 được định nghĩa như sau:

$$T_n(x) := \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$$

(5.7)

trong đó $f^{(k)}(x_0)$ là đạo hàm bậc k của f tại x_0 (mà chúng ta giả định là tồn tại) và $\frac{f^{(k)}(x_0)}{k!}$ là các hệ số của đa thức. $k!$

Định nghĩa 5.4 (Chuỗi Taylor). Đối với một hàm trơn $f \in C^\infty$, $f : \mathbb{R} \rightarrow \mathbb{R}$, chuỗi Taylor của f tại x_0 được định nghĩa như sau:

5.1 Vi phân của hàm một biến143

$$T_{\infty}(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k.$$

(5.8)

Với $x_0 = 0$, ta thu được chuỗi Maclaurin như một trường hợp đặc biệt của chuỗi Taylor. Nếu $f \in C^{\infty}$ có nghĩa là $f(x) = T_{\infty}(x)$, thì f được gọi là hàm giải tích.

f có thể khả vi liên tục vô số lần.

Lưu ý. Nói chung, đa thức Taylor bậc n là một phép xấp xỉ của một hàm, hàm này không nhất thiết phải là một đa thức. Đa thức Taylor tương tự như f trong một vùng lân cận xung quanh x_0 . Tuy nhiên, đa thức Taylor bậc n là một biểu diễn chính xác của một đa thức f bậc $k \leq n$ vì tất cả các đạo hàm của f ($i \leq k$), $i > k$ biến mất.

Loại Maclaurin phân tích

Ví dụ 5.3 (Đa thức Taylor)
Chúng ta xem xét đa thức

$$f(x) = x^4$$

(5.9)

và tìm đa thức Taylor T_6 , được đánh giá tại $x_0 = 1$. Chúng ta bắt đầu bằng cách tính các hệ số $f^{(k)}(1)$ cho $k = 0, \dots, 6$:

$$f(1) = 1$$

$f'(1) = 4$

(5.10)

$$f'(1) = 4$$

(5.11)

$$f''(1) = 12$$

(5.12)

$$f^{(3)}(1) = 24$$

(5.13)

$$f^{(4)}(1) = 24$$

(5.14)

$$f^{(5)}(1) = 0$$

(5.15)

$$f^{(6)}(1) = 0$$

(5.16)

Do đó, đa thức Taylor cần tìm là

$$T_6(x) = \sum_{k=0}^6 \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$$

(5.17a)

$$= 1 + 4(x - 1) + 6(x - 1)^2 + 4(x - 1)^3 + (x - 1)^4 + 0.$$

(5.17b)

Nhân ra và sắp xếp lại ta được

$$T_6(x) = (1^4 + 6^4 + 1) + x(4^12 + 12^4)$$

$$+ x^2(6^12 + 6) + x^3(4^4) + x^4$$

(5.18a)

$$4 = x^4 = f(x),$$

(5.18b)

Tức là, ta thu được một biểu diễn chính xác của hàm số ban đầu.

Hình 5.4 Đa thức

Taylor. Hàm gốc

$$f(x) = \sin(x) + \cos(x)$$

(màu đen, nét

liền) được xấp

xỉ bằng đa thức

Taylor (nét đứt) xung

quanh $x_0 = 0$.

Đa thức Taylor bậc

cao hơn xấp


xỉ hàm f tốt hơn

và toàn cục hơn.

T10 đã tương tự

như f trong

[4, 4].



Ví dụ 5.4 (Dãy Taylor)

Hãy xem xét hàm số trong Hình 5.4 được cho bởi

$$f(x) = \sin(x) + \cos(x) \quad C^\infty. \quad (5.19)$$

Chúng ta tìm khai triển chuỗi Taylor của f tại $x_0 = 0$, đó chính là khai triển chuỗi Maclaurin của f . Chúng ta thu được các đạo hàm sau:

$$f(0) = \sin(0) + \cos(0) = 1 \quad f \quad (5.20)$$

$$f'(0) = \cos(0) - \sin(0) = 1 \quad (5.21)$$

$$f''(0) = -\sin(0) - \cos(0) = -1 \quad (5.22)$$

$$f^{(3)}(0) = -\cos(0) + \sin(0) = -1 \quad f \quad (5.23)$$

$$f^{(4)}(0) = \sin(0) + \cos(0) = f(0) = 1 \quad (5.24)$$

$$\vdots$$

Chúng ta có thể thấy một quy luật ở đây: Các hệ số trong chuỗi Taylor của chúng ta chỉ là ± 1 (vì $\sin(0) = 0$), mỗi hệ số xuất hiện hai lần trước khi chuyển sang hệ số khác. Hơn nữa, $f^{(k+4)}(0) = f^{(k)}(0)$.

Do đó, khai triển chuỗi Taylor đầy đủ của f tại $x_0 = 0$ được cho bởi $f^{(k)}(x_0) (x$

$$T^\infty(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(0)}{k!} x^k \quad (5.25a)$$

$$= 1 + x - \frac{1}{2!}x^2 + \frac{1}{3!}x^3 - \frac{1}{4!}x^4 + \frac{1}{5!}x^5 - \dots \quad (5.25b)$$

$$= 1 - \frac{1}{2!}x^2 + \frac{1}{4!}x^4 - \dots + x - \frac{1}{3!}x^3 + \frac{1}{5!}x^5 - \dots \quad (5.25c)$$

$$= \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k)!} x^{2k} + \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k+1)!} x^{2k+1} \quad (5.25d)$$

$$= \cos(x) + \sin(x), \quad (5.25e)$$