

trong đó chúng tôi đã sử dụng các biểu diễn chuỗi lũy thừa.

$$\cos(x) = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k)!} x^{2k}, \tag{5.26}$$

$$\sin(x) = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k+1)!} x^{2k+1}. \tag{5.27}$$

Hình 5.4 thể hiện các đa thức Taylor bậc nhất tương ứng T_n cho $n = 0, 1, 5, 10$.

biểu diễn chuỗi lũy thừa

Lưu ý: Dãy Taylor là một trường hợp đặc biệt của dãy lũy thừa.

$$f(x) = \sum_{k=0}^{\infty} a_k (x - c)^k \tag{5.28}$$

trong đó a_k là các hệ số và c là một hằng số, có dạng đặc biệt như trong Định nghĩa 5.4.

5.1.2 Quy tắc đạo hàm

Trong phần tiếp theo, chúng ta sẽ trình bày ngắn gọn các quy tắc đạo hàm cơ bản, trong đó ta ký hiệu đạo hàm của f là f' .

Quy tắc sản phẩm:

$$(f(x)g(x))' = f'(x)g(x) + f(x)g'(x) \tag{5.29}$$

Quy tắc thương:

$$\left(\frac{f(x)}{g(x)}\right)' = \frac{f'(x)g(x) - f(x)g'(x)}{(g(x))^2} \tag{5.30}$$

Quy tắc cộng:

$$(f(x) + g(x))' = f'(x) + g'(x) \tag{5.31}$$

Quy tắc chuỗi:

$$(g(f(x)))' = (g' \circ f)(x) = g'(f(x))f'(x) \tag{5.32}$$

Ở đây, $g' \circ f$ biểu thị phép hợp hàm $x \mapsto g'(f(x))$.

Ví dụ 5.5 (Quy tắc chuỗi)
Hãy tính đạo hàm của hàm số $h(x) = (2x + 1)^4$ bằng cách sử dụng quy tắc chuỗi. Với

$$h(x) = (2x + 1)^4 = g(f(x)), \tag{5.33}$$

$$f(x) = 2x + 1, \tag{5.34}$$

$$g(f) = f^4, \tag{5.35}$$

chúng ta thu được các đạo hàm của f và g như sau:

$$f'(x) = 2, \tag{5.36}$$

$$g'(f) = 4f^3, \tag{5.37}$$

sao cho đạo hàm của h được cho bởi

$$h'(x) = g'(f)f'(x) = (4f^3)' \cdot 2 \stackrel{(5.34)}{=} 4(2x + 1)^3 \cdot 2 = 8(2x + 1)^3, \quad (5.38)$$

trong đó chúng tôi đã sử dụng quy tắc chuỗi (5.32) và thay thế định nghĩa của $f'(f)$.
(5.34) trong g trong

5.2 Vi phân riêng phần và đạo hàm riêng

Phép vi phân như đã thảo luận trong Phần 5.1 áp dụng cho các hàm f của một biến vô hướng $x \in \mathbb{R}$. Trong phần tiếp theo, chúng ta xem xét trường hợp tổng quát khi hàm f phụ thuộc vào một hoặc nhiều biến $x \in \mathbb{R}^n$, ví dụ, $f(x) = f(x_1, x_2)$. Sự tổng quát hóa của đạo hàm đối với các hàm nhiều biến chính là đạo hàm bậc hai (gradient).

Ta tìm đạo hàm riêng của hàm f theo x bằng cách thay đổi từng biến một và giữ các biến còn lại không đổi. Đạo hàm riêng chính là tập hợp các đạo hàm riêng này.

Định nghĩa 5.5 (Đạo hàm riêng). Đối với một hàm $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $x = f(x)$, $x \in \mathbb{R}^n$ của n biến $x_1, \dots, x_n$, ta định nghĩa các đạo hàm riêng như sau:

$$\frac{\partial f}{\partial x_1} = \lim_{h \rightarrow 0} \frac{f(x_1 + h, x_2, \dots, x_n) - f(x)}{h}$$
$$\vdots$$
$$\frac{\partial f}{\partial x_n} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{n-1}, x_n + h) - f(x)}{h}$$

(5.39)

và tập hợp chúng lại thành vectơ hàng.

$$x^T f = \text{grad} f = dx \frac{df}{dx} = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right] \in \mathbb{R}^{1 \times n}, \quad (5.40)$$

x_2 trong đó n là số biến và 1 là chiều của ảnh/phạm vi/miền giá trị của f . Ở đây, chúng ta định nghĩa vectơ cột $x = [x_1, \dots, x_n]^T$ quát. Vectơ hàng trong (5.40) được gọi là đạo hàm của f hoặc Jacobian $\in \mathbb{R}^n$ và là sự tổng hóa của đạo hàm từ Phần 5.1.

Lưu ý. Định nghĩa ma trận Jacobian này là trường hợp đặc biệt của định nghĩa tổng quát về ma trận Jacobian cho các hàm giá trị vectơ như là tập hợp các đạo hàm riêng. Chúng ta sẽ quay lại vấn đề này trong Phần 5.3.

Ví dụ 5.6 (Đạo hàm riêng sử dụng quy tắc chuỗi)

Đối với $f(x, y) = (x + 2y)^3$ ta thu được các đạo hàm riêng $f(x, y)$

$$\frac{\partial f}{\partial x} = 2(x + 2y)^2 \cdot 1 = 2(x + 2y)^2, \quad \frac{\partial f}{\partial y} = 3(x + 2y)^2 \cdot 2 = 6(x + 2y)^2, \quad (5.41)$$

đạo hàm riêng

độ dốc
Jacobian

Chúng ta có thể sử dụng
kết quả từ vô hướng
Ví phân: Mỗi đạo hàm
riêng là một đạo hàm
theo một đại lượng
vô hướng.

5.2 Vi phân riêng phần và đạo hàm riêng

147

$$\frac{f(x, y)}{y} = 2(x + 2y^3) - (x + 2y^3) = 12(x + 2y^3)y^2. \quad (5.42)$$

trong đó chúng tôi đã sử dụng quy tắc chuỗi (5.32) để tính các đạo hàm riêng.

Lưu ý (Gradient dưới dạng vectơ hàng). Trong tài liệu, việc định nghĩa vectơ gradient dưới dạng vectơ cột không phải là hiếm gặp, theo quy ước rằng các vectơ nói chung là vectơ cột. Lý do chúng ta định nghĩa vectơ gradient dưới dạng vectơ hàng là có hai mặt: Thứ nhất, chúng ta có thể khái quát hóa một cách nhất quán gradient thành các hàm có giá trị vectơ $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ (khi đó gradient trở thành một ma trận). Thứ hai, chúng ta có thể áp dụng ngay quy tắc chuỗi đa biến mà không cần chú ý đến chiều của gradient. Chúng ta sẽ thảo luận cả hai điểm này trong Phần 5.3.

Ví dụ 5.7 (Độ dốc)

Với hàm $f(x_1, x_2) = 2x_1x_2 + x_1^3$ đạo hàm riêng (tức là đạo hàm của f đối với x_1 và x_2) là $f(x_1, x_2) = 2x_1x_2 + x_1^3$

$$\frac{f(x_1, x_2)}{x_2} = 2x_1 + \frac{3x_1^3}{2} \quad (5.43)$$

$$\frac{f(x_1, x_2)}{x_1} = 2x_2 + 3x_1^2 \quad (5.44)$$

và độ dốc sau đó là

$$\frac{df}{dx} = \begin{pmatrix} \frac{f(x_1, x_2)}{x_1} & \frac{f(x_1, x_2)}{x_2} \end{pmatrix} = \begin{pmatrix} 2x_2 + 3x_1^2 & 2x_1 + \frac{3x_1^3}{2} \end{pmatrix} \in \mathbb{R}^{1 \times 2}. \quad (5.45)$$

5.2.1 Các quy tắc cơ bản của phép đạo hàm riêng

Trong trường hợp đa biến, khi $x \in \mathbb{R}^n$, những quy tắc phân biệt cơ bản đó điều chúng ta đã biết từ thời đi học (ví dụ: quy tắc tổng, quy tắc tích, quy tắc chuỗi; xem thêm Mục 5.1.2) vẫn áp dụng được. Tuy nhiên, khi tính đạo hàm đối với các vectơ $x \in \mathbb{R}^n$, chúng ta cần chú ý: Độ dốc của chúng ta lúc này liên quan đến vectơ và ma trận, và phép nhân ma trận không có tính chất giao hoán (Mục 2.2.1), tức là thứ tự thực hiện rất quan trọng.

Dưới đây là các quy tắc tích, quy tắc tổng và quy tắc chuỗi tổng quát:

$$\text{Quy tắc sản phẩm: } \frac{d}{dx} (g(x) + f(x)) = \frac{dg(x)}{dx} + \frac{df(x)}{dx} \quad (5.46)$$

$$\text{Quy tắc cộng: } \frac{d}{dx} (g(x) \cdot f(x)) = \frac{dg(x)}{dx} \cdot f(x) + g(x) \cdot \frac{df(x)}{dx} \quad (5.47)$$

Quy tắc tích:

$$(fg)' = f'g + fg'$$

Quy tắc

$$(f + g)' = f' + g'$$

Quy tắc

$$\text{chuỗi: } (g(f))' = (g'(f))f'$$

Quy tắc chuỗi:
$$\frac{d}{dx}(g \circ f)(x) = \frac{dg}{df} \frac{df}{dx} = \frac{dg}{df} \frac{1}{f'(x)} \quad (5.48)$$

Đây chỉ là trực
giác, chứ không chính
xác về mặt toán
học vì đạo hàm riêng
không phải là một phân
số.

Chúng ta hãy xem xét kỹ hơn quy tắc chuỗi. Quy tắc chuỗi (5.48) có phần giống với các quy tắc nhân ma trận, trong đó chúng ta đã nói rằng các chiều liên kế phải khớp nhau để phép nhân ma trận được xác định; xem Phần 2.2.1. Nếu chúng ta đi từ trái sang phải, quy tắc chuỗi thể hiện các tính chất tương tự: f xuất hiện trong “mẫu số” của thừa số đầu tiên và trong “tử số” của thừa số thứ hai. Nếu chúng ta nhân các thừa số với nhau, phép nhân được xác định, tức là các chiều của f khớp nhau, và f “triệt tiêu”, sao cho g/f vẫn giữ nguyên.

5.2.2 Quy tắc chuỗi

Xét một hàm $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ của hai biến x_1, x_2 . Hơn nữa, $x_1(t)$ và $x_2(t)$ bản thân chúng là các hàm của t . Để tính đạo hàm của f đối với t , chúng ta cần áp dụng quy tắc chuỗi (5.48) cho các hàm đa biến như sau:

$$\frac{df}{dt} = \frac{f}{x_1} \frac{dx_1}{dt} + \frac{f}{x_2} \frac{dx_2}{dt} = \frac{f}{x_1} \frac{1}{t} + \frac{f}{x_2} \frac{1}{t}, \quad (5.49)$$

trong đó d biểu thị độ dốc và dx biểu thị các đạo hàm riêng.

Ví dụ 5.8 Xét
hàm $f(x_1, x_2) = x_1^2 + 2x_2$, trong đó $x_1 = \sin t$ và $x_2 = \cos t$, thì

$$\frac{df}{dt} = \frac{f}{x_1} \frac{dx_1}{dt} + \frac{f}{x_2} \frac{dx_2}{dt} = \frac{2x_1}{\sin t} \cos t + \frac{2}{\cos t} (-\sin t) = 2 \sin t \cos t - 2 \sin t = 2 \sin t (\cos t - 1) \quad (5.50a)$$
$$\frac{df}{dt} = \frac{2 \sin t \cos t - 2 \sin t}{\cos t} = 2 \sin t (\cos t - 1) \quad (5.50b)$$

là đạo hàm tương ứng của f theo t .

Nếu $f(x_1, x_2)$ là một hàm của x_1 và x_2 , trong đó $x_1(s, t)$ và $x_2(s, t)$ bản thân chúng cũng là các hàm của hai biến s và t , thì quy tắc chuỗi sẽ cho ra các đạo hàm riêng.

$$\frac{f}{s} = \frac{f}{x_1} \frac{dx_1}{ds} + \frac{f}{x_2} \frac{dx_2}{ds} = \frac{f}{x_1} \frac{1}{s} + \frac{f}{x_2} \frac{1}{s}, \quad (5.51)$$

$$\frac{f}{t} = \frac{f}{x_1} \frac{dx_1}{dt} + \frac{f}{x_2} \frac{dx_2}{dt} = \frac{f}{x_1} \frac{1}{t} + \frac{f}{x_2} \frac{1}{t}, \quad (5.52)$$

Do đó, đạo hàm riêng của một hàm vectơ $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ đối với x_i , $i = 1, \dots, n$, được cho bởi vectơ

$$\frac{df}{dx_i} = \begin{pmatrix} \frac{f_1}{x_i} \\ \vdots \\ \frac{f_m}{x_i} \end{pmatrix} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{i-1}, x_i+h, x_{i+1}, \dots, x_n) - f(x)}{h} \in \mathbb{R}^m. \quad (5.55)$$

Từ (5.40), ta biết rằng đạo hàm riêng của f đối với một vectơ là vectơ hàng của các đạo hàm riêng. Trong (5.55), mỗi đạo hàm riêng f/x_i bản thân nó là một vectơ cột. Do đó, ta thu được đạo hàm riêng của $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ đối với $x \in \mathbb{R}^n$ bằng cách tập hợp các đạo hàm riêng này:

$$\frac{df(x)}{dx} = f(x) \begin{pmatrix} \frac{f_1(x)}{x_1} & \dots & \frac{f_1(x)}{x_n} \\ \vdots & & \vdots \\ \frac{f_m(x)}{x_1} & \dots & \frac{f_m(x)}{x_n} \end{pmatrix} \quad (5.56a)$$

$$= \begin{pmatrix} \frac{f_1(x)}{x_1} & \dots & \frac{f_1(x)}{x_n} \\ \vdots & & \vdots \\ \frac{f_m(x)}{x_1} & \dots & \frac{f_m(x)}{x_n} \end{pmatrix} \in \mathbb{R}^{m \times n}. \quad (5.56b)$$

Jacobian

Độ dốc của một hàm số

$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ là một ma trận có kích thước $m \times n$.

Định nghĩa 5.6 (Ma trận Jacobian). Tập hợp tất cả các đạo hàm riêng bậc nhất của một hàm vectơ $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ được gọi là ma trận Jacobian. Ma trận Jacobian J là một ma trận $m \times n$, mà chúng ta định nghĩa và sắp xếp như sau:

$$J = \frac{df(x)}{dx} = \begin{pmatrix} \frac{f_1(x)}{x_1} & \dots & \frac{f_1(x)}{x_n} \\ \vdots & & \vdots \\ \frac{f_m(x)}{x_1} & \dots & \frac{f_m(x)}{x_n} \end{pmatrix} \quad (5.57)$$

$$= \begin{pmatrix} \frac{f_1(x)}{x_1} & \dots & \frac{f_1(x)}{x_n} \\ \vdots & & \vdots \\ \frac{f_m(x)}{x_1} & \dots & \frac{f_m(x)}{x_n} \end{pmatrix}, \quad (5.58)$$

$$J_{ij} = \frac{\partial f_i}{\partial x_j}. \quad (5.59)$$


Là trường hợp đặc biệt của (5.58), một hàm $f: \mathbb{R}^n \rightarrow \mathbb{R}^1$, (ánh xạ một vectơ $x \in \mathbb{R}^n$ lên một vô hướng (ví dụ, $f(x) = \sum_{i=1}^n x_i$), sở hữu ma trận Jacobian = đó là một vectơ hàng (ma trận có kích thước $1 \times n$); xem (5.40).

bổ cục tử số

Lưu ý. Trong cuốn sách này, chúng tôi sử dụng cách bố trí tử số của đạo hàm, tức là đạo hàm df/dx của $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ đối với $x \in \mathbb{R}^n$ là một ma trận $m \times n$, trong đó các phần tử của f xác định các hàng và các phần tử của x xác định các cột của ma trận Jacobian tương ứng; xem (5.58). Có

5.3 Độ dốc của các hàm giá trị vectơ

151



Hình 5.5 Yếu tố quyết định của

Ma trận Jacobian của f có thể được sử dụng để tính toán hệ số phóng đại giữa màu xanh lam và khu vực màu cam.

Ngoài ra còn có dạng bố cục mẫu số, là dạng chuyển vị của bố cục tử số - mẫu số. Trong cuốn sách này, chúng ta sẽ sử dụng bố cục tử số.

Chúng ta sẽ xem cách sử dụng ma trận Jacobian trong phương pháp đổi biến cho các phân phối xác suất ở Phần 6.7. Định thức cung cấp thông tin về mức độ thay đổi tỷ lệ do phép biến đổi biến.

Trong Phần 4.1, chúng ta đã thấy rằng định thức có thể được sử dụng để tính diện tích của hình bình hành. Nếu ta được cho hai vectơ $b_1 = [1, 0]$, $b_2 = [0, 1]$ là các cạnh của hình vuông đơn vị (màu xanh; xem Hình 5.5), thì diện tích của hình vuông này là

$$\text{xác định} \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} = 1. \quad (5.60)$$

Nếu ta xét một hình bình hành có các cạnh $c_1 = [2, 1]$, $c_2 = [1, 1]$ (màu cam trong Hình 5.5), diện tích của nó được tính bằng giá trị tuyệt đối của định thức (xem Phần 4.1).

$$\text{xác định} \begin{vmatrix} 2 & 1 \\ 1 & 1 \end{vmatrix} = |3| = 3, \quad (5.61)$$

Tức là, diện tích của hình này gấp đúng ba lần diện tích của hình vuông đơn vị. Chúng ta có thể tìm hệ số tỉ lệ này bằng cách tìm một phép biến đổi biến hình vuông đơn vị thành hình vuông kia. Về mặt đại số tuyến tính, chúng ta thực hiện một phép biến đổi biến số từ (b_1, b_2) sang (c_1, c_2) . Trong trường hợp của chúng ta, phép biến đổi này là tuyến tính và giá trị tuyệt đối của định thức của phép biến đổi này cho chúng ta chính xác hệ số tỉ lệ mà chúng ta đang tìm kiếm.

Chúng ta sẽ mô tả hai cách tiếp cận để xác định ánh xạ này. Thứ nhất, chúng ta khai thác tính chất tuyến tính của ánh xạ để có thể sử dụng các công cụ từ Chương 2 để xác định ánh xạ này. Thứ hai, chúng ta sẽ tìm ánh xạ bằng cách sử dụng đạo hàm riêng, sử dụng các công cụ mà chúng ta đã thảo luận trong chương này.

Phương pháp 1 Để bắt đầu với phương pháp đại số tuyến tính, chúng ta xác định cả $\{b_1, b_2\}$ và $\{c_1, c_2\}$ là cơ sở của $\mathbb{R}^2$ (xem Mục 2.6.1 để tóm tắt). Về cơ bản, chúng ta thực hiện phép đổi cơ sở từ (b_1, b_2) sang (c_1, c_2) , và chúng ta đang tìm ma trận biến đổi thực hiện phép đổi cơ sở này. Sử dụng kết quả từ Mục 2.7.2, chúng ta xác định ma trận đổi cơ sở cần tìm là

$$J = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad (5.62)$$

sao cho $Jb_1 = c_1$ và $Jb_2 = c_2$. Giá trị tuyệt đối của định thức-

nant của J , cho ra hệ số tỷ lệ mà chúng ta đang tìm kiếm, được cho là $|\det(J)| = 3$, tức là diện tích của hình vuông được tạo bởi (c_1, c_2) lớn gấp ba lần diện tích được tạo bởi (b_1, b_2) .

biến đổi tuyến Phương pháp đại số tuyến tính có hiệu quả đối với các phép tính ; đối với các phép biến đổi phi tuyến tính (sẽ trở nên quan trọng trong Phần 6.7), chúng ta sẽ sử dụng một phương pháp tổng quát hơn bằng cách sử dụng đạo hàm riêng.

Với phương pháp này, chúng ta xem xét một hàm $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ thực hiện phép biến đổi biến. Trong ví dụ của chúng ta, f ánh xạ biểu diễn tọa độ của bất kỳ vectơ $x \in \mathbb{R}^2$ nào đối với (b_1, b_2) lên biểu diễn tọa độ $y \in \mathbb{R}^2$ đối với (c_1, c_2) . Chúng ta muốn xác định ánh xạ này để có thể tính toán sự thay đổi của một diện tích (hoặc thể tích) khi nó được biến đổi bởi f . Để làm được điều này, chúng ta cần tìm hiểu xem $f(x)$ thay đổi như thế nào nếu ta thay đổi x một chút. Câu hỏi này được trả lời chính xác bởi ma trận Jacobian $df_x : \mathbb{R}^2 \times \mathbb{R}^2 \rightarrow \mathbb{R}^2 \times \mathbb{R}^2$. Vì vậy, chúng ta có thể viết

$$y_1 = 2x_1 + x_2$$

(5.63)

$$y_2 = x_1 + x_2$$

(5.64)

Chúng ta thu được mối quan hệ hàm số giữa x và y , cho phép ta có được các đạo hàm riêng $\frac{\partial y_i}{\partial x_j}$

$$\frac{\partial y_1}{\partial x_1} = 2, \quad \frac{\partial y_1}{\partial x_2} = 1, \quad \frac{\partial y_2}{\partial x_1} = 1, \quad \frac{\partial y_2}{\partial x_2} = 1$$

(5.65)

và cấu thành ma trận Jacobian là

$$J = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}.$$


(5.66)

Về mặt hình học, ma trận Jacobian biểu thị phép biến đổi tọa độ mà chúng ta đang tìm kiếm. Nó chính xác nếu phép biến đổi tọa độ là tuyến tính (như trong trường hợp của chúng ta), và (5.66) khôi phục chính xác ma trận thay đổi cơ sở trong (5.62). Nếu phép biến đổi tọa độ là phi tuyến tính, ma trận Jacobian sẽ xấp xỉ phép biến đổi phi tuyến tính này cục bộ bằng một phép biến đổi tuyến tính. Giá trị tuyệt đối của định thức ma trận Jacobian $|\det(J)|$ là hệ số mà diện tích hoặc thể tích được điều chỉnh tỷ lệ khi tọa độ được biến đổi. Trường hợp của chúng ta cho kết quả $|\det(J)| = 3$. Định thức Jacobian và các phép biến đổi biến sẽ trở thành

Điều này có liên quan trong Phần 6.7 khi chúng ta biến đổi các biến ngẫu nhiên và phân phối xác suất. Những biến đổi này cực kỳ quan trọng trong học máy trong bối cảnh huấn luyện mạng nơ-ron sâu bằng cách sử dụng thủ thuật tái tham số hóa, còn được gọi là phân tích nhiễu loạn vô hạn.

Trong chương này, chúng ta đã tìm hiểu về đạo hàm của các hàm số. Hình 5.6 tóm tắt kích thước của các đạo hàm đó. Nếu $f : \mathbb{R} \rightarrow \mathbb{R}$, đạo hàm chỉ đơn giản là một đại lượng vô hướng (phần tử trên cùng bên trái). Đối với $f : \mathbb{R}^D \rightarrow \mathbb{R}$, đạo hàm là một vectơ hàng $1 \times D$ (phần tử trên cùng bên phải). Đối với $f : \mathbb{R} \rightarrow \mathbb{R}^E$, đạo hàm là một vectơ cột $E \times 1$, và đối với $f : \mathbb{R}^D \rightarrow \mathbb{R}^E$, đạo hàm là một ma trận $E \times D$.

Hình 5.6.
Kích thước của
đạo hàm (riêng phần).



Ví dụ 5.9 (Độ dốc của một hàm giá trị vectơ)

Chúng ta được trao

$f(x) = Ax$, $f(x) \in \mathbb{R}^M, A \in \mathbb{R}^{M \times N}, x \in \mathbb{R}^N$.

Để tính đạo hàm bậc hai df/dx , trước tiên ta xác định chiều của df/dx : Vì $f : \mathbb{R}^N \rightarrow \mathbb{R}^M$, nên suy ra $df/dx \in \mathbb{R}^{M \times N}$. Thứ hai, để tính đạo hàm bậc hai, ta xác định các đạo hàm riêng của f đối với mọi x_j :

$$f_i(x) = \sum_{j=1}^N A_{ij}x_j = \frac{f_i}{x_j} = A_{ij} \tag{5.67}$$

Chúng ta thu thập các đạo hàm riêng trong ma trận Jacobian và tính được đạo hàm bậc hai.

$$\frac{df}{dx} = \begin{bmatrix} \frac{f_1}{x_1} & \dots & \frac{f_1}{x_N} \\ \vdots & & \vdots \\ \frac{f_M}{x_1} & \dots & \frac{f_M}{x_N} \end{bmatrix} = \begin{bmatrix} A_{11} & \dots & A_{1N} \\ \vdots & & \vdots \\ A_{M1} & \dots & A_{MN} \end{bmatrix} = A \in \mathbb{R}^{M \times N} \tag{5.68}$$

Ví dụ 5.10 (Quy tắc chuỗi)

Xét hàm $h : \mathbb{R}^2 \rightarrow \mathbb{R}, h(t) = (f \circ g)(t)$ với

$f : \mathbb{R}^2 \rightarrow \mathbb{R} \tag{5.69}$

$g : \mathbb{R} \rightarrow \mathbb{R}^2 \tag{5.70}$

$f(x) = \exp(x_1x_2^2), \tag{5.71}$

$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = g(t) = \begin{pmatrix} \cos t \\ \sin t \end{pmatrix} \tag{5.72}$

và tính đạo hàm của h theo t . Vì $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ và $g : \mathbb{R} \rightarrow \mathbb{R}^2$ nên ta lưu ý rằng $f \in \mathbb{R}^{1 \times 2}$

$\frac{df}{dx} \in \mathbb{R}^{1 \times 2}, \frac{dg}{dt} \in \mathbb{R}^{2 \times 1}.$ (5.73)

Độ dốc mong muốn được tính bằng cách áp dụng quy tắc chuỗi:

$$\frac{dh}{dt} = \frac{df}{dx} \frac{dx}{dt} = \frac{df}{dx_1} \frac{dx_1}{dt} + \frac{df}{dx_2} \frac{dx_2}{dt} \tag{5.74a}$$

$$= \exp(x_1x_2^2) \frac{2}{2} x_2^2 - 2 \exp(x_1x_2^2) x_1x_2 \frac{\cos t}{\sin t + t \cos t} \tag{5.74b}$$

$$= \exp(x_1x_2^2) x_2^2 (\cos t - \sin t) + 2x_1x_2(\sin t + t \cos t), \tag{5.74c}$$

trong đó $x_1 = t \cos t$ và $x_2 = \sin t$; xem (5.72).

Ví dụ 5.11 (Độ dốc của hàm mất mát bình phương tối thiểu trong mô hình tuyến tính)
Chúng ta hãy xem xét mô hình tuyến tính.

$$y = \Phi \theta \quad , \tag{5.75}$$

trong đó $\theta \in \mathbb{R}^D$ là vectơ tham số, $\Phi \in \mathbb{R}^{N \times D}$ là các đặc trưng đầu vào và $y \in \mathbb{R}^N$ là các quan sát tương ứng. Chúng ta định nghĩa các hàm sau:

$$L(e) := \|e\|^2 \tag{5.76}$$

$$e(\theta) := y - \Phi \theta \tag{5.77}$$

Chúng tôi tìm kiếm $\frac{\partial L}{\partial \theta}$, và chúng ta sẽ sử dụng quy tắc chuỗi cho mục đích này. L được gọi là hàm mất mát bình phương tối thiểu.

Trước khi bắt đầu tính toán, chúng ta xác định số chiều của gradient như sau:

$$\frac{\partial L}{\partial \theta} \in \mathbb{R}^{1 \times D} \tag{5.78}$$

Quy tắc chuỗi cho phép chúng ta tính toán đạo hàm như sau:

$$\frac{\partial L}{\partial \theta} = \frac{\partial L}{\partial e} \frac{\partial e}{\partial \theta} \tag{5.79}$$

trong đó phần tử thứ d được xác định bởi

$$\frac{\partial L}{\partial \theta} [1, d] = \sum_{n=1}^N \frac{\partial L}{\partial e[n, d]} e_{\theta}$$

`np.einsum( 'n,nd', dLde,dedtheta)`

$$\tag{5.80}$$

Chúng ta biết rằng $\|e\|^2 = e^T e$ (xem Mục 3.2) và xác định

$$\frac{\partial L}{\partial e} = 2e^T \in \mathbb{R}^{1 \times N} \tag{5.81}$$

Hơn nữa, chúng tôi thu được

$$\frac{\partial e}{\partial \theta} = -\Phi \in \mathbb{R}^{N \times D} \tag{5.82}$$

sao cho đạo hàm mong muốn của chúng ta là

$$\frac{\partial L}{\partial \theta} = 2e^T \Phi = 2(y - \Phi \theta)^T \Phi \in \mathbb{R}^{1 \times D} \tag{5.83}$$

Lưu ý: Chúng ta sẽ thu được kết quả tương tự mà không cần sử dụng quy tắc chuỗi bằng cách xem xét trực tiếp hàm số.


$$L2(\theta) := \|y - \Phi \theta\|^2 = (y - \Phi \theta)^T (y - \Phi \theta) \tag{5.84}$$

Cách tiếp cận này vẫn khả thi đối với các hàm đơn giản như $L2$ nhưng trở nên không thực tế đối với các phép kết hợp hàm phức tạp.


Chúng ta sẽ thảo luận chi tiết hơn về mô hình này trong Chương 9 trong bối cảnh hồi quy tuyến tính, nơi chúng ta cần đạo hàm của tổn thất bình phương nhỏ nhất L đối với các tham số θ .

Chúng tôi tìm kiếm $\frac{\partial L}{\partial \theta}$, và chúng ta sẽ sử dụng quy tắc chuỗi cho mục đích này. L được gọi là hàm mất mát bình phương tối thiểu



5.4 Độ dốc của ma trận



Đạo hàm riêng:



(a) Cách tiếp cận 1: Chúng ta tính đạo hàm riêng $\frac{\partial A}{\partial x}$, mỗi đạo hàm là một ma trận 4×2 , và kết hợp chúng thành một tensor $4 \times 2 \times 3$.



(b) Cách tiếp cận 2: Chúng ta định hình lại (lập phương) A 4×2 thành một vectơ $A^{\sim}$ 8×1 . Sau đó, chúng ta tính toán đạo hàm $\frac{\partial A^{\sim}}{\partial x}$. Chúng ta thu được tensor đạo hàm bằng cách định hình lại đạo này như minh họa ở trên.

5.4 Độ dốc của ma trận

Chúng ta sẽ gặp những tình huống cần lấy đạo hàm của ma trận đối với vectơ (hoặc các ma trận khác), kết quả là một tensor đa chiều. Ta có thể coi tensor này như một mảng đa chiều mà...

Hình 5.7 Minh họa quá trình tính toán đạo hàm của một ma trận đối với một vectơ. Chúng ta quan tâm đến

Tính đạo hàm của A 4×2 đối với vectơ x 3×1 . Ta biết rằng đạo hàm của A $4 \times 2 \times 3$. Ta

$\frac{dA}{dx}$ có hai cách tiếp cận tương đương để đạt được điều đó: (a) tập hợp các đạo hàm riêng thành ma trận Jacobian

(a) tensor; (b) làm phẳng ma trận thành vectơ, tính ma trận Jacobian, định hình lại thành tensor Jacobian.

Chúng ta có thể nghĩ đến một tensor dưới dạng đa chiều mảng.

Thu thập các đạo hàm riêng. Ví dụ, nếu ta tính đạo hàm của ma trận A kích thước $m \times n$ đối với ma trận B kích thước $p \times q$, thì ma trận Jacobian thu được sẽ là $(m \times n) \times (p \times q)$, tức là một tenxơ bốn chiều J , với các phần tử được cho bởi $J_{ijkl} = A_{ij} / B_{kl}$.

Vì ma trận biểu diễn các ánh xạ tuyến tính, chúng ta có thể tận dụng thực tế rằng tồn tại một phép đẳng cấu không gian vectơ (ánh xạ tuyến tính, khả nghịch) giữa không gian $R^{m \times n}$ của các ma trận $m \times n$ và không gian R^{mn} của các vectơ mn . Do đó, chúng ta có thể định hình lại các ma trận của mình thành các vectơ có độ dài lần lượt là mn và pq . Gradient sử dụng các vectơ mn này sẽ tạo ra một ma trận Jacobian có kích thước $mn \times pq$. Hình 5.7 minh họa cả hai cách tiếp cận. Trong các ứng dụng thực tế, người ta thường muốn định hình lại ma trận thành một vectơ và tiếp tục làm việc với ma trận Jacobian này: Quy tắc chuỗi (5.48) được rút gọn thành phép nhân ma trận đơn giản, trong khi đối với tensor Jacobian, chúng ta cần chú ý hơn đến kích thước cần thiết.

Tóm lại là như vậy.

Ma trận có thể được biến đổi thành vectơ bằng cách xếp chồng các cột của ma trận ("làm phẳng").

Ví dụ 5.12 (Đạo hàm của vectơ đối với ma trận)

Chúng ta hãy xem xét ví dụ sau, trong đó

$$A \in \mathbb{R}^{M \times N}, \quad f: \mathbb{R}^M \rightarrow \mathbb{R}, \quad x \in \mathbb{R}^N \quad (5.85)$$

và ở đây chúng ta tìm đạo hàm df/dA . Hãy bắt đầu lại bằng cách xác định chiều của đạo hàm như sau:

$$\frac{df}{dA} \in \mathbb{R}^{M \times (M \times N)}. \quad (5.86)$$

Theo định nghĩa, đạo hàm bậc hai (gradient) là tập hợp các đạo hàm riêng:

$$\frac{df}{dA} = \begin{bmatrix} \frac{\partial f}{\partial A_{11}} \\ \vdots \\ \frac{\partial f}{\partial A_{1M}} \end{bmatrix}, \quad \frac{\partial f}{\partial A} \in \mathbb{R}^{1 \times (M \times N)}. \quad (5.87)$$

Để tính các đạo hàm riêng, sẽ hữu ích nếu viết rõ phép nhân ma trận với vectơ:

$$f_i = \sum_{j=1}^N A_{ij} x_j, \quad i = 1, \dots, M, \quad (5.88)$$

và các đạo hàm riêng sau đó được cho bởi $\frac{\partial f_i}{\partial A_{ij}}$

$$= x_j. \quad A_{iq} \quad (5.89)$$

Điều này cho phép chúng ta tính các đạo hàm riêng của f_i đối với một hàng của A , được cho bởi công

$$\frac{\partial f_i}{\partial A_{i:}} = x \in \mathbb{R}^{1 \times N}, \quad (5.90)$$

$$\frac{df_i}{dA_{k \neq i, :}} = 0 \quad R^{1 \times 1 \times N} \quad (5.91)$$

Trong đó, chúng ta phải chú ý đến chiều không gian chính xác. Vì f_i ánh xạ lên R và mỗi hàng của A có kích thước $1 \times N$, nên ta thu được một tenxơ có kích thước $1 \times 1 \times N$ bằng cách lấy đạo hàm riêng của f_i đối với một hàng của A .

Chúng ta xếp chồng các đạo hàm riêng (5.91) và nhận được đạo hàm mong muốn trong (5.87) thông qua

$$\frac{df_i}{dA} = \begin{pmatrix} 0 \\ \vdots \\ \cdot \\ \vdots \\ 0 \end{pmatrix} R^{1 \times (M \times N)} \quad (5.92)$$

Ví dụ 5.13 (Đạo hàm của ma trận đối với ma trận)

Xét ma trận $R \in \mathbb{R}^{M \times N}$ và hàm $f: \mathbb{R}^{M \times N} \rightarrow \mathbb{R}^{N \times N}$ với

$$f(R) = R^T R =: K \in \mathbb{R}^{N \times N}, \quad (5.93)$$

trong đó chúng ta tìm kiếm độ dốc dK/dR .

Để giải quyết vấn đề khó khăn này, trước tiên chúng ta hãy viết ra những gì chúng ta đã biết: Độ dốc có các chiều

$$\frac{dK}{dR} \in \mathbb{R}^{(N \times N) \times (M \times N)}, \quad (5.94)$$

đó là một tenxơ. Hơn nữa,

$$\frac{dK_{pq}}{dR} \in \mathbb{R}^{1 \times M \times N} \quad (5.95)$$

với $p, q = 1, \dots, N$, trong đó K_{pq} là phần tử thứ (p, q) của $K = f(R)$. Ký hiệu cột thứ i của R là r_i , mỗi phần tử của K được cho bởi tích vô hướng của hai cột của R , tức là,

$$K_{pq} = r_p^T r_q = \sum_{m=1}^M R_{mp} R_{mq}. \quad (5.96)$$

Khi ta tính đạo hàm riêng K_{pq} , ta thu được $\frac{dK_{pq}}{dR_{ij}}$

$$\frac{dK_{pq}}{dR_{ij}} = \sum_{m=1}^M \frac{d}{dR_{ij}} R_{mp} R_{mq} = p q_{ij}, \quad (5.97)$$

$$pq_{ij} = \begin{cases} R_{ij} & \text{nếu } j = p, p \neq q \\ R_{ip} & \text{nếu } j = q, p \neq q \\ 2R_{ip} & \text{nếu } j = p, p = q \\ 0 & \text{nếu không thì} \end{cases} \quad (5.98)$$

Từ (5.94), chúng ta biết rằng độ dốc mong muốn có kích thước $(N \times N) \times (M \times N)$, và mỗi phần tử của tenxơ này được cho bởi pq_{ij} trong (5.98), trong đó $p, q, j = 1, \dots, N$ và $i = 1, \dots, M$.

5.5 Các đẳng thức hữu ích để tính toán đạo hàm

Trong phần tiếp theo, chúng tôi liệt kê một số đạo hàm hữu ích thường được yêu cầu trong bối cảnh học máy (Petersen và Pedersen, 2012). Ở đây, chúng tôi sử dụng $\text{tr}(\cdot)$ làm vết (xem Định nghĩa 4.4), $\det(\cdot)$ làm định thức (xem Phần 4.1) và $f^1(X)$ làm nghịch đảo của $f(X)$, giả sử nó tồn tại.

$$\frac{\partial}{\partial X} f(X) = \frac{f(X)}{X} \quad (5.99)$$

$$\frac{\partial}{\partial X} \text{tr}(f(X)) = \text{tr} \frac{f(X)}{X} \quad (5.100)$$

$$\frac{\partial}{\partial X} \det(f(X)) = \det(f(X)) \text{tr} f(X) \frac{1}{X} \frac{f(X)}{X} \quad (5.101)$$

$$\frac{\partial}{\partial X} f(X)^{-1} = -f(X)^{-1} \frac{f(X)}{X} f(X)^{-1} \quad (5.102)$$

$$\frac{\partial}{\partial X} \begin{pmatrix} a & X & 1 \\ b & & \end{pmatrix} = \begin{pmatrix} X & 1 \\ 1 & \end{pmatrix} \begin{pmatrix} a & b \\ 1 & \end{pmatrix} \quad (5.103)$$

$$\frac{\partial}{\partial x} \frac{x}{a} = \frac{1}{a} \quad (5.104)$$

$$\frac{\partial}{\partial a} \frac{x}{a} = -\frac{x}{a^2} \quad (5.105)$$

$$\frac{\partial}{\partial a} \frac{x}{ab} Xb = \frac{x}{ab} \quad (5.106)$$

$$\frac{\partial}{\partial X} \frac{X}{Bx} Bx = x (B + B^T) \quad (5.107)$$

$$\frac{\partial}{\partial s} (x - As) W(x - As) = 2(x - As) W A \text{ đối với } W \text{ đối xứng} \quad (5.108)$$

Lưu ý: Trong cuốn sách này, chúng tôi chỉ đề cập đến vết và ma trận chuyển vị. Tuy nhiên, chúng ta đã thấy rằng đạo hàm có thể là các tenxơ đa chiều, trong trường hợp đó vết và ma trận chuyển vị thông thường không được định nghĩa. Trong những trường hợp này, vết của một tenxơ $D \times D \times E \times F$ sẽ là một ma trận $E \times F$ chiều. Đây là một trường hợp đặc biệt của phép co tenxơ. Tương tự, khi chúng ta

“Chuyển vị” một tensor, chúng ta có nghĩa là hoán đổi hai chiều đầu tiên. Cụ thể, trong (5.99) đến (5.102), chúng ta yêu cầu các phép tính liên quan đến tensor khi chúng ta làm việc với các hàm đa biến $f(\cdot)$ và tính đạo hàm đối với ma trận (và chọn không chuyển đổi chúng thành vectơ như đã thảo luận trong Phần 5.4).

5.6 Lan truyền ngược và vi phân tự động Trong nhiều ứng dụng học máy, chúng ta tìm được các tham số mô hình tốt bằng cách thực hiện thuật toán giảm độ dốc (Mục 7.1), dựa trên thực tế là chúng ta có thể tính toán độ dốc của mục tiêu học tập đối với các tham số của mô hình. Đối với một hàm mục tiêu cho trước, chúng ta có thể thu được độ dốc đối với các tham số mô hình bằng cách sử dụng phép tính vi phân và áp dụng quy tắc chuỗi; xem Mục 5.2.2. Chúng ta đã có một cái nhìn sơ lược trong Mục 5.3 khi xem xét độ dốc của bình phương tổn thất đối với các tham số của mô hình hồi quy tuyến tính.

Hãy xem xét hàm số

$$f(x) = x^2 + \exp(x^2) + \cos x^2 + \exp(x^2) \tag{5.109}$$

Bằng cách áp dụng quy tắc chuỗi và lưu ý rằng phép vi phân là tuyến tính, ta tính được đạo hàm bậc hai.

$$\begin{aligned} \frac{df}{dx} &= \frac{2x + 2x \exp(x^2)}{2x^2 + \exp(x^2)} \sin x^2 + \exp(x^2) 2x + 2x \exp(x^2) \\ &= 2x \frac{1}{2x^2 + \exp(x^2)} \sin^2 + \exp(x^2) 1 + \exp(x^2) \end{aligned} \tag{5.110}$$

Việc viết rõ đạo hàm theo cách tưởng minh này thường không thực tế vì nó thường dẫn đến một biểu thức đạo hàm rất dài. Trên thực tế, điều đó có nghĩa là, nếu không cẩn thận, việc triển khai đạo hàm có thể tốn kém hơn đáng kể so với việc tính toán hàm số, gây ra chi phí không cần thiết. Đối với việc huấn luyện các mô hình mạng nơ-ron sâu, thuật toán lan truyền ngược (Kelley, 1960; Bryson, 1961; Dreyfus, 1962 ; Rumelhart et al., 1986) là một cách hiệu quả để tính toán đạo hàm của hàm lỗi đối với các tham số của mô hình.

5.6.1 Độ dốc trong mạng nơ-ron sâu


Một lĩnh vực mà quy tắc chuỗi được sử dụng đến mức cực đoan là học sâu, trong đó giá trị hàm y được tính toán như một phép hợp hàm nhiều cấp.

$$y = (f_K \circ f_{K-1} \circ \dots \circ f_1)(x) = f_K(f_{K-1}(\dots(f_1(x)) \dots)), \tag{5.111}$$

trong đó x là các đầu vào (ví dụ: hình ảnh), y là các quan sát (ví dụ: nhãn lớp), và mỗi hàm f_i , $i = 1, \dots, K$, đều có các tham số riêng của nó.

Bạn có thể tìm thấy bài thảo luận hay về lan truyền ngược và quy tắc chuỗi trên blog của Tim Vieira tại địa chỉ <https://tinyurl.com/ycfm2yrw>.

Hình 5.8 Tiến về phía trước truyền qua nhiều lớp mạng thần kinh đến tính toán tổn thất L như một hàm của đầu vào x và tham số A_i, b_i .



Chúng ta thảo luận về trường hợp kích hoạt các chức năng là giống hệt nhau trong mỗi cấp nếp theo lớp để giảm bớt sự lộn xộn ký hiệu.

Trong mạng nơ-ron nhiều lớp, ta có các hàm $f_i(x_{i-1}) = \sigma(A_{i-1}x_{i-1} + b_{i-1})$ ở lớp thứ i . Ở đây x_{i-1} là đầu ra của lớp $i-1$ và σ là một hàm kích hoạt, chẳng hạn như hàm sigmoid logistic, tanh hoặc $\frac{1}{1 + e^{-x}}$, đơn vị tuyến tính hiệu chỉnh (ReLU). Để huấn luyện các mô hình này, chúng ta cần đạo hàm của hàm mất mát L đối với tất cả các tham số mô hình A_j, b_j với $j = 1, \dots, K$. Điều này cũng yêu cầu chúng ta tính đạo hàm của L với liên quan đến đầu vào của mỗi lớp. Ví dụ, nếu chúng ta có đầu vào x và các quan sát y và một cấu trúc mạng được xác định bởi

$$\theta := X \tag{5.112}$$

$$f_i := \sigma(A_{i-1}f_{i-1} + b_{i-1}), \quad i = 1, \dots, K, \tag{5.113}$$

Xem thêm Hình 5.8 để hình dung rõ hơn, chúng ta có thể quan tâm đến việc tìm kiếm A_j, b_j với $j = 0, \dots, K-1$, sao cho tổn thất bình phương

$$L(\theta) = \|y - f_K(\theta, x)\|^2 \tag{5.114}$$

được tối thiểu hóa, trong đó $\theta = \{A_0, b_0, \dots, A_{K-1}, b_{K-1}\}$.

Để thu được đạo hàm theo tập tham số θ , chúng ta cần các đạo hàm riêng của L đối với các tham số $\theta_j = \{A_j, b_j\}$ của mỗi lớp $j = 0, \dots, K-1$. Quy tắc chuỗi cho phép chúng ta xác định đạo hàm riêng như

$$\frac{\partial L}{\partial \theta_{K-1}} = \frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial \theta_{K-1}} \tag{5.115}$$

$$\frac{\partial L}{\partial \theta_{K-2}} = \frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial f_{K-1}} \frac{\partial f_{K-1}}{\partial \theta_{K-2}} \tag{5.116}$$

$$\frac{\partial L}{\partial \theta_{K-3}} = \frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial f_{K-1}} \frac{\partial f_{K-1}}{\partial f_{K-2}} \frac{\partial f_{K-2}}{\partial \theta_{K-3}} \tag{5.117}$$


$$\frac{\partial L}{\partial \theta_i} = \frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial f_{K-1}} \dots \frac{\partial f_{i+2}}{\partial f_{i+1}} \frac{\partial f_{i+1}}{\partial \theta_i} \tag{5.118}$$

Các thuật ngữ màu cam là đạo hàm riêng của đầu ra của một lớp với liên quan đến các đầu vào của nó, trong khi các thuật ngữ màu xanh lam là đạo hàm riêng của Đầu ra của một lớp liên quan đến các tham số của nó. Giả sử, chúng ta có Nếu đã tính toán các đạo hàm riêng $\partial L / \partial \theta_{i+1}$, thì phần lớn phép tính có thể được sử dụng lại để tính $\partial L / \partial \theta_i$. Các thuật ngữ bổ sung mà chúng ta


Một cuộc thảo luận sâu hơn về độ dốc của thần kinh mạng có thể là được tìm thấy ở Justin Bài giảng của Domke ghi chú <https://tinyurl.com/yalcxgvtv>.

5.6 Lan truyền ngược và phép vi phân tự động

161



Hình 5.9. Quá trình truyền ngược trong mạng nơ-ron đa lớp để tính toán độ dốc của hàm mất mát.



Hình 5.10. Đồ thị đơn giản minh họa luồng dữ liệu từ x đến y thông qua một số trung cấp các biến a, b.

Các phần cần tính toán được biểu thị bằng các ô vuông. Hình 5.9 minh họa cách các gradient được truyền ngược trở lại qua mạng.

5.6.2 Vi phân tự động

Hóa ra, lan truyền ngược là một trường hợp đặc biệt của một kỹ thuật tổng quát trong phân tích số gọi là phép vi phân tự động. Chúng ta có thể coi phép vi phân tự động như một tập hợp các kỹ thuật để tính toán bằng số (trái ngược với tính toán ký hiệu) đạo hàm chính xác (đến độ chính xác của máy tính) của một hàm bằng cách làm việc với các biến trung gian và áp dụng quy tắc chuỗi. Phép vi phân tự động áp dụng một loạt các phép toán số học cơ bản, ví dụ như phép cộng và phép nhân, và các hàm cơ bản, ví dụ như sin, cos, exp, logarit. Bằng cách áp dụng quy tắc chuỗi cho các phép toán này, đạo hàm của các hàm khá phức tạp có thể được tính toán tự động. Vi phân tự động áp dụng cho các chương trình máy tính nói chung và có chế độ thuận và nghịch. Baydin et al. (2018) đưa ra một tổng quan tuyệt vời về vi phân tự động trong học máy.

Hình 5.10 thể hiện một đồ thị đơn giản mô tả luồng dữ liệu từ đầu vào x đến đầu ra y thông qua một số biến trung gian a, b. Nếu ta tính đạo hàm dy/dx , ta sẽ áp dụng quy tắc chuỗi và thu được

$$\frac{dy}{dx} = \frac{dy}{db} \frac{db}{da} \frac{da}{dx} . \quad (5.119)$$

Theo trực giác, chế độ thuận và nghịch khác nhau ở thứ tự phép nhân. Trong trường hợp tổng quát, do tính chất kết hợp của phép nhân ma trận, ta có thể chọn giữa...

$$\frac{dy}{dx} = \frac{dy}{db} \frac{db}{da} \frac{da}{dx} , \quad (5.120)$$

$$\frac{dy}{dx} = \frac{db}{da} \frac{da}{dx} \frac{dy}{db} . \quad (5.121)$$

Phương trình (5.120) sẽ là chế độ đảo ngược vì độ dốc được truyền ngược qua đồ thị, tức là ngược với luồng dữ liệu. Phương trình (5.121) sẽ là chế độ thuận, trong đó độ dốc truyền dữ liệu từ trái sang phải qua đồ thị.

Trong phần tiếp theo, chúng ta sẽ tập trung vào phép vi phân tự động theo chế độ ngược, tức là lan truyền ngược. Trong bối cảnh của mạng nơ-ron, nơi mà Số chiều của dữ liệu đầu vào thường cao hơn nhiều so với số chiều của dữ liệu đầu ra. Các nhân, chế độ đảo ngược có chi phí tính toán thấp hơn đáng kể so với Chế độ tiến. Chúng ta hãy bắt đầu với một ví dụ minh họa.

Ví dụ 5.14
Hãy xem xét hàm số

$$f(x) = x^2 + \exp(x^2) + \cos(x^2) + \exp(x^2) \tag{5.122}$$

từ (5.109). Nếu chúng ta triển khai một hàm f trên máy tính, chúng ta Có thể tiết kiệm được một số phép tính bằng cách sử dụng các biến trung gian:

$$a = x^2, \tag{5.123}$$


$$b = \exp(a), \tag{5.124}$$

$$c = a + \dots, \tag{5.125}$$

$$bd = \sqrt{\dots}, \tag{5.126}$$

$$ce = \dots \tag{5.127}$$

$$\cos(c), f = d + e. \tag{5.128}$$



Đây là kiểu tư duy tương tự như khi áp dụng quy tắc chuỗi. Lưu ý rằng tập hợp các phương trình trước đó yêu cầu ít hơn các phép toán hơn là việc triển khai trực tiếp hàm $f(x)$ như đã định nghĩa trong (5.109). Đồ thị tính toán tương ứng trong Hình 5.11 cho thấy Luồng dữ liệu và các phép tính cần thiết để thu được giá trị của hàm. f .

Tập hợp các phương trình có chứa các biến trung gian có thể được coi là như một đồ thị tính toán, một dạng biểu diễn được sử dụng rộng rãi trong việc triển khai các thư viện phần mềm mạng nơ-ron. Chúng ta có thể tính toán trực tiếp. đạo hàm của các biến trung gian đối với các biến đầu vào tương ứng bằng cách nhắc lại định nghĩa đạo hàm của các biến cơ bản. các hàm. Chúng ta thu được những điều sau:

$$\frac{a}{x} = 2x \tag{5.129}$$

$$\frac{b}{a} = \exp(a) \tag{5.130}$$

$$\frac{c}{a} = \frac{1}{b} = \frac{c}{d} \quad (5.131)$$

$$\frac{c}{c} = \frac{1}{2\sqrt{c}} \quad (5.132)$$

$$\frac{e}{e} = \sin(c) \quad (5.133)$$

$$\frac{c}{d} = \frac{f}{e} \cdot 1 = \frac{f}{e} \quad (5.134)$$

Bằng cách xem xét biểu đồ tính toán trong Hình 5.11, chúng ta có thể tính toán f / x bằng cách làm ngược từ kết quả đầu ra và thu được

$$\frac{f}{c} = \frac{f}{d} \frac{d}{c} + \frac{f}{e} \frac{e}{c} \quad (5.135)$$

$$\frac{f}{c} = \frac{f}{c} \frac{c}{c} \quad (5.136)$$

$$\frac{b}{a} = \frac{b}{b} \frac{f}{a} + \frac{f}{c} \frac{c}{a} \quad (5.137)$$

$$\frac{f}{x} = \frac{f}{a} \frac{a}{x} \quad (5.138)$$

Lưu ý rằng chúng ta đã áp dụng ngầm quy tắc chuỗi để thu được f / x . Bằng cách thay thế kết quả của các đạo hàm của các hàm cơ bản, ta được

$$\frac{f}{c} = 1 \cdot \frac{1}{2\sqrt{c}} + 1 \cdot (\sin(c)) \quad (5.139)$$

$$\frac{f}{1} = \frac{f}{1} \quad (5.140)$$

$$\frac{b}{a} = \frac{b}{f} \frac{c}{\exp(a)} + 1 \cdot \frac{f}{b} \frac{c}{c} \quad (5.141)$$

$$\frac{f}{x} = \frac{f}{2x} \cdot \frac{a}{a} \quad (5.142)$$

Bằng cách coi mỗi đạo hàm ở trên như một biến số, ta quan sát thấy rằng phép tính cần thiết để tính đạo hàm cũng tương tự như vậy.

Độ phức tạp nằm ở chính việc tính toán hàm số. Điều này khá phản trực giác vì biểu thức toán học cho đạo hàm f / x (5.110) nó phức tạp hơn đáng kể so với biểu thức toán học của nó. hàm $f(x)$ trong (5.109).

Vi phân tự động là một hình thức hóa của Ví dụ 5.14. Cho $x_1, \dots, x_d$ là các biến đầu vào của hàm, $x_{d+1}, \dots, x_D$ là các biến trung gian các biến, và x_D là biến đầu ra. Khi đó, đồ thị tính toán có thể là được diễn đạt như sau:

$$i = d + 1, \dots, D : x_i = g_i(x_{Pa}(x_i)), \text{ Với} \quad (5.143)$$

trong đó $g_i(\cdot)$ là các hàm cơ bản và $xPa(x_i)$ là các nút cha của biến x_i trong đồ thị. Cho một hàm được định nghĩa theo cách này, ta có thể sử dụng quy tắc chuỗi để tính đạo hàm của hàm theo từng bước. Nhớ lại rằng theo định nghĩa $f = xD$ và do đó

$$\frac{f}{x_i} = 1.$$

(5.144)

Đối với các biến khác x_i , chúng ta áp dụng quy tắc chuỗi

$$\frac{f}{x_i} = \sum_{x_j : x_i Pa(x_j)} \frac{f}{x_j} \frac{x_j}{x_i} = \sum_{x_j : x_i Pa(x_j)} \frac{f}{x_j} g_{ji},$$

(5.145)

trong đó $Pa(x_j)$ là tập hợp các nút cha của x_j trong đồ thị tính toán.

Phương trình tự vi phân (5.143) là sự lan truyền thuận của một hàm, trong khi (5.145) là sự lan truyền ngược của gradient thông qua đồ thị tính toán.

ở chế độ ngược

yêu cầu phân tích cú pháp cây.

Để huấn luyện mạng nơ-ron, chúng ta sử dụng phương pháp lan truyền ngược lỗi của dự đoán so với nhãn.

Phương pháp vi phân tự động nêu trên hoạt động hiệu quả khi ta có một hàm có thể biểu diễn dưới dạng đồ thị tính toán, trong đó các hàm cơ bản có thể vi phân được. Trên thực tế, hàm đó thậm chí có thể không phải là một hàm toán học mà là một chương trình máy tính. Tuy nhiên, không phải tất cả các chương trình máy tính đều có thể được vi phân tự động, ví dụ, nếu ta không thể tìm thấy các hàm cơ bản có thể vi phân. Các cấu trúc lặp trình, chẳng hạn như vòng lặp for và câu lệnh if , cũng cần được xử lý cẩn thận hơn.

5.7 Đạo hàm bậc cao Cho đến nay,


chúng ta đã thảo luận về độ dốc, tức là đạo hàm bậc nhất. Đôi khi, chúng ta quan tâm đến đạo hàm bậc cao hơn, ví dụ, khi chúng ta muốn sử dụng phương pháp Newton để tối ưu hóa, phương pháp này yêu cầu đạo hàm bậc hai (Nocedal và Wright, 2006). Trong Phần 5.1.1, chúng ta đã thảo luận về chuỗi Taylor để xấp xỉ các hàm số bằng cách sử dụng đa thức. Trong trường hợp đa biến, chúng ta có thể làm chính xác điều tương tự. Trong phần tiếp theo, chúng ta sẽ làm chính xác điều này. Nhưng hãy bắt đầu với một số ký hiệu.

Xét hàm $f : R^2 \rightarrow R$ của hai biến x, y . Chúng ta sử dụng ký hiệu sau cho các đạo hàm riêng bậc cao (và cho độ dốc):

- $\frac{\partial^2 f}{\partial x^2}$ là đạo hàm riêng bậc hai của f theo x .
- $\frac{\partial^2 f}{\partial x \partial y}$ là đạo hàm riêng bậc n của f theo x, y .
- $\frac{\partial f}{\partial x} = \frac{df}{dx}$ thu được bằng cách lấy đạo hàm riêng bậc nhất theo trục x rồi sau đó xoay theo trục y .
- $\frac{\partial^2 f}{\partial x \partial y}$ là đạo hàm riêng thu được bằng cách lấy đạo hàm riêng bậc nhất bởi y rồi đến x .

Hessian

Ma trận Hessian là tập hợp tất cả các đạo hàm riêng bậc hai.



Hình 5.12. Phép xấp xỉ tuyến tính của một hàm số. Hàm số ban đầu f được tuyến tính hóa tại $x_0 = 2$ bằng cách sử dụng khai triển chuỗi Taylor bậc nhất.

Nếu $f(x, y)$ là một hàm khả vi liên tục hai lần thì

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 f}{\partial y \partial x}, \tag{5.146}$$

Tức là, thứ tự vi phân không quan trọng, và ma trận Hessian tương ứng cũng vậy.

Ma trận Hessian

$$H = \begin{pmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{pmatrix} \tag{5.147}$$

Ma trận $\frac{\partial^2 f}{\partial x \partial y}$ là ma trận đối xứng. Ma trận Hessian được ký hiệu là $H_{x,y}f(x, y)$. Nói chung, đối với $x \in \mathbb{R}^n$ và $f: \mathbb{R}^n \rightarrow \mathbb{R}$, ma trận Hessian là một ma trận $n \times n$. Ma trận Hessian đo độ cong của hàm số cục bộ xung quanh điểm (x, y) .

Ghi chú (Ma trận Hessian của trường vectơ). Nếu $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ là một trường vectơ, thì ma trận Hessian là một tenxơ $(m \times n \times n)$.


5.8 Tuyến tính hóa và chuỗi Taylor đa biến

Độ dốc f của một hàm f thường được sử dụng để xấp xỉ tuyến tính cục bộ của f xung quanh x_0 :

$$f(x) \approx f(x_0) + (x - x_0) \nabla f(x_0). \tag{5.148}$$

Ở đây $\nabla f(x_0)$ là đạo hàm của f đối với x , được đánh giá tại x_0 . Hình 5.12 minh họa phép xấp xỉ tuyến tính của một hàm f tại đầu vào x_0 . Hàm gốc được xấp xỉ bằng một đường thẳng. Phép xấp xỉ này chính xác cục bộ, nhưng càng xa x_0 thì phép xấp xỉ càng kém chính xác. Phương trình (5.148) là trường hợp đặc biệt của khai triển chuỗi Taylor đa biến của f tại x_0 , trong đó chúng ta chỉ xem xét hai số hạng đầu tiên. Chúng ta sẽ thảo luận về trường hợp tổng quát hơn ở phần tiếp theo, điều này sẽ cho phép các phép xấp xỉ tốt hơn.

Hình 5.13 Minh họa tích ngoài. Tích ngoài của các vectơ làm tăng chiều của mảng lên 1 cho mỗi phần tử. (a) Tích ngoài của hai vectơ tạo thành một ma trận; (b) tích ngoài của ba vectơ tạo thành một tenxơ bậc ba.



Định nghĩa 5.7 (Chuỗi Taylor đa biến). Chúng ta xét một hàm số

$$f : \mathbb{R}^D \rightarrow \mathbb{R} \tag{5.149}$$

$$x \in \mathbb{R}^D, \tag{5.150}$$

đó trơn tru tại x_0 . Khi ta định nghĩa vectơ hiệu $\delta := x - x_0$, chuỗi Taylor đa biến của f tại (x_0) được định nghĩa là

$$f(x) = \sum_{k=0}^{\infty} \frac{D^k_x f(x_0)}{k!} \delta^k, \tag{5.151}$$

trong đó $D^k_x f(x_0)$ là đạo hàm bậc k (toàn phần) của f đối với x , đánh giá được cập nhật tại x_0 .

Đa thức Taylor

Định nghĩa 5.8 (Đa thức Taylor). Đa thức Taylor bậc n của f tại x_0 chứa $n + 1$ thành phần đầu tiên của chuỗi trong (5.151) và được định nghĩa là

$$T_n(x) = \sum_{k=0}^n \frac{D^k_x f(x_0)}{k!} \delta^k. \tag{5.152}$$

Trong (5.151) và (5.152), chúng ta đã sử dụng ký hiệu δ hơi cầu thả, ký hiệu δ^k , này không được định nghĩa cho các vectơ $x \in \mathbb{R}^D$, $D > 1$ và $k > 1$. Lưu ý rằng cả $D^k_x f$ và δ^k đều là tenxơ bậc k , tức là mảng k chiều.

Một vectơ có thể là được triển khai dưới dạng một mảng, một ma trận dưới dạng hai chiều mảng.

Tenxơ bậc k $\delta \in \mathbb{R}^{D \times D \times \dots \times D}$ được ký hiệu $\delta^{(k)}$ được thu được dưới dạng tích ngoài bậc k hiệu bởi δ , của vectơ $\delta \in \mathbb{R}^D$. Ví dụ:

$$\delta^2 := \delta \otimes \delta \in \mathbb{R}^{D \times D}, \quad \delta^2_{[i, j]} = \delta_{[i]} \delta_{[j]} \tag{5.153}$$

5.8 Tuyến tính hóa và chuỗi Taylor đa biến 167

$$\delta^3 := \delta \quad \delta \quad \delta, \quad \delta^3_{[i, j, k]} = \delta[i]\delta[j]\delta[k] \text{ .} \tag{5.154}$$

Hình 5.13 minh họa hai tích ngoài như vậy. Nói chung, ta thu được

các điều khoản

$$D^k_x f(x_0)\delta = \sum_{i_1=1}^D \cdots \sum_{i_k=1}^D D^k_x f(x_0)[i_1, \dots, i_k]\delta[i_1] \cdots \delta[i_k] \tag{5.155}$$

trong chuỗi Taylor, trong đó $D^k_x f(x_0)\delta$ chứa các đa thức bậc k .

Bây giờ chúng ta đã định nghĩa chuỗi Taylor cho trường vectơ, hãy trình bày viết ra các thuật ngữ đầu tiên $D^k_x f(x_0)\delta$ rõ ràng khai triển chuỗi Taylor cho $k = 0, \dots, 3$ và $\delta := x - x_0$:

$$k = 0 : D^0_x f(x_0)\delta^0 = f(x_0) \quad R \tag{5.156}$$

$$k = 1 : D^1_x f(x_0)\delta^1 = \underbrace{x f(x_0)}_{1 \times D} \underbrace{\delta}_{D \times 1} = \sum_{i=1}^D x f(x_0)[i]\delta[i] \quad R \tag{5.157}$$

$$k = 2 : D^2_x f(x_0)\delta^2 = \text{tr} \underbrace{H(x_0)}_{D \times D} \underbrace{\delta \delta^T}_{D \times 1 \times D} = \delta^T H(x_0)\delta \tag{5.158}$$

`np.einsum( 'i,i',Df1,d) np.einsum( 'ij,i,j`

$$= \sum_{i=1}^D \sum_{j=1}^D H[i, j]\delta[i]\delta[j] \quad R \tag{5.159}$$

$$k = 3 : D^3_x f(x_0)\delta^3 = \sum_{i=1}^D \sum_{j=1}^D \sum_{k=1}^D D^3_x f(x_0)[i, j, k]\delta[i]\delta[j]\delta[k] \quad R \tag{5.160}$$

Ở đây, $H(x_0)$ là ma trận Hessian của hàm f được tính tại x_0 .

Ví dụ 5.15 (Khai triển chuỗi Taylor của một hàm hai biến)

Hãy xem xét hàm số

$$f(x, y) = x^2 + 2xy + y^3 \text{ .} \tag{5.161}$$

Chúng ta muốn tính khai triển chuỗi Taylor của f tại $(x_0, y_0) = (1, 2)$. Trước khi bắt đầu, chúng ta hãy thảo luận về những gì cần mong đợi: Hàm trong (5.161) là một đa thức bậc 3. Chúng ta đang tìm kiếm khai triển chuỗi Taylor, bản thân nó là một tổ hợp tuyến tính của các đa thức. Do đó, chúng ta không mong đợi khai triển chuỗi Taylor chứa các số hạng bậc bốn hoặc cao hơn để biểu diễn một đa thức bậc ba. Điều này có nghĩa là chỉ cần xác định bốn số hạng đầu tiên của (5.151) là đủ để có một biểu diễn thay thế chính xác cho (5.161).

Để xác định khai triển chuỗi Taylor, ta bắt đầu với hằng số và các đạo hàm bậc nhất, được cho bởi

$$f(1, 2) = 13 \tag{5.162}$$

$$\frac{f}{f} = \frac{2x + 2y}{2x + 3y} = \frac{x}{y} \quad \frac{x}{x(1, 2)} = 6 \quad (5.163)$$

$$\frac{f}{f} = \frac{2x + 2y}{2x + 3y} = \frac{x}{y} \quad \frac{f}{y}(1, 2) = 14. \quad (5.164)$$

Do đó, chúng ta thu được

$$D_1 x, y f(1, 2) = \frac{f}{x}(1, 2) = 6 \quad \frac{f}{y}(1, 2) = 14 \quad R^{1 \times 2} \quad (5.165)$$

sao cho

$$\frac{D_1 x, y f(1, 2)}{1!} \delta = 6 \quad \frac{x}{1} \quad \frac{y}{2} = 6(x - 1) + 14(y - 2). \quad (5.166)$$

Lưu ý rằng $D_1 x, y f(1, 2) \delta$ chỉ chứa các số hạng tuyến tính, tức là đa thức bậc nhất-mials.

Các đạo hàm riêng bậc hai được cho bởi $2f(1,$

$$\frac{2f}{2f} = 2 = \frac{2}{2f} = 2 \quad x^2 \quad (5.167)$$

$$\frac{x^2}{2f} = 6y \quad \frac{(1, 2)}{2} = 12 \quad (5.168)$$

$$\frac{y^2}{2f} = 2 \quad \frac{y^2}{y} \quad \frac{2f}{x(1, 2)} = 2 \quad (5.169)$$

$$\frac{y \cdot x}{x \cdot y} \quad 2f = 2 \quad \frac{2f}{x \cdot y}(1, 2) = 2. \quad (5.170)$$

Khi ta thu thập các đạo hàm riêng bậc hai, ta sẽ thu được ma trận Hessian.

$$H = \begin{pmatrix} \frac{2f}{2} & \frac{2f}{x \cdot y} \\ \frac{2f}{y \cdot x} & \frac{2f}{y^2} \end{pmatrix} = \begin{pmatrix} 2 & 2 \\ 2 & 6 \end{pmatrix} \quad (5.171)$$

sao cho

$$H(1, 2) = \begin{pmatrix} 2 & 2 \\ 2 & 12 \end{pmatrix} \quad R^{2 \times 2}. \quad (5.172)$$

Do đó, hạng tử tiếp theo của khai triển chuỗi Taylor được cho bởi

$$\frac{D_2 x, y f(1, 2)}{2!} \delta^2 = \frac{1}{2} \delta^T H(1, 2) \delta \quad (5.173a)$$

$$= \frac{1}{2} \begin{pmatrix} x & y \end{pmatrix} \begin{pmatrix} 2 & 2 \\ 2 & 12 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} \quad (5.173b)$$

$$= (x - 1)^2 + 2(x - 1)(y - 2) + 6(y - 2)^2. \quad (5.173c)$$

Ở đây, $D_2 x, y f(1, 2) \delta^2$ chỉ chứa các số hạng bậc hai, tức là đa thức bậc hai-danh từ.

Các đạo hàm bậc ba được thu được như sau:

$$D3 \ x,yf = \frac{H}{x} \quad \frac{H}{y} \quad R^{2 \times 2 \times 2}, \quad (5.174)$$

$$D3 \ x, yf[:, :, 1] = \frac{H}{x} = \frac{\frac{3}{f}}{\frac{f}{f} \ x \ y \ x} = \frac{\frac{3}{f}}{\frac{x^2 \ y \ 3}{x \ y}} \quad , \quad (5.175)$$

$$D3 \ x, y f[:, :, 2] = \frac{H}{y} = \frac{\frac{3}{y} \frac{f}{x^2 3}}{\frac{f}{y^2 x}} = \frac{\frac{3}{y} \frac{f}{x y^3}}{\frac{f}{y^3}}. \quad (5.176)$$

Vì hầu hết các đạo hàm riêng bậc hai trong ma trận Hessian trong (5.171) đều là hằng số, nên đạo hàm riêng bậc ba khác không duy nhất là

$$\frac{3f}{y^3} = 6 = \frac{3f}{y^3} (1, 2) = 6. \quad (5.177)$$

Các đạo hàm bậc cao hơn và các đạo hàm hỗn hợp bậc 3 (ví dụ, f_{33}) bằng 0, sao cho $x_2 = y$

$$\begin{matrix} 0 & 0 \\ 0 & 0 \end{matrix} \quad , \quad \begin{matrix} 0 & 0 \\ 0 & 6 \end{matrix} \quad (5.178)$$

Và

$$\frac{D_3 x, y f(1, 2)}{3!} \delta^3 = (y - 2)^3, \quad (5.179)$$

tập hợp tất cả các số hạng bậc ba của chuỗi Taylor. Nhìn chung, (chính xác)

Khai triển chuỗi Taylor của f tại $(x_0, y_0) = (1, 2)$ là **D2**

$$f(x) = f(1, 2) + D1 \, x, yf(1, 2)\delta + \delta \, 2! \frac{x, yf(1, 2)}{2!}^2 + \frac{D3 \, x, yf(1, 2)}{3!}\delta^3$$

(5.180a)

[illegible]

$$+ (x-1)^2 + 6(y-2)^2 + 2(x-1)(y-2) + (y-2)^3 \quad (5.180c)$$

Trong trường hợp này, chúng tôi đã thu được khai triển chuỗi Taylor chính xác của đa thức trong (5.161), tức là đa thức trong (5.180c) giống hệt với đa thức ban đầu trong (5.161). Trong ví dụ cụ thể này, kết quả này không đáng ngạc nhiên vì hàm ban đầu là một đa thức bậc ba, mà chúng tôi đã biểu diễn thông qua tổ hợp tuyến tính của các hằng số, đa thức bậc nhất, bậc hai và bậc ba trong (5.180c).

5.9 Tài liệu tham khảo thêm

Thông tin chi tiết hơn về vi phân ma trận, cùng với phần tóm tắt ngắn gọn về đại số tuyến tính cần thiết, có thể được tìm thấy trong Magnus và Neudecker (2007). Việc vi phân tự động đã có một lịch sử lâu dài, và chúng tôi tham khảo Griewank và Walther (2003), Griewank và Walther (2008), và Elliott (2009) cùng các tài liệu tham khảo trong đó.

Trong học máy (và các lĩnh vực khác), chúng ta thường cần tính toán kỳ vọng, tức là chúng ta cần giải các tích phân có dạng

$$\mathbb{E}[f(x)] = \int f(x)p(x)dx \quad .$$

(5.181)

Ngay cả khi $p(x)$ có dạng thuận tiện (ví dụ: phân bố Gauss), tích phân này nói chung không thể giải được bằng phương pháp phân tích. Khai triển chuỗi Taylor của f là một cách để tìm ra lời giải gần đúng: Giả sử $p(x) = N(\mu, \Sigma)$ là phân bố Gauss, thì khai triển chuỗi Taylor bậc nhất xung quanh μ sẽ tuyến tính hóa cục bộ hàm phi tuyến f . Đối với các hàm tuyến tính, ta có thể tính toán chính xác giá trị trung bình (và hiệp phương sai) nếu $p(x)$ được phân bố Gauss (xem Mục 6.5). Thuộc tính này được khai thác triệt để bởi bộ lọc Kalman mở rộng (Maybeck, 1979) để ước lượng trạng thái trực tuyến trong các hệ thống động phi tuyến (còn được gọi là "mô hình không gian trạng thái"). Các phương pháp xác định khác của phép biến đổi không mùi để xấp xỉ tích phân trong (5.181) là phép biến đổi không mùi (Julier và Uhlmann, 1997), không yêu cầu bất kỳ đạo hàm nào, hoặc phép xấp xỉ Laplace (MacKay, 2003; Bishop, 2006; Murphy, 2012), sử dụng khai triển chuỗi Taylor bậc hai (yêu cầu ma trận Hessian) để xấp xỉ Gaussian cục bộ của $p(x)$ xung quanh điểm cực đại của nó.

Kalman mở rộng
lọc

Bài tập

- 5.1 Tính đạo hàm f
- (x) cho
- $$f(x) = \log(x^4) \sin(x^3).$$
- 5.2 Tính đạo hàm f
- (x) của hàm sigmoid logistic
- $$f(x) = \frac{1}{1 + \exp(-x)}.$$
- 5.3 Tính đạo hàm f
- (x) của hàm
- $$f(x) = \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right),$$

- trong đó $\mu, \sigma \in \mathbb{R}$ là các hằng số.
- 5.4 Tính đa thức Taylor T_n , $n = 0, 1, \dots, 5$ của hàm $f(x) = \sin(x) + \cos(x)$ tại $x_0 = 0$.
- 5.5 Hãy xem xét các hàm số sau:

$$f_1(x) = \sin(x_1) \cos(x_2), \quad x \in \mathbb{R}^2$$
$$f_2(x, y) = x^N y, \quad x, y \in \mathbb{R}$$
$$f_3(x) = x^N, \quad x \in \mathbb{R}$$


- a. Kích thước của f_i là bao nhiêu? $\frac{b}{x}$?
Tính ma trận Jacobian.
- 5.6 Vi phân hàm f theo t và hàm g theo X , trong đó $f(t) = \sin(\log(t-t))$, $g(X)$
- $$= \text{tr}(AXB), A \in \mathbb{R}^{D \times E}, t \in \mathbb{R}^D$$
- $$X \in \mathbb{R}^{E \times F}, B \in \mathbb{R}^{F \times D},$$
- trong đó $\text{tr}(\cdot)$ biểu thị vết.
- 5.7 Tính đạo hàm riêng df/dx của các hàm số sau bằng cách sử dụng quy tắc chuỗi. Cung cấp kích thước của từng đạo hàm riêng. Mô tả chi tiết các bước thực hiện.

- Một.
- $$f(z) = \log(1+z), z = x - x, x \in \mathbb{R}^D$$
- b.
- $$f(z) = \sin(z), z = Ax + b, A \in \mathbb{R}^{E \times D}, x \in \mathbb{R}^D, b \in \mathbb{R}^E$$
- trong đó $\sin(\cdot)$ được áp dụng cho mọi phần tử của z .
- 5.8 Tính đạo hàm riêng df/dx của các hàm số sau. Mô tả chi tiết các bước thực hiện. a. Sử dụng quy tắc chuỗi. Cung cấp kích thước của từng đạo hàm riêng.
- tive.

- $$f(z) = \exp\left(\frac{1}{1-z}\right)$$
- $$1-z = g(y) = \sum y y^T$$
- $$h(x) = x^T \mu$$
- trong đó $x, \mu \in \mathbb{R}^D, S \in \mathbb{R}^{D \times D}$.
- b.
- $$f(x) = \text{tr}(xx^{2+\sigma} I), x \in \mathbb{R}^D$$
- Ở đây $\text{tr}(A)$ là vết của A , tức là tổng của các phần tử đường chéo A_{ii} .
Gợi ý: Hãy viết rõ tích ngoài.
- c. Sử dụng quy tắc chuỗi. Cung cấp kích thước của từng đạo hàm riêng. Bạn không cần phải tính tích của các đạo hàm riêng một cách rõ ràng.

- $$f = \tanh(z) \in \mathbb{R}^M$$
- $$z = Ax + b, x \in \mathbb{R}^N, A \in \mathbb{R}^{M \times N}, b \in \mathbb{R}^M.$$
- Ở đây, hàm $\tanh$ được áp dụng cho mọi thành phần của z .

- 5.9 Chúng tôi định nghĩa
- $$g(x, z, v) := \log p(x, z) - \log q(z, v)$$
- $$z := t(\epsilon, v)$$
- Đối với các hàm khả vi p, q, t và $x \in \mathbb{R}^D, z \in \mathbb{R}^E, v \in \mathbb{R}^F, \epsilon \in \mathbb{R}^G$. Bởi
hãy tính đạo hàm bằng quy tắc chuỗi.
- $$\frac{d}{dv} g(x, z,$$



Xác suất và phân phối

Hiểu một cách đơn giản, xác suất là môn học nghiên cứu về sự không chắc chắn. Xác suất có thể được hiểu là tỷ lệ số lần một sự kiện xảy ra, hoặc là một mức độ nào đó. niềm tin về một sự kiện. Sau đó, chúng ta muốn sử dụng xác suất này để đo lường khả năng xảy ra của một sự kiện nào đó trong một thí nghiệm. Như đã đề cập

Trong Chương 1, chúng ta thường định lượng sự không chắc chắn trong dữ liệu, sự không chắc chắn trong mô hình học máy và sự không chắc chắn trong các dự đoán được tạo ra bởi

Mô hình. Việc định lượng sự không chắc chắn đòi hỏi ý tưởng về một biến ngẫu nhiên. đây là một hàm ánh xạ kết quả của các thí nghiệm ngẫu nhiên đến một tập hợp các

Các thuộc tính mà chúng ta quan tâm. Liên quan đến biến ngẫu nhiên

là một hàm đo lường xác suất xảy ra một kết quả cụ thể (hoặc

(một tập hợp các kết quả) sẽ xảy ra; điều này được gọi là phân phối xác suất.

Các phân phối xác suất được sử dụng như một khối xây dựng cho các khái niệm khác, chẳng hạn như mô hình xác suất (Mục 8.4), mô hình đồ họa (Mục 8.5) và lựa chọn mô hình (Mục 8.6). Trong phần tiếp theo, chúng tôi trình bày

ba khái niệm xác định không gian xác suất (không gian mẫu, các sự kiện, và xác suất của một sự kiện) và mối liên hệ của chúng với nhau.

Khái niệm thứ tư được gọi là biến ngẫu nhiên. Cách trình bày được cố ý hơi mơ hồ một chút vì một cách trình bày chặt chẽ có thể che khuất ý nghĩa của nó.

Trực giác đằng sau các khái niệm. Bản tóm tắt các khái niệm được trình bày trong tài liệu này. Các chương được thể hiện trong Hình 6.1.

6.1 Xây dựng không gian xác suất

Lý thuyết xác suất nhằm mục đích định nghĩa một cấu trúc toán học cho

Mô tả các kết quả ngẫu nhiên của thí nghiệm. Ví dụ, khi tung một vật

Với một đồng xu duy nhất, chúng ta không thể xác định được kết quả, nhưng bằng cách tung nhiều đồng xu, chúng ta có thể quan sát được quy luật trong kết quả trung bình.

Sử dụng cấu trúc toán học của xác suất này, mục tiêu là thực hiện


suy luận tự động, và theo nghĩa này, xác suất khái quát hóa logic.

Lý luận (Jaynes, 2003).

6.1.1 Các vấn đề triết học

Khi xây dựng các hệ thống suy luận tự động, cần sử dụng logic Boolean cổ điển.

không cho phép chúng ta diễn đạt một số hình thức lập luận hợp lý. Hãy xem xét



Hình 6.1 Sơ đồ tư duy về các khái niệm liên quan đến biến ngẫu nhiên và các phân bố xác suất, như được mô tả trong chương này.

Tình huống sau: Ta nhận thấy A là sai. Ta thấy B trở nên kém thuyết phục hơn, mặc dù không thể rút ra kết luận nào từ logic cổ điển. Chúng ta nhận thấy B là đúng. Có vẻ như A trở nên hợp lý hơn. Chúng ta sử dụng hình thức lập luận này hàng ngày. Chúng ta đang đợi một người bạn và xem xét ba khả năng: H1, cô ấy đến đúng giờ; H2, cô ấy bị kẹt xe; và H3, cô ấy bị người ngoài hành tinh bắt cóc. Khi thấy bạn mình đến muộn, chúng ta phải loại trừ H1 một cách logic. Chúng ta cũng có xu hướng cho rằng H2 có khả năng xảy ra hơn, mặc dù về mặt logic chúng ta không bắt buộc phải làm vậy. Cuối cùng, chúng ta có thể xem xét H3 là có thể xảy ra, nhưng vẫn cho rằng nó khá khó xảy ra.

Làm thế nào chúng ta kết luận H2 là câu trả lời khả thi nhất? Nhìn theo cách này, " Lý thuyết xác suất khả thi có thể được coi là sự khái quát hóa của logic Boolean. Trong lập luận, cần phải mở rộng bối cảnh của học máy, nó thường được áp dụng theo cách này để hình thức hóa các giá trị đúng rồi rạc và thiết kế các hệ thống suy luận tự động. Các lập luận sâu hơn về cách lý thuyết xác suất là nền tảng của các hệ thống suy luận có thể được tìm thấy trong Pearl (1988).

những giá trị sai lệch của sự thật liên tục khả năng xảy ra" (Jaynes, 2003).

Cơ sở triết học của xác suất và mối liên hệ của nó với những gì chúng ta cho là đúng (theo nghĩa logic) đã được Cox nghiên cứu (Jaynes, 2003). Một cách khác để suy nghĩ về điều này là nếu chúng ta chính xác về lẽ thường, cuối cùng chúng ta sẽ xây dựng nên các xác suất.

ET Jaynes (1922-1998) đã xác định ba tiêu chí toán học, phải được áp dụng cho mọi khả năng:

- 1. Mức độ hợp lý được biểu thị bằng các số thực.
- 2. Những con số này phải dựa trên các quy tắc của lẽ thường.

3. Kết quả lập luận phải nhất quán với ba nghĩa sau của từ “nhất quán”:

- (a) Tính nhất quán hoặc không mâu thuẫn: Khi cùng một kết quả có thể đạt được thông qua các phương pháp khác nhau, thì phải tìm thấy cùng một giá trị độ tin cậy trong tất cả các trường hợp. (b)

Tính trung thực: Tất cả dữ liệu có sẵn phải được xem xét. (c) Tính khả tái

tạo: Nếu kiến thức của chúng ta về hai vấn đề là như nhau, thì chúng ta phải gán cùng một mức độ tin cậy cho cả hai.

Định lý Cox-Jaynes chứng minh rằng những tính khả thi này đủ để xác định các quy tắc toán học phổ quát áp dụng cho tính khả thi p , cho đến khi được biến đổi bởi một hàm đơn điệu tùy ý. Điều quan trọng là, những quy tắc này chính là các quy tắc về xác suất.

Lưu ý. Trong học máy và thống kê, có hai cách hiểu chính về xác suất: cách hiểu Bayes và cách hiểu tần suất (Bishop, 2006; Efron và Hastie, 2016). Cách hiểu Bayes sử dụng xác suất để xác định mức độ không chắc chắn mà người dùng có về một sự kiện. Nó đôi khi được gọi là “xác suất chủ quan” hoặc “mức độ tin tưởng”.

Cách diễn giải theo trường phái tần suất xem xét tần suất tương đối của các sự kiện quan tâm so với tổng số sự kiện đã xảy ra. Xác suất của một sự kiện được định nghĩa là tần suất tương đối của sự kiện đó trong giới hạn khi có dữ liệu vô hạn. Một số tài liệu về máy học về mô hình xác suất sử dụng ký hiệu và thuật ngữ chuyên ngành khá sơ sài, gây khó hiểu. Văn bản

này cũng không ngoại lệ. Nhiều khái niệm khác nhau đều được gọi chung là “phân phối xác suất”, và người đọc thường phải phân tách ý nghĩa khỏi ngữ cảnh. Một mẹo để giúp hiểu rõ hơn về phân phối xác suất là kiểm tra xem chúng ta đang cố gắng mô hình hóa một cái gì đó thuộc loại phân loại (biến ngẫu nhiên rời rạc) hay một cái gì đó liên tục (biến ngẫu nhiên liên tục). Các loại câu hỏi mà chúng ta giải quyết trong máy học có liên quan chặt chẽ đến việc chúng ta đang xem xét các mô hình phân loại hay liên tục.

6.1.2 Xác suất và Biến ngẫu nhiên Có ba khái niệm khác

biệt thường bị nhầm lẫn khi thảo luận về xác suất. Đầu tiên là khái niệm về không gian xác suất, cho phép chúng ta định lượng khái niệm xác suất. Tuy nhiên, chúng ta thường không làm việc trực tiếp với không gian xác suất cơ bản này. Thay vào đó, chúng ta làm việc với các biến ngẫu nhiên (khái niệm thứ hai), chuyển xác suất sang một không gian thuận tiện hơn (thường là không gian số). Khái niệm thứ ba là khái niệm về phân phối hoặc quy luật liên quan đến một biến ngẫu nhiên. Chúng ta sẽ giới thiệu hai khái niệm đầu tiên trong phần này và mở rộng khái niệm thứ ba trong Phần 6.2.

Lý thuyết xác suất hiện đại dựa trên một tập hợp các tiên đề do Kolmogorov đề xuất.

Bản thảo (15/01/2024) của cuốn “Toán học cho máy học”. Phản hồi: <https://mml-book.com>.

6.1 Xây dựng không gian xác suất175

(Grinstead và Snell, 1997; Jaynes, 2003) giới thiệu ba khái niệm về không gian mẫu, không gian sự kiện và độ đo xác suất. Không gian xác suất mô hình hóa một quá trình trong thế giới thực (được gọi là thí nghiệm). với kết quả ngẫu nhiên.

Không gian mẫu Ω

Không gian mẫu là tập hợp tất cả các kết quả có thể xảy ra của thí nghiệm, không gian mẫu thường được ký hiệu là Ω . Ví dụ, hai lần tung đồng xu liên tiếp có không gian mẫu là {hh, tt, ht, th}, trong đó “h” biểu thị “mặt ngửa” và “t” biểu thị “mặt sấp”.

Không gian tổ chức sự kiện A

Không gian sự kiện là không gian các kết quả tiềm năng của thí nghiệm. Một tập con không gian sự kiện A của không gian mẫu Ω nằm trong không gian sự kiện A nếu vào cuối thí nghiệm, ta có thể quan sát xem một kết quả cụ thể $\omega \in \Omega$ có nằm trong A hay không. Không gian sự kiện A được thu được bằng cách xem xét tập hợp các tập con của Ω , và đối với các phân bố xác suất rời rạc (Mục 6.2.1). A thường là tập hợp con của Ω .

Với mỗi sự kiện A

A , ta gán một số $P(A)$ để đo xác suất hoặc mức độ tin tưởng rằng sự kiện đó sẽ xảy ra. $P(A)$ được gọi là xác suất của A .

xác suất

Xác suất của một sự kiện đơn lẻ phải nằm trong khoảng $[0, 1]$, và tổng xác suất trên tất cả các kết quả trong không gian mẫu Ω phải bằng 1, tức là $P(\Omega) = 1$. Cho một không gian xác suất (Ω, A, P) , chúng ta muốn sử dụng nó để mô hình hóa một số hiện tượng trong thế giới thực. Trong học máy, chúng ta thường tránh đề cập rõ ràng đến không gian xác suất, mà thay vào đó đề cập đến xác suất trên các đại lượng quan tâm, mà chúng ta ký hiệu là T .

Trong cuốn sách này, chúng ta gọi T là không gian đích và các phần tử của T là các trạng thái. Chúng ta giới thiệu một hàm không gian đích $X : \Omega \rightarrow T$ nhận một phần tử của Ω (một kết quả) và trả về một đại lượng cụ thể x , một giá trị trong T . Sự liên kết/ánh xạ từ Ω đến T này được gọi là biến ngẫu nhiên. Ví dụ, trong trường hợp tung hai đồng xu và đếm số lần xuất hiện mặt ngửa, một biến ngẫu nhiên X ánh xạ tới ba kết quả có thể xảy ra: $X(hh) = 2, X(ht) = 1, X(th) = 1$ và $X(tt) = 0$. Trong trường hợp cụ thể này, $T = \{0, 1, 2\}$, và chúng ta quan tâm đến xác suất trên các phần tử của T . Đối với một không gian mẫu hữu hạn Ω và T , tên gọi “biến ngẫu nhiên hữu hạn” là một nguồn tra cứu tuyệt vời. Với bất kỳ tập con $S \subseteq T$ nào, ta liên kết $P_X(S) = \sum_{\omega \in \Omega: X(\omega) \in S} P(\omega)$ (xác suất) với một sự kiện cụ thể xảy ra tương ứng với biến ngẫu nhiên X . Ví dụ 6.1 cung cấp một minh họa cụ thể về thuật ngữ-

sự hiểu lầm vì nó không phải là
Nó là ngẫu nhiên và cũng không phải là một biến số. Nó là một chức năng.

Lưu ý. Không gian mẫu Ω nói trên không may lại được gọi bằng những tên khác nhau trong các sách khác nhau. Một tên gọi phổ biến khác của Ω là “không gian trạng thái” (Jacod và Protter, 2004), nhưng không gian trạng thái đôi khi được dành riêng để chỉ các trạng thái trong một hệ thống động (Hasselblatt và...) .

Katok, 2003). Các tên gọi khác đôi khi được sử dụng để mô tả Ω là: “mẫu không gian mô tả”, “không gian khả năng” và “không gian sự kiện”.

Ví dụ 6.1

Ví dụ minh họa này nhằm mục đích giúp người đọc hiểu rõ hơn về cách tính xác suất.
về cơ bản là thiên vị
Ví dụ về tung đồng xu.

về các giao điểm và hợp nhất của các tập hợp sự kiện. Một lời giới thiệu nhẹ nhàng hơn về
Xác suất với nhiều ví dụ có thể được tìm thấy trong chương 2 của Walpole.
và cộng sự (2011).

Hãy xem xét một thí nghiệm thống kê trong đó ta mô hình hóa một trò chơi hội chợ bao gồm việc rút hai đồng xu từ một túi (có hoàn lại). Có Các đồng xu của Mỹ (ký hiệu là \$) và Anh (ký hiệu là £) nằm trong túi, và Vì ta rút hai đồng xu từ trong túi, nên tổng cộng có bốn kết quả. Không gian trạng thái hay không gian mẫu Ω của thí nghiệm này là $(\$, \$), (\$, £), (£, \$), (£, £)$. Giả sử thành phần của túi tiền xu là sao cho mỗi lần rút thăm sẽ trả về ngẫu nhiên một \$ với xác suất 0,3. Sự kiện mà chúng ta quan tâm là tổng số lần lặp lại. Lệnh draw trả về \$. Chúng ta hãy định nghĩa một biến ngẫu nhiên X ánh xạ mẫu không gian Ω đến T biểu thị số lần chúng ta rút \$ ra khỏi túi. Từ không gian mẫu trước đó, ta có thể thấy ta có thể nhận được 0 đô la, 1 đô la, hoặc hai \$, và do đó $T = \{0, 1, 2\}$. Biến ngẫu nhiên X (một hàm hoặc bảng tra cứu) có thể được biểu diễn dưới dạng bảng như sau:

$$X((\$, \$)) = 2$$

(6.1)

$$X((\$, £)) = 1$$

(6.2)

$$X((£, \$)) = 1$$

(6.3)

$$X((£, £)) = 0$$

(6.4)

Vì ta trả lại đồng xu đầu tiên đã rút trước khi rút đồng xu thứ hai, nên điều này Điều này ngụ ý rằng hai lần rút thăm là độc lập với nhau, điều mà chúng ta sẽ Thảo luận chi tiết tại Mục 6.4.5. Lưu ý rằng có hai kết quả thí nghiệm. những sự kiện này đều tương ứng với cùng một kết quả, trong đó chỉ có một trong các kết quả rút thăm trả về \$. Do đó, hàm phân bố xác suất (Mục 6.2.1) của X được cho bởi

$$\begin{aligned} P(X = 2) &= P((\$, \$)) \\ &= P(\$) \cdot P(\$) \\ &= 0,3 \cdot 0,3 = 0,09 \end{aligned}$$

(6.5)

$$\begin{aligned} P(X = 1) &= P((\$, £) \quad (£, \$)) \\ &= P((\$, £)) + P((£, \$)) \\ &= 0,3 \cdot (1 - 0,3) + (1 - 0,3) \cdot 0,3 = 0,42 \end{aligned}$$

(6.6)

$$\begin{aligned} P(X = 0) &= P((£, £)) \\ &= P(£) \cdot P(£) \\ &= (1 - 0,3) \cdot (1 - 0,3) = 0,49 \end{aligned}$$

(6.7)

Trong phép tính, chúng ta đã đánh đồng hai khái niệm khác nhau, xác suất của đầu ra X và xác suất của các mẫu trong Ω . Ví dụ, trong (6.7) chúng ta nói $P(X = 0) = P((\mathbb{F}, \mathbb{F}))$. Xét biến ngẫu nhiên $X : \Omega \rightarrow \mathbb{T}$ và một tập con $S \subseteq \mathbb{T}$ (ví dụ, một phần tử đơn lẻ của $\mathbb{T}$ như kết quả thu được một mặt ngửa khi tung hai đồng xu).

Gọi $X^{-1}(S)$ là ảnh ngược của S bởi X , tức là tập hợp các phần tử của Ω ánh xạ tới S dưới X ; $\{\omega \in \Omega : X(\omega) \in S\}$. Một cách để hiểu sự biến đổi xác suất từ các sự kiện trong Ω thông qua biến ngẫu nhiên X là liên kết nó với xác suất của ảnh ngược của S (Jacod và Protter, 2004). Đối với $S \subseteq \mathbb{T}$, chúng ta có ký hiệu

$$P_X(S) = P(X \in S) = P(X^{-1}(S)) = P(\{\omega \in \Omega : X(\omega) \in S\}). \quad (6.8)$$

Về trái của (6.8) là xác suất của tập hợp các kết quả có thể xảy ra (ví dụ: số lượng $\$ = 1$) mà chúng ta quan tâm. Thông qua biến ngẫu nhiên X , ánh xạ các trạng thái đến các kết quả, chúng ta thấy ở vế phải của (6.8) rằng đây là xác suất của tập hợp các trạng thái (trong Ω) có thuộc tính (ví dụ: $\$ \mathbb{F}, \mathbb{F} \$$). Chúng ta nói rằng một biến ngẫu nhiên X được phân phối theo một phân phối xác suất cụ thể P_X , xác định ánh xạ xác suất giữa sự kiện và xác suất của kết quả của biến ngẫu nhiên. Nói cách khác, hàm P_X hoặc tương đương $P \circ X^{-1}$ là luật hoặc phân phối của biến ngẫu nhiên X .

Lưu ý. Không gian mục tiêu, tức là phạm vi $\mathbb{T}$ của biến ngẫu nhiên X , được sử dụng để chỉ loại không gian xác suất, nghĩa là biến ngẫu nhiên $\mathbb{T}$. Khi $\mathbb{T}$ hữu hạn hoặc vô hạn đếm được, nó được gọi là biến ngẫu nhiên rời rạc (Mục 6.2.1). Đối với các biến ngẫu nhiên liên tục (Mục 6.2.2), chúng ta chỉ xét $\mathbb{T} = \mathbb{R}$ hoặc $\mathbb{T} = \mathbb{R}^D$.

6.1.3 Thống kê

Lý thuyết xác suất và thống kê thường được trình bày cùng nhau, nhưng chúng liên quan đến các khía cạnh khác nhau của sự không chắc chắn. Một cách để phân biệt chúng là thông qua loại vấn đề được xem xét. Sử dụng xác suất, chúng ta có thể xem xét một mô hình của một quá trình nào đó, trong đó sự không chắc chắn tiềm ẩn được thể hiện bằng các biến ngẫu nhiên, và chúng ta sử dụng các quy tắc xác suất để suy ra điều gì sẽ xảy ra. Trong thống kê, chúng ta quan sát thấy một điều gì đó đã xảy ra và cố gắng tìm ra quá trình tiềm ẩn giải thích các quan sát đó. Theo nghĩa này, máy học gần giống với thống kê ở mục tiêu xây dựng một mô hình thể hiện đầy đủ quá trình đã tạo ra dữ liệu. Chúng ta có thể sử dụng các quy tắc xác suất để có được một mô hình "phù hợp nhất" cho một số dữ liệu.

Một khía cạnh khác của hệ thống học máy là chúng ta quan tâm đến lỗi khái quát hóa (xem Chương 8). Điều này có nghĩa là chúng ta thực sự quan tâm đến hiệu suất của hệ thống trên các trường hợp mà chúng ta sẽ quan sát trong tương lai, những trường hợp này không hoàn toàn giống với các trường hợp mà chúng ta đã có.

đã thấy cho đến nay. Phân tích hiệu suất trong tương lai này dựa trên xác suất và Phần lớn các số liệu thống kê nằm ngoài phạm vi trình bày trong chương này. Độc giả quan tâm được khuyến khích tìm đọc các tác phẩm của Boucheron. et al. (2013) và Shalev-Shwartz và Ben-David (2014). Chúng ta sẽ thấy thêm Về thống kê trong Chương 8.

6.2 Xác suất rời rạc và xác suất liên tục

Chúng ta hãy tập trung vào các cách để mô tả xác suất của một sự kiện. như đã giới thiệu trong Phần 6.1. Tùy thuộc vào việc không gian mục tiêu là rời rạc hay liên tục, cách tự nhiên để gọi tên các phân bố sẽ khác nhau. Khi không gian đích T là rời rạc, ta có thể xác định xác suất xảy ra điều đó. Biến ngẫu nhiên X nhận một giá trị cụ thể x T được ký hiệu là $P(X = x)$. Biểu thức $P(X = x)$ đối với biến ngẫu nhiên rời rạc X được gọi là hàm phân bố xác suất. Khi không gian đích T liên tục, ví dụ, Trên trục số thực R, sẽ tự nhiên hơn nếu xác định xác suất xảy ra một sự kiện ngẫu nhiên. Biến ngẫu nhiên X nằm trong một khoảng, được ký hiệu là $P(a \leq X \leq b)$ với $a < b$. Theo quy ước, chúng ta xác định xác suất để một biến ngẫu nhiên X nhỏ hơn một giá trị cụ thể x, được ký hiệu là $P(X \leq x)$. Biểu thức $P(X \leq x)$ cho Biến ngẫu nhiên liên tục X được gọi là phân phối tích lũy.

hàm phân bố xác suất

tích lũy

hàm phân phối . Chúng ta sẽ thảo luận về các biến ngẫu nhiên liên tục trong Phần 6.2.2. Chúng ta sẽ xem xét lại thuật ngữ và so sánh giữa rời rạc và liên tục. các biến ngẫu nhiên trong Mục 6.2.3.

đơn biến

đa biến

Lưu ý. Chúng ta sẽ sử dụng cụm từ "phân phối đơn biến" để chỉ các phân phối của một biến ngẫu nhiên duy nhất (các trạng thái của biến này được ký hiệu bằng chữ thường). x). Chúng ta sẽ gọi các phân phối của nhiều hơn một biến ngẫu nhiên là phân phối đa biến , và thường sẽ xem xét một vectơ ngẫu nhiên. các biến (trạng thái của chúng được ký hiệu bằng chữ x in đậm).

6.2.1 Xác suất rời rạc

Khi không gian mục tiêu là rời rạc, ta có thể hình dung phân bố xác suất của nhiều biến ngẫu nhiên như lấp đầy một (đa chiều) mảng các số. Hình 6.2 hiển thị một ví dụ. Không gian đích của Xác suất đồng thời là tích Descartes của các không gian mục tiêu của mỗi trường hợp. các biến ngẫu nhiên. Chúng ta định nghĩa xác suất đồng thời là giá trị của cả hai các giá trị chung


xác suất chung

$$P(X = x_i, Y = y_j) = \frac{n_{ij}}{N},$$

(6.9)

trong đó n_{ij} là số sự kiện có trạng thái x_i và y_j , và N là tổng số. số sự kiện. Xác suất đồng thời là xác suất giao nhau của cả hai sự kiện, tức là $P(X = x_i, Y = y_j) = P(X = x_i \cap Y = y_j)$. Hình 6.2 minh họa hàm khối lượng xác suất (pmf) của một phân phối xác suất rời rạc. Đối với hai biến ngẫu nhiên X và Y, xác suất

hàm phân bố xác suất



Hình 6.2 Minh họa trực quan của một hàm phân bố xác suất hai biến rời rạc, với các biến ngẫu nhiên X và Y. Điều này sơ đồ được điều chỉnh từ Bishop (2006).

Trường hợp $X = x$ và $Y = y$ được viết (một cách đơn giản) là $p(x, y)$ và được gọi là xác suất đồng thời. Có thể coi xác suất như một hàm nhận vào trạng thái x và y và trả về một số thực, đó là lý do tại sao chúng ta viết $p(x, y)$. Xác suất biên để X nhận giá trị x bất kể giá trị xác suất biên của biến ngẫu nhiên Y được viết (một cách đơn giản) là $p(x)$. Chúng ta viết $\sum_y p(x, y)$ để biểu thị rằng biến ngẫu nhiên X được phân phối theo $p(x)$. Nếu chúng ta chỉ xem xét các trường hợp $X = x$, thì tỷ lệ các trường hợp (xác suất có điều kiện) mà $Y = y$ được viết (một cách đơn giản) là $p(y | x)$. xác suất có điều kiện

Ví dụ 6.2 Xét hai biến ngẫu nhiên X và Y , Trong đó X có năm trạng thái khả dĩ và Y có ba trạng thái khả dĩ, như thể hiện trong Hình 6.2. Chúng ta ký hiệu n_{ij} là số sự kiện có trạng thái $X = x_i$ và $Y = y_j$, và ký hiệu N là tổng số sự kiện. Giá trị c_i là tổng tần số riêng lẻ của cột thứ i , tức là $c_i = \sum_{j=1}^3 n_{ij}$ ($j=1 \dots 3$). Tương tự, giá trị r_j là tổng hàng, tức là $r_j = \sum_{i=1}^5 n_{ij}$ ($i=1 \dots 5$). Sử dụng các định nghĩa này, chúng ta có thể biểu diễn một cách gọn gàng sự phân bố của X và Y .

Phân bố xác suất của mỗi biến ngẫu nhiên, hay xác suất biên, có thể được xem như tổng của các xác suất trên một hàng hoặc một cột.

$$P(X = x_i) = \frac{c_i}{N} = \frac{\sum_{j=1}^3 n_{ij}}{N} \tag{6.10}$$

Và

$$P(Y = y_j) = \frac{r_j}{N} = \frac{\sum_{i=1}^5 n_{ij}}{N}, \tag{6.11}$$

trong đó c_i và r_j lần lượt là cột thứ i và hàng thứ j của bảng xác suất. Theo quy ước, đối với các biến ngẫu nhiên rời rạc có số sự kiện hữu hạn, ta giả định rằng tổng các xác suất bằng một, tức là

$$\sum_{i=1}^5 P(X = x_i) = 1 \text{ và } \sum_{j=1}^3 P(Y = y_j) = 1. \tag{6.12}$$

Xác suất có điều kiện là tỷ lệ phần trăm của một hàng hoặc cột trong một phần tử.

tế bào cụ thể. Ví dụ, xác suất có điều kiện của Y khi biết X là

$$P(Y = y_j \mid X = x_i) = \frac{n_{ij}}{c_i}, \tag{6.13}$$

và xác suất có điều kiện của X khi biết Y là

$$P(X = x_i \mid Y = y_j) = \frac{n_{ij}}{r_j}. \tag{6.14}$$

Trong học máy, chúng ta sử dụng các phân phối xác suất rời rạc để mô hình hóa. Biến phân loại là các biến nhận một tập hợp hữu hạn các giá trị không có thứ tự. Chúng có thể là các đặc điểm phân loại, chẳng hạn như bằng cấp đạt được tại trường đại học khi được sử dụng để dự đoán mức lương của một người, hoặc các nhãn phân loại, chẳng hạn như các chữ cái trong bảng chữ cái khi thực hiện nhận dạng chữ viết tay. Các phân phối rời rạc cũng thường được sử dụng để xây dựng các mô hình xác suất. Kết hợp một số hữu hạn các phân phối liên tục (Chương 11).

6.2.2 Xác suất liên tục

Trong phần này, chúng ta xem xét các biến ngẫu nhiên có giá trị thực, tức là chúng ta xem xét... các không gian mục tiêu là các khoảng trên đường thẳng thực $\mathbb{R}$. Trong cuốn sách này, chúng ta giả vờ Chúng ta có thể thực hiện các phép toán trên các biến ngẫu nhiên thực như thể chúng ta có các không gian xác suất rời rạc với số trạng thái hữu hạn. Tuy nhiên, sự đơn giản hóa này là Không chính xác trong hai trường hợp: khi chúng ta lặp lại một điều gì đó vô số lần, và khi ta muốn vẽ một điểm từ một khoảng. Tình huống đầu tiên Tình huống thứ nhất phát sinh khi chúng ta thảo luận về lỗi khái quát hóa trong học máy (Chương 8). Tình huống thứ hai phát sinh khi chúng ta muốn thảo luận về tính liên tục. các phân phối, chẳng hạn như phân phối Gaussian (Mục 6.5). Đối với mục đích của chúng ta, thì Việc thiếu độ chính xác cho phép giới thiệu ngắn gọn hơn về xác suất.

Lưu ý. Trong không gian liên tục, có thêm hai điểm kỹ thuật nữa, Điều này nghe có vẻ phi trực quan. Thứ nhất, tập hợp tất cả các tập con (được sử dụng để định nghĩa) Không gian sự kiện $\mathcal{A}$ trong Mục 6.1) không đủ ổn định. $\mathcal{A}$ cần bị hạn chế để cư xử tốt dưới các phần bù tập hợp, các giao tập hợp, và các phép hợp tập hợp. Thứ hai, kích thước của một tập hợp (trong không gian rời rạc có thể là (được thu được bằng cách đếm các phần tử) hóa ra lại khá phức tạp. Kích thước của một Một tập hợp được gọi là độ đo của nó. Ví dụ, số phần tử của các tập hợp rời rạc, Độ dài của một khoảng trong $\mathbb{R}$ và thể tích của một vùng trong $\mathbb{R}^d$ đều là các phép đo. Các tập hợp hoạt động tốt dưới các phép toán tập hợp và ngoài ra còn có Một tôpô được gọi là đại số σ Borel . Betancourt trình bày chi tiết cách xây dựng cẩn thận các không gian xác suất từ lý thuyết tập hợp mà không bị sa lầy vào những chi tiết rườm rà. Về mặt kỹ thuật, xem <https://tinyurl.com/yb3t6mfd>. Để có cách xây dựng chính xác hơn, chúng tôi tham khảo Billingsley (1995) và Jacod và Protter. (2004).

Trong cuốn sách này, chúng ta xem xét các biến ngẫu nhiên có giá trị thực cùng với hệ số tương quan của chúng.

Đáp ứng đại số σ -Borel. Chúng ta xem xét các biến ngẫu nhiên có giá trị trong $\mathbb{R}^D$ được coi là một vectơ gồm các biến ngẫu nhiên có giá trị thực.

Định nghĩa 6.1 (Hàm mật độ xác suất). Một hàm $f : \mathbb{R}^D \rightarrow \mathbb{R}$ là được gọi là hàm mật độ xác suất (pdf) nếu

1. $x \in \mathbb{R}^D : f(x) \geq 0$
2. Tích phân của nó tồn tại và

$$\int_{\mathbb{R}^D} f(x) dx = 1.$$

(6.15)

Đối với hàm phân bố xác suất (pmf) của các biến ngẫu nhiên rời rạc, thì Tích phân trong (6.15) được thay thế bằng tổng (6.12).

Hãy lưu ý rằng hàm mật độ xác suất là bất kỳ hàm f nào thỏa mãn điều kiện sau: không âm và tích phân bằng một. Chúng ta liên kết một biến ngẫu nhiên X với hàm f này bởi

$$P(a \leq X \leq b) = \int_a^b f(x) dx,$$

(6.16)

trong đó $a, b \in \mathbb{R}$ và $x \in \mathbb{R}$ là các kết quả của biến ngẫu nhiên liên tục X . Các trạng thái $x \in \mathbb{R}^D$ được định nghĩa tương tự bằng cách xem xét một vectơ của $x \in \mathbb{R}$. Mỗi liên hệ này (6.16) được gọi là luật hoặc phân phối luật. Biến ngẫu nhiên X .

Nhận xét. Ngược lại với các biến ngẫu nhiên rời rạc, xác suất để một biến ngẫu nhiên liên tục X nhận một giá trị cụ thể $P(X = x)$ là bằng không. Điều này giống như cố gắng xác định một khoảng trong (6.16) trong đó $a = b$.

Định nghĩa 6.2 (Hàm phân phối tích lũy). Hàm phân phối tích lũy... tích lũy hàm phân phối tích lũy (cdf) của biến ngẫu nhiên thực đa biến X với Trạng thái $x \in \mathbb{R}^D$ được cho bởi

$$F_X(x) = P(X_1 \leq x_1, \dots, X_D \leq x_D),$$

trong đó

(6.17)

$X = [X_1, \dots, X_D]$, $x = [x_1, \dots, x_D]$, và vế phải biểu thị xác suất biến ngẫu nhiên X_i nhận giá trị nhỏ hơn lớn hơn hoặc bằng x_i .

Hàm phân phối tích lũy (cdf) cũng có thể được biểu diễn dưới dạng tích phân của mật độ xác suất. hàm $f(x)$ sao cho

$$F_X(x) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_D} f(z_1, \dots, z_D) dz_1 \dots dz_D.$$

(6.18)

Lưu ý. Chúng tôi nhắc lại rằng thực tế có hai khái niệm khác biệt khi Chúng ta sẽ nói về các phân phối. Đầu tiên là khái niệm về hàm mật độ xác suất (ký hiệu là $f(x)$), đó là một hàm không âm có tổng bằng một. Thứ hai là định luật của một biến ngẫu nhiên X , tức là mối liên hệ của biến ngẫu nhiên X với

Hàm mật độ xác suất $f(x)$.


mật độ xác suất
chức năng
pdf

$P(X = x)$ là một tập hợp
đo bằng không.

hàm phân phối

Có các hàm phân phối tích lũy (cdf).
những thứ không có
các tệp PDF tương ứng.

Hình 6.3 Ví dụ về (a) rời rạc và (b) liên tục đồng nhất phân phối. Xem Ví dụ 6.3 để biết chi tiết về phân phối.



Trong phần lớn cuốn sách này, chúng ta sẽ không sử dụng ký hiệu $f(x)$ và $F(x)$ vì hầu hết chúng ta không cần phân biệt giữa hàm mật độ xác suất (pdf) và hàm phân phối tích lũy (cdf). Tuy nhiên, chúng ta sẽ cần phải cẩn thận về pdf và cdf trong Phần 6.7.

6.2.3 So sánh phân phối rời rạc và phân phối liên tục

Nhớ lại từ Mục 6.1.2 rằng xác suất là dương và tổng xác suất cộng lại bằng một. Đối với các biến ngẫu nhiên rời rạc (xem (6.12)), điều này ngụ ý rằng xác suất của mỗi trạng thái phải nằm trong khoảng $[0, 1]$. Tuy nhiên, đối với các biến ngẫu nhiên liên tục, việc chuẩn hóa (xem (6.15)) không ngụ ý rằng giá trị của mật độ nhỏ hơn hoặc bằng 1 cho tất cả các giá trị. Chúng tôi minh họa điều này trong Hình 6.3 bằng cách sử dụng phân phối đồng đều cho cả các biến ngẫu nhiên rời rạc và liên tục.

phân phối đồng đều

Ví dụ 6.3 Chúng ta xem xét hai ví dụ về phân phối đều, trong đó mỗi trạng thái có xác suất xảy ra như nhau. Ví dụ này minh họa một số điểm khác biệt giữa phân phối xác suất rời rạc và liên tục.

Giả sử Z là một biến ngẫu nhiên phân bố đều rời rạc với ba trạng thái $\{z = \text{Giá trị thực tế là } 1.1, z = 0.3, z = 1.5\}$. Hàm phân bố xác suất có thể được biểu diễn như sau: như một bảng giá trị xác suất:

những tiểu bang này không phải là có ý nghĩa ở đây, và chúng tôi có tình chọn các con số để nhấn mạnh rằng chúng tôi không muốn sử dụng (và nên bỏ qua) thứ tự của

	z	1.1	0.3	1.5
$P(Z = z)$		$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

các tiểu bang.

Ngoài ra, chúng ta cũng có thể coi đây như một đồ thị (Hình 6.3(a)), trong đó chúng ta sử dụng thực tế là các trạng thái có thể được định vị trên trục x , và trục y biểu thị xác suất của một trạng thái cụ thể. Trục y trong Hình 6.3(a) được kéo dài một cách có chủ ý để giống với trục y trong Hình 6.3(b).

Giả sử X là một biến ngẫu nhiên liên tục nhận giá trị trong khoảng $[0, 9]$ $X = 1.6$, như được thể hiện trong Hình 6.3(b). Quan sát thấy chiều cao của

Kiểu	“Xác suất điểm”	“Xác suất khoảng”
Rời rạc	$P(X = x)$ Hàm phân bố xác suất	Không áp dụng
Liên tục	$p(x)$ Hàm mật độ xác suất	$P(X \leq x)$ Hàm phân phối tích lũy

Bảng 6.1
Danh pháp cho
xác suất
phân phối.

Mật độ có thể lớn hơn 1. Tuy nhiên, nó cần phải thỏa mãn điều kiện đó.

$$\int_{-\infty}^{\infty} p(x) dx = 1. \tag{6.19}$$

Lưu ý. Có một điểm tinh tế khác liên quan đến phân bố xác suất rời rạc. Về nguyên tắc, các trạng thái $z_1, \dots, z_d$ không có bất kỳ về cấu trúc, tức là thường không có cách nào để so sánh chúng, ví dụ như vậy. $z_1 = \text{đỏ}$, $z_2 = \text{xanh lá cây}$, $z_3 = \text{xanh dương}$. Tuy nhiên, trong nhiều máy học Các ứng dụng trạng thái rời rạc nhận các giá trị số, ví dụ: $z_1 = 1.1$, $z_2 = 0.3$, $z_3 = 1.5$, trong đó ta có thể nói $z_1 < z_2 < z_3$. Các trạng thái rời rạc giả định các giá trị số đặc biệt hữu ích vì chúng ta thường xem xét Giá trị kỳ vọng (Mục 6.4.1) của các biến ngẫu nhiên.

Thật không may, tài liệu về học máy sử dụng ký hiệu và thuật ngữ che giấu sự khác biệt giữa không gian mẫu Ω và mục tiêu. không gian, T và biến ngẫu nhiên X . Với một giá trị x thuộc tập hợp các giá trị có thể có kết quả của biến ngẫu nhiên X , tức là $x \in T$, $p(x)$ biểu thị xác suất. Chúng ta nghĩ về Khả năng biến ngẫu nhiên X có kết quả là x . Đối với biến ngẫu nhiên rời rạc Đối với các biến số, điều này được viết là $P(X = x)$, được gọi là hàm khối lượng xác suất. Hàm khối lượng xác suất thường được gọi là “phân bố”. Đối với Đối với các biến liên tục, $p(x)$ được gọi là hàm mật độ xác suất (thường là (được gọi là mật độ). Để mọi thứ trở nên phức tạp hơn nữa, tích lũy Hàm phân phối $P(X \leq x)$ thường cũng được gọi là “phân phối”. Trong chương này, chúng ta sẽ sử dụng ký hiệu X để chỉ cả phân phối đơn biến. và các biến ngẫu nhiên đa chiều, và ký hiệu các trạng thái lần lượt là x và x . Chúng tôi tóm tắt danh pháp trong Bảng 6.1.

kết quả x là
lập luận rằng
kết quả là
xác suất $p(x)$.

Lưu ý. Chúng ta sẽ sử dụng thuật ngữ “phân phối xác suất” chứ không phải Điều này không chỉ áp dụng cho các hàm phân bố xác suất rời rạc mà còn cho các hàm phân bố xác suất liên tục, mặc dù về mặt kỹ thuật điều này không chính xác. Phù hợp với... Trong hầu hết các tài liệu về học máy, chúng ta cũng dựa vào ngữ cảnh để phân biệt. Các cách sử dụng khác nhau của cụm từ “phân phối xác suất”.

6.3 Quy tắc tổng, quy tắc tích và định lý Bayes

Chúng ta coi lý thuyết xác suất như một sự mở rộng của lý luận logic. Khi chúng ta Như đã thảo luận trong Phần 6.1.1, các quy tắc xác suất được trình bày ở đây tuân theo

một cách tự nhiên từ việc đáp ứng các yêu cầu (Jaynes, 2003, chương 2). Mô hình xác suất (Mục 8.4) cung cấp nền tảng nguyên tắc cho việc thiết kế các phương pháp học máy. Một khi chúng ta đã xác định các phân phối xác suất (Mục 6.2) tương ứng với sự không chắc chắn của dữ liệu và Vấn đề của chúng ta, hóa ra chỉ có hai quy tắc cơ bản, đó là quy tắc tổng và quy tắc tích.

Nhớ lại từ (6.9) rằng $p(x, y)$ là phân phối chung của hai biến ngẫu nhiên x, y . Các phân phối $p(x)$ và $p(y)$ là các phân phối biên tương ứng, và $p(y | x)$ là phân phối có điều kiện của y . Cho trước giá trị x . Cho trước định nghĩa về xác suất biên và xác suất có điều kiện. Đối với các biến ngẫu nhiên rời rạc và liên tục trong Phần 6.2, giờ đây chúng ta có thể Trình bày hai quy tắc cơ bản trong lý thuyết xác suất.

Quy tắc đầu tiên, quy tắc tổng, phát biểu rằng:

$$p(x) = \sum_y p(x, y) \quad \text{nếu } y \text{ là biến rời rạc}$$
$$p(x) = \int_Y p(x, y) dy \quad \text{nếu } y \text{ liên tục}$$

(6.20)

trong đó Y là các trạng thái của không gian đích của biến ngẫu nhiên Y . Điều này có nghĩa là chúng ta tính tổng (hoặc tích phân) tập hợp các trạng thái y của quá trình ngẫu nhiên biến Y . Quy tắc tổng còn được gọi là tính chất biên.

Quy tắc tổng liên hệ phân phối chung với phân phối biên. Trong Nói chung, khi phân phối chung chứa nhiều hơn hai biến ngẫu nhiên, quy tắc cộng có thể được áp dụng cho bất kỳ tập con nào của các biến ngẫu nhiên đó. dẫn đến phân phối biên có thể có nhiều hơn một giá trị ngẫu nhiên biến. Cụ thể hơn, nếu $x = [x_1, \dots, x_D]$, ta thu được biến biên.

$$p(x_i) = \sum_{x_1, \dots, x_D} p(x_1, \dots, x_D)$$

(6.21)

bằng cách áp dụng lặp đi lặp lại quy tắc tổng, trong đó ta tích phân/cộng tất cả các giá trị lại với nhau. các biến ngẫu nhiên ngoại trừ x_i , điều này được biểu thị bằng $\setminus i$, có nghĩa là “tất cả ngoại trừ tối.”

Lưu ý. Nhiều thách thức về tính toán trong mô hình xác suất. là do việc áp dụng quy tắc cộng. Khi có nhiều biến số hoặc các biến rời rạc với nhiều trạng thái, quy tắc tổng quy về việc thực hiện phép cộng hoặc tích phân đa chiều. Thực hiện phép cộng đa chiều Tổng hoặc tích phân nói chung là khó tính toán, theo nghĩa là... Hiện chưa có thuật toán nào có độ phức tạp thời gian đa thức để tính toán chính xác chúng.

Quy tắc thứ hai, được gọi là quy tắc tích, liên quan đến phân phối chung. đến phân phối có điều kiện thông qua

$$p(x, y) = p(y | x)p(x).$$

(6.22)

Quy tắc tích có thể được hiểu là mọi phân phối chung của hai biến ngẫu nhiên đều có thể được phân tích thành tích (viết dưới dạng tích).

của hai phân phối khác. Hai yếu tố là phân phối biên của biến ngẫu nhiên đầu tiên $p(x)$ và phân phối có điều kiện của biến ngẫu nhiên thứ hai khi biết biến ngẫu nhiên đầu tiên $p(y \mid x)$. Vì thứ tự của các biến ngẫu nhiên là tùy ý trong $p(x, y)$, nên quy tắc tích cũng ngụ ý $p(x, y) = p(x \mid y)p(y)$. Nói chính xác hơn, (6.22) được biểu diễn theo các hàm khối lượng xác suất đối với các biến ngẫu nhiên rời rạc. Đối với các biến ngẫu nhiên liên tục, quy tắc tích được biểu diễn theo các hàm mật độ xác suất (Mục 6.2.3).

Trong học máy và thống kê Bayes, chúng ta thường quan tâm đến việc suy luận về các biến ngẫu nhiên chưa quan sát được (biến tiềm ẩn) khi đã quan sát được các biến ngẫu nhiên khác. Giả sử chúng ta có một số kiến thức tiên nghiệm $p(x)$ về một biến ngẫu nhiên chưa quan sát được x và một số mối quan hệ $p(y \mid x)$ giữa x và một biến ngẫu nhiên thứ hai y mà chúng ta có thể quan sát được. Nếu chúng ta quan sát được y , chúng ta có thể sử dụng định lý Bayes để rút ra một số kết luận về x dựa trên các giá trị quan sát được của y . Định lý Bayes (còn gọi là định lý Bayes, quy tắc Bayes hoặc định luật Bayes)

Quy tắc Bayes

Định luật Bayes

xác suất

trước

·

·

$$\underbrace{p(x \mid y)}_{\text{sau}} = \frac{\underbrace{p(y \mid x)}_{\text{chứng cứ}} \underbrace{p(x)}_{\text{·}}}{\underbrace{p(y)}_{\text{·}}}$$

(6.23)

là hệ quả trực tiếp của quy tắc sản phẩm trong (6.22) vì

$$p(x, y) = p(x \mid y)p(y)$$

(6.24)

Và

$$p(x, y) = p(y \mid x)p(x)$$

(6.25)

để có thể

$$p(x \mid y)p(y) = p(y \mid x)p(x) \qquad p(x \mid y) = \frac{p(y \mid x)p(x)}{p(y)} \cdot$$

(6.26)

Trong (6.23), $p(x)$ là phân phối tiên nghiệm, bao hàm phân phối tiên nghiệm chủ quan của chúng ta . Kiến thức về biến tiềm ẩn (không quan sát được) x trước khi quan sát bất kỳ dữ liệu nào. Chúng ta có thể chọn bất kỳ phân bố tiên nghiệm nào mà chúng ta thấy hợp lý, nhưng điều quan trọng là phải đảm bảo rằng phân bố tiên nghiệm đó có hàm mật độ xác suất (pdf hoặc pmf) khác 0 đối với tất cả các giá trị x khả thi, ngay cả khi chúng rất hiếm.

Xác suất $p(y \mid x)$ mô tả mối quan hệ giữa x và y , và trong xác suất Trong trường hợp phân phối xác suất rời rạc, đó là xác suất của dữ liệu y nếu ta biết biến ẩn x . Lưu ý rằng xác suất không phải là một phân phối theo x , mà chỉ theo y . Chúng ta gọi $p(y \mid x)$ là “xác suất của x (khi biết y)” hoặc “xác suất của y khi biết x ” nhưng không bao giờ gọi là xác suất của y (MacKay, 2003).

Xác suất đôi khi cũng

được gọi là

“phép đo”

người mẫu”.

Xác suất hậu nghiệm $p(x \mid y)$ là đại lượng quan tâm trong thống kê Bayes . Bởi vì nó thể hiện chính xác những gì chúng ta quan tâm, tức là những gì chúng ta biết về x sau khi đã quan sát y .

Số lượng

$$p(y) := p(y \mid x)p(x)dx = EX[p(y \mid x)]$$

(6.27)

xác suất cận biên
chứng cứ

là xác suất/bằng chứng cận biên . Về phải của (6.27) sử dụng
Toán tử kỳ vọng mà chúng ta định nghĩa trong Mục 6.4.1. Theo định nghĩa,
Xác suất biên tích hợp tử số của (6.23) đối với
biến ẩn x . Do đó, xác suất biên không phụ thuộc vào
 x , và điều này đảm bảo rằng xác suất hậu nghiệm $p(x \mid y)$ được chuẩn hóa. Xác suất biên
Xác suất cũng có thể được hiểu là xác suất kỳ vọng, trong đó chúng ta
lấy kỳ vọng liên quan đến $p(x)$ trước đó. Ngoài chuẩn hóa
Trong phân bố hậu nghiệm, xác suất biên cũng đóng một vai trò quan trọng.
Lựa chọn mô hình Bayes, như chúng ta sẽ thảo luận trong Phần 8.6. Do...

Định lý Bayes còn
được gọi là
"xác suất
nghịch đảo."
nghịch đảo xác suất

tích hợp trong (8.44), bằng chứng thường khó tính toán.
Định lý Bayes (6.23) cho phép chúng ta đảo ngược mối quan hệ giữa x
và y được xác định bởi xác suất. Do đó, định lý Bayes đôi khi được sử dụng
được gọi là nghịch đảo xác suất. Chúng ta sẽ thảo luận thêm về định lý Bayes trong Phần
8.4.

Lưu ý. Trong thống kê Bayes, phân phối hậu nghiệm là đại lượng
có ích vì nó bao hàm tất cả thông tin có sẵn từ trước và
dữ liệu. Thay vì mang theo phân bố hậu nghiệm, có thể tập trung vào...
dựa trên một số thống kê của phân bố hậu nghiệm, chẳng hạn như giá trị cực đại của phân bố hậu nghiệm,
mà chúng ta sẽ thảo luận trong Phần 8.3. Tuy nhiên, tập trung vào một số thống kê
Việc sử dụng phân bố hậu nghiệm dẫn đến mất thông tin. Nếu ta suy nghĩ trong bối cảnh
rộng hơn, thì phân bố hậu nghiệm có thể được sử dụng trong một hệ thống ra quyết định, và
Việc có được toàn bộ dữ liệu phía sau có thể cực kỳ hữu ích và dẫn đến những quyết định mà
có khả năng chống chịu tốt với các nhiễu loạn. Ví dụ, trong bối cảnh học tăng cường
dựa trên mô hình, Deisenroth et al. (2015) chỉ ra rằng việc sử dụng đầy đủ
Phân bố hậu nghiệm của các hàm chuyển đổi khả thi dẫn đến rất nhanh
(học tập hiệu quả về dữ liệu/mẫu), đồng thời tập trung vào mức tối đa của
Phân bố hậu nghiệm dẫn đến những lỗi liên tục. Do đó, việc có đầy đủ phân bố hậu
nghiệm có thể rất hữu ích cho một nhiệm vụ tiếp theo. Trong Chương 9, chúng ta sẽ...
Hãy tiếp tục thảo luận này trong bối cảnh hồi quy tuyến tính.

6.4 Thống kê tóm tắt và tính độc lập

Chúng ta thường quan tâm đến việc tóm tắt các tập hợp biến ngẫu nhiên và so sánh các
cặp biến ngẫu nhiên. Thống kê của một biến ngẫu nhiên là một hàm xác định của biến
ngẫu nhiên đó. Các thống kê tóm tắt của một
Phân phối cung cấp một cái nhìn hữu ích về cách một biến ngẫu nhiên hoạt động.
Và như tên gọi cho thấy, nó cung cấp các con số tóm tắt và mô tả đặc điểm của phân
bố. Chúng ta sẽ mô tả giá trị trung bình và phương sai, hai thống kê tóm tắt nổi
tiếng. Sau đó, chúng ta sẽ thảo luận về hai cách để so sánh một cặp.
Về các biến ngẫu nhiên: thứ nhất, làm thế nào để nói rằng hai biến ngẫu nhiên là độc
lập; và thứ hai, làm thế nào để tính tích vô hướng giữa chúng.

6.4.1 Trung bình và hiệp phương sai

Giá trị trung bình và (hiệp) phương sai thường hữu ích để mô tả các thuộc tính của phân phối xác suất (giá trị kỳ vọng và độ phân tán). Chúng ta sẽ thấy trong Phần 6.6 rằng có một họ phân phối hữu ích (được gọi là họ hàm mũ), trong đó thống kê của biến ngẫu nhiên nằm bất được tất cả thông tin có thể có.

Khái niệm giá trị kỳ vọng là trọng tâm của học máy, và các khái niệm nền tảng về xác suất có thể được suy ra từ giá trị kỳ vọng (Whittle, 2000).

Định nghĩa 6.3 (Giá trị kỳ vọng). Giá trị kỳ vọng của một hàm $g : \mathcal{R} \rightarrow \mathcal{R}$ giá trị kỳ vọng $\mathcal{R}$ của một biến ngẫu nhiên liên tục đơn biến X $p(x)$ được cho bởi

$$EX[g(x)] = \int_{\mathcal{X}} g(x)p(x)dx .$$

(6.28)

Tương ứng, giá trị kỳ vọng của hàm g của biến ngẫu nhiên rời rạc X $p(x)$ được cho bởi

$$EX[g(x)] = \sum_{x \in \mathcal{X}} g(x)p(x),$$

(6.29)

trong đó $\mathcal{X}$ là tập hợp các kết quả có thể xảy ra (không gian mục tiêu) của biến ngẫu nhiên X .

Trong phần này, chúng ta xem xét các biến ngẫu nhiên rời rạc có kết quả là các số. Điều này có thể thấy rõ bằng cách quan sát thấy hàm g nhận đầu vào là các số thực.

Lưu ý. Chúng ta xem các biến ngẫu nhiên đa chiều X như một vectơ hữu hạn các biến ngẫu nhiên đơn chiều $[X_1, \dots, X_D]$. Đối với các biến ngẫu nhiên đa chiều, chúng ta định nghĩa giá trị kỳ vọng theo từng phần tử.

$$EX[g(x)] = \begin{bmatrix} EX_1[g(x_1)] \\ \vdots \\ EX_D[g(x_D)] \end{bmatrix} \in \mathcal{R}^D ,$$

(6.30)

trong đó chỉ số dưới EX_d cho biết chúng ta đang lấy giá trị kỳ vọng đối với phần tử thứ d của vectơ x .

Định nghĩa 6.3 xác định ý nghĩa của ký hiệu EX là toán tử chỉ ra rằng chúng ta nên lấy tích phân đối với mật độ xác suất (đối với phân bố liên tục) hoặc tổng trên tất cả các trạng thái (đối với phân bố rời rạc). Định nghĩa về giá trị trung bình (Định nghĩa 6.4) là trường hợp đặc biệt của giá trị kỳ vọng, thu được bằng cách chọn g là hàm đồng nhất.

Định nghĩa 6.4 (Trung bình). Trung bình của một biến ngẫu nhiên X với trạng thái trung bình là...

Giá trị kỳ vọng của một hàm số của a
Biến ngẫu nhiên đôi khi được gọi là như là quy luật của tiềm thức
nhà thống kê (Casella và Berger, 2002, Phần 2.2).

$x_1, \dots, x_D$ là giá trị trung bình và được định nghĩa là

$$EX[x] = \begin{pmatrix} EX[x_1] \\ \vdots \\ EX[x_D] \end{pmatrix} \quad D \times R, \tag{6.31}$$

Ở đâu

$$EX_d[x_d] := \int_{-\infty}^{\infty} x_d p(x_d) dx_d \quad \text{nếu } X \text{ là một biến ngẫu nhiên liên tục}$$
$$EX_d[x_d] := \sum_{x_i \in X} x_i p(x_d = x_i) \quad \text{nếu } X \text{ là một biến ngẫu nhiên rời rạc}$$

(6.32)

với $d = 1, \dots, D$, trong đó chỉ số dưới d biểu thị chiều tương ứng của x . Tích phân và tổng được thực hiện trên các trạng thái X của không gian đích của biến ngẫu nhiên X .

Trong một chiều, có hai khái niệm trực quan khác về “trung bình”, đó là trung vị và mode. Trung vị là giá trị “ở giữa” nếu

Chúng ta sắp xếp các giá trị, tức là 50% giá trị lớn hơn giá trị trung vị và 50% giá trị nhỏ hơn giá trị trung vị. Ý tưởng này có thể được khái quát hóa cho các giá trị liên tục bằng cách xem xét giá trị mà tại đó hàm phân phối tích lũy (cdf) (Định nghĩa 6.2) bằng 0,5. Đối với các phân phối không đối xứng hoặc có đuôi dài, trung vị cung cấp ước tính về giá trị điển hình gần với trực giác của con người hơn so với giá trị trung bình. Hơn nữa, trung vị ít bị ảnh hưởng bởi các giá trị ngoại lai hơn so với giá trị trung bình. Việc khái quát hóa trung vị lên các chiều cao hơn không hề đơn giản vì không có cách nào rõ ràng để “sắp xếp” trong nhiều hơn một chiều (Hallin et al., 2010; Kong và Mizera, 2012). Giá trị xuất hiện nhiều nhất (mode) là giá trị xuất hiện thường xuyên nhất. Đối với biến ngẫu nhiên rời rạc, mode được định nghĩa là giá trị của x có tần suất xuất hiện cao nhất. Đối với biến ngẫu nhiên liên tục, mode được định nghĩa là đỉnh trong hàm mật độ $p(x)$. Một hàm mật độ $p(x)$ cụ thể có thể có nhiều hơn một mode, và hơn nữa, có thể có rất nhiều mode trong các phân phối đa chiều. Do đó, việc tìm tất cả các mode của một phân phối có thể là một thách thức về mặt tính toán.


Ví dụ 6.4
Xét phân bố hai chiều được minh họa trong Hình 6.4:

$$p(x) = 0,4 N(x_1, 10, x_2, 0,1) + 0,6 N(x_1, 8,4, x_2, 2,0) \tag{6.33}$$

Chúng ta sẽ định nghĩa phân phối Gaussian $N(\mu, \sigma^2)$ trong Phần 6.5. Phân phối biên tương ứng của nó trong mỗi chiều cũng được hiển thị. Quan sát thấy rằng phân phối này có hai đỉnh (bimodal), nhưng một trong hai đỉnh đó...

Phân phối biên là đơn đỉnh (có một đỉnh). Phân phối đơn biến hai đỉnh ngang minh họa rằng giá trị trung bình và trung vị có thể khác nhau. Mặc dù việc định nghĩa trung vị hai chiều là sự kết hợp của các trung vị trong mỗi chiều có vẻ hấp dẫn, nhưng thực tế là chúng ta không thể định nghĩa thứ tự của các điểm hai chiều khiến điều đó trở nên khó khăn. Khi chúng ta nói "không thể định nghĩa thứ tự", chúng ta muốn nói rằng có nhiều hơn một cách để định nghĩa mối quan hệ $<$ sao cho

$$\begin{matrix} 3 & 2 \\ 0 & < & 3 \end{matrix}.$$



Hình 6.4 Minh họa của trung bình, mode và trung vị cho một Tập dữ liệu hai chiều, cũng như mật độ biên của nó.

Lưu ý. Giá trị kỳ vọng (Định nghĩa 6.3) là một toán tử tuyến tính. Ví dụ, cho một hàm giá trị thực $f(x) = ag(x)+bh(x)$ trong đó $a, b \in \mathbb{R}$ và $x \in \mathbb{R}^D$, ta thu được

$$EX[f(x)] = \int f(x)p(x)dx \tag{6.34a}$$

$$= \int [ag(x) + bh(x)]p(x)dx \tag{6.34b}$$

$$= \int ag(x)p(x)dx + \int bh(x)p(x)dx \tag{6.34c}$$

$$= aEX[g(x)] + bEX[h(x)] . \tag{6.34d}$$

Đối với hai biến ngẫu nhiên, chúng ta có thể muốn mô tả sự tương ứng của chúng.

sự tin tưởng lẫn nhau. Hiệp phương sai thể hiện một cách trực quan khái niệm về Mức độ phụ thuộc lẫn nhau của các biến ngẫu nhiên.

hiệp phương sai

Định nghĩa 6.5 (Hiệp phương sai (Đơn biến)). Hiệp phương sai giữa hai Các biến ngẫu nhiên đơn biến $X, Y \in \mathbb{R}$ được cho bởi tích kỳ vọng. về độ lệch của chúng so với giá trị trung bình tương ứng, tức là,

$$\text{Cov}X, Y [x, y] := E(X, Y (x - EX[x])(y - EY [y])) . \tag{6.35}$$

Thuật ngữ: Cái hiệp phương sai của ngẫu nhiên đa biến biến $\text{Cov}[x, y]$ đôi khi được gọi là hiệp phương sai chéo, với hiệp phương sai đề cập đến $\text{Cov}[x, x]$.

Lưu ý. Khi biến ngẫu nhiên liên quan đến kỳ vọng hoặc

Tính hiệp phương sai được thể hiện rõ qua các lập luận của nó, chỉ số phụ thường bị lược bỏ (ví dụ: Ví dụ, $EX[x]$ thường được viết là $E[x]$).

Bằng cách sử dụng tính tuyến tính của kỳ vọng, biểu thức trong Định nghĩa 6.5 có thể được viết lại thành giá trị kỳ vọng của tích trừ đi tích của các giá trị kỳ vọng, tức là,

$$\text{Cov}[x, y] = E[xy] - E[x]E[y] . \tag{6.36}$$

phương sai độ lệch chuẩn

Hiệp phương sai của một biến với chính nó $\text{Cov}[x, x]$ được gọi là phương sai và được ký hiệu là $VX[x]$. Căn bậc hai của phương sai được gọi là độ lệch chuẩn. độ lệch và thường được ký hiệu là $\sigma(x)$. Khái niệm hiệp phương sai có thể là được khái quát hóa cho các biến ngẫu nhiên đa chiều.

Định nghĩa 6.6 (Hiệp phương sai (Đa biến)). Nếu ta xét hai biến ngẫu nhiên đa biến X và Y với các trạng thái $x \in \mathbb{R}^D$ và $y \in \mathbb{R}^E$ tương ứng, thì hiệp phương sai giữa X và Y được định nghĩa như sau:

hiệp phương sai

$$\text{Cov}[x, y] = E[xy^T] - E[x]E[y]^T = \text{Cov}[y, x]^T \in \mathbb{R}^{D \times E} . \tag{6.37}$$

Định nghĩa 6.6 có thể được áp dụng với cùng một biến ngẫu nhiên đa chiều trong cả hai đối số, dẫn đến một khái niệm hữu ích mà về mặt trực quan có thể hiểu được. Nó thể hiện "sự phân tán" của một biến ngẫu nhiên. Đối với biến ngẫu nhiên đa biến, Trong biến số, phương sai mô tả mối quan hệ giữa các chiều riêng lẻ của biến ngẫu nhiên.

phương sai

Định nghĩa 6.7 (Phương sai). Phương sai của một biến ngẫu nhiên X với các trạng thái $x \in \mathbb{R}^D$ và vectơ trung bình $\mu \in \mathbb{R}^D$ được định nghĩa như sau:

$$VX[x] = \text{Cov}X[x, x] \tag{6.38a}$$

$$= E[(x - \mu)(x - \mu)^T] = EX[xx^T] - EX[x]EX[x]^T \tag{6.38b}$$

$$\begin{aligned} & \begin{bmatrix} \text{Cov}[x_1, x_1] & \text{Cov}[x_1, x_2] & \dots & \text{Cov}[x_1, x_D] \\ \text{Cov}[x_2, x_1] & \text{Cov}[x_2, x_2] & \dots & \text{Cov}[x_2, x_D] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[x_D, x_1] & \dots & \dots & \text{Cov}[x_D, x_D] \end{bmatrix} . \end{aligned} \tag{6.38c}$$


ma trận hiệp phương sai

Ma trận $D \times D$ trong (6.38c) được gọi là ma trận hiệp phương sai của biến ngẫu nhiên đa biến X . Ma trận hiệp phương sai là ma trận đối xứng và bán xác định dương, cho chúng ta biết điều gì đó về sự phân tán của dữ liệu. Trên Đường chéo của nó, ma trận hiệp phương sai, chứa các phương sai của các biến biên.


cận biên

6.4 Thống kê tóm tắt và tính độc lập

191



(a) x và y có tương quan nghịch.



(b) x và y có tương quan thuận.

Hình 6.5
Hai chiều
tập dữ liệu với
có nghĩa là giống hệt nhau và
sự khác biệt dọc theo
mỗi trục (màu)
đồng) nhưng với
khác biệt
hiệp phương sai.

$$p(x_i) = p(x_1, \dots, x_D) dx_i, \quad (6.39)$$

trong đó “ i ” biểu thị “tất cả các biến trừ i ”. Các phần tử ngoài đường chéo chính là các số hạng hiệp phương sai chéo $\text{Cov}[x_i, x_j]$ cho $i, j = 1, \dots, D, i \neq j$.

hiệp phương sai chéo

Lưu ý. Trong cuốn sách này, chúng ta thường giả định rằng ma trận hiệp phương sai là xác định dương để giúp trực quan tốt hơn. Do đó, chúng tôi không thảo luận các trường hợp đặc biệt dẫn đến ma trận hiệp phương sai bán xác định dương (hạng thấp).

Khi chúng ta muốn so sánh hiệp phương sai giữa các cặp khác nhau của các biến ngẫu nhiên, hóa ra phương sai của mỗi biến ngẫu nhiên ảnh hưởng đến giá trị của hiệp phương sai. Phiên bản chuẩn hóa của hiệp phương sai được gọi là hệ số tương quan.

Định nghĩa 6.8 (Tương quan). Tương quan giữa hai biến ngẫu nhiên .

Bảng X, Y được cho bởi

$$\text{corr}[x, y] = \frac{\text{Cov}[x, y]}{\sqrt{V[x]V[y]}} \quad [1, 1]. \quad (6.40)$$

Ma trận tương quan là ma trận hiệp phương sai của các biến ngẫu nhiên được chuẩn hóa các biến ngẫu nhiên, $x/\sigma(x)$. Nói cách khác, mỗi biến ngẫu nhiên được chia cho nó độ lệch chuẩn (căn bậc hai của phương sai) trong hệ số tương quan ma trận.

Hiệp phương sai (và hệ số tương quan) cho biết hai biến ngẫu nhiên như thế nào. có liên quan; xem Hình 6.5. Hệ số tương quan dương $\text{corr}[x, y]$ có nghĩa là khi x tăng, thì y cũng được dự đoán sẽ tăng. Hệ số tương quan nghịch có nghĩa là khi x tăng thì y giảm.

6.4.2 Trung bình thực nghiệm và hiệp phương sai

Các định nghĩa trong Mục 6.4.1 thường cũng được gọi là trung bình dân số .

và hiệp phương sai vì nó đề cập đến số liệu thống kê thực sự của quần thể. Trong học máy, chúng ta cần học hỏi từ các quan sát thực nghiệm về dữ liệu. Hãy xem xét một biến ngẫu nhiên X . Có hai bước khái niệm để đi từ

và hiệp phương sai

Từ số liệu thống kê dân số đến việc hiện thực hóa số liệu thống kê thực nghiệm. Đầu tiên, chúng ta sử dụng thực tế là chúng ta có một tập dữ liệu hữu hạn (kích thước N) để xây dựng một mô hình thực nghiệm. Thống kê là một hàm số của một số hữu hạn các biến ngẫu nhiên giống hệt nhau.

$X_1, \dots, X_N$. Thứ hai, chúng ta quan sát dữ liệu, tức là, chúng ta xem xét giá trị $x_1, \dots, x_N$, thực tế của X_N của mỗi biến ngẫu nhiên và áp dụng phương pháp thực nghiệm thống kê.

Cụ thể, đối với giá trị trung bình (Định nghĩa 6.4), khi cho một tập dữ liệu cụ thể, chúng ta có thể thu được ước tính về giá trị trung bình, được gọi là giá trị trung bình thực nghiệm hoặc trung bình mẫu. Điều tương tự cũng đúng với hiệp phương sai thực nghiệm.

Định nghĩa 6.9 (Trung bình thực nghiệm và Hiệp phương sai). Vectơ trung bình thực nghiệm là trung bình cộng của các quan sát cho mỗi biến, và nó được định nghĩa là

$$\bar{x} := \frac{1}{N} \sum_{n=1}^N x_n,$$

(6.41)

trong đó $x_n \in \mathbb{R}^D$.

Tương tự như giá trị trung bình thực nghiệm, ma trận hiệp phương sai thực nghiệm là ma trận $D \times D$. ma trận

$$\Sigma := \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(x_n - \bar{x})^T.$$

(6.42)

Để tính toán số liệu thống kê cho một tập dữ liệu cụ thể, chúng ta sẽ sử dụng...

các thực hiện (quan sát) $x_1, \dots, x_N$ và sử dụng (6.41) và (6.42). Ma trận hiệp phương sai thực nghiệm là đối xứng, bán xác định dương (xem Phần 3.2.3).

6.4.3 Ba cách biểu diễn phương sai

Bây giờ chúng ta tập trung vào một biến ngẫu nhiên duy nhất X và sử dụng các công thức thực nghiệm đã nêu ở trên để suy ra ba biểu thức khả thi cho phương sai.

Quá trình suy luận sau đây cũng tương tự đối với phương sai dân số, ngoại trừ việc

Chúng ta cần chú ý đến các tích phân. Định nghĩa chuẩn của phương sai, tương ứng với định nghĩa của hiệp phương sai (Định nghĩa 6.5), là kỳ vọng của bình phương độ lệch của một biến ngẫu nhiên X so với kỳ vọng của nó.

giá trị μ , tức là,

$$\text{Var}[X] := \mathbb{E}[(X - \mu)^2].$$

(6.43)

Kỳ vọng trong (6.43) và giá trị trung bình $\mu = \mathbb{E}(X)$ được tính bằng cách sử dụng (6.32), tùy thuộc vào việc X là biến ngẫu nhiên rời rạc hay liên tục.

biến. Phương sai được thể hiện trong (6.43) là giá trị trung bình của một biến ngẫu nhiên mới. biến $Z := (X - \mu)^2$.

Khi ước tính phương sai trong (6.43) theo kinh nghiệm, chúng ta cần phải sử dụng đối với thuật toán hai bước: một bước xử lý dữ liệu để tính giá trị trung bình.

μ sử dụng (6.41), và sau đó thực hiện lượt thứ hai sử dụng ước tính này $\hat{\mu}$ để tính toán

trung bình thực
nghiệm trung bình mẫu

trung bình thực nghiệm

Định nghĩa 6.9 (Trung bình thực nghiệm và Hiệp phương sai). Vectơ trung bình thực nghiệm là trung bình cộng của các quan sát cho mỗi biến, và nó được định nghĩa là

hiệp phương sai thực nghiệm

Trong suốt
cuốn sách, chúng tôi sử dụng
thực nghiệm
hiệp phương sai, tức là
một ước tính thiên lệch.
Người không thiên vị
(đôi khi được gọi là)
(đã sửa)
hiệp phương sai có
hệ số $N - 1$ trong
mẫu số
thay vì N .
Các phép tính đạo hàm là
bài tập ở cuối
của chương này.

phương sai. Hóa ra chúng ta có thể tránh hai lần tính toán bằng cách sắp xếp lại các thuật ngữ. Công thức trong (6.43) có thể được chuyển đổi thành công thức điểm thô được gọi là công thức điểm thô cho phương sai:

$$VX[x] = EX[x^2] - (EX[x])^2. \tag{6.44}$$

Biểu thức trong (6.44) có thể được nhớ là “trung bình của bình phương trừ đi bình phương của trung bình”. Nó có thể được tính toán theo kinh nghiệm trong một lần thực hiện Thông qua dữ liệu, vì chúng ta có thể tích lũy xi (để tính trung bình) và x đồng thời, trong đó xi là quan sát thứ i. Thật không may, nếu triển khai theo cách này, nó có thể không ổn định về mặt số học. Phiên bản điểm thô của phương sai có thể hữu ích trong học máy, ví dụ, khi suy ra sự phân tích độ lệch-phương sai (Bishop, 2006).

Một cách thứ ba để hiểu về phương sai là nó là tổng của các chênh lệch từng cặp. Sự khác biệt giữa tất cả các cặp quan sát. Xét một mẫu x1, . . . , gồm các giá trị thực xN hiện của biến ngẫu nhiên X, và ta tính bình phương hiệu số giữa các cặp xi và xj . Bằng cách khai triển bình phương, ta có thể chứng minh rằng tổng của N2 hiệu số từng cặp chính là phương sai thực nghiệm của các quan sát:

$$\frac{1}{N^2} \sum_{i,j=1}^N (x_i - x_j)^2 = 2 \left[\frac{1}{N} \sum_{i=1}^N x_i^2 - \left(\frac{1}{N} \sum_{i=1}^N x_i \right)^2 \right]. \tag{6.45}$$

Chúng ta thấy rằng (6.45) gấp đôi biểu thức điểm thô (6.44). Điều này có nghĩa là chúng ta có thể biểu diễn tổng các khoảng cách từng cặp (trong đó có N2 khoảng cách) dưới dạng tổng các độ lệch so với giá trị trung bình (trong đó có N độ lệch). Về mặt hình học, điều này có nghĩa là có sự tương đương giữa các khoảng cách từng cặp và khoảng cách từ tâm của tập hợp các điểm. Từ quan điểm tính toán, điều này có nghĩa là bằng cách tính giá trị trung bình (N số hạng trong phép tính tổng), và sau đó tính phương sai (lại là N số hạng trong phép tính tổng), chúng ta có thể thu được một biểu thức (về trái của (6.45)) có N2 số hạng.

6.4.4 Tổng và Biến đổi của Biến ngẫu nhiên Chúng ta có thể

muốn mô hình hóa một hiện tượng không thể giải thích tốt bằng các phân phối trong sách giáo khoa (chúng ta sẽ giới thiệu một số trong Phần 6.5 và 6.6), và do đó có thể thực hiện các thao tác đơn giản với các biến ngẫu nhiên (chẳng hạn như cộng hai biến ngẫu nhiên).

Xét hai biến ngẫu nhiên X, Y với các trạng thái x, y ∈ RD. Khi đó:

$$E[x + y] = E[x] + E[y] \tag{6.46}$$

$$E[xy] = E[x]E[y] \tag{6.47}$$

$$V[x + y] = V[x] + V[y] + Cov[x, y] + Cov[y, x] \tag{6.48}$$

$$V[xy] = V[x]V[y] + Cov[x, y]^2 + Cov[y, x]^2. \tag{6.49}$$

trong (6.44) rất lớn và xấp xỉ bằng nhau, chúng ta có thể gặp phải Mất mát độ chính xác số học không cần thiết trong phép toán số thực dấu phẩy động.

Giá trị trung bình và (hiệp) phương sai thể hiện một số tính chất hữu ích khi nói đến phép biến đổi affine của các biến ngẫu nhiên. Hãy xem xét một biến ngẫu nhiên X có giá trị trung bình μ và ma trận hiệp phương sai Σ , cùng với phép biến đổi affine (xác định) $y = Ax + b$ của x . Khi đó, y bản thân nó là một biến ngẫu nhiên có vectơ trung bình và ma trận hiệp phương sai được cho bởi

$$EY[y] = EX[Ax + b] = AEX[x] + b = A\mu + b$$

,

$$(6.50)$$

$$VY[y] = VX[Ax + b] = VX[AX] = AVX[x]A = A\Sigma A$$

,

$$(6.51)$$

tương ứng. Hơn nữa, $Cov[x,$

$$y] = E[x(Ax + b)] - E[x]E[Ax + b] = \mu b$$

$$(6.52a)$$

$$= E[x]b + E[xx^T]A - \mu\mu^T A$$

$$(6.52b)$$

$$= \mu b - \mu\mu^T A + E[xx^T] - \mu\mu^T = A\Sigma A$$

$$(6.52c)$$

$$(6.38b) = \Sigma A$$

,

$$(6.52d)$$

trong đó $\Sigma = E[xx^T] - \mu\mu^T$ là hiệp phương sai của X .

6.4.5 Tính độc lập thống kê

Định nghĩa 6.10 (Độc lập). Hai biến ngẫu nhiên X, Y được gọi là độc lập về mặt thống kê nếu và chỉ nếu

$$p(x, y) = p(x)p(y).$$

$$(6.53)$$

Theo trực giác, hai biến ngẫu nhiên X và Y được gọi là độc lập nếu giá trị của y (sau khi đã biết) không cung cấp thêm thông tin nào về x (và ngược lại). Nếu X, Y độc lập (về mặt thống kê), thì

- $p(y | x) = p(y)$
- $p(x | y) = p(x)$
- $VX,Y[x + y] = VX[x] + VY[y]$
- $CovX,Y[x, y] = 0$

Điểm cuối cùng có thể không đúng theo chiều ngược lại, tức là hai biến ngẫu nhiên có thể có hiệp phương sai bằng 0 nhưng không độc lập về mặt thống kê. Để hiểu tại sao, hãy nhớ rằng hiệp phương sai chỉ đo lường sự phụ thuộc tuyến tính. Do đó, các biến ngẫu nhiên không phụ thuộc tuyến tính vẫn có thể có hiệp phương sai bằng 0.
số không.

Ví dụ 6.5 Xét

một biến ngẫu nhiên X có giá trị trung bình bằng 0 ($EX[x] = 0$) và cũng $EX[x^3] = 0$ (do đó, Y phụ thuộc vào X) và xét hiệp phương sai (6.36) giữa X và Y . Nhưng điều này cho

$$Cov[x, y] = E[xy] - E[x]E[y] = E[x^3] = 0.$$

$$(6.54)$$