
TRÍ TUỆ NHÂN TẠO

Hồi quy tuyến tính

Lý thuyết — Mất mát, tham số, gradient descent, siêu tham số

Biên soạn:

ĐẶNG TẤN QUÍ

SĐT: 0377 122 210

2026

Mục lục

Lời nói đầu	3
1 Hồi quy tuyến tính (linear regression)	4
1.1 Phương trình hồi quy tuyến tính	5
1.2 Mô hình nhiều đặc trưng	6
2 Mất mát (loss)	8
3 Bài tập về tham số	12
4 Phương pháp giảm độ dốc (gradient descent)	13
4.1 MSE và bước tính cụ thể	14
4.2 Đường cong mất mát và hội tụ	15
4.3 Hàm lỗi và cực tiểu toàn cục	16
5 Siêu tham số (hyperparameters)	19
5.1 Tốc độ học (learning rate)	19
5.2 Batch size	22
5.3 Epoch	23
6 Bài tập về phương pháp giảm độ dốc	25

Lời nói đầu

Nguồn và cách đọc

Tài liệu biên soạn và dịch từ *Linear Regression* (Google ML Crash Course)^a.

^a<https://developers.google.com/machine-learning/crash-course/linear-regression>

Điều kiện tiên quyết

Cần nắm khái niệm từ [Introduction to Machine Learning](#): mẫu, đặc trưng, nhãn, huấn luyện, mất mát, hồi quy có giám sát.

Mục tiêu học tập

- Giải thích hàm mất mát và cách dùng trong huấn luyện.
- Mô tả gradient descent tìm tham số tối ưu (trọng số, bias).
- Điều chỉnh siêu tham số (learning rate, batch size, epoch) để huấn luyện hiệu quả.

1 Hồi quy tuyến tính (linear regression)

Dự đoán mức tiêu thụ nhiên liệu


Cho biết **trọng lượng xe** (nghìn pound), ta muốn dự đoán **dặm/gallon** (MPG). Quan hệ gần **tuyến tính**: xe nặng hơn $\Rightarrow$ MPG thường thấp hơn. Hồi quy tuyến tính tìm đường thẳng (hoặc siêu phẳng) “khớp” dữ liệu nhất.

Hồi quy tuyến tính

Hồi quy tuyến tính tìm quan hệ giữa **đặc trưng** và **nhãn**. Trong ML, đó là mô hình dự đoán nhãn số từ đặc trưng bằng tổ hợp **tuyến tính** của các đặc trưng.


Dữ liệu mẫu — Trọng lượng vs MPG

Trọng lượng (nghìn pound)	MPG (nhãn)
3.5	18
3.69	15
3.44	18
3.43	16
4.34	15
4.42	14
2.37	24



Hình 1. Trọng lượng vs MPG — xu hướng giảm.

Khi ô tô càng nặng, chỉ số quãng đường đi được trên một gallon nhiên liệu thường giảm.



Hình 2. Đường khớp tốt nhất (best fit).

1.1 Phương trình hồi quy tuyến tính


Dạng đại số và dạng ML (một đặc trưng)

Đại số: $y = mx + b$ với $y = \text{MPG}$, $x = \text{trọng lượng}$, $m = \text{độ dốc}$, $b = \text{giao Oy}$.

ML (một đặc trưng):

$$y' = b + w_1 x_1$$

- y' : nhãn **dự đoán**.
- b : **bias** (tương đương w_0 , giao Oy - tung độ gốc) — tham số học được.
- w_1 : **trọng số** (tương đương độ dốc - hệ số góc m) — tham số học được.
- x_1 : đặc trưng đầu vào (không đổi trong tập dữ liệu).


**Hình 3.** Các thành phần phương trình.

Đọc tham số từ đường khớp

Từ đồ thị: $b \approx 34$, $w_1 \approx -4,6$.

$$y' = 34 + (-4,6) x_1$$

Xe 4,000 pound ($x_1 = 4$): Dự đoán MPG $\approx 15,6$.

Hình 4. Dự đoán tại $x_1 = 4$.

1.2 Mô hình nhiều đặc trưng

Nhiều đặc trưng


$$y' = b + w_1x_1 + w_2x_2 + \dots + w_nx_n$$

Ví dụ dự đoán MPG thêm: dung tích xi-lanh, gia tốc, số xi-lanh, mã lực.


$$y' = b + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + w_5x_5$$

Pounds
Displacement
Acceleration
Number of cylinders
Horsepower

Hình 5. Phương trình năm đặc trưng.



Hình 6. Dung tích xi-lanh vs MPG (quan hệ tuyến tính âm).



Hình 7. Gia tốc vs MPG (quan hệ tuyến tính dương).

Phần nào được cập nhật khi huấn luyện?

- **Cập nhật:** bias b và các trọng số w_i .
- **Không cập nhật:** y' (là kết quả tính), giá trị đặc trưng x_i (cố định trong dataset).


2 Mất mát (loss)

Làm sao biết đường thẳng “tốt”?

Hai đường khác nhau đều “nhìn ổn” trên đồ thị MPG — cần một **số** đo mức sai.

Mất mát

Mất mát (loss) đo khoảng cách giữa dự đoán y' và nhãn thật y ; mục tiêu huấn luyện là **giảm mất mát** tới mức thấp nhất có thể. Mất mát (loss) không quan tâm dự đoán **cao** hơn hay **thấp** hơn, chỉ quan tâm **xa bao nhiêu**.



Hình 8. Mũi tên loss: từ giá trị thực tới dự đoán.

Bỏ dấu khi tính loss

Dự đoán 2, thực tế 5: sai -3 nhưng ta chỉ cần **khoảng cách 3** chứ không cần hướng. Hai cách phổ biến:

- **Trị tuyệt đối** $|y - y'|$;
- **Bình phương** $(y - y')^2$.

Năm loại mất mát thường gặp

Loại	Ý nghĩa	Công thức
L_1 loss	Tổng $ y - y' $ trên các mẫu	$\sum y - y' $
Sai số trung bình tuyệt đối (MAE)	Trung bình L_1 trên N mẫu	$\frac{1}{N} \sum y - y' $
L_2 loss	Tổng $(y - y')^2$	$\sum (y - y')^2$
Sai số bình phương trung bình (MSE)	Trung bình L_2 trên N mẫu	$\frac{1}{N} \sum (y - y')^2$
Căn bậc hai của sai số bình phương trung bình (RMSE)	Căn bậc hai của MSE (cùng thang với y)	$\sqrt{\text{MSE}}$

 L_1 vs L_2 — ảnh hưởng của bình phương

- Sai số **lớn**: bình phương làm loss **càng lớn thêm**.
- Sai số **nhỏ** (< 1): bình phương làm loss **nhỏ hơn nữa**.
- MAE/RMSE thường **đễ diễn giải** hơn (cùng đơn vị với nhãn); RMSE nhạy hơn với lỗi lớn so với MAE.

Lưu ý

Khi xử lý nhiều mẫu, nên **lấy trung bình** (MAE, MSE, RMSE) thay vì chỉ cộng tổng L_1/L_2 thuần.

Ví dụ: Tính L_2 loss cho một điểm

Mô hình MPG: $y' = 34 + (-4,6) x_1$

Xe 2,370 pound ($x_1 = 2,37$ nghìn pound): dự đoán $y' \approx 23,1$ MPG, thực tế $y = 24$ MPG.

$$L_2 = (24 - 23,1)^2 = 0,81$$

Ngoại lệ (outlier) trong dữ liệu và trong dự đoán

Outlier dữ liệu: xe 8,000 pound hoặc 100 MPG — ngoài khoảng thường (2–5 nghìn pound, 8–50 MPG).

Outlier dự đoán: xe 3,000 pound, 40 MPG có thể hợp lý trong dữ liệu nhưng mô hình dự đoán ~ 20 MPG — lệch lớn so với thực tế.

Khi nào dùng MSE / RMSE? Khi nào dùng MAE?

Chọn MSE (hoặc RMSE) khi:

- Muốn **phạt nặng** sai số lớn.
- Coi outlier là phản ánh biến thiên thật mà mô hình nên học.

- Cần tối ưu “mượt” (tính chất toán của MSE thuận lợi cho gradient descent).


Chọn MAE khi:

- Dataset có outlier mà không muốn chúng **kéo** mô hình quá mạnh.
- Muốn loss = “sai số trung bình” dễ hiểu trực tiếp.

Thực tế còn phụ thuộc **bài toán kinh doanh**: loại sai lệch nào “đắt” hơn.



Hình 9. Huấn luyện với MSE — đường (đỏ) gần outlier hơn.




Hình 10. Huấn luyện với MAE — đường xa outlier, gần đám đông hơn.


So sánh trực quan

- **MSE:** mô hình gần outlier, xa phần lớn điểm còn lại.
- **MAE:** mô hình xa outlier, gần phần lớn điểm.

Kiểm tra hiểu biết — MSE trên hai đồ thị



Hình 11. Trái



Hình 12. Phải

Đồ thị bên phải có MSE cao hơn ($\approx 0,8$ vs $\approx 0,4$): nhiều điểm trên đường nhưng hai điểm lệch **gấp đôi** khoảng cách; bình phương làm loss tăng mạnh ($2^2 = 4$ lần so với lệch 1).

Phản ví dụ

$MSE = 0$ trên mọi điểm $\Rightarrow$ khớp hoàn hảo — thường là **overfitting**, không phải mục tiêu thực tế.

3 Bài tập về tham số


Nhiệm vụ (Parameters exercise)

1. Vẽ 20 mẫu: trục x = trọng lượng (nghìn pound), trục y = MPG.
2. Điều chỉnh Weight và Bias để tìm đường thẳng **minimize MSE**.
3. Ghi MSE thấp nhất và cặp (w, b) tương ứng.

Link bài tập: <https://developers.google.com/machine-learning/crash-course/linear-regression/parameters-exercise>

Đáp án

MSE tối thiểu $\approx 3,37$ với $w = -0,12$, $b = 16,96$.



Hình 13. Đường tối ưu cho bài tập tham số.

Ý nghĩa & Trực giác

Tham số (w, b) quyết định độ nghiêng và vị trí đường;
MSE đo tổng bình phương sai số — gradient descent tự làm việc này.

4 Phương pháp giảm độ dốc (gradient descent)

Không thể thử hết mọi (w, b)

Với hai tham số còn tìm được bằng mắt; với hàng chục đặc trưng thì không. **Gradient descent** (GD) lặp: tính mất mát $\rightarrow$ biết hướng giảm $\rightarrow$ bước nhỏ $\rightarrow$ lặp đến **hội tụ**.


Video: <https://www.youtube.com/watch?v=QoK1nNAURw4>

Gradient descent

Kỹ thuật lặp tìm w, b (và các tham số khác) sao cho **mất mát** (thường MSE) **nhỏ nhất**.

Vòng lặp gradient descent

1. Khởi tạo w, b gần 0 (ngẫu nhiên nhỏ).
2. Tính mất mát với w, b hiện tại.
3. Tính hướng (gradient) làm **giảm** mất mát.
4. Cập nhật w, b một bước nhỏ theo hướng đó.
5. Lặp đến khi không giảm thêm đáng kể (**hội tụ**).



Hình 14. Quy trình gradient descent.

4.1 MSE và bước tính cụ thể

MSE (Mean Squared Error)

Với M mẫu, dự đoán $f_{w,b}(x) = wx + b$, nhân thật y :

$$\text{MSE} = \frac{1}{M} \sum_{i=1}^M (f_{w,b}(x^{(i)}) - y^{(i)})^2$$

7 mẫu dữ liệu

Pao (tính bằng nghìn)	Số dặm trên mỗi ga lông (nhân)
3,5	18
3,69	15
3,44	18
3,43	16
4,34	15
4,42	14
2,37	24

Khởi tạo $w = 0$, $b = 0$ và tính MSE

$$1. \text{ MSE} = \frac{1}{7} \sum_{i=1}^7 (0 - y^{(i)})^2 \approx 303,71 \text{ (dự đoán 0 cho mọi mẫu).}$$

$$2. \text{ Đạo hàm theo } w: \text{ độ dốc tiếp tuyến } \frac{\partial}{\partial w} \text{MSE} \approx -119,7; \text{ theo } b: \frac{\partial}{\partial b} \text{MSE} \approx -34,3.$$

3. Bước nhỏ $\eta = 0,01$ (learning rate):

$$w_{\text{mới}} = w_{\text{cũ}} - \eta x \frac{\partial}{\partial w} \text{MSE} = 0 - 0,01 \times (-119,7) \approx 1,2, \quad b_{\text{mới}} = b_{\text{cũ}} - \eta x \frac{\partial}{\partial b} \text{MSE} = 0 - 0,01 \times (-34,3) \approx 0,343$$

Đạo hàm MSE

$$\frac{\partial}{\partial w} \text{MSE} = \frac{1}{M} \sum_{i=1}^M 2(f_{w,b}(x^{(i)}) - y^{(i)}) x^{(i)}$$

$$\frac{\partial}{\partial b} \text{MSE} = \frac{1}{M} \sum_{i=1}^M 2(f_{w,b}(x^{(i)}) - y^{(i)})$$

Gradient âm $\Rightarrow$ tăng w , b để giảm mất mát (với khởi tạo 0).

Bảng 1: MSE giảm qua các vòng lặp (ví dụ minh họa)

Vòng	Weight	Bias	MSE
1	0	0	303.71
2	1.20	0.34	170.84
3	2.05	0.59	103.17
4	2.66	0.78	68.70
5	3.09	0.91	51.13
6	3.40	1.01	42.17


Hội tụ và huấn luyện quá lâu

Khi **hội tụ**, thêm vòng lặp hầu như không giảm MSE; huấn luyện thêm có thể làm mất mát **dao động nhẹ** quanh cực tiểu. Cần theo dõi đến khi mất mát **ổn định**.


4.2 Đường cong mất mát và hội tụ

Loss curve


Đường cong mất mát: trục $y = \text{loss}$, trục $x = \text{số vòng lặp}$. Giảm mạnh đầu, sau đó phẳng dần $\Rightarrow$ mô hình đã hội tụ.




Hình 15. Hội tụ quanh vòng ~ 1000 .



Hình 16. Đầu huấn luyện — loss lớn.



Hình 17. Giữa quá trình — đường gần dữ liệu hơn.



Hình 18. Cuối — loss thấp, đường khớp tốt.


Kiểm tra hiểu biết

Vai trò GD: lập tìm w, b minimize loss. GD không chọn loại loss (L1/L2) và không xóa outlier khỏi dataset.


4.3 Hàm lỗi và cực tiểu toàn cục

Mô hình tuyến tính và hàm lỗi

Mất mát của hồi quy tuyến tính tạo mặt **lồi** (convex). Khi hội tụ, mô hình đã tìm (w, b) cho **mất mát thấp nhất** (cực tiểu toàn cục).



Hình 19. Mặt mất mát lỗi.




Hình 20. Cực tiểu: $w \approx -5,44$, $b \approx 35,94$, $MSE \approx 5,54$.

Quả bóng lăn xuống đồi

Các điểm (w, b) trong GD như quả bóng lăn xuống đáy thung lũng mất mát; thực tế thường đạt **gần** cực tiểu.

Linear regression models converge because the loss surface is convex and contains a point where the weight and bias have a slope that's almost zero.



Hình 21. Điểm GD trên mặt loss.



Hình 22. Mô hình với w, b tối ưu.

MSE = 0 không phải lúc nào cũng tốt

MSE = 0 nghĩa là khớp **mọi** điểm — thường là **overfitting**. Cực tiểu thực tế thường > 0 .

5 Siêu tham số (hyperparameters)

Ai điều khiển tốc độ học?

Tham số (w, b) do mô hình học.

Siêu tham số do người đặt trước: learning rate, batch size, số epoch — quyết định *cách* và *tốc độ* hội tụ.

Siêu tham số vs tham số

- **Siêu tham số** ([hyperparameter](#)): learning rate, batch size, epochs — bạn kiểm soát.
- **Tham số** ([parameter](#)): w, b — mô hình tính khi huấn luyện.

5.1 Tốc độ học (learning rate)

Tốc độ học

Tốc độ học xác định mức độ thay đổi cần thực hiện đối với các trọng số và độ lệch trong mỗi bước của quy trình hạ độ dốc, ảnh hưởng đến tốc độ hội tụ của mô hình. Nếu tốc độ học quá thấp, mô hình có thể mất nhiều thời gian để hội tụ. Tuy nhiên, nếu tốc độ học tập quá cao, mô hình sẽ không bao giờ hội tụ, mà thay vào đó sẽ dao động xung quanh các trọng số và độ lệch giúp giảm thiểu tổn thất. Mục tiêu là chọn tốc độ học tập không quá cao cũng không quá thấp để mô hình hội tụ nhanh chóng.

Hệ số η nhân với gradient để quyết định **độ lớn bước** cập nhật w, b mỗi vòng. Sự khác biệt giữa các tham số mô hình cũ và các tham số mô hình mới tỷ lệ thuận với độ dốc của hàm tổn thất. Ví dụ: nếu độ dốc lớn, mô hình sẽ thực hiện một bước lớn. Nếu nhỏ, hãy thực hiện một bước nhỏ.

Trong ví dụ GD trước, “bước nhỏ” 0,01 chính là learning rate.


Cập nhật với learning rate

$$w_{\text{mới}} = w_{\text{cũ}} - \eta \cdot \frac{\partial \text{MSE}}{\partial w}, \quad b_{\text{mới}} = b_{\text{cũ}} - \eta \cdot \frac{\partial \text{MSE}}{\partial b}$$


Gradient lớn $\Rightarrow$ bước lớn (nếu η cố định); gradient nhỏ $\Rightarrow$ bước nhỏ.

Learning rate và đường cong mất mát


Mức	Hiện tượng
Phù hợp	Giảm nhanh rồi phẳng — hội tụ trong số vòng hợp lý.
Quá nhỏ	Cải thiện chậm từng vòng — cần rất nhiều vòng.
Quá lớn	Loss dao động hoặc tăng — không hội tụ.




Hình 23. Learning rate tốt.



Hình 24. Learning rate quá nhỏ.



Hình 25. Learning rate quá lớn — dao động.



Hình 26. Learning rate quá lớn — loss tăng.

Kiểm tra hiểu biết

Learning rate **lý tưởng phụ thuộc bài toán** — không có một số cố định (0.01 hay 1.0) cho mọi dataset.


5.2 Batch size

Batch size


Số **mẫu** xử lý trước mỗi lần cập nhật w, b .

Ba kiểu cập nhật

- **Giảm độ dốc ngẫu nhiên trên toàn bộ batch (Full batch)**: toàn dataset $\rightarrow$ 1 cập nhật / epoch. Tuy nhiên, khi dataset chứa hàng trăm nghìn hoặc thậm chí hàng triệu mẫu, việc sử dụng toàn bộ batch là không thực tế.
- **Giảm độ dốc ngẫu nhiên (SGD)**: 1 mẫu / bước — nhanh, **nhiều** (loss nhấp nhô).
- **Giảm độ dốc ngẫu nhiên trên batch nhỏ (Mini-batch SGD)**: $1 < \text{batch} < N$ — cân bằng; gradient trung bình trên batch.



Hình 27. SGD — nhiễu trên loss curve.



Hình 28. Mini-batch — ít nhiễu hơn gần hội tụ.


Nhiều không luôn xấu

Một mức nhiễu có thể giúp **tổng quát hóa** tốt hơn và tìm ra các trọng số và độ lệch tối ưu trong một **mạng nơ-ron**.

5.3 Epoch

Epoch

Một **epoch** = mô hình đã duyệt **toàn bộ** tập huấn luyện đúng một lần. Ví dụ: 1000 mẫu, batch 100 $\Rightarrow$ 10 **iteration** / epoch.



Hình 29. Full batch, mini-batch, epoch.

Số lần cập nhật tham số (ví dụ 1000 mẫu, 20 epoch)

Kiểu batch	Cập nhật w, b
Full batch	20 lần (1 lần / epoch, hình dung 1 batch x 20 epoch).
SGD	20 000 lần (1 mẫu / epoch, hình dung 1 000 batch x 20 epoch).
Mini-batch (100)	200 lần (10 batch $\times$ 20 epoch).

Kiểm tra hiểu biết

1. Batch size mini-batch **tùy dataset và tài nguyên**, không cố định 10 hay 100.
2. Tăng gấp đôi learning rate có thể làm huấn luyện **chậm hơn** (nhảy quá mạnh, không hội tụ).
3. Batch lớn “không phù hợp” dữ liệu nhiều outlier — trung bình gradient trên batch lớn có thể **giảm** ảnh hưởng outlier.

6 Bài tập về phương pháp giảm độ dốc

Thực hành learning rate

Cùng dữ liệu MPG, lần này máy tự chạy GD. Ba mức learning rate cho ba kiểu hành vi: hội tụ nhanh, quá chậm, không hội tụ.

Link bài tập: <https://developers.google.com/machine-learning/crash-course/linear-regression/gradient-descent-exercise>

Ba nhiệm vụ

Nhiệm vụ 1: Learning rate = 0,03, nhấn Start. Ghi thời gian hội tụ, MSE, w , b .

Nhiệm vụ 2: Reset; learning rate $\approx 1,1 \times 10^{-5}$. Quan sát tốc độ hội tụ.

Nhiệm vụ 3: Reset; learning rate = 1. Quan sát loss dao động / không hội tụ.

Đáp án nhiệm vụ 1

$\eta = 0,03$: hội tụ ~ 30 giây; MSE $\approx 2,67$; $w \approx -1,14$, $b \approx 20,389$ — learning rate hợp lý.

Đáp án nhiệm vụ 2

$\eta \approx 10^{-5}$: sau vài phút vẫn chưa hội tụ; mỗi bước giảm loss rất ít $\Rightarrow$ nên **tăng** learning rate.

Đáp án nhiệm vụ 3

$\eta = 1$: MSE nhảy mạnh (có thể > 300), dao động — **quá lớn**, không bao giờ hội tụ ổn định.

Tổng kết chương — Hồi quy tuyến tính

- Mô hình: $y' = b + \sum_i w_i x_i$; học w , b bằng cách giảm MSE.
- **Gradient descent**: lặp tính gradient và cập nhật; mất loss lồi $\Rightarrow$ cực tiểu tin cậy.
- **Siêu tham số**: η (learning rate), batch size, epoch — cần thử nghiệm theo dataset.