
TRÍ TUỆ NHÂN TẠO

Phân loại

Lý thuyết — Ngưỡng, metric, ROC/AUC, đa lớp

Biên soạn:

ĐẶNG TẤN QUÍ

SĐT: 0377 122 210

2026

Mục lục

Lời nói đầu	3
1 Giới thiệu phân loại	4
2 Ngưỡng và ma trận nhầm lẫn	5
2.1 Ma trận nhầm lẫn	5
2.2 Ảnh hưởng của ngưỡng	6
3 Accuracy, recall, precision và metric liên quan	7
4 ROC và AUC	9
5 Độ lệch dự đoán (prediction bias)	13
6 Phân loại đa lớp	14

Đặng Tấn Quý

Lời nói đầu

Nguồn và cách đọc

Tài liệu biên soạn và dịch từ *Classification* (Google ML Crash Course)^a.

^a<https://developers.google.com/machine-learning/crash-course/classification>

Điều kiện tiên quyết

Cần nắm [Introduction to ML](#), [Linear regression](#) và [Logistic regression](#).

Mục tiêu học tập

- Xác định ngưỡng phù hợp cho phân loại nhị phân.
- Tính và chọn metric đánh giá mô hình.
- Đọc và diễn giải ROC và AUC.

1 Giới thiệu phân loại

Từ 75% spam sang lớp “spam”

Logistic cho $P(\text{spam}) = 0,75$. Ứng dụng lọc thư cần **lớp** spam/không spam — đó là phân loại.

Phân loại

Phân loại (classification): dự đoán mẫu thuộc **lớp** nào.

- **Nhị phân**: hai lớp.
- **Đa lớp**: hơn hai lớp (giới thiệu cuối module).

Luồng module

Xác suất (logistic) $\xrightarrow{\text{ngưỡng}}$ lớp $\xrightarrow{\text{ma trận nhầm lẫn}}$ metric $\xrightarrow{\text{mọi ngưỡng}}$ ROC/AUC.

2 Ngưỡng và ma trận nhầm lẫn

Từ 0,75 sang thư mục spam

Mô hình spam cho xác suất 0–1. Triển khai cần chuyển 0.75 thành “spam” hoặc “không spam” bằng **ngưỡng**.

Ngưỡng phân loại

Ngưỡng t : $y' \geq t \Rightarrow$ **lớp dương** (spam); $y' < t \Rightarrow$ **lớp âm**. Với thư viện Keras: $y' = t$ xếp vào **âm**.

0,51 vs 0,99 với ngưỡng khác nhau

Email A: $y' = 0,99$; email B: $y' = 0,51$. Ngưỡng 0,5: cả hai là spam. Ngưỡng 0,95: chỉ A là spam.

0,5 không luôn tối ưu

Tránh mặc định 0,5 khi: lớp mất cân bằng (0,01% spam); chi phí FP/FN không đối xứng; phân loại nhầm thư hợp lệ đắt hơn phân loại spam lọt vào hộp thư đến.

2.1 Ma trận nhầm lẫn

Confusion matrix

Điểm số xác suất không phải là thực tế, cũng không phải là sự thật khách quan (**ground truth**). Bốn ô (cột = thực tế, hàng = dự đoán):

- Probability score (Điểm số xác suất): Con số thể hiện khả năng xảy ra của một sự kiện (thường là kết quả dự đoán của thuật toán, mô hình AI).
- Reality (Thực tế): Những gì thực sự xảy ra hoặc tồn tại trong đời thực.
- Ground truth (Sự thật khách quan/Dữ liệu thực tế): Kết quả chính xác, đúng đắn đã được kiểm chứng ngoài đời thực.

Ma trận nhầm lẫn (spam)

	Thực tế dương	Thực tế âm
Dự đoán dương	TP (True positive) (Dương tính thật) — spam đúng vào thư rác	FP (False positive) (Dương tính giả) — thư hợp lệ vào spam
Dự đoán âm	FN (False negative) (Âm tính giả) — spam lọt hộp thư	TN (True negative) (Âm tính thật) — thư hợp lệ đúng hộp thư

Tổng theo hàng và cột

- **Hàng:** mọi dự đoán dương ($TP + FP$), mọi dự đoán âm ($FN + TN$).
- **Cột:** mọi thực tế dương ($TP + FN$), mọi thực tế âm ($FP + TN$).

Dữ liệu mất cân bằng

Tổng thực tế dương không gần bằng tổng âm $\Rightarrow$ **mất cân bằng lớp**.

2.2 Ảnh hưởng của ngưỡng**Video ngưỡng**

<https://www.youtube.com/watch?v=QM0sYbEQSkM>

Widget MLCC (Separated / Unseparated / Imbalanced)

Kéo ngưỡng từ 0,1 $\rightarrow$ 0,9 để quan sát TP, FP, FN, TN thay đổi.

Liên kết: [Widget MLCC \(Separated / Unseparated / Imbalanced\)](#)

Ngưỡng

Site hợp lệ bị gán malware $\Rightarrow$ **FP** (âm bị gán dương - dương tính giả).

Tăng ngưỡng $\Rightarrow$ **TP và FP giảm; còn FN và TN tăng**.

3 Accuracy, recall, precision và metric liên quan

Một con số không đủ

Metric phụ thuộc chi phí sai, mất cân bằng lớp và **ngưỡng** đang dùng (mỗi metric tính tại một ngưỡng cố định).

- Accuracy: Độ chính xác
- Recall: Độ nhạy / độ thu hồi / tỷ lệ dự báo đúng
- Precision: Độ chuẩn xác / độ chuẩn xác dương tính
- Metric: Đo lường / chỉ số đánh giá

Các công thức chính

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad F_1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} = \frac{2TP}{2TP + FP + FN}$$

Diễn giải (ví dụ spam)

- **Accuracy:** tỷ lệ email phân loại đúng. Cho biết tổng tỷ lệ dự đoán đúng của toàn bộ mô hình trên mọi trường hợp. Một mô hình hoàn hảo sẽ không có kết quả dương tính giả và không có kết quả âm tính giả, do đó, độ chính xác là 1.0.
- **Recall (TPR):** trong spam thật, bắt được bao nhiêu? (*probability of detection*). Trả lời câu hỏi: "Trong tổng số trường hợp thực tế cần tìm, mô hình đã quét được bao nhiêu phần trăm?"
- **FPR:** tỷ lệ thư hợp lệ bị gán nhầm spam. Trả lời câu hỏi: "Trong số những lần mô hình báo động (dự đoán dương tính), có bao nhiêu lần là cảnh báo thật?"
- **Precision:** trong email gán spam, bao nhiêu đúng là spam? Trả lời câu hỏi: "Mô hình dự đoán đúng được bao nhiêu trong số những lần nó cảnh báo?"
- **F1:** "Mô hình hoạt động cân bằng và ổn định như thế nào?" Trả lời câu hỏi: "Mô hình đang hoạt động ở mức độ nào? Độ nhạy và độ chính xác có đồng đều không?"

Accuracy trên tập mất cân bằng

Tuy nhiên, khi tập dữ liệu không cân bằng hoặc khi một loại lỗi (FN hoặc FP) tốn kém hơn loại còn lại (trường hợp này xảy ra trong hầu hết các ứng dụng thực tế), bạn nên tối ưu hoá cho một trong các chỉ số khác.

Đối với các tập dữ liệu có độ mất cân bằng cao, trong đó một lớp xuất hiện rất hiếm, chẳng hạn như 1%, một mô hình dự đoán giá trị âm 100% sẽ đạt điểm 99% về độ chính xác, mặc dù không có tác dụng.

Precision vs recall

Tăng ngưỡng $\Rightarrow$ thường precision $\uparrow$, recall $\downarrow$ (đánh đổi nghịch).

NaN

$TP = FP = 0 \Rightarrow$ precision không xác định. Mô hình không bao giờ dự đoán dương có thể cho NaN.

Gợi ý chọn metric

Metric	Khi nào ưu tiên
Accuracy	Tập cân bằng; chỉ dùng kèm metric khác.
Recall	FN đắt (bỏ sót bệnh, spam lọt).
FPR	FP đắt (báo động giả).
Precision	Cần dự đoán dương chính xác.
F_1	Cân bằng precision/recall; tập mất cân bằng.

Tính recall và precision

$TP = 5, TN = 6, FP = 3, FN = 2$: Recall $= 5/7 \approx 0,714$; Precision $= 5/8 = 0,625$.

$TP = 3, FP = 2, FN = 1$: Precision $= 3/5 = 0,6$.

Metric

Câu 1. $TP = 5, FN = 2 \Rightarrow$ Recall $= 5/7$ (không chia cho tổng mọi phân loại đúng).

Câu 2. $TP = 3, FP = 2 \Rightarrow$ Precision $= 3/5$ (chia cho mọi dự đoán dương).

Câu 3. Bẫy cón trùng xâm lấn: FN đắt, FP rẻ $\Rightarrow$ tối đa **Recall**.


4 ROC và AUC

Đánh giá mọi ngưỡng

Accuracy/recall tại **một** ngưỡng. ROC quét ngưỡng — so sánh mô hình toàn cục.

Đường cong ROC


Với mỗi ngưỡng: tính TPR (recall) và FPR; vẽ TPR (y) theo FPR (x). Điểm (0, 1): hoàn hảo (FPR=0, TPR=1).




Hình 1. ROC mô hình hoàn hảo ($AUC = 1$).

AUC

AUC: xác suất mô hình xếp ngẫu nhiên một mẫu dương **cao hơn** một mẫu âm (không phụ thuộc ngưỡng).




Hình 2. $AUC = P(\text{vuông bên phải hình tròn})$.




Hình 3. Đoán ngẫu nhiên: đường chéo, $AUC = 0,5$.

Precision-Recall curve (tùy chọn)


Tập mất cân bằng nặng: PRC (precision vs recall) đôi khi so sánh tốt hơn ROC.



Hình 4. Ví dụ đường precision-recall.



Hình 5. $AUC = 0,65$ (trái) vs $0,93$ (phải).




Hình 6. Điểm A, B, C — chọn ngưỡng theo chi phí FP/FN.

Chọn điểm trên ROC

- **A:** FP đắt $\Rightarrow$ FPR thấp, chấp nhận TPR thấp hơn.
- **C:** FN đắt $\Rightarrow$ tối đa TPR.
- **B:** chi phí tương đương $\Rightarrow$ cân bằng.

AUC nhỏ hơn 0,5

Tệ hơn ngẫu nhiên — có thể **đảo nhãn** $0 \leftrightarrow 1$ mà không cần huấn luyện lại.



Hình 7. So sánh AUC: 0,77 tốt nhất; 0,31 tệ hơn ngẫu nhiên.

ROC

Câu 1. AUC cao nhất: auc_0-77.png ($\approx 0,77$).

Câu 2. Tệ hơn ngẫu nhiên: auc_0-32.png (AUC nhỏ hơn 0,5).

Câu 3. Cải thiện không huấn luyện lại: **đảo nhãn dự đoán**.

Câu 4. Thư quan trọng không được vào spam $\Rightarrow$ **điểm A** (FPR thấp).

5 Độ lệch dự đoán (prediction bias)

Kiểm tra nhanh sau huấn luyện

Trung bình xác suất dự đoán có khớp tỷ lệ nhãn thật? Lệch sớm $\Rightarrow$ lỗi dữ liệu, pipeline hoặc chuẩn hóa quá mạnh.

Prediction bias

$$\text{bias} = \bar{y}' - \bar{y}$$

$\bar{y}$: trung bình nhãn ground truth; $\bar{y}'$: trung bình dự đoán. Ví dụ: 5% spam $\Rightarrow$ kỳ vọng $\bar{y}' \approx 0,05$. Mô hình luôn “50% spam” $\Rightarrow$ lệch nghiêm trọng.

Nguyên nhân có thể

- Dữ liệu / lấy mẫu thiên lệch.
- Regularization quá mạnh.
- Lỗi pipeline huấn luyện.
- Đặc trưng không đủ cho tác vụ.

6 Phân loại đa lớp

Hơn hai lớp

Nhận dạng chữ số 0–9; phân loại nhiều loài — không chỉ spam/không spam.

One-vs-rest

Mỗi mẫu một lớp: chia thành nhiều bài toán nhị phân. Ba lớp A, B, C:

1. $(A+B)$ vs C.
2. Trong $(A+B)$: A vs B.

Chữ số viết tay

Ảnh một chữ số $\Rightarrow$ dự đoán 0–9.

Đa nhãn

Một mẫu thuộc **nhiều lớp cùng lúc** $\Rightarrow$ **đa nhãn** (multi-label), khác đa lớp. Chi tiết: [Multi-class neural networks](#).

Tổng kết chương — Phân loại

- Xác suất + **ngưỡng** $\rightarrow$ lớp; **confusion matrix** $\rightarrow$ metric.
- Chọn metric theo chi phí FN/FP; **ROC/AUC** cho mọi ngưỡng.
- Kiểm tra **prediction bias**; đa lớp = one-vs-rest hoặc mô hình chuyên sâu.