
TRÍ TUỆ NHÂN TẠO

Phân loại

Lý thuyết — Ngưỡng, metric, ROC/AUC, đa lớp

Biên soạn:

ĐẶNG TẤN QUÍ

SĐT: 0377 122 210

2026

Mục lục

Lời nói đầu	3
1 Giới thiệu phân loại	4
2 Ngưỡng và ma trận nhầm lẫn	5
2.1 Ma trận nhầm lẫn	5
2.2 Ảnh hưởng của ngưỡng	6
3 Accuracy, recall, precision và metric liên quan	7
4 ROC và AUC	9
5 Độ lệch dự đoán (prediction bias)	13
6 Phân loại đa lớp	14

Đặng Tấn Quý

Lời nói đầu

Nguồn và cách đọc

Tài liệu biên soạn và dịch từ *Classification* (Google ML Crash Course)^a.

^a<https://developers.google.com/machine-learning/crash-course/classification>

Điều kiện tiên quyết

Cần nắm [Introduction to ML](#), [Linear regression](#) và [Logistic regression](#).

Mục tiêu học tập

- Xác định ngưỡng phù hợp cho phân loại nhị phân.
- Tính và chọn metric đánh giá mô hình.
- Đọc và diễn giải ROC và AUC.

1 Giới thiệu phân loại

Động cơ học — Từ 75% spam sang lớp “spam”

Logistic cho $P(\text{spam}) = 0,75$. Ứng dụng lọc thư cần **lớp** spam/không spam — đó là phân loại.

Phân loại

Phân loại (classification): dự đoán mẫu thuộc **lớp** nào.

- **Nhị phân**: hai lớp.
- **Đa lớp**: hơn hai lớp (giới thiệu cuối module).

Luồng module

Xác suất (logistic) $\xrightarrow{\text{ngưỡng}}$ lớp $\xrightarrow{\text{ma trận nhầm lẫn}}$ metric $\xrightarrow{\text{mọi ngưỡng}}$ ROC/AUC.

2 Ngưỡng và ma trận nhầm lẫn

Động cơ học — Từ 0,75 sang thư mục spam

Mô hình spam cho xác suất 0–1. Triển khai cần chuyển 0.75 thành “spam” hoặc “không spam” bằng **ngưỡng**.

Ngưỡng phân loại

Ngưỡng t : $y' \geq t \Rightarrow$ **lớp dương** (spam); $y' < t \Rightarrow$ **lớp âm**. Keras: $y' = t$ xếp vào **âm**.

0,51 vs 0,99 với ngưỡng khác nhau

Email A: $y' = 0,99$; email B: $y' = 0,51$. Ngưỡng 0,5: cả hai là spam. Ngưỡng 0,95: chỉ A là spam.

0,5 không luôn tối ưu

Tránh mặc định 0,5 khi: lớp mất cân bằng (0,01% spam); chi phí FP/FN không đối xứng; sai lệch thư hợp lệ đắt hơn để spam lọt.

2.1 Ma trận nhầm lẫn

Confusion matrix

Điểm dự đoán $\neq$ **ground truth**. Bốn ô (cột = thực tế, hàng = dự đoán):

Ma trận nhầm lẫn (spam)

	Thực tế dương	Thực tế âm
Dự đoán dương	TP — spam đúng vào thư rác	FP — thư hợp lệ vào spam
Dự đoán âm	FN — spam lọt hộp thư	TN — thư hợp lệ đúng hộp thư

Tổng theo hàng và cột

- **Hàng:** mọi dự đoán dương ($TP + FP$), mọi dự đoán âm ($FN + TN$).
- **Cột:** mọi thực tế dương ($TP + FN$), mọi thực tế âm ($FP + TN$).

Dữ liệu mất cân bằng

Tổng thực tế dương không gần bằng tổng âm $\Rightarrow$ **mất cân bằng lớp**. Ví dụ: hàng nghìn ảnh mây, loại volutus chỉ vài ảnh.

2.2 Ảnh hưởng của ngưỡng

Video ngưỡng

<https://www.youtube.com/watch?v=QM0sYbEQSkM>

Widget MLCC (Separated / Unseparated / Imbalanced)

Kéo ngưỡng từ 0,1 $\rightarrow$ 0,9 để quan sát TP, FP, FN, TN thay đổi.

Kiểm tra hiểu biết — Ngưỡng

Câu 1. Site hợp lệ bị gán malware $\Rightarrow$ **FP** (âm bị gán dương).

Câu 2. Tăng ngưỡng $\Rightarrow$ **cả TP và FP giảm** (ít gán dương; ví dụ ngưỡng 0,9999).

Câu 3. Tăng ngưỡng $\Rightarrow$ **TN tăng, FN giảm** (theo đáp án MLCC; thử trên widget).

3 Accuracy, recall, precision và metric liên quan

Động cơ học — Một con số không đủ

Metric phụ thuộc chi phí sai, mất cân bằng lớp và **ngưỡng** đang dùng (mỗi metric tính tại một ngưỡng cố định).

Các công thức chính

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad F_1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} = \frac{2TP}{2TP + FP + FN}$$

Diễn giải (ví dụ spam)

- **Accuracy:** tỷ lệ email phân loại đúng.
- **Recall (TPR):** trong spam thật, bắt được bao nhiêu? (*probability of detection*)
- **FPR:** tỷ lệ thư hợp lệ bị gán nhầm spam.
- **Precision:** trong email gán spam, bao nhiêu đúng là spam?

Accuracy trên tập mất cân bằng

99% nhân âm: mô hình luôn dự đoán âm $\Rightarrow$ accuracy 99% nhưng **vô dụng**.

Precision vs recall

Tăng ngưỡng $\Rightarrow$ thường precision $\uparrow$, recall $\downarrow$ (đánh đổi nghịch).

NaN

$TP = FP = 0 \Rightarrow$ precision không xác định. Mô hình không bao giờ dự đoán dương có thể cho NaN.

Gợi ý chọn metric

Metric	Khi nào ưu tiên
Accuracy	Tập cân bằng; chỉ dùng kèm metric khác.
Recall	FN đắt (bỏ sót bệnh, spam lọt).
FPR	FP đắt (báo động giả).
Precision	Cần dự đoán dương chính xác.
F_1	Cân bằng precision/recall; tập mất cân bằng.

Tính recall và precision

$TP = 5, TN = 6, FP = 3, FN = 2$: Recall = $5/7 \approx 0,714$; Precision = $5/8 = 0,625$.

$TP = 3, FP = 2, FN = 1$: Precision = $3/5 = 0,6$.

Kiểm tra hiểu biết — Metric

Câu 1. $TP = 5, FN = 2 \Rightarrow$ Recall = $5/7$ (không chia cho tổng mọi phân loại đúng).

Câu 2. $TP = 3, FP = 2 \Rightarrow$ Precision = $3/5$ (chia cho mọi dự đoán dương).

Câu 3. Bẫy côn trùng xâm lấn: FN đắt, FP rẻ $\Rightarrow$ tối đa **Recall**.


4 ROC và AUC

Động cơ học — Đánh giá mọi ngưỡng

Accuracy/recall tại **một** ngưỡng. ROC quét ngưỡng — so sánh mô hình toàn cục.

Đường cong ROC


Với mỗi ngưỡng: tính TPR (recall) và FPR; vẽ TPR (y) theo FPR (x). Điểm (0, 1): hoàn hảo (FPR=0, TPR=1).




Hình 1. ROC mô hình hoàn hảo ($AUC = 1$).

AUC

AUC: xác suất mô hình xếp ngẫu nhiên một mẫu dương **cao hơn** một mẫu âm (không phụ thuộc ngưỡng).




Hình 2. $AUC = P(\text{vuông bên phải hình tròn})$.




Hình 3. Đoán ngẫu nhiên: đường chéo, $AUC = 0,5$.

Precision-Recall curve (tùy chọn)


Tập mất cân bằng nặng: PRC (precision vs recall) đôi khi so sánh tốt hơn ROC.



Hình 4. Ví dụ đường precision-recall.



Hình 5. $AUC = 0,65$ (trái) vs $0,93$ (phải).




Hình 6. Điểm A, B, C — chọn ngưỡng theo chi phí FP/FN.

Chọn điểm trên ROC

- **A:** FP đắt $\Rightarrow$ FPR thấp, chấp nhận TPR thấp hơn.
- **C:** FN đắt $\Rightarrow$ tối đa TPR.
- **B:** chi phí tương đương $\Rightarrow$ cân bằng.

AUC nhỏ hơn 0,5

Tệ hơn ngẫu nhiên — có thể **đảo nhãn** $0 \leftrightarrow 1$ mà không cần huấn luyện lại.



Hình 7. So sánh AUC: 0,77 tốt nhất; 0,31 tệ hơn ngẫu nhiên.

Kiểm tra hiểu biết — ROC

Câu 1. AUC cao nhất: auc_0-77.png ($\approx 0,77$).

Câu 2. Tệ hơn ngẫu nhiên: auc_0-32.png (AUC nhỏ hơn 0,5).

Câu 3. Cải thiện không huấn luyện lại: **đảo nhãn dự đoán**.

Câu 4. Thư quan trọng không được vào spam $\Rightarrow$ **điểm A** (FPR thấp).

5 Độ lệch dự đoán (prediction bias)

Động cơ học — Kiểm tra nhanh sau huấn luyện

Trung bình xác suất dự đoán có khớp tỷ lệ nhân thật? Lệch sớm $\Rightarrow$ lỗi dữ liệu, pipeline hoặc chuẩn hóa quá mạnh.

Prediction bias

$$\text{bias} = \bar{y}' - \bar{y}$$

$\bar{y}$: trung bình nhân ground truth; $\bar{y}'$: trung bình dự đoán. Ví dụ: 5% spam $\Rightarrow$ kỳ vọng $\bar{y}' \approx 0,05$. Mô hình luôn “50% spam” $\Rightarrow$ lệch nghiêm trọng.

Nguyên nhân có thể

- Dữ liệu / lấy mẫu thiên lệch.
- Regularization quá mạnh.
- Lỗi pipeline huấn luyện.
- Đặc trưng không đủ cho tác vụ.

6 Phân loại đa lớp

Động cơ học — Hơn hai lớp

Nhận dạng chữ số 0–9; phân loại nhiều loài — không chỉ spam/không spam.

One-vs-rest

Mỗi mẫu một lớp: chia thành nhiều bài toán nhị phân. Ba lớp A, B, C:

1. $(A+B)$ vs C.
2. Trong $(A+B)$: A vs B.

Chữ số viết tay

Ảnh một chữ số $\Rightarrow$ dự đoán 0–9.

Đa nhãn

Một mẫu thuộc **nhiều lớp cùng lúc** $\Rightarrow$ **đa nhãn** (multi-label), khác đa lớp. Chi tiết: [Multi-class neural networks](#).

Tổng kết chương — Phân loại

- Xác suất + **ngưỡng** $\rightarrow$ lớp; **confusion matrix** $\rightarrow$ metric.
- Chọn metric theo chi phí FN/FP; **ROC/AUC** cho mọi ngưỡng.
- Kiểm tra **prediction bias**; đa lớp = one-vs-rest hoặc mô hình chuyên sâu.