
TRÍ TUỆ NHÂN TẠO

Mạng nơron

Lý thuyết — Kiến trúc, hàm kích hoạt, lan truyền ngược, đa lớp

Biên soạn:

ĐẶNG TẤN QUÍ

SĐT: 0377 122 210

2026

Mục lục

Lời nói đầu	3
1 Giới thiệu mạng nơron	4
2 Nút và lớp ẩn	4
3 Hàm kích hoạt	5
3.1 Ba hàm kích hoạt phổ biến	6
4 Huấn luyện bằng lan truyền ngược	6
4.1 Một số hiện tượng khi huấn luyện	7
4.2 Dropout regularization	7
5 Bài tập tương tác	7
6 Phân loại đa lớp với mạng nơron	8
6.1 One-vs-all	8
6.2 Softmax (one-vs-one)	8

Lời nói đầu

Nguồn và cách đọc

Tài liệu biên soạn và dịch từ *Neural networks* (Google Machine Learning Crash Course).

Điều kiện tiên quyết

- Introduction to ML, Linear regression, Logistic regression, Classification.
- Numerical data, Categorical data.
- Datasets, Generalization, and Overfitting.

Mục tiêu học tập

- Hiểu động cơ dùng mạng nơon cho bài toán phi tuyến.
- Nắm khái niệm nút, lớp ẩn, hàm kích hoạt.
- Nắm trực giác suy luận (inference) trong mạng nơon nhiều lớp.
- Nắm ý tưởng lan truyền ngược, vấn đề gradient mất/ nổ, dropout.
- Hiểu phân loại đa lớp kiểu one-vs-all và softmax (one-vs-one).

1 Giới thiệu mạng nơon

Động cơ học — Bài toán phi tuyến

Trong module dữ liệu danh mục, bạn đã thấy bài toán phân loại phi tuyến: điểm xanh/da cam nằm xen kẽ theo hình vòng tròn hoặc hình chữ thập; đường thẳng không thể chia chúng sạch sẽ.

Feature cross cho bài toán đơn giản

Với bài toán “chữ thập” đơn giản, thêm feature cross x_1x_2 cho phép mô hình tuyến tính học đường cong siêu bậc tách hai lớp.

Bài toán vòng tròn khó hơn

Với tập dữ liệu “vòng tròn trong vòng tròn”, việc đoán trước feature cross phù hợp trở nên khó và tốn công thử nghiệm.

Mạng nơon

Mạng nơon là họ kiến trúc mô hình được thiết kế để học **mối quan hệ phi tuyến** trong dữ liệu, bằng cách xếp chồng nhiều tầng phép biến đổi tuyến tính + phi tuyến.

Tổng kết chương

Các phần sau lần lượt trình bày: (1) nút và lớp ẩn, (2) hàm kích hoạt, (3) lan truyền ngược và regularization, (4) bài tập tương tác, (5) phân loại đa lớp.

2 Nút và lớp ẩn

Mô hình tuyến tính dạng mạng

Mô hình tuyến tính quen thuộc $y' = b + w_1x_1 + w_2x_2 + w_3x_3$ có thể vẽ thành “mạng” với 3 nút đầu vào (xanh) và 1 nút đầu ra (xanh lá): mỗi cạnh mang một trọng số w_i , cộng thêm bias b .

Bài tập 1 (tương tác trong MLCC)

Widget cho phép thay đổi các x_i , w_i , b và xem lại cách tính y' (hàm Linear chỉ trả về đầu vào). Việc chỉnh tham số không làm thay đổi việc mô hình vẫn là **tuyến tính** theo x_i .

Lớp ẩn và nơon

- **Lớp đầu vào**: chứa các đặc trưng x_i .
- **Lớp ẩn**: lớp nằm giữa đầu vào và đầu ra; mỗi nút gọi là **nơon**.
- Giá trị từng nơon ẩn: tổng có trọng số của đầu vào từ lớp trước + bias riêng, giống

hết mô hình tuyến tính.

Thêm lớp ẩn có giúp phi tuyến?

Nếu mọi phép biến đổi giữa các lớp đều **tuyến tính** (nhân + cộng), thì xếp chồng nhiều lớp vẫn chỉ là **một phép tuyến tính tương đương**. Do đó, chỉ thêm lớp ẩn mà không thêm phi tuyến thì mô hình vẫn không học được phi tuyến.

Kiểm tra hiểu biết — Số tham số

Ví dụ mạng 3 đầu vào, 1 lớp ẩn 4 nơon, 1 đầu ra:

- 4 nơon ẩn: mỗi nơon có 3 trọng số + 1 bias $\Rightarrow$ 16 tham số.
- 1 nơon đầu ra: 4 trọng số (mỗi nơon ẩn một trọng số) + 1 bias $\Rightarrow$ 5 tham số.
- Tổng cộng: 21 tham số.

Mặc dù nhiều lớp và tham số hơn, mọi phép tính vẫn tuyến tính $\Rightarrow$ chưa học được phi tuyến.

3 Hàm kích hoạt

Động cơ học — Làm sao đưa phi tuyến vào mạng?

Ghép tuyến tính sau tuyến tính vẫn tuyến tính. Cần chèn **phép biến đổi phi tuyến** giữa các lớp để mạng học quan hệ phức tạp.

So sánh với logistic regression

Trong hồi quy logistic, ta đưa đầu ra tuyến tính z qua hàm sigmoid để được xác suất y' . Tương tự, trong mạng nơon, ta đưa tổng có trọng số qua **hàm kích hoạt** trước khi chuyển sang lớp kế tiếp.

Hàm kích hoạt

Hàm kích hoạt σ là hàm phi tuyến áp dụng lên đầu ra tuyến tính của mỗi nơon:

$$\text{nơon}(\mathbf{x}) = \sigma(\mathbf{w} \cdot \mathbf{x} + b)$$

Xếp chồng nhiều lớp với hàm kích hoạt $\Rightarrow$ mô hình hóa được quan hệ phi tuyến phức tạp.

3.1 Ba hàm kích hoạt phổ biến

Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Đầu ra trong $(0, 1)$. Hay dùng ở đầu ra cho xác suất.

tanh

$$\sigma(x) = \tanh(x)$$

Đầu ra trong $(-1, 1)$. Hình chữ S giống sigmoid nhưng dốc hơn.

ReLU

$$\sigma(x) = \max(0, x)$$

Đưa mọi giá trị âm về 0, giữ nguyên giá trị dương.

So sánh sigmoid, tanh, ReLU

- Sigmoid, tanh trơn, nhưng dễ gặp **vanishing gradient** khi $|x|$ lớn.
- ReLU đơn giản, rẻ tính toán, thường giúp giảm vấn đề gradient mất.

Tóm tắt kiến trúc mạng nơron

Một mạng nơron điển hình gồm:

- Nhiều lớp nơron (input, ẩn, output).
- Trọng số + bias giữa các lớp.
- Hàm kích hoạt áp dụng trên mỗi nơron (có thể khác nhau giữa các lớp, nhưng thường cùng loại trong một lớp).

4 Huấn luyện bằng lan truyền ngược

Backpropagation

Lan truyền ngược là thuật toán chuẩn để tính gradient trong mạng nơron nhiều lớp, giúp áp dụng gradient descent cho toàn mạng.

Video trực quan

<https://www.youtube.com/watch?v=ovCyBmlrZGg>

4.1 Một số hiện tượng khi huấn luyện

Vanishing gradient

- Ở các lớp dưới (gần đầu vào), gradient có thể rất nhỏ do là tích của nhiều số nhỏ.
- Khi gradient gần 0, lớp đó học rất chậm hoặc không học được.
- Hàm kích hoạt như ReLU giúp giảm bớt hiện tượng này.

Exploding gradient

- Nếu trọng số lớn, gradient ở lớp dưới là tích của nhiều số lớn $\Rightarrow$ **gradient nổ**.
- Có thể làm việc học không hội tụ.
- Khắc phục: batch normalization, giảm learning rate.

Dead ReLU units

- Khi tổng có trọng số vào ReLU < 0 , đầu ra $= 0$ và gradient qua nút đó $= 0$.
- Nút có thể “chết” (luôn ra 0) nếu không còn gradient để cập nhật.
- Khắc phục: giảm learning rate; dùng biến thể ReLU (LeakyReLU, v.v.).

4.2 Dropout regularization

Dropout

Dropout là kỹ thuật regularization trong đó một tỉ lệ nút được “tắt” (output=0) ngẫu nhiên trong một bước cập nhật.

- Tỉ lệ 0,0: không dropout.
- Tỉ lệ 1,0: tắt hết, không học được gì.
- Thực tế: giá trị trung gian (ví dụ 0,2–0,5).

5 Bài tập tương tác

Khám phá mạng nơon bằng widget

MLCC cung cấp widget cho phép:

- Thay đổi số lớp ẩn, số nơon, learning rate, hàm kích hoạt.
- Quan sát giá trị từng nơon và loss train/test khi huấn luyện.

Các bài tập chính

- Ảnh hưởng của giá trị đầu vào và trọng số tới output khi dùng ReLU.
- Ảnh hưởng của thêm lớp ẩn, thêm nơon vào mạng.
- Bài toán “vòng tròn trong vòng tròn”: cấu hình mạng để loss train/test $< 0,2$.

Một cấu hình mẫu cho bài toán phi tuyến

Một cấu hình đạt loss $< 0,2$ trên train/test:

- 1 lớp ẩn với 3 nơon.
- Learning rate 0,01.
- Hàm kích hoạt ReLU.

6 Phân loại đa lớp với mạng nơon

Bài toán đa lớp

Phân loại đa lớp: mỗi ví dụ thuộc một trong nhiều lớp (ví dụ loại hoa, loại máy bay, loại quả).

6.1 One-vs-all

Nhiều bộ phân loại nhị phân

- Với N lớp, huấn luyện N bộ phân loại nhị phân “lớp i vs không phải lớp i ”.
- Ví dụ: ảnh quả: “apple vs not-apple”, “orange vs not-orange”, v.v.

One-vs-all với mạng nơon

Mạng nơon nhiều lớp có thể thực hiện one-vs-all bằng cách có **một nút đầu ra cho mỗi lớp**, áp dụng sigmoid độc lập trên từng nút. Mỗi nút cho xác suất “là lớp i ” so với “không phải i ”.

6.2 Softmax (one-vs-one)

Vấn đề tổng xác suất

Trong one-vs-all, các xác suất đầu ra không nhất thiết tổng bằng 1. Khi cần xác suất tương đối giữa các lớp (ví dụ “apple vs orange vs pear vs grape”), dùng **softmax**.

Softmax

Với véc-tơ điểm $z_j = \mathbf{w}_j^T \mathbf{x} + b_j$ cho mỗi lớp j trong tập lớp K :

$$p(y = j \mid \mathbf{x}) = \frac{e^{z_j}}{\sum_{k \in K} e^{z_k}}$$

Mọi xác suất $p(y = j \mid \mathbf{x})$ đều trong $(0, 1)$ và **tổng bằng 1**.

Biến thể softmax

- **Full softmax**: tính xác suất cho mọi lớp — phù hợp khi số lớp nhỏ/vừa.
- **Candidate sampling**: tính xác suất cho mọi nhãn dương và một mẫu con nhãn âm — hiệu quả hơn khi số lớp rất lớn.

Giới hạn của softmax

Softmax giả định **mỗi ví dụ thuộc đúng một lớp**. Nếu ví dụ có thể thuộc nhiều lớp cùng lúc (đa nhãn), cần dùng **nhiều hồi quy logistic nhị phân** thay vì softmax.

Tổng kết chương — Mạng nơon

- Mạng nơon = nhiều lớp tuyến tính + hàm kích hoạt phi tuyến.
- Lan truyền ngược cho phép lan truyền gradient qua nhiều lớp; cần chú ý gradient mất/nổ, dead ReLU, dropout.
- Softmax mở rộng logistic cho phân loại đa lớp, softmax layer cho output tổng xác suất = 1.