

First Printing: July 5, 2023

Gửi đến bố mẹ:

Alison và Michael James

Chiara Nappi và Edward Witten

Valerie và Patrick Hastie

Vera và Sami Tibshirani

John và Brenda Taylor

và gửi đến gia đình chúng tôi:

Michael, Daniel và Catherine

Tessa, Theo, Otto và Ari

Samantha, Timothy và Lynda

Charlie, Ryan, Julie và Cheryl

Lee-Ann và Isobel

Lời tựa

Học máy thống kê đề cập đến một tập hợp các công cụ để hiểu được ý nghĩa của các tập dữ liệu phức tạp. Trong những năm gần đây, chúng ta đã chứng kiến sự gia tăng đáng kể về quy mô và phạm vi thu thập dữ liệu trên hầu hết mọi lĩnh vực khoa học và công nghiệp.

Do đó, học máy thống kê đã trở thành một công cụ thiết yếu cho bất kỳ ai muốn hiểu dữ liệu – và khi ngày càng nhiều công việc hiện nay liên quan đến dữ liệu, điều này có nghĩa là học máy thống kê đang nhanh chóng trở thành một công cụ thiết yếu cho tất cả mọi người.

Một trong những cuốn sách đầu tiên về học máy thống kê – " Các yếu tố của học máy thống kê" (ESL, của Hastie, Tibshirani và Friedman) – được xuất bản năm 2001, với ấn bản thứ hai vào năm 2009. ESL đã trở thành một tài liệu tham khảo phổ biến không chỉ trong thống kê mà còn trong các lĩnh vực liên quan. Một trong những lý do cho sự phổ biến của ESL là phong cách tương đối dễ tiếp cận của nó. Tuy nhiên, ESL phù hợp nhất với những người có trình độ chuyên môn cao trong các ngành khoa học toán học.

Giới thiệu về Học máy Thống kê, với các ứng dụng trong R (ISLR) – xuất bản lần đầu năm 2013, tái bản lần thứ hai năm 2021 – ra đời từ nhu cầu rõ ràng về một cách tiếp cận rộng hơn và ít mang tính kỹ thuật hơn đối với các chủ đề chính trong học máy thống kê. Ngoài phần ôn tập về hồi quy tuyến tính, ISLR còn đề cập đến nhiều phương pháp thống kê và học máy quan trọng nhất hiện nay, bao gồm lấy mẫu lại, các phương pháp thưa cho phân loại và hồi quy, mô hình cộng tính tổng quát, các phương pháp dựa trên cây, máy vectơ hỗ trợ, học sâu, phân tích sống sót, phân cụm và kiểm định đa biến.

Kể từ khi được xuất bản năm 2013, ISLR đã trở thành một tài liệu tham khảo quan trọng trong các lớp học đại học và sau đại học trên toàn thế giới, cũng như là một cuốn sách tham khảo cần thiết cho các nhà khoa học dữ liệu. Một trong những chìa khóa thành công của cuốn sách là, bắt đầu từ Chương 2, mỗi chương đều có một bài thực hành bằng ngôn ngữ R minh họa cách triển khai các phương pháp học thống kê được trình bày trong chương đó, cung cấp cho người đọc kinh nghiệm thực tiễn quý giá.

Tuy nhiên, trong những năm gần đây, Python đã trở thành một ngôn ngữ ngày càng phổ biến trong lĩnh vực khoa học dữ liệu, và nhu cầu về các công cụ hỗ trợ Python cũng ngày càng tăng.

Đây là một cuốn sách thay thế dựa trên ISLR. Do đó, cuốn sách này, "Giới thiệu về Học máy Thống kê, Với Ứng dụng trong Python" (ISLP), bao gồm các nội dung tương tự như ISLR nhưng với các bài thực hành được triển khai bằng **Python** – một thành tựu đạt được nhờ sự tham gia của đồng tác giả mới, Jonathan Taylor. Một số bài thực hành sử dụng gói **ISLP Python**, mà chúng tôi đã viết để hỗ trợ việc thực hiện các phương pháp học máy thống kê được đề cập trong mỗi chương bằng **Python**. Những bài thực hành này sẽ hữu ích cho cả người mới bắt đầu học **Python** cũng như người dùng có kinh nghiệm.

Mục đích của ISLP (và ISLR) là tập trung nhiều hơn vào các ứng dụng của phương pháp và ít hơn vào các chi tiết toán học, vì vậy nó phù hợp cho sinh viên đại học năm cuối hoặc sinh viên cao học chuyên ngành thống kê hoặc các lĩnh vực định lượng liên quan, hoặc cho những người thuộc các ngành khác muốn sử dụng các công cụ học thống kê để phân tích dữ liệu của họ. Nó có thể được sử dụng như một giáo trình cho một khóa học kéo dài hai học kỳ.

Chúng tôi xin bày tỏ lòng biết ơn đến những độc giả đã đóng góp những ý kiến quý báu cho ấn bản đầu tiên của ISLR: Pallavi Basu, Alexandra Chouldechova, Patrick Dana-her, Will Fithian, Luella Fu, Sam Gross, Max Grazier G'Sell, Courtney Paulson, Xinghao Qiao, Elisa Sheng, Noah Simon, Kean Ming Tan, Xin Lu Tan. Chúng tôi cũng cảm ơn những độc giả đã đóng góp ý kiến hữu ích cho ấn bản thứ hai của ISLR: Alan Agresti, Iain Carmichael, Yiqun Chen, Erin Craig, Daisy Ding, Lucy Gao, Ismael Lemhadri, Bryan Martin, Anna Neufeld, Geoff Tims, Carsten Voelkmann, Steve Yadlowsky và James Zou. Chúng tôi vô cùng biết ơn Balasubramanian "Naras" Narasimhan vì sự hỗ trợ của ông đối với cả ISLR và ISLP.

Chúng tôi rất vinh dự và tự hào khi được chứng kiến tác động đáng kể mà ISLR đã tạo ra đối với cách thức thực hành học thống kê, cả trong và ngoài môi trường học thuật. Chúng tôi hy vọng rằng phiên bản **Python** mới này sẽ tiếp tục cung cấp cho các nhà thống kê ứng dụng và nhà khoa học dữ liệu hiện tại và tương lai những công cụ cần thiết để thành công trong một thế giới dựa trên dữ liệu.

Việc dự đoán rất khó, đặc biệt là về tương lai.

-Yogi Berra

Nội dung

Lời tựa	vii
1. Giới thiệu	1
2. Học máy thống kê 2.1 Học	15
máy thống kê là gì?	15
2.1.1 Tại sao cần ước lượng f?	17
2.1.2 Làm thế nào để ước tính f?	20
2.1.3 Sự đánh đổi giữa độ chính xác dự đoán	
và khả năng giải thích của mô hình.	23
2.1.4 Học có giám sát so với học không giám sát.	25
2.1.5 Bài toán hồi quy so với bài toán phân loại.	27
2.2 Đánh giá độ chính xác của mô hình.	27
2.2.1 Đo lường chất lượng độ vừa vặn.	28
2.2.2 Sự đánh đổi giữa độ lệch và phương sai.	31
2.2.3 Thiết lập phân loại.	34
2.3 Bài thực hành: Giới thiệu về Python.	40
2.3.1 Bắt đầu.	40
2.3.2 Các lệnh cơ bản.	40
2.3.3 Giới thiệu về Python số học.	42
2.3.4 Đồ họa.	48
2.3.5 Chuỗi và ký hiệu lát cắt.	51
2.3.6 Lập chỉ mục dữ liệu.	51
2.3.7 Tải dữ liệu.	55
2.3.8 Vòng lặp For.	59
2.3.9 Tóm tắt bằng đồ thị và số liệu bổ sung.	61
2.4 Bài tập.	63
3 Hồi quy tuyến tính 3.1	69
Hồi quy tuyến tính đơn giản.	70
3.1.1 Ước tính các hệ số.	71
3.1.2 Đánh giá độ chính xác của hệ số	
Ước tính.	72
3.1.3 Đánh giá độ chính xác của mô hình.	77
3.2 Hồi quy tuyến tính bội.	80
3.2.1 Ước tính các hệ số hồi quy.	81

3.2.2 Một số câu hỏi quan trọng.	83
3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy.	91
3.3.1 Các yếu tố dự báo định tính.	91
3.3.2 Mở rộng mô hình tuyến tính.	94
3.3.3 Các vấn đề tiềm ẩn.	100
3.4 Kế hoạch Marketing.	109
3.5 So sánh hồi quy tuyến tính với thuật toán K-Nearest	
Hàng xóm.	111
3.6 Bài thực hành: Hồi quy tuyến tính.	116
3.6.1 Nhập gói phần mềm.	116
3.6.2 Hồi quy tuyến tính đơn giản.	117
3.6.3 Hồi quy tuyến tính bội.	122
3.6.4 Kiểm định độ phù hợp đa biến.	123
3.6.5 Các thuật ngữ tương tác.	124
3.6.6 Biến đổi phi tuyến tính của các biến dự báo.	125
3.6.7 Các yếu tố dự báo định tính.	126
3.7 Bài tập.	127
4. Phân loại	135
4.1 Tổng quan về phân loại.	135
4.2 Tại sao không sử dụng hồi quy tuyến tính?	136
4.3 Hồi quy Logistic.	138
4.3.1 Mô hình Logistic.	139
4.3.2 Ước lượng các hệ số hồi quy.	140
4.3.3 Đưa ra dự đoán.	141
4.3.4 Hồi quy logistic đa biến.	142
4.3.5 Hồi quy Logistic đa biến.	144
4.4 Mô hình tạo sinh cho phân loại.	146
4.4.1 Phân tích phân biệt tuyến tính cho $p = 1$.	147
4.4.2 Phân tích phân biệt tuyến tính cho $p > 1$.	150
4.4.3 Phân tích phân biệt bậc hai.	156
4.4.4 Thuật toán Naive Bayes.	158
4.5 So sánh các phương pháp phân loại.	161
4.5.1 So sánh phân tích.	161
4.5.2 So sánh thực nghiệm.	164
4.6 Mô hình tuyến tính tổng quát.	167
4.6.1 Hồi quy tuyến tính trên dữ liệu chia sẻ xe đạp . . 167	
4.6.2 Hồi quy Poisson trên dữ liệu chia sẻ xe đạp . . 169	
4.6.3 Mô hình tuyến tính tổng quát trong phạm vi rộng hơn. 172	
4.7 Thực hành: Hồi quy Logistic, LDA, QDA và KNN.	173
4.7.1 Dữ liệu thị trường chứng khoán. 173	
4.7.2 Hồi quy Logistic.	174
4.7.3 Phân tích phân biệt tuyến tính.	179
4.7.4 Phân tích phân biệt bậc hai.	181
4.7.5 Thuật toán Naive Bayes.	182
4.7.6 K-Hàng xóm gần nhất . . 183	
4.7.7 Hồi quy tuyến tính và Poisson trên dữ liệu chia sẻ xe đạp 188	
4.8 Bài tập.	193

5 Phương pháp lấy mẫu lại	201
5.1 Kiểm định chéo	202
5.1.1 Phương pháp tập dữ liệu kiểm định.	202
5.1.2 Kiểm định chéo loại bỏ một mẫu (Leave-One-Out Cross-Validation).	204
5.1.3 Kiểm định chéo k lần (k-Fold Cross-Validation).	206
5.1.4 Sự đánh đổi giữa độ lệch và phương sai cho phép thử k-fold Kiểm định chéo.	208
5.1.5 Kiểm định chéo trên các bài toán phân loại.	209
5.2 Phương pháp Bootstrap.	212
5.3 Bài thực hành: Kiểm định chéo và phương pháp Bootstrap.	215
5.3.1 Phương pháp tập dữ liệu kiểm định.	216
5.3.2 Kiểm định chéo.	217
5.3.3 Hệ thống Bootstrap.	220
5.4 Bài tập.	224
6. Lựa chọn và điều chỉnh mô hình tuyến tính	229
6.1 Lựa chọn tập con.	231
6.1.1 Lựa chọn tập con tốt nhất.	231
6.1.2 Lựa chọn từng bước.	233
6.1.3 Lựa chọn mô hình tối ưu.	235
6.2 Phương pháp đo độ co ngót.	240
6.2.1 Hồi quy Ridge.	240
6.2.2 Dây thừng.	244
6.2.3 Chọn tham số điều chỉnh.	252
6.3 Các phương pháp giảm chiều dữ liệu.	253
6.3.1 Hồi quy thành phần chính.	254
6.3.2 Phương pháp bình phương tối thiểu từng phần.	260
6.4 Những cân nhắc trong không gian đa chiều.	262
6.4.1 Dữ liệu đa chiều.	262
6.4.2 Điều gì xảy ra sai sót trong không gian đa chiều?	263
6.4.3 Hồi quy trong không gian nhiều chiều.	265
6.4.4 Giải thích kết quả trong không gian đa chiều.	266
6.5 Bài thực hành: Mô hình tuyến tính và các phương pháp điều chỉnh.	267
6.5.1 Phương pháp lựa chọn tập con.	268
6.5.2 Hồi quy Ridge và Lasso.	273
6.5.3 PCR và hồi quy PLS.	280
6.6 Bài tập.	283
7 Vượt ra ngoài tính tuyến tính	289
7.1 Hồi quy đa thức.	290
7.2 Hàm bậc thang.	292
7.3 Các hàm cơ sở.	293
7.4 Đường cong Spline hồi quy.	294
7.4.1 Đa thức từng phần.	294
7.4.2 Ràng buộc và đường cong Spline.	296
7.4.3 Biểu diễn cơ sở Spline.	296
7.4.4 Lựa chọn số lượng và địa điểm của các nút thắt.	297
7.4.5 So sánh với hồi quy đa thức.	299

7.5	Làm mịn đường cong Spline.	300
7.5.1	Tổng quan về Spline làm mịn.	300
7.5.2	Lựa chọn tham số làm mịn λ	301
7.6	Hồi quy cục bộ.	303
7.7	Mô hình cộng tính tổng quát.	305
7.7.1	Mô hình GAM cho các bài toán hồi quy.	306
7.7.2	Mô hình GAM cho các bài toán phân loại.	308
7.8	Bài thực hành: Mô hình hóa phi tuyến tính.	309
7.8.1	Hồi quy đa thức và hàm bậc thang.	310
7.8.2	Đường cong Splines.	315
7.8.3	Làm mịn đường cong Spline và GAM.	317
7.8.4	Hồi quy cục bộ.	324
7.9	Bài tập.	325
8	Phương pháp dựa trên cây.	331
8.1	Khái niệm cơ bản về cây quyết định.	331
8.1.1	Cây hồi quy.	331
8.1.2	Cây phân loại.	337
8.1.3	Cây quyết định so với mô hình tuyến tính.	341
8.1.4	Ưu điểm và nhược điểm của cây xanh.	341
8.2	Phương pháp Bagging, Rừng ngẫu nhiên, Boosting và Phương pháp cộng Bayes	
	Cây hồi quy . . 343	
8.2.1	Đóng bao . . 343	
8.2.2	Rừng ngẫu nhiên . . 346	
8.2.3	Tăng cường	347
8.2.4	Cây hồi quy cộng tính Bayes.	350
8.2.5	Tóm tắt các phương pháp tập hợp cây quyết định.	353
8.3	Bài thực hành: Phương pháp dựa trên cây.	354
8.3.1	Xây dựng cây phân loại.	355
8.3.2	Xây dựng cây hồi quy.	358
8.3.3	Phương pháp đóng gói và rừng ngẫu nhiên.	360
8.3.4	Tăng cường.	361
8.3.5	Cây hồi quy cộng tính Bayes.	362
8.4	Bài tập.	363
9	Máy hỗ trợ vectơ.	367
9.1	Bộ phân loại biên độ tối đa.	367
9.1.1	Siêu mặt phẳng là gì?	368
9.1.2	Phân loại bằng cách sử dụng siêu mặt phẳng phân tách.	368
9.1.3	Bộ phân loại biên độ tối đa.	370
9.1.4	Xây dựng bộ phân loại biên độ tối đa.	372
9.1.5	Trường hợp không thể tách rời.	372
9.2	Bộ phân loại vectơ hỗ trợ.	373
9.2.1	Tổng quan về bộ phân loại vectơ hỗ trợ.	373
9.2.2	Chi tiết về Bộ phân loại vectơ hỗ trợ.	374
9.3	Máy hỗ trợ vectơ (Support Vector Machines)	377
9.3.1	Phân loại bằng quyết định phi tuyến tính	
	Ranh giới.	378
9.3.2	Máy hỗ trợ vectơ (Support Vector Machine).	379

9.3.3 Ứng dụng vào dữ liệu bệnh tim mạch.	382
9.4 SVM với nhiều hơn hai lớp.	383
9.4.1 Phân loại một đối một.	384
9.4.2 Phân loại "Một đối với tất cả".	384
9.5 Mối quan hệ với hồi quy logistic.	384
9.6 Bài thực hành: Máy hỗ trợ vectơ (Support Vector Machines).	387
9.6.1 Bộ phân loại vectơ hỗ trợ.	387
9.6.2 Máy hỗ trợ vectơ (Support Vector Machine).	390
9.6.3 Đường cong ROC.	392
9.6.4 SVM với nhiều lớp.	393
9.6.5 Ứng dụng vào dữ liệu biểu hiện gen.	394
9.7 Bài tập.	395
10. Học sâu	399
10.1 Mạng nơ-ron đơn lớp.	400
10.2 Mạng nơ-ron đa lớp.	402
10.3 Mạng nơ-ron tích chập.	406
10.3.1 Lớp tích chập.	407
10.3.2 Các lớp gộp.	410
10.3.3 Kiến trúc của mạng nơ-ron tích chập.	410
10.3.4 Bổ sung dữ liệu.	411
10.3.5 Kết quả sử dụng bộ phân loại đã được huấn luyện trước.	412
10.4 Phân loại tài liệu.	413
10.5 Mạng thần kinh hồi quy.	416
10.5.1 Mô hình tuần tự cho phân loại tài liệu.	418
10.5.2 Dự báo chuỗi thời gian.	420
10.5.3 Tóm tắt về RNN.	424
10.6 Khi nào nên sử dụng học sâu.	425
10.7 Xây dựng mạng nơ-ron.	427
10.7.1 Lan truyền ngược.	428
10.7.2 Chuẩn hóa và thuật toán giảm độ dốc ngẫu nhiên.	429
10.7.3 Học tập bỏ học.	431
10.7.4 Điều chỉnh mạng.	431
10.8 Nội suy và Giảm độ dốc kép.	432
10.9 Bài thực hành: Học sâu.	435
10.9.1 Mạng một lớp trên dữ liệu người đánh bóng.	437
10.9.2 Mạng đa lớp trên dữ liệu chữ số MNIST.	444
10.9.3 Mạng nơ-ron tích chập.	448
10.9.4 Sử dụng các mô hình CNN được huấn luyện trước.	452
10.9.5 Phân loại tài liệu IMDB.	454
10.9.6 Mạng thần kinh hồi quy.	458
10.10 Bài tập.	465
11 Phân tích sống sót và dữ liệu bị kiểm duyệt	469
11.1 Thời gian sống sót và thời gian kiểm duyệt.	470
11.2 Cái nhìn sâu hơn về kiểm duyệt.	470
11.3 Đường cong sống sót Kaplan-Meier.	472
11.4 Kiểm định Log-Rank.	474
11.5 Mô hình hồi quy với biến phản hồi sống sót.	476

11.5.1	Hàm nguy hiểm.	476
11.5.2	Rủi ro tỷ lệ thuận.	478
11.5.3	Ví dụ: Dữ liệu về ung thư não.	482
11.5.4	Ví dụ: Dữ liệu xuất bản.	482
11.6	Sự co rút đối với mô hình Cox.	484
11.7	Các chủ đề bổ sung.	486
11.7.1	Diện tích dưới đường cong trong phân tích sống sót.	486
11.7.2	Lựa chọn thang thời gian.	487
11.7.3	Các biến phụ thuộc thời gian.	488
11.7.4	Kiểm tra giả định về tỷ lệ nguy cơ tương ứng.	488
11.7.5	Cây sinh tồn.	488
11.8	Bài thực hành: Phân tích sống sót.	489
11.8.1	Dữ liệu về ung thư não.	489
11.8.2	Dữ liệu xuất bản.	493
11.8.3	Dữ liệu trung tâm cuộc gọi.	494
11.9	Bài tập.	498
12	Học không giám sát	503
12.1	Thách thức của học không giám sát	503
12.2	Phân tích thành phần chính	504
12.2.1	Thành phần chính là gì?	505
12.2.2	Một cách diễn giải khác về các thành phần chính.	508
12.2.3	Tỷ lệ phương sai được giải thích	510
12.2.4	Thêm thông tin về PCA	512
12.2.5	Các ứng dụng khác của thành phần chính.	515
12.3	Giá trị thiếu và hoàn thiện ma trận.	515
12.4	Phương pháp phân cụm.	520
12.4.1	Phân cụm K-Means.	521
12.4.2	Phân cụm phân cấp.	525
12.4.3	Các vấn đề thực tiễn trong phân cụm.	532
12.5	Bài thực hành: Học không giám sát.	535
12.5.1	Phân tích thành phần chính.	535
12.5.2	Hoàn thành ma trận.	539
12.5.3	Phân cụm.	542
12.5.4	Ví dụ về dữ liệu NCI60.	546
12.6	Bài tập.	552
13	Kiểm định bội	557
13.1	Ôn tập nhanh về kiểm định giả thuyết.	558
13.1.1	Kiểm định giả thuyết.	558
13.1.2	Lỗi loại I và lỗi loại II.	562
13.2	Thách thức của việc kiểm thử đa lớp	563
13.3	Tỷ lệ lỗi chung của cả nhóm	565
13.3.1	Tỷ lệ lỗi chung của nhóm là bao nhiêu?	565
13.3.2	Các phương pháp kiểm soát tỷ lệ lỗi tổng thể	567
13.3.3	Sự đánh đổi giữa FWER và công suất	572
13.4	Tỷ lệ phát hiện sai.	573
13.4.1	Trực giác về Tỷ lệ phát hiện sai.	573
13.4.2	Phương pháp Benjamini-Hochberg.	575

13.5 Phương pháp lấy mẫu lại đối với giá trị p và phát hiện sai	
Tỷ lệ . . . 577	
13.5.1 Phương pháp lấy mẫu lại đối với giá trị p . . . 578	
13.5.2 Phương pháp lấy mẫu lại đối với tỷ lệ phát hiện sai 579	
13.5.3 Khi nào thì các phương pháp lấy mẫu lại hữu ích? . . . 581 . . .	
13.6 Thực hành: Kiểm tra nhiều lần.	583
13.6.1 Ôn tập về kiểm định giả thuyết.	583
13.6.2 Tỷ lệ lỗi theo nhóm.	585
13.6.3 Tỷ lệ phát hiện sai.	588
13.6.4 Phương pháp lấy mẫu lại.	590
13.7 Bài tập.	593
Mục lục	597

1

Giới thiệu



Tổng quan về học máy thống kê


Học thống kê đề cập đến một tập hợp rộng lớn các công cụ để hiểu dữ liệu. Các công cụ này có thể được phân loại là có giám sát hoặc không giám sát. Nói một cách tổng quát, học thống kê có giám sát liên quan đến việc xây dựng một mô hình thống kê để dự đoán, hoặc ước tính, một đầu ra dựa trên một hoặc nhiều đầu vào. Các vấn đề thuộc bản chất này xuất hiện trong các lĩnh vực đa dạng như kinh doanh, y học, vật lý thiên văn và chính sách công. Với học thống kê không giám sát, có đầu vào nhưng không có đầu ra giám sát; tuy nhiên, chúng ta vẫn có thể học được các mối quan hệ và cấu trúc từ dữ liệu như vậy. Để minh họa một số ứng dụng của học thống kê, chúng ta sẽ thảo luận ngắn gọn về ba tập dữ liệu thực tế được xem xét trong cuốn sách này.

Dữ liệu tiền lương

Trong ứng dụng này (mà chúng tôi gọi là bộ dữ liệu **Tiền lương** trong suốt cuốn sách này), chúng tôi xem xét một số yếu tố liên quan đến tiền lương của một nhóm nam giới đến từ vùng Đại Tây Dương của Hoa Kỳ. Cụ thể, chúng tôi muốn hiểu mối liên hệ giữa **tuổi tác** và **trình độ học vấn của người lao động**, cũng như **năm dương lịch**, với **tiền lương của họ**. Ví dụ, hãy xem bảng bên trái của Hình 1.1, hiển thị **tiền lương** so với **tuổi tác** của từng cá nhân trong bộ dữ liệu. Có bằng chứng cho thấy **tiền lương** tăng theo **tuổi** nhưng sau đó lại giảm xuống sau khoảng 60 tuổi. Đường màu xanh lam, cung cấp ước tính về mức **lương** trung bình cho một **độ tuổi nhất định**, làm rõ hơn xu hướng này.

Dựa vào tuổi của một nhân viên, chúng ta có thể sử dụng đường cong này để dự đoán mức lương của họ. Tuy nhiên, từ Hình 1.1 cũng cho thấy rõ ràng rằng có một lượng biến động đáng kể liên quan đến giá trị trung bình này, do đó, chỉ dựa vào **tuổi tác** khó có thể đưa ra dự đoán chính xác về mức lương của một người cụ thể.

2 1. Giới thiệu




HÌNH 1.1. Dữ liệu **tiền lương**, bao gồm thông tin khảo sát thu nhập của nam giới từ khu vực Trung Đại Tây Dương của Hoa Kỳ. Bên trái: **tiền lương** theo độ **tuổi**. Trung bình, **tiền lương** tăng theo độ **tuổi** cho đến khoảng 60 tuổi, sau đó bắt đầu giảm. Giữa: **tiền lương** theo **năm**. Có sự tăng chậm nhưng ổn định khoảng 10.000 đô la trong mức **lương** trung bình từ năm 2003 đến năm 2009. Bên phải: Biểu đồ hộp thể hiện **tiền lương** theo trình độ **học vấn**, với 1 biểu thị trình độ thấp nhất (không có bằng tốt nghiệp trung học) và 5 biểu thị trình độ cao nhất (bằng thạc sĩ trở lên). Trung bình, **tiền lương** tăng theo trình độ học vấn.

Chúng tôi cũng có thông tin liên quan đến trình độ học vấn của mỗi nhân viên và **năm** mà **tiền lương** được trả. Các bảng ở giữa và bên phải của Hình 1.1, hiển thị **tiền lương** như một hàm của cả **năm** và **trình độ học vấn**, cho thấy cả hai yếu tố này đều có liên quan đến **tiền lương**. Tiền lương tăng khoảng 10.000 đô la, theo cách gần như tuyến tính (hoặc đường thẳng), từ năm 2003 đến năm 2009, mặc dù mức tăng này rất nhỏ so với sự biến động trong dữ liệu. Tiền lương cũng thường cao hơn đối với những người có trình độ học vấn cao hơn: nam giới có trình độ học vấn thấp nhất (1) có xu hướng có mức lương thấp hơn đáng kể so với những người có trình độ học vấn cao nhất (5). Rõ ràng, dự đoán chính xác nhất về **tiền lương** của một người đàn ông cụ thể sẽ có được bằng cách kết hợp **tuổi tác**, **trình độ học vấn** và **năm** của anh ta. Trong Chương 3, chúng tôi thảo luận về hồi quy tuyến tính, có thể được sử dụng để dự đoán **tiền lương** từ tập dữ liệu này. Lý tưởng nhất, chúng ta nên dự đoán **tiền lương** theo cách tính đến mối quan hệ phi tuyến tính giữa **tiền lương** và **tuổi tác**. Trong Chương 7, chúng tôi thảo luận về một nhóm các phương pháp để giải quyết vấn đề này.

Dữ liệu thị trường chứng khoán

Dữ liệu về **tiền lương** liên quan đến việc dự đoán một giá trị đầu ra liên tục hoặc định lượng. Điều này thường được gọi là bài toán hồi quy. Tuy nhiên, trong một số trường hợp, chúng ta có thể muốn dự đoán một giá trị rời rạc—tức là một kết quả phân loại hoặc định tính. Ví dụ, trong Chương 4, chúng ta xem xét một tập dữ liệu thị trường chứng khoán chứa các biến động hàng ngày của chỉ số chứng khoán Standard & Poor's 500 (S&P) trong khoảng thời gian 5 năm từ năm 2001 đến năm 2005. Chúng ta gọi đây là dữ liệu **Smarket**. Mục tiêu là dự đoán liệu chỉ số sẽ tăng hay giảm vào một ngày nhất định, sử dụng phần trăm thay đổi của chỉ số trong 5 ngày trước đó. Ở đây, bài toán học thống kê không liên quan đến việc dự đoán một giá trị số. Thay vào đó, nó liên quan đến việc dự đoán liệu một giá trị nhất định sẽ tăng hay giảm vào một ngày cụ thể.



HÌNH 1.2. Bên trái: Biểu đồ hộp thể hiện phần trăm thay đổi của chỉ số S&P so với ngày hôm trước. chỉ số cho những ngày thị trường tăng hoặc giảm, được lấy từ Dữ liệu *Smarket*. Giữa và bên phải: Giống như bảng bên trái, nhưng tỷ lệ phần trăm thay đổi. Số liệu của 2 và 3 ngày trước đó được hiển thị.

Diễn biến thị trường chứng khoán trong ngày sẽ thuộc nhóm **Tăng** hoặc nhóm **Giảm**.

thùng. Đây được gọi là bài toán phân loại. Một mô hình có thể

Dự đoán chính xác hướng đi của thị trường sẽ là

Rất hữu ích!

Bảng bên trái của Hình 1.2 hiển thị hai biểu đồ hộp của dữ liệu trước đó.

Tỷ lệ phần trăm thay đổi hàng ngày của chỉ số chứng khoán: một tỷ lệ cho 648 ngày mà

Thị trường tăng giá vào ngày hôm sau, và một lần nữa trong 602 ngày.

Điều này khiến thị trường giảm điểm. Hai biểu đồ trông gần như giống hệt nhau, cho thấy không có chiến lược đơn giản nào để sử dụng diễn biến của ngày hôm qua trong tương lai.

Chỉ số S&P dự đoán lợi nhuận hôm nay. Các biểu đồ còn lại, hiển thị biểu đồ hộp cho phần trăm thay đổi trong 2 và 3 ngày trước hôm nay, cũng tương tự.

Điều này cho thấy mối liên hệ rất ít giữa lợi nhuận trong quá khứ và hiện tại. Tất nhiên, điều này Việc thiếu tính quy luật là điều dễ hiểu: khi có sự tương quan mạnh mẽ giữa lợi nhuận của các ngày liên tiếp, người ta có thể áp dụng một chiến lược giao dịch đơn giản.

để tạo ra lợi nhuận từ thị trường. Tuy nhiên, trong Chương 4, chúng ta sẽ khám phá

Những dữ liệu này được thu thập bằng cách sử dụng một số phương pháp học thống kê khác nhau. Điều thú vị là,

Có những dấu hiệu về một số xu hướng yếu trong dữ liệu cho thấy rằng, ít nhất là

Trong khoảng thời gian 5 năm này, có thể dự đoán chính xác hướng đi của

Biến động trên thị trường chiếm khoảng 60% thời gian (Hình 1.3).

Dữ liệu biểu hiện gen

Hai ứng dụng trước đó minh họa các tập dữ liệu với cả đầu vào và đầu ra.

các biến đầu ra. Tuy nhiên, một loại vấn đề quan trọng khác liên quan đến


các tình huống mà chúng ta chỉ quan sát các biến đầu vào, mà không có sự tương ứng nào khác.

đầu ra. Ví dụ, trong lĩnh vực tiếp thị, chúng ta có thể có dữ liệu nhân khẩu học.

thông tin cho một số khách hàng hiện tại hoặc tiềm năng. Chúng tôi có thể muốn

Hiểu được những loại khách hàng nào tương tự nhau bằng cách nhóm chúng lại.

các cá nhân được phân loại theo đặc điểm quan sát được. Điều này được gọi là



HÌNH 1.3. Chúng tôi đã áp dụng mô hình phân tích phân biệt bậc hai cho tập con dữ liệu **Smarket** tương ứng với giai đoạn 2001-2004 và dự đoán xác suất giảm giá thị trường chứng khoán bằng cách sử dụng dữ liệu năm 2005. Trung bình, xác suất giảm được dự đoán cao hơn vào những ngày thị trường thực sự giảm. Dựa trên kết quả này, chúng tôi có thể dự đoán chính xác hướng chuyển động của thị trường với độ chính xác 60%.


Bài toán phân cụm . Khác với các ví dụ trước, ở đây chúng ta không cố gắng dự đoán một biến đầu ra.

Chương 12 sẽ được dành để thảo luận về các phương pháp học thống kê cho các bài toán không có biến đầu ra tự nhiên. Chúng ta xem xét tập dữ liệu **NCI60** , bao gồm 6.830 phép đo biểu hiện gen cho mỗi trong số 64 dòng tế bào ung thư. Thay vì dự đoán một biến đầu ra cụ thể, chúng ta quan tâm đến việc xác định xem có các nhóm, hay cụm, giữa các dòng tế bào dựa trên các phép đo biểu hiện gen của chúng hay không.

Đây là một câu hỏi khó trả lời, một phần vì có hàng nghìn phép đo biểu hiện gen trên mỗi dòng tế bào, khiến việc trực quan hóa dữ liệu trở nên khó khăn.

Hình 1.4 , bảng bên trái , giải quyết vấn đề này bằng cách biểu diễn mỗi trong số 64 dòng tế bào chỉ bằng hai con số, Z1 và Z2. Đây là hai thành phần chính đầu tiên của dữ liệu, tóm tắt 6.830 phép đo biểu hiện cho mỗi dòng tế bào thành hai con số hoặc hai chiều. Mặc dù việc giảm chiều này có thể dẫn đến một số mất mát thông tin, nhưng giờ đây có thể trực quan kiểm tra dữ liệu để tìm bằng chứng về sự phân cụm. Việc quyết định số lượng cụm thường là một vấn đề khó khăn. Nhưng hình 1.4 , bảng bên trái, cho thấy ít nhất bốn nhóm dòng tế bào, mà chúng tôi đã biểu diễn bằng các màu riêng biệt.

Trong tập dữ liệu cụ thể này, hóa ra các dòng tế bào tương ứng với 14 loại ung thư khác nhau. (Tuy nhiên, thông tin này không được sử dụng để tạo ra bảng bên trái của Hình 1.4.) Bảng bên phải của Hình 1.4 giống hệt bảng bên trái, ngoại trừ việc 14 loại ung thư được hiển thị bằng các ký hiệu màu khác nhau. Có bằng chứng rõ ràng cho thấy các dòng tế bào cùng loại ung thư có xu hướng nằm gần nhau trong biểu diễn hai chiều này. Ngoài ra, mặc dù thông tin về ung thư không được sử dụng để tạo ra bảng bên trái, nhưng sự phân cụm thu được có một số điểm tương đồng với một số loại ung thư thực tế được quan sát trong bảng bên phải. Điều này cung cấp một số xác minh độc lập về độ chính xác của phân tích phân cụm của chúng tôi.



HÌNH 1.4. Bên trái: Biểu diễn tập dữ liệu biểu hiện gen **NCI60** trong một không gian hai chiều, Z1 và Z2. Mỗi điểm tương ứng với một trong 64 các dòng tế bào. Có vẻ như có bốn nhóm dòng tế bào, mà chúng tôi đã trình bày. Sử dụng các màu sắc khác nhau. Bên phải: Giống như bảng bên trái ngoại trừ việc chúng ta đã thể hiện Mỗi loại trong số 14 loại ung thư khác nhau được biểu thị bằng một ký hiệu màu khác nhau. Dòng tế bào Các khối u cùng loại thường nằm gần nhau trong không gian hai chiều.

Lịch sử tóm lược về học máy thống kê

Mặc dù thuật ngữ học thống kê còn khá mới, nhưng nhiều khái niệm trong đó... Các nguyên lý cơ bản của lĩnh vực này đã được phát triển từ lâu. Vào đầu thế kỷ XIX, phương pháp bình phương tối thiểu đã được phát triển, và việc áp dụng phương pháp này đã dẫn đến sự ra đời của nó. Hình thức sơ khai nhất của cái mà ngày nay được gọi là hồi quy tuyến tính. Phương pháp tiếp cận Phương pháp này lần đầu tiên được áp dụng thành công vào các vấn đề trong thiên văn học. Hồi quy tuyến tính Nó được sử dụng để dự đoán các giá trị định lượng, chẳng hạn như mức lương của một cá nhân. Để dự đoán các giá trị định tính, chẳng hạn như liệu bệnh nhân có sống sót hay không. Cho dù một người chết hay thị trường chứng khoán tăng hay giảm, phương pháp phân tích phân biệt tuyến tính đã được đề xuất vào năm 1936. Vào những năm 1940, nhiều tác giả đã đưa ra Đưa ra một phương pháp tiếp cận khác, hồi quy logistic. Vào đầu những năm 1970, Thuật ngữ mô hình tuyến tính tổng quát được phát triển để mô tả toàn bộ một lớp các mô hình tuyến tính tổng quát. các phương pháp học thống kê bao gồm cả hồi quy tuyến tính và hồi quy logistic.

Đến cuối những năm 1970, đã có thêm nhiều kỹ thuật học tập từ dữ liệu. Các phương pháp đó đã có sẵn. Tuy nhiên, chúng hầu như chỉ là các phương pháp tuyến tính vì việc khớp các mối quan hệ phi tuyến tính rất khó khăn về mặt tính toán. thời gian. Đến những năm 1980, công nghệ máy tính cuối cùng đã được cải thiện đủ. Các phương pháp phi tuyến tính không còn đòi hỏi chi phí tính toán quá cao nữa. Vào giữa những năm 1980, cây phân loại và hồi quy được phát triển, tiếp theo đó là... Ngay sau đó, các mô hình cộng tính tổng quát đã trở nên phổ biến. Mạng nơ-ron đã trở nên phổ biến.

Vào những năm 1980, thuật toán máy học hỗ trợ vectơ (Support Vector Machines - SVM) xuất hiện, còn vào những năm 1990 thì có sự ra đời của SVM.

Kể từ thời điểm đó, học máy thống kê đã nổi lên như một lĩnh vực phụ mới trong Thống kê, tập trung vào mô hình hóa và dự đoán có giám sát và không giám sát. Trong những năm gần đây, sự tiến bộ trong học máy thống kê đã được đánh dấu bởi... sự gia tăng về tính sẵn có của các phần mềm mạnh mẽ và tương đối thân thiện với người dùng, chẳng hạn như Là hệ thống **Python** phổ biến và miễn phí, điều này có tiềm năng tiếp tục quá trình chuyển đổi lĩnh vực này từ một tập hợp các kỹ thuật được sử dụng và

6 1. Giới thiệu

Được phát triển bởi các nhà thống kê và nhà khoa học máy tính, nó trở thành một bộ công cụ thiết yếu cho một cộng đồng rộng lớn hơn nhiều.

Cuốn sách này

Cuốn sách "Các yếu tố của học máy thống kê" (ESL) của Hastie, Tibshirani và Friedman được xuất bản lần đầu vào năm 2001. Kể từ đó, nó đã trở thành một tài liệu tham khảo quan trọng về các nguyên tắc cơ bản của học máy thống kê.

Thành công của cuốn sách đến từ cách trình bày toàn diện và chi tiết nhiều chủ đề quan trọng trong học tập thống kê, cũng như việc nó dễ tiếp cận với nhiều đối tượng độc giả (so với nhiều sách giáo khoa thống kê nâng cao khác).

Tuy nhiên, yếu tố quan trọng nhất đằng sau thành công của ESL chính là tính thời sự của nó. Vào thời điểm xuất bản, sự quan tâm đến lĩnh vực học máy thống kê đang bắt đầu bùng nổ. ESL đã cung cấp một trong những tài liệu giới thiệu toàn diện và dễ tiếp cận đầu tiên về chủ đề này.

Kể từ khi cuốn sách ESL được xuất bản lần đầu, lĩnh vực học máy thống kê đã tiếp tục phát triển mạnh mẽ. Sự mở rộng của lĩnh vực này diễn ra theo hai hình thức. Sự phát triển rõ rệt nhất liên quan đến việc phát triển các phương pháp học máy thống kê mới và được cải tiến nhằm trả lời một loạt các câu hỏi khoa học trong nhiều lĩnh vực. Tuy nhiên, lĩnh vực học máy thống kê cũng đã mở rộng đối tượng người dùng. Vào những năm 1990, sự gia tăng sức mạnh tính toán đã tạo ra một làn sóng quan tâm đến lĩnh vực này từ những người không phải là nhà thống kê, những người rất muốn sử dụng các công cụ thống kê tiên tiến để phân tích dữ liệu của họ. Thật không may, bản chất kỹ thuật cao của các phương pháp này có nghĩa là cộng đồng người dùng vẫn chủ yếu bị giới hạn ở các chuyên gia về thống kê, khoa học máy tính và các lĩnh vực liên quan có đủ kiến thức (và thời gian) để hiểu và triển khai chúng.

Trong những năm gần đây, các gói phần mềm mới và được cải tiến đã giúp giảm bớt đáng kể gánh nặng triển khai đối với nhiều phương pháp học thống kê.

Đồng thời, ngày càng có nhiều sự công nhận trong nhiều lĩnh vực, từ kinh doanh đến chăm sóc sức khỏe, di truyền học, khoa học xã hội và hơn thế nữa, rằng học máy thống kê là một công cụ mạnh mẽ với những ứng dụng thực tiễn quan trọng. Kết quả là, lĩnh vực này đã chuyển từ một lĩnh vực chủ yếu mang tính học thuật sang một ngành học chính thống, với tiềm năng ứng dụng khổng lồ.

Xu hướng này chắc chắn sẽ tiếp tục với sự gia tăng đáng kể lượng dữ liệu khổng lồ và phần mềm để phân tích dữ liệu đó.

Mục đích của cuốn sách "Giới thiệu về Học máy Thống kê" (ISL) là tạo điều kiện thuận lợi cho quá trình chuyển đổi học máy thống kê từ lĩnh vực học thuật sang lĩnh vực chính thống. ISL không nhằm mục đích thay thế "ESL", một tài liệu toàn diện hơn nhiều cả về số lượng phương pháp được xem xét và độ sâu nghiên cứu. Chúng tôi coi ESL là một tài liệu tham khảo quan trọng dành cho các chuyên gia (có bằng thạc sĩ về thống kê, máy học hoặc các lĩnh vực liên quan) cần hiểu rõ các chi tiết kỹ thuật đằng sau các phương pháp học máy thống kê. Tuy nhiên, cộng đồng người sử dụng các kỹ thuật học máy thống kê đã mở rộng bao gồm những cá nhân có nhiều sở thích và nền tảng khác nhau. Do đó, cần có một phiên bản ESL ít chuyên sâu về kỹ thuật và dễ tiếp cận hơn.

Qua nhiều năm giảng dạy các chủ đề này, chúng tôi nhận thấy rằng chúng rất quan trọng.

Cuốn sách này sẽ hữu ích cho sinh viên cao học và nghiên cứu sinh tiến sĩ thuộc nhiều lĩnh vực khác nhau, từ kinh doanh đến các lĩnh vực khác.

Điều này rất quan trọng đối với các ngành học đa dạng như quản trị, sinh học và khoa học máy tính, cũng như sinh viên đại học năm cuối có định hướng định lượng.

Nhóm có thể hiểu được các mô hình, trực giác và điểm mạnh và

những điểm yếu của các phương pháp khác nhau. Nhưng đối với đối tượng này, nhiều trong số đó...

Các chi tiết kỹ thuật đằng sau các phương pháp học thống kê, chẳng hạn như thuật toán tối ưu hóa và các thuộc tính lý thuyết, không phải là mối quan tâm chính.

Chúng tôi tin rằng những sinh viên này không cần phải hiểu sâu về những điều này.

các khía cạnh để trở thành người sử dụng thành thạo các phương pháp khác nhau, và

nhằm đóng góp vào lĩnh vực mà họ đã chọn thông qua việc sử dụng thống kê.

Công cụ học tập.

ISL dựa trên bốn tiền đề sau.

1. Nhiều phương pháp học thống kê có liên quan và hữu ích trong nhiều lĩnh vực rộng lớn.

Phạm vi ứng dụng rộng rãi trong nhiều lĩnh vực học thuật và phi học thuật, không chỉ riêng khoa học thống kê. Chúng tôi tin rằng nhiều quy trình học thống kê hiện đại nên và sẽ trở nên phổ biến và được sử dụng rộng rãi hơn.

như trường hợp hiện tại đối với các phương pháp cổ điển như hồi quy tuyến tính. Do đó, thay vì cố gắng xem xét mọi khả năng có thể xảy ra, chúng ta nên xem xét mọi khả năng có thể.

cách tiếp cận (một nhiệm vụ bất khả thi), chúng tôi đã tập trung vào việc trình bày Những phương pháp mà chúng tôi tin là có tính ứng dụng rộng rãi nhất.

2. Học máy thống kê không nên được xem như một loạt các hộp đen. Không

Một phương pháp duy nhất sẽ hoạt động tốt trong mọi ứng dụng có thể. Nếu không hiểu hết các bộ phận bên trong hoặc sự tương tác giữa chúng thì sẽ không hiệu quả.

Trong số các bánh răng đó, không thể chọn ra chiếc hộp tốt nhất. Do đó, chúng ta

Chúng tôi đã cố gắng mô tả cẩn thận mô hình, trực giác, giả định và sự đánh đổi đằng sau mỗi phương pháp mà chúng tôi xem xét.

3. Mặc dù việc biết mỗi bánh răng trong bộ phận nào thực hiện công việc gì là quan trọng, nhưng điều đó không phải lúc nào cũng đúng.

Không nhất thiết phải có kỹ năng chế tạo máy móc bên trong.

hộp! Do đó, chúng tôi đã giảm thiểu việc thảo luận về các chi tiết kỹ thuật liên quan.

phù hợp với các quy trình lắp ráp và các đặc tính lý thuyết. Chúng tôi giả định rằng

Người đọc nắm vững các khái niệm toán học cơ bản, nhưng chúng tôi thì không.

Không nhất thiết phải có bằng thạc sĩ về khoa học toán học. Ví dụ, chúng tôi hầu như đã tránh hoàn toàn việc sử dụng đại số ma trận.

và hoàn toàn có thể hiểu toàn bộ cuốn sách mà không cần bản tóm tắt chi tiết.

Kiến thức về ma trận và vectơ.

4. Chúng tôi cho rằng người đọc quan tâm đến việc áp dụng các phương pháp học thống kê vào

các vấn đề thực tế. Để tạo điều kiện thuận lợi cho việc này, cũng như

Để làm rõ lý do đằng sau các kỹ thuật đã thảo luận, chúng tôi đã dành một phần riêng biệt.

Trong mỗi chương đều có các bài thực hành máy tính. Tại mỗi bài thực hành, chúng tôi sẽ hướng dẫn người đọc.

Thông qua việc áp dụng thực tiễn các phương pháp đã được xem xét trong chương đó. Khi

giảng dạy tài liệu này trong các khóa học của mình, chúng tôi đã dành khoảng một phần ba thời gian trên lớp để thực hành các bài tập thực tế.

các phòng thí nghiệm, và chúng tôi nhận thấy chúng vô cùng hữu ích. Nhiều trong số đó

những sinh viên ít am hiểu về máy tính, những người ban đầu cảm thấy e ngại.

Các phòng thí nghiệm đã dần nắm bắt được mọi thứ trong suốt học kỳ hoặc

học kỳ. Cuốn sách này lần đầu được xuất bản (năm 2013, tái bản lần thứ hai năm 2021).

8 1. Giới thiệu

với các phòng máy tính được viết bằng ngôn ngữ **R**. Kể từ đó, đã có
Nhu cầu về các triển khai bằng **Python** cho các kỹ thuật quan trọng trong học máy thống kê ngày
càng tăng. Do đó, phiên bản này đã được phát triển.
các bài thực hành trong **Python**. Hiện nay có rất nhiều gói **Python** đang được phát triển nhanh
chóng, và bằng cách kiểm tra các lệnh nhập ở đầu...
Trong mỗi bài thực hành, người đọc sẽ thấy rằng chúng tôi đã lựa chọn và sử dụng một cách cẩn thận...
phù hợp nhất. Chúng tôi cũng đã cung cấp thêm một số mã và
Chức năng này có trong gói **ISLP của chúng tôi**. Tuy nhiên, các bài thực hành trong ISL là độc
lập và có thể bỏ qua nếu người đọc muốn sử dụng một phương pháp khác.
gói phần mềm hoặc không muốn áp dụng các phương pháp đã thảo luận
Các vấn đề thực tế.

Ai nên đọc cuốn sách này?

Cuốn sách này dành cho bất cứ ai quan tâm đến việc sử dụng các phương pháp thống kê hiện đại để lập
mô hình và dự đoán từ dữ liệu. Nhóm đối tượng này bao gồm:
các nhà khoa học, kỹ sư, nhà phân tích dữ liệu, nhà khoa học dữ liệu và các chuyên gia định lượng, nhưng cũng có những người ít hơn
Những cá nhân có chuyên môn kỹ thuật, có bằng cấp trong các lĩnh vực phi định lượng như khoa học xã
hội hoặc kinh doanh. Chúng tôi kỳ vọng người đọc sẽ có ít nhất...
Một khóa học thống kê cơ bản. Kiến thức về hồi quy tuyến tính cũng là điều cần thiết.
Hữu ích, mặc dù không bắt buộc, vì chúng ta sẽ xem xét lại các khái niệm chính đằng sau tuyến tính.
Hồi quy trong Chương 3. Trình độ toán học của cuốn sách này ở mức khiêm tốn.
và không yêu cầu kiến thức chi tiết về các phép toán ma trận. Cuốn sách này
Khóa học này cung cấp phần giới thiệu về **Python**. Yêu cầu người học phải có kinh nghiệm lập trình trước đó.
Việc sử dụng các ngôn ngữ lập trình như **MATLAB** hoặc **R** rất hữu ích nhưng không bắt buộc.
Ấn bản đầu tiên của sách giáo khoa này đã được sử dụng để giảng dạy cho sinh viên cao học và
Nghiên cứu sinh tiến sĩ thuộc các ngành kinh doanh, kinh tế, khoa học máy tính, sinh học, khoa học
trái đất, tâm lý học và nhiều lĩnh vực khác thuộc khoa học tự nhiên và xã hội.
Nó cũng được sử dụng để giảng dạy cho sinh viên đại học năm cuối, những người đã...
Đã tham gia một khóa học về hồi quy tuyến tính. Trong bối cảnh một khóa học có tính toán học chặt chẽ
hơn, trong đó ESL đóng vai trò là sách giáo khoa chính, ISL
Có thể được sử dụng như một tài liệu bổ trợ để giảng dạy các khía cạnh tính toán.
trong số các phương pháp tiếp cận khác nhau.

Ký hiệu và Đại số ma trận đơn giản

Việc lựa chọn ký hiệu cho sách giáo khoa luôn là một nhiệm vụ khó khăn. Đối với hầu hết các trường hợp,
Trong phần này, chúng tôi áp dụng các quy ước ký hiệu giống như ESL.
Chúng ta sẽ sử dụng n để biểu thị số lượng điểm dữ liệu riêng biệt, hay quan sát, trong mẫu của
chúng ta. Chúng ta sẽ để p biểu thị số lượng biến số.
có sẵn để sử dụng trong việc đưa ra dự đoán. Ví dụ, tập dữ liệu **Tiền lương** bao gồm 11 biến cho 3.000
người, vì vậy chúng ta có $n = 3.000$ quan sát và
 $p = 11$ biến số (như **năm**, **tuổi**, **chủng tộc**, v.v.). Lưu ý rằng xuyên suốt
Trong cuốn sách này, chúng tôi sử dụng phông chữ màu để chỉ ra tên biến: **Tên biến**.
Trong một số trường hợp, p có thể khá lớn, chẳng hạn như hàng nghìn hoặc thậm chí hàng triệu; tình
huống này xảy ra khá thường xuyên, ví dụ, trong
Phân tích dữ liệu sinh học hiện đại hoặc dữ liệu quảng cáo trên web.

Nhìn chung, ta sẽ ký hiệu x_{ij} là giá trị của biến thứ j cho quan sát thứ i , trong đó $i = 1, 2, \dots, n$ và $j = 1, 2, \dots, p$. Trong suốt cuốn sách này, i sẽ được dùng để chỉ số các mẫu hoặc quan sát (từ 1 đến n) và j sẽ được dùng để chỉ số các biến (từ 1 đến p). Ta ký hiệu X là ma trận $n \times p$ có phần tử (i, j) là x_{ij} . Tức là,

$$X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \dots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix}.$$

Đối với những độc giả chưa quen thuộc với ma trận, việc hình dung X như một bảng tính gồm các số với n hàng và p cột sẽ rất hữu ích.

Đôi khi chúng ta sẽ quan tâm đến các hàng của X , mà ta viết là $x_1, x_2, \dots, x_n$. Ở đây x_i là một vectơ có độ dài p , chứa p giá trị đo biến đổi cho quan sát thứ i . Tức là,

$$x_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{pmatrix}. \quad (1.1)$$

(Theo mặc định, vectơ được biểu diễn dưới dạng cột.) Ví dụ, đối với dữ liệu **Tiền lương**, x_i là một vectơ có độ dài 11, bao gồm **năm**, **tuổi**, **chủng tộc** và các giá trị khác cho cá nhân thứ i . Đôi khi, chúng ta sẽ quan tâm đến các cột của X , mà chúng ta viết là $x_1, x_2, \dots, x_p$. Mỗi cột là một vectơ có độ dài n . Tức là,

$$x_j = \begin{pmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{pmatrix}.$$

Ví dụ, đối với dữ liệu **Tiền lương**, x_1 chứa $n = 3.000$ giá trị cho mỗi **năm**.

Sử dụng ký hiệu này, ma trận X có thể được viết như sau:

$$X = x_1 \ x_2 \ \dots \ x_p,$$

hoặc

$$X = \begin{pmatrix} x_{T1} \\ x_{T2} \\ \vdots \\ x_{Tn} \end{pmatrix}.$$

Cái T Ký hiệu này biểu thị ma trận chuyển vị của một ma trận hoặc vectơ. Ví dụ:

$$X^T = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & & \vdots \\ x_{p1} & x_{p2} & \dots & x_{pn} \end{pmatrix},$$

trong khi

$$\mathbf{x}^T = x_1 \ x_2 \ \cdots \ x_p \ .$$

Chúng ta sử dụng y_i để ký hiệu quan sát thứ i của biến mà chúng ta muốn đưa ra dự đoán, chẳng hạn như **tiền lương**. Do đó, chúng ta viết tập hợp tất cả n quan sát dưới dạng vectơ như sau:

$$\mathbf{y} = \begin{matrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{matrix} \ .$$

Dữ liệu quan sát được của chúng ta bao gồm $\{(x_1,y_1),(x_2,y_2),\dots,(x_n,y_n)\}$, trong đó mỗi x_i là một vectơ có độ dài p . (Nếu $p = 1$, thì x_i chỉ đơn giản là một đại lượng vô hướng.)

Trong văn bản này, vectơ có độ dài n sẽ luôn được ký hiệu bằng chữ thường in đậm; ví dụ:

$$\mathbf{a} = \begin{matrix} a_1 \\ a_2 \\ \vdots \\ \text{MỘT} \end{matrix} \ .$$

Tuy nhiên, các vectơ không có độ dài n (chẳng hạn như các vectơ đặc trưng có độ dài p , như trong (1.1)) sẽ được ký hiệu bằng chữ thường, ví dụ: $\mathbf{ega}$. Các đại lượng vô hướng cũng sẽ được ký hiệu bằng chữ thường, ví dụ : $\mathbf{ega}$. Trong những trường hợp hiếm hoi mà hai cách sử dụng chữ thường này dẫn đến sự mơ hồ, chúng tôi sẽ làm rõ cách sử dụng nào được dự định. Ma trận sẽ được ký hiệu bằng chữ in hoa đậm, ví dụ: $\mathbf{A}$. Các biến ngẫu nhiên sẽ được ký hiệu bằng chữ in hoa thường, ví dụ: A , bất kể kích thước của chúng.

Đôi khi chúng ta cần chỉ ra kích thước của một vật thể cụ thể. Để chỉ ra rằng một đối tượng là một đại lượng vô hướng, chúng ta sẽ sử dụng ký hiệu $a \in \mathbb{R}$. Để chỉ ra rằng nó là một vectơ có độ dài k , chúng ta sẽ sử dụng $\mathbf{a} \in \mathbb{R}^k$ (hoặc $\mathbf{a} \in \mathbb{R}^n$ nếu nó có độ dài n). Chúng ta sẽ chỉ ra rằng một đối tượng là một ma trận $\mathbf{r} \times \mathbf{s}$ bằng cách sử dụng $\mathbf{A} \in \mathbb{R}^{\mathbf{r} \times \mathbf{s}}$.

Chúng tôi đã cố gắng tránh sử dụng đại số ma trận bất cứ khi nào có thể. Tuy nhiên, trong một vài trường hợp, việc tránh hoàn toàn trở nên quá phức tạp. Trong những trường hợp hiếm hoi này, điều quan trọng là phải hiểu khái niệm nhân hai ma trận. Giả sử $\mathbf{A} \in \mathbb{R}^{\mathbf{r} \times \mathbf{d}}$ và $\mathbf{B} \in \mathbb{R}^{\mathbf{d} \times \mathbf{s}}$. Khi đó, tích của $\mathbf{A}$ và $\mathbf{B}$ được ký hiệu là $\mathbf{AB}$. Phần tử (i, j) của $\mathbf{AB}$ được tính bằng cách nhân mỗi phần tử của hàng thứ i của $\mathbf{A}$ với phần tử tương ứng của cột thứ j của $\mathbf{B}$. Tức là, $(\mathbf{AB})_{ij} = \sum_k a_{ik}b_{kj}$. Ví dụ, hãy xem xét

$$\mathbf{A} = \begin{matrix} & & & & dk=1 \\ & & 12 & & \\ & & 34 & & \end{matrix} \quad \text{và} \quad \mathbf{B} = \begin{matrix} & & & & \\ & & 56 & & \\ & & 78 & & \end{matrix} \ .$$

Sau đó

$$\mathbf{AB} = \begin{matrix} & & & & \\ 12 & 34 & 56 & 78 & \\ \end{matrix} = \begin{matrix} & & & & \\ 1 \times 5 + 2 \times 7 & 1 \times 6 + 2 \times 8 & & & \\ 8 \times 5 + 4 \times 7 & 8 \times 6 + 4 \times 8 & & & \end{matrix} = \begin{matrix} & & & & \\ 19 & 22 & & & \\ 43 & 50 & & & \end{matrix} \ .$$

Lưu ý rằng phép toán này tạo ra một ma trận $\mathbf{r} \times \mathbf{s}$. Chỉ có thể tính $\mathbf{AB}$ nếu số cột của $\mathbf{A}$ bằng số hàng của $\mathbf{B}$.

Cấu trúc của cuốn sách này

Chương 2 giới thiệu các thuật ngữ và khái niệm cơ bản về học thống kê. Chương này cũng trình bày bộ phân loại K-nearest neighbor, một thuật toán

Phương pháp rất đơn giản nhưng lại hoạt động hiệu quả đáng ngạc nhiên trên nhiều bài toán. Chương 3 và 4 đề cập đến các phương pháp tuyến tính cổ điển cho hồi quy và phân loại.

Cụ thể, Chương 3 xem xét lại hồi quy tuyến tính, điểm khởi đầu cơ bản cho tất cả các phương pháp hồi quy. Trong Chương 4, chúng ta thảo luận về hai trong số các phương pháp...

Các phương pháp phân loại cổ điển quan trọng nhất bao gồm hồi quy logistic và phân tích phân biệt tuyến tính.

Một vấn đề cốt lõi trong tất cả các tình huống học thống kê liên quan đến việc lựa chọn phương pháp tốt nhất cho một ứng dụng cụ thể. Do đó, trong Chương 5, chúng tôi giới thiệu phương pháp kiểm định chéo và phương pháp bootstrap, có thể được sử dụng để ước tính Đánh giá độ chính xác của một số phương pháp khác nhau để chọn ra phương pháp tốt nhất.

Phần lớn các nghiên cứu gần đây về học máy thống kê đã tập trung vào...

các phương pháp phi tuyến tính. Tuy nhiên, các phương pháp tuyến tính thường có ưu điểm hơn so với các phương pháp khác.

các đối thủ cạnh tranh phi tuyến tính của họ về khả năng giải thích và đôi khi cũng

độ chính xác. Do đó, trong Chương 6, chúng ta sẽ xem xét một loạt các phương pháp tuyến tính, cả hai

Các phương pháp cổ điển và hiện đại hơn, mang lại những cải tiến tiềm năng so với hồi quy tuyến

tính tiêu chuẩn. Chúng bao gồm lựa chọn từng bước, hồi quy Ridge,

Hồi quy thành phần chính và phương pháp Lasso.

Các chương còn lại sẽ đi sâu vào thể giới thống kê phi tuyến tính.

học tập. Trước tiên, trong Chương 7, chúng tôi giới thiệu một số phương pháp phi tuyến tính hoạt động tốt cho các bài toán có một biến đầu vào duy nhất. Sau đó, chúng tôi...

Trình bày cách các phương pháp này có thể được sử dụng để phù hợp với các mô hình cộng tính phi tuyến tính cho

trong đó có nhiều hơn một đầu vào. Trong Chương 8, chúng ta sẽ nghiên cứu về cây dựa trên

các phương pháp, bao gồm bagging, boosting và random forests. Hỗ trợ vectơ

máy móc, một tập hợp các phương pháp để thực hiện cả các phép tính tuyến tính và phi tuyến tính.

Phân loại được thảo luận trong Chương 9. Chúng ta sẽ đề cập đến học sâu, một phương pháp hồi quy và phân loại phi tuyến tính đã nhận được rất nhiều sự quan tâm.

sự chú ý trong những năm gần đây được đề cập trong Chương 10. Chương 11 khám phá về sự sống sót.

phân tích, một phương pháp hồi quy chuyên biệt cho bối cảnh mà trong đó

Biến đầu ra bị kiểm duyệt, tức là không được quan sát đầy đủ.

Trong Chương 12, chúng ta xem xét thiết lập không giám sát trong đó chúng ta có

các biến đầu vào nhưng không có biến đầu ra. Cụ thể, chúng tôi trình bày phân tích thành phần chính, phân cụm K-means và phân cụm phân cấp.

Cuối cùng, trong Chương 13, chúng ta sẽ đề cập đến chủ đề rất quan trọng về kiểm định đa giả thuyết.

Cuối mỗi chương, chúng tôi trình bày một hoặc nhiều phần thực hành Python.

Trong đó, chúng ta sẽ hệ thống hóa việc ứng dụng các phương pháp khác nhau đã được thảo luận trong

chương đó. Các bài thực hành này minh họa những ưu điểm và nhược điểm của các phương pháp.

những điểm yếu của các phương pháp khác nhau, đồng thời cung cấp một tài liệu tham khảo hữu ích.

Về cú pháp cần thiết để triển khai các phương thức khác nhau. Người đọc có thể

Sinh viên có thể lựa chọn làm bài thực hành theo tốc độ riêng của mình, hoặc các bài thực hành có thể là...

trọng tâm của các buổi học nhóm như một phần của môi trường lớp học. Trong mỗi buổi học nhóm

Trong bài thực hành Python, chúng tôi trình bày kết quả thu được khi thực hiện các bước sau: phòng thí nghiệm tại thời điểm viết cuốn sách này. Tuy nhiên, các phiên bản Python mới hơn...

được phát hành liên tục, và theo thời gian, các gói được gọi trong phòng thí nghiệm sẽ

có thể được cập nhật. Do đó, trong tương lai, có thể kết quả hiển thị trong

Tên	Sự miêu tả
Tư đồ ng	Mức tiêu hao nhiên liệu, mã lực và các thông tin khác về xe hơi.
Chia sẻ xe đạp	Lượng sử dụng dịch vụ chia sẻ xe đạp theo giờ tại Washington, DC.
Boston	Giá trị nhà ở và các thông tin khác về các khu vực thống kê dân số của Boston.
Thời gian sống sót của bệnh nhân ung thư não .	
Thông tin về các cá nhân cung cấp bảo hiểm xe caravan.	
Ghế ngồi ô tô	Thông tin về doanh số bán ghế ngồi ô tô cho trẻ em tại 400 cửa hàng.
Trường cao đẳng	Đặc điểm nhân khẩu học, học phí và nhiều thông tin khác về các trường đại học tại Hoa Kỳ.
Tín dụng	Thông tin về nợ thẻ tín dụng của 400 khách hàng.
Mặc định	Hồ sơ nợ quá hạn của khách hàng tại một công ty thẻ tín dụng.
Quý	Lợi nhuận của 2.000 nhà quản lý quỹ đầu cơ trong vòng 50 tháng.
Người đánh bóng	Thành tích và mức lương của các cầu thủ bóng chày.
Khan	Đo lường biểu hiện gen đối với bốn loại ung thư.
NCI60	Đo lường biểu hiện gen của 64 dòng tế bào ung thư.
NYSE	Lợi nhuận, biến động và khối lượng giao dịch của Sở Giao dịch Chứng khoán New York.
OJ	Thông tin bán hàng về nước cam Citrus Hill và Minute Maid.
Thời gian công	Giá trị quá khứ của các tài sản tài chính, được sử dụng trong việc phân bổ danh mục đầu tư.
bổ danh mục đầu tư	Thời gian công bố cho 244 thử nghiệm lâm sàng.
Smarket	Tỷ lệ lợi nhuận hàng ngày của chỉ số S&P 500 trong vòng 5 năm.
Hoa Kỳ bắt giữ	Thống kê tội phạm trên 100.000 cư dân tại 50 tiểu bang của Hoa Kỳ.
Tiê n công	Dữ liệu khảo sát thu nhập của nam giới tại khu vực Trung Đại Tây Dương của Hoa Kỳ.
Hàng tuần	1.089 lợi nhuận thị trường chứng khoán hàng tuần trong 21 năm.

BẢNG 1.1. Danh sách các bộ dữ liệu cần thiết để thực hiện các thí nghiệm và bài tập trong tài liệu này. sách giáo khoa. Tất cả các bộ dữ liệu đều có sẵn trong gói **ISLP** , ngoại trừ...

USArrests là một phần của bản phân phối **R** cơ bản , nhưng có thể truy cập được từ **Python**.

Các phần thí nghiệm có thể không còn hoàn toàn tương ứng với kết quả thu được.
Do người đọc thực hiện các thí nghiệm. Khi cần thiết, chúng tôi sẽ đăng tải các bản cập nhật.
Các bài thực hành thí nghiệm trên trang web của cuốn sách.

Chúng tôi sử dụng  ký hiệu dùng để chỉ các phần hoặc bài tập có chứa nhiều hơn những khái niệm khó hiểu. Những người đọc không hiểu có thể dễ dàng bỏ qua chúng. những người muốn tìm hiểu sâu hơn về tài liệu, hoặc những người thiếu kiến thức toán học. lý lịch.

Bộ dữ liệu được sử dụng trong các bài thực hành và bài tập.

Trong sách giáo khoa này, chúng tôi minh họa các phương pháp học thống kê bằng cách sử dụng các ứng dụng từ lĩnh vực tiếp thị, tài chính, sinh học và các lĩnh vực khác. Gói **ISLP** chứa một số tập dữ liệu cần thiết để thực hiện việc đó.
Các bài thực hành và bài tập liên quan đến cuốn sách này. Một bộ dữ liệu khác là một phần của...
Bản phân phối **R** cơ bản (dữ liệu **USArrests**), và chúng tôi sẽ hướng dẫn cách truy cập nó.
Trích từ **Python** trong Mục **12.5.1**. Bảng **1.1** chứa tóm tắt dữ liệu.
Các bộ dữ liệu cần thiết để thực hiện các bài thí nghiệm và bài tập. Một vài trong số các bộ dữ liệu này.
Các tài liệu này cũng có sẵn dưới dạng tệp văn bản trên trang web của cuốn sách, để sử dụng trong Chương 2.

Trang web đặt sách

Trang web của cuốn sách này nằm tại địa chỉ:

www.statlearning.com

Nó chứa một số tài nguyên, bao gồm gói `Python` liên kết với cuốn sách này và một số bộ dữ liệu bổ sung.

Lời cảm ơn

Một vài đồ thị trong cuốn sách này được lấy từ ESL: Hình 6.7, 8.3 và 12.14. Tất cả các đồ thị khác được tạo ra cho phiên bản `R` của ISL, ngoại trừ Hình 13.10 khác biệt do phần mềm `Python` hỗ trợ đồ thị này.

2

Học thống kê



2.1 Học máy thống kê là gì?

Để làm rõ hơn lý do chúng ta nghiên cứu về học máy thống kê, chúng ta bắt đầu với một ví dụ đơn giản. Giả sử chúng ta là các chuyên gia tư vấn thống kê được một khách hàng thuê để điều tra mối liên hệ giữa quảng cáo và doanh số bán hàng của một sản phẩm cụ thể. Tập dữ liệu **Quảng cáo** bao gồm doanh số **bán hàng** của sản phẩm đó tại 200 thị trường khác nhau, cùng với ngân sách quảng cáo cho sản phẩm đó tại mỗi thị trường trên ba phương tiện truyền thông khác nhau: **truyền hình**, **radio** và **báo chí**.

Dữ liệu được hiển thị trong Hình 2.1. Khách hàng của chúng ta không thể trực tiếp tăng doanh số bán sản phẩm. Mặt khác, họ có thể kiểm soát chi phí quảng cáo trên mỗi trong ba phương tiện truyền thông. Do đó, nếu chúng ta xác định được mối liên hệ giữa quảng cáo và doanh số bán hàng, thì chúng ta có thể hướng dẫn khách hàng điều chỉnh ngân sách quảng cáo, từ đó gián tiếp tăng doanh số bán hàng. Nói cách khác, mục tiêu của chúng ta là phát triển một mô hình chính xác có thể được sử dụng để dự đoán doanh số bán hàng dựa trên ngân sách của ba phương tiện truyền thông.

Trong bối cảnh này, ngân sách quảng cáo là các biến đầu vào, trong khi **doanh số bán hàng** là biến đầu ra. Các biến đầu vào thường được ký hiệu bằng chữ X, kèm theo chỉ số dưới để phân biệt. Ví dụ, X1 có thể là ngân sách **truyền hình**, X2 là ngân sách **radio**, và X3 là ngân sách **báo chí**. Các biến đầu vào có nhiều tên gọi khác nhau, chẳng hạn như biến dự báo, biến độc lập, đặc trưng, hoặc đôi khi chỉ đơn giản là biến số. Biến đầu ra—trong trường hợp này là **doanh số bán hàng**—thường được gọi là biến phản hồi hoặc biến phụ thuộc, và thường được ký hiệu bằng chữ Y. Trong suốt cuốn sách này, chúng ta sẽ sử dụng tất cả các thuật ngữ này một cách thay thế cho nhau.

Tổng quát hơn, giả sử chúng ta quan sát được một biến phản hồi định lượng Y và p biến dự báo khác nhau, X1, X2, ..., Xp. Chúng ta giả định rằng có một mối quan hệ nào đó giữa Y và $X = (X1, X2, \dots, Xp)$, có thể được viết dưới dạng rất tổng quát.

$$Y = f(X) + \epsilon \quad (2.1)$$

biến
đầu vào
biến đầu
ra


biến độc
lập dự đoán

tính năng

biến

phản ứng


biến phụ thuộc



HÌNH 2.1. Bộ dữ liệu Quảng cáo . Biểu đồ hiển thị doanh số bán hàng, tính bằng nghìn số lượng đơn vị, tùy thuộc vào ngân sách của truyền hình, đài phát thanh và báo chí , tính bằng nghìn đơn vị. đó là, cho 200 thị trường khác nhau. Trong mỗi biểu đồ, chúng tôi hiển thị phương pháp bình phương tối thiểu đơn giản. sự phù hợp của doanh số với biến số đó, như đã mô tả trong Chương 3. Nói cách khác, mỗi màu xanh lam Đường thẳng biểu thị một mô hình đơn giản có thể được sử dụng để dự đoán doanh số bán hàng dựa trên thông tin từ truyền hình, radio, v.v. và báo chí, tương ứng.

Ở đây f là một hàm cố định nhưng chưa biết của $X_1, \dots, X_p$, và là một biến ngẫu nhiên. sai số, không phụ thuộc vào X và có giá trị trung bình bằng 0. Trong công thức này, f biểu thị thông tin có hệ thống mà X cung cấp về Y .

thuật ngữ lỗi
có hệ thống



HÌNH 2.2. Tập dữ liệu Thu nhập . Bên trái: Các chấm đỏ là các giá trị quan sát được. thu nhập (tính bằng nghìn đô la) và số năm học vấn của 30 cá nhân. Bên phải: Đường cong màu xanh biểu thị mối quan hệ thực sự tiềm ẩn giữa thu nhập và số năm học vấn, điều này thường không được biết đến (nhưng trong trường hợp này thì được biết đến) (vì dữ liệu được mô phỏng). Các đường màu đen biểu thị sai số liên quan với mỗi lần quan sát. Lưu ý rằng một số lỗi là dương (nếu một quan sát nằm) (phía trên đường cong màu xanh) và một số là âm (nếu quan sát nằm dưới) (đường cong). Nhìn chung, những sai số này có giá trị trung bình xấp xỉ bằng không.

Ví dụ khác, hãy xem xét bảng bên trái của Hình 2.2, một đồ thị của Mối quan hệ giữa thu nhập và số năm học vấn của 30 cá nhân trong bộ dữ liệu Thu nhập . Cốt truyện cho thấy người ta có thể dự đoán thu nhập bằng cách sử dụng số năm kinh nghiệm. giáo dục. Tuy nhiên, hàm f kết nối biến đầu vào với

Biến đầu ra nói chung là không xác định. Trong trường hợp này, người ta phải ước tính f dựa trên các điểm quan sát được. Vì **Thu nhập** là một tập dữ liệu mô phỏng, nên f đã biết và được thể hiện bằng đường cong màu xanh lam ở bảng bên phải của Hình 2.2.

Các đường thẳng đứng biểu thị các sai số. Chúng ta nhận thấy rằng một số trong 30 quan sát nằm phía trên đường cong màu xanh lam và một số nằm phía dưới; nhìn chung, các sai số có giá trị trung bình xấp xỉ bằng không.

Nhìn chung, hàm f có thể liên quan đến nhiều hơn một biến đầu vào. Trong Hình 2.3, chúng ta biểu diễn **thu nhập** như một hàm của **số năm học vấn** và **thâm niên**. Ở đây, f là một mặt phẳng hai chiều cần được ước tính dựa trên dữ liệu quan sát được.

Về bản chất, học thống kê đề cập đến một tập hợp các phương pháp để ước lượng f . Trong chương này, chúng ta sẽ phác thảo một số khái niệm lý thuyết chính phát sinh trong việc ước lượng f , cũng như các công cụ để đánh giá các ước lượng thu được.

2.1.1 Tại sao cần ước lượng f ?

Có hai lý do chính khiến chúng ta muốn ước tính f : dự đoán và suy luận. Chúng ta sẽ thảo luận từng lý do một.

Dự đoán

Trong nhiều trường hợp, tập hợp các đầu vào X có sẵn, nhưng đầu ra Y lại không dễ dàng thu được. Trong trường hợp này, vì sai số trung bình bằng không, ta có thể dự đoán Y bằng cách sử dụng

$$\hat{Y} = \hat{f}(X), \tag{2.2}$$
 trong đó $\hat{f}$ biểu thị ước tính của


chúng ta cho f , và $\hat{Y}$ biểu thị dự đoán kết quả cho Y . Trong trường hợp này, $\hat{f}$ thường được coi là một hộp đen, theo nghĩa là người ta thường không quan tâm đến dạng chính xác của $\hat{f}$, miễn là nó đưa ra dự đoán chính xác cho Y .

Ví dụ, giả sử $X_1, \dots, X_p$ là các đặc điểm của mẫu máu bệnh nhân có thể dễ dàng đo được trong phòng thí nghiệm, và Y là một biến số mã hóa nguy cơ phản ứng phụ nghiêm trọng của bệnh nhân đối với một loại thuốc cụ thể. Việc tìm cách dự đoán Y bằng cách sử dụng X là điều tự nhiên, vì khi đó chúng ta có thể tránh việc kê đơn thuốc đó cho những bệnh nhân có nguy cơ phản ứng phụ cao—nghĩa là những bệnh nhân mà ước tính của Y cao.

Độ chính xác của $\hat{Y}$ như một dự đoán cho Y phụ thuộc vào hai đại lượng, mà chúng ta sẽ gọi là sai số có thể giảm thiểu và sai số không thể giảm thiểu. Nói chung, $\hat{f}$ sẽ không phải là một ước lượng hoàn hảo cho f , và sự không chính xác này sẽ gây ra một số sai số. Sai số này có thể giảm thiểu vì chúng ta có thể cải thiện độ chính xác của $\hat{f}$ bằng cách sử dụng kỹ thuật học thống kê phù hợp nhất để ước lượng f . Tuy nhiên, ngay cả khi có thể tạo ra một ước lượng hoàn hảo cho f , sao cho phân hồi ước lượng của chúng ta có dạng $\hat{Y} = f(X)$, thì dự đoán của chúng ta vẫn sẽ có một số sai số! Điều này là do Y cũng là một hàm của ϵ , mà theo định nghĩa, không thể được dự đoán bằng X . Do đó, sự biến thiên liên quan đến cũng ảnh hưởng đến độ chính xác của các dự đoán của chúng ta. Điều này được gọi là sai số không thể giảm thiểu, bởi vì cho dù chúng ta ước lượng f tốt đến đâu, chúng ta cũng không thể giảm thiểu sai số do gây ra.

Tại sao sai số không thể giảm thiểu lại lớn hơn không? Đại lượng này có thể chứa các biến chưa được đo lường nhưng hữu ích trong việc dự đoán Y : vì chúng ta không

có thể giảm
lỗi
không thể giảm thiểu
lỗi



HÌNH 2.3. Đồ thị thể hiện thu nhập theo số năm học.

và thâm niên trong tập dữ liệu Thu nhập. Bề mặt màu xanh lam thể hiện giá trị thực.

mối quan hệ cơ bản giữa thu nhập, số năm học và thâm niên.

Điều này đã được biết vì dữ liệu được mô phỏng. Các chấm đỏ biểu thị dữ liệu quan sát được.

Giá trị của các đại lượng này đối với 30 cá nhân.

do chúng, f không thể sử dụng chúng để dự đoán. Đại lượng có thể cũng chứa đựng những biến động không thể đo lường được. Ví dụ, nguy cơ xảy ra tác dụng phụ Phản ứng có thể khác nhau ở mỗi bệnh nhân vào cùng một ngày, tùy thuộc vào... sự khác biệt trong quá trình sản xuất thuốc hoặc cảm nhận chung của bệnh nhân về sức khỏe vào ngày hôm đó.

Xét một ước lượng $\hat{f}$ cho trước và một tập hợp các biến dự báo X , từ đó suy ra

Dự đoán $\hat{Y} = \hat{f}(X)$. Giả sử trong giây lát cả $\hat{f}$ và X đều cố định, do đó sự biến thiên duy nhất đến từ ϵ . Khi đó, dễ dàng chứng minh rằng

$$\begin{aligned} E(Y - \hat{Y})^2 &= E[f(X) + \epsilon - \hat{f}(X)]^2 \\ &= E[f(X) - \hat{f}(X)]^2 + E[\epsilon^2] + 2E[(f(X) - \hat{f}(X))\epsilon] \end{aligned} \quad (2.3)$$

Có thể thu nhỏ Không thể giảm lược

trong đó $E(Y - \hat{Y})^2$ biểu thị giá trị trung bình, hay giá trị kỳ vọng, của bình phương hiệu số giữa giá trị dự đoán và giá trị thực tế của Y và $\text{Var}(\epsilon)$ biểu thị phương sai, liên quan đến số hạng sai số.

hy vọng
giá trị
phương sai

Trọng tâm của cuốn sách này là các kỹ thuật ước lượng f với mục đích giảm thiểu sai số có thể giảm thiểu. Điều quan trọng cần ghi nhớ là Sai số không thể giảm thiểu sẽ luôn cung cấp giới hạn trên cho độ chính xác của Dự đoán của chúng tôi về Y . Giới hạn này hầu như luôn không được biết đến trong thực tế.

Suy luận

Chúng ta thường quan tâm đến việc hiểu mối liên hệ giữa Y và $X_1, \dots, X_p$. Trong trường hợp này, chúng ta muốn ước tính f , nhưng mục tiêu của chúng ta không phải là nhất thiết phải đưa ra dự đoán cho Y . Giờ đây $\hat{f}$ không thể được coi là một màu đen hộp, vì chúng ta cần biết hình dạng chính xác của nó. Trong trường hợp này, người ta có thể Tôi quan tâm đến việc trả lời các câu hỏi sau:

- Những yếu tố dự báo nào liên quan đến phản hồi? Thường thì là như vậy chỉ một phần nhỏ trong số các yếu tố dự báo có sẵn là đáng kể. liên quan đến Y . Xác định một vài yếu tố dự báo quan trọng trong số đó. Một tập hợp lớn các biến số khả thi có thể cực kỳ hữu ích, tùy thuộc vào Ứng dụng.
- Mối quan hệ giữa biến phản hồi và từng biến dự báo là gì?
Một số biến dự báo có thể có mối quan hệ tích cực với Y , nghĩa là, theo nghĩa là giá trị lớn hơn của biến dự báo sẽ tương ứng với giá trị lớn hơn của Y . Các yếu tố dự báo khác có thể có mối quan hệ ngược lại. Tùy thuộc vào... về độ phức tạp của f , mối quan hệ giữa phản hồi và a
Biến dự báo đã cho cũng có thể phụ thuộc vào giá trị của các biến dự báo khác.
- Liệu mối quan hệ giữa Y và mỗi biến dự báo có thể được tóm tắt đầy đủ bằng một phương trình tuyến tính hay mối quan hệ đó phức tạp hơn? Trong lịch sử, hầu hết các phương pháp ước tính f đều sử dụng phương trình tuyến tính. hình thức. Trong một số trường hợp, giả định như vậy là hợp lý hoặc thậm chí là đáng mong muốn. Nhưng thường thì mối quan hệ thực sự phức tạp hơn, trong đó trong trường hợp này, mô hình tuyến tính có thể không cung cấp sự biểu diễn chính xác của Mối quan hệ giữa các biến đầu vào và đầu ra.

Trong cuốn sách này, chúng ta sẽ xem xét một số ví dụ phù hợp với dự đoán. cài đặt, cài đặt suy luận, hoặc sự kết hợp của cả hai.

Ví dụ, hãy xem xét một công ty quan tâm đến việc tiến hành một Chiến dịch tiếp thị trực tiếp. Mục tiêu là xác định những cá nhân nào... Dựa trên các quan sát về các biến số nhân khẩu học được đo lường trên từng cá nhân, một người có khả năng phản hồi tích cực với thư quảng cáo. Trong trường hợp này, các biến số nhân khẩu học đóng vai trò là yếu tố dự báo, và phản hồi đối với chiến dịch tiếp thị (tích cực hoặc tiêu cực) đóng vai trò là kết quả. Công ty không quan tâm đến việc hiểu sâu sắc mối quan hệ giữa từng biến dự báo riêng lẻ và biến phản hồi; thay vào đó, công ty
Mục đích đơn giản là muốn dự đoán chính xác phản hồi bằng cách sử dụng các biến dự báo. Điều này Đây là một ví dụ về mô hình dự đoán.

Ngược lại, hãy xem xét dữ liệu **Quảng cáo** được minh họa trong Hình 2.1. Một có thể quan tâm đến việc trả lời các câu hỏi như:

- Những phương tiện truyền thông nào liên quan đến doanh số bán hàng?
 - Phương tiện truyền thông nào tạo ra sự thúc đẩy doanh số lớn nhất?
 - Mức tăng doanh số tương ứng với một mức tăng nhất định là bao nhiêu?
- Trong quảng cáo truyền hình?

Tình huống này thuộc về mô hình suy luận. Một ví dụ khác liên quan đến... Mô hình hóa thương hiệu của một sản phẩm mà khách hàng có thể mua dựa trên... Các biến số như giá cả, vị trí cửa hàng, mức chiết khấu, giá của đối thủ cạnh tranh, vân vân. Trong tình huống này, người ta có thể thực sự quan tâm nhất đến... Mối liên hệ giữa mỗi biến số và xác suất mua hàng. Ví dụ, giá sản phẩm có liên quan đến doanh số bán hàng đến mức độ nào? Điều này là
Một ví dụ về mô hình hóa để suy luận.

Cuối cùng, một số mô hình có thể được thực hiện cả để dự đoán và suy luận. Ví dụ, trong lĩnh vực bất động sản, người ta có thể tìm cách liên hệ các giá trị.

Các yếu tố ảnh hưởng đến số lượng nhà ở bao gồm tỷ lệ tội phạm, quy hoạch khu vực, khoảng cách từ sông, chất lượng không khí. Chất lượng, trường học, mức thu nhập của cộng đồng, diện tích nhà ở, v.v. Trong trường hợp này, người ta có thể quan tâm đến mối liên hệ giữa từng biến đầu vào riêng lẻ và giá nhà ở – ví dụ, một người sẽ phải trả thêm bao nhiêu tiền nếu... Ngôi nhà sẽ đáng giá bao nhiêu nếu nó có tầm nhìn ra sông? Đây là một bài toán suy luận. Hoặc đơn giản hơn, người ta có thể chỉ quan tâm đến việc dự đoán giá trị của một Xét về các đặc điểm của ngôi nhà: Ngôi nhà này đang được định giá thấp hay cao hơn giá trị thực ? một bài toán dự đoán.

Tùy thuộc vào việc mục tiêu cuối cùng của chúng ta là dự đoán, suy luận hay... Sự kết hợp của cả hai, các phương pháp khác nhau để ước tính f có thể phù hợp. Ví dụ, mô hình tuyến tính cho phép suy luận tương đối đơn giản và dễ hiểu, nhưng có thể không đưa ra dự đoán chính xác như một số phương pháp khác. mô hình tuyến tính

các phương pháp tiếp cận khác. Ngược lại, một số phương pháp tiếp cận phi tuyến tính cao Những điều mà chúng ta sẽ thảo luận trong các chương sau của cuốn sách này có thể mang lại Các dự đoán khá chính xác cho Y nhưng điều này lại phải trả giá bằng độ chính xác thấp hơn. mô hình có thể giải thích được nhưng việc suy luận lại khó khăn hơn.

2.1.2 Làm thế nào để ước tính f?

Xuyên suốt cuốn sách này, chúng ta sẽ khám phá nhiều phương pháp tuyến tính và phi tuyến tính. Để ước tính f. Tuy nhiên, nhìn chung các phương pháp này đều có một số đặc điểm chung. Chúng tôi sẽ cung cấp tổng quan về những đặc điểm chung này trong phần này. phần. Chúng ta sẽ luôn giả định rằng chúng ta đã quan sát được một tập hợp n khác nhau điểm dữ liệu. Ví dụ, trong Hình 2.2, chúng ta quan sát được n = 30 điểm dữ liệu. Những quan sát này được gọi là dữ liệu huấn luyện vì chúng ta sẽ sử dụng những quan sát này để huấn luyện, hay dạy, phương pháp của chúng ta cách ước lượng f. Đặt x_j biểu thị giá trị của biến dự đoán thứ j, hay đầu vào, cho quan sát thứ i, trong đó i = 1, 2, ..., n và j = 1, 2, ..., p. Tương ứng, hãy để y_i đại diện cho biến phản hồi cho quan sát thứ i. Sau đó, dữ liệu huấn luyện của chúng ta bao gồm {(x₁,y₁),(x₂,y₂),...,(x_n,y_n)} trong đó x_i=(x_{i1},x_{i2},...,x_{ip})^T .

Mục tiêu của chúng tôi là áp dụng phương pháp học thống kê vào dữ liệu huấn luyện. để ước lượng hàm f chưa biết. Nói cách khác, chúng ta muốn Tìm một hàm $\hat{f}$ sao cho $\hat{Y} = \hat{f}(X)$ đối với bất kỳ quan sát nào (X, Y). Nói một cách tổng quát Nói chung, hầu hết các phương pháp học thống kê cho nhiệm vụ này có thể được phân loại là tham số hoặc phi tham số. Bây giờ chúng ta sẽ thảo luận ngắn gọn về hai loại phương pháp này.


Phương pháp tham số

Các phương pháp tham số bao gồm cách tiếp cận dựa trên mô hình gồm hai bước.

- 1. Đầu tiên, chúng ta đưa ra một giả định về hình thức chức năng, hay hình dạng. của f. Ví dụ, một giả định rất đơn giản là f là tuyến tính trong X:

$$f(X)= \beta_0 + \beta_1X_1 + \beta_2X_2 + \cdots + \beta_pX_p. \tag{2.4}$$

Đây là một mô hình tuyến tính, sẽ được thảo luận chi tiết trong Chương 3. Một khi chúng ta đã giả định rằng f là tuyến tính, vấn đề ước lượng f sẽ được đơn giản hóa rất nhiều. Thay vì phải ước lượng một hàm hoàn toàn khác, chúng ta chỉ cần ước lượng một hàm tuyến tính. hàm p chiều tùy ý f(X), người ta chỉ cần ước tính p + 1 hệ số $\beta_0, \beta_1, \dots, \beta_p$.



HÌNH 2.4. Mô hình tuyến tính được hiệu chỉnh bằng phương pháp bình phương nhỏ nhất cho dữ liệu Thu nhập từ Hình 2.3. Các quan sát được hiển thị bằng màu đỏ, và mặt phẳng màu vàng biểu thị...

Phương pháp bình phương tối thiểu phù hợp với dữ liệu.

2. Sau khi mô hình đã được chọn, chúng ta cần một quy trình sử dụng mô hình đó. dữ liệu huấn luyện để phù hợp hoặc huấn luyện mô hình. Trong trường hợp mô hình tuyến tính (2.4), chúng ta cần ước tính các tham số $\beta_0, \beta_1, \dots, \beta_p$. Tức là, chúng ta muốn tìm giá trị của các tham số này sao cho

$$Y \approx \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p.$$


Cách tiếp cận phổ biến nhất để phù hợp với mô hình (2.4) được đề cập đến như phương pháp bình phương tối thiểu (thông thường), mà chúng ta sẽ thảo luận trong Chương 3. Tuy nhiên, bình phương tối thiểu chỉ là một trong nhiều cách có thể để phù hợp với mô hình tuyến tính. Trong Chương 6, chúng ta sẽ thảo luận về các phương pháp khác để ước lượng các tham số. trong (2.4).

Phương pháp dựa trên mô hình vừa mô tả được gọi là phương pháp tham số; Nó đơn giản hóa vấn đề ước lượng f thành vấn đề ước lượng một tập hợp các tham số. Giả sử dạng tham số cho f sẽ đơn giản hóa vấn đề của ước tính f vì nhìn chung việc ước tính một tập hợp các tham số, chẳng hạn như $\beta_0, \beta_1, \dots, \beta_p$ trong mô hình tuyến tính (2.4), dễ dàng hơn nhiều so với việc điều chỉnh một hàm f hoàn toàn tùy ý. Nhược điểm tiềm tàng của phương pháp tham số là mô hình chúng ta chọn thường sẽ không khớp với thực tế.

dạng f chưa biết. Nếu mô hình được chọn quá khác biệt so với f thực sự, thì Ước tính của chúng ta sẽ không chính xác. Chúng ta có thể cố gắng giải quyết vấn đề này bằng cách chọn các mô hình linh hoạt có thể phù hợp với nhiều dạng hàm khác nhau cho f . Nhưng nhìn chung, việc phù hợp với một mô hình linh hoạt hơn đòi hỏi phải ước tính một số lượng tham số lớn hơn. Các mô hình phức tạp hơn này có thể dẫn đến Hiện tượng này được gọi là quá khớp dữ liệu, về cơ bản có nghĩa là dữ liệu bám sát các lỗi, hay nhiễu, quá mức. Những vấn đề này được thảo luận xuyên suốt cuốn sách này.

Hình 2.4 minh họa một ví dụ về phương pháp tham số được áp dụng cho Dữ liệu thu nhập từ Hình 2.3. Chúng tôi đã điều chỉnh một mô hình tuyến tính có dạng

$$\text{thu nhập} \approx \beta_0 + \beta_1 \times \text{trình độ học vấn} + \beta_2 \times \text{thâm niên}.$$



HÌNH 2.5. Đường cong spline mỏng, mượt mà được khớp với dữ liệu **Thu nhập** từ Hình 2.3 được hiển thị bằng màu vàng; các quan sát được hiển thị bằng màu đỏ. Đường cong spline được thảo luận trong Chương 7.

Vì chúng ta đã giả định mối quan hệ tuyến tính giữa biến phản hồi và hai biến dự báo, toàn bộ bài toán khớp dữ liệu được thu gọn lại thành việc ước lượng β_0 , β_1 và β_2 , mà chúng ta thực hiện bằng phương pháp hồi quy tuyến tính bình phương tối thiểu. So sánh Hình 2.3 với Hình 2.4, ta có thể thấy rằng đường khớp tuyến tính trong Hình 2.4 không hoàn toàn chính xác: hàm f thực sự có một số độ cong mà đường khớp tuyến tính không thể hiện được.

Tuy nhiên, mô hình tuyến tính vẫn thể hiện khá tốt mối quan hệ tích cực giữa **số năm học** và **thu nhập**, cũng như mối quan hệ ít tích cực hơn giữa **thâm niên** và **thu nhập**. Có lẽ với số lượng quan sát ít ỏi như vậy, đây là kết quả tốt nhất chúng ta có thể đạt được.


Phương pháp phi tham số

Các phương pháp phi tham số không đưa ra giả định rõ ràng nào về dạng hàm của f . Thay vào đó, chúng tìm kiếm một ước lượng của f càng gần với các điểm dữ liệu càng tốt mà không quá thô hoặc không chính xác. Những cách tiếp cận này có thể có một lợi thế lớn so với các cách tiếp cận tham số: bằng cách tránh giả định về một dạng hàm cụ thể cho f , chúng có tiềm năng phù hợp chính xác với một phạm vi rộng hơn các dạng hàm có thể có của f . Bất kỳ cách tiếp cận tham số nào cũng tiềm ẩn khả năng dạng hàm được sử dụng để ước lượng f rất khác với f thực sự, trong trường hợp đó mô hình thu được sẽ không phù hợp với dữ liệu. Ngược lại, các cách tiếp cận phi tham số hoàn toàn tránh được nguy hiểm này, vì về cơ bản không có giả định nào về dạng của f được đưa ra. Nhưng các cách tiếp cận phi tham số lại có một nhược điểm lớn: vì chúng không giảm vấn đề ước lượng f xuống một số lượng nhỏ các tham số, nên cần một số lượng lớn các quan sát (nhiều hơn nhiều so với số lượng thường cần thiết cho một cách tiếp cận tham số) để có được một ước lượng chính xác cho f .

Hình 2.5 minh họa một ví dụ về phương pháp phi tham số để khớp dữ liệu **Thu nhập**. Phương pháp spline dạng tấm mỏng được sử dụng để ước tính f . Phương pháp này không áp đặt bất kỳ mô hình nào được xác định trước lên f . Thay vào đó, nó cố gắng...

rãnh then
mỏng

2.1 Học thống kê là gì? 23



HÌNH 2.6. Đường cong spline mỏng thô phù hợp với dữ liệu **Thu nhập** từ Hình 2.3. Mô hình này không mắc lỗi nào trên dữ liệu huấn luyện.

Mục tiêu là đưa ra ước tính cho f càng gần với dữ liệu quan sát được càng tốt, với điều kiện là đường cong phù hợp—tức là bề mặt màu vàng trong Hình 2.5—phải trơn tru. Trong trường hợp này, phương pháp phù hợp phi tham số đã tạo ra một ước tính chính xác đáng kể về giá trị f thực sự được thể hiện trong Hình 2.3. Để phù hợp với spline dạng tấm mỏng, nhà phân tích dữ liệu phải chọn một mức độ trơn tru. Hình 2.6 cho thấy cùng một đường cong spline dạng tấm mỏng được điều chỉnh bằng cách sử dụng mức độ trơn tru thấp hơn, cho phép sự phù hợp thô hơn. Ước tính thu được hoàn toàn phù hợp với dữ liệu quan sát được!

Tuy nhiên, đường cong spline được thể hiện trong Hình 2.6 có độ biến thiên lớn hơn nhiều so với hàm f thực sự, từ Hình 2.3. Đây là một ví dụ về hiện tượng quá khớp dữ liệu, mà chúng ta đã thảo luận trước đó. Đây là một tình huống không mong muốn vì đường cong phù hợp thu được sẽ không cho ra ước tính chính xác về phản hồi trên các quan sát mới không nằm trong tập dữ liệu huấn luyện ban đầu. Chúng ta sẽ thảo luận về các phương pháp lựa chọn mức độ làm mịn phù hợp trong Chương 5.

Đường cong spline được thảo luận trong Chương 7.

Như chúng ta đã thấy, phương pháp tham số và phi tham số đều có những ưu điểm và nhược điểm riêng trong học máy thống kê. Chúng ta sẽ khám phá cả hai loại phương pháp này trong suốt cuốn sách này.

2.1.3 Sự đánh đổi giữa độ chính xác dự đoán và khả năng giải thích của mô hình

Trong số nhiều phương pháp mà chúng ta xem xét trong cuốn sách này, một số phương pháp kém linh hoạt hơn, hoặc hạn chế hơn, theo nghĩa là chúng chỉ có thể tạo ra một phạm vi hình dạng tương đối nhỏ để ước tính f . Ví dụ, hồi quy tuyến tính là một phương pháp tương đối thiếu linh hoạt, bởi vì nó chỉ có thể tạo ra các hàm tuyến tính như các đường thẳng được hiển thị trong Hình 2.1 hoặc mặt phẳng được hiển thị trong Hình 2.4.

Các phương pháp khác, chẳng hạn như các đường cong spline dạng tấm mỏng được thể hiện trong Hình 2.5 và 2.6, linh hoạt hơn đáng kể vì chúng có thể tạo ra nhiều hình dạng khác nhau để ước tính f .



HÌNH 2.7. Minh họa sự đánh đổi giữa tính linh hoạt và khả năng giải thích, sử dụng các phương pháp học thống kê khác nhau. Nhìn chung, khi tính linh hoạt của một phương pháp tăng lên, khả năng giải thích của nó sẽ giảm xuống.

Người ta hoàn toàn có thể đặt câu hỏi sau: tại sao chúng ta lại chọn sử dụng phương pháp hạn chế hơn thay vì một phương pháp linh hoạt hơn? Có một số lý do khiến chúng ta có thể thích một mô hình hạn chế hơn. Nếu chúng ta chủ yếu quan tâm đến suy luận, thì các mô hình hạn chế sẽ dễ hiểu hơn nhiều. Ví dụ, khi mục tiêu là suy luận, mô hình tuyến tính có thể là một lựa chọn tốt vì nó khá dễ hiểu mối quan hệ giữa Y và $X_1, X_2, \dots, X_p$. Ngược lại, các phương pháp rất linh hoạt, chẳng hạn như các hàm spline được thảo luận trong Chương 7 và được hiển thị trong Hình 2.5 và 2.6, và các phương pháp boosting được thảo luận trong Chương 8, có thể dẫn đến các ước tính f phức tạp đến mức khó hiểu mối liên hệ giữa bất kỳ biến dự báo riêng lẻ nào với biến phản hồi.

Hình 2.7 minh họa sự đánh đổi giữa tính linh hoạt và khả năng giải thích đối với một số phương pháp mà chúng tôi đề cập trong cuốn sách này. Hồi quy tuyến tính bình phương nhỏ nhất, được thảo luận trong Chương 3, tương đối không linh hoạt nhưng khá dễ giải thích. Phương pháp lasso, được thảo luận trong Chương 6, dựa trên mô hình tuyến tính (2.4) nhưng sử dụng một quy trình phù hợp thay thế để ước tính các hệ số $\beta_0, \beta_1, \dots, \beta_p$. Quy trình mới này hạn chế hơn trong việc ước tính các hệ số và đặt một số hệ số bằng chính xác 0. Do đó, theo nghĩa này, lasso là một phương pháp kém linh hoạt hơn so với hồi quy tuyến tính. Nó cũng dễ hiểu hơn so với hồi quy tuyến tính, bởi vì trong mô hình cuối cùng, biến phản hồi sẽ chỉ liên quan đến một tập hợp nhỏ các biến dự đoán-cụ thể là những biến có ước lượng hệ số khác không. Mô hình cộng tính tổng quát (GAM), được thảo luận trong Chương 7, mở rộng mô hình tuyến tính (2.4) để cho phép một số mối quan hệ phi tuyến tính nhất định. Do đó, GAM linh hoạt hơn hồi quy tuyến tính. Chúng cũng khó hiểu hơn hồi quy tuyến tính một chút, bởi vì mối quan hệ giữa mỗi biến dự đoán và biến phản hồi hiện được mô hình hóa bằng một đường cong. Cuối cùng, các phương pháp hoàn toàn phi tuyến tính như bagging, boosting, máy vectơ hỗ trợ với hạt nhân phi tuyến tính và mạng nơ-ron (học sâu), được thảo luận trong Chương 8, 9 và 10, là những phương pháp rất linh hoạt nhưng khó hiểu hơn.

đầy đủ

mô hình cộng
tính tổng
quát

tăng
cường đóng gói
ứng hộ
vectơ
máy móc

2.1 Học thống kê là gì? 25

Chúng ta đã xác định rằng khi mục tiêu là suy luận, việc sử dụng các phương pháp học thống kê đơn giản và tương đối cứng nhắc mang lại những lợi thế rõ ràng. Tuy nhiên, trong một số trường hợp, chúng ta chỉ quan tâm đến dự đoán, và Khả năng giải thích của mô hình dự đoán đơn giản là không đáng quan tâm. Ví dụ, nếu chúng ta muốn phát triển một thuật toán để dự đoán giá của một... Về cơ bản, yêu cầu duy nhất của chúng tôi đối với thuật toán là nó phải dự đoán chính xác- Khả năng giải thích không phải là vấn đề đáng lo ngại. Trong bối cảnh này, chúng ta có thể kỳ vọng rằng... Tốt nhất nên sử dụng mô hình linh hoạt nhất hiện có. Điều đáng ngạc nhiên là, đây lại là... Không phải lúc nào cũng vậy! Chúng ta thường sẽ nhận được những dự đoán chính xác hơn bằng cách sử dụng một phương pháp kém linh hoạt hơn. Hiện tượng này, thoạt nhìn có vẻ phản trực giác, liên quan đến khả năng quá khớp dữ liệu trong các mô hình có độ phức tạp cao. các phương pháp linh hoạt. Chúng ta đã thấy một ví dụ về hiện tượng quá khớp trong Hình 2.6. Chúng ta sẽ Chúng ta sẽ thảo luận thêm về khái niệm rất quan trọng này trong Phần 2.2 và xuyên suốt tài liệu. cuốn sách này.

2.1.4 Học có giám sát so với học không giám sát


Hầu hết các bài toán học máy thống kê đều thuộc một trong hai loại: học có giám sát hoặc học không giám sát. Các ví dụ mà chúng ta đã thảo luận cho đến nay trong chương này đều thuộc lĩnh vực học có giám sát. Đối với mỗi quan sát của phép đo dự đoán x_i , $i = 1, \dots, n$ có phản hồi liên quan phép đo y_i . Chúng tôi muốn xây dựng một mô hình liên hệ phản hồi với các yếu tố dự báo, với mục đích dự đoán chính xác phản hồi trong tương lai. quan sát (dự đoán) hoặc hiểu rõ hơn mối quan hệ giữa Phản hồi và các yếu tố dự đoán (suy luận). Nhiều phương pháp học thống kê cổ điển như hồi quy tuyến tính và hồi quy logistic (Chương 4), cũng như các phương pháp hiện đại hơn như GAM, boosting và máy vectơ hỗ trợ, hoạt động trong lĩnh vực học có giám sát. Phần lớn

được giám sát
không giám sát

hồi quy
logistic

Phần lớn nội dung cuốn sách này dành riêng cho bối cảnh đó. Ngược lại, học không giám sát mô tả tình huống khó khăn hơn một chút, trong đó với mỗi quan sát $i = 1, \dots, n$, chúng ta quan sát thấy Một vectơ các phép đo x_i nhưng không có biến phản hồi y_i tương ứng. Không thể áp dụng mô hình hồi quy tuyến tính vì không có biến phản hồi. để dự đoán. Trong bối cảnh này, ở một khía cạnh nào đó, chúng ta đang làm việc một cách mù quáng; tình huống này được gọi là không giám sát vì chúng ta thiếu một biến phản hồi có thể giám sát phân tích của chúng ta. Loại phân tích thống kê nào là Có thể không? Chúng ta có thể tìm hiểu mối quan hệ giữa các biến số. hoặc giữa các quan sát. Một công cụ học thống kê mà chúng ta có thể sử dụng Trong ngữ cảnh này, thuật ngữ được sử dụng là phân tích cụm, hay phân nhóm. Mục tiêu của phân tích cụm là xác định, dựa trên $x_1, \dots, x_n$, xem các quan sát có thuộc vào nhóm nào hay không. các nhóm tương đối khác biệt. Ví dụ, trong một nghiên cứu phân khúc thị trường, chúng ta có thể quan sát nhiều đặc điểm (biến số) của khách hàng tiềm năng, Chẳng hạn như mã bưu điện, thu nhập gia đình và thói quen mua sắm. Chúng ta có thể tin rằng Khách hàng được chia thành các nhóm khác nhau, chẳng hạn như những người chi tiêu nhiều so với những người chi tiêu ít ỏi. những người chi tiêu ít. Nếu có thông tin về mô hình chi tiêu của từng khách hàng. Nếu có sẵn các công cụ hỗ trợ, thì việc phân tích có giám sát sẽ khả thi. Tuy nhiên, điều này Thông tin hiện không có sẵn – nghĩa là, chúng ta không biết liệu mỗi khách hàng tiềm năng có phải là người chi tiêu nhiều hay không. Trong trường hợp này, chúng ta có thể thử phân cụm. khách hàng dựa trên các biến số đo lường được, nhằm mục đích xác định

Cụm
Phân tích



HÌNH 2.8. Một tập dữ liệu phân cụm bao gồm ba nhóm. Mỗi nhóm là được thể hiện bằng ký hiệu màu khác. Bên trái: Ba nhóm được phân tách rõ ràng. Trong bối cảnh này, phương pháp phân cụm sẽ giúp xác định thành công ba nhóm. Bên phải: Có một số sự chồng chéo giữa các nhóm. Giờ đây, nhiệm vụ phân cụm trở nên phức tạp hơn. Đây là thách thức.

các nhóm khách hàng tiềm năng khác nhau. Việc xác định các nhóm này có thể là có hứng thú vì có thể các nhóm khác nhau về một số khía cạnh.

Đặc điểm đáng quan tâm, chẳng hạn như thói quen chi tiêu.

Hình 2.8 minh họa đơn giản cho bài toán phân cụm. Chúng ta

đã vẽ biểu đồ 150 quan sát với các phép đo trên hai biến, X_1

và X_2 . Mỗi quan sát tương ứng với một trong ba nhóm khác nhau. Đối với

để minh họa, chúng tôi đã vẽ biểu đồ các thành viên của mỗi nhóm bằng cách sử dụng

màu sắc và biểu tượng khác nhau. Tuy nhiên, trên thực tế, các thành viên nhóm

Các nhóm chưa được biết, và mục tiêu là xác định nhóm mà mỗi quan sát thuộc về. Trong bảng bên

trái của Hình 2.8, điều này tương đối dễ dàng.

Nhiệm vụ này dễ dàng hơn vì các nhóm được phân tách rõ ràng. Ngược lại, bên tay phải...

Hình minh họa cho thấy một bối cảnh phức tạp hơn, trong đó có một số sự chồng chéo.

giữa các nhóm. Không thể kỳ vọng một phương pháp phân cụm sẽ phân bổ

Hãy gán tất cả các điểm trùng lặp vào đúng nhóm của chúng (xanh dương, xanh lá cây hoặc cam).

Trong các ví dụ được minh họa trong Hình 2.8, chỉ có hai biến số, và

Vì vậy, người ta có thể dễ dàng quan sát trực quan các biểu đồ phân tán của các quan sát trong

để xác định các cụm. Tuy nhiên, trên thực tế, chúng ta thường gặp phải dữ liệu

các tập hợp chứa nhiều hơn hai biến. Trong trường hợp này, chúng ta không thể

dễ dàng vẽ biểu đồ các quan sát. Ví dụ, nếu có p biến trong của chúng ta

Với tập dữ liệu này, có thể tạo ra $p(p-1)/2$ biểu đồ phân tán khác nhau và trực quan hóa.

Việc quan sát trực tiếp không phải là phương pháp khả thi để xác định các cụm. Vì lý do này,

Các phương pháp phân cụm tự động rất quan trọng. Chúng ta sẽ thảo luận về phân cụm và

Các phương pháp học không giám sát khác được trình bày trong Chương 12.

Nhiều vấn đề tự nhiên thuộc về mô hình học có giám sát hoặc không giám sát. Tuy nhiên, đôi khi câu hỏi đặt ra là liệu một phân tích có phù hợp hay không lại khó giải quyết.

Việc nên coi đó là có giám sát hay không giám sát thì không rõ ràng. Ví dụ, giả sử chúng ta có

một tập hợp gồm n quan sát. Đối với m trong số các quan sát đó, với $m < n$, chúng ta có cả các

phép đo biến dự đoán và biến phản hồi.

phép đo. Đối với n m quan sát còn lại, chúng ta có bộ dự đoán.
Có các phép đo nhưng không có phép đo phản hồi. Tình huống như vậy có thể xảy ra nếu
Các yếu tố dự báo có thể được đo lường với chi phí tương đối thấp, nhưng các yếu tố tương ứng
Việc thu thập phản hồi tốn kém hơn nhiều. Chúng tôi gọi thiết lập này là
một bài toán học bán giám sát . Trong bối cảnh này, chúng tôi muốn sử dụng một phương pháp học
thống kê có thể kết hợp m quan sát mà đối với đó
Các phép đo phản hồi cũng như các quan sát n m đều có sẵn.
mà thực tế không phải vậy. Mặc dù đây là một chủ đề thú vị, nhưng nó vượt quá phạm vi của...
phạm vi của cuốn sách này.

bán
giám sát
học hồi

2.1.5 So sánh giữa bài toán hồi quy và bài toán phân loại

Các biến có thể được phân loại là định lượng hoặc định tính (còn được gọi là biến phân loại).
Biến định lượng nhận các giá trị số. Ví dụ bao gồm tuổi, chiều cao hoặc thu nhập của một người,
giá trị của một ngôi nhà, v.v.
giá của một cổ phiếu. Ngược lại, các biến định tính có giá trị trong
Một trong K lớp hoặc danh mục khác nhau. Ví dụ về các biến định tính bao gồm tình trạng hôn
nhân của một người (đã kết hôn hay chưa), nhãn hiệu sản phẩm.
đã mua (thương hiệu A, B hoặc C), liệu một người có vợ hay không (có).
hoặc không), hoặc chẩn đoán ung thư (Bệnh bạch cầu tủy cấp tính, Bệnh bạch cầu lympho cấp tính,
hoặc Không mắc bệnh bạch cầu). Chúng tôi thường đề cập đến các vấn đề liên quan đến
Phản hồi định lượng được gọi là bài toán hồi quy , trong khi những phản hồi định tính thường
được gọi là bài toán phân loại . Tuy nhiên, sự phân biệt này không phải lúc nào cũng rõ ràng.
Hồi quy tuyến tính bình phương nhỏ nhất
(Chương 3) được sử dụng với phản hồi định lượng, trong khi hồi quy logistic
(Chương 4) thường được sử dụng với phản hồi định tính (hai lớp, hay nhị phân) . Do đó, mặc dù
tên gọi là vậy, hồi quy logistic là một phương pháp phân loại.
Nhưng vì nó ước tính xác suất của các lớp, nên nó cũng có thể được coi là một phương pháp hồi quy.
Một số phương pháp thống kê, chẳng hạn như thuật toán K-nearest neighbors, cũng sử dụng phương pháp này.
(Chương 2 và 4) và tăng cường (Chương 8) có thể được sử dụng trong trường hợp
Cả phản hồi định lượng lẫn định tính.

định lượng
phân loại
định tính

lớp học

hồi quy
phân loại

nhị phân

Chúng ta thường lựa chọn các phương pháp học thống kê dựa trên việc liệu...
Câu trả lời có thể là định lượng hoặc định tính; tức là chúng ta có thể sử dụng hồi quy tuyến
tính khi cần câu trả lời định lượng và hồi quy logistic khi cần câu trả lời định tính. Tuy nhiên,
Việc các biến dự báo là định tính hay định lượng nhìn chung được coi là ít quan trọng hơn. Hầu
hết các phương pháp học thống kê được thảo luận trong
Cuốn sách này có thể được áp dụng bất kể loại biến dự báo nào, miễn là
đảm bảo rằng mọi biến dự báo định tính đều được mã hóa đúng cách trước khi tiến hành phân tích.
đã thực hiện. Điều này được thảo luận trong Chương 3.

2.2 Đánh giá độ chính xác của mô hình

Một trong những mục tiêu chính của cuốn sách này là giới thiệu cho người đọc một loạt các chủ đề đa dạng.
các phương pháp học thống kê mở rộng vượt xa các phương pháp tuyến tính tiêu chuẩn.
phương pháp hồi quy. Tại sao lại cần phải giới thiệu quá nhiều phương pháp khác nhau như vậy?
Các phương pháp học thống kê, thay vì chỉ một phương pháp tốt nhất duy nhất ?
Trong thống kê không có chuyện "miễn phí": không có phương pháp nào vượt trội hơn tất cả các phương pháp khác.
các tập dữ liệu khá thi. Trên một tập dữ liệu cụ thể, một phương pháp cụ thể có thể hiệu quả.

Phương pháp tốt nhất, nhưng một số phương pháp khác có thể hiệu quả hơn trên một trường hợp tương tự nhưng khác biệt. tập dữ liệu. Do đó, việc quyết định cho bất kỳ tập dữ liệu nào là một nhiệm vụ quan trọng. Phương pháp nào mang lại kết quả tốt nhất. Việc lựa chọn phương pháp tốt nhất có thể Đây có thể là một trong những phần khó khăn nhất khi thực hiện học máy thống kê.

Trong phần này, chúng ta sẽ thảo luận về một số khái niệm quan trọng nhất mà Vấn đề này phát sinh khi lựa chọn một quy trình học thống kê cho một tập dữ liệu cụ thể. Ví dụ: Khi cuốn sách tiếp tục, chúng tôi sẽ giải thích cách các khái niệm được trình bày ở đây có thể được áp dụng, có thể được áp dụng trong thực tế.

2.2.1 Đo lường chất lượng sự vừa vặn

Để đánh giá hiệu suất của một phương pháp học thống kê trên

Với một tập dữ liệu nhất định, chúng ta cần một phương pháp nào đó để đo lường mức độ chính xác của các dự đoán của nó.

Thực sự phù hợp với dữ liệu quan sát được. Nghĩa là, chúng ta cần định lượng mức độ.

trong đó giá trị phản hồi dự đoán cho một quan sát nhất định gần với

Giá trị phản hồi thực sự cho quan sát đó. Trong thiết lập hồi quy, thì

Phương pháp đo lường được sử dụng phổ biến nhất là sai số bình phương trung bình (MSE), được tính bằng công thức sau:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{f}(x_i))^2, \quad (2.5)$$

trong đó $\hat{f}(x_i)$ là dự đoán mà $\hat{f}$ đưa ra cho quan sát thứ i . MSE

Sai số sẽ nhỏ nếu các phản hồi dự đoán rất gần với phản hồi thực tế.

và sẽ lớn nếu đối với một số quan sát, giá trị dự đoán và giá trị thực tế trùng khớp.

Các phản hồi khác nhau đáng kể.

MSE trong (2.5) được tính toán bằng cách sử dụng dữ liệu huấn luyện đã được dùng để phù hợp với mô hình, và do đó nên được gọi chính xác hơn là quá trình huấn luyện.

MSE. Nhìn chung, chúng ta không thực sự quan tâm đến việc phương pháp hoạt động tốt như thế nào trên dữ liệu huấn luyện. Thay vào đó, chúng ta quan tâm đến độ chính xác của các dự đoán mà chúng ta thu được khi áp dụng phương pháp của mình cho các dữ liệu chưa từng được thấy trước đó. Dữ liệu thử nghiệm. Tại sao chúng ta lại quan tâm đến điều này? Giả sử chúng ta quan tâm đến việc phát triển một thuật toán để dự đoán giá cổ phiếu dựa trên dữ liệu trước đó.

Lợi nhuận cổ phiếu. Chúng ta có thể huấn luyện phương pháp này bằng cách sử dụng lợi nhuận cổ phiếu từ quá khứ 6 tháng. Nhưng chúng ta không thực sự quan tâm phương pháp của mình dự đoán tuần trước chính xác đến mức nào. giá cổ phiếu. Thay vào đó, chúng ta quan tâm đến việc nó dự đoán giá ngày mai chính xác đến mức nào. hoặc giá của tháng tới. Tương tự, giả sử chúng ta có dữ liệu lâm sàng

các chỉ số đo lường (ví dụ: cân nặng, huyết áp, chiều cao, tuổi tác, tiền sử gia đình) bệnh) cho một số bệnh nhân, cũng như thông tin về việc mỗi người có mắc bệnh hay không.

Bệnh nhân này mắc bệnh tiểu đường. Chúng ta có thể sử dụng những bệnh nhân này để huấn luyện một phương pháp học máy thống kê nhằm dự đoán nguy cơ mắc bệnh tiểu đường dựa trên các chỉ số lâm sàng.

Trên thực tế, chúng tôi muốn phương pháp này dự đoán chính xác nguy cơ mắc bệnh tiểu đường trong tương lai. bệnh nhân dựa trên các chỉ số lâm sàng của họ. Chúng tôi không mấy quan tâm.

liệu phương pháp này có dự đoán chính xác nguy cơ mắc bệnh tiểu đường ở bệnh nhân hay không.

được sử dụng để huấn luyện mô hình, vì chúng ta đã biết đó là những bệnh nhân nào.

bị tiểu đường.

Nói một cách toán học hơn, giả sử chúng ta huấn luyện phương pháp học thống kê của mình trên

các quan sát huấn luyện $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$,


và ta thu được ước lượng $\hat{f}$. Sau đó, ta có thể tính $\hat{f}(x_1), \hat{f}(x_2), \dots, \hat{f}(x_n)$.

nghĩa là
bình phương
lỗi

MSE

dữ liệu thử nghiệm

2.2 Đánh giá độ chính xác của mô hình



HÌNH 2.9. Bên trái: Dữ liệu mô phỏng từ f , được hiển thị bằng màu đen. Ba ước tính của Hình f được hiển thị: đường hồi quy tuyến tính (đường cong màu cam) và hai đường cong spline làm mịn. Đường cong phù hợp (màu xanh lam và xanh lục). Bên phải: MSE huấn luyện (đường cong màu xám), MSE kiểm tra (đường cong màu đỏ), và MSE kiểm thử tối thiểu có thể có trên tất cả các phương pháp (đường nét đứt). Hình vuông biểu diễn các giá trị MSE huấn luyện và kiểm tra cho ba mô hình phù hợp được hiển thị ở bên trái bảng.

Nếu các giá trị này xấp xỉ bằng $y_1, y_2, \dots, y_n$, thì MSE huấn luyện sẽ là được đưa ra bởi (2.5) là nhỏ. Tuy nhiên, chúng ta thực sự không quan tâm đến việc liệu $\hat{f}(x_i) \approx y_i$; thay vào đó, chúng ta muốn biết liệu $\hat{f}(x_0)$ có xấp xỉ bằng hay không. đến y_0 , trong đó (x_0, y_0) là một quan sát thử nghiệm chưa từng thấy trước đây và không được sử dụng để huấn luyện. phương pháp học thống kê. Chúng ta muốn chọn phương pháp mang lại MSE kiểm tra thấp nhất, trái ngược với MSE huấn luyện thấp nhất. Nói cách khác, nếu chúng ta có một số lượng lớn các quan sát kiểm tra, chúng ta có thể tính toán

$$\text{Ave}(y_0 - \hat{f}(x_0))^2, \quad (2.6)$$

sai số dự đoán bình phương trung bình cho các quan sát thử nghiệm này (x_0, y_0) .

Chúng tôi muốn chọn mô hình có lượng này nhỏ nhất có thể.

Chúng ta có thể lựa chọn phương pháp nào để giảm thiểu số lần kiểm tra? MSE? Trong một số trường hợp, chúng ta có thể có sẵn bộ dữ liệu thử nghiệm—tức là, chúng ta có thể có quyền truy cập vào một tập hợp các quan sát chưa được sử dụng để huấn luyện. phương pháp học thống kê. Sau đó, chúng ta có thể đơn giản đánh giá (2.6) trên kiểm tra các quan sát và chọn phương pháp học tập có MSE kiểm tra là nhỏ nhất. Nhưng nếu không có dữ liệu quan sát thử nghiệm nào thì sao? Trong trường hợp đó, một có thể hình dung việc đơn giản chỉ cần chọn một phương pháp học thống kê giúp giảm thiểu...

MSE huấn luyện (2.5). Điều này có vẻ như là một cách tiếp cận hợp lý,

Vì sai số bình phương trung bình (MSE) trong quá trình huấn luyện và trong quá trình kiểm tra có vẻ liên quan mật thiết với nhau.

Thật không may, chiến lược này lại có một vấn đề cơ bản: đó là...

Không có gì đảm bảo rằng phương pháp có MSE huấn luyện thấp nhất cũng sẽ hiệu quả.

có MSE kiểm thử thấp nhất. Nói một cách đại khái, vấn đề là nhiều

Các phương pháp thống kê ước tính cụ thể các hệ số để giảm thiểu

Sai số bình phương trung bình (MSE) trên tập huấn luyện. Đối với các phương pháp này, MSE trên tập huấn luyện có thể khá lớn.

Nhỏ, nhưng sai số bình phương trung bình (MSE) của bài kiểm tra thường lớn hơn nhiều.

Hình 2.9 minh họa hiện tượng này trên một ví dụ đơn giản. Ở bảng bên trái của Hình 2.9, chúng ta đã tạo ra các quan sát từ (2.1) với

Giá trị f thực sự được biểu thị bằng đường cong màu đen. Các đường cong màu cam, xanh lam và xanh lục minh họa ba ước tính khả thi cho f thu được bằng các phương pháp với mức độ linh hoạt tăng dần. Đường màu cam là đường hồi quy tuyến tính, tương đối không linh hoạt. Các đường cong màu xanh lam và xanh lục được tạo ra bằng cách sử dụng spline làm mịn, được thảo luận trong Chương 7, với các mức độ làm mịn khác nhau. Rõ ràng là khi mức độ linh hoạt tăng lên, các đường cong phù hợp với dữ liệu quan sát hơn. Đường cong màu xanh lục là linh hoạt nhất và phù hợp với dữ liệu rất tốt; tuy nhiên, chúng ta nhận thấy rằng nó không phù hợp với giá trị f thực sự (được hiển thị bằng màu đen) vì nó quá ngoằn ngoèo. Bằng cách điều chỉnh mức độ linh hoạt của spline làm mịn, chúng ta có thể tạo ra nhiều đường phù hợp khác nhau cho dữ liệu này.


đường cong
spline làm mịn

Bây giờ chúng ta chuyển sang bảng bên phải của Hình 2.9. Đường cong màu xám hiển thị MSE huấn luyện trung bình như một hàm của độ linh hoạt, hay nói chính xác hơn là bậc tự do, cho một số spline làm mịn. Bậc tự do là một đại lượng tóm tắt độ linh hoạt của một đường cong; nó được thảo luận đầy đủ hơn trong Chương 7. Các hình vuông màu cam, xanh lam và xanh lục biểu thị MSE liên quan đến các đường cong tương ứng trong bảng bên trái. Một đường cong bị hạn chế hơn và do đó mượt mà hơn có ít bậc tự do hơn so với một đường cong ngoằn ngoèo – lưu ý rằng trong Hình 2.9, hồi quy tuyến tính ở đầu bị hạn chế nhất, với hai bậc tự do. MSE huấn luyện giảm dần khi độ linh hoạt tăng lên. Trong ví dụ này, f thực sự là phi tuyến tính, và do đó đường cong tuyến tính màu cam không đủ linh hoạt để ước tính f tốt. Đường cong màu xanh lục có MSE huấn luyện thấp nhất trong cả ba phương pháp, vì nó tương ứng với đường cong linh hoạt nhất trong ba đường cong được khớp trong bảng bên trái.

bậc tự do

Trong ví dụ này, chúng ta biết hàm f thực sự, và do đó chúng ta cũng có thể tính toán MSE kiểm tra trên một tập dữ liệu kiểm tra rất lớn, như một hàm của độ linh hoạt. (Tất nhiên, nói chung f là không xác định, vì vậy điều này sẽ không thể thực hiện được.) MSE kiểm tra được hiển thị bằng đường cong màu đỏ trong bảng bên phải của Hình 2.9. Cũng giống như MSE huấn luyện, MSE kiểm tra ban đầu giảm khi mức độ linh hoạt tăng lên. Tuy nhiên, tại một thời điểm nào đó, MSE kiểm tra ổn định và sau đó bắt đầu tăng trở lại. Do đó, cả đường cong màu cam và màu xanh lá cây đều có MSE kiểm tra cao. Đường cong màu xanh lam tối thiểu hóa MSE kiểm tra, điều này không có gì đáng ngạc nhiên khi xét đến việc trực quan nó dường như ước tính f tốt nhất trong bảng bên trái của Hình 2.9. Đường chấm ngang biểu thị $\text{Var}()$, sai số không thể giảm thiểu trong (2.3), tương ứng với MSE kiểm tra thấp nhất có thể đạt được trong số tất cả các phương pháp có thể. Do đó, spline làm mịn được biểu diễn bởi đường cong màu xanh lam gần như tối ưu.

Trong bảng bên phải của Hình 2.9, khi tính linh hoạt của phương pháp học thống kê tăng lên, chúng ta quan sát thấy sự giảm đơn điệu của MSE huấn luyện và hình chữ U trong MSE kiểm tra. Đây là một thuộc tính cơ bản của học thống kê, đúng bất kể tập dữ liệu cụ thể nào và bất kể phương pháp thống kê nào được sử dụng. Khi tính linh hoạt của mô hình tăng lên, MSE huấn luyện sẽ giảm, nhưng MSE kiểm tra có thể không. Khi một phương pháp nhất định cho ra MSE huấn luyện nhỏ nhưng MSE kiểm tra lớn, người ta nói rằng chúng ta đang quá khớp dữ liệu. Điều này xảy ra vì quy trình học thống kê của chúng ta đang làm việc quá sức để tìm ra các mẫu trong dữ liệu huấn luyện, và có thể đang chọn ra một số mẫu chỉ do ngẫu nhiên chứ không phải do các thuộc tính thực sự của hàm f chưa biết. Khi chúng ta quá khớp dữ liệu huấn luyện, MSE kiểm tra sẽ rất lớn vì giả định



HÌNH 2.10. Chi tiết tương tự như trong Hình 2.9, sử dụng giá trị f thực khác là... Gần với tuyến tính hơn nhiều. Trong trường hợp này, hồi quy tuyến tính cung cấp sự phù hợp rất tốt với dữ liệu.

Các mẫu mà phương pháp này tìm thấy trong dữ liệu huấn luyện đơn giản là không tồn tại. trong dữ liệu kiểm thử. Lưu ý rằng bất kể có xảy ra hiện tượng quá khớp hay không. Nếu điều đó xảy ra, chúng ta hầu như luôn kỳ vọng MSE huấn luyện sẽ nhỏ hơn kiểm tra MSE vì hầu hết các phương pháp học thống kê, dù trực tiếp hay gián tiếp, đều không chính xác. Mục tiêu gián tiếp là giảm thiểu MSE trong quá trình huấn luyện. Hiện tượng quá khớp (overfitting) đề cập cụ thể đến vấn đề này. trong trường hợp mô hình kém linh hoạt hơn sẽ mang lại kết quả nhỏ hơn Kiểm tra MSE.


Hình 2.10 cung cấp một ví dụ khác trong đó f thực sự xấp xỉ tuyến tính. Một lần nữa, chúng ta quan sát thấy rằng MSE huấn luyện giảm dần khi độ linh hoạt của mô hình tăng lên, và có hình dạng chữ U trong MSE kiểm thử. Tuy nhiên, vì giá trị thực tế gần với tuyến tính, nên MSE kiểm thử chỉ giảm nhẹ trước khi tăng trở lại, do đó màu cam ít nhất Hình vuông khớp tốt hơn đáng kể so với đường cong màu xanh lá cây có tính linh hoạt cao. Cuối cùng, Hình 2.11 hiển thị một ví dụ trong đó f có tính phi tuyến cao. Đường cong MSE của quá trình huấn luyện và kiểm tra vẫn thể hiện các mô hình tổng quát giống nhau, nhưng Hiện tại, cả hai đường cong đều giảm nhanh trước khi bắt đầu kiểm tra MSE. Tăng dần từ từ.

Trên thực tế, người ta thường có thể tính toán MSE huấn luyện bằng phương pháp tương đối. dễ dàng, nhưng việc ước tính MSE của bài kiểm tra khó khăn hơn đáng kể vì Thông thường không có dữ liệu thử nghiệm nào. Như ba ví dụ trước đã minh họa, mức độ linh hoạt tương ứng với mô hình có MSE kiểm thử tối thiểu có thể khác nhau đáng kể giữa các tập dữ liệu. Xuyên suốt cuốn sách này, chúng ta sẽ thảo luận về... có nhiều phương pháp khác nhau có thể được sử dụng trong thực tế để ước tính mức tối thiểu này. Một phương pháp quan trọng là kiểm định chéo (Chương 5), đây là phương pháp ước tính MSE kiểm thử bằng cách sử dụng dữ liệu huấn luyện.

đi qua-
xác thực

2.2.2 Sự đánh đổi giữa độ lệch và phương sai

Hình dạng chữ U quan sát được trong các đường cong MSE thử nghiệm (Hình 2.9-2.11) cho thấy là kết quả của hai đặc tính đối lập của các phương pháp học thống kê.



HÌNH 2.11. Chi tiết tương tự như trong Hình 2.9, sử dụng một giá trị f khác xa với giá trị ban đầu. tuyến tính. Trong trường hợp này, hồi quy tuyến tính cho kết quả phù hợp rất kém với dữ liệu.

Mặc dù chứng minh toán học nằm ngoài phạm vi của cuốn sách này, nhưng nó...
có thể chứng minh rằng MSE kiểm định dự kiến, với giá trị x_0 cho trước, có thể
luôn được phân tích thành tổng của ba đại lượng cơ bản:
phương sai của $\hat{f}(x_0)$, độ lệch bình phương của $\hat{f}(x_0)$ và phương sai của các số hạng sai số. Tức là,

$$E y_0 - \hat{f}(x_0)^2 = \text{Var}(\hat{f}(x_0)) + [\text{Độ lệch}(\hat{f}(x_0))]^2 + \text{Var}(). \tag{2.7}$$


Ở đây ký hiệu là $E y_0 - \hat{f}(x_0)^2$ xác định MSE kiểm thử dự kiến tại x_0 , dự kiến
và đề cập đến MSE kiểm tra trung bình mà chúng ta sẽ thu được nếu chúng ta kiểm tra MSE nhiều lần.
 f được ước tính bằng cách sử dụng một số lượng lớn tập dữ liệu huấn luyện và được kiểm tra ở x_0 .

Sai số bình phương trung bình (MSE) dự kiến tổng thể của bài kiểm tra có thể được tính bằng cách lấy trung bình $E y_0 - \hat{f}(x_0)$
trên tất cả các giá trị có thể có của x_0 trong tập dữ liệu thử nghiệm.

Phương trình 2.7 cho chúng ta biết rằng để giảm thiểu sai số kiểm tra dự kiến,
Chúng ta cần lựa chọn một phương pháp học thống kê đạt được đồng thời các mục tiêu sau:
Độ lệch chuẩn thấp và độ sai lệch thấp. Lưu ý rằng độ lệch chuẩn vốn dĩ là một giá trị không âm.
Số lượng và độ lệch bình phương cũng không âm. Do đó, ta thấy rằng
Sai số bình phương trung bình (MSE) dự kiến của bài kiểm tra không bao giờ có thể thấp hơn $\text{Var}()$, sai số không thể giảm thiểu từ
(2.3).

Chúng ta hiểu phương sai và độ lệch của một thuật toán học thống kê là gì?
phương pháp? Phương sai đề cập đến lượng mà $\hat{f}$ sẽ thay đổi nếu chúng ta
Ước tính bằng cách sử dụng một tập dữ liệu huấn luyện khác. Vì dữ liệu huấn luyện
được sử dụng để phù hợp với phương pháp học thống kê, các tập dữ liệu huấn luyện khác nhau.
sẽ dẫn đến một giá trị $\hat{f}$ khác. Nhưng lý tưởng nhất là ước tính cho f không nên thay đổi.
quá nhiều khác biệt giữa các tập dữ liệu huấn luyện. Tuy nhiên, nếu một phương pháp có độ biến thiên cao
khi đó, những thay đổi nhỏ trong dữ liệu huấn luyện có thể dẫn đến những thay đổi lớn trong $\hat{f}$. Trong
Các phương pháp thống kê tổng quát, linh hoạt hơn thường có phương sai cao hơn. Hãy xem xét...
Các đường cong màu xanh lá cây và màu cam trong Hình 2.9. Đường cong màu xanh lá cây linh hoạt đang theo sau.
Các quan sát rất sát sao. Nó có độ biến thiên cao vì việc thay đổi bất kỳ
Một trong những điểm dữ liệu này có thể khiến giá trị ước tính $\hat{f}$ thay đổi đáng kể.

2.2 Đánh giá độ chính xác của mô hình 33



HÌNH 2.12. Sai số bình phương (đường cong màu xanh), phương sai (đường cong màu cam), $\text{Var}()$ (đường nét đứt) và MSE kiểm định (đường cong màu đỏ) cho ba bộ dữ liệu trong Hình 2.9-2.11. Đường chấm dọc biểu thị mức độ linh hoạt tương ứng với giá trị nhỏ nhất. Kiểm tra MSE.

Ngược lại, đường hồi quy bình phương tối thiểu màu cam tương đối cứng nhắc và có độ ổn định thấp. sự sai lệch, bởi vì việc di chuyển bất kỳ quan sát đơn lẻ nào cũng có thể chỉ gây ra một sự sai lệch nhỏ. Sự dịch chuyển nhỏ về vị trí của đường kẻ.

Mặt khác, độ lệch đề cập đến sai số phát sinh khi xấp xỉ một vấn đề thực tế, vốn có thể cực kỳ phức tạp, bằng một phương pháp đơn giản hơn nhiều.

Mô hình đơn giản hơn. Ví dụ, hồi quy tuyến tính giả định rằng có một mối quan hệ tuyến tính.

Mối quan hệ giữa Y và $X_1, X_2, \dots, X_p$. Rất khó có khả năng có bất kỳ mối quan hệ thực tế nào như vậy. Vấn đề thực sự có mối quan hệ tuyến tính đơn giản như vậy, do đó việc thực hiện hồi quy tuyến tính chắc chắn sẽ dẫn đến một số sai lệch trong ước lượng của f .

Hình 2.11 cho thấy, hàm f thực sự không tuyến tính đáng kể, vì vậy bất kể có bao nhiêu Dữ liệu quan sát về quá trình huấn luyện mà chúng ta được cung cấp, sẽ không thể tạo ra được một kết luận chính xác. Ước tính chính xác bằng cách sử dụng hồi quy tuyến tính. Nói cách khác, hồi quy tuyến tính Điều này dẫn đến độ lệch cao trong ví dụ này. Tuy nhiên, trong Hình 2.10, giá trị f thực sự rất gần với tuyến tính, và do đó, nếu có đủ dữ liệu, điều đó hoàn toàn có thể thực hiện được. Hồi quy tuyến tính được sử dụng để đưa ra ước tính chính xác. Nói chung, phương pháp này linh hoạt hơn. các phương pháp này dẫn đến ít sai lệch hơn.

Theo nguyên tắc chung, khi chúng ta sử dụng các phương pháp linh hoạt hơn, phương sai sẽ... tăng lên và độ lệch sẽ giảm xuống. Tốc độ thay đổi tương đối của những điều này Hai đại lượng này quyết định xem sai số bình phương trung bình (MSE) của bài kiểm tra tăng hay giảm. Khi chúng ta tăng tính linh hoạt của một nhóm phương pháp, thì xu hướng ban đầu có xu hướng thiên lệch. giảm nhanh hơn so với mức tăng của phương sai. Do đó, kỳ vọng Kiểm tra MSE giảm. Tuy nhiên, đến một lúc nào đó, việc tăng tính linh hoạt sẽ không còn nhiều tác dụng. ảnh hưởng đến độ lệch nhưng bắt đầu làm tăng đáng kể phương sai. Khi Điều này xảy ra khi MSE của bài kiểm tra tăng lên. Lưu ý rằng chúng tôi đã quan sát thấy mô hình này. của phép thử MSE giảm dần, sau đó là phép thử MSE tăng dần ở phía bên phải. các bảng trong Hình 2.9-2.11.

Ba đồ thị trong Hình 2.12 minh họa Phương trình 2.7 cho các ví dụ trong Hình 2.9-2.11. Trong mỗi trường hợp, đường cong liên màu xanh lam biểu thị bình phương của độ lệch, đối với các mức độ linh hoạt khác nhau, trong khi đường cong màu cam tương ứng với phương sai. Đường nét đứt ngang biểu thị $\text{Var}()$, không thể rút gọn. lỗi. Cuối cùng, đường cong màu đỏ, tương ứng với MSE của tập dữ liệu thử nghiệm, là tổng.

của ba đại lượng này. Trong cả ba trường hợp, phương sai đều tăng lên và Sai lệch giảm khi tính linh hoạt của phương pháp tăng lên. Tuy nhiên, tính linh hoạt Mức độ tương ứng với MSE kiểm tra tối ưu khác nhau đáng kể giữa các nhóm. ba bộ dữ liệu, vì độ lệch bình phương và phương sai thay đổi ở các mức khác nhau tỷ lệ trong mỗi tập dữ liệu. Ở bảng bên trái của Hình 2.12 , Độ lệch ban đầu giảm nhanh chóng, dẫn đến sự giảm mạnh ban đầu về MSE kiểm tra dự kiến. Mặt khác, ở bảng giữa của Hình 2.12 Hệ số f thực sự gần như tuyến tính, do đó độ lệch chỉ giảm nhẹ khi độ linh hoạt tăng lên, và MSE của bài kiểm tra chỉ giảm nhẹ trước khi tăng trở lại. nhanh chóng khi phương sai tăng lên. Cuối cùng, trong bảng bên phải của Hình 2.12, khi tính linh hoạt tăng lên, độ lệch giảm mạnh vì Hàm f thực sự rất phi tuyến tính. Ngoài ra, độ biến thiên cũng tăng rất ít. Khi tính linh hoạt tăng lên, kết quả là sai số bình phương trung bình (MSE) của bài kiểm tra giảm đáng kể. trước khi có sự tăng nhẹ khi tính linh hoạt của mô hình tăng lên.

Mối quan hệ giữa độ lệch, phương sai và MSE của tập dữ liệu kiểm tra được đưa ra trong Phương trình 2.7 và hiển thị trong Hình 2.12 được gọi là phương sai-độ lệch.

Sự đánh đổi. Hiệu suất tốt trên tập dữ liệu kiểm thử của một phương pháp học thống kê đòi hỏi phương sai thấp cũng như độ lệch bình phương thấp. Điều này được gọi là sự đánh đổi. sự đánh đổi vì để đạt được một phương pháp với độ sai lệch cực thấp nhưng độ lệch chuẩn cao (ví dụ, bằng cách vẽ một đường cong đi qua mọi quan sát huấn luyện đơn lẻ) hoặc một phương pháp có độ biến thiên rất thấp nhưng cao sai lệch (bằng cách vẽ một đường thẳng nằm ngang phù hợp với dữ liệu). Thử thách nằm ở việc tìm ra một phương pháp mà cả phương sai và bình phương độ lệch đều thấp. Điều này Sự đánh đổi là một trong những chủ đề quan trọng nhất được đề cập xuyên suốt cuốn sách này.

Trong tình huống thực tế mà f không được quan sát, nhìn chung không thể tính toán rõ ràng MSE, độ lệch hoặc phương sai của phép thử thống kê. phương pháp học tập. Tuy nhiên, người ta luôn phải giữ vững phương sai thiên lệch. Cân nhắc sự đánh đổi. Trong cuốn sách này, chúng ta sẽ khám phá những phương pháp vô cùng quan trọng. tính linh hoạt và do đó về cơ bản có thể loại bỏ sự thiên vị. Tuy nhiên, điều này không có nghĩa là... đảm bảo rằng chúng sẽ hoạt động tốt hơn nhiều so với một phương pháp đơn giản hơn như phương pháp tuyến tính. hồi quy. Lấy một ví dụ cực đoan, giả sử rằng hàm f thực sự là tuyến tính. Trong trường hợp này, hồi quy tuyến tính sẽ không có sai lệch, khiến nó trở nên rất khó. để có phương pháp cạnh tranh tính linh hoạt hơn. Ngược lại, nếu f thực sự cao phi tuyến tính và chúng ta có số lượng quan sát huấn luyện dồi dào, vậy thì Chúng ta có thể đạt kết quả tốt hơn bằng cách sử dụng phương pháp tính linh hoạt cao, như trong Hình 2.11 . Chương 5 chúng ta sẽ thảo luận về phương pháp kiểm định chéo, một cách để ước tính kết quả kiểm định. MSE sử dụng dữ liệu huấn luyện.

độ lệch-phương sai
sự đánh đổi

2.2.3 Thiết lập phân loại

Cho đến nay, cuộc thảo luận của chúng ta về độ chính xác của mô hình tập trung vào thiết lập hồi quy. Nhưng nhiều khái niệm mà chúng ta đã gặp phải, chẳng hạn như Như một sự đánh đổi giữa độ lệch và phương sai, hãy chuyển sang thiết lập phân loại. với một số sửa đổi nhỏ do thực tế là y không còn mang tính định lượng nữa. Giả sử chúng ta muốn ước lượng f dựa trên các quan sát huấn luyện $\{(x_1, y_1), \dots, (x_n, y_n)\}$, trong đó $y_1, \dots, y_n$ bây giờ mang tính định tính. Phương pháp phổ biến nhất để định lượng độ chính xác của ước tính $\hat{f}$ của chúng ta là tỷ lệ lỗi huấn luyện , tỷ lệ sai sót mắc phải nếu chúng ta áp dụng

tỷ lệ lỗi

ước tính $\hat{f}$ của chúng tôi đối với các quan sát huấn luyện:

$$\frac{1}{N} \sum_{i=1}^N I(y_i = \hat{y}_i)$$

Tôi

$(y_i = \hat{y}_i)$

(2.8)

Ở đây, $\hat{y}_i$ là nhãn lớp dự đoán cho quan sát thứ i sử dụng $\hat{f}$. Và $I(y_i = \hat{y}_i)$ là một biến chỉ thị bằng 1 nếu $y_i = \hat{y}_i$ và bằng 0 nếu $y_i \neq \hat{y}_i$.
Nếu $I(y_i = \hat{y}_i) = 0$ thì quan sát thứ i đã được phân loại chính xác bởi chúng tôi.
phương pháp phân loại; nếu không thì nó đã bị phân loại sai. Do đó, Phương trình 2.8
Tính toán tỷ lệ phân loại sai.

Phương trình 2.8 được gọi là tỷ lệ lỗi huấn luyện vì nó được tính toán dựa trên dữ liệu được sử dụng để huấn luyện bộ phân loại của chúng ta. Như trong
Trong bối cảnh hồi quy, chúng ta quan tâm nhất đến tỷ lệ lỗi phát sinh từ...
Áp dụng bộ phân loại của chúng tôi để kiểm tra các quan sát chưa được sử dụng trong quá trình huấn luyện.
Tỷ lệ lỗi kiểm định liên quan đến một tập hợp các quan sát kiểm định có dạng (x_0, y_0) được cho bởi

Ave

$(I(y_0 \neq \hat{y}_0))$

(2.9)

trong đó $\hat{y}_0$ là nhãn lớp dự đoán thu được từ việc áp dụng bộ phân loại.
để kiểm tra quan sát với biến dự đoán x_0 . Một bộ phân loại tốt là bộ phân loại mà...
lỗi kiểm tra (2,9) là nhỏ nhất.

Bộ phân loại Bayes


Có thể chứng minh (mặc dù việc chứng minh nằm ngoài phạm vi của bài viết này).
sách) rằng tỷ lệ lỗi kiểm tra được đưa ra trong (2.9) được giảm thiểu, trung bình, bởi một
Bộ phân loại rất đơn giản, gán mỗi quan sát vào lớp có khả năng xảy ra cao nhất.
dựa trên các giá trị dự đoán của nó. Nói cách khác, chúng ta chỉ cần chỉ định một bài kiểm tra
quan sát với vectơ dự đoán x_0 cho lớp j mà trong đó

$\Pr(Y = j | X = x_0)$

(2.10)

là lớn nhất. Lưu ý rằng (2.10) là xác suất có điều kiện: đó là xác suất $Y = j$, cho trước
vectơ dự đoán quan sát được x_0 . Bộ phân loại rất đơn giản này được gọi là bộ phân loại
Bayes. Trong bài toán hai lớp, trong đó chỉ có hai giá trị phản hồi có thể, chẳng hạn như
lớp 1 hoặc lớp 2, bộ phân loại Bayes
tương ứng với việc dự đoán lớp một nếu $\Pr(Y = 1 | X = x_0) > 0,5$ và lớp
hai trường hợp khác.

Hình 2.13 cung cấp một ví dụ sử dụng tập dữ liệu mô phỏng trong không gian hai chiều
bao gồm các biến dự đoán X_1 và X_2 . Màu cam và
Các vòng tròn màu xanh lam tương ứng với các quan sát huấn luyện thuộc về hai nhóm khác nhau.
các lớp. Với mỗi giá trị của X_1 và X_2 , có một xác suất khác nhau của
Phản hồi có thể là màu cam hoặc màu xanh lam. Vì đây là dữ liệu mô phỏng, chúng ta biết cách...
Dữ liệu đã được tạo ra và chúng ta có thể tính toán xác suất có điều kiện.
cho mỗi giá trị của X_1 và X_2 . Vùng tô màu cam phản ánh tập hợp các giá trị đó.
các điểm mà $\Pr(Y = \text{orange} | X)$ lớn hơn 50%, trong khi màu xanh lam
Vùng được tô bóng biểu thị tập hợp các điểm có xác suất thấp hơn
50%. Đường chấm tím biểu thị các điểm mà xác suất
Chính xác là 50%. Đây được gọi là ranh giới quyết định Bayes. Dự đoán của bộ phân loại
Bayes được xác định bởi ranh giới quyết định Bayes; một
Quan sát nào nằm ở phía màu cam của ranh giới sẽ được chỉ định.



HÌNH 2.13. Một tập dữ liệu mô phỏng gồm 100 quan sát trong mỗi nhóm, được biểu thị bằng màu xanh lam và màu cam. Đường chấm tím biểu thị ranh giới quyết định Bayes. Lưới nền màu cam chỉ ra vùng mà một quan sát thử nghiệm sẽ được gán vào lớp màu cam, và lưới nền màu xanh lam chỉ ra vùng mà một quan sát thử nghiệm sẽ được gán vào lớp màu xanh lam.

Tương tự, một quan sát ở phía màu xanh lam của ranh giới sẽ được xếp vào lớp màu cam, và một quan sát ở phía màu xanh lam của ranh giới sẽ được xếp vào lớp màu xanh lam.

Bộ phân loại Bayes tạo ra tỷ lệ lỗi kiểm thử thấp nhất có thể, được gọi là tỷ lệ lỗi Bayes. Vì bộ phân loại Bayes sẽ luôn chọn lớp mà (2.10) lớn nhất, nên tỷ lệ lỗi sẽ là $\max_j \Pr(Y = j|X = x_0)$ tại $X = x_0$. Nói chung, tỷ lệ lỗi Bayes tổng thể được cho bởi

Tỷ lệ lỗi Bayes

$$1 - E \max_j \Pr(Y = j|X) , \tag{2.11}$$

Trong đó, kỳ vọng trung bình là xác suất trên tất cả các giá trị có thể có của X . Đối với dữ liệu mô phỏng của chúng tôi, tỷ lệ lỗi Bayes là 0,133. Nó lớn hơn 0 vì các lớp chồng chéo trong quần thể thực, điều này ngụ ý rằng $\max_j \Pr(Y = j|X = x_0) < 1$ đối với một số giá trị của x_0 . Tỷ lệ lỗi Bayes tương tự như lỗi không thể giảm thiểu, đã được thảo luận trước đó.

K-Hàng xóm gần nhất

Về lý thuyết, chúng ta luôn muốn dự đoán các phản hồi định tính bằng cách sử dụng bộ phân loại Bayes. Nhưng đối với dữ liệu thực tế, chúng ta không biết phân bố có điều kiện của Y khi biết X , và do đó việc tính toán bộ phân loại Bayes là không thể. Vì vậy, bộ phân loại Bayes đóng vai trò như một tiêu chuẩn vàng không thể đạt được để so sánh với các phương pháp khác. Nhiều phương pháp cố gắng ước tính phân bố có điều kiện của Y khi biết X , và sau đó phân loại một quan sát nhất định vào lớp có xác suất ước tính cao nhất. Một trong những phương pháp đó là bộ phân loại K-nearest neighbors (KNN). Cho một đầu vào dương.

K-hàng xóm gần nhất

Với một số nguyên K và một quan sát thử nghiệm x_0 , bộ phân loại KNN trước tiên xác định K điểm trong dữ liệu huấn luyện gần nhất với x_0 , được biểu thị bằng N_0 . Sau đó, nó ước tính xác suất có điều kiện cho lớp j là tỷ lệ các điểm trong N_0 có giá trị phản hồi bằng j :

$$\Pr(Y = j | X = x_0) = \frac{1}{K} \sum_{i \in N_0} \mathbb{I}(y_i = j). \quad (2.12)$$

Cuối cùng, KNN phân loại quan sát thử nghiệm x_0 vào lớp có xác suất lớn nhất từ (2.12).

Hình 2.14 cung cấp một ví dụ minh họa về phương pháp KNN. Ở bảng bên trái, chúng ta đã vẽ một tập dữ liệu huấn luyện nhỏ bao gồm sáu quan sát màu xanh lam và sáu quan sát màu cam. Mục tiêu của chúng ta là đưa ra dự đoán cho điểm được đánh dấu bằng dấu thập đen. Giả sử chúng ta chọn $K = 3$. Khi đó, KNN sẽ xác định ba quan sát gần nhất với dấu thập.

Khu vực này được biểu diễn dưới dạng một vòng tròn. Nó bao gồm hai điểm màu xanh lam và một điểm màu cam, dẫn đến xác suất ước tính là $2/3$ cho lớp màu xanh lam và $1/3$ cho lớp màu cam. Do đó, KNN sẽ dự đoán rằng dấu thập đen thuộc về lớp màu xanh lam. Trong bảng bên phải của Hình 2.14, chúng ta đã áp dụng phương pháp KNN với $K = 3$ ở tất cả các giá trị có thể có cho X_1 và X_2 , và đã vẽ ranh giới quyết định KNN tương ứng.


Mặc dù là một phương pháp rất đơn giản, KNN thường có thể tạo ra các bộ phân loại gần giống với bộ phân loại Bayes tối ưu một cách đáng ngạc nhiên.

Hình 2.15 hiển thị ranh giới quyết định của KNN, sử dụng $K = 10$, khi được áp dụng cho tập dữ liệu mô phỏng lớn hơn từ Hình 2.13. Lưu ý rằng mặc dù bộ phân loại KNN không biết phân bố thực sự, ranh giới quyết định của KNN rất gần với ranh giới của bộ phân loại Bayes. Tỷ lệ lỗi kiểm thử sử dụng KNN là 0,1363, gần với tỷ lệ lỗi Bayes là 0,1304.


Việc lựa chọn K có ảnh hưởng rất lớn đến bộ phân loại KNN thu được.

Hình 2.16 hiển thị hai đường cong phù hợp của thuật toán KNN với dữ liệu mô phỏng từ Hình 2.13, sử dụng $K = 1$ và $K = 100$. Khi $K = 1$, ranh giới quyết định quá linh hoạt và tìm thấy các mẫu trong dữ liệu không tương ứng với ranh giới quyết định Bayes. Điều này tương ứng với một bộ phân loại có độ lệch thấp nhưng phương sai rất cao. Khi K tăng lên, phương pháp trở nên ít linh hoạt hơn và tạo ra một ranh giới quyết định gần như tuyến tính. Điều này tương ứng với một bộ phân loại có phương sai thấp nhưng độ lệch cao. Trên tập dữ liệu mô phỏng này, cả $K = 1$ và $K = 100$ đều không cho kết quả dự đoán tốt: chúng có tỷ lệ lỗi kiểm thử lần lượt là 0,1695 và 0,1925.

Cũng giống như trong thiết lập hồi quy, không có mối quan hệ chặt chẽ giữa tỷ lệ lỗi huấn luyện và tỷ lệ lỗi kiểm tra. Với $K = 1$, tỷ lệ lỗi huấn luyện của KNN bằng 0, nhưng tỷ lệ lỗi kiểm tra có thể khá cao. Nói chung, khi chúng ta sử dụng các phương pháp phân loại linh hoạt hơn, tỷ lệ lỗi huấn luyện sẽ giảm nhưng tỷ lệ lỗi kiểm tra có thể không giảm. Trong Hình 2.17, chúng ta đã vẽ biểu đồ lỗi kiểm tra và huấn luyện của KNN theo hàm của $1/K$. Khi $1/K$ tăng, phương pháp trở nên linh hoạt hơn. Cũng như trong thiết lập hồi quy, tỷ lệ lỗi huấn luyện liên tục giảm khi tính linh hoạt tăng lên. Tuy nhiên, lỗi kiểm tra thể hiện hình dạng chữ U đặc trưng, giảm xuống lúc đầu (với mức tối thiểu ở khoảng $K = 10$) trước khi tăng trở lại khi phương pháp trở nên quá linh hoạt và bị quá khớp.




HÌNH 2.14. Phương pháp KNN, sử dụng $K = 3$, được minh họa trong một tình huống đơn giản với sáu quan sát màu xanh lam và sáu quan sát màu cam. Bên trái: một quan sát thử nghiệm mà nhân lớp dự đoán mong muốn được hiển thị dưới dạng dấu thập màu đen. Ba điểm gần nhất với quan sát thử nghiệm được xác định, và dự đoán rằng quan sát thử nghiệm thuộc về lớp xuất hiện phổ biến nhất, trong trường hợp này là màu xanh lam. Bên phải: Đường ranh giới quyết định KNN cho ví dụ này được hiển thị bằng màu đen. Lưới màu xanh lam biểu thị vùng mà kết quả quan sát thử nghiệm sẽ được xếp vào lớp màu xanh lam, và lưới màu cam biểu thị vùng mà kết quả đó sẽ được xếp vào lớp màu cam.




HÌNH 2.15. Đường cong màu đen biểu thị ranh giới quyết định của KNN trên dữ liệu từ Hình 2.13, sử dụng $K = 10$. Ranh giới quyết định của Bayes được thể hiện bằng đường chấm tím. Ranh giới quyết định của KNN và Bayes rất giống nhau.

Trong cả thiết lập hồi quy và phân loại, việc lựa chọn mức độ linh hoạt phù hợp là rất quan trọng đối với sự thành công của bất kỳ phương pháp học thống kê nào.

Sự đánh đổi giữa độ lệch và phương sai, cùng với hình dạng chữ U trong sai số kiểm định, có thể khiến việc này trở nên khó khăn. Trong Chương 5, chúng ta sẽ quay lại chủ đề này và thảo luận thêm.



HÌNH 2.16. So sánh các đường ranh giới quyết định KNN (đường cong màu đen liền nét) thu được khi sử dụng $K = 1$ và $K = 100$ trên dữ liệu từ Hình 2.13. Với $K = 1$, đường ranh giới quyết định quá linh hoạt, trong khi với $K = 100$ thì nó lại không đủ linh hoạt. Đường ranh giới quyết định Bayes được thể hiện bằng đường chấm tím.



HÌNH 2.17. Tỷ lệ lỗi huấn luyện KNN (màu xanh lam, 200 quan sát) và tỷ lệ lỗi kiểm tra (màu cam, 5.000 quan sát) trên dữ liệu từ Hình 2.13, khi mức độ linh hoạt (được đánh giá bằng $1/K$ trên thang logarit) tăng lên, hoặc tương đương khi số lượng láng giềng K giảm xuống. Đường nét đứt màu đen biểu thị tỷ lệ lỗi Bayes. Sự không ổn định của các đường cong là do kích thước nhỏ của tập dữ liệu huấn luyện.

Các phương pháp khác nhau để ước tính tỷ lệ lỗi kiểm thử và từ đó lựa chọn mức độ linh hoạt tối ưu cho một phương pháp học thống kê nhất định.

2.3 Thực hành: Giới thiệu về Python

2.3.1 Bắt đầu

Để thực hiện các thí nghiệm trong cuốn sách này, bạn cần hai thứ:

1. Cần có bản cài đặt **Python3**, đây là phiên bản **Python** cụ thể được sử dụng.
trong phòng thí nghiệm.
2. Truy cập vào **Jupyter**, một giao diện **Python** rất phổ biến dùng để chạy mã.
thông qua một tập tin có tên là sổ tay.

sổ tay

Bạn có thể tải xuống và cài đặt **Python3** bằng cách làm theo hướng dẫn có sẵn.
có thể tìm thấy tại anaconda.com.

Có nhiều cách để truy cập **Jupyter**. Dưới đây chỉ là một vài ví dụ:

1. Sử dụng dịch vụ **Colaboratory** của Google : colab.research.google.com/.
2. Sử dụng **JupyterHub**, có sẵn tại jupyter.org/hub.
3. Sử dụng bản cài đặt **Jupyter** của riêng bạn . Hướng dẫn cài đặt như sau:
Có thể tải xuống tại jupyter.org/install.

Vui lòng xem trang tài nguyên **Python** trên trang web của cuốn sách : statlearning.com
Để có thông tin cập nhật về cách cài đặt và sử dụng **Python** và **Jupyter**, hãy tham khảo...
máy tính của bạn.

Bạn cần cài đặt gói **ISLP** , gói này cung cấp quyền truy cập vào...
các tập dữ liệu và các hàm tùy chỉnh do chúng tôi cung cấp. Bên trong macOS hoặc
Gõ lệnh `'pip install ISLP'` trong terminal Linux ; lệnh này cũng cài đặt hầu hết các gói cần
thiết khác trong các bài thực hành. Trang tài nguyên **Python** có liên kết đến **ISLP**.
Trang web tài liệu.

Để chạy bài thực hành này, hãy tải xuống tệp **Ch2-statlearn-lab.ipynb** từ [nguồn].
Trang tài nguyên **Python** . Bây giờ hãy chạy đoạn mã sau tại dòng lệnh:
phòng thí nghiệm jupyter Ch2-statlearn-lab.ipynb.

Nếu bạn đang sử dụng Windows, bạn có thể sử dụng menu **Bắt đầu** để truy cập **Anaconda**.
và làm theo các liên kết. Ví dụ, để cài đặt **ISLP** và chạy bài thực hành này, bạn có thể
Chạy đoạn mã trên trong trình thông dịch **Anaconda** .

2.3.2 Các lệnh cơ bản

Trong bài thực hành này, chúng ta sẽ giới thiệu một số lệnh **Python** đơn giản . Để biết thêm chi tiết...
Để tìm hiểu thêm về **Python** nói chung, độc giả có thể tham khảo hướng dẫn.
tại docs.python.org/3/tutorial/.

Giống như hầu hết các ngôn ngữ lập trình, **Python** sử dụng các hàm để thực hiện các phép toán.
Để chạy một hàm có tên là **fun**, ta gõ **fun(input1, input2)**, trong đó
Các tham số đầu vào (hoặc đối số) **input1** và **input2** cho **Python** biết cách chạy chương trình.
Hàm. Một hàm có thể có bất kỳ số lượng đầu vào nào. Ví dụ, hàm **print()** xuất ra một biểu diễn văn
bản của tất cả các đối số của nó ra bảng điều khiển.

chức năng

lý lẽ
in()

Trong [1]: `print('phù hợp với một mô hình với', 11, 'biến')`

xây dựng mô hình với 11 biến số

Lệnh sau đây sẽ cung cấp thông tin về hàm `print()` .

```
Trong [2]: in?
```

Việc cộng hai số nguyên trong `Python` khá dễ hiểu.

```
Trong [3]: 3+5
```

Ra ngoài[3]: 8

Trong `Python`, dữ liệu văn bản được xử lý bằng chuỗi. Ví dụ, `"hello"` và `'hello'` là các chuỗi. Chúng ta có thể nối chúng lại với nhau bằng ký hiệu cộng (`+`) .

```
Trong [4]: "xin chào" + " " + "thế giới"
```

Ra ngoài[4]: 'xin chào thế giới'

Chuỗi ký tự thực chất là một loại dãy số: đây là thuật ngữ chung cho một danh sách có thứ tự. Ba loại dãy số quan trọng nhất là danh sách, bộ dữ liệu (tuple) và dãy số thực (string).

Chuỗi ký tự. Bây giờ chúng ta sẽ giới thiệu danh sách.

Lệnh sau đây hướng dẫn `Python` nối các số 3 lại với nhau,

Nhập số 4 và 5, rồi lưu chúng vào một danh sách có tên là `x`. Khi ta gõ `x`, nó sẽ trả về danh sách đó.

```
Trong [5]: x = [3, 4, 5]
x
```

Ra[5]: [3, 4, 5]

Lưu ý rằng chúng ta đã sử dụng dấu ngoặc vuông `[]` để tạo ra danh sách này.

Chúng ta thường muốn cộng hai nhóm số với nhau. Điều đó là hợp lý.

Hãy thử đoạn mã sau, mặc dù nó sẽ không mang lại kết quả như mong muốn.

```
Trong [6]: y = [4, 9, 7]
x+y
```

Ra[6]: [3, 4, 5, 4, 9, 7]

Kết quả có vẻ hơi trái ngược với trực giác: tại sao `Python` lại không thêm các phần tử của danh sách được lấy từng phần tử một? Trong `Python`, danh sách chứa các phần tử tùy ý. Các đối tượng được thêm vào bằng phép nối chuỗi. Trên thực tế, phép nối chuỗi chính là hành vi mà chúng ta đã thấy trước đó khi nhập `"hello" + " " + "thế giới"`.

rằng `Python` là một ngôn ngữ lập trình đa năng. Phần lớn chức năng cụ thể về dữ liệu của `Python` đến từ

các gói khác, đáng chú ý là `numpy` và `pandas`. Trong phần tiếp theo, chúng ta sẽ giới thiệu gói `numpy` . Xem docs.scipy.org/doc/numpy/user/quickstart.html

Để biết thêm thông tin về `numpy`.

2.3.3 Giới thiệu về Python số học

Như đã đề cập trước đó, cuốn sách này sử dụng các chức năng có sẵn. Trong thư viện `numpy`, hay còn gọi là gói. Gói là một tập hợp các mô-đun không nhất thiết phải được bao gồm trong bản phân phối `Python` cơ bản. Tên `numpy` là viết tắt của `Numbering Python` (`Python` số). Để truy cập `numpy`, trước tiên chúng ta phải nhập nó.

```
Trong [7]: import numpy as np
```

Ở dòng trước, chúng ta đã đặt tên cho mô-đun `numpy` là `np`; một từ viết tắt để dễ tham chiếu hơn.

Trong `NumPy`, mảng là thuật ngữ chung dùng để chỉ một tập hợp các số có nhiều chiều. Chúng ta sử dụng hàm `np.array()` để định nghĩa `x` và `y`, là các mảng một chiều, tức là các vectơ.

```
Trong [8]: x = np.array([3, 4, 5])
y = np.array([4, 9, 7])
```

Lưu ý rằng nếu bạn quên chạy lệnh `import numpy as np` trước đó, Khi đó bạn sẽ gặp lỗi khi gọi hàm `np.array()` trong dòng trước đó. Cú pháp `np.array()` cho biết hàm được gọi là một phần của gói `numpy`, mà chúng ta đã viết tắt là `np`.

Vì `x` và `y` đã được định nghĩa bằng `np.array()`, ta thu được kết quả hợp lý. Khi chúng ta cộng chúng lại với nhau. Hãy so sánh điều này với kết quả của chúng ta trong lần trước. phần này, khi chúng tôi cố gắng cộng hai danh sách mà không sử dụng `numpy`.

```
Trong [9]: x+y
```

Out[9]: array([7, 13, 12])

Trong thư viện `NumPy`, ma trận thường được biểu diễn dưới dạng mảng hai chiều. và các vectơ dưới dạng mảng một chiều. Chúng ta có thể tạo ra một mảng hai chiều mảng như sau.

```
Trong [10]: x = np.array([[1, 2], [3, 4]])
x
```

Out[10]: array([[1, 2],
[3, 4]])

Đối tượng `x` có một số thuộc tính, hay các đối tượng liên kết. Để truy cập một thuộc tính của `x`, ta gõ `x.attribute`, trong đó ta thay thế `attribute` bằng `x.attribute`. Tên của thuộc tính. Ví dụ, ta có thể truy cập thuộc tính `ndim` của `x` như sau.

```
Trong [11]: x.ndim
```

Ra ngoài[11]: 2

Kết quả đầu ra cho thấy `x` là một mảng hai chiều. Tương tự, `x.dtype` là thuộc tính kiểu dữ liệu của đối tượng `x`. Điều này cho biết `x` được cấu tạo từ các số nguyên 64 bit:

Mặc dù cũng có thể tạo ma trận bằng cách sử dụng `np.matrix()`, nhưng chúng ta sẽ sử dụng `np.array()` xuyên suốt các bài thực hành trong cuốn sách này.