

```
Trong [12]: x.dtype
```

```
Out[12]: dtype('int64')
```

Tại sao `x` lại bao gồm các số nguyên? Đó là vì chúng ta đã tạo ra `x` bằng cách truyền vào các số nguyên. chỉ truyền vào các số nguyên cho hàm `np.array()`. Nếu chúng ta đã truyền vào bất kỳ Nếu ta sử dụng số thập phân, thì ta sẽ thu được một mảng các số thực (tức là các số có giá trị thực).

nổi
điểm

```
Trong [13]: np.array([[1, 2], [3.0, 4]]).dtype
```

```
Out[13]: dtype('float64')
```

"Typing `fun?` " sẽ khiến `Python` hiển thị tài liệu liên quan đến...
Hàm `fun`, nếu nó tồn tại. Chúng ta có thể thử điều này với `np.array()`.

```
Trong [14]: np.array?
```

Tài liệu này cho thấy chúng ta có thể tạo một mảng số thực.
bằng cách truyền đối số `dtype` vào `np.array()`.

kiểu dữ liệu

```
Trong [15]: np.array([[1, 2], [3, 4]], float).dtype
```

```
Out[15]: dtype('float64')
```

Mảng `x` là mảng hai chiều. Ta có thể tìm ra số hàng và
các cột bằng cách xem xét thuộc tính `hình dạng` của chúng.

hình dạng

```
Trong [16]: x.hình dạng
```

```
Ra[16]: (2, 2)
```

Phương thức là một hàm được liên kết với một đối tượng. Ví dụ, cho một mảng `x`, biểu
thức `x.sum()` tính tổng tất cả các phần tử của nó, sử dụng...
Phương thức `sum()` dành cho mảng. Lệnh gọi `x.sum()` tự động cung cấp `x` làm đối số đầu tiên
cho phương thức `sum()` của nó.

phương pháp

.sum()

```
Trong [17]: x = np.array([1, 2, 3, 4])
x.sum()
```

```
Ra ngoài[17]: 10
```

Chúng ta cũng có thể tính tổng các phần tử của `x` bằng cách truyền `x` làm đối số cho hàm.
Hàm `np.sum()`.

np.sum()

```
Trong [18]: x = np.array([1, 2, 3, 4])
np.sum(x)
```

```
Ra ngoài[18]: 10
```

Ví dụ khác, phương thức `reshape()` trả về một mảng mới có cùng các phần tử với `x`,
nhưng có hình dạng khác. Chúng ta thực hiện điều này bằng cách truyền vào một `tuple`.

.reshape()
bộ

44 2. Học thống kê

trong lời gọi hàm `reshape()` của chúng ta, trong trường hợp này là `(2, 3)`. Bộ giá trị này chỉ định rằng chúng ta muốn tạo một mảng hai chiều với 2 hàng và 3 cột. Trong phần tiếp theo, ký tự `\n` tạo ra một dòng mới.

```
Trong [19]: x = np.array([1, 2, 3, 4, 5, 6]) print('bắt đầu
x:\n', x) x_reshape = x.reshape((2, 3))
print('đã định hình lại x:\n', x_reshape)
```

```
bắt đầu x:
[1 2 3 4 5 6] được
định hình lại
x: [[1 2
3] [4 5 6]]
```

Kết quả đầu ra trước đó cho thấy mảng `NumPy` được chỉ định dưới dạng một chuỗi các hàng. Điều này được gọi là thứ tự theo hàng (row-major ordering), trái ngược với thứ tự theo cột (column-major ordering).

`Python` (và do đó cả `numpy`) sử dụng chỉ mục dựa trên 0. Điều này có nghĩa là để truy cập phần tử trên cùng bên trái của `x_reshape`, chúng ta nhập `x_reshape[0,0]`.

```
Trong [20]: x_reshape[0, 0]
```

```
Ra[20]: 1
```

Tương tự, `x_reshape[1,2]` trả về phần tử ở hàng thứ hai và cột thứ ba của `x_reshape`.

```
Trong [21]: x_reshape[1, 2]
```

```
Ra ngoài[21]: 6
```

Tương tự, `x[2]` cho ra mục thứ ba của `x`.

Bây giờ, hãy sửa đổi phần tử trên cùng bên trái của `x_reshape`. Thật bất ngờ, chúng ta phát hiện ra rằng phần tử đầu tiên của `x` cũng đã bị thay đổi!

```
Trong [22]: print('x trước khi chúng ta sửa đổi x_reshape:\n', x)
print('x_reshape trước khi chúng ta sửa đổi x_reshape:\n', x_reshape) x_reshape[0, 0] = 5
print('x_reshape sau khi
chúng ta sửa đổi phần tử trên cùng bên trái của nó:\n', x_reshape)

print('x sau khi chúng ta sửa đổi phần tử trên cùng bên trái của x_reshape:\n', x)
```

```
Out[22]: x trước khi chúng ta sửa đổi x_reshape: [1 2 3 4 5
6]
x_reshape trước khi chúng ta sửa đổi x_reshape: [[1 2 3] [4
5 6]]
```

```
x_reshape sau khi chúng ta sửa đổi phần tử trên cùng bên trái của nó:
[[5 2 3]
```

Giống như danh sách, bộ dữ liệu (tuple) biểu diễn một chuỗi các đối tượng. Tại sao chúng ta cần nhiều hơn một cách để tạo ra một chuỗi? Có một vài điểm khác biệt giữa bộ dữ liệu và danh sách, nhưng có lẽ quan trọng nhất là các phần tử của bộ dữ liệu không thể được sửa đổi, trong khi các phần tử của danh sách thì có thể.

```
[4 5 6]]
x sau khi chúng ta sửa đổi phần tử trên cùng bên trái của x_reshape:
[5 2 3 4 5 6]
```

Việc sửa đổi `x_reshape` cũng đã sửa đổi `x` vì hai đối tượng này chiếm cùng một không gian trong bộ nhớ.

Chúng ta vừa thấy rằng ta có thể sửa đổi một phần tử của mảng. Vậy ta có thể sửa đổi một tuple không? Hóa ra là không thể – và việc cố gắng làm như vậy sẽ gây ra ngoại lệ, hay lỗi.

ngoại lệ

```
Trong [23]: my_tuple = (3, 4, 5)
my_tuple[0] = 2
```

`TypeError: đối tượng 'tuple' không hỗ trợ gán phần tử`

Chúng ta sẽ đi qua một số thuộc tính của mảng mà sẽ rất hữu ích.

Thuộc tính `'shape'` của mảng chứa kích thước của nó; kích thước này luôn là một bộ giá trị (tuple).

Thuộc tính `ndim` cung cấp số chiều, và `T` cung cấp ma trận chuyển vị của nó.

```
Trong [24]: x_reshape.shape, x_reshape.ndim, x_reshape.T
```

```
Ra[24]: ((2, 3),
        2, mảng([[5, 4],
                 [2, 5],
                 [3, 6]]))
```

Lưu ý rằng ba đầu ra riêng lẻ `(2,3)`, `2` và `mảng([[5, 4],[2, 5], [3,6]])` đều được xuất ra dưới dạng một bộ.

Chúng ta thường muốn áp dụng các hàm cho mảng. Ví dụ, chúng ta có thể tính căn bậc hai của các phần tử bằng cách sử dụng hàm `np.sqrt()` :

```
Trong [25]: np.sqrt(x)
```

```
Out[25]: array([2.24, 1.41, 1.73, 2., 2.24, 2.45])
```

Chúng ta cũng có thể bình phương các phần tử:

```
Trong [26]: x**2
```

```
Out[26]: array([25, 4, 9, 16, 25, 36])
```

Chúng ta có thể tính căn bậc hai bằng cách sử dụng cùng một ký hiệu, nhưng nâng lên lũy thừa $1/2$ thay vì 2 .

```
Trong [27]: x**0.5
```

```
Out[27]: array([2.24, 1.41, 1.73, 2., 2.24, 2.45])
```

Trong suốt cuốn sách này, chúng ta sẽ thường xuyên cần tạo dữ liệu ngẫu nhiên. Hàm `np.random.noirmal()` tạo ra một vectơ các biến ngẫu nhiên phân phối chuẩn.

Chúng ta có thể tìm hiểu thêm về hàm này bằng cách xem trang trợ giúp, thông qua lệnh gọi `np.random.noirmal?`. Dòng đầu tiên của trang trợ giúp có nội dung là `normal(loc=0.0, scale=1.0, size=None)`. Dòng chữ ký này cho chúng ta biết rằng hàm này...

`np.random.noirmal()`

chữ ký

Các tham số là `loc`, `scale` và `size`. Đây là các tham số từ khóa, có nghĩa là khi chúng được truyền từ khóa vào hàm, chúng có thể được tham chiếu đến.

theo tên (theo bất kỳ thứ tự nào).³ Theo mặc định, hàm này sẽ tạo ngẫu nhiên biến ngẫu nhiên thông thường với giá trị trung bình (`loc`) là 0 và độ lệch chuẩn (`scale`) là 1; hơn nữa, một biến ngẫu nhiên duy nhất sẽ được tạo ra trừ khi đối số

Kích thước đã được thay đổi.

Bây giờ chúng ta tạo ra 50 biến ngẫu nhiên độc lập từ phân phối $N(0, 1)$.

```
Trong [28]: x = np.random.normal(size=50)
x
```

```
Out[28]: array([-1.19,  0.41,  0.9          , -0.44, -0.9          , -0.38,  0.13,  1.87,
               -0.35,  1.16,  0.79, -0.97, -1.21,  0.06, -1.62, -0.6 -0.77, -2.12,  0.38,
               -1.22, -0.06, -1.97, -1.74, -0.56,
               1.7   , -0.95,  0.56,  0.35,  0.87,  0.88, -1.66, -0.32,
               -0.3, -1.36,  0.92, -0.31,  1.28, -1.94,  1.07,  0.07,
               0.79, -0.46,  2.19, -0.27, -0.64,  0.85,  0.13,  0.46,
               -0.09,  0.7  ])
```

Chúng ta tạo một mảng `y` bằng cách thêm một biến ngẫu nhiên độc lập $N(50, 1)$ cho mỗi phần tử của `x`.

```
Trong [29]: y = x + np.random.normal(loc=50, scale=1, size=50)
```

Hàm `np.corrcoef()` tính toán ma trận tương quan giữa `x` và `y`. Các phần tử ngoài đường chéo chính cho biết hệ số tương quan giữa `x` và `y`. `np.corrcoef()`

```
Trong [30]: np.corrcoef(x, y)
```

```
Out[30]: array([[1. ,  0.69],
                [0.69,  1. ]])
```

Nếu bạn đang làm theo hướng dẫn trong sổ tay *Jupyter* của riêng mình, thì có lẽ bạn sẽ thấy... Tôi nhận thấy bạn nhận được kết quả khác nhau khi chạy vài lần gần đây. các lệnh. Cụ thể, mỗi lần chúng ta gọi `np.random.normal()`, chúng ta sẽ nhận được Một câu trả lời khác, như được minh họa trong ví dụ sau.

```
Trong [31]: print(np.random.normal(scale=5, size=2))
print(np.random.normal(scale=5, size=2))
```

```
Ra ngoài[31]: [4.28 2.59]
[4.62 -2.54]
```

Để đảm bảo rằng mã của chúng tôi cung cấp kết quả chính xác như nhau trong mỗi trường hợp. Khi chạy, chúng ta có thể thiết lập một hạt giống ngẫu nhiên bằng cách sử dụng hàm `np.random.default_rng()`. Hàm này nhận một đối số số nguyên tùy ý do người dùng chỉ định. Nếu chúng ta đặt một hạt giống ngẫu nhiên trước khi tạo dữ liệu ngẫu nhiên, thì việc chạy lại sẽ... Mã của chúng ta sẽ cho ra kết quả tương tự. Đối tượng `rng` về cơ bản chứa tất cả các thông tin cần thiết.

hạt giống ngẫu nhiên
`np.random.default_rng()`

³Python cũng sử dụng các đối số vị trí. Các đối số vị trí không cần phải sử dụng một từ khóa. Để xem ví dụ, hãy nhập `np.sum?`. Ta thấy rằng `a` là một đối số vị trí. Tức là hàm này giả định rằng đối số không tên đầu tiên mà nó nhận được là mảng. cần được tóm tắt. Ngược lại, `axis` và `dtype` là các đối số từ khóa: vị trí trong Việc các đối số này được nhập vào `np.sum()` bằng cách nào không quan trọng.

Các phương thức tạo số ngẫu nhiên được tìm thấy trong `np.random`. Do đó, để tạo dữ liệu phân bố chuẩn, chúng ta sử dụng `rng.normal()`.

```
Trong [32]: rng = np.random.default_rng(1303)
print(rng.normal(scale=5, size=2)) rng2 =
np.random.default_rng(1303)
print(rng2.normal(scale=5, size=2))
```

```
Ra[32]: [4.09 -1.07 ]
        [4.09 -1.07 ]
```

Trong suốt các bài thực hành trong cuốn sách này, chúng ta sử dụng `np.random.default_rng()` bất cứ khi nào thực hiện các phép tính liên quan đến các đại lượng ngẫu nhiên trong `numpy`. Về nguyên tắc, điều này sẽ cho phép người đọc tái tạo chính xác các kết quả đã nêu. Tuy nhiên, khi các phiên bản `numpy` mới hơn được phát hành, có thể xảy ra một số sai lệch nhỏ giữa kết quả trong các bài thực hành và kết quả từ `numpy`.

Các hàm `np.mean()`, `np.var()` và `np.std()` có thể được sử dụng để tính toán `np.mean()` trung bình, phương sai và độ lệch chuẩn của mảng. Các hàm này cũng có sẵn dưới dạng phương thức trên mảng. `np.var()`

```
Trong [33]: rng = np.random.default_rng(3) y
           = rng.standard_normal(10)
           np.mean(y), y.mean()
```

```
Out[33]: (-0.11, -0.11)
```

```
Trong [34]: np.var(y), y.var(), np.mean((y - y.mean())**2)
```

```
Ra[34]: (2,72, 2,72, 2,72)
```

Lưu ý rằng theo mặc định, `np.var()` chia cho kích thước mẫu n thay vì $n - 1$; xem đối số `ddof` trong `np.var()`.

```
Trong [35]: np.sqrt(np.var(y)), np.std(y)
```

```
Ra[35]: (1,65, 1,65)
```

Các hàm `np.mean()`, `np.var()` và `np.std()` cũng có thể được áp dụng cho các hàng và cột của ma trận. Để thấy điều này, chúng ta xây dựng một ma trận 10×3 gồm $N(0, 1)$ biến ngẫu nhiên và xem xét việc tính tổng các hàng của nó.

```
Trong [36]: X = rng.standard_normal((10, 3))
           X
```

```
Out[36]: array([[ 0.23, -0.35, -0.28],
                [-0.67, -1.06, -0.39],
                [ 0.48, -0.24,  0.96],
                [-0.2 ,  0.02,  1.55],
                [ 0.55, -0.51, -0.18],
                [ 0.54,  1.94, -0.27],
                [-0.24,  1. , -0.89],
                [-0.29,  0.88,  0.58],
                [ 0.09,  0.67, -2.83],
                [ 1.02, -0.96, -1.67]])
```

Vì mảng được sắp xếp theo hàng, nên trục đầu tiên, tức là `axis=0`, đề cập đến phần tử của nó. Chúng ta truyền đối số này vào phương thức `mean()` của đối tượng `X`.

`.nhĩa là()`

Trong [37]: `X.mean(axis=0)`

Out[37]: `array([0.15, 0.14, -0.34])`

Cách làm sau đây cũng cho kết quả tương tự.

Trong [38]: `X.mean(0)`

Out[38]: `array([0.15, 0.14, -0.34])`

2.3.4 Đồ họa

Trong `Python`, thông lệ phổ biến là sử dụng thư viện `matplotlib` để vẽ đồ họa.

`matplotlib`

Tuy nhiên, vì `Python` không được viết ra với mục đích phân tích dữ liệu, nên khái niệm về đồ thị không phải là tính năng vốn có của ngôn ngữ này. Chúng ta sẽ sử dụng hàm `subplots()`. Hàm từ thư viện `matplotlib.pyplot` dùng để tạo hình vẽ và các trục tọa độ mà hình vẽ đó xoay quanh. Chúng ta vẽ biểu đồ dữ liệu. Để xem thêm nhiều ví dụ về cách tạo biểu đồ trong `Python`, hãy tham khảo... Đọc giả được khuyến khích truy cập matplotlib.org/stable/gallery/.

Trong `matplotlib`, một đồ thị bao gồm một hình vẽ và một hoặc nhiều trục tọa độ. Bạn có thể coi hình vẽ như một khung trống mà trên đó một hoặc nhiều đồ thị sẽ được vẽ. được hiển thị: đó là toàn bộ cửa sổ đồ thị. Các trục chứa thông tin quan trọng. Thông tin về từng đồ thị, chẳng hạn như nhãn trục x và trục y, tiêu đề, và thêm nữa. (Lưu ý rằng trong `matplotlib`, từ "axes" không phải là dạng số nhiều của "axis":a) Các trục của đồ thị chứa nhiều thông tin hơn là chỉ trục x và trục y. trục y.)

nhãn và t
trục

Chúng ta bắt đầu bằng cách nhập hàm `subplots()` từ `matplotlib`. Chúng ta sử dụng hàm này xuyên suốt quá trình tạo hình ảnh. Hàm này trả về giá trị (...)

`subplots()`

Một bộ gồm hai phần tử: một đối tượng hình vẽ và một đối tượng trục tọa độ tương ứng. Thông thường, chúng ta sẽ truyền `figsize` dưới dạng tham số từ khóa. Sau khi tạo ra sản phẩm của chúng ta... Với các trục tọa độ, chúng ta sẽ thử vẽ đồ thị đầu tiên bằng phương thức `'plot()'`. Để tìm hiểu thêm về phương thức này, hãy gõ `'ax.plot?'`.

`.kích bản()`

Trong [39]: từ `matplotlib.pyplot` nhập `subplots`
`hình, trục = subplots(kích thước hình=(8, 8))`
`x = rng.standard_normal(100)`
`y = rng.standard_normal(100)`
`ax.plot(x, y);`

Chúng ta tạm dừng ở đây để lưu ý rằng chúng ta đã giải nén bộ dữ liệu có độ dài hai được trả về bởi hàm `subplots()` thành hai biến riêng biệt là `fig` và `ax`. Giải nén thường được ưa chuộng hơn so với cách diễn đạt tương đương nhưng dài dòng hơn một chút sau đây. mã số:

Trong [40]: `output = subplots(figsize=(8, 8))`
`hình = đầu ra[0]`
`ax = đầu ra[1]`

Chúng ta thấy rằng ô trước đó đã tạo ra biểu đồ đường, đây là chế độ mặc định. Để tạo biểu đồ phân tán, chúng ta cung cấp thêm một đối số cho hàm `ax.plot()`, Điều này cho thấy cần hiển thị các hình tròn.

```
Trong [41]: fig, ax = subplots(figsize=(8, 8))
          ax.plot(x, y, 'o');
```

Các giá trị khác nhau của đối số bổ sung này có thể được sử dụng để tạo ra các đường kẻ có màu sắc khác nhau cũng như các kiểu đường kẻ khác nhau.

Ngoài ra, chúng ta cũng có thể sử dụng hàm `ax.scatter()` để tạo biểu đồ phân tán.

`.tiêu_tan()`

```
Trong [42]: fig, ax = subplots(figsize=(8, 8))
          ax.scatter(x, y, marker='o');
```

Hãy lưu ý rằng trong các khối mã ở trên, chúng ta đã kết thúc dòng cuối cùng bằng dấu chấm phẩy. Điều này ngăn `ax.plot(x, y)` in văn bản ra sổ tay.

Tuy nhiên, điều đó không ngăn cản việc tạo ra biểu đồ. Nếu ta bỏ dấu chấm phẩy cuối cùng, ta sẽ thu được kết quả sau:

```
Trong [43]: fig, ax = subplots(figsize=(8, 8))
          ax.scatter(x, y, marker='o')
```

```
Out[43]: <matplotlib.collections.PathCollection at 0x7fb3d9c8f310 >
Hình (432x288)
```

Trong phần tiếp theo, chúng ta sẽ sử dụng dấu chấm phẩy ở cuối câu bất cứ khi nào đoạn văn bản được xuất ra không liên quan đến nội dung đang thảo luận.

Để gắn nhãn cho đồ thị, chúng ta sử dụng các phương thức `set_xlabel()`, `set_ylabel()` và `set_title()` của `ax`.

`.set_xlabel()`

`.set_ylabel()`

`.set_title()`

```
Trong [44]: fig, ax = subplots(figsize=(8, 8)) ax.scatter(x,
y, marker='o') ax.set_xlabel("đây là trục
x") ax.set_ylabel("đây là trục y") ax.set_title("Đồ
thị X so với Y");
```

Việc có quyền truy cập vào chính đối tượng hình vẽ `fig` có nghĩa là chúng ta có thể vào đó và thay đổi một số khía cạnh rồi hiển thị lại. Ở đây, chúng ta thay đổi kích thước từ `(8, 8)` thành `(12, 3)`.

```
fig.set_size_inches(12,3) fig
```

Đôi khi chúng ta muốn tạo nhiều đồ thị trong cùng một hình. Điều này có thể đạt được bằng cách truyền thêm các đối số cho hàm `subplots()`. Dưới đây, chúng ta tạo một lưới đồ thị 2×3 trong một hình có kích thước được xác định bởi đối số `figsize`. Trong những trường hợp như vậy, thường có mối quan hệ giữa các trục trong các đồ thị. Ví dụ, tất cả các đồ thị có thể có chung trục x. Hàm `subplots()` có thể tự động xử lý tình huống này khi được truyền đối số từ khóa `sharex=True`. Đối tượng `axes` bên dưới là một mảng trỏ đến các đồ thị khác nhau trong hình.

```
Trong [45]: fig, axes = subplots(nrows=2,
                                ncols=3,
                                figsize=(15, 5))
```

Bây giờ chúng ta tạo một biểu đồ phân tán với ký tự `'o'` ở cột thứ hai của hàng đầu tiên và một biểu đồ phân tán với ký tự `'+'` ở cột thứ ba của hàng thứ hai.

```
Trong [46]: trục[0,1].plot(x, y, 'o')
trục[1,2].phân tán(x, y, marker='+')
```

Nhập "subplots?" để tìm hiểu thêm về hàm `subplots()`.
Để lưu kết quả của `fig`, chúng ta gọi phương thức `savefig()` của nó. Tham số `dpi` là số điểm ảnh trên mỗi inch, được sử dụng để xác định kích thước của hình ảnh sẽ như thế nào. `.savefig()`
pixel.

```
Trong [47]: fig.savefig("Figure.png", dpi=400)
fig.savefig("Figure.pdf", dpi=200);
```

Chúng ta có thể tiếp tục chỉnh sửa hình vẽ bằng cách cập nhật từng bước; ví dụ: Chúng ta có thể sửa đổi phạm vi của trục x, lưu lại hình vẽ, và thậm chí hiển thị lại. Nó.

```
Trong [48]: trục[0,1].set_xlim([-1,1])
fig.savefig("Figure_updated.jpg")
```

Giờ chúng ta sẽ tạo ra một số biểu đồ phức tạp hơn. Phương thức `ax.contour()` tạo ra biểu đồ đường đồng mức để biểu diễn dữ liệu ba chiều, tương tự như bản đồ địa hình. `.contour()`
Phương thức này nhận ba tham số: biểu đồ đường đồng mức

- Một vectơ gồm các giá trị `x` (chiều thứ nhất),
- Một vectơ các giá trị `y` (chiều thứ hai), và
- Một ma trận có các phần tử tương ứng với giá trị `z` (chiều thứ ba) (sion) cho mỗi cặp tọa độ `(x,y)`.

Để tạo ra `x` và `y`, chúng ta sẽ sử dụng lệnh `np.linspace(a, b, n)`, lệnh này trả về một vectơ gồm `n` số bắt đầu từ `a` và kết thúc ở `b`. `np.linspace()`

```
Trong [49]: fig, ax = subplots(figsize=(8, 8))
x = np.linspace(-np.pi, np.pi, 50)
y=x
f = np.multiply.outer(np.cos(y), 1 / (1 + x**2))
ax.contour(x, y, f);
```

Chúng ta có thể tăng độ phân giải bằng cách thêm nhiều lớp vào hình ảnh.

```
Trong [50]: fig, ax = subplots(figsize=(8, 8))
ax.contour(x, y, f, levels=45);
```

Để tinh chỉnh đầu ra của hàm `ax.contour()`, hãy xem phần sau:
Tệp trợ giúp có thể được tìm thấy bằng cách gõ `plt.contour`.
Phương thức `ax.imshow()` tương tự như `ax.contour()`, ngoại trừ việc nó tạo ra một biểu đồ mã màu với các màu sắc phụ thuộc vào giá trị `z`. Điều này được biết đến `.imshow()`
Nó được dùng như một bản đồ nhiệt, và đôi khi được sử dụng để biểu diễn nhiệt độ trong các dự báo thời tiết. bản đồ nhiệt

```
Trong [51]: fig, ax = subplots(figsize=(8, 8))
ax.imshow(f);
```


2.3.5 Chuỗi và ký hiệu lát cắt

Như đã thấy ở trên, hàm `np.linspace()` có thể được sử dụng để tạo ra một dãy số.

```
Trong [52]: seq1 = np.linspace(0, 10, 11)
           seq1
```

```
Out[52]: array([ 0.,  1.,  2.,  3.,  4.,  5.,  6.,  7.,  8.,  9., 10.])
```

Hàm `np.arange()` trả về một dãy số được phân cách bởi *bước nhảy*. Nếu *bước nhảy* không được chỉ định, giá trị mặc định là 1 sẽ được sử dụng. Hãy tạo một dãy số bắt đầu từ 0 và kết thúc ở 10.

`np.arange()`

```
Trong [53]: seq2 = np.arange(0, 10)
           seq2
```

```
Out[53]: array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

Tại sao kết quả hiển thị ở trên không phải là 10? Điều này liên quan đến cú pháp cắt lát trong *Python*. Ký hiệu lát cắt được sử dụng để lập chỉ mục các chuỗi như danh sách, bộ dữ liệu và mảng. Giả sử chúng ta muốn truy xuất các mục thứ tư đến thứ sáu (bao gồm) của một chuỗi. Chúng ta thu được một phần của chuỗi bằng cách sử dụng ký hiệu chỉ mục `[3:6]`.

```
Trong [54]: "xin chào thế giới"[3:6]
```

```
Ra[54]: 'lo '
```

Trong khối mã ở trên, ký hiệu `3:6` là viết tắt của `slice(3,6)` khi được sử dụng bên trong `[]`.

```
Trong [55]: "hello world"[slice(3,6)]
```

```
Ra[55]: 'lo '
```

Bạn có thể mong đợi `slice(3,6)` sẽ xuất ra các ký tự thứ tư đến thứ sáu trong chuỗi văn bản (nhớ rằng *Python* bắt đầu đánh chỉ mục từ số không), nhưng thay vào đó nó lại xuất ra các ký tự thứ tư đến thứ sáu. Điều này cũng giải thích tại sao lệnh `np.arange(0, 10)` trước đó chỉ xuất ra các số nguyên từ 0 đến 9. Xem tài liệu *slice?* để biết các tùy chọn hữu ích khi tạo lát cắt.

2.3.6 Lập chỉ mục dữ liệu

Đầu tiên, chúng ta tạo một mảng *numpy* hai chiều.

```
Trong [56]: A = np.array(np.arange(16)).reshape((4, 4))
```

```
Out[56]: array([[ 0,  1,  2,  3], [ 4,
                    5,  6,  7], [ 8,  9,
                    10, 11], [12, 13,
                    14, 15]])
```

Gõ `A[1,2]` sẽ truy xuất phần tử tương ứng với hàng thứ hai và cột thứ ba. (Như thường lệ, *Python* đánh số từ 0.)

```
Trong [57]: A[1,2]
```

```
Ra ngoài[57]: 6
```

Số đầu tiên sau dấu ngoặc vuông [biểu thị hàng, và số thứ hai biểu thị cột.

Lập chỉ mục hàng, cột và ma trận con

Để chọn nhiều hàng cùng một lúc, chúng ta có thể truyền vào một danh sách chỉ định lựa chọn của mình. Ví dụ, [1,3] sẽ truy xuất hàng thứ hai và hàng thứ tư:

```
Trong [58]: A[[1,3]]
```

```
Out[58]: array([[ 4, 5, 6, 7], [12, 13,
                  14, 15]])
```

Để chọn cột thứ nhất và cột thứ ba, ta truyền [0,2] làm đối số thứ hai trong dấu ngoặc vuông. Trong trường hợp này, ta cần cung cấp đối số đầu tiên : điều này sẽ chọn tất cả các hàng.

```
Trong [59]: A[:,[0,2]]
```

```
Out[59]: array([[ 0, 2], [ 4,
                  6], [ 8,
                  10], [12,
                  14]])
```

Bây giờ, giả sử chúng ta muốn chọn ma trận con được tạo thành từ hàng thứ hai và thứ tư cũng như cột thứ nhất và thứ ba. Đây là lúc việc lập chỉ mục trở nên hơi phức tạp. Thông thường, người ta sẽ cố gắng sử dụng danh sách để truy xuất các hàng và cột:

```
Trong [60]: A[[1,3],[0,2]]
```

```
Out[60]: array([ 4, 14])
```

Ồi không – chuyện gì đã xảy ra vậy? Chúng ta nhận được một mảng một chiều có độ dài hai giống hệt với

```
Trong [61]: np.array([A[1,0],A[3,2]])
```

```
Out[61]: array([ 4, 14])
```

Tương tự, đoạn mã sau không thể trích xuất ma trận con bao gồm hàng thứ hai và thứ tư cùng các cột thứ nhất, thứ ba và thứ tư:

```
Trong [62]: A[[1,3],[0,2,3]]
```

```
IndexError: hình dạng không khớp: không thể mở rộng mảng chỉ mục cùng với hình dạng (2,) (3,)
```

Chúng ta có thể thấy vấn đề ở đây là gì. Khi được cung cấp hai danh sách chỉ mục, cách hiểu của NumPy là chúng cung cấp các cặp chỉ mục i, j cho một chuỗi các mục nhập. Đó là lý do tại sao cặp danh sách phải có cùng độ dài.

Tuy nhiên, đó không phải là ý định của chúng tôi, vì chúng tôi đang tìm kiếm một ma trận con.

Một cách đơn giản để thực hiện việc này như sau. Đầu tiên, chúng ta tạo một ma trận con bằng cách chọn lọc các hàng của ma trận A, và sau đó, chúng ta tạo thêm một ma trận con khác bằng cách chọn lọc các cột của ma trận con đó.

```
Trong [63]: A[[1,3]][:,[0,2]]
```

```
Out[63]: array([[ 4,  6],
                [12, 14]])
```

Có những cách hiệu quả hơn để đạt được kết quả tương tự.

Hàm tiện ích `np.ix_()` cho phép chúng ta trích xuất một ma trận con bằng cách sử dụng liệt kê, bằng cách tạo một đối tượng lưới trung gian .

chức năng
tiện lợi

```
Trong [64]: idx = np.ix_([1,3],[0,2,3])
           A[idx]
```

`np.ix_()`
lưới

```
Out[64]: array([[ 4,  6,  7],
                [12, 14, 15]])
```

Ngoài ra, chúng ta cũng có thể trích xuất các phần tử con của ma trận một cách hiệu quả bằng cách sử dụng các lát cắt. Lát cắt `1:4:2` bao gồm phần tử thứ hai và thứ tư của một chuỗi, trong khi lát cắt `0:3:2` bao gồm phần tử thứ nhất và thứ ba (phần tử thứ ba trong chuỗi lát cắt là kích thước bước).

```
Trong [65]: A[1:4:2,0:3:2]
```

```
Out[65]: array([[ 4,  6],
                [12, 14]])
```

Tại sao chúng ta có thể truy xuất trực tiếp một ma trận con bằng cách sử dụng slice nhưng không thể sử dụng list? Đó là vì chúng là các kiểu dữ liệu khác nhau trong Python và được NumPy xử lý khác nhau. Slice có thể được sử dụng để trích xuất các đối tượng từ các chuỗi tùy ý, chẳng hạn như chuỗi ký tự, danh sách và bộ dữ liệu, trong khi việc sử dụng list để lập chỉ mục thì hạn chế hơn.

Lập chỉ mục Boolean

Trong `numpy`, Boolean là kiểu dữ liệu bằng `True` hoặc `False` (cũng được biểu diễn tương ứng là 1 và 0). Dòng tiếp theo tạo một vectơ gồm toàn số 0, được biểu diễn dưới dạng Boolean, có độ dài bằng chiều thứ nhất của ma trận A.

Boolean

```
Trong [66]: keep_rows = np.zeros(A.shape[0], bool)
           keep_rows
```

```
Out[66]: array([Sai, Sai, Sai, Sai])
```

Giờ chúng ta đặt hai trong số các phần tử thành `True`.

```
Trong [67]: keep_rows[[1,3]] = True
           keep_rows
```

```
Out[67]: array([False, True, False, True])
```

Lưu ý rằng các phần tử của `keep_rows`, khi được xem như số nguyên, giống với các giá trị của `np.array([0,1,0,1])`. Bên dưới, chúng ta sử dụng `==` để kiểm tra sự bằng nhau của chúng. Khi áp dụng cho hai mảng, phép toán `==` được áp dụng trên từng phần tử.

```
Trong [68]: np.all(keep_rows == np.array([0,1,0,1]))
```

```
Ra ngoài[68]: Đúng
```

(Ở đây, hàm `np.all()` kiểm tra xem tất cả các phần tử của mảng `np.all()` có phải là `True` hay không. Một hàm tương tự, `np.any()`, có thể được sử dụng để kiểm tra xem có bất kỳ phần tử nào trong mảng `np.any()` có phải là `True` hay không.)

Tuy nhiên, mặc dù `np.array([0,1,0,1])` và `keep_rows` bằng nhau theo toán tử `==`, chúng lại truy cập các tập hợp hàng khác nhau! Phương thức trước truy xuất hàng thứ nhất, thứ hai, hàng thứ nhất và hàng thứ hai của mảng A.

```
Trong [69]: A[np.array([0,1,0,1])]
```

```
Out[69]: array([[0, 1, 2, 3], [4,
      5, 6, 7], [0,
      1, 2, 3], [4,
      5, 6, 7]])
```

Ngược lại, `keep_rows` chỉ truy xuất hàng thứ hai và thứ tư của A – tức là các hàng mà giá trị Boolean bằng `TRUE`.

```
Trong [70]: A[keep_rows]
```

```
Out[70]: array([[ 4, 5, 6, 7], [12,
      13, 14, 15]])
```

Ví dụ này cho thấy rằng kiểu dữ liệu Boolean và số nguyên được xử lý khác nhau bởi `numpy`.

Chúng ta lại sử dụng hàm `np.ix_()` để tạo một lưới chứa hàng thứ hai và thứ tư, cùng các cột thứ nhất, thứ ba và thứ tư. Lần này, chúng ta áp dụng hàm này cho các giá trị Boolean, thay vì danh sách.

```
Trong [71]: keep_cols = np.zeros(A.shape[1], bool)
keep_cols[[0, 2, 3]] = True
idx_bool = np.ix_(keep_rows, keep_cols)
A[idx_bool]
```

```
Out[71]: array([[ 4, 6, 7],
      [12, 14, 15]])
```

Chúng ta cũng có thể kết hợp một danh sách với một mảng các giá trị Boolean trong các đối số của `np.ix_()`:

```
Trong [72]: idx_mixed = np.ix_([1,3], keep_cols)
A[idx_mixed]
```

```
Out[72]: array([[ 4, 6, 7],
      [12, 14, 15]])
```

Để biết thêm chi tiết về việc lập chỉ mục trong `numpy`, độc giả có thể tham khảo hướng dẫn `numpy` đã đề cập trước đó.

2.3.7 Tải dữ liệu

Các tập dữ liệu thường chứa nhiều loại dữ liệu khác nhau và có thể có tên được liên kết với các hàng hoặc cột. Vì những lý do này, chúng thường được...
Cách tốt nhất để xử lý vấn đề này là sử dụng data frame. Chúng ta có thể coi data frame như một chuỗi các mảng có độ dài giống nhau; đây là các cột. Các mục trong
khung dữ liệu
Các mảng khác nhau có thể được kết hợp để tạo thành một hàng. Thư viện pandas có thể
Được sử dụng để tạo và làm việc với các đối tượng khung dữ liệu.

Đọc tập dữ liệu

Bước đầu tiên của hầu hết các phân tích là nhập tập dữ liệu vào Python.
Trước khi cố gắng tải một tập dữ liệu, chúng ta phải đảm bảo rằng Python biết
Vị trí tìm thấy tệp chứa nó. Nếu tệp nằm cùng vị trí với tệp này
Sau khi thêm tệp notebook, chúng ta đã hoàn tất. Nếu không, có thể sử dụng lệnh os.chdir() để
os.chdir()
thay đổi thư mục. (Bạn cần gọi import os trước khi gọi lệnh này)

os.chdir(..)
Chúng ta sẽ bắt đầu bằng cách đọc dữ liệu từ tệp Auto.csv, có sẵn trên trang web của cuốn sách. Tệp này
Đây là một tập tin được phân tách bằng dấu phẩy và có thể được đọc bằng cách sử dụng pd.read_csv():
pd.read_csv()

```
Trong [73]: import pandas as pd
Auto = pd.read_csv('Auto.csv')
Tư đồ ng
```

Trang web của cuốn sách cũng có một phiên bản dữ liệu được phân tách bằng khoảng trắng.
Được gọi là Auto.data. Có thể đọc dữ liệu này như sau:

```
Trong [74]: Auto = pd.read_csv('Auto.data', delim_whitespace=True)
```

Cả Auto.csv và Auto.data đều chỉ là các tệp văn bản. Trước khi tải dữ liệu vào...
Đối với Python, tốt nhất nên xem mã nguồn bằng trình soạn thảo văn bản hoặc phần mềm khác.
Ví dụ như Microsoft Excel.

Bây giờ chúng ta hãy xem xét cột Auto tương ứng với biến số đó.

mã lực:

```
Trong [75]: Auto['horsepower']
```

```
Ra[75]: 0      130.0
        165.0
        1  150.0
        150.0
        3  140.0
        ...
        392  86,00
        393  52,00
        394  84,00
        395  79,00
        396  82,00
```

Tên: mã lực, Độ dài: 397, kiểu dữ liệu: object

Ta thấy rằng kiểu dữ liệu (dtype) của cột này là object. Hóa ra tất cả các giá trị đều như vậy.
Các giá trị trong cột mã lực được hiểu là chuỗi ký tự khi đọc.
dữ liệu. Chúng ta có thể tìm ra lý do bằng cách xem xét các giá trị duy nhất.

```
Trong [76]: np.unique(Auto['horsepower'])
```

Để tiết kiệm không gian, chúng tôi đã lược bỏ kết quả đầu ra của khối mã trước đó. Chúng tôi Thủ phạm chính là giá trị ?, được sử dụng để mã hóa các giá trị bị thiếu.

Để khắc phục sự cố, chúng ta phải cung cấp một đối số cho `pd.read_csv()` được gọi là `na_values`. Bây giờ, mỗi lần xuất hiện dấu ? trong tệp sẽ được thay thế bằng dấu `np.nan`, có nghĩa là không phải là số:

```
Trong [77]: Auto = pd.read_csv('Auto.data',
                             na_values=['?'],
                             delim_whitespace=True)
Auto['horsepower'].sum()
```

Out[77]: 40952.0

Thuộc tính `Auto.shape` cho chúng ta biết rằng dữ liệu có 397 quan sát, hay nói cách khác, hàng và chín biến, hay cột.

```
Trong [78]: Auto.shape
```

Ra ngoài[78]: (397, 9)

Có nhiều cách để xử lý dữ liệu bị thiếu. Trong trường hợp này, vì Vì chỉ có năm hàng chứa dữ liệu bị thiếu, chúng tôi chọn sử dụng phương pháp này. Phương thức `Auto.dropna()` được sử dụng để xóa các hàng này một cách đơn giản.

```
Trong [79]: Auto_new = Auto.dropna()
Auto_new.shape
```

Ra ngoài[79]: (392, 9)

Những kiến thức cơ bản về chọn hàng và cột Chúng ta có thể sử dụng `Auto.columns` để kiểm tra tên biến.

```
Trong [80]: Auto = Auto_new # ghi đè giá trị trước đó
Cột tự động
```

Out[80]: Index(['mpg', 'cylinders', 'displacement', 'horsepower', 'trọng lượng', 'gia tốc', 'năm', 'nguồn gốc', 'tên'], dtype='object')

Việc truy cập các hàng và cột của một data frame tương tự, nhưng không hoàn toàn giống với việc truy cập các hàng và cột của một mảng. Hãy nhớ rằng điều đầu tiên Đối số truyền vào phương thức `[]` luôn được áp dụng cho các hàng của mảng. Tương tự, việc truyền vào một slice cho phương thức `[]` sẽ tạo ra một data frame có các hàng tương ứng . được xác định bởi lát cắt:

```
Trong [81]: Tự động[:3]
```

Ra ngoài[81]:

	mpg	xi lanh	dung tích mã	lực trọng lượng	18.0	307.0	130.0	3504.0	...
0			8						...
1	15.0		8		350.0		165.0	3693.0	...
2	18.0		8		318.0		150.0	3436.0	...

Tương tự, một mảng các giá trị Boolean có thể được sử dụng để chọn lọc các hàng:

```
Trong [82]: idx_80 = Auto['year'] > 80
           Tự động[idx_80]
```

Tuy nhiên, nếu ta truyền vào một danh sách chuỗi cho phương thức `[]` thì ta sẽ nhận được một Khung dữ liệu chứa tập hợp các cột tương ứng.

```
Trong [83]: Ô tô[['mpg', 'mã lực']]
```

```
Ra ngoài[83]:      18.0      mã lực
              0      mpg      130.0
              1      15.0      165.0
              2      18.0      150.0
              3      16.0      150.0
              4      17.0      140.0
              ...      ...      ...
            392      27.0      86.0
            393      44.0      52.0
            394      32.0      84.0
            395      28.0      79.0
            396      31.0      82.0
            392 hàng x 2 cột
```

Vì chúng ta không chỉ định cột chỉ mục khi tải khung dữ liệu, Các hàng được đánh số từ 0 đến 396.

```
Trong [84]: Auto.index
```

```
Out[84]: Int64Index([ 0,          1,    2, 3, 4, 5,          6,    7,    8,    9,
                    ...,
                    387, 388, 389, 390, 391, 392, 393, 394, 395, 396],
                  dtype='int64', length=392)
```

Chúng ta có thể sử dụng phương thức `set_index()` để đổi tên các hàng bằng cách sử dụng nội dung của `Auto['name']`. `.set_index()`

```
Trong [85]: Auto_re = Auto.set_index('name')
           Tự động_re
```

```
Ra ngoài[85]:      mpg dung tích xi lanh ...
              tên
Chevrolet Chevelle Malibu 18.0      8      307.0      ...
              Buick Skylark 32 15.0 Plymouth      8      350.0      ...
              Satellite 18.0 AMC Rebel SST 16.0      8      318.0      ...
              8      304.0      ...
```

```
Trong [86]: Auto_re.columns
```

```
Out[86]: Index(['mpg', 'cylinders', 'displacement', 'horsepower',
               ['trọng lượng', 'gia tốc', 'năm', 'nguồn gốc'],
               dtype='object')
```

Chúng ta thấy rằng cột `'tên'` không còn tồn tại nữa.

Giờ đây, sau khi đã thiết lập chỉ mục theo `tên`, chúng ta có thể truy cập các hàng dữ liệu.

Tìm kiếm theo `tên` bằng phương thức `loc[]` của `Auto`:

```
.loc[]
```

```
Trong [87]: hàng = ['amc rebel sst', 'ford torino']
Auto_re.loc[rows]
```

Ra ngoài[87]:

tên	mpg	xi-lanh	dung tích	mã lực	...
amc rebel sst	16.0	8	304.0	150.0	...
Ford Torino	17.0	8	302.0	140.0	...

Thay vì sử dụng tên chỉ mục, chúng ta có thể truy xuất chỉ mục thứ 4 và
Hàng thứ 5 của `Auto` sử dụng phương thức `iloc[]` :

```
Trong [88]: Auto_re.iloc[[3,4]]
```

Chúng ta cũng có thể sử dụng nó để truy xuất cột thứ nhất, thứ ba và thứ tư của `Auto_re`:

```
Trong [89]: Auto_re.iloc[:,[0,2,3]]
```

Chúng ta có thể trích xuất hàng thứ 4 và thứ 5, cũng như hàng thứ 1, thứ 3 và thứ 4.
các cột, sử dụng một lệnh gọi duy nhất đến `iloc[]`:

```
Trong [90]: Auto_re.iloc[[3,4],[0,2,3]]
```

Ra ngoài[90]:

tên	mpg	dung tích	xi	lanh	mã lực
amc rebel sst	16.0	304.0	150.0		
Ford Torino	17.0	302.0	140.0		

Các mục trong chỉ mục không nhất thiết phải là duy nhất: có nhiều xe trong khung dữ liệu.
được đặt tên là `Ford Galaxie 500`.

```
Trong [91]: Auto_re.loc['ford galaxie 500',['mpg', 'origin']]
```

Ra ngoài[91]:

tên	mpg	nguồn gốc
Ford Galaxie 500	15.0	1
Ford Galaxie 500	14.0	1
Ford Galaxie 500	14.0	1

Thêm thông tin về cách chọn hàng và cột

Giả sử bây giờ chúng ta muốn tạo một data frame chứa trọng lượng.
và nguồn gốc của tập hợp con các xe có năm sản xuất lớn hơn 80 – tức là những chiếc xe đó
được xây dựng sau năm 1980. Để làm điều này, trước tiên chúng ta tạo một mảng Boolean để lập chỉ mục.
các hàng. Phương thức `loc[]` cho phép nhập cả giá trị Boolean và chuỗi:

```
Trong [92]: idx_80 = Auto_re['year'] > 80
Auto_re.loc[idx_80, ['weight', 'origin']]
```

Để thực hiện điều này một cách ngắn gọn hơn, chúng ta có thể sử dụng một hàm ẩn danh được gọi là...
`lambda`:

```
Trong [93]: Auto_re.loc[lambda df: df['year'] > 80, ['weight', 'origin']]
```

Lời gọi hàm `lambda` tạo ra một hàm nhận một đối số duy nhất, ở đây là `df`,
và trả về `df['year']>80`. Vì nó được tạo bên trong phương thức `loc[]` cho

2.3 Thực hành: Giới thiệu về Python 59

DataFrame `Auto_re` sẽ là đối số được cung cấp. Một ví dụ khác về việc sử dụng `lambda` là giả sử chúng ta muốn tất cả các xe ô tô được sản xuất sau năm 1980 có mức tiêu hao nhiên liệu trên 30 dặm/gallon:

```
Trong [94]: Auto_re.loc[lambda df: (df['year'] > 80) & (df['mpg'] > 30), ['weight', 'origin']]

]
```

Ký hiệu `&` thực hiện phép toán AND trên từng phần tử. Ví dụ khác, giả sử chúng ta muốn truy xuất tất cả các xe `Ford` và `Datsun` có dung tích xi lanh nhỏ hơn 300. Chúng ta kiểm tra xem mỗi mục `tên` có chứa chuỗi `"ford"` hoặc `"datsun"` hay không bằng cách sử dụng phương thức `str.contains()` của thuộc tính `index` của dataframe:

```
Trong [95]: Auto_re.loc[lambda df: (df['displacement'] < 300)
                        & (df.index.str.contains('ford') |
                           df.index.str.contains('datsun')), ['weight', 'origin']]

                                                .str.
                                                chứa()
```

Ở đây, ký hiệu `|` thực hiện phép toán OR trên từng phần tử. Tóm lại, có một tập hợp các thao tác mạnh mẽ để lập chỉ mục các hàng và cột của khung dữ liệu. Đối với các truy vấn dựa trên số nguyên, hãy sử dụng phương thức `iloc[]`. Đối với các lựa chọn chuỗi và Boolean, hãy sử dụng phương thức `loc[]`. Đối với các truy vấn chức năng lọc hàng, hãy sử dụng phương thức `loc[]` với một hàm (thường là `lambda`) trong đối số `rows`.

2.3.8 Vòng lặp For

Vòng lặp `for` là một công cụ tiêu chuẩn trong nhiều ngôn ngữ lập trình, dùng để lặp đi lặp lại việc đánh giá một đoạn mã nào đó trong khi thay đổi các giá trị khác nhau bên trong đoạn mã đó. Ví dụ, giả sử chúng ta lặp qua các phần tử của một danh sách và tính tổng của chúng.

```
Trong [96]: tổng = 0 cho
           giá trị trong [3,2,19]:
           tổng += giá trị
           print('Tổng cộng là: {}'.format(total))
```

Tổng cộng là: 24

Đoạn mã thực tế bên dưới dòng chứa câu lệnh `for` sẽ được thực thi cho mỗi giá trị trong chuỗi được chỉ định trong câu lệnh `for`. Vòng lặp kết thúc khi ô kết thúc hoặc khi mã được thực thi ở cùng cấp độ với câu lệnh `for` ban đầu. Chúng ta thấy rằng dòng cuối cùng ở trên in ra tổng chỉ được thực thi một lần sau khi vòng lặp `for` kết thúc. Các vòng lặp có thể được lồng nhau bằng cách thực tế thêm.

```
Trong [97]: tổng = 0
           với giá trị trong [2,3,19]:
           với trọng lượng trong [3, 2, 1]:
           tổng += giá trị * trọng lượng
           print('Tổng là: {}'.format(tổng))
```

Tổng cộng là: 144

60 2. Học thống kê

Ở trên, chúng ta đã tính tổng cho từng sự kết hợp giữa **giá trị** và **trọng lượng**. Chúng ta cũng...
Đã tận dụng ký hiệu phép cộng trong **Python**: biểu thức $a \pm b$ tương đương với $a = a + b$. Bên cạnh việc là một ký hiệu tiện lợi, điều này còn có thể tiết kiệm thời gian trong các tác vụ tính toán nặng, trong đó giá trị trung gian các cặp $a+b$ không nhất thiết phải được tạo ra một cách rõ ràng.

Có lẽ một nhiệm vụ phổ biến hơn là tính tổng (**giá trị**, **trọng lượng**).
các cặp. Ví dụ, để tính giá trị trung bình của một biến ngẫu nhiên.
Nếu biến đó nhận các giá trị có thể là 2, 3 hoặc 19 với xác suất tương ứng là 0,2, 0,3, 0,5,
thì ta sẽ tính tổng có trọng số. Những nhiệm vụ như thế này thường có thể được thực hiện.
Việc này được thực hiện bằng cách sử dụng hàm `zip()` lặp qua một chuỗi các bộ dữ liệu.

```
Trong [98]: tổng = 0
           cho giá trị, trọng lượng trong zip([2,3,19],
                                             [0.2,0.3,0.5]):
               tổng cộng ± trọng lượng * giá trị
           print('Trung bình có trọng số là: {}'.format(total))
```

Điểm trung bình có trọng số là: 10,8

Định dạng chuỗi

Trong đoạn mã trên, chúng ta cũng đã in ra một chuỗi hiển thị tổng số.
Tuy nhiên, **tổng số** đối tượng là một số nguyên chứ không phải là một chuỗi. Chèn
Việc chuyển đổi giá trị của một chuỗi thành chuỗi ký tự là một tác vụ phổ biến, được đơn giản hóa bằng cách sử dụng một số công cụ.
một trong những công cụ định dạng chuỗi mạnh mẽ trong **Python**. Nhiều tác vụ làm sạch dữ liệu.
Bao gồm việc thao tác và tạo ra các chuỗi ký tự bằng lập trình.
Ví dụ, chúng ta có thể muốn lặp qua các cột của một khung dữ liệu.
và in ra phần trăm dữ liệu thiếu trong mỗi cột. Hãy tạo một khung dữ liệu.
Bảng D có các cột mà trong đó 20% số mục bị thiếu, tức là được đặt thành **np.nan**.
Chúng ta sẽ tạo ra các giá trị trong D từ phân phối chuẩn với giá trị trung bình là 0 và
phương sai 1 bằng cách sử dụng `rng.standard_normal()` và sau đó ghi đè lên một số ngẫu nhiên
các mục sử dụng `rng.choice()`.

```
Trong [99]: rng = np.random.default_rng(1)
           A = rng.standard_normal((127, 5))
           M = rng.choice([0, np.nan], p=[0.8,0.2], size=A.shape)
           A ± M
           D = pd.DataFrame(A, columns=['food',
                                         'thanh',
                                         'dưa chua',
                                         'đồ ăn vặt',
                                         'bông ngô'])
           D[:3]
```

Ra ngoài[99]:

	đồ ăn	dưa chua	thanh	bông ngô	ăn nhẹ
0	0.345584	0.821618	0.330437	-1.303157	NaN
1	NaN	-0.536953	0.581118	0.364572	0.294132
2	NaN	0.546713	NaN	-0.162910	-0.482119

```
Trong [100]: cho col trong D.columns:
            template = 'Cột "{0}" có {1:.2%} giá trị bị thiếu'
            in(mẫu.định dạng(cột,
                             np.isnan(D[col]).mean()))
```

Cột "food" có 16,54% giá trị bị thiếu. Cột "bar" có 25,98% giá trị bị thiếu. Cột "pickle" có 29,13% giá trị bị thiếu. Cột "snack" có 21,26% giá trị bị thiếu. Cột "popcorn" có 22,83% giá trị bị thiếu.

Ta thấy rằng phương thức `template.format()` mong đợi hai đối số `{0}` và `{1:.2%}`, và đối số thứ hai bao gồm một số thông tin định dạng. Cụ thể, nó chỉ định rằng đối số thứ hai phải được biểu thị dưới dạng phần trăm với hai chữ số thập phân.

Tài liệu tham khảo : docs.python.org/3/library/string.html bao gồm nhiều trợ giúp. Các ví dụ đầy đủ và phức tạp hơn.

2.3.9 Tóm tắt bằng đồ thị và số liệu bổ sung

Chúng ta có thể sử dụng các hàm `ax.plot()` hoặc `ax.scatter()` để hiển thị các biến định lượng. Tuy nhiên, chỉ cần gõ tên biến sẽ tạo ra thông báo lỗi, vì Python không biết cách tìm các biến đó trong tập dữ liệu `Auto`.

```
Trong [101]: fig, ax = subplots(figsize=(8, 8))
            ax.plot(horsepower, 'o');
```

`NameError: tên 'horsepower' chưa được định nghĩa`

Chúng ta có thể giải quyết vấn đề này bằng cách truy cập trực tiếp vào các cột:

```
Trong [102]: fig, ax = subplots(figsize=(8, 8))
            ax.plot(Auto['horsepower'], Auto['mpg'], 'o');
```

Ngoài ra, chúng ta cũng có thể sử dụng phương thức `plot()` với lệnh gọi `Auto.plot()`. Sử dụng phương thức này, các biến có thể được truy cập theo tên. Phương thức `plot` của một data frame trả về một đối tượng quen thuộc: một trục tọa độ. Chúng ta có thể sử dụng nó để cập nhật biểu đồ như đã làm trước đây:

```
Trong [103]: ax = Auto.plot.scatter('horsepower', 'mpg');
            ax.set_title('Mức lực so với MPG')
```

Nếu muốn lưu hình ảnh chứa một trục tọa độ nhất định, ta có thể tìm hình ảnh đó bằng cách truy cập thuộc tính `figure`:

```
Trong [104]: fig = ax.figure
            fig.savefig('horsepower_mpg.png');
```

Chúng ta có thể hướng dẫn thêm cho khung dữ liệu để vẽ biểu đồ lên một đối tượng trục cụ thể. Trong trường hợp này, phương thức `plot()` tương ứng sẽ trả về các trục đã được sửa đổi mà chúng ta đã truyền vào làm đối số. Lưu ý rằng khi chúng ta yêu cầu một lưới đồ thị một chiều, đối tượng `axes` cũng tương tự như vậy, là một chiều. Chúng ta đặt biểu đồ phân tán của mình vào đồ thị ở giữa của một hàng gồm ba đồ thị trong một hình.

```
Trong [105]: fig, axes = subplots(ncols=3, figsize=(15, 5))
            Auto.plot.scatter('horsepower', 'mpg', ax=axes[1]);
```

Cũng cần lưu ý rằng các cột của khung dữ liệu có thể được truy cập như các thuộc tính: Hãy thử nhập `Auto.horsepower`.

Bây giờ chúng ta xem xét biến `cylinders`. Gõ vào `Auto.cylinders.dtype`

Điều này cho thấy nó đang được coi là một biến định lượng. Tuy nhiên, vì chỉ có một số ít giá trị có thể có cho biến này, chúng ta có thể

Tôi muốn coi nó như một yếu tố định tính. Bên dưới, chúng tôi thay thế cột `hình trụ` bằng

Một phiên bản phân loại của `Auto.cylinders`. Hàm `pd.Series()` có tên gọi như vậy là do `pandas` thường được sử dụng trong các ứng dụng chuỗi thời gian.

```
Trong [106]: Auto.cylinders = pd.Series(Auto.cylinders, dtype='category')
Auto.cylinders.dtype
```

Vì `hình trụ` là dữ liệu định tính, chúng ta có thể hiển thị nó bằng phương pháp `boxplot()`.

```
Trong [107]: fig, ax = subplots(figsize=(8, 8))
Auto.boxplot('mpg', by='cylinders', ax=ax);
```

Phương thức `hist()` có thể được sử dụng để vẽ biểu đồ tần số.

```
Trong [108]: fig, ax = subplots(figsize=(8, 8))
Auto.hist('mpg', ax=ax);
```

Bạn có thể thay đổi màu sắc của các thanh và số lượng ô:

```
Trong [109]: fig, ax = subplots(figsize=(8, 8))
Auto.hist('mpg', color='red', bins=12, ax=ax);
```

Xem `Auto.hist?` để biết thêm các tùy chọn vẽ biểu đồ.

Chúng ta có thể sử dụng hàm `pd.plotting.scatter_matrix()` để tạo ma trận biểu đồ phân tán nhằm trực quan hóa tất cả các mối quan hệ từng cặp giữa các đối tượng.

các cột trong một khung dữ liệu.

`pd.plotting.`
`tiêu tan_`
`ma trận()`

```
Trong [110]: pd.plotting.scatter_matrix(Auto);
```

Chúng ta cũng có thể tạo biểu đồ phân tán cho một tập hợp con các biến.

```
Trong [111]: pd.plotting.scatter_matrix(Auto[['mpg',
                                             'sự dịch chuyển',
                                             'cân nặng']]);
```

Phương thức `describe()` tạo ra một bản tóm tắt bằng số cho mỗi cột trong khung dữ liệu.

`.mô tả()`

```
Trong [112]: Auto[['mpg', 'weight']].describe()
```

Chúng ta cũng có thể tạo bản tóm tắt chỉ từ một cột duy nhất.

```
Trong [113]: Auto['cylinders'].describe()
Auto['mpg'].describe()
```

Để thoát khỏi Jupyter, chọn `File / Close` và `Halt`.

2.4 Bài tập

Khái niệm

- Đối với mỗi phần tử (a) đến (d), hãy cho biết liệu chúng ta thường kỳ vọng hiệu suất của một phương pháp học thống kê linh hoạt sẽ tốt hơn hay kém hơn so với một phương pháp không linh hoạt. Hãy giải thích câu trả lời của bạn.
 - Kích thước mẫu n rất lớn, và số lượng dự đoán p nhỏ.
 - Số lượng biến dự đoán p rất lớn, trong khi số lượng quan sát n lại nhỏ.
 - Mối quan hệ giữa các yếu tố dự báo và phản hồi rất chặt chẽ phi tuyến tính.
 - Phương sai của các số hạng sai số, tức là $\sigma^2 = \text{Var}(\epsilon)$, là cực kỳ cao.
- Hãy giải thích xem mỗi tình huống là bài toán phân loại hay hồi quy, và cho biết chúng ta quan tâm nhất đến suy luận hay dự đoán. Cuối cùng, hãy cung cấp n và p .
 - Chúng tôi thu thập một bộ dữ liệu về 500 công ty hàng đầu tại Mỹ. Đối với mỗi công ty, chúng tôi ghi lại lợi nhuận, số lượng nhân viên, ngành nghề và mức lương của CEO. Chúng tôi quan tâm đến việc tìm hiểu những yếu tố nào ảnh hưởng đến mức lương của CEO. (b) Chúng tôi đang xem xét việc ra mắt một sản phẩm mới và muốn biết liệu nó sẽ thành công hay thất bại. Chúng tôi thu thập dữ liệu về 20 sản phẩm tương tự đã được ra mắt trước đó. Đối với mỗi sản phẩm, chúng tôi đã ghi lại liệu nó có thành công hay thất bại, giá bán sản phẩm, ngân sách tiếp thị, giá của đối thủ cạnh tranh và mười biến số khác.
 - Chúng tôi quan tâm đến việc dự đoán phần trăm thay đổi của tỷ giá USD/Euro liên quan đến những thay đổi hàng tuần trên thị trường chứng khoán thế giới. Do đó, chúng tôi thu thập dữ liệu hàng tuần trong suốt năm 2012. Mỗi tuần, chúng tôi ghi lại phần trăm thay đổi của tỷ giá USD/Euro, phần trăm thay đổi của thị trường Mỹ, phần trăm thay đổi của thị trường Anh và phần trăm thay đổi của thị trường Đức.
- Bây giờ chúng ta sẽ xem xét lại sự phân tích độ lệch-phương sai.
 - Hãy phác thảo các đường cong điển hình (bình phương) về độ lệch, phương sai, lỗi huấn luyện, lỗi kiểm tra và lỗi Bayes (hoặc lỗi không thể giảm thiểu), trên cùng một đồ thị, khi chúng ta chuyển từ các phương pháp học thống kê kém linh hoạt hơn sang các phương pháp linh hoạt hơn. Trục x nên biểu thị mức độ linh hoạt của phương pháp, và trục y nên biểu thị các giá trị cho mỗi đường cong. Sẽ có năm đường cong. Hãy nhớ dán nhãn cho từng cái.
 - Giải thích tại sao mỗi trong năm đường cong lại có hình dạng như được hiển thị trong phần (a).

64 2. Học thống kê

4. Bây giờ bạn hãy nghĩ đến một số ứng dụng thực tế của học máy thống kê.

(a) Mô tả ba ứng dụng thực tế mà trong đó phân loại có thể hữu ích. Mô tả phản hồi cũng như các yếu tố dự đoán. Mục tiêu của mỗi ứng dụng là suy luận hay dự đoán? Giải thích lý do của bạn.

Trả lời.

(b) Mô tả ba ứng dụng thực tế mà trong đó hồi quy có thể hữu ích. Mô tả biến phản hồi cũng như các biến dự đoán. Mục tiêu của mỗi ứng dụng là suy luận hay dự đoán? Giải thích lý do của bạn.

Trả lời.

(c) Mô tả ba ứng dụng thực tế mà phân tích cụm có thể hữu ích.

5. Ưu điểm và nhược điểm của phương pháp tiếp cận rất linh hoạt (so với phương pháp ít linh hoạt hơn) đối với hồi quy hoặc phân loại là gì? Trong những trường hợp nào thì phương pháp tiếp cận linh hoạt hơn nên được ưu tiên hơn phương pháp ít linh hoạt? Khi nào thì phương pháp ít linh hoạt hơn nên được ưu tiên?

6. Mô tả sự khác biệt giữa phương pháp học thống kê tham số và phi tham số. Ưu điểm của phương pháp tham số trong hồi quy hoặc phân loại là gì (so với phương pháp phi tham số)? Nhược điểm của nó là gì?

7. Bảng dưới đây cung cấp một tập dữ liệu huấn luyện bao gồm sáu quan sát, ba biến dự đoán và một biến phản hồi định tính.

Quan sát.	X1	X2	X3	Y
1	2	0	0	Đỏ
2	2	0	0	Đỏ
3	0	1	3	Đỏ
4	0	1	2	Đỏ
5	5	1	0	Xanh lá
6	5	1	0	Xanh lá

Giả sử chúng ta muốn sử dụng tập dữ liệu này để dự đoán Y khi $X_1 = X_2 = X_3 = 0$ bằng phương pháp K-hàng xóm gần nhất.

(a) Tính khoảng cách Euclidean giữa mỗi điểm quan sát và điểm kiểm tra, $X_1 = X_2 = X_3 = 0$.

(b) Dự đoán của chúng ta với $K = 1$ là gì? Tại sao?

(c) Dự đoán của chúng ta với $K = 3$ là gì? Tại sao?

(d) Nếu ranh giới quyết định Bayes trong bài toán này có tính phi tuyến cao, thì liệu chúng ta có kỳ vọng giá trị tối ưu của K sẽ lớn hay nhỏ? Tại sao?

Đã áp dụng

8. Bài tập này liên quan đến tập dữ liệu **College**, có thể tìm thấy trong tệp **College.csv** trên trang web của sách. Tập dữ liệu này chứa một số biến số cho 777 trường đại học và cao đẳng khác nhau ở Hoa Kỳ. Các biến số đó là:

- **Riêng tư** : Chỉ báo công khai/riêng tư • **Ứng dụng** : Số lượng ứng dụng đã nhận
- **Chấp nhận** : Số lượng ứng viên được chấp nhận
- **Số lượng đăng ký** : Số lượng sinh viên mới đăng ký
- **Top10perc** : Học sinh mới thuộc top 10% học sinh giỏi nhất trường trung học • **Top25perc** : Học sinh mới thuộc top 25% học sinh giỏi nhất trường trung học
- **F.Undergrad** : Số lượng sinh viên đại học hệ chính quy • **P.Undergrad** : Số lượng sinh viên đại học hệ bán thời gian
- **Ngoại bang** : Học phí dành cho sinh viên ngoại bang
- **Chi phí ăn ở** : Chi phí ăn ở
- **Sách** : Chi phí sách ước tính
- **Cá nhân** : Chi tiêu cá nhân ước tính
- **Tiến sĩ** : Tỷ lệ giảng viên có bằng Tiến sĩ • **Bằng cấp cao nhất** : Tỷ lệ giảng viên có bằng cấp cao nhất • **Tỷ lệ sinh viên/giảng viên** : Tỷ lệ sinh viên/ giảng viên • **Tỷ lệ cựu sinh viên đóng góp**
- **Chi phí** : Chi phí giảng dạy trên mỗi học sinh
- **Tỷ lệ tốt nghiệp** : Tỷ lệ tốt nghiệp

Trước khi đọc dữ liệu vào **Python**, dữ liệu có thể được xem trước trong Excel hoặc trình soạn thảo văn bản.

- (a) Sử dụng hàm `pd.read_csv()` để đọc dữ liệu vào **Python**. Gọi tập dữ liệu đã tải là `'column'`. Hãy chắc chắn rằng bạn đã thiết lập thư mục đến đúng vị trí chứa dữ liệu.
- (b) Hãy xem dữ liệu được sử dụng trong sổ tay bằng cách tạo và chạy một ô mới chỉ chứa mã `" college"`. Bạn sẽ nhận thấy rằng cột đầu tiên chỉ là tên của mỗi trường đại học trong một cột có tên tương tự như `"Unnamed: 0"`. Chúng ta thực sự không muốn **pandas** coi đây là dữ liệu. Tuy nhiên, việc có những tên này có thể hữu ích cho sau này. Hãy thử các lệnh sau và xem các khung dữ liệu kết quả tương tự:

```
college2 = pd.read_csv('College.csv', index_col=0) college3 =
college.rename({'Unnamed: 0': 'College'}, axis=1) college3 =
college3.set_index('College')
```

2. Học thống kê

Thao tác này đã sử dụng cột đầu tiên trong tệp làm **chỉ mục** cho khung dữ liệu. Điều này có nghĩa là **pandas** đã gán cho mỗi hàng một tên tương ứng với trường đại học thích hợp. Bây giờ bạn sẽ thấy rằng cột dữ liệu đầu tiên là **Private**. Lưu ý rằng tên của các trường cao đẳng xuất hiện ở bên trái của bảng. Chúng ta cũng đã giới thiệu một đối tượng Python mới ở trên: một từ điển, được xác định bởi các cặp (**khóa**, **giá trị**). Hãy giữ nguyên phiên bản dữ liệu đã chỉnh sửa của bạn như sau:

từ điển

```
trường đại học = trường đại học3
```

- (c) Sử dụng phương thức **describe()** để tạo bản tóm tắt số của các biến trong tập dữ liệu.
- (d) Sử dụng hàm **pd.plotting.scatter_matrix()** để tạo ra một Ma trận biểu đồ phân tán của các cột đầu tiên **[Top10perc, Apps, Enroll]**. Hãy nhớ rằng bạn có thể tham chiếu đến một danh sách **C** các cột của một khung dữ liệu **A** bằng cách
- sử dụng **A[C]**. (e) Sử dụng phương thức **boxplot()** của **thư viện** để tạo biểu đồ cạnh nhau. Biểu đồ hộp so sánh giữa **khuvực ngoại thành** và **khuvực tư nhân**.
- (f) Tạo một biến định tính mới, gọi là **Elite**, bằng cách chia biến **Top10perc** thành hai nhóm dựa trên việc tỷ lệ học sinh đến từ nhóm 10% học sinh giỏi nhất trường trung học có vượt quá 50% hay không.

```
college['Elite'] = pd.cut(college['Top10perc'],
                          [0,0.5,1],
                          nhãn=['Không', 'Có'])
```

- (g) Sử dụng phương thức **value_counts()** của **college['Elite']** để xem có bao nhiêu trường đại học ưu tú. Cuối cùng, sử dụng lại phương thức **boxplot()** để tạo biểu đồ hộp song song của **Outstate** so với **Elite**. (h) Sử dụng phương thức **plot.hist()** của **college** để tạo một số biểu đồ tần số với số lượng bin khác nhau cho một vài biến định lượng. Lệnh **plt.subplots(2, 2)** có thể hữu ích: nó sẽ chia cửa sổ đồ thị thành bốn vùng để có thể tạo bốn đồ thị đồng thời. Bằng cách thay đổi các đối số, bạn có thể chia màn hình theo các cách kết hợp khác. (h) Tiếp tục khám phá dữ liệu và cung cấp bản tóm tắt ngắn gọn về những gì bạn phát hiện ra.

9. Bài tập này sử dụng bộ dữ liệu **Auto** đã được nghiên cứu trong phòng thí nghiệm. Hãy đảm bảo rằng các giá trị bị thiếu đã được loại bỏ khỏi bộ dữ liệu.

- (a) Trong số các biến dự báo, biến nào là định lượng và biến nào là định tính?
- (b) Phạm vi của mỗi biến dự báo định lượng là bao nhiêu? Bạn có thể trả lời câu hỏi này bằng cách sử dụng các phương thức **min()** và **max()** trong **thư viện numpy**. **.min()**
- (c) Giá trị trung bình và độ lệch chuẩn của mỗi đại lượng là bao nhiêu? **.max()**
- yếu tố dự báo?

2.4 Bài tập 67

- (d) Bây giờ hãy loại bỏ các quan sát từ thứ 10 đến thứ 85. Khoảng biến thiên, giá trị trung bình và độ lệch chuẩn của mỗi biến dự báo trong tập dữ liệu còn lại là bao nhiêu?
- (e) Sử dụng toàn bộ tập dữ liệu, hãy nghiên cứu các biến dự báo bằng đồ thị, sử dụng biểu đồ phân tán hoặc các công cụ khác mà bạn lựa chọn. Tạo một số biểu đồ làm nổi bật mối quan hệ giữa các biến dự báo. Nhận xét về những phát hiện của bạn.
- (f) Giả sử chúng ta muốn dự đoán mức tiêu hao nhiên liệu (mpg) dựa trên các biến số khác. Các biểu đồ của bạn có cho thấy bất kỳ biến số nào khác có thể hữu ích trong việc dự đoán mpg không? Hãy giải thích lý do.
trả lời.

10. Bài tập này sử dụng bộ dữ liệu nhà ở Boston .

- (a) Đầu tiên, hãy tải bộ dữ liệu Boston , một phần của ISLP.
thư viện.
- (b) Tập dữ liệu này có bao nhiêu hàng? Bao nhiêu cột? Cái gì
Các hàng và cột biểu thị điều gì?
- (c) Vẽ một số biểu đồ phân tán theo cặp của các biến dự đoán (cột) trong
Bộ dữ liệu này. Hãy mô tả những phát hiện của bạn.
- (d) Có yếu tố dự báo nào liên quan đến tỷ lệ tội phạm bình quân đầu người không?
Nếu vậy, hãy giải thích mối quan hệ đó.
- (e) Có khu ngoại ô nào của Boston có tỷ lệ tội phạm đặc biệt cao không? Thuế suất? Tỷ lệ
học sinh-giáo viên? Nhận xét về phạm vi của mỗi yếu tố dự báo.
- (f) Có bao nhiêu vùng ngoại ô trong tập dữ liệu này giáp với sông Charles?
dòng sông?
- (g) Tỷ lệ học sinh trên giáo viên trung vị ở các thị trấn trong khu vực này là bao nhiêu?
bộ dữ liệu?
- (h) Khu ngoại ô nào của Boston có giá trị trung vị thấp nhất đối với nhà ở do chủ sở hữu
tự ở? Giá trị của các biến dự báo khác đối với khu ngoại ô đó là bao nhiêu, và các
giá trị đó so sánh như thế nào với phạm vi tổng thể của các biến dự báo đó? Nhận xét
về kết quả của bạn. (i) Trong tập dữ liệu này, có bao nhiêu khu ngoại ô có
trung bình hơn bảy phòng mỗi căn nhà? Hơn tám phòng mỗi căn nhà?

Hãy bình luận về các khu ngoại ô có trung bình hơn tám phòng mỗi căn nhà.

3

Hồi quy tuyến tính



Chương này đề cập đến hồi quy tuyến tính, một phương pháp rất đơn giản cho học có giám sát. Cụ thể, hồi quy tuyến tính là một công cụ hữu ích để dự đoán một phản hồi định lượng. Nó đã tồn tại từ lâu và là chủ đề của vô số sách giáo khoa. Mặc dù có vẻ hơi nhàm chán so với một số phương pháp học thống kê hiện đại hơn được mô tả trong các chương sau của cuốn sách này, hồi quy tuyến tính vẫn là một phương pháp học thống kê hữu ích và được sử dụng rộng rãi. Hơn nữa, nó đóng vai trò là điểm khởi đầu tốt cho các phương pháp mới hơn: như chúng ta sẽ thấy trong các chương sau, nhiều phương pháp học thống kê phức tạp có thể được coi là sự khái quát hóa hoặc mở rộng của hồi quy tuyến tính. Do đó, tầm quan trọng của việc hiểu rõ hồi quy tuyến tính trước khi nghiên cứu các phương pháp học phức tạp hơn là không thể phủ nhận. Trong chương này, chúng ta sẽ xem xét lại một số ý tưởng chính làm nền tảng cho mô hình hồi quy tuyến tính, cũng như phương pháp bình phương nhỏ nhất được sử dụng phổ biến nhất để phù hợp với mô hình này.

Hãy nhớ lại dữ liệu về **quảng cáo** từ Chương 2. Hình 2.1 hiển thị **doanh số bán hàng** (tính bằng nghìn đơn vị) của một sản phẩm cụ thể như một hàm số của ngân sách quảng cáo (tính bằng nghìn đô la) cho các phương tiện truyền thông **truyền hình**, **phát thanh** và **báo chí**. Giả sử trong vai trò là chuyên gia tư vấn thống kê, chúng ta được yêu cầu đề xuất, dựa trên dữ liệu này, một kế hoạch tiếp thị cho năm tới nhằm mang lại doanh số bán sản phẩm cao. Thông tin nào sẽ hữu ích để đưa ra khuyến nghị như vậy? Dưới đây là một vài câu hỏi quan trọng mà chúng ta có thể tìm cách giải đáp:

1. Có mối quan hệ nào giữa ngân sách quảng cáo và doanh số bán hàng không?

Mục tiêu đầu tiên của chúng ta là xác định xem dữ liệu có cung cấp bằng chứng về mối liên hệ giữa chi phí quảng cáo và doanh số bán hàng hay không. Nếu bằng chứng yếu, thì người ta có thể lập luận rằng không nên chi tiền cho quảng cáo!

70 3. Hồi quy tuyến tính

2. Mối quan hệ giữa ngân sách quảng cáo và doanh số bán hàng mạnh đến mức nào?
Giả sử có mối quan hệ giữa quảng cáo và doanh số bán hàng,
Chúng tôi muốn biết mức độ bền chặt của mối quan hệ này. Liệu việc nắm rõ ngân sách quảng cáo có cung cấp nhiều thông tin về vấn đề này không?
Doanh số bán sản phẩm?
3. Những phương tiện truyền thông nào liên quan đến doanh số bán hàng?
Cả ba phương tiện truyền thông-truyền hình, phát thanh và báo chí-đều có liên quan đến
Doanh số bán hàng, hay chỉ một hoặc hai phương tiện truyền thông liên quan? Để trả lời câu hỏi này
Câu hỏi đặt ra là, chúng ta phải tìm cách tách biệt đóng góp riêng lẻ của từng phương tiện truyền thông
vào doanh thu khi chúng ta đã chi tiền cho cả ba phương tiện.
phương tiện truyền thông
4. Mức độ liên quan giữa mỗi phương tiện truyền thông và doanh số bán hàng lớn đến mức nào?
Với mỗi đô la chi cho quảng cáo trên một phương tiện truyền thông cụ thể, bằng cách
Doanh số sẽ tăng bao nhiêu? Chúng ta có thể dự đoán điều này chính xác đến mức nào?
Mức tăng là bao nhiêu?
5. Chúng ta có thể dự đoán doanh số bán hàng trong tương lai chính xác đến mức nào?
Với bất kỳ mức độ quảng cáo nào trên truyền hình, đài phát thanh hoặc báo chí, điều gì sẽ xảy ra?
Dự đoán của chúng ta về doanh số bán hàng là bao nhiêu, và độ chính xác của dự đoán này là bao nhiêu?
6. Mối quan hệ này có tuyến tính không?
Nếu có mối quan hệ tuyến tính gần đúng giữa chi phí quảng cáo trên các phương tiện truyền thông khác
nhau và doanh số bán hàng, thì hồi quy tuyến tính có thể được sử dụng.
là một công cụ thích hợp. Nếu không, thì vẫn có thể biến đổi biến dự báo hoặc biến phản hồi để có thể
sử dụng hồi quy tuyến tính.
đã sử dụng.
7. Có sự phối hợp hiệu quả giữa các phương tiện quảng cáo không?
Có lẽ việc chi 50.000 đô la cho quảng cáo truyền hình và 50.000 đô la cho quảng cáo phát thanh sẽ mang
lại doanh số cao hơn so với việc phân bổ 100.000 đô la.
phát sóng riêng lẻ cho truyền hình hoặc đài phát thanh. Trong lĩnh vực marketing, điều này được gọi là...
Như một hiệu ứng hiệp đồng , trong khi trong thống kê nó được gọi là hiệu ứng tương tác .

sự phối hợp
sự tương tác

Hóa ra, hồi quy tuyến tính có thể được sử dụng để trả lời từng câu hỏi này.
các câu hỏi. Trước tiên, chúng ta sẽ thảo luận tất cả những câu hỏi này trong bối cảnh tổng quát.
và sau đó quay lại với chúng trong bối cảnh cụ thể này ở Mục 3.4.

3.1 Hồi quy tuyến tính đơn giản

Hồi quy tuyến tính đơn giản đúng như tên gọi của nó: đây là một phương pháp rất trực tiếp để dự đoán một biến
phản hồi định lượng Y dựa trên một biến dự báo duy nhất X. Nó giả định rằng có một mối quan hệ tuyến tính gần
đúng.
mối quan hệ giữa X và Y. Về mặt toán học, ta có thể viết điều này dưới dạng tuyến tính.
mối quan hệ như

tuyến tính đơn giản
hồi quy

$$Y \approx \beta_0 + \beta_1 X.$$
(3.1)

Bạn có thể hiểu ký hiệu “≈” là “được mô hình hóa gần đúng như”. Đôi khi chúng ta sẽ
mô tả (3.1) bằng cách nói rằng chúng ta đang hồi quy Y trên X (hoặc Y trên X).

Vi dụ, X có thể đại diện cho quảng cáo trên truyền hình và Y có thể đại diện cho doanh số bán hàng. Sau đó, chúng ta có thể hồi quy doanh số bán hàng dựa trên truyền hình bằng cách điều chỉnh mô hình.

$$\text{doanh số} \approx \beta_0 + \beta_1 \times \text{TV}.$$

Trong phương trình 3.1, β_0 và β_1 là hai hằng số chưa biết biểu thị các hệ số chặn và hệ số góc trong mô hình tuyến tính. β_0 và β_1 được gọi chung là các hệ số hoặc tham số của mô hình. Sau khi chúng ta đã sử dụng... Sử dụng dữ liệu huấn luyện để tạo ra các ước tính $\hat{\beta}_0$ và $\hat{\beta}_1$ cho các hệ số của mô hình, chúng ta có thể dự đoán doanh số bán hàng trong tương lai dựa trên giá trị cụ thể của quảng cáo truyền hình. bằng cách tính toán

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x, \quad (3.2)$$

trong đó $\hat{y}$ biểu thị dự đoán của Y dựa trên $X = x$. Ở đây chúng ta sử dụng một ký hiệu mũ, ^, dùng để biểu thị giá trị ước tính cho một tham số chưa biết. hoặc hệ số, hoặc để biểu thị giá trị dự đoán của phản hồi.

3.1.1 Ước tính các hệ số

Trên thực tế, β_0 và β_1 chưa được biết. Vì vậy, trước khi chúng ta có thể sử dụng (3.1) để tạo ra để đưa ra dự đoán, chúng ta phải sử dụng dữ liệu để ước tính các hệ số. Hãy

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

Biểu thị n cặp quan sát, mỗi cặp bao gồm một phép đo. X và một phép đo của Y. Trong ví dụ về Quảng cáo, tập dữ liệu này bao gồm ngân sách quảng cáo truyền hình và doanh số bán sản phẩm tại n = 200 cửa hàng khác nhau. thị trường. (Hãy nhớ rằng dữ liệu được hiển thị trong Hình 2.1.) Mục tiêu của chúng ta là thu được các ước tính hệ số $\hat{\beta}_0$ và $\hat{\beta}_1$ sao cho mô hình tuyến tính (3.1) phù hợp dữ liệu có sẵn tốt-tức là, sao cho $y_i \approx \beta_0 + \beta_1 x_i$ với $i = 1, \dots, n$. Trong Nói cách khác, chúng ta muốn tìm hệ số chặn $\hat{\beta}_0$ và hệ số góc $\hat{\beta}_1$ sao cho Đường thẳng thu được càng sát với 200 điểm dữ liệu càng tốt. Có Có nhiều cách để đo lường sự gần gũi. Tuy nhiên, phương pháp phổ biến nhất là tối thiểu hóa tiêu chí bình phương nhỏ nhất, và chúng ta sẽ sử dụng phương pháp đó trong chương này. Các phương pháp thay thế sẽ được xem xét trong các phần tiếp theo. Chương 6.

Đặt $y^i = \beta_0 + \beta_1 x_i$ là giá trị dự đoán cho Y dựa trên giá trị thứ i của X. Khi đó, $e_i = y_i - y^i$ biểu thị phần dư thứ i – đây là sự khác biệt giữa giá trị phản hồi quan sát được thứ i và giá trị phản hồi được dự đoán thứ i. theo mô hình tuyến tính của chúng tôi. Chúng tôi định nghĩa tổng bình phương phần dư (RSS) là


$$RSS = e_1^2 + e_2^2 + \dots + e_n^2,$$

hoặc tương đương với

$$RSS = (y_1 - \beta_0 - \beta_1 x_1)^2 + (y_2 - \beta_0 - \beta_1 x_2)^2 + \dots + (y_n - \beta_0 - \beta_1 x_n)^2. \quad (3.3)$$

Phương pháp bình phương tối thiểu chọn $\hat{\beta}_0$ và $\hat{\beta}_1$ để giảm thiểu RSS. Sử dụng Với một chút kiến thức về giải tích, người ta có thể chứng minh rằng các phần tử cực tiểu là

$$\hat{\beta}_1 = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \quad (3.4)$$



HÌNH 3.1. Đối với dữ liệu **Quảng cáo**, đường hồi quy được khớp bằng phương pháp bình phương nhỏ nhất.

Biểu đồ thể hiện doanh số bán hàng trên truyền hình. Độ phù hợp được tìm thấy bằng cách tối thiểu hóa tổng dư của các hình vuông. Mỗi đoạn thẳng màu xám biểu thị một phần dư. Trong trường hợp này là một đường thẳng phù hợp.

Nó nắm bắt được bản chất của mối quan hệ, mặc dù nó đánh giá quá cao xu hướng trong mối quan hệ đó.

Bên trái của cột truyện.

trong đó $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$ và $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ là các giá trị trung bình mẫu. Nói cách khác, từ ngữ, (3.4) định nghĩa các ước tính hệ số bình phương nhỏ nhất cho tuyến tính đơn giản hồi quy.

Hình 3.1 hiển thị đường hồi quy tuyến tính đơn giản phù hợp với dữ liệu **Quảng cáo** dữ liệu, trong đó $\beta^0 = 7,03$ và $\beta^1 = 0,0475$. Nói cách khác, theo Theo ước tính này, việc chi thêm 1.000 đô la cho quảng cáo truyền hình sẽ giúp bán thêm khoảng 47,5 đơn vị sản phẩm.

Hình 3.2, chúng tôi đã tính toán RSS cho một số giá trị của β^0 và β^1 .

Sử dụng dữ liệu quảng cáo với **doanh số bán hàng** là biến phản hồi và **truyền hình** là biến dự báo. Trong mỗi biểu đồ, chấm đỏ biểu thị cặp ước lượng bình phương nhỏ nhất.

(β^0, β^1) được đưa ra bởi (3.4). Những giá trị này rõ ràng làm giảm thiểu RSS.

3.1.2 Đánh giá độ chính xác của các ước lượng hệ số

Nhớ lại từ (2.1) rằng chúng ta giả định rằng mối quan hệ thực sự giữa X và Y có dạng $Y = f(X) + \epsilon$ với một hàm f chưa biết nào đó, trong đó ϵ là một số hạng sai số ngẫu nhiên có giá trị trung bình bằng 0. Nếu f được xấp xỉ bằng một hàm tuyến tính hàm, sau đó chúng ta có thể viết mối quan hệ này như sau:

$$Y = \beta^0 + \beta^1 X + \epsilon. \quad (3.5)$$


Ở đây β^0 là hệ số chặn—tức là giá trị kỳ vọng của Y khi $X = 0$.

và β^1 là độ dốc — mức tăng trung bình của Y tương ứng với mỗi đơn vị tăng một đơn vị. sự gia tăng của X . Sai số là một thuật ngữ bao quát cho những gì chúng ta bỏ sót với điều này.

Mô hình đơn giản: mối quan hệ thực sự có lẽ không phải là tuyến tính, có thể có...

các biến số khác gây ra sự biến thiên trong Y và có thể, có phép đo

lỗi. Thông thường, chúng ta giả định rằng số hạng lỗi không phụ thuộc vào X .



HÌNH 3.2. Đồ thị đường đồng mức và đồ thị ba chiều của RSS trên

Dữ liệu **quảng cáo**, sử dụng **doanh số bán hàng** làm yếu tố phản hồi và **truyền hình** làm yếu tố dự báo. Các chấm đỏ tương ứng với các ước tính bình phương nhỏ nhất β^0 và β^1 , được đưa ra bởi (3.4).

Mô hình được đưa ra bởi (3.5) xác định đường hồi quy dân số, là phép xấp xỉ tuyến tính tốt nhất cho mỗi quan hệ thực sự giữa X và

Y . 1. Các ước tính hệ số hồi quy bình phương nhỏ nhất (3.4) đặc trưng cho

đường hồi quy bình phương nhỏ nhất (3.2). Bảng bên trái của Hình 3.3 hiển thị hai đường này trong một ví dụ mô phỏng đơn giản. Chúng tôi đã tạo ra 100 X ngẫu nhiên và đã tạo ra 100 giá trị Y tương ứng từ mô hình.

$$Y = 2 + 3X + \epsilon, \quad (3.6)$$

trong đó được tạo ra từ phân phối chuẩn với giá trị trung bình bằng không.

Đường màu đỏ ở bảng bên trái của Hình 3.3 thể hiện mối quan hệ thực sự.

$f(X) = 2 + 3X$, trong khi đường màu xanh là ước tính bình phương nhỏ nhất dựa trên dữ liệu quan sát được. Mối quan hệ thực sự thường không được biết đến.


Dữ liệu thực tế, nhưng đường hồi quy bình phương tối thiểu luôn có thể được tính toán bằng cách sử dụng ước tính hệ số được đưa ra trong (3.4). Nói cách khác, trong các ứng dụng thực tế, Chúng ta có quyền truy cập vào một tập hợp các quan sát mà từ đó chúng ta có thể tính toán Đường hồi quy bình phương nhỏ nhất; tuy nhiên, đường hồi quy dân số không được quan sát. Trong bảng bên phải của Hình 3.3, chúng tôi đã tạo ra mười dữ liệu khác nhau.

Các bộ dữ liệu mô hình được đưa ra bởi (3.6) và vẽ mười ít nhất tương ứng các đường thẳng vuông. Lưu ý rằng các tập dữ liệu khác nhau được tạo ra từ cùng một dữ liệu thực. Kết quả mà mô hình tạo ra các đường hồi quy bình phương tối thiểu hơi khác nhau, nhưng không quan sát được. Đường hồi quy dân số không thay đổi.

Thoạt nhìn, sự khác biệt giữa đường hồi quy dân số và Đường hồi quy bình phương tối thiểu có vẻ tinh tế và khó hiểu. Chúng ta chỉ có một tập dữ liệu, vậy việc hai đường khác nhau mô tả tập dữ liệu đó có nghĩa là gì? Mối quan hệ giữa biến dự đoán và biến phản hồi là gì? Về cơ bản, Khái niệm của hai dòng này là sự mở rộng tự nhiên của thống kê tiêu chuẩn. phương pháp sử dụng thông tin từ một mẫu để ước tính các đặc điểm của một dân số lớn. Ví dụ, giả sử chúng ta quan tâm đến việc biết

dân số
hồi quy
đường kẻ
bình phương tối thiểu
đường kẻ

1. Giả định về tính tuyến tính thường là một mô hình làm việc hữu ích. Tuy nhiên, bất chấp điều đó... Nhiều sách giáo khoa có thể nói với chúng ta điều đó, nhưng chúng ta hiếm khi tin rằng mối quan hệ thực sự là tuyến tính.



HÌNH 3.3. Một tập dữ liệu mô phỏng. Bên trái: Đường màu đỏ biểu thị dữ liệu thực.

mối quan hệ, $f(X) = 2 + 3X$, được gọi là đường hồi quy của quần thể.

Đường màu xanh là đường bình phương nhỏ nhất; đó là ước lượng bình phương nhỏ nhất cho $f(X)$

Dựa trên dữ liệu quan sát được, hiển thị bằng màu đen. Bên phải: Đường hồi quy dân số

được hiển thị lại bằng màu đỏ, và đường hồi quy bình phương nhỏ nhất bằng màu xanh đậm. Bằng màu xanh nhạt, mười Các đường hồi quy bình phương tối thiểu được hiển thị, mỗi đường được tính toán dựa trên một phương pháp ngẫu nhiên riêng biệt. tập hợp các quan sát. Mỗi đường hồi quy bình phương nhỏ nhất đều khác nhau, nhưng trung bình, đường hồi quy bình phương nhỏ nhất... Các đường hình vuông khá gần với đường hồi quy dân số.

Giá trị trung bình μ của quần thể đối với một biến ngẫu nhiên Y nào đó. Thật không may, μ là

Chưa rõ, nhưng chúng ta có quyền truy cập vào n quan sát từ Y , $y_1, \dots, y_n$,

mà chúng ta có thể sử dụng để ước tính μ . Một ước tính hợp lý là $\mu^* = \bar{y}$, trong đó

$$\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i \text{ là trung bình mẫu. Trung bình mẫu và tổng thể}$$

giá trị trung bình có thể khác nhau, nhưng nhìn chung, giá trị trung bình mẫu sẽ cung cấp một kết quả tốt.

Ước tính trung bình của quần thể. Tương tự như vậy, các hệ số chưa biết

β_0 và β_1 trong hồi quy tuyến tính xác định đường hồi quy của quần thể. Chúng ta tìm kiếm

để ước tính các hệ số chưa biết này bằng cách sử dụng β_0^* và β_1^* được đưa ra trong (3.4). Những hệ số này Các ước lượng hệ số xác định đường hồi quy bình phương nhỏ nhất.

Sự tương đồng giữa hồi quy tuyến tính và ước lượng giá trị trung bình của một

Biến ngẫu nhiên là một ví dụ thích hợp dựa trên khái niệm về độ lệch. Nếu ta sử dụng giá trị

trung bình mẫu μ^* để ước tính μ , thì ước tính này là không thiên lệch, theo nghĩa là trung bình,

ta kỳ vọng μ^* bằng μ . Điều này chính xác có nghĩa là gì? Nó có nghĩa là

dựa trên một tập hợp quan sát cụ thể $y_1, \dots, y_n$, μ^* có thể

đánh giá quá cao μ , và dựa trên một tập hợp các quan sát khác, μ^* có thể

đánh giá thấp μ . Nhưng nếu chúng ta có thể lấy trung bình một số lượng lớn các ước tính về

μ thu được từ một số lượng lớn các tập hợp quan sát, thì giá trị trung bình này là...

sẽ chính xác bằng μ . Do đó, một ước lượng không thiên lệch không có tính hệ thống

Đánh giá quá cao hoặc quá thấp tham số thực. Tính chất không thiên vị.

Điều này cũng đúng đối với các ước tính hệ số bình phương nhỏ nhất được đưa ra bởi (3.4) : nếu chúng tôi ước tính β_0 và β_1 dựa trên một tập dữ liệu cụ thể, sau đó...

Các ước tính sẽ không hoàn toàn bằng β_0 và β_1 . Nhưng nếu chúng ta có thể lấy trung bình

các ước tính thu được từ một số lượng lớn tập dữ liệu, sau đó lấy giá trị trung bình.

Trong số các ước tính này, hầu hết đều chính xác! Thực tế, chúng ta có thể thấy từ bảng bên

phải của Hình 3.3 rằng trung bình của nhiều đường hồi quy bình phương nhỏ nhất, mỗi đường,

thiên vị
không thiên vị

Ước tính từ một tập dữ liệu riêng biệt, con số này khá sát với dân số thực tế. Đường hồi quy.

Chúng ta tiếp tục phép so sánh với việc ước tính giá trị trung bình của quần thể μ của một biến ngẫu nhiên Y . Một câu hỏi tự nhiên đặt ra là: độ chính xác như thế nào? Liệu trung bình mẫu $\hat{\mu}$ có phải là ước lượng của μ không? Chúng ta đã xác định rằng Giá trị trung bình của $\hat{\mu}$ trên nhiều tập dữ liệu sẽ rất gần với μ , nhưng điều đó không có nghĩa là... Ước tính đơn lẻ $\hat{\mu}$ có thể là ước tính thấp hơn hoặc cao hơn đáng kể so với μ thực tế. Ước tính đơn lẻ về $\hat{\mu}$ sẽ sai lệch bao xa? Nói chung, chúng ta trả lời câu hỏi này như sau: câu hỏi được đặt ra bằng cách tính sai số chuẩn của $\hat{\mu}$, được viết là $SE(\hat{\mu})$. Chúng ta có công thức quen thuộc

tiêu chuẩn lỗi

$$\text{Var}(\hat{\mu}) = SE(\hat{\mu})^2 = \frac{\sigma^2}{N}, \tag{3.7}$$

trong đó σ là độ lệch chuẩn của mỗi lần thực hiện Y . Nói một cách đại khái, sai số chuẩn cho chúng ta biết lượng trung bình mà điều này Ước tính $\hat{\mu}$ khác với giá trị thực của μ . Phương trình 3.7 cũng cho chúng ta biết cách Độ lệch này giảm dần khi n tăng – càng có nhiều quan sát, độ lệch càng nhỏ. sai số chuẩn của $\hat{\mu}$. Tương tự, ta có thể tự hỏi β^0 gần với mức độ nào. và β^1 tương ứng với các giá trị thực β_0 và β_1 . Để tính toán sai số chuẩn Liên quan đến β^0 và β^1 , chúng ta sử dụng các công thức sau:

$$SE(\beta^0)^2 = \sigma^2 \left(\frac{1}{N} + \frac{\bar{x}^2}{\sum_{i=1}^N (x_i - \bar{x})^2} \right), \quad SE(\beta^1)^2 = \frac{\sigma^2}{\sum_{i=1}^N (x_i - \bar{x})^2}, \tag{3.8}$$

trong đó $\sigma^2 = \text{Var}()$. Để các công thức này hoàn toàn chính xác, chúng ta cần giả sử rằng các sai số ϵ_i đối với mỗi quan sát đều có phương sai chung σ^2 và không tương quan. Điều này rõ ràng không đúng trong Hình 3.1, nhưng công thức vẫn đúng. hóa ra là một phép xấp xỉ tốt. Lưu ý trong công thức rằng $SE(\beta^1)$ là nhỏ hơn khi các x_i phân bố rộng hơn; theo trực giác, chúng ta có nhiều đòn bẩy hơn. để ước tính độ dốc khi điều này xảy ra. Chúng ta cũng thấy rằng $SE(\beta^0)$ sẽ là tương tự như $SE(\hat{\mu})$ nếu $\bar{x}$ bằng 0 (trong trường hợp đó β^0 sẽ bằng $\bar{y}$). Trong Nói chung, σ^2 không được biết, nhưng có thể được ước tính từ dữ liệu. Ước tính này của σ được gọi là sai số chuẩn dư, và được tính bằng công thức $RSE = \text{RSS}/(n - 2)$. Nói một cách chính xác, khi σ^2 được ước tính từ dữ liệu chúng ta nên viết $SE(\hat{\beta}^1)$ để chỉ ra rằng một ước tính đã được thực hiện, nhưng để đơn giản hóa ký hiệu, chúng ta sẽ bỏ đi phần “mũ” thừa này.

dư tiêu chuẩn lỗi

Sai số chuẩn có thể được sử dụng để tính khoảng tin cậy. Khoảng tin cậy 95% được định nghĩa là một phạm vi giá trị sao cho với 95% Xác suất, khoảng giá trị sẽ chứa giá trị chưa biết thực sự của tham số. Khoảng giá trị được xác định dựa trên giới hạn dưới và giới hạn trên đã được tính toán. Từ mẫu dữ liệu. Khoảng tin cậy 95% có đặc tính sau: nếu ta lấy mẫu lặp lại và xây dựng khoảng tin cậy cho Trong mỗi mẫu, 95% khoảng tin cậy sẽ chứa giá trị thực chưa biết. tham số. Đối với hồi quy tuyến tính, khoảng tin cậy 95% cho β_1 có dạng gần đúng như sau:

sự tự tin khoảng thời gian

$$\hat{\beta}^1 \pm 2 \cdot SE(\hat{\beta}^1). \tag{3.9}$$

2Công thức này đúng với điều kiện n quan sát không tương quan với nhau.

Tức là, có khoảng 95% khả năng khoảng thời gian đó sẽ đúng.

$$\beta^1 \pm 2 \cdot SE(\beta^1), \beta^1 + 2 \cdot SE(\beta^1) \tag{3.10}$$

sẽ chứa giá trị thực của β_1 .³ Tương tự, khoảng tin cậy cho β_0 có dạng gần đúng như sau:

$$\beta^0 \pm 2 \cdot SE(\beta^0).$$
 (3.11)

Trong trường hợp dữ liệu quảng cáo, khoảng tin cậy 95% cho β_0 là [6,130, 7,935] và khoảng tin cậy 95% cho β_1 là [0,042, 0,053]. Do đó, chúng ta có thể kết luận rằng trong trường hợp không có quảng cáo, doanh số bán hàng sẽ, Trung bình, con số này nằm trong khoảng từ 6.130 đến 7.935 đơn vị. Hơn nữa, Với mỗi khoản tăng 1.000 đô la trong quảng cáo truyền hình, sẽ có mức tăng trung bình là bao nhiêu? Doanh số bán hàng tăng từ 42 đến 53 sản phẩm.

Sai số chuẩn cũng có thể được sử dụng để thực hiện các kiểm định giả thuyết trên các hệ số. Kiểm định giả thuyết phổ biến nhất liên quan đến việc kiểm định giả thuyết không giả thuyết của

$$H_0 : \text{Không có mối quan hệ nào giữa } X \text{ và } Y \tag{3.12}$$

so với giả thuyết thay thế

$$H_a : \text{Giữa } X \text{ và } Y \text{ có mối quan hệ nào đó.} \tag{3.13}$$

Về mặt toán học, điều này tương ứng với việc kiểm tra.

$$H_0 : \beta_1 = 0$$

so với

$$H_a : \beta_1 \neq 0,$$

vì nếu $\beta_1 = 0$ thì mô hình (3.5) giảm xuống còn $Y = \beta_0 +$ và X là không liên quan đến Y . Để kiểm tra giả thuyết không, chúng ta cần xác định liệu β^1 , ước tính của chúng ta cho β_1 , có đủ xa số 0 để chúng ta có thể Hãy tự tin rằng β_1 khác 0. Khoảng cách bao xa là đủ? Tất nhiên là điều này phụ thuộc vào độ chính xác của β^1 —tức là, nó phụ thuộc vào $SE(\beta^1)$. Nếu $SE(\beta^1)$ là nhỏ, thì ngay cả những giá trị tương đối nhỏ của β^1 cũng có thể cung cấp bằng chứng mạnh mẽ. rằng $\beta_1 \neq 0$, và do đó có mối quan hệ giữa X và Y . Ngược lại, nếu $SE(\beta^1)$ lớn thì β^1 phải lớn về giá trị tuyệt đối để để chúng ta bác bỏ giả thuyết null. Trên thực tế, chúng ta tính toán thống kê t , được cho bởi

$$t = \frac{\beta^1 - 0}{SE(\beta^1)} \tag{3.14}$$

3. Xấp xỉ vì một số lý do. Phương trình 3.10 dựa trên giả định rằng Các lỗi có phân bố Gaussian. Ngoài ra, hệ số 2 phía trước số hạng $SE(\beta^1)$ sẽ thay đổi một chút. tùy thuộc vào số lượng quan sát n trong hồi quy tuyến tính. Nói chính xác hơn, hơn số 2, (3.10) nên chứa phân vị 97,5% của phân phối t với $n - 2$ bậc tự do. Chi tiết về cách tính khoảng tin cậy 95% một cách chính xác. Phần mềm R sẽ được cung cấp sau trong chương này.

	Hệ số Sai số chuẩn Thống kê t 7,0325 0,4578	Giá trị
Chặn	0,0475 0,0027	p 15,36 < 0,0001
TV		17,67 < 0,0001

BẢNG 3.1. Đối với dữ liệu **Quảng cáo**, hệ số của mô hình bình phương nhỏ nhất cho hồi quy số lượng sản phẩm bán ra dựa trên ngân sách quảng cáo truyền hình. Việc tăng ngân sách quảng cáo truyền hình thêm 1.000 đô la Mỹ tương ứng với việc tăng doanh số bán hàng khoảng 50 sản phẩm. (Lưu ý rằng biến doanh số **bán hàng** được tính bằng nghìn sản phẩm, và biến ngân sách **truyền hình** được tính bằng nghìn đô la Mỹ.)

điều này đo lường số độ lệch chuẩn mà β^1 cách xa 0. Nếu vậy, chúng ta kỳ vọng rằng quan hệ nào giữa X và Y sẽ có phân phối t với $n - 2$, (3.14) thực sự không có mối bậc tự do. Phân phối t có hình chuông và đối với các giá trị của n lớn hơn khoảng 30, nó khá giống với phân phối chuẩn tắc. Do đó, việc tính toán xác suất quan sát bất kỳ số nào bằng $|t|$ hoặc lớn hơn về giá trị tuyệt đối là một vấn đề đơn giản, giả sử $\beta_1 = 0$. Chúng ta gọi xác suất này là giá trị p . Nói một cách đại khái, chúng ta diễn giải giá trị p như sau: một giá trị p nhỏ cho thấy rằng khó có khả năng quan sát thấy mối liên hệ đáng kể như vậy giữa biến dự đoán và biến phản hồi do ngẫu nhiên, khi không có bất kỳ mối liên hệ thực sự nào giữa biến dự đoán và biến phản hồi. Do đó, nếu chúng ta thấy một giá trị p nhỏ, thì chúng ta có thể suy ra rằng có mối liên hệ giữa biến dự đoán và biến phản hồi. Chúng ta bác bỏ giả thuyết không – nghĩa là, chúng ta tuyên bố tồn tại mối quan hệ giữa X và Y – nếu giá trị p đủ nhỏ. Ngưỡng giá trị p điển hình để bác bỏ giả thuyết không là 5% hoặc 1%, mặc dù chủ đề này sẽ được khám phá chi tiết hơn nhiều trong Chương 13. Khi $n = 30$, những giá trị này tương ứng với thống kê t (3,14) lần lượt khoảng 2 và 2,75.

giá trị p

Bảng 3.1 cung cấp chi tiết về mô hình bình phương nhỏ nhất cho hồi quy số lượng sản phẩm bán ra dựa trên ngân sách quảng cáo truyền hình đối với dữ liệu **Quảng cáo**. Lưu ý rằng các hệ số cho β^0 và β^1 rất lớn so với sai số chuẩn của chúng, do đó thống kê t cũng lớn; xác suất thấy các giá trị như vậy nếu H_0 đúng gần như bằng không. Do đó, chúng ta có thể kết luận rằng $\beta_0 = 0$ và $\beta_1 = 0$.

3.1.3 Đánh giá độ chính xác của mô hình

Một khi chúng ta đã bác bỏ giả thuyết không (3.12) để ủng hộ giả thuyết thay thế (3.13), điều tự nhiên là chúng ta muốn định lượng mức độ phù hợp của mô hình với dữ liệu. Chất lượng của sự phù hợp hồi quy tuyến tính thường được đánh giá bằng hai đại lượng liên quan: sai số chuẩn dư (RSE) và thống kê R^2 .

R2

4Trong Bảng 3.1, giá trị p nhỏ đối với hệ số chặn cho thấy chúng ta có thể bác bỏ giả thuyết không rằng $\beta_0 = 0$, và giá trị p nhỏ đối với **TV** cho thấy chúng ta có thể bác bỏ giả thuyết không rằng $\beta_1 = 0$. Việc bác bỏ giả thuyết không thứ hai cho phép chúng ta kết luận rằng có mối quan hệ giữa **TV** và **doanh số bán hàng**. Việc bác bỏ giả thuyết không thứ nhất cho phép chúng ta kết luận rằng nếu không có chi tiêu cho **TV**, **doanh số bán hàng** sẽ khác không.

Số lượng	Giá trị	Sai số chuẩn dư	3	26	R2
0,612	Thông kê F	312,1			

BẢNG 3.2. Đối với dữ liệu **Quảng cáo** , thông tin chi tiết hơn về mô hình bình phương nhỏ nhất cho hồi quy số lượng sản phẩm bán ra dựa trên ngân sách quảng cáo truyền hình.

Bảng 3.2 hiển thị RSE, thống kê R2 và thống kê F (sẽ được mô tả trong Phần 3.2.2) cho hồi quy tuyến tính của số lượng sản phẩm bán ra dựa trên ngân sách quảng cáo truyền hình.

Sai số chuẩn còn lại

Nhớ lại mô hình (3.5) rằng mỗi quan sát đều liên quan đến một số hạng sai số. Do sự hiện diện của các số hạng sai số này, ngay cả khi chúng ta biết đường hồi quy thực sự (tức là ngay cả khi β_0 và β_1 đã biết), chúng ta cũng không thể dự đoán Y từ X một cách hoàn hảo. RSE là ước tính độ lệch chuẩn của . Nói một cách đại khái, đó là lượng trung bình mà phản hồi sẽ lệch khỏi đường hồi quy thực sự. Nó được tính bằng công thức

$$RSE = \frac{1}{n-2} \sqrt{RSS} = \frac{1}{n-2} \sqrt{\sum_{i=1}^N (y_i - \hat{y}_i)^2} \tag{3.15}$$

Lưu ý rằng RSS đã được định nghĩa trong Mục 3.1.1 và được tính bằng công thức sau:

$$RSS = \sum_{i=1}^N (y_i - \hat{y}_i)^2 \tag{3.16}$$

Trong trường hợp dữ liệu quảng cáo, từ kết quả hồi quy tuyến tính trong Bảng 3.2 , ta thấy RSE là 3,26. Nói cách khác, doanh số thực tế ở mỗi thị trường lệch khỏi đường hồi quy thực khoảng 3.260 đơn vị, trung bình. Một cách khác để hiểu điều này là ngay cả khi mô hình chính xác và giá trị thực của các hệ số chưa biết β_0 và β_1 được biết chính xác, bất kỳ dự đoán doanh số nào dựa trên quảng cáo truyền hình vẫn sẽ sai lệch khoảng 3.260 đơn vị, trung bình. Tất nhiên, liệu 3.260 đơn vị có phải là sai số dự đoán chấp nhận được hay không phụ thuộc vào bối cảnh của bài toán. Trong tập dữ liệu quảng cáo, giá trị trung bình của **doanh số** trên tất cả các thị trường là khoảng 14.000 đơn vị, do đó sai số phần trăm là $3.260/14.000 = 23\%$.

RSE được coi là thước đo mức độ không phù hợp của mô hình (3.5) với dữ liệu. Nếu các dự đoán thu được bằng cách sử dụng mô hình rất gần với các giá trị kết quả thực sự—tức là, nếu $\hat{y}_i \approx y_i$ đối với $i = 1, \dots, n$ —thì (3.15) sẽ nhỏ, và chúng ta có thể kết luận rằng mô hình phù hợp với dữ liệu rất tốt. Mặt khác, nếu $\hat{y}_i$ rất xa y_i đối với một hoặc nhiều quan sát, thì RSE có thể khá lớn, cho thấy mô hình không phù hợp với dữ liệu tốt.

Thống kê R2

RSE cung cấp một thước đo tuyệt đối về sự thiếu phù hợp của mô hình (3.5) với dữ liệu. Nhưng vì nó được đo bằng đơn vị Y nên nó không phải lúc nào cũng chính xác. ,

Làm rõ những gì tạo nên một RSE tốt. Chỉ số R2 cung cấp một giải pháp thay thế. Mức độ phù hợp. Nó có dạng tỷ lệ- tỷ lệ phương sai. đã giải thích-và do đó nó luôn có giá trị nằm giữa 0 và 1, và là không phụ thuộc vào quy mô của Y.

Để tính R2, chúng ta sử dụng công thức sau:

$$R^2 = 1 - \frac{TSS - RSS}{TSS} = \frac{RSS}{TSS}$$

(3.17)

trong đó TSS = $\sum (y_i - \bar{y})^2$ là tổng bình phương, và RSS được định nghĩa trong (3.16). TSS đo lường tổng phương sai trong phản hồi Y và có thể là được coi là mức độ biến thiên vốn có trong phản hồi trước khi Phép hồi quy được thực hiện. Ngược lại, RSS đo lường mức độ biến thiên. Điều đó vẫn chưa được giải thích sau khi thực hiện hồi quy. Do đó, TSS RSS đo lường mức độ biến thiên trong phản hồi được giải thích (hoặc (đã loại bỏ) bằng cách thực hiện phép hồi quy, và R2 đo lường tỷ lệ của Sự biến thiên trong Y có thể được giải thích bằng X. Một thống kê R2 gần với Giá trị từ 0 đến 1 cho thấy một tỷ lệ lớn sự biến thiên trong phản hồi là được giải thích bằng phương trình hồi quy. Một con số gần bằng 0 cho thấy phương trình hồi quy Điều này không giải thích được nhiều về sự biến thiên trong phản hồi; điều này có thể xảy ra Bởi vì mô hình tuyến tính không chính xác, hoặc phương sai sai số σ^2 cao, hoặc cả hai. Trong Bảng 3.2, hệ số R2 là 0,61, tức là chỉ chiếm chưa đến hai phần ba tổng biến thiên.

Doanh số bán hàng được giải thích bằng phương trình hồi quy tuyến tính dựa trên số liệu truyền hình.

Chỉ số R2 (3.17) có ưu thế về mặt diễn giải so với RSE. (3.15), vì không giống như RSE, nó luôn nằm giữa 0 và 1. Tuy nhiên, nó có thể Việc xác định giá trị R2 tốt vẫn còn là một thách thức, và nói chung, Điều này sẽ phụ thuộc vào ứng dụng. Ví dụ, trong một số bài toán nhất định về Trong vật lý, chúng ta có thể biết rằng dữ liệu thực sự đến từ một mô hình tuyến tính với một sai số dư nhỏ. Trong trường hợp này, chúng ta sẽ kỳ vọng thấy giá trị R2 là Giá trị R2 cực kỳ gần với 1, và giá trị R2 nhỏ hơn đáng kể có thể cho thấy... Vấn đề nghiêm trọng với thí nghiệm mà dữ liệu được tạo ra. Mặt khác, trong các ứng dụng điển hình trong sinh học, tâm lý học, tiếp thị, và các lĩnh vực khác, mô hình tuyến tính (3.5) tốt nhất chỉ là một mô hình cực kỳ thô sơ sự xấp xỉ dữ liệu và các sai số còn lại do các yếu tố chưa được đo lường khác. Các yếu tố thường rất lớn. Trong bối cảnh này, chúng ta chỉ mong đợi một kết quả rất nhỏ. một tỷ lệ nhỏ sự biến thiên trong phản hồi được giải thích bởi Là một công cụ dự đoán, và giá trị R2 thấp hơn 0,1 có lẽ sẽ thực tế hơn! Hệ số R2 là thước đo mối quan hệ tuyến tính giữa X và Y. Hãy nhớ rằng hệ số tương quan, được định nghĩa là

$$\text{Cor}(X, Y) = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2 \sum_{i=1}^N (y_i - \bar{y})^2}}$$

(3.18)

Đây cũng là thước đo mối quan hệ tuyến tính giữa X và Y. Điều này cho thấy chúng ta có thể sử dụng $r = \text{Cor}(X, Y)$ thay vì R2 để đánh giá sự phù hợp của mô hình tuyến tính. Trên thực tế, có thể chứng minh rằng trong trường hợp đơn giản

5 Chúng tôi lưu ý rằng trên thực tế, vế phải của (3.18) là hệ số tương quan mẫu; do đó, Viết $\text{Cor}(X, Y)$ sẽ chính xác hơn; tuy nhiên, chúng ta bỏ dấu “mẫu” để đơn giản hóa. ký hiệu.

tổng cộng của hình vuông

tương quan

Hồi quy đơn giản về doanh số bán hàng trên đài phát thanh			
	Hệ số Sai số chuẩn Thống kê t Giá trị p		
Đài phát thanh chặn	9,312	0,563	16,54 < 0,0001
	0,203	0,020	9,92 < 0,0001

Hồi quy đơn giản về doanh số bán báo			
	Hệ số Sai số chuẩn Thống kê t Giá trị p		
Chặn báo	12.351	0,621	19,88 < 0,0001
	0.055	0,017	3,30 0,00115

BẢNG 3.3. Các mô hình hồi quy tuyến tính đơn giản hơn cho dữ liệu **Quảng cáo** . Các hệ số của mô hình hồi quy tuyến tính đơn giản cho số lượng sản phẩm bán ra trên Top: Ngân sách quảng cáo trên đài phát thanh và ngân sách quảng cáo trên báo chí. Mỗi khoản tăng 1.000 đô la chỉ cho quảng cáo trên đài phát thanh tương ứng với mức tăng trung bình trong... Doanh số bán hàng tăng khoảng 203 đơn vị, trong khi mức tăng chi tiêu cho quảng cáo trên báo chí tương đương chỉ làm tăng doanh số bán hàng trung bình khoảng 55 đơn vị. (Lưu ý) Biến số **doanh số** được tính bằng nghìn đơn vị, và **đài phát thanh** và **báo chí**. (Các biến số được tính bằng nghìn đô la.)

Trong thiết lập hồi quy tuyến tính, $R^2 = r^2$. Nói cách khác, hệ số tương quan bình phương. và chỉ số R^2 là giống hệt nhau. Tuy nhiên, trong phần tiếp theo, chúng ta sẽ Thảo luận về bài toán hồi quy tuyến tính bội, trong đó chúng ta sử dụng đồng thời nhiều biến dự báo để dự đoán biến phản hồi. Khái niệm về hệ số tương quan. Mối quan hệ giữa các biến dự báo và biến phản hồi không tự động mở rộng đến... thiết lập này, vì hệ số tương quan định lượng mối liên hệ giữa một yếu tố duy nhất giữa một cặp biến thay vì giữa một số lượng lớn biến hơn. Chúng ta sẽ Như bạn thấy, R^2 đảm nhiệm vai trò này.

3.2 Hồi quy tuyến tính bội

Hồi quy tuyến tính đơn giản là một phương pháp hữu ích để dự đoán phản hồi trên dựa trên một biến dự báo duy nhất. Tuy nhiên, trên thực tế, chúng ta thường có nhiều hơn một biến dự báo. nhiều hơn một yếu tố dự báo. Ví dụ, trong dữ liệu **Quảng cáo** , chúng tôi đã xem xét mối quan hệ giữa doanh số bán hàng và quảng cáo truyền hình. Chúng tôi cũng có dữ liệu về số tiền chi cho quảng cáo trên đài phát thanh và báo chí, và chúng ta có thể muốn biết liệu hai phương tiện truyền thông này có liên quan đến nhau hay không. với doanh số bán hàng. Làm thế nào chúng ta có thể mở rộng phân tích dữ liệu quảng cáo của mình để Đáp ứng hai yếu tố dự báo bổ sung này?

Một phương án là thực hiện ba phép hồi quy tuyến tính đơn giản riêng biệt, mỗi phép hồi quy bao gồm... sử dụng một phương tiện quảng cáo khác làm yếu tố dự báo. Ví dụ: Chúng ta có thể sử dụng mô hình hồi quy tuyến tính đơn giản để dự đoán doanh số bán hàng dựa trên các yếu tố sau: số tiền chi cho quảng cáo trên đài phát thanh. Kết quả được hiển thị trong Bảng 3.3 (phần trên). (bảng). Chúng tôi nhận thấy rằng việc tăng chi tiêu cho quảng cáo trên đài phát thanh thêm 1.000 đô la là liên quan đến sự tăng doanh số khoảng 203 đơn vị. Bảng 3.3 (phần dưới) bảng) chứa các hệ số bình phương nhỏ nhất cho hồi quy tuyến tính đơn giản của Doanh thu được chuyển vào ngân sách quảng cáo trên báo. Tăng 1.000 đô la cho báo chí. Ngân sách quảng cáo có liên quan đến việc tăng doanh số bán hàng khoảng... 55 đơn vị.

3.2 Hồi quy tuyến tính bội 81

Tuy nhiên, phương pháp sử dụng mô hình hồi quy tuyến tính đơn giản riêng biệt cho mỗi biến dự báo không hoàn toàn thỏa đáng. Trước hết, không rõ làm thế nào để đưa ra một dự đoán duy nhất về doanh số bán hàng dựa trên ba ngân sách quảng cáo khác nhau, vì mỗi ngân sách lại gắn liền với một phương trình hồi quy riêng biệt. Thứ hai, mỗi trong ba phương trình hồi quy đều bỏ qua hai phương tiện truyền thông còn lại khi ước tính các hệ số hồi quy. Chúng ta sẽ thấy ngay sau đây rằng nếu ngân sách truyền thông có tương quan với nhau trong 200 thị trường trong tập dữ liệu của chúng ta, thì điều này có thể dẫn đến những ước tính rất sai lệch về mối liên hệ giữa ngân sách truyền thông và doanh số bán hàng.

Thay vì áp dụng một mô hình hồi quy tuyến tính đơn giản riêng biệt cho mỗi biến dự báo, một cách tiếp cận tốt hơn là mở rộng mô hình hồi quy tuyến tính đơn giản (3.5) để nó có thể trực tiếp bao gồm nhiều biến dự báo. Chúng ta có thể làm điều này bằng cách gán cho mỗi biến dự báo một hệ số độ dốc riêng biệt trong một mô hình duy nhất. Nói chung, giả sử chúng ta có p biến dự báo khác nhau. Khi đó, mô hình hồi quy tuyến tính bội có dạng như sau:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon, \quad (3.19)$$

Trong đó, X_j biểu thị biến dự báo thứ j và β_j định lượng mối liên hệ giữa biến đó và biến phản hồi. Chúng ta diễn giải β_j là tác động trung bình lên Y khi X_j tăng một đơn vị, giữ nguyên tất cả các biến dự báo khác.

Trong ví dụ quảng cáo, (3.19) trở thành

$$\text{doanh thu} = \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times \text{báo} + \epsilon. \quad (3.20)$$

3.2.1 Ước tính các hệ số hồi quy


Như trường hợp trong thiết lập hồi quy tuyến tính đơn giản, các hệ số hồi quy $\beta_0, \beta_1, \dots, \beta_p$ trong (3.19) chưa biết và phải được ước tính. Với các ước tính $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$, chúng ta có thể đưa ra dự đoán bằng cách sử dụng công thức

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p. \quad (3.21)$$

Các tham số được ước tính bằng phương pháp bình phương tối thiểu tương tự như chúng ta đã thấy trong bối cảnh hồi quy tuyến tính đơn giản. Chúng ta chọn $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ để giảm thiểu tổng bình phương phần dư.

$$\begin{aligned} \text{RSS} &= \sum_{i=1}^N (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip})^2. \end{aligned} \quad (3.22)$$

Các giá trị $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ làm giảm thiểu (3.22) là các ước tính hệ số hồi quy bình phương nhỏ nhất bội. Không giống như các ước tính hồi quy tuyến tính đơn giản được đưa ra trong (3.4), các ước tính hệ số hồi quy bội có dạng phức tạp hơn một chút, để biểu diễn nhất bằng đại số ma trận. Vì lý do này, chúng tôi không cung cấp chúng ở đây. Bất kỳ phần mềm thống kê nào cũng có thể được sử dụng để tính toán các ước tính hệ số này, và sau trong chương này, chúng tôi sẽ chỉ ra cách thực hiện điều này trong R. Hình 3.4



HÌNH 3.4. Trong không gian ba chiều, với hai biến dự đoán và một biến phản hồi, đường hồi quy bình phương nhỏ nhất trở thành một mặt phẳng. Mặt phẳng này được chọn để giảm thiểu tổng bình phương khoảng cách thẳng đứng giữa mỗi điểm quan sát (hiển thị màu đỏ) và mặt phẳng.

Hình minh họa này thể hiện một ví dụ về phương pháp bình phương tối thiểu phù hợp với một tập dữ liệu giả định có $p = 2$ biến dự đoán.

Bảng 3.4 hiển thị các ước tính hệ số hồi quy bội khi sử dụng ngân sách quảng cáo trên truyền hình, radio và báo chí để dự đoán doanh số bán sản phẩm dựa trên dữ liệu **Quảng cáo**. Chúng tôi diễn giải các kết quả này như sau: với một lượng quảng cáo trên truyền hình và báo chí nhất định, việc chi thêm 1.000 đô la cho quảng cáo trên radio sẽ tương ứng với khoảng 189 đơn vị doanh số bán hàng tăng thêm. So sánh các ước tính hệ số này với các ước tính được hiển thị trong Bảng 3.1 và 3.3, chúng ta nhận thấy rằng các ước tính hệ số hồi quy bội cho **truyền hình** và **radio** khá giống với các ước tính hệ số hồi quy tuyến tính đơn giản. Tuy nhiên, trong khi ước tính hệ số hồi quy **báo chí** trong Bảng 3.3 có giá trị khác 0 đáng kể, thì ước tính hệ số cho **báo chí** trong mô hình hồi quy bội lại gần bằng 0, và giá trị p tương ứng không còn đáng kể, với giá trị khoảng 0,86. Điều này cho thấy các hệ số hồi quy đơn giản và đa biến có thể khá khác nhau. Sự khác biệt này xuất phát từ thực tế là trong trường hợp hồi quy đơn giản, hệ số góc biểu thị mức tăng trung bình doanh số bán sản phẩm liên quan đến việc tăng 1.000 đô la chi phí quảng cáo trên báo chí, bỏ qua các yếu tố dự báo khác như **truyền hình** và **radio**. Ngược lại, trong mô hình hồi quy đa biến, hệ số của **báo chí** thể hiện mức tăng trung bình doanh số bán sản phẩm khi tăng chi tiêu cho báo chí thêm 1.000 đô la trong khi giữ chi tiêu cho **truyền hình** và **radio** không đổi.

Liệu có hợp lý không khi phân tích hồi quy đa biến cho thấy không có mối quan hệ nào giữa **doanh số bán hàng** và **báo chí**, trong khi phân tích hồi quy tuyến tính đơn giản lại cho thấy điều ngược lại?

3.2 Hồi quy tuyến tính bội 83

	Hệ số Sai số chuẩn Thống kê t Giá trị p
Chặn	2,939 0,3119 9,42 < 0,0001
TV	0,046 0,0014 32,81 < 0,0001
radio	0,189 0,0086 21,89 < 0,0001
báo	0,001 0,0059 0,18 0,8599

BẢNG 3.4. Đối với dữ liệu **Quảng cáo** , ước tính hệ số bình phương nhỏ nhất của Hồi quy tuyến tính bội về số lượng sản phẩm bán ra trên truyền hình, đài phát thanh và báo chí. ngân sách quảng cáo.

	TV	bán báo phát thanh
TV	1.0000 0.0548 1.0000	0,0567 0,7822
radio		0.3541 0.5762
doanh số bán		1.0000 0.2283
báo		1.0000

BẢNG 3.5. Ma trận tương quan giữa **truyền hình**, **đài phát thanh**, **báo chí** và **doanh số bán hàng** của Dữ liệu **quảng cáo** .

Ngược lại ư? Thực tế là đúng vậy. Hãy xem xét ma trận tương quan của ba yếu tố đó. Các biến dự báo và biến phản hồi được hiển thị trong Bảng 3.5. Lưu ý Hệ số tương quan giữa **đài phát thanh** và **báo chí** là 0,35. Điều này cho thấy Các thị trường có nhiều quảng cáo trên báo chí thường cũng có nhiều quảng cáo trên đài phát thanh. Bây giờ giả sử rằng mô hình hồi quy bội là chính xác và Quảng cáo trên báo chí không liên quan đến doanh số bán hàng, mà là quảng cáo trên đài phát thanh. có liên quan đến doanh số bán hàng. Sau đó, ở những thị trường mà chúng ta chi nhiều hơn cho quảng cáo trên đài phát thanh. Doanh số bán hàng của chúng ta sẽ có xu hướng cao hơn, và như ma trận tương quan của chúng ta cho thấy, chúng ta Họ cũng có xu hướng chi tiêu nhiều hơn cho quảng cáo trên báo chí ở những thị trường đó. Do đó, trong một phép hồi quy tuyến tính đơn giản chỉ xem xét **doanh số bán hàng** so với... **Từ báo chí**, chúng ta sẽ nhận thấy rằng giá trị cao hơn của **báo chí** thường đi kèm với giá trị cao hơn của **doanh số bán hàng**, mặc dù quảng cáo trên báo chí thường ít phổ biến hơn. Không liên quan trực tiếp đến doanh số bán hàng. Vì vậy, quảng cáo **trên báo chí** chỉ là một hình thức gián tiếp. Đối với quảng cáo **trên đài phát thanh** ; **báo chí** được "ghi nhận" về sự liên kết giữa hai bên. **Radio** đang được bán.

Kết quả có vẻ hơi trái ngược với trực giác này lại rất phổ biến trong nhiều trường hợp thực tế. các tình huống. Hãy xem xét một ví dụ phi lý để minh họa điểm này. Chạy Phân tích hồi quy mối quan hệ giữa số vụ cá mập tấn công và doanh số bán kem dựa trên dữ liệu thu thập được tại... Một cộng đồng ven biển nhất định trong một khoảng thời gian nhất định sẽ cho thấy kết quả tích cực. Mối quan hệ này tương tự như mối quan hệ giữa **bộ phận bán hàng** và **báo chí**. Tất nhiên rồi. Cho đến nay, chưa ai đề xuất việc cấm kem ở các bãi biển. để giảm thiểu các vụ tấn công của cá mập. Trên thực tế, nhiệt độ cao hơn khiến nhiều người hơn. đi đến bãi biển, điều này dẫn đến doanh số bán kem tăng lên và nhiều hơn nữa. Các vụ tấn công của cá mập. Phân tích hồi quy đa biến về các vụ tấn công của cá mập và doanh số bán kem. và nhiệt độ cho thấy rằng, như trực giác mách bảo, doanh số bán kem không hề giảm. Không còn là yếu tố dự báo quan trọng sau khi điều chỉnh theo nhiệt độ.

3.2.2 Một số câu hỏi quan trọng

Khi thực hiện hồi quy tuyến tính bội, chúng ta thường quan tâm đến Giải đáp một vài câu hỏi quan trọng.

84 3. Hồi quy tuyến tính

1. Liệu ít nhất một trong các biến dự báo $X_1, X_2, \dots, X_p$ có hữu ích trong việc dự đoán không? Câu trả lời là gì?
2. Liệu tất cả các biến dự báo có giúp giải thích được biến dự , hoặc chỉ là một tập hợp con của biến Y một cách hữu ích không?
3. Mô hình phù hợp với dữ liệu tốt đến mức nào?
4. Cho một tập hợp các giá trị biến dự đoán, chúng ta nên dự đoán giá trị biến phản hồi nào? Vậy dự đoán của chúng ta chính xác đến mức nào?

Chúng ta sẽ lần lượt giải đáp từng câu hỏi này.

Câu hỏi thứ nhất: Có mối quan hệ nào giữa biến phản hồi và biến dự báo không?

Hãy nhớ rằng trong thiết lập hồi quy tuyến tính đơn giản, để xác định xem có mối quan hệ giữa biến phản hồi và biến dự báo hay không, chúng ta chỉ cần kiểm tra xem $\beta_1 = 0$ hay không. Trong thiết lập hồi quy đa biến với p biến dự báo, chúng ta cần phải hỏi xem tất cả các hệ số hồi quy có bằng 0 hay không, tức là liệu $\beta_1 = \beta_2 = \dots = \beta_p = 0$ hay không. Cũng như trong thiết lập hồi quy tuyến tính đơn giản, chúng ta sử dụng kiểm định giả thuyết để trả lời câu hỏi này. Chúng ta kiểm định giả thuyết không,

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

so với phương án thay thế

$$H_a : \text{Ít nhất một } \beta_j \text{ khác } 0.$$

Phép kiểm định giả thuyết này được thực hiện bằng cách tính toán thống kê F .

Thống kê F

$$F = \frac{(TSS - RSS)/p}{RSS/(n - p - 1)}, \quad (3.23)$$

trong đó, cũng như với hồi quy tuyến tính đơn giản, $TSS = (y_i - \bar{y})^2$ và $RSS = (y_i - \hat{y}_i)^2$.

Nếu các giả định của mô hình tuyến tính là chính xác, người ta có thể chứng minh rằng

$$E\{RSS/(n - p - 1)\} = \sigma^2$$

và với điều kiện H_0 là đúng,

$$E\{(TSS - RSS)/p\} = \sigma^2.$$

Do đó, khi không có mối quan hệ giữa biến phản hồi và các biến dự đoán, người ta kỳ vọng thống kê F sẽ có giá trị gần bằng 1. Mặt khác, nếu giả thuyết H_a đúng, thì $E\{(TSS - RSS)/p\} > \sigma^2$, nên ta kỳ vọng F sẽ lớn hơn 1.

Bảng 3.6 hiển thị chỉ số F cho mô hình hồi quy tuyến tính bội thu được bằng cách hồi quy doanh số bán hàng dựa trên quảng cáo trên radio, TV và báo chí. Trong ví dụ này, chỉ số F là 570. Vì giá trị này lớn hơn 1 rất nhiều, nó cung cấp bằng chứng thuyết phục chống lại giả thuyết không H_0 . Nói cách khác, chỉ số F lớn cho thấy ít nhất một trong các phương tiện quảng cáo phải có liên quan đến doanh số bán hàng. Tuy nhiên, điều gì sẽ xảy ra nếu chỉ số F gần với 1 hơn? Chỉ số F cần lớn đến mức nào để chúng ta có thể bác bỏ H_0 ?

3.2 Hồi quy tuyến tính bội 85

Số lượng	Giá trị Sai số chuẩn dư	1,69 R2
0,897 Thống kê F 570		

BẢNG 3.6. Thông tin chi tiết hơn về mô hình bình phương tối thiểu cho hồi quy số lượng sản phẩm bán ra dựa trên ngân sách quảng cáo trên truyền hình, báo chí và radio trong dữ liệu **Quảng cáo** . Các thông tin khác về mô hình này được trình bày trong Bảng 3.4.

Kết luận rằng có mối quan hệ? Hóa ra câu trả lời phụ thuộc vào giá trị của n và p. Khi n lớn, thống kê F chỉ lớn hơn 1 một chút vẫn có thể cung cấp bằng chứng chống lại H0. Ngược lại, cần một thống kê F lớn hơn để bác bỏ H0 nếu n nhỏ. Khi H0 đúng và sai số i có phân phối chuẩn, thống kê F tuân theo phân phối F.6 Với bất kỳ giá trị nào của n và p, bất kỳ phần mềm thống kê nào cũng có thể được sử dụng để tính giá trị p liên quan đến thống kê F bằng cách sử dụng phân phối này. Dựa trên giá trị p này, chúng ta có thể xác định xem có nên bác bỏ H0 hay không. Đối với dữ liệu quảng cáo, giá trị p liên quan đến thống kê F trong Bảng 3.6 về cơ bản bằng 0, vì vậy chúng ta có bằng chứng cực kỳ mạnh mẽ rằng ít nhất một trong các phương tiện truyền thông có liên quan đến việc tăng doanh số **bán hàng**.

Trong (3.23) chúng ta đang kiểm tra H0 rằng tất cả các hệ số đều bằng không. Đôi khi chúng ta muốn kiểm tra xem một tập con cụ thể q của các hệ số có bằng không hay không. Điều này tương ứng với giả thuyết không.

$$H_0 : \beta_p \quad q+1 = \beta_p \quad q+2 = \cdots = \beta_p = 0,$$

Để thuận tiện, chúng tôi đã đặt các biến được chọn để loại bỏ ở cuối danh sách. Trong trường hợp này, chúng tôi xây dựng mô hình thứ hai sử dụng tất cả các biến ngoại trừ q biến cuối cùng. Giá trị tổng bình phương phần dư của mô hình đó là RSS0. Khi đó, thống kê F thích hợp là

$$= \frac{(RSS_0 - RSS)/q}{RSS/(n - p - 1)} \tag{3.24}$$

Lưu ý rằng trong Bảng 3.4, đối với mỗi biến dự báo riêng lẻ, một thống kê t và một giá trị p đã được báo cáo. Chúng cung cấp thông tin về việc liệu mỗi biến dự báo riêng lẻ có liên quan đến biến phản hồi hay không, sau khi điều chỉnh cho các biến dự báo khác. Hóa ra mỗi giá trị này hoàn toàn tương đương với phép thử F loại bỏ biến đơn đó khỏi mô hình, giữ lại tất cả các biến khác – tức là q=1 trong (3.24). Vì vậy, nó báo cáo tác động một phần của việc thêm biến đó vào mô hình. Ví dụ, như chúng ta đã thảo luận trước đó, các giá trị p này cho thấy **TV** và **radio** có liên quan đến **doanh số bán hàng**, nhưng không có bằng chứng nào cho thấy **báo chí** có liên quan đến **doanh số bán hàng** khi **TV** và **radio** được giữ cố định.

Với các giá trị p riêng lẻ cho từng biến, tại sao chúng ta cần xem xét thống kê F tổng thể? Rốt cuộc, có vẻ như nếu bất kỳ giá trị p nào của các biến riêng lẻ rất nhỏ, thì ít nhất một trong các biến dự báo có liên quan đến biến phản hồi. Tuy nhiên, lập luận này có sai sót, đặc biệt khi số lượng biến dự báo p lớn.

6Ngày cả khi sai số không phân bố chuẩn, thống kê F vẫn xấp xỉ tuân theo. Phân phối F được xác định khi kích thước mẫu n lớn.
7Bình phương của mỗi giá trị thống kê t là giá trị thống kê F tương ứng.

Ví dụ, hãy xem xét trường hợp $p = 100$ và $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ là đúng, vì vậy không có biến nào thực sự liên quan đến phản hồi. Trong tình huống này, khoảng 5% giá trị p liên quan đến mỗi biến (của loại được hiển thị trong Bảng 3.4) sẽ có giá trị dưới 0,05 một cách ngẫu nhiên. Nói cách khác, Chúng tôi dự kiến sẽ thấy khoảng năm giá trị p nhỏ ngay cả khi không có bất kỳ mối liên hệ thực sự nào giữa các yếu tố dự báo và phản hồi. Trên thực tế, nó Rất có thể chúng ta sẽ quan sát thấy ít nhất một giá trị p nhỏ hơn 0,05 một cách ngẫu nhiên! Do đó, nếu chúng ta sử dụng các giá trị thống kê riêng lẻ và các giá trị p tương ứng theo thứ tự để quyết định xem có mối liên hệ nào giữa các biến số hay không và Câu trả lời là, rất có thể chúng ta sẽ đưa ra kết luận sai. Có một mối quan hệ như vậy. Tuy nhiên, thống kê F không bị ảnh hưởng bởi vấn đề này là do nó điều chỉnh theo số lượng biến dự đoán. Do đó, nếu H_0 Đúng vậy, chỉ có 5% khả năng thống kê F sẽ cho ra giá trị p nhỏ hơn 0,05, bất kể số lượng biến dự đoán hay số lượng biến ngẫu nhiên là bao nhiêu. quan sát.

Phương pháp sử dụng thống kê F để kiểm tra mối liên hệ giữa Mô hình dự đoán và phản hồi hoạt động tốt khi p tương đối nhỏ, và chắc chắn là nhỏ so với n . Tuy nhiên, đôi khi chúng ta có rất nhiều biến. Nếu $p > n$ thì sẽ có nhiều hệ số β_j cần ước lượng. hơn là các quan sát để từ đó ước tính chúng. Trong trường hợp này, chúng ta không thể thậm chí không thể áp dụng mô hình hồi quy tuyến tính bội bằng phương pháp bình phương nhỏ nhất, do đó thống kê F không thể được sử dụng, và hầu hết các khái niệm khác cũng vậy. Như chúng ta đã thấy trong chương này. Khi p lớn, một số phương pháp tiếp cận như đã thảo luận trong phần tiếp theo, chẳng hạn như phương pháp chọn lọc tiến lên, có thể được sử dụng. Điều này Khái niệm về môi trường đa chiều sẽ được thảo luận chi tiết hơn trong Chương 6.

chiều cao

Phần hai: Quyết định về các biến số quan trọng

Như đã thảo luận ở phần trước, bước đầu tiên trong hồi quy đa biến là... Mục đích của phân tích là tính toán thống kê F và kiểm tra giá trị p tương ứng. Nếu dựa trên giá trị p đó, chúng ta kết luận rằng ít nhất một trong các trường hợp sau đây đúng: Nếu các biến dự báo có liên quan đến biến phản hồi, thì việc tự hỏi biến nào có liên quan là điều tự nhiên. Những kẻ có tội! Chúng ta có thể xem xét các giá trị p riêng lẻ như trong Bảng 3.4, nhưng như đã thảo luận (và được tìm hiểu sâu hơn trong Chương 13), nếu p lớn thì chúng ta Có khả năng sẽ dẫn đến một số phát hiện sai.

Có khả năng tất cả các yếu tố dự báo đều có liên quan đến phản hồi. nhưng thường thì phản ứng đó chỉ liên quan đến một tập hợp con của các biến dự báo. Nhiệm vụ là xác định biến dự báo nào là... liên quan đến phản hồi, để phù hợp với một mô hình duy nhất chỉ bao gồm Việc lựa chọn các biến dự báo đó được gọi là lựa chọn biến. Vấn đề lựa chọn biến được nghiên cứu rộng rãi trong Chương 6, và vì vậy ở đây chúng ta sẽ trình bày Đây chỉ là một phác thảo ngắn gọn về một số phương pháp cổ điển.

biến
lựa chọn

Lý tưởng nhất, chúng ta muốn thực hiện việc lựa chọn biến bằng cách thử nghiệm nhiều biến khác nhau. các mô hình khác nhau, mỗi mô hình chứa một tập hợp con khác nhau của các biến dự đoán. Ví dụ: ví dụ, nếu $p = 2$, thì chúng ta có thể xem xét bốn mô hình: (1) mô hình không chứa biến nào, (2) mô hình chỉ chứa X_1 , (3) mô hình chứa

8. Điều này liên quan đến khái niệm quan trọng về kiểm định đa biến, vốn là trọng tâm của... Chương 13.

3.2 Hồi quy tuyến tính bội 87

chỉ X_2 , và (4) một mô hình chứa cả X_1 và X_2 . Sau đó, chúng ta có thể chọn mô hình tốt nhất trong số tất cả các mô hình mà chúng ta đã xem xét. Làm thế nào

Chúng ta xác định mô hình nào là tốt nhất bằng cách nào? Có thể sử dụng nhiều số liệu thống kê khác nhau để

Đánh giá chất lượng của một mô hình. Các chỉ số này bao gồm Cp của Mallow , tiêu chí thông tin Akaike (AIC), tiêu chí thông tin Bayesian (BIC) và R^2 hiệu chỉnh . Chúng được thảo luận chi tiết hơn trong Chương 6. Chúng ta cũng có thể xác định mô hình nào tốt nhất bằng cách vẽ biểu đồ các kết quả đầu ra khác nhau của mô hình, chẳng hạn như... phần dư, để tìm kiếm các quy luật.

Thật không may, có tổng cộng 2^p mô hình chứa các tập con của p các biến số. Điều này có nghĩa là ngay cả với p vừa phải, việc thử mọi khả năng cũng rất khó khăn. Việc chọn một tập con của các biến dự đoán là không khả thi. Ví dụ, chúng ta đã thấy rằng nếu $p = 2$ thì có $2^2 = 4$ mô hình cần xem xét. Nhưng nếu $p = 30$, thì chúng ta phải xem xét $2^{30} = 1.073.741.824$ mô hình! Điều này không thực tế. Do đó, trừ khi p rất lớn. Vì kích thước nhỏ, chúng ta không thể xem xét tất cả các mô hình 2^p , và thay vào đó chúng ta cần một giải pháp tự động. và phương pháp hiệu quả để lựa chọn một tập hợp nhỏ hơn các mô hình cần xem xét. Có ba cách tiếp cận kinh điển cho nhiệm vụ này:

- Phương pháp chọn lọc tiến lên. Chúng ta bắt đầu với mô hình rỗng—mô hình chỉ chứa hệ số chặn mà không có biến dự đoán. Sau đó, chúng ta thực hiện p hồi quy tuyến tính đơn giản và thêm vào mô hình rỗng biến dẫn đến kết quả cuối cùng. RSS thấp nhất. Sau đó, chúng ta thêm vào mô hình đó biến số thu được ở mức RSS thấp nhất cho mô hình hai biến mới. Phương pháp này là tiếp tục cho đến khi một quy tắc dừng nào đó được thỏa mãn.

phía trước
lựa chọn
mô hình rỗng
- Phương pháp chọn lọc ngược. Chúng ta bắt đầu với tất cả các biến trong mô hình và loại bỏ biến có giá trị p lớn nhất – tức là biến đó là giá trị có ý nghĩa thống kê thấp nhất. Biến ($p - 1$) mới Mô hình được điều chỉnh và biến có giá trị p lớn nhất sẽ bị loại bỏ. Điều này Quy trình tiếp tục cho đến khi đạt đến một quy tắc dừng. Ví dụ, chúng ta có thể dừng lại khi tất cả các biến còn lại có giá trị p nhỏ hơn một mức nào đó. ngưỡng.

lùi lại
lựa chọn
- Lựa chọn hỗn hợp. Đây là sự kết hợp giữa lựa chọn tiến và lựa chọn lùi. Chúng ta bắt đầu với mô hình không có biến nào, và tương tự như lựa chọn tiến. Sau khi chọn, chúng ta thêm biến số mang lại sự phù hợp tốt nhất. Chúng ta tiếp tục thêm từng biến số một. Tất nhiên, như chúng ta đã lưu ý với... Ví dụ trong quảng cáo , giá trị p cho các biến có thể trở nên lớn hơn khi Các biến dự báo mới được thêm vào mô hình. Do đó, nếu tại bất kỳ thời điểm nào Giá trị p của một trong các biến trong mô hình tăng lên trên một ngưỡng nhất định. Khi đạt đến ngưỡng nhất định, chúng ta loại bỏ biến đó khỏi mô hình. Chúng ta tiếp tục thực hiện các bước tiến và lùi này cho đến khi tất cả các biến đều đạt ngưỡng. trong mô hình có giá trị p đủ thấp, và tất cả các biến bên ngoài Mô hình sẽ có giá trị p lớn nếu được thêm vào mô hình.

hỗn hợp
lựa chọn

Không thể sử dụng phương pháp chọn lọc ngược nếu $p > n$, trong khi phương pháp chọn lọc tiến thì có thể. Luôn được sử dụng. Lựa chọn tiến lên là một phương pháp tham lam và có thể bao gồm Các biến số xuất hiện sớm có thể trở nên dư thừa về sau. Lựa chọn hỗn hợp có thể khắc phục điều này. cái này.

Ba: Độ vừa vặn của mô hình

Hai trong số những thước đo định lượng phổ biến nhất về độ phù hợp của mô hình là RSE và R², tức là tỷ lệ phương sai được giải thích. Các đại lượng này được tính toán và diễn giải theo cùng một cách như đối với hồi quy tuyến tính đơn giản.

Hãy nhớ rằng trong hồi quy đơn giản, R² là bình phương hệ số tương quan giữa biến phản hồi và biến ngẫu nhiên. Trong hồi quy tuyến tính đa biến, R² bằng $\text{Cor}(Y, \hat{Y})^2$, bình phương hệ số tương quan giữa biến phản hồi và mô hình tuyến tính được hiệu chỉnh; trên thực tế, một đặc tính của mô hình tuyến tính được hiệu chỉnh là nó tối đa hóa hệ số tương quan này trong số tất cả các mô hình tuyến tính có thể có.


Giá trị R² gần bằng 1 cho thấy mô hình giải thích được một phần lớn phương sai của biến phản hồi. Ví dụ, như trong Bảng 3.6, đối với dữ liệu Quảng cáo, mô hình sử dụng cả ba phương tiện quảng cáo để dự đoán doanh số có giá trị R² là 0,8972. Mặt khác, mô hình chỉ sử dụng TV và radio để dự đoán doanh số có giá trị R² là 0,89719. Nói cách khác, R² tăng nhẹ nếu chúng ta đưa quảng cáo báo chí vào mô hình đã bao gồm quảng cáo TV và radio, mặc dù trước đó chúng ta đã thấy rằng giá trị p cho quảng cáo báo chí trong Bảng 3.4 không có ý nghĩa thống kê. Hóa ra R² luôn tăng khi thêm nhiều biến vào mô hình, ngay cả khi các biến đó chỉ liên quan yếu đến biến phản hồi. Điều này là do việc thêm một biến khác luôn dẫn đến sự giảm tổng bình phương phần dư trên dữ liệu huấn luyện (mặc dù không nhất thiết là trên dữ liệu kiểm tra). Do đó, chỉ số R², cũng được tính toán trên dữ liệu huấn luyện, phải tăng lên. Việc thêm quảng cáo báo chí vào mô hình chỉ chứa quảng cáo truyền hình và radio chỉ dẫn đến sự tăng nhẹ trong R², cung cấp thêm bằng chứng cho thấy có thể loại bỏ báo chí khỏi mô hình. Về cơ bản, báo chí không mang lại sự cải thiện thực sự nào về độ phù hợp của mô hình với các mẫu huấn luyện, và việc đưa nó vào có thể dẫn đến kết quả kém trên các mẫu kiểm tra độc lập do hiện tượng quá khớp (overfitting).

Ngược lại, mô hình chỉ chứa TV làm biến dự báo có R² là 0,61 (Bảng 3.2). Việc thêm radio vào mô hình dẫn đến sự cải thiện đáng kể về R². Điều này ngụ ý rằng một mô hình sử dụng chỉ tiêu cho quảng cáo trên TV và radio để dự đoán doanh số bán hàng tốt hơn đáng kể so với mô hình chỉ sử dụng quảng cáo trên TV. Chúng ta có thể định lượng thêm sự cải thiện này bằng cách xem xét giá trị p của hệ số radio trong mô hình chỉ chứa TV và radio làm biến dự báo.

Mô hình chỉ sử dụng chỉ tiêu cho truyền hình và radio làm biến dự báo có hệ số RSE là 1,681, và mô hình sử dụng thêm chỉ tiêu cho báo chí làm biến dự báo có hệ số RSE là 1,686 (Bảng 3.6). Ngược lại, mô hình chỉ sử dụng chỉ tiêu cho truyền hình có hệ số RSE là 3,26 (Bảng 3.2). Điều này củng cố kết luận trước đó của chúng tôi rằng mô hình sử dụng chỉ tiêu cho truyền hình và radio để dự đoán doanh số bán hàng chính xác hơn nhiều (trên dữ liệu huấn luyện) so với mô hình chỉ sử dụng chỉ tiêu cho truyền hình. Hơn nữa, vì chỉ tiêu cho truyền hình và radio được sử dụng làm biến dự báo, nên việc sử dụng chỉ tiêu cho báo chí làm biến dự báo trong mô hình là không cần thiết. Người đọc tinh ý có thể thắc mắc làm thế nào RSE có thể tăng lên khi thêm chỉ tiêu cho báo chí vào mô hình trong khi RSS phải giảm. Nói chung, RSE được định nghĩa là

$$RSE = \frac{1}{n - p - 1} RSS,$$

(3.25)



HÌNH 3.5. Đối với dữ liệu **Quảng cáo**, một mô hình hồi quy tuyến tính được áp dụng cho **doanh số bán hàng** sử dụng **truyền hình** và **radio** làm biến dự báo. Từ mô hình phần dư, chúng ta có thể thấy rằng có một mối quan hệ phi tuyến tính rõ rệt trong dữ liệu. Các phần dư dương (những phần dư hiển thị trên bề mặt) có xu hướng nằm dọc theo đường 45 độ, nơi ngân sách truyền hình và radio được phân bổ đều. Các phần dư âm (hầu hết không hiển thị) có xu hướng nằm ngoài đường này, nơi ngân sách phân bổ không đồng đều hơn.

Điều này đơn giản hóa thành (3.15) đối với hồi quy tuyến tính đơn giản. Do đó, các mô hình có nhiều biến hơn có thể có RSE cao hơn nếu sự giảm RSS nhỏ so với sự tăng p .

Ngoài việc xem xét các chỉ số RSE và R^2 vừa được thảo luận, việc vẽ biểu đồ dữ liệu cũng rất hữu ích. Tóm tắt bằng đồ thị có thể tiết lộ các vấn đề của mô hình mà không thể nhìn thấy từ các số liệu thống kê. Ví dụ, Hình 3.5 hiển thị biểu đồ ba chiều về lượng **người xem truyền hình** và **radio** so với **doanh số bán hàng**. Chúng ta thấy rằng một số quan sát nằm phía trên và một số quan sát nằm phía dưới mặt phẳng hồi quy bình phương nhỏ nhất. Cụ thể, mô hình tuyến tính dường như đánh giá quá cao **doanh số bán hàng** trong trường hợp phần lớn ngân sách quảng cáo được chỉ riêng cho **truyền hình** hoặc **radio**. Nó lại đánh giá thấp **doanh số bán hàng** trong trường hợp ngân sách được chia đều cho cả hai phương tiện truyền thông. Mô hình phi tuyến tính rõ rệt này cho thấy hiệu ứng cộng hưởng hoặc tương tác giữa các phương tiện quảng cáo, theo đó việc kết hợp các phương tiện truyền thông với nhau sẽ mang lại hiệu quả thúc đẩy doanh số bán hàng lớn hơn so với việc sử dụng bất kỳ phương tiện nào riêng lẻ. Trong Phần 3.3.2, chúng ta sẽ thảo luận về việc mở rộng mô hình tuyến tính để phù hợp với các hiệu ứng cộng hưởng như vậy thông qua việc sử dụng các thuật ngữ tương tác.

sự tương tác

Bốn: Dự đoán

Sau khi đã phù hợp với mô hình hồi quy bội, việc áp dụng (3.21) để dự đoán phản hồi Y dựa trên một tập hợp các giá trị cho các biến dự báo $X_1, X_2, \dots, X_p$ là rất đơn giản. Tuy nhiên, có ba loại sự không chắc chắn liên quan đến dự đoán này.

1. Các ước lượng hệ số $\beta^0, \beta^1, \dots, \beta^p$ là các ước lượng cho $\beta_0, \beta_1, \dots, \beta_p$.
Tức là, mặt phẳng bình phương tối thiểu

$$\hat{Y} = \beta^0 + \beta^1 X_1 + \dots + \beta^p X_p$$

chỉ là ước tính cho mặt phẳng hồi quy dân số thực sự

$$f(X)=\beta_0+\beta_1X_1+\cdots+\beta_pX_p.$$

Sự không chính xác trong ước lượng hệ số có liên quan đến sai số có thể giảm thiểu từ Chương 2. Chúng ta có thể tính khoảng tin cậy để xác định $\hat{Y}$ sẽ gần với $f(X)$ đến mức nào.

2. Tất nhiên, trên thực tế, việc giả định một mô hình tuyến tính cho $f(X)$ hầu như luôn là một phép xấp xỉ của thực tế, vì vậy có một nguồn lỗi tiềm ẩn có thể giảm thiểu được mà chúng ta gọi là sai lệch mô hình. Vì vậy, khi chúng ta sử dụng một mô hình tuyến tính, trên thực tế chúng ta đang ước tính phép xấp xỉ tuyến tính tốt nhất cho bề mặt thực. Tuy nhiên, ở đây chúng ta sẽ bỏ qua sự khác biệt này và hoạt động như thể mô hình tuyến tính là chính xác.

3. Ngay cả khi chúng ta biết $f(X)$ —tức là, ngay cả khi chúng ta biết các giá trị thực của $\beta_0, \beta_1, \dots, \beta_p$ —giá trị phản hồi vẫn không thể được dự đoán một cách hoàn hảo do sai số ngẫu nhiên trong mô hình (3.20). Trong Chương 2, chúng ta đã gọi đây là sai số không thể giảm thiểu. Y sẽ khác $\hat{Y}$ bao nhiêu? Chúng ta sử dụng khoảng dự đoán để trả lời câu hỏi này. Khoảng dự đoán luôn rộng hơn khoảng tin cậy, bởi vì chúng bao gồm cả sai số trong ước tính cho $f(X)$ (sai số có thể giảm thiểu) và sự không chắc chắn về mức độ khác biệt của một điểm riêng lẻ so với mặt phẳng hồi quy của quần thể (sai số không thể giảm thiểu).

Chúng tôi sử dụng khoảng tin cậy để định lượng sự không chắc chắn xung quanh **doanh số bán hàng** trung bình trên một số lượng lớn các thành phố. Ví dụ, giả sử mỗi thành phố chi 100.000 đô la cho quảng cáo **truyền hình** và 20.000 đô la cho quảng cáo **radio** , thì khoảng tin cậy 95% là [10.985, 11.528]. Chúng tôi hiểu điều này có nghĩa là 95% các khoảng có dạng này sẽ chứa giá trị thực của $f(X)$.

khoảng tin
cậy

⁹ Mặt khác, khoảng dự đoán có thể được sử dụng để định lượng sự không chắc chắn xung quanh **doanh số bán hàng** của một thành phố cụ thể . Giả sử 100.000 đô la được chi cho quảng cáo **truyền hình** và 20.000 đô la được chi cho quảng cáo **radio** tại thành phố đó, thì khoảng dự đoán 95% là [7.930, 14.580]. Chúng ta hiểu điều này có nghĩa là 95% các khoảng có dạng này sẽ chứa giá trị thực của Y cho thành phố này. Lưu ý rằng cả hai khoảng đều tập trung ở mức 11.256, nhưng khoảng dự đoán rộng hơn đáng kể so với khoảng tin cậy, phản ánh sự không chắc chắn gia tăng về **doanh số bán hàng** của một thành phố nhất định so với doanh số **bán hàng** trung bình trên nhiều địa điểm.

khoảng dự
đoán

Nói cách khác, nếu chúng ta thu thập một số lượng lớn các tập dữ liệu như tập dữ liệu **Quảng cáo** , và chúng ta xây dựng khoảng tin cậy cho **doanh số bán hàng** trung bình dựa trên mỗi tập dữ liệu (giả sử 100.000 đô la cho quảng cáo **truyền hình** và 20.000 đô la cho quảng cáo **radio**), thì 95% các khoảng tin cậy này sẽ chứa giá trị thực của **doanh số bán hàng trung bình**.

3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy

3.3.1 Các yếu tố dự báo định tính

Trong cuộc thảo luận cho đến nay, chúng ta đã giả định rằng tất cả các biến trong hệ quy chiếu tuyến tính của chúng ta đều đúng. Mô hình hồi quy là định lượng. Nhưng trên thực tế, điều này không nhất thiết đúng. Trong trường hợp này, thường thì một số yếu tố dự báo mang tính định tính.

Ví dụ, tập dữ liệu **Tín dụng** được hiển thị trong Hình 3.6 ghi lại các biến số. Đối với một số lượng lớn chủ thẻ tín dụng. Câu trả lời là **số dư** (tín dụng trung bình) . (nợ thẻ tín dụng của mỗi cá nhân) và có một số yếu tố dự báo định lượng: **tuổi**, **thẻ** (số lượng thẻ tín dụng), **trình độ học vấn** (số năm học), **thu nhập** (đơn vị nghìn đô la), **hạn mức** (hạn mức tín dụng) và **xếp hạng** (xếp hạng tín dụng). Mỗi ô trong Hình 3.6 là một biểu đồ phân tán cho một cặp biến có định danh được xác định bởi nhãn hàng và cột tương ứng. Ví dụ: Biểu đồ phân tán ngay bên phải từ "Balance" thể hiện **sự cân bằng**. so với **tuổi tác**, trong khi biểu đồ ngay bên phải mục "Tuổi tác" tương ứng với **Tuổi tác** so với **số thẻ**. Bên cạnh các biến định lượng này, chúng ta cũng có bốn biến định tính: **sở hữu** (quyền sở hữu nhà), **sinh viên** (tình trạng sinh viên), **tình trạng** hôn nhân và **khu vực** (Đông, Tây hoặc Nam).

Các yếu tố dự báo chỉ có hai cấp độ

Giả sử chúng ta muốn điều tra sự khác biệt về số dư thẻ tín dụng giữa những người sở hữu nhà và những người không sở hữu nhà, tạm thời bỏ qua các biến số khác. Nếu một biến dự báo định tính (còn được gọi là yếu tố) chỉ có hai mức độ, hay hai giá trị có thể có, thì việc kết hợp nó vào mô hình hồi quy rất đơn giản. Chúng ta chỉ cần tạo một biến chỉ báo hoặc biến giả có hai giá trị số có thể có.

nhân tố
mức độ
giả
biến

Với biến **riêng của mình** , chúng ta có thể tạo một biến mới có dạng

xi = 1 nếu người thứ i sở hữu một ngôi nhà
0 nếu người thứ i không sở hữu nhà. (3.26)


và sử dụng biến này làm biến dự báo trong phương trình hồi quy. Kết quả là trong mô hình

yi = β0 + β1xi + i = β0 + β1 + nếu người thứ i sở hữu một ngôi nhà
i β0 + i nếu người thứ i không làm thế. (3.27)

Giờ đây, β0 có thể được hiểu là số dư thẻ tín dụng trung bình trong số những người đó. những người không sở hữu, β0 + β1 là số dư thẻ tín dụng trung bình trong số những người đó những người sở hữu nhà riêng, và β1 là sự khác biệt trung bình về thẻ tín dụng Sự cân bằng giữa chủ sở hữu và người không sở hữu.

Bảng 3.7 hiển thị các ước tính hệ số và thông tin khác liên quan đến mô hình (3.27). Mức nợ thẻ tín dụng trung bình đối với những người không sở hữu Ước tính tổng tài sản là 509,80 đô la, trong khi chủ sở hữu ước tính đang gánh khoản nợ 19,73 đô la. thêm khoản nợ với tổng số tiền là \$509.80 + \$19.73 = \$529.53. Tuy nhiên, chúng tôi

10Trong cộng đồng học máy, việc tạo ra các biến giả để xử lý Các yếu tố dự báo định tính được gọi là "mã hóa một điểm nóng".



HÌNH 3.6. Bộ dữ liệu Tín dụng chứa thông tin về số dư, tuổi,

Thông tin về thẻ tín dụng, trình độ học vấn, thu nhập, hạn mức và xếp hạng của một số khách hàng tiềm năng.

Hãy lưu ý rằng giá trị p cho biến giả rất cao. Điều này cho thấy

Không có bằng chứng thống kê nào cho thấy sự khác biệt về điểm tín dụng trung bình của thẻ tín dụng.

Số dư dựa trên quyền sở hữu nhà.

Quyết định mã hóa chủ sở hữu là 1 và người không sở hữu là 0 trong (3.27)

là tùy ý và không ảnh hưởng đến sự phù hợp của hồi quy, nhưng làm thay đổi cách giải thích các hệ số. Nếu chúng ta mã hóa người không sở hữu là 1 và chủ sở hữu là 0, thì ước tính cho β_0 và β_1 sẽ là 529,53 và -19,73, tương ứng, một lần nữa dẫn đến dự đoán về nợ thẻ tín dụng.

$\$529.53 - \$19.73 = \$509.80$ đối với người không sở hữu và dự đoán là $\$529.53$

dành cho chủ sở hữu. Ngoài ra, thay vì sơ đồ mã hóa 0/1, chúng ta có thể tạo ra một biến giả

$$x_i = \begin{cases} 1 & \text{nếu người thứ } i \text{ sở hữu một ngôi nhà} \\ -1 & \text{nếu người thứ } i \text{ không sở hữu nhà} \end{cases}$$

và sử dụng biến này trong phương trình hồi quy. Điều này dẫn đến mô hình.

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i = \begin{cases} \beta_0 + \beta_1 + \epsilon_i & \text{nếu người thứ } i \text{ sở hữu một ngôi nhà} \\ \beta_0 - \beta_1 + \epsilon_i & \text{nếu người thứ } i \text{ không sở hữu nhà.} \end{cases}$$

3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy 93

	Hệ số Sai số chuẩn Thống kê t	509,80 33,13 19,73	giá trị p
Chặn chính	46,05	15,389 < 0,0001	
minh[Có]		0,429 0,6690	

BẢNG 3.7. Ước lượng hệ số bình phương nhỏ nhất liên quan đến hồi quy số dư trên cơ sở riêng trong tập dữ liệu Tín dụng . Mô hình tuyến tính được đưa ra trong (3.27). Tức là, quyền sở hữu được mã hóa dưới dạng biến giả, như trong (3.26).

Giờ đây, β_0 có thể được hiểu là số dư thẻ tín dụng trung bình tổng thể (bỏ qua ảnh hưởng của việc sở hữu nhà), và β_1 là số tiền mà nhà ở. Những người sở hữu và không sở hữu tài sản có số dư thẻ tín dụng cao hơn và thấp hơn mức quy định. trung bình, tương ứng.11 Trong ví dụ này, ước tính cho β_0 là 519,665 đô la, nằm giữa mức trung bình của người không sở hữu nhà và người sở hữu nhà, lần lượt là 509,80 đô la và 529,53 đô la. Ước tính cho β_1 là 9,865 đô la, bằng một nửa của 19,73 đô la, là mức chênh lệch trung bình giữa chủ sở hữu và người không sở hữu. Điều quan trọng cần lưu ý là các dự đoán cuối cùng về số dư tín dụng của chủ sở hữu và người không sở hữu sẽ giống nhau. bất kể lược đồ mã hóa nào được sử dụng. Sự khác biệt duy nhất nằm ở cách thức mà Các hệ số được giải thích.

Các yếu tố dự báo định tính có nhiều hơn hai cấp độ

Khi một biến dự báo định tính có nhiều hơn hai cấp độ, một biến giả duy nhất sẽ được sử dụng. Biến không thể biểu diễn tất cả các giá trị có thể có. Trong trường hợp này, chúng ta có thể tạo ra các biến giả bổ sung. Ví dụ, đối với biến khu vực , chúng ta tạo ra hai biến giả. Biến giả đầu tiên có thể là

$$x_{i1} = \begin{cases} 1 & \text{nếu người thứ } i \text{ đến từ miền Nam} \\ 0 & \text{nếu người đó không đến từ miền Nam,} \end{cases} \tag{3.28}$$

và cái thứ hai có thể là

$$x_{i2} = \begin{cases} 1 & \text{nếu người thứ } i \text{ đến từ phương Tây} \\ 0 & \text{nếu người đó không đến từ phương Tây.} \end{cases} \tag{3.29}$$

Sau đó, cả hai biến này đều có thể được sử dụng trong phương trình hồi quy, trong để có được mô hình

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \begin{cases} \beta_0 + \beta_1 + \epsilon_i & \text{nếu người thứ } i \text{ đến từ miền Nam} \\ \beta_0 + \beta_2 + \epsilon_i & \text{nếu người thứ } i \text{ đến từ phương Tây} \\ \beta_0 + \epsilon_i & \text{nếu người thứ } i \text{ đến từ phương Đông.} \end{cases} \tag{3.30}$$

Lúc này, β_0 có thể được hiểu là số dư thẻ tín dụng trung bình của từng cá nhân. Từ phía Đông, β_1 có thể được hiểu là sự khác biệt về số dư trung bình giữa người miền Nam và miền Đông, và β_2 có thể được giải thích như sau: sự khác biệt về số dư trung bình giữa những người đến từ phương Tây so với Phía Đông. Sẽ luôn có ít hơn một biến giả so với số lượng của các cấp độ. Cấp độ không có biến giả–phía Đông trong ví dụ này–là được gọi là đường cơ sở.

cơ sở

11Về mặt kỹ thuật, β_0 bằng một nửa tổng nợ trung bình của chủ nhà và mức trung bình nợ đối với những người không sở hữu nhà. Do đó, β_0 chỉ chính xác bằng mức trung bình chung nếu Hai nhóm có số lượng thành viên bằng nhau.

	Hệ số Sai số chuẩn	Thống kê t	531,00	46,32	giá trị p
Khu vực chặn	12,50	56,68	18,69	65,02	11,464 < 0,0001
[Nam] khu vực					0,221 0,8260
[Tây]					0,287 0,7740

BẢNG 3.8. Ước tính hệ số bình phương nhỏ nhất liên quan đến hồi quy của cân bằng trên khu vực trong tập dữ liệu *Tín dụng* . Mô hình tuyến tính được đưa ra trong (3.30). Tức là, khu vực được mã hóa thông qua hai biến giả (3.28) và (3.29) .

Từ Bảng 3.8, chúng ta thấy rằng số dư ước tính cho đường cơ sở, phía Đông, Mức lương là 531,00 đô la. Ước tính những người ở miền Nam sẽ mất đi 18,69 đô la. nợ nần nhiều hơn so với những người ở phía Đông, và những người ở phía Tây sẽ có 12,50 đô la. ít nợ hơn so với các nước ở phía Đông. Tuy nhiên, giá trị p liên quan đến Các ước tính hệ số cho hai biến giả rất lớn, cho thấy Không có bằng chứng thống kê nào cho thấy sự khác biệt thực sự về số dư thẻ tín dụng trung bình giữa Nam và Đông hoặc giữa Tây và Đông.12 Một lần nữa, Mức độ được chọn làm hạng mục cơ sở là tùy ý, và các dự đoán cuối cùng Kết quả cho mỗi nhóm sẽ giống nhau bất kể lựa chọn này. Tuy nhiên, Các hệ số và giá trị p của chúng phụ thuộc vào việc lựa chọn biến giả. mã hóa. Thay vì dựa vào các hệ số riêng lẻ, chúng ta có thể sử dụng kiểm định F. Để kiểm tra $H_0 : \beta_1 = \beta_2 = 0$; điều này không phụ thuộc vào cách mã hóa. Kiểm định F này có giá trị p là 0,96, cho thấy chúng ta không thể bác bỏ giả thuyết null. Điều đó cho thấy không có mối liên hệ nào giữa sự cân bằng và khu vực.

Việc sử dụng phương pháp biến giả này không gặp khó khăn gì khi kết hợp cả các biến dự báo định lượng và định tính. Ví dụ, để Đề hồi quy sự cân bằng dựa trên cả biến định lượng như thu nhập và biến định tính như số sinh viên, chúng ta chỉ cần tạo một biến giả. cho sinh viên và sau đó áp dụng mô hình hồi quy đa biến sử dụng thu nhập và... Biến giả được sử dụng làm biến dự báo cho số dư thẻ tín dụng.

Ngoài ra còn có nhiều cách khác nhau để mã hóa các biến định tính. Phương pháp biến giả được sử dụng ở đây. Tất cả các phương pháp này đều dẫn đến Mô hình phù hợp tương đương, nhưng các hệ số khác nhau và có ý nghĩa khác nhau. Các cách diễn giải này được thiết kế để đo lường những sự tương phản cụ thể. Chủ đề này nằm ngoài phạm vi của cuốn sách.

sự tương phản

3.3.2 Mở rộng mô hình tuyến tính

Mô hình hồi quy tuyến tính tiêu chuẩn (3.19) cung cấp kết quả có thể giải thích được và hoạt động khá tốt trên nhiều vấn đề thực tế. Tuy nhiên, nó đưa ra một số giả định rất hạn chế mà thường bị vi phạm trong thực tế. Hai Một trong những giả định quan trọng nhất nêu rõ mối quan hệ giữa Các biến dự báo và biến phản hồi có mối quan hệ cộng tính và tuyến tính. Giả định về tính cộng tính có nghĩa là mối liên hệ giữa biến dự báo X_j và biến phản hồi Y không... Không phụ thuộc vào giá trị của các biến dự báo khác. Giả định tuyến tính nêu rõ sự thay đổi trong phản hồi Y liên quan đến sự thay đổi một đơn vị. Trong X_j , hằng số là không đổi, bất kể giá trị của X_j là bao nhiêu . Trong các chương sau của cuốn sách này... Trong cuốn sách này, chúng tôi xem xét một số phương pháp phức tạp giúp giảm bớt hai hạn chế này.

chất phụ gia
tuyến tính

12Về mặt lý thuyết, vẫn có thể có sự khác biệt giữa miền Nam và miền Tây, mặc dù...
Dữ liệu ở đây không cho thấy bất kỳ sự khác biệt nào.

3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy 95

các giả định. Ở đây, chúng ta sẽ xem xét ngắn gọn một số phương pháp cổ điển phổ biến để mở rộng mô hình tuyến tính.

Loại bỏ giả định cộng tính

Trong phân tích trước đây của chúng tôi về dữ liệu **Quảng cáo**, chúng tôi đã kết luận rằng cả **TV** và **radio** dường như đều có liên quan đến **doanh số bán hàng**. Các mô hình tuyến tính làm cơ sở cho kết luận này giả định rằng tác động lên **doanh số bán hàng** của việc tăng một phương tiện quảng cáo là độc lập với số tiền chi cho phương tiện khác. Ví dụ, mô hình tuyến tính (3.20) cho biết mức tăng trung bình về **doanh số bán hàng** liên quan đến việc tăng một đơn vị quảng cáo trên **TV** luôn là β_1 , bất kể số tiền chi cho **radio** là bao nhiêu.

Tuy nhiên, mô hình đơn giản này có thể không chính xác. Giả sử rằng việc chi tiền cho quảng cáo trên đài phát thanh thực sự làm tăng hiệu quả của quảng cáo trên truyền hình, do đó hệ số góc đối với quảng cáo trên **truyền hình** sẽ tăng khi quảng cáo trên **đài phát thanh** tăng. Trong trường hợp này, với ngân sách cố định là 100.000 đô la, việc chi một nửa cho **radio** và một nửa cho **TV** có thể làm tăng **doanh số bán hàng** nhiều hơn so với việc phân bổ toàn bộ số tiền cho **TV** hoặc **radio**. Trong marketing, điều này được gọi là hiệu ứng hiệp đồng, và trong thống kê, nó được gọi là hiệu ứng tương tác. Hình 3.5 cho thấy hiệu ứng như vậy có thể xuất hiện trong dữ liệu quảng cáo. Lưu ý rằng khi mức độ quảng cáo trên **TV** hoặc **radio** thấp, thì **doanh số bán hàng** thực tế thấp hơn so với dự đoán của mô hình tuyến tính. Nhưng khi quảng cáo được chia đều giữa hai phương tiện truyền thông, thì mô hình có xu hướng đánh giá thấp **doanh số bán hàng**.

Hãy xem xét mô hình hồi quy tuyến tính chuẩn với hai biến số,

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$$

Theo mô hình này, sự tăng một đơn vị của X_1 tương ứng với sự tăng trung bình của Y là β_1 đơn vị. Lưu ý rằng sự hiện diện của X_2 không làm thay đổi phát biểu này—nghĩa là, bất kể giá trị của X_2 là bao nhiêu, sự tăng một đơn vị của X_1 tương ứng với sự tăng β_1 đơn vị của Y . Một cách để mở rộng mô hình này là bao gồm một biến dự báo thứ ba, được gọi là thuật ngữ tương tác, được xây dựng bằng cách tính tích của X_1 và X_2 . Điều này dẫn đến mô hình

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \epsilon \quad (3.31)$$

Việc đưa thêm thuật ngữ tương tác này vào sẽ làm giảm bớt giả định về tính cộng như thế nào? Lưu ý rằng (3.31) có thể được viết lại như sau:

$$Y = \beta_0 + (\beta_1 + \beta_3 X_2) X_1 + \beta_2 X_2 + \epsilon = \beta_0 + \beta_1^* X_1 + \beta_2 X_2 + \epsilon \quad (3.32)$$

trong đó $\beta_1^* = \beta_1 + \beta_3 X_2$. Vì β_1^* giờ là một hàm của X_2 , nên mối liên hệ giữa X_1 và Y không còn là hằng số nữa: sự thay đổi giá trị của X_2 sẽ làm thay đổi mối liên hệ giữa X_1 và Y . Một lập luận tương tự cho thấy rằng sự thay đổi giá trị của X_1 sẽ làm thay đổi mối liên hệ giữa X_2 và Y .

Ví dụ, giả sử chúng ta quan tâm đến việc nghiên cứu năng suất của một nhà máy. Chúng ta muốn dự đoán số lượng **sản phẩm** được sản xuất dựa trên số lượng **dây chuyền** sản xuất và tổng số **công nhân**.

Có vẻ như việc tăng số lượng dây chuyền sản xuất sẽ có tác động nhất định.