

	Hệ số Sai số chuẩn Thống kê t 6.7502 0.248	giá trị p
Chặn	0.0191 0.002 0.0289 0.009	27,23 < 0,0001
TV	0.0011 0.000	12,70 < 0,0001
radio		3,24 0,0014
TV×radio		20,73 < 0,0001

BẢNG 3.9. Đối với dữ liệu **Quảng cáo** , ước tính hệ số bình phương nhỏ nhất liên quan đến hồi quy doanh số **bán hàng** theo **TV** và **radio**, có thêm thuật ngữ tương tác. như trong (3.33).

sẽ phụ thuộc vào số lượng công nhân, vì nếu không có công nhân nào sẵn sàng thì sẽ không có mặt. để vận hành các dây chuyền, thì việc tăng số lượng dây chuyền sẽ không làm tăng số lượng dây chuyền hoạt động. sản xuất. Điều này cho thấy rằng việc đưa thêm một thuật ngữ tương tác giữa **các dây chuyền** và **công nhân** vào mô hình tuyến tính để dự đoán **số lượng sản phẩm là phù hợp**. Giả sử khi ta điều chỉnh mô hình, ta thu được

$$\text{đơn vị} \approx 1,2 + 3,4 \times \text{dây chuyền} + 0,22 \times \text{công nhân} + 1,4 \times (\text{dây chuyền} \times \text{công nhân})$$
$$= 1,2 + (3,4 + 1,4 \times \text{công nhân}) \times \text{dây chuyền} + 0,22 \times \text{công nhân}.$$

Nói cách khác, thêm một dòng nữa sẽ làm tăng số lượng đơn vị. được sản xuất bởi 3,4 + 1,4 **công nhân**. Do đó, càng nhiều **công nhân** thì sản lượng càng cao. Hiệu quả của **các đường kẻ** sẽ **càng mạnh mẽ hơn**.

Bây giờ chúng ta quay lại ví dụ về **Quảng cáo** . Một mô hình tuyến tính sử dụng **Việc sử dụng radio, TV** và sự tương tác giữa hai phương tiện này để dự đoán **doanh số bán hàng** đòi hỏi... hình thức

$$\text{doanh số} = \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times (\text{radio} \times \text{TV}) + = \beta_0 + (\beta_1 + \beta_3 \times \text{radio}) \times \text{TV} + \beta_2 \times \text{radio} + . \tag{3.33}$$

Chúng ta có thể hiểu β_3 là sự gia tăng hiệu quả của quảng cáo truyền hình. liên quan đến việc tăng một đơn vị quảng cáo trên đài phát thanh (hoặc ngược lại). các hệ số thu được từ việc điều chỉnh mô hình (3.33) được đưa ra trong Bảng 3.9. Kết quả trong Bảng 3.9 cho thấy rõ ràng rằng mô hình bao gồm Thuật ngữ tương tác vượt trội hơn so với mô hình chỉ chứa các hiệu ứng chính. hiệu ứng chính Giá trị p cho thuật ngữ tương tác **TV×radio** là cực kỳ thấp, điều này cho thấy Có bằng chứng mạnh mẽ cho $H_0 : \beta_3 = 0$. Nói cách khác, rõ ràng là Mọi quan hệ thực sự không phải là mối quan hệ cộng. Hệ số R^2 của mô hình (3,33) là 96,8%. so với chỉ 89,7% đối với mô hình dự đoán **doanh số bán hàng** dựa trên **truyền hình** và **radio** không có số hạng tương tác. Điều này có nghĩa là $(96,8 - 89,7)/(100 - 89,7) = 69\%$ sự biến thiên trong **doanh số** còn lại sau khi áp dụng mô hình cộng tính đã được giải thích bởi thuật ngữ tương tác. Hệ số

Các ước tính trong Bảng 3.9 cho thấy rằng việc tăng chi phí quảng cáo truyền hình thêm 1.000 đô la là liên quan đến việc tăng doanh số bán hàng của $(\beta^1 + \beta^3 \times \text{radio}) \times 1,000 = 19 + 1.1 \times \text{radio}$ đơn vị. Và việc tăng chi phí quảng cáo trên đài phát thanh thêm 1.000 đô la sẽ liên quan đến doanh số bán hàng tăng thêm $(\beta^2 + \beta^3 \times \text{TV}) \times 1.000 = 29 + 1,1 \times \text{đơn vị TV}$.

Trong ví dụ này, các giá trị p liên quan đến **TV, radio** và thuật ngữ tương tác đều có ý nghĩa thống kê (Bảng 3.9), do đó rõ ràng là... rằng cả ba biến số đều nên được đưa vào mô hình. Tuy nhiên, Đôi khi có trường hợp hệ số tương tác có giá trị p rất nhỏ, nhưng Các hiệu ứng chính liên quan (trong trường hợp này là **truyền hình** và **radio**) thì không. Nguyên tắc phân cấp nêu rõ rằng nếu chúng ta đưa một tương tác vào mô hình, thì chúng ta

phân cấp
nguyên tắc

3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy 97

Cần phải bao gồm cả các hiệu ứng chính, ngay cả khi giá trị p liên quan đến hệ số của chúng không có ý nghĩa thống kê. Nói cách khác, nếu tương tác giữa X1 và X2 có vẻ quan trọng, thì chúng ta nên đưa cả X1 và X2 vào mô hình ngay cả khi ước tính hệ số của chúng có giá trị p lớn. Lý do cho nguyên tắc này là nếu X1 × X2 có liên quan đến biến phản hồi, thì việc hệ số của X1 hoặc X2 có chính xác bằng 0 hay không không mấy quan trọng. Ngoài ra, X1 × X2 thường tương quan với X1 và X2, vì vậy việc bỏ chúng ra có xu hướng làm thay đổi ý nghĩa của tương tác.

Trong ví dụ trước, chúng ta đã xem xét sự tương tác giữa TV và radio, cả hai đều là biến định lượng. Tuy nhiên, khái niệm tương tác cũng áp dụng tốt cho các biến định tính, hoặc cho sự kết hợp của các biến định lượng và định tính. Trên thực tế, sự tương tác giữa một biến định tính và một biến định lượng có một cách diễn giải đặc biệt hay. Hãy xem xét tập dữ liệu **Tín dụng** từ Phần 3.3.1, và giả sử chúng ta muốn dự đoán **số dư** bằng cách sử dụng các biến **thu nhập** (định lượng) và **sinh viên** (định tính). Trong trường hợp không có thuật ngữ tương tác, mô hình có dạng

$$\begin{aligned} \text{số dư} &\approx \beta_0 + \beta_1 \times \text{thu nhập}_i + \\ &= \beta_1 \times \text{thu nhập}_i + \end{aligned}$$

$$\beta_2$$

$$0$$

$$\beta_0 + \beta_2$$

$$\beta_0$$

Nếu người thứ i là sinh viên,

nếu người thứ i không phải là sinh viên.

Nếu người thứ i là sinh viên,

nếu người thứ i không phải là sinh viên.

(3.34)

Lưu ý rằng điều này tương đương với việc khớp hai đường thẳng song song với dữ liệu, một cho sinh viên và một cho người không phải sinh viên. Các đường thẳng dành cho sinh viên và người không phải sinh viên có các điểm cắt trục tung khác nhau, $\beta_0 + \beta_2$ so với β_0 , nhưng có cùng độ dốc, β_1 . Điều này được minh họa trong bảng bên trái của Hình 3.7. Việc các đường thẳng song song có nghĩa là tác động trung bình lên **cán cân** của việc tăng **thu nhập** một đơn vị không phụ thuộc vào việc cá nhân đó có phải là sinh viên hay không. Điều này cho thấy một hạn chế tiềm tàng nghiêm trọng của mô hình, vì trên thực tế, sự thay đổi về **thu nhập** có thể có tác động rất khác nhau đến số dư thẻ tín dụng của sinh viên so với người không phải sinh viên. Hạn chế này có thể được khắc phục bằng cách thêm một biến tương tác, được tạo ra bằng cách nhân **thu nhập** với biến giả đại diện cho **sinh viên**. Mô hình của chúng ta lúc này trở thành

$$\text{số dư} \approx \beta_0 + \beta_1 \times \text{thu nhập}_i +$$

$$\beta_2 + \beta_3 \times \text{thu nhập}_i$$


nếu là sinh viên
0 nếu không phải là sinh viên

$$= (\beta_0 + \beta_2) + (\beta_1 + \beta_3) \times \text{thu nhập}_i$$

nếu sinh viên
$$\beta_0 + \beta_1$$
 nếu không phải là sinh viên.

(3.35)

Một lần nữa, chúng ta có hai đường hồi quy khác nhau cho sinh viên và người không phải sinh viên. Nhưng giờ đây, các đường hồi quy đó có hệ số chặn khác nhau, $\beta_0 + \beta_2$ so với β_0 , cũng như hệ số góc khác nhau, $\beta_1 + \beta_3$ so với β_1 . Điều này cho phép khả năng thay đổi thu nhập có thể ảnh hưởng đến số dư thẻ tín dụng của sinh viên và người không phải sinh viên theo những cách khác nhau. Bảng bên phải của Hình 3.7



HÌNH 3.7. Đối với dữ liệu **Tín dụng**, các đường hồi quy bình phương nhỏ nhất được hiển thị để dự đoán **số dư** từ **thu nhập** cho sinh viên và người không phải sinh viên. Bên trái: Mô hình (3.34) đã phù hợp. Không có sự tương tác giữa **thu nhập** và **sinh viên**. Bên phải: Cái mô hình (3.35) đã được điều chỉnh. Có một thuật ngữ tương tác giữa **thu nhập** và **sinh viên**.

Thể hiện mối quan hệ ước tính giữa **thu nhập** và **số dư tài khoản** của sinh viên. và những người không phải sinh viên trong mô hình (3.35). Chúng tôi lưu ý rằng độ dốc dành cho sinh viên Độ dốc này thấp hơn so với độ dốc của nhóm không phải sinh viên. Điều này cho thấy sự gia tăng trong thu nhập có liên quan đến mức tăng nhỏ hơn trong số dư thẻ tín dụng trong số những người có thu nhập cao hơn, so sánh sinh viên với người không phải sinh viên.

Mối quan hệ phi tuyến tính

Như đã thảo luận trước đó, mô hình hồi quy tuyến tính (3.19) giả định một tuyến tính mối quan hệ giữa biến phản hồi và biến dự báo. Nhưng trong một số trường hợp, Mối quan hệ thực sự giữa biến phản hồi và các biến dự báo có thể không tuyến tính. Ở đây, chúng tôi trình bày một cách rất đơn giản để mở rộng trực tiếp mô hình tuyến tính. Để xử lý các mối quan hệ phi tuyến tính, chúng tôi sử dụng hồi quy đa thức. Trong các chương sau, chúng tôi sẽ trình bày các phương pháp phức tạp hơn để thực hiện việc này. sự phù hợp phi tuyến tính trong các thiết lập tổng quát hơn.

đa thức
hồi quy


Hãy xem Hình 3.8, trong đó **mpg** (mức tiêu hao nhiên liệu tính bằng dặm trên gallon) Tỷ lệ giữa mã lực và **công suất động cơ** được thể hiện cho một số xe trong bộ dữ liệu **Auto**. Đường màu cam biểu thị đường hồi quy tuyến tính. Có mối quan hệ rõ rệt giữa **mpg** (**số dặm trên mỗi gallon**) và **mã lực**, nhưng dường như mối quan hệ này thực chất là phi tuyến tính: dữ liệu cho thấy một mối quan hệ cong. Một cách đơn giản Cách tiếp cận để kết hợp các mối liên hệ phi tuyến tính vào một mô hình tuyến tính là... bao gồm các phiên bản đã được biến đổi của các biến dự báo. Ví dụ, các điểm trong Hình 3.8 dường như có dạng bậc hai, cho thấy mô hình có dạng như vậy.

bậc hai

$$mpg = \beta_0 + \beta_1 \times \text{mã lực} + \beta_2 \times \text{mã lực}^2 +$$
 (3.36)

có thể mang lại sự phù hợp tốt hơn. Phương trình 3.36 liên quan đến việc dự đoán **mpg** bằng cách sử dụng một Hàm phi tuyến tính của **mã lực**. Nhưng nó vẫn là một mô hình tuyến tính! Nghĩa là, (3.36) chỉ đơn giản là một mô hình hồi quy tuyến tính bởi với $X_1 = \text{mã lực}$ và $X_2 = \text{mã lực}^2$. Vì vậy, chúng ta có thể sử dụng phần mềm hồi quy tuyến tính tiêu chuẩn để Ước tính β_0 , β_1 và β_2 để tạo ra sự phù hợp phi tuyến tính. Đường cong màu xanh Hình 3.8 thể hiện đường cong phù hợp bậc hai với dữ liệu. Đường cong bậc hai...

3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy 99



HÌNH 3.8. Bộ dữ liệu Ô tô . Đối với một số xe, mpg và mã lực là được hiển thị. Đường hồi quy tuyến tính được hiển thị bằng màu cam. Đường hồi quy tuyến tính phù hợp cho một Mô hình bao gồm mã lực² được hiển thị dưới dạng đường cong màu xanh lam. Hồi quy tuyến tính phù hợp với một mô hình bao gồm tất cả các đa thức của mã lực lên đến bậc năm là

Được hiển thị bằng màu xanh lá cây.

	Hệ số Sai số chuẩn Thống kê t Giá trị p
Công suất	56.9001 1.8004 31.6 < 0.0001
chặn mã lực	0,4662 0,0311 15,0 < 0,0001
mã lực ²	0,0012 0,0001 10,1 < 0,0001

BẢNG 3.10. Đối với tập dữ liệu Auto , các ước tính hệ số bình phương nhỏ nhất liên quan với sự suy giảm của mpg theo mã lực và mã lực².

Độ phù hợp có vẻ tốt hơn đáng kể so với độ phù hợp thu được khi chỉ có Hệ số tuyến tính được bao gồm. Hệ số R² của phép nội suy bậc hai là 0,688, so với... 0,606 đối với đường hồi quy tuyến tính và giá trị p trong Bảng 3.10 đối với số hạng bậc hai. Điều này vô cùng quan trọng.

Nếu việc bổ sung horsepower² dẫn đến sự cải thiện đáng kể như vậy trong mô hình, tại sao? Không bao gồm mã lực³, mã lực⁴, hay thậm chí mã lực⁵? Đường cong màu xanh lá cây Hình 3.8 hiển thị kết quả khớp dữ liệu thu được khi bao gồm tất cả các đa thức đến bậc thứ năm trong mô hình (3,36). Sự phù hợp thu được dường như không cần thiết ngoài ngoà-ngoài là, không rõ liệu việc bao gồm các điều khoản bổ sung có thực sự Điều này dẫn đến sự phù hợp tốt hơn với dữ liệu.

Phương pháp mà chúng ta vừa mô tả để mở rộng mô hình tuyến tính Phương pháp này, nhằm đáp ứng các mối quan hệ phi tuyến tính, được gọi là hồi quy đa thức, vì chúng ta đã bao gồm các hàm đa thức của các biến dự đoán trong mô hình. mô hình hồi quy. Chúng tôi tiếp tục khám phá phương pháp này và các phương pháp phi tuyến tính khác. các phần mở rộng của mô hình tuyến tính trong Chương 7.


3.3.3 Các vấn đề tiềm ẩn

Khi áp dụng mô hình hồi quy tuyến tính cho một tập dữ liệu cụ thể, nhiều vấn đề có thể phát sinh. Phổ biến nhất trong số đó là:

- 1. Tính phi tuyến tính của mối quan hệ giữa biến phản hồi và biến dự báo.
- 2. Tương quan giữa các sai số.
- 3. Sai số có phương sai không đổi.
- 4. Các giá trị ngoại lệ.
- 5. Các điểm có đòn bẩy cao.
- 6. Hiện tượng cộng tuyến.

Trên thực tế, việc xác định và khắc phục những vấn đề này cũng quan trọng không kém việc... Nghệ thuật như một môn khoa học. Vô số trang sách đã được viết về chủ đề này. chủ đề. Vì mô hình hồi quy tuyến tính không phải là trọng tâm chính của chúng ta ở đây, nên chúng ta Bài viết này chỉ tóm tắt ngắn gọn một số điểm chính.

1. Tính phi tuyến tính của dữ liệu



HÌNH 3.9. Đồ thị biểu diễn phần dư so với giá trị dự đoán (hoặc giá trị phù hợp) cho Auto tập dữ liệu. Trong mỗi biểu đồ, đường màu đỏ là đường cong phù hợp mượt mà với phần dư, nhằm mục đích làm cho Việc này giúp dễ dàng nhận biết xu hướng hơn. Bên trái: Biểu đồ hồi quy tuyến tính của mức tiêu hao nhiên liệu (mpg) theo công suất động cơ. Mô hình mạnh mẽ trong phần dư cho thấy tính phi tuyến tính trong dữ liệu. Bên phải: Một đường thẳng Hồi quy của mpg theo mã lực và mã lực². Hầu như không có quy luật nào trong phần dư.

Mô hình hồi quy tuyến tính giả định rằng có mối quan hệ tuyến tính giữa các biến dự báo và biến phản hồi. Nếu mối quan hệ thực sự không phải như vậy thì... Nếu nó không phải là một đường thẳng, thì hầu hết các kết luận mà chúng ta rút ra từ đó đều không hoàn toàn chính xác. Độ phù hợp có vấn đề. Ngoài ra, độ chính xác dự đoán của mô hình có thể sẽ giảm đáng kể.

Biểu đồ phần dư là một công cụ đồ họa hữu ích để xác định tính phi tuyến tính. Với một mô hình hồi quy tuyến tính đơn giản, ta có thể vẽ đồ thị phần dư, e_i = biểu đồ dư

3.3 Các yếu tố cần xem xét khác trong Mô hình hồi quy 101

y_i , so với biến dự đoán x_i . Trong trường hợp mô hình hồi quy đa biến, vì có nhiều biến dự đoán, chúng ta thay vào đó vẽ biểu đồ phần dư so với các giá trị dự đoán (hoặc phù hợp) $\hat{y}_i$. Lý tưởng nhất, biểu đồ phần dư sẽ không cho thấy bất kỳ mô hình nào có thể nhận biết được. Sự hiện diện của một mô hình có thể cho thấy vấn đề với một khía cạnh nào đó của mô hình tuyến tính.

được lập dự

Hình 3.9, bảng bên trái, hiển thị biểu đồ phần dư từ phép hồi quy tuyến tính của mpg (dặm trên gallon) lên mã lực trên tập dữ liệu Auto đã được minh họa trong Hình 3.8. Đường màu đỏ là đường cong phù hợp mượt mà với phần dư, được hiển thị để dễ dàng nhận diện bất kỳ xu hướng nào. Phần dư thể hiện rõ hình chữ U, cho thấy rõ tính phi tuyến tính trong dữ liệu.

Ngược lại, bảng bên phải của Hình 3.9 hiển thị biểu đồ phần dư thu được từ mô hình (3.36), chứa một số hạng bậc hai. Dường như không có nhiều mẫu trong phần dư, cho thấy số hạng bậc hai cải thiện sự phù hợp với dữ liệu.

Nếu biểu đồ phần dư cho thấy có mối liên hệ phi tuyến tính trong dữ liệu, thì một cách tiếp cận đơn giản là sử dụng các phép biến đổi phi tuyến tính của các biến dự báo, chẳng hạn như $\log X$, $\sqrt{X}$ và X^2 , trong mô hình hồi quy. Trong các chương sau của cuốn sách này, chúng ta sẽ thảo luận về các phương pháp phi tuyến tính nâng cao hơn để giải quyết vấn đề này.

2. Tương quan giữa các sai số

Một giả định quan trọng của mô hình hồi quy tuyến tính là các sai số không tương quan. Điều này có tương quan, thì việc dương nghĩa là gì? Ví dụ, với các số hạng 1, 2,..., n, nếu các sai số không cung cấp rất ít hoặc không cung cấp thông tin nào về dấu của . Các sai số chuẩn được tính toán cho các hệ số hồi quy ước tính hoặc các giá trị được hiệu chỉnh dựa trên giả định các số hạng sai số không tương quan. Nếu trên thực tế có sự tương quan giữa các số hạng sai số, thì các sai số chuẩn ước tính sẽ có xu hướng đánh giá thấp hơn các sai số chuẩn thực sự. Kết quả là, khoảng tin cậy và khoảng dự đoán sẽ hẹp hơn so với thực tế. Ví dụ, khoảng tin cậy 95% trên thực tế có thể có xác suất chứa giá trị thực của tham số thấp hơn nhiều so với 0,95. Ngoài ra, giá trị p liên quan đến mô hình sẽ thấp hơn so với thực tế; điều này có thể khiến chúng ta kết luận sai rằng một tham số có ý nghĩa thống kê. Tóm lại, nếu các số hạng sai số tương quan, chúng ta có thể có cảm giác tự tin không chính đáng vào mô hình của mình.


Ví dụ cực đoan, giả sử chúng ta vô tình nhân đôi dữ liệu, dẫn đến các quan sát và sai số giống hệt nhau theo từng cặp. Nếu bỏ qua điều này, phép tính sai số chuẩn của chúng ta sẽ giống như khi chúng ta có mẫu cỡ 2n, trong khi thực tế chúng ta chỉ có n mẫu. Các tham số ước tính sẽ giống nhau đối với 2n mẫu và n mẫu, nhưng khoảng tin cậy sẽ hẹp hơn một hệ số $\sqrt{2}$!

—

Tại sao lại có thể xảy ra sự tương quan giữa các sai số? Sự tương quan như vậy thường xảy ra trong bối cảnh dữ liệu chuỗi thời gian, bao gồm các quan sát mà phép đo được thực hiện tại các thời điểm rời rạc.

chuỗi thời gian

Trong nhiều trường hợp, các quan sát thu được tại các thời điểm liên tiếp sẽ có sai số tương quan dương. Để xác định xem điều này có đúng với một tập dữ liệu nhất định hay không, chúng ta có thể vẽ đồ thị phần dư từ mô hình của mình theo thời gian. Nếu các sai số không tương quan, thì sẽ không có mô hình nào có thể nhận biết được.



HÌNH 3.10. Đồ thị phần dư từ các tập dữ liệu chuỗi thời gian mô phỏng được tạo ra với các mức độ tương quan ρ khác nhau giữa các sai số tại các thời điểm liên tiếp.

Ngược lại, nếu các sai số có tương quan dương thì... Chúng ta có thể thấy sự theo dõi trong phần dư—nghĩa là, các phần dư liên tiếp có thể có giá trị tương tự nhau. Hình 3.10 minh họa điều này. Ở bảng trên, chúng ta thấy Phần dư từ phép hồi quy tuyến tính được thực hiện trên dữ liệu được tạo ra với các sai số không tương quan. Không có bằng chứng về xu hướng liên quan đến thời gian trong phần dư.


Ngược lại, phần dư ở bảng dưới cùng đến từ một tập dữ liệu trong đó Các lỗi liên tiếp có hệ số tương quan là 0,9. Giờ đây, đã có một mô hình rõ ràng trong... phần dư—các phần dư liên tiếp có xu hướng có giá trị tương tự nhau. Cuối cùng, Hình ở giữa minh họa một trường hợp ôn hòa hơn, trong đó phần dư có... Hệ số tương quan là 0,5. Vẫn còn bằng chứng về sự theo dõi, nhưng mô hình này ít rõ rệt hơn.

theo dõi

thống toán.

Nhiều phương pháp đã được phát triển để tính toán chính xác sự tương quan giữa các sai số trong dữ liệu chuỗi thời gian. Sự tương quan giữa các sai số Các thuật ngữ này cũng có thể xuất hiện bên ngoài dữ liệu chuỗi thời gian. Ví dụ, hãy xem xét một Nghiên cứu dự đoán chiều cao của cá nhân dựa trên cân nặng của họ. Giả định về các sai số không tương quan có thể bị vi phạm nếu một số cá nhân trong nghiên cứu là thành viên của cùng một gia đình, ăn cùng một chế độ ăn uống, hoặc đã tiếp xúc với cùng các yếu tố môi trường. Nói chung, Giả định về các sai số không tương quan là vô cùng quan trọng đối với hồi quy tuyến tính cũng như các phương pháp thống kê khác và thiết kế thí nghiệm tốt. Điều này rất quan trọng để giảm thiểu rủi ro từ những mối tương quan như vậy.

3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy 103



HÌNH 3.11. Biểu đồ phần dư. Trong mỗi biểu đồ, đường màu đỏ là đường khớp mượt mà với dữ liệu. các phần dư, nhằm mục đích giúp dễ dàng xác định xu hướng hơn. Các đường màu xanh theo dõi các phần vị ngoại của phần dư và nhấn mạnh các mẫu. Bên trái: Hình phần dư. Biểu thị hiện tượng phương sai không đồng nhất. Bên phải: Biến phản hồi đã được biến đổi logarit, và hiện tại không còn bằng chứng nào về hiện tượng phương sai không đồng nhất.

3. Phương sai không đổi của các thành phần sai số

Một giả định quan trọng khác của mô hình hồi quy tuyến tính là...

Các số hạng sai số có phương sai không đổi, $Var(i) = \sigma^2$. Sai số chuẩn, khoảng tin cậy và kiểm định giả thuyết liên quan đến mô hình tuyến tính dựa trên giả định này.

Thật không may, thường thì phương sai của các sai số lại là...

không cố định. Ví dụ, phương sai của các sai số có thể tăng lên.

với giá trị của phản hồi. Người ta có thể xác định các phương sai không đổi trong Các lỗi, hay hiện tượng phương sai không đồng nhất, xuất phát từ sự hiện diện của hình dạng phổ trong biểu đồ phần dư. Một ví dụ được thể hiện ở bảng bên trái của Hình 3.11. trong đó độ lớn của phần dư có xu hướng tăng lên cùng với giá trị được điều chỉnh.

các giá trị. Khi đối mặt với vấn đề này, một giải pháp khả thi là biến đổi đáp ứng Y bằng cách sử dụng một hàm lõm như $\log Y$ hoặc $\sqrt{Y}$. Như vậy

Sự biến đổi này dẫn đến sự thu hẹp đáng kể hơn của các phản hồi lớn hơn, dẫn đến giảm hiện tượng phương sai không đồng nhất. Bảng bên phải

Hình 3.11 hiển thị biểu đồ phần dư sau khi biến đổi phản hồi.

sử dụng $\log Y$. Tuy nhiên, phần dư hiện có vẻ như có phương sai không đổi.

Có một số bằng chứng cho thấy mối quan hệ phi tuyến tính nhẹ trong dữ liệu.

Đôi khi chúng ta có thể ước lượng khá chính xác sự biến thiên của từng phản hồi. Ví dụ:

Ví dụ, phản hồi thứ i có thể là giá trị trung bình của n_i quan sát thô. Nếu

Mỗi quan sát thô này đều không tương quan với phương sai σ^2 , do đó chúng

trung bình có phương sai $\sigma^2_{\bar{y}} = \sigma^2/n_i$. Trong trường hợp này, một biện pháp đơn giản là điều chỉnh cho phù hợp.

Mô hình được xây dựng bằng phương pháp bình phương tối thiểu có trọng số, với trọng số tỷ lệ thuận với nghịch đảo của phương sai – tức là $w_i = n_i$ trong trường hợp này. Hầu hết các phần mềm hồi quy tuyến tính đều cho phép đối với trọng số quan sát.


phương sai không đồng nhất

có trọng số bình phương tối thiểu

4. Các giá trị ngoại lệ

Điểm ngoại lệ là điểm mà giá trị y_i nằm cách xa giá trị dự đoán của mô hình.

ngoại lệ



HÌNH 3.12. Bên trái: Đường hồi quy bình phương nhỏ nhất được hiển thị bằng màu đỏ, và Đường hồi quy sau khi loại bỏ điểm ngoại lệ được hiển thị bằng màu xanh lam. Tâm: Phần dư Biểu đồ xác định rõ ràng điểm ngoại lệ. Bên phải: Điểm ngoại lệ có phần dư chuẩn hóa là 6; thông thường chúng ta kỳ vọng các giá trị nằm trong khoảng từ -3 đến 3.

mô hình. Các giá trị ngoại lệ có thể xuất hiện vì nhiều lý do, chẳng hạn như ghi chép không chính xác. về một quan sát trong quá trình thu thập dữ liệu.

Điểm màu đỏ (quan sát 20) ở bảng bên trái của Hình 3.12 Hình minh họa thể hiện một điểm ngoại lệ điển hình. Đường liên nét màu đỏ là đường hồi quy bình phương nhỏ nhất. Đường chấm màu xanh là đường khớp tối thiểu sau khi loại bỏ các sai số. giá trị ngoại lệ. Trong trường hợp này, việc loại bỏ giá trị ngoại lệ có rất ít ảnh hưởng đến phương pháp bình phương tối thiểu. đường thẳng: nó hầu như không làm thay đổi độ dốc, và chỉ làm giảm một lượng rất nhỏ. trong điểm giao nhau. Đó là điều điển hình đối với một giá trị ngoại lệ không có đặc điểm bất thường. Giá trị dự đoán có ít ảnh hưởng đến sự phù hợp theo phương pháp bình phương tối thiểu. Tuy nhiên, ngay cả Nếu một giá trị ngoại lệ không ảnh hưởng nhiều đến kết quả khớp bình phương tối thiểu, nó có thể gây ra các vấn đề khác. Ví dụ, trong trường hợp này, RSE là 1,09 khi Giá trị ngoại lệ được đưa vào hồi quy, nhưng nó chỉ là 0,77 khi giá trị ngoại lệ xuất hiện. đã bị loại bỏ. Vì RSE được sử dụng để tính toán tất cả các khoảng tin cậy và Giá trị p, sự gia tăng đột biến như vậy do một điểm dữ liệu duy nhất gây ra có thể có những hàm ý đối với việc giải thích sự phù hợp. Tương tự, việc bao gồm Giá trị ngoại lệ khiến hệ số R2 giảm từ 0,892 xuống 0,805.

Biểu đồ phần dư có thể được sử dụng để xác định các giá trị ngoại lệ. Trong ví dụ này, giá trị ngoại lệ hiển thị rõ ràng trong biểu đồ phần dư được minh họa ở bảng giữa. Hình 3.12. Nhưng trên thực tế, rất khó để quyết định mức độ sai số cần thiết trước khi coi điểm đó là điểm ngoại lệ. Để giải quyết vấn đề này... Trong bài toán này, thay vì vẽ đồ thị phần dư, ta có thể vẽ đồ thị chuẩn hóa. Phần dư, được tính bằng cách chia mỗi phần dư ei cho sai số chuẩn ước tính của nó. Các quan sát có phần dư chuẩn hóa lớn hơn 3 về giá trị tuyệt đối có thể là các giá trị ngoại lệ. Trong bảng bên phải của Hình 3.12 , Phần dư chuẩn hóa của giá trị ngoại lệ vượt quá 6, trong khi tất cả các quan sát khác đều có Phần dư chuẩn hóa nằm giữa -2 và 2.

Nếu chúng ta tin rằng giá trị ngoại lệ xuất hiện do lỗi trong quá trình thu thập hoặc ghi dữ liệu, thì một giải pháp đơn giản là loại bỏ quan sát đó. Tuy nhiên, cần thận trọng, vì một giá trị ngoại lệ có thể lại là dấu hiệu của một điều gì đó khác. Thiếu sót trong mô hình, chẳng hạn như thiếu biến dự đoán.


5. Các điểm đòn bẩy cao

Chúng ta vừa thấy rằng các giá trị ngoại lệ là những quan sát mà giá trị phản hồi yi là Điều này bất thường khi xét đến biến dự báo xi. Ngược lại, các quan sát có đòn bẩy cao lại có giá trị xi bất thường. Ví dụ, quan sát 41 ở phía bên trái.

sinh viên
dự

cao
tận dụng

3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy 105




HÌNH 3.13. Bên trái: Quan sát 41 là điểm đòn bẩy cao, trong khi 20 thì không. Đường màu đỏ là đường khớp với tất cả dữ liệu, và đường màu xanh là đường khớp với dữ liệu quan sát. 41 đã bị xóa. Trung tâm: Quan sát màu đỏ không có gì bất thường về giá trị X1 của nó. hoặc giá trị X2 của nó , nhưng vẫn nằm ngoài phần lớn dữ liệu, và do đó có giá trị cao. Đòn bẩy. Bên phải: Quan sát 41 có đòn bẩy cao và phần dư cao.

Bảng trong Hình 3.13 có đòn bẩy cao, ở chỗ giá trị dự đoán cho điều này Quan sát này có quy mô lớn so với các quan sát khác. (Lưu ý rằng dữ liệu) Các dữ liệu hiển thị trong Hình 3.13 giống với dữ liệu hiển thị trong Hình 3.12. nhưng với sự bổ sung của một quan sát có đòn bẩy cao.) Đường màu đỏ liền nét Đường thẳng là đường khớp dữ liệu theo phương pháp bình phương tối thiểu, trong khi đường chấm xanh là đường thẳng nối các điểm dữ liệu với trục hoành. Hình ảnh phù hợp được tạo ra khi loại bỏ quan sát 41. So sánh với hình ảnh bên trái. Từ các bảng trong Hình 3.12 và 3.13, chúng ta nhận thấy rằng việc loại bỏ đòn bẩy cao Quan sát có tác động đáng kể hơn nhiều đến đường hồi quy bình phương tối thiểu. hơn là loại bỏ giá trị ngoại lệ. Trên thực tế, các quan sát có đòn bẩy cao thường có có tác động đáng kể đến đường hồi quy ước tính. Điều này đáng lo ngại nếu Đường hồi quy bình phương tối thiểu bị ảnh hưởng rất nhiều bởi chỉ một vài quan sát. vì bất kỳ vấn đề nào với những điểm này đều có thể làm mất hiệu lực toàn bộ quá trình lắp ráp. Ví dụ: Vì lý do này, việc xác định các quan sát có tính ảnh hưởng cao là rất quan trọng. Trong hồi quy tuyến tính đơn giản, các quan sát có đòn bẩy cao khá dễ dàng để xác định, vì chúng ta chỉ cần tìm kiếm các quan sát mà bộ dự đoán Giá trị này nằm ngoài phạm vi quan sát thông thường. Nhưng trong nhiều trường hợp Hồi quy tuyến tính với nhiều biến dự đoán, có thể có một quan sát Điều đó nằm trong phạm vi giá trị của từng biến dự báo riêng lẻ, nhưng điều đó Điều này khá bất thường xét về toàn bộ các biến dự đoán. Một ví dụ được minh họa trong... bảng giữa của Hình 3.13, dành cho tập dữ liệu có hai biến dự đoán, X1 và X2. Hầu hết các giá trị dự đoán của các quan sát nằm trong vùng gạch ngang màu xanh lam. hình elip, nhưng quan sát màu đỏ nằm ngoài phạm vi này. Nhưng cả hai đều không phải của nó Giá trị của X1 cũng như giá trị của nó đối với X2 đều không có gì bất thường. Vì vậy, nếu chúng ta chỉ xem xét X1 hoặc Chỉ cần gấp đôi, chúng ta sẽ không nhận ra điểm đòn bẩy cao này. Vấn đề này còn nghiêm trọng hơn. được thể hiện rõ trong các thiết lập hồi quy đa biến với nhiều hơn hai biến dự đoán. vì khi đó không có cách nào đơn giản để vẽ biểu đồ tất cả các chiều của dữ liệu. đồng thời.

Để định lượng mức độ ảnh hưởng của một quan sát, chúng ta tính toán đòn bẩy. thống kê. Giá trị lớn của thống kê này cho thấy một quan sát có độ ảnh hưởng cao. Đối với hồi quy tuyến tính đơn giản,

tận dụng
thống kê

$$chào = \frac{1}{N} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^N (x_i - \bar{x})^2} . \tag{3.37}$$



HÌNH 3.14. Biểu đồ phân tán các quan sát từ tập dữ liệu *Tín dụng* . Bên trái: Đồ thị biểu diễn mối quan hệ giữa *tuổi* và *giới hạn*. Hai biến này không cùng phương. Bên phải: Một đồ thị về *xếp hạng* so với *giới hạn*. Có sự tương quan tuyến tính cao.

Từ phương trình này, rõ ràng hi tăng theo khoảng cách của xi so với x^{*}. Tuy nhiên, có một cách mở rộng đơn giản của hi cho trường hợp có nhiều biến dự đoán. Chúng tôi không cung cấp công thức ở đây. Chỉ số đòn bẩy hi luôn luôn là nằm giữa 1/n và 1, và đòn bẩy trung bình cho tất cả các quan sát là luôn bằng (p + 1)/n. Vì vậy, nếu một quan sát nhất định có thống kê đòn bẩy nếu giá trị đó vượt xa (p+1)/n thì ta có thể nghi ngờ rằng giá trị tương ứng Điểm này có đòn bẩy cao.

Bảng bên phải của Hình 3.13 cung cấp đồ thị của hệ số chuẩn hóa. Phần dư so với hi đối với dữ liệu ở bảng bên trái của Hình 3.13. Quan sát 41 nổi bật với chỉ số đòn bẩy rất cao cũng như một phần dư chuẩn hóa cao. Nói cách khác, nó vừa là một giá trị ngoại lệ vừa là một giá trị cao. Quan sát đòn bẩy. Đây là một sự kết hợp đặc biệt nguy hiểm! Điều này Biểu đồ cũng cho thấy lý do tại sao quan sát 20 lại có tác động tương đối nhỏ. Trên đường khớp bình phương tối thiểu trong Hình 3.12: nó có đòn bẩy thấp.

6. Tính cộng tuyến


Hiện tượng đa cộng tuyến đề cập đến tình huống trong đó hai hoặc nhiều biến dự báo có mối liên hệ chặt chẽ với nhau. Khái niệm đa cộng tuyến được minh họa như sau:

Hình 3.14 sử dụng tập dữ liệu *Tín dụng* . Ở bảng bên trái của Hình 3.14, hai biến dự báo *giới hạn* và *tuổi tác* dường như không có mối quan hệ rõ ràng. Ngược lại, ở bảng bên phải của Hình 3.14, các biến dự báo... tính cộng tuyến

Giới hạn và *xếp hạng* có mối tương quan rất cao với nhau, và chúng tôi nói rằng Điều đó có nghĩa là chúng cùng nằm trên một đường thẳng. Sự hiện diện của hiện tượng cùng nằm trên một đường thẳng có thể gây ra vấn đề trong... Trong bối cảnh hồi quy, việc tách biệt các tác động riêng lẻ của các biến cộng tuyến lên biến phản hồi có thể khó khăn. Nói cách khác, vì *Giới hạn* và *xếp hạng* thường tăng hoặc giảm cùng nhau, điều này có thể gây khó khăn. Xác định mối liên hệ riêng lẻ của từng yếu tố với phản hồi và *sự cân bằng*.

Hình 3.15 minh họa một số khó khăn có thể phát sinh do hiện tượng cộng tuyến. Bảng bên trái của Hình 3.15 là biểu đồ đường đồng mức của RSS (3.22) liên quan đến các ước tính hệ số khác nhau có thể có cho hồi quy về *sự cân bằng* dựa trên *giới hạn* và *tuổi tác*. Mỗi hình elíp biểu thị một tập hợp các hệ số.

3.3 Các yếu tố khác cần xem xét trong mô hình hồi quy 107



HÌNH 3.15. Đồ thị đường đồng mức của các giá trị RSS theo hàm số của các tham số. Hệ số β được sử dụng cho các phép hồi quy khác nhau liên quan đến tập dữ liệu *Tin dụng*. Trong mỗi biểu đồ, đường màu đen Các dấu chấm biểu thị giá trị hệ số tương ứng với RSS tối thiểu. Bên trái: Biểu đồ đường đồng mức của RSS cho phép hồi quy *sự cân bằng* theo *tuổi* và *giới hạn*. Giá trị tối thiểu được xác định rõ ràng. Bên phải: Biểu đồ đường đồng mức của RSS cho phép hồi quy. *cân bằng* dựa trên *xếp hạng* và *giới hạn*. Do tính đa cộng tuyến, có rất nhiều các cặp (β_{Limit} , β_{Rating}) có giá trị RSS tương tự.

Các đường này tương ứng với cùng một giá trị RSS, trong đó các hình elip gần tâm nhất lấy các giá trị RSS thấp nhất. Các chấm đen và các đường nét đứt liên quan Các đường thẳng biểu thị các ước tính hệ số dẫn đến giá trị nhỏ nhất có thể. RSS—nói cách khác, đây là các ước lượng bình phương nhỏ nhất. Các trục cho *Giới hạn* và *tuổi* đã được điều chỉnh tỷ lệ sao cho biểu đồ bao gồm các ước tính hệ số có thể có nằm trong phạm vi bốn sai số chuẩn ở cả hai phía của giá trị. ước lượng bình phương nhỏ nhất. Do đó, biểu đồ bao gồm tất cả các giá trị khả thi cho các hệ số. Ví dụ, ta thấy rằng hệ số *giới hạn* thực sự gần như Chắc chắn là nằm trong khoảng từ 0,15 đến 0,20.

Ngược lại, bảng bên phải của Hình 3.15 hiển thị các biểu đồ đường đồng mức. của RSS liên quan đến các ước tính hệ số có thể có cho hồi quy về *sự cân bằng* dựa trên *giới hạn* và *xếp hạng*, mà chúng ta biết là có mối tương quan rất cao. Hiện nay, các đường đồng mức chạy dọc theo một thung lũng hẹp; có một phạm vi rộng lớn của các giá trị ước lượng hệ số dẫn đến các giá trị RSS bằng nhau. Do đó, một thay đổi nhỏ trong dữ liệu có thể làm thay đổi cặp giá trị hệ số. những giá trị mang lại RSS nhỏ nhất – tức là các ước lượng bình phương tối thiểu – để di chuyển bất cứ nơi nào dọc theo thung lũng này. Điều này dẫn đến rất nhiều sự không chắc chắn trong ước tính hệ số. Lưu ý rằng thang đo cho hệ số *giới hạn* hiện đang chạy Từ khoảng -0,2 đến 0,2; đây là mức tăng gấp tám lần so với mức hợp lý. phạm vi của hệ số *giới hạn* trong hồi quy theo *tuổi*. Điều thú vị là, ngay cả mặc dù các hệ số *giới hạn* và *xếp hạng* hiện nay có tính cá nhân hóa cao hơn nhiều. Với sự không chắc chắn này, chúng gần như chắc chắn sẽ nằm ở đâu đó trong thung lũng theo đường đồng mức này. Ví dụ, chúng ta sẽ không kỳ vọng vào giá trị thực sự của *giới hạn* và *xếp hạng*. các hệ số lần lượt là -0,1 và 1, mặc dù giá trị đó là Có thể hợp lý đối với từng hệ số riêng lẻ.

Vì hiện tượng đa cộng tuyến làm giảm độ chính xác của các ước lượng hồi quy. các hệ số này khiến sai số chuẩn của β_j tăng lên. Hãy nhớ rằng Giá trị t-statistic cho mỗi biến dự đoán được tính bằng cách chia β_j cho hệ số chuẩn của nó.

	Hệ số Sai số chuẩn	Thống kê t	43,828 0,672 0,005	giá trị p
Chặn	173,411	45,254	3,957	< 0,0001
Giới hạn độ tuổi của mẫu 1	2,292	0,952	3,407	0,0007
	0,173	0,064	34,496	< 0,0001
Chặn	377,537		8,343	< 0,0001
Đánh giá Mô hình 2	2,202		2,312	0,0213
giới hạn	0,025		0.384	0.7012

BẢNG 3.11. Kết quả của hai mô hình hồi quy bội liên quan đến **Tín dụng**
Bộ dữ liệu được hiển thị. Mô hình 1 là hồi quy về **sự cân bằng dựa trên tuổi và giới hạn**, và Mô hình 2 là mô hình hồi quy về **số dư dựa trên xếp hạng và giới hạn**. Sai số chuẩn của β -limit tăng gấp 12 lần trong hồi quy thứ hai do hiện tượng đa cộng tuyến.

Lỗi. Do đó, hiện tượng đa cộng tuyến dẫn đến sự suy giảm của thống kê t. Như một
Kết quả là, trong trường hợp có sự cộng tuyến, chúng ta có thể không bác bỏ giả thuyết $H_0 : \beta_j = 0$. Điều này
Điều này có nghĩa là sức mạnh của phép kiểm định giả thuyết – xác suất phát hiện chính xác một hệ
số khác không – bị giảm đi do hiện tượng đa cộng tuyến. quyền lực

Bảng 3.11 so sánh các ước tính hệ số thu được từ hai phương pháp riêng biệt.
các mô hình hồi quy đa biến. Mô hình đầu tiên là hồi quy về **sự cân bằng theo tuổi và giới hạn**, và thứ hai là sự hồi quy của **số dư dựa trên xếp hạng và giới hạn**. Trong
Trong phân tích hồi quy đầu tiên, cả **tuổi tác** và **giới hạn** đều có ý nghĩa thống kê cao với giá
trị p rất nhỏ. Trong phân tích thứ hai, hiện tượng đa cộng tuyến giữa **giới hạn** và **xếp hạng** đã gây ra
sai số chuẩn cho ước lượng hệ số **giới hạn** tăng lên một hệ số
của 12 và giá trị p tăng lên 0,701. Nói cách khác, tầm quan trọng
Giá trị của biến **giới hạn** đã bị che khuất do sự hiện diện của hiện tượng đa cộng tuyến.
Để tránh tình huống như vậy, cần phải xác định và giải quyết các vấn đề tiềm ẩn.
Các vấn đề về tính đa cộng tuyến trong quá trình xây dựng mô hình.

Một cách đơn giản để phát hiện hiện tượng đa cộng tuyến là xem xét ma trận tương quan.
của các biến dự đoán. Một phần tử của ma trận này có giá trị tuyệt đối lớn.
ký hiệu này chỉ ra một cặp biến có tương quan cao, và do đó dẫn đến hiện tượng đa cộng tuyến.
vấn đề nằm ở dữ liệu. Thật không may, không phải tất cả các vấn đề về đa cộng tuyến đều có thể được giải quyết.
Được phát hiện bằng cách kiểm tra ma trận tương quan: hiện tượng đa cộng tuyến có thể tồn tại
giữa ba hoặc nhiều biến ngay cả khi không có cặp biến nào có chung hệ số tương quan.
có mối tương quan đặc biệt cao. Chúng ta gọi tình trạng này là đa cộng tuyến.
Thay vì kiểm tra ma trận tương quan, một cách tốt hơn để đánh giá hiện tượng đa cộng tuyến là
tính toán hệ số khuếch đại phương sai (VIF). VIF là tỷ lệ giữa phương sai của $\hat{\beta}_j$ khi áp dụng mô
hình đầy đủ chia cho... nhiều-
tính cộng tuyến
phương sai
lạm phát
nhân tố

Phương sai của $\hat{\beta}_j$ nếu được tính toán riêng lẻ. Giá trị nhỏ nhất có thể của VIF là 1.
Điều này cho thấy sự vắng mặt hoàn toàn của hiện tượng cộng tuyến. Thông thường trong thực tế
Có một lượng nhỏ hiện tượng đa cộng tuyến giữa các biến dự báo. Theo quy tắc của
Ngón tay cái, giá trị VIF vượt quá 5 hoặc 10 cho thấy lượng chất đó có vấn đề.
hiện tượng đa cộng tuyến. Hệ số VIF cho mỗi biến có thể được tính bằng công thức sau:

$$VIF(\hat{\beta}_j) = \frac{1}{1 - R_{X_j}^2}$$

trong đó $R_{X_j}^2$ là hệ số R^2 thu được từ phép hồi quy của X_j trên tất cả các biến còn lại.
biến dự đoán. Nếu $R_{X_j}^2$ gần bằng một thì sẽ có hiện tượng cộng tuyến, và do đó
VIF sẽ lớn.

Trong dữ liệu **tín dụng**, hồi quy số **dự dựa trên tuổi, xếp hạng và hạn mức** cho thấy các biến dự báo có giá trị VIF lần lượt là 1,01, 160,67 và 160,59.

Đúng như dự đoán, dữ liệu có sự tương quan tuyến tính đáng kể!

Khi đối mặt với vấn đề đa cộng tuyến, có hai giải pháp đơn giản. Giải pháp đầu tiên là loại bỏ một trong những biến gây vấn đề khỏi mô hình hồi quy. Điều này thường có thể được thực hiện mà không ảnh hưởng nhiều đến độ phù hợp của mô hình hồi quy, vì sự hiện diện của đa cộng tuyến ngụ ý rằng thông tin mà biến này cung cấp về biến phản hồi là dư thừa khi có sự hiện diện của các biến khác. Ví dụ, nếu chúng ta hồi quy biến **"balance"** dựa trên **"age"** và **"limit"**, mà không có biến dự báo **"rating"**, thì giá trị VIF thu được sẽ gần với giá trị tối thiểu có thể là 1, và R2 giảm từ 0,754 xuống 0,75.

Vì vậy, việc loại bỏ **biến xếp hạng** khỏi tập hợp các biến dự đoán đã giải quyết hiệu quả vấn đề đa cộng tuyến mà không ảnh hưởng đến độ phù hợp của mô hình. Giải pháp thứ hai là kết hợp các biến đa cộng tuyến lại với nhau thành một biến dự đoán duy nhất. Ví dụ, chúng ta có thể lấy trung bình của các phiên bản chuẩn hóa của **giới hạn** và **xếp hạng** để tạo ra một biến mới đo lường khả năng tín dụng.

3.4 Kế hoạch Marketing

Giờ đây, chúng ta sẽ quay lại với bảy câu hỏi về dữ liệu **quảng cáo** mà chúng ta đã đặt ra để trả lời ở đầu chương này.

1. Có mối quan hệ nào giữa doanh thu và ngân sách quảng cáo không?

Câu hỏi này có thể được trả lời bằng cách áp dụng mô hình hồi quy đa biến về **doanh số bán hàng lên TV, radio và báo chí**, như trong (3.20), và kiểm định

giả thuyết $H_0: \beta_{TV} = \beta_{radio} = \beta_{newspaper} = 0$. Trong Phần 3.2.2, Chúng tôi đã chứng minh rằng thống kê F có thể được sử dụng để xác định xem chúng ta có nên

bác bỏ giả thuyết không này hay không. Trong trường hợp này, giá trị p tương ứng với thống kê F trong Bảng 3.6 rất thấp, cho thấy bằng chứng rõ ràng về mối quan hệ giữa quảng cáo và doanh số bán hàng.

2. Mối quan hệ đó bền chặt đến mức nào?

Chúng ta đã thảo luận về hai thước đo độ chính xác của mô hình trong Phần 3.1.3. Thứ nhất, RSE ước tính độ lệch chuẩn của phản hồi so với đường hồi quy của quần thể. Đối với dữ liệu **Quảng cáo**, RSE là 1,69 đơn vị trong khi giá trị trung bình của phản hồi là 14,022, cho thấy sai số phần trăm khoảng 12%. Thứ hai, thống kê R2 ghi lại phần trăm biến thiên trong phản hồi được giải thích bởi các biến dự báo. Các biến dự báo giải thích gần 90% phương sai trong **doanh số bán hàng**. Các thống kê RSE và R2 được hiển thị trong Bảng 3.6.

3. Những phương tiện truyền thông nào liên quan đến doanh số bán hàng?

Để trả lời câu hỏi này, chúng ta có thể xem xét các giá trị p liên quan đến thống kê t của mỗi biến dự báo (Mục 3.1.2). Trong hồi quy tuyến tính đa biến được hiển thị trong Bảng 3.4, các giá trị p cho **TV** và **radio** thấp, nhưng giá trị p cho **báo chí** thì không. Điều này cho thấy chỉ có **TV** và **radio** có liên quan đến **doanh số bán hàng**. Trong Chương 6, chúng ta sẽ khám phá câu hỏi này chi tiết hơn.

4. Mức độ liên quan giữa mỗi phương tiện truyền thông và doanh số bán hàng lớn đến mức nào?

Chúng ta đã thấy trong Phần 3.1.2 rằng sai số chuẩn của β_j có thể được sử dụng để xây dựng khoảng tin cậy cho β_j . Đối với dữ liệu **Quảng cáo**, chúng tôi có thể sử dụng kết quả trong Bảng 3.4 để tính khoảng tin cậy 95% cho các hệ số trong mô hình hồi quy bội sử dụng cả ba biến.

Ngân sách truyền thông được sử dụng làm yếu tố dự báo. Khoảng tin cậy như sau:

(0,043, 0,049) cho **TV**, (0,172, 0,206) cho **radio** và (0,013, 0,011) cho **báo chí**. Khoảng tin cậy đối với **truyền hình** và **radio** thì hẹp và xa rời con số không, cung cấp bằng chứng cho thấy các phương tiện truyền thông này có liên quan đến **doanh số bán hàng**. Nhưng khoảng giá cho **báo chí** bao gồm cả số 0, cho thấy rằng Biến số này không có ý nghĩa thống kê khi xét đến các giá trị của **TV** và **radio**.

Chúng ta đã thấy trong Phần 3.3.3 rằng hiện tượng đa cộng tuyến có thể dẫn đến sai số chuẩn rất lớn. Liệu đa cộng tuyến có phải là lý do khiến khoảng tin cậy liên quan đến **biên báo chí** lại rộng như vậy? Điểm VIF là 1,005.

1,145, và 1,145 đối với **truyền hình**, **đài phát thanh** và **báo chí**, cho thấy không có bằng chứng nào về hiện tượng cộng tuyến.

Để đánh giá mối liên hệ của từng phương tiện riêng lẻ trên

Để phân tích mối liên hệ giữa doanh số bán hàng và truyền hình, chúng ta có thể thực hiện ba phép hồi quy tuyến tính đơn giản riêng biệt. Kết quả được trình bày trong Bảng 3.1 và 3.3. Có bằng chứng cho thấy mối liên hệ cực kỳ mạnh mẽ giữa **truyền hình** và **doanh số bán hàng**, cũng như giữa **radio** và **truyền thông đại chúng**.

và **doanh số bán hàng**. Có bằng chứng về mối liên hệ nhẹ giữa **báo chí**.

và **doanh số bán hàng**, khi bỏ qua giá trị của **truyền hình** và **radio**.

5. Chúng ta có thể dự đoán doanh số bán hàng trong tương lai chính xác đến mức nào?

Phần hồi có thể được dự đoán bằng cách sử dụng (3.21). Độ chính xác liên quan đến ước tính này phụ thuộc vào việc chúng ta muốn dự đoán một

phản ứng cá nhân, $Y = f(X)_i$, hoặc phản ứng trung bình, $f(X)$

(Mục 3.2.2). Nếu là trường hợp thứ nhất, chúng ta sử dụng khoảng dự đoán, và nếu

Đối với trường hợp thứ hai, chúng ta sử dụng khoảng tin cậy. Khoảng dự đoán sẽ luôn rộng hơn khoảng tin cậy vì chúng tính đến các yếu tố khác.

sự không chắc chắn liên quan đến sai số, không thể giảm thiểu.

6. Mối quan hệ này có tuyến tính không?

Trong Mục 3.3.3, chúng ta đã thấy rằng biểu đồ phần dư có thể được sử dụng để Xác định tính phi tuyến tính. Nếu mối quan hệ là tuyến tính, thì phần dư Các đồ thị không nên thể hiện bất kỳ quy luật nào. Trong trường hợp dữ liệu **Quảng cáo**,

Chúng ta quan sát thấy một hiệu ứng phi tuyến tính trong Hình 3.5, mặc dù hiệu ứng này có thể Điều này cũng có thể được quan sát trong biểu đồ phần dư. Trong Phần 3.3.2, chúng ta đã thảo luận về bao gồm các phép biến đổi của các biến dự báo trong hồi quy tuyến tính

mô hình nhằm mục đích phù hợp với các mối quan hệ phi tuyến tính.

7. Có sự phối hợp hiệu quả giữa các phương tiện quảng cáo không?

Mô hình hồi quy tuyến tính chuẩn giả định mối quan hệ cộng giữa các biến dự báo và biến phản hồi. Một mô hình cộng

Dễ hiểu vì mối liên hệ giữa mỗi yếu tố dự báo.

và phản hồi này không liên quan đến giá trị của các biến dự báo khác.

Tuy nhiên, giả định cộng có thể không thực tế đối với một số dữ liệu nhất định.

tập hợp. Trong Mục 3.3.2, chúng tôi đã trình bày cách bao gồm một thuật ngữ tương tác.

Trong mô hình hồi quy, cần bổ sung thêm biến tương tác để xử lý các mối quan hệ không cộng tính. Giá trị p nhỏ liên quan đến biến tương tác cho thấy sự hiện diện của các mối quan hệ như vậy. Hình 3.5 cho thấy dữ liệu **Quảng cáo** có thể không mang tính cộng tính. Việc đưa biến tương tác vào mô hình dẫn đến sự gia tăng đáng kể R^2 , từ khoảng 90% lên gần 97%.


3.5 So sánh hồi quy tuyến tính với thuật toán K-hàng xóm gần nhất

Như đã thảo luận trong Chương 2, hồi quy tuyến tính là một ví dụ về phương pháp tham số vì nó giả định dạng hàm tuyến tính cho $f(X)$. Các phương pháp tham số có một số ưu điểm. Chúng thường dễ dàng để xây dựng mô hình, vì người ta chỉ cần ước tính một số lượng nhỏ các hệ số. Trong trường hợp hồi quy tuyến tính, các hệ số có cách giải thích đơn giản và các kiểm định ý nghĩa thống kê có thể được thực hiện dễ dàng. Nhưng các phương pháp tham số cũng có một nhược điểm: theo cấu trúc, chúng đưa ra những giả định mạnh mẽ về dạng của $f(X)$. Nếu dạng hàm được chỉ định khác xa so với thực tế, và độ chính xác dự đoán là mục tiêu của chúng ta, thì phương pháp tham số sẽ hoạt động kém hiệu quả. Ví dụ, nếu chúng ta giả định mối quan hệ tuyến tính giữa X và Y nhưng mối quan hệ thực tế lại khác xa so với tuyến tính, thì mô hình thu được sẽ không phù hợp với dữ liệu và bất kỳ kết luận nào rút ra từ đó đều đáng ngờ.

Ngược lại, các phương pháp phi tham số không giả định rõ ràng dạng tham số cho $f(X)$, và do đó cung cấp một cách tiếp cận thay thế và linh hoạt hơn để thực hiện hồi quy. Chúng tôi thảo luận về nhiều phương pháp phi tham số khác nhau trong cuốn sách này. Ở đây, chúng tôi xem xét một trong những phương pháp phi tham số đơn giản và nổi tiếng nhất, hồi quy K-hàng xóm gần nhất (hồi quy KNN). Phương pháp hồi quy KNN có liên quan mật thiết đến bộ phân loại KNN đã được thảo luận trong Chương 2. Cho một giá trị K và một điểm dự đoán x_0 , hồi quy KNN trước tiên xác định K quan sát huấn luyện gần nhất với x_0 , được biểu thị bằng N_0 . Sau đó, nó ước tính $f(x_0)$ bằng cách sử dụng giá trị trung bình của tất cả các phản hồi huấn luyện trong N_0 . Nói cách khác,

$$\hat{f}(x_0) = \frac{1}{K} \sum_{x_i \in N_0} y_i.$$

Hình 3.16 minh họa hai phép khớp KNN trên một tập dữ liệu với $p = 2$ biến dự đoán. Phép khớp với $K = 1$ được hiển thị ở bảng bên trái, trong khi bảng bên phải tương ứng với $K = 9$. Chúng ta thấy rằng khi $K = 1$, phép khớp KNN nội suy hoàn hảo các quan sát huấn luyện, và do đó có dạng hàm bậc thang. Khi $K = 9$, phép khớp KNN vẫn là hàm bậc thang, nhưng việc lấy trung bình trên chín quan sát dẫn đến các vùng dự đoán không đổi nhỏ hơn nhiều, và do đó phép khớp mượt mà hơn. Nói chung, giá trị tối ưu cho K sẽ phụ thuộc vào sự đánh đổi giữa độ lệch và phương sai, mà chúng ta đã giới thiệu trong Chương 2. Giá trị nhỏ của K cung cấp phép khớp linh hoạt nhất, có độ lệch thấp nhưng phương sai cao. Phương sai này là do thực tế là dự đoán trong một vùng nhất định hoàn toàn phụ thuộc vào chỉ một quan sát.



HÌNH 3.16. Đồ thị của $\hat{f}(X)$ sử dụng hồi quy KNN trên không gian hai chiều Tập dữ liệu với 64 quan sát (chấm màu cam). Bên trái: $K = 1$ tạo ra một bước thô. Sự phù hợp của hàm. Bên phải: $K = 9$ tạo ra sự phù hợp mượt mà hơn nhiều.

Ngược lại, giá trị K lớn hơn sẽ mang lại sự phù hợp mượt mà hơn và ít biến thiên hơn; Dự đoán trong một khu vực là giá trị trung bình của nhiều điểm, do đó việc thay đổi một Việc quan sát có tác động nhỏ hơn. Tuy nhiên, việc làm mịn có thể gây ra sai lệch do che giấu một số cấu trúc trong $f(X)$. Trong Chương 5, chúng tôi giới thiệu một số Các phương pháp ước tính tỷ lệ lỗi kiểm thử. Những phương pháp này có thể được sử dụng để Xác định giá trị tối ưu của K trong hồi quy KNN.

Trong trường hợp nào thì phương pháp tham số như hồi quy tuyến tính bình phương tối thiểu sẽ cho kết quả tốt hơn phương pháp phi tham số như hồi quy KNN?

Câu trả lời rất đơn giản: phương pháp tham số sẽ cho kết quả tốt hơn phương pháp phi tham số nếu dạng tham số được chọn gần giống với dạng tham số ban đầu.

đến dạng thực sự của f . Hình 3.17 cung cấp một ví dụ với dữ liệu được tạo ra.

từ mô hình hồi quy tuyến tính một chiều. Các đường liền nét màu đen biểu thị $f(X)$, trong khi các đường cong màu xanh lam tương ứng với các phép khớp KNN sử dụng $K = 1$

và $K = 9$. Trong trường hợp này, các dự đoán với $K = 1$ có độ biến thiên quá lớn, trong khi Đường cong phù hợp $K = 9$ mượt mà hơn sẽ gần với $f(X)$ hơn nhiều. Tuy nhiên, vì thực tế Mọi quan hệ này là tuyến tính, nên phương pháp phi tham số khó có thể cạnh tranh được.

Với hồi quy tuyến tính: phương pháp phi tham số gây ra tổn thất về phương sai.

Điều đó không được bù đắp bằng việc giảm độ lệch. Đường chấm xanh lam ở bảng bên trái của Hình 3.18 biểu thị sự phù hợp hồi quy tuyến tính với cùng một dữ liệu.

dữ liệu. Nó gần như hoàn hảo. Phần bên phải của Hình 3.18 cho thấy rằng

Hồi quy tuyến tính cho kết quả tốt hơn thuật toán KNN với tập dữ liệu này. Đường liền nét màu xanh lá cây, được vẽ dưới dạng hàm của $1/K$, biểu thị sai số bình phương trung bình (MSE) của tập dữ liệu thử nghiệm. đối với KNN. Sai số của KNN nằm cao hơn nhiều so với đường chấm đen, tức là

Kiểm tra MSE cho hồi quy tuyến tính. Khi giá trị của K lớn, thì KNN


Về mặt MSE, phương pháp này chỉ cho kết quả kém hơn một chút so với hồi quy bình phương tối thiểu.

Nó hoạt động kém hơn nhiều khi K nhỏ.

Trên thực tế, mối quan hệ thực sự giữa X và Y hiếm khi hoàn toàn tuyến tính. Hình 3.19 xem xét hiệu suất tương đối của hồi quy bình phương tối thiểu và KNN dưới các mức độ phi tuyến tính tăng dần trong mối quan hệ này.

giữa X và Y . Ở hàng trên cùng, mối quan hệ thực sự gần như tuyến tính.

Trong trường hợp này, chúng ta thấy rằng MSE kiểm định cho hồi quy tuyến tính vẫn tốt hơn.




HÌNH 3.17. Đồ thị của $\hat{f}(X)$ sử dụng hồi quy KNN trên dữ liệu một chiều

Được thiết lập với 50 quan sát. Mỗi quan hệ thực sự được thể hiện bằng đường liền nét màu đen.

Bên trái: Đường cong màu xanh lam tương ứng với $K = 1$ và nội suy (tức là đi qua trực tiếp).

(thông qua) dữ liệu huấn luyện. Bên phải: Đường cong màu xanh lam tương ứng với $K = 9$, và thể hiện sự phù hợp mượt mà hơn.



HÌNH 3.18. Tập dữ liệu tương tự như trong Hình 3.17 được nghiên cứu sâu hơn.

Bên trái: Đường nét đứt màu xanh lam là đường khớp bình phương nhỏ nhất với dữ liệu. Vì $f(X)$ nằm trong Trên thực tế, đường thẳng (được hiển thị dưới dạng đường màu đen), đường hồi quy bình phương nhỏ nhất cung cấp một ước tính rất tốt về $f(X)$. Bên phải: Đường ngang đứt đoạn biểu thị


MSE của tập dữ liệu kiểm tra bình phương tối thiểu, trong khi đường liền màu xanh lá cây tương ứng với MSE.

Đối với KNN như một hàm của $1/K$ (trên thang logarit). Hồi quy tuyến tính đạt được

MSE kiểm thử thấp hơn so với hồi quy KNN, vì $f(X)$ thực chất là tuyến tính. Đối với KNN

Trong hồi quy, kết quả tốt nhất đạt được với giá trị K rất lớn, tương ứng với a

Giá trị nhỏ của $1/K$.



HÌNH 3.19. Góc trên bên trái: Trong một bối cảnh với mối quan hệ hồi phi tuyến tính

Giữa X và Y (đường màu đen liền nét), thuật toán KNN khớp với $K = 1$ (màu xanh lam) và $K = 9$.

(màu đỏ) được hiển thị. Góc trên bên phải: Đối với dữ liệu hồi phi tuyến tính, MSE của tập dữ liệu thử nghiệm đối với hồi quy bình phương tối thiểu (màu đen nằm ngang) và KNN với các giá trị khác nhau của $1/K$ (màu xanh lá cây) được hiển thị. Góc dưới bên trái và góc dưới bên phải: Giống như ở bảng trên, nhưng với mối quan hệ phi tuyến tính mạnh mẽ giữa X và Y .

so với KNN đối với các giá trị K thấp. Tuy nhiên, đối với $K \geq 4$, KNN hoạt động tốt hơn hồi quy tuyến tính. Hàng thứ hai minh họa điều này một cách rõ ràng hơn.

sai lệch so với tính tuyến tính. Trong trường hợp này, KNN hoạt động hiệu quả hơn đáng kể.

Hồi quy tuyến tính cho tất cả các giá trị của K . Lưu ý rằng mức độ phi tuyến tính tăng lên.

Khi tăng lên, MSE của tập dữ liệu kiểm thử hầu như không thay đổi đối với phương pháp phi tham số.

Phương pháp KNN, nhưng có sự gia tăng đáng kể về MSE trên tập dữ liệu kiểm thử của phương pháp tuyến tính. hồi quy.

Hình 3.18 và 3.19 minh họa các tình huống trong đó thuật toán KNN hoạt động kém hiệu quả hơn một chút.

Tệ hơn hồi quy tuyến tính khi mối quan hệ là tuyến tính, nhưng tốt hơn nhiều so với hồi quy tuyến tính trong các trường hợp phi tuyến tính. Trong một tình huống thực tế


Trong trường hợp mối quan hệ thực sự chưa được biết rõ, người ta có thể nghi ngờ rằng KNN

Nên ưu tiên phương pháp hồi quy tuyến tính hơn vì trong trường hợp xấu nhất thì sai số cũng chỉ hơi nhỏ.

kém hiệu quả hơn so với hồi quy tuyến tính nếu mối quan hệ thực sự là tuyến tính, và có thể dẫn đến kết quả không như mong muốn.

Kết quả sẽ tốt hơn đáng kể nếu mối quan hệ thực sự là phi tuyến tính. Nhưng trên thực tế, ngay cả khi mối quan hệ thực sự rất phi tuyến tính, KNN vẫn có thể...

cho kết quả kém hơn so với hồi quy tuyến tính. Cụ thể, cả Hình 3.18 đều như vậy.



HÌNH 3.20. Sai số bình phương trung bình (MSE) kiểm định cho hồi quy tuyến tính (đường nét đứt màu đen) và KNN (đường cong màu xanh lá cây) khi số lượng biến p tăng lên. Hàm thực sự không tuyến tính đối với biến đầu tiên, như trong bảng dưới của Hình 3.19, và không phụ thuộc vào các biến bổ sung. Hiệu suất của hồi quy tuyến tính giảm dần khi có sự xuất hiện của các biến nhiễu bổ sung này, trong khi hiệu suất của KNN giảm nhanh hơn nhiều khi p tăng lên.

Hình 3.19 minh họa các thiết lập với $p = 1$ biến dự đoán. Nhưng trong không gian nhiều chiều hơn, KNN thường hoạt động kém hơn so với hồi quy tuyến tính.

Hình 3.20 xem xét tình huống phi tuyến mạnh tương tự như ở hàng thứ hai của Hình 3.19, ngoại trừ việc chúng ta đã thêm các biến dự báo nhiễu bổ sung không liên quan đến phản hồi. Khi $p = 1$ hoặc $p = 2$, KNN hoạt động tốt hơn hồi quy tuyến tính. Nhưng đối với $p = 3$, kết quả không nhất quán, và đối với $p \geq 4$, hồi quy tuyến tính vượt trội hơn KNN. Trên thực tế, việc tăng chiều chỉ gây ra sự suy giảm nhỏ trong MSE của tập dữ liệu kiểm tra hồi quy tuyến tính, nhưng nó đã gây ra sự gia tăng hơn mười lần trong MSE của KNN. Sự suy giảm hiệu suất khi chiều tăng lên là một vấn đề phổ biến đối với KNN, và là kết quả của việc ở các chiều cao hơn, kích thước mẫu thực tế bị giảm. Trong tập dữ liệu này có 50 quan sát huấn luyện; khi $p = 1$, điều này cung cấp đủ thông tin để ước tính chính xác $f(X)$. Tuy nhiên, việc trải rộng 50 quan sát trên $p = 20$ chiều dẫn đến hiện tượng trong đó một quan sát nhất định không có hàng xóm gần đó - đây được gọi là lời nguyền của chiều không gian. Tức là, K quan sát gần nhất với một quan sát thử nghiệm x0 nhất định có thể nằm rất xa x0 trong không gian p chiều khi p lớn, dẫn đến dự đoán $f(x0)$ rất kém và do đó KNN không phù hợp. Theo nguyên tắc chung, các phương pháp tham số sẽ có xu hướng hoạt động tốt hơn các phương pháp phi tham số khi có ít quan sát trên mỗi biến dự đoán.

lời nguyền
của chiều không gian

Ngay cả khi kích thước nhỏ, chúng ta vẫn có thể ưu tiên hồi quy tuyến tính hơn KNN xét về khía cạnh khả năng giải thích. Nếu MSE kiểm định của KNN chỉ thấp hơn một chút so với hồi quy tuyến tính, chúng ta có thể sẵn sàng bỏ qua một chút độ chính xác dự đoán để đổi lấy một mô hình đơn giản có thể được mô tả chỉ bằng một vài hệ số, và có sẵn giá trị p .

3.6 Bài thực hành: Hồi quy tuyến tính

3.6.1 Nhập gói hàng

Chúng tôi nhập các thư viện tiêu chuẩn của mình ở cấp cao nhất này.

```
Trong [1]: import numpy as np
import pandas as pd from
matplotlib.pyplot import subplots
```

Hàng nhập khẩu mới

Trong suốt bài thực hành này, chúng ta sẽ giới thiệu các hàm và thư viện mới. Tuy nhiên, chúng ta sẽ nhập chúng vào đây để nhấn mạnh rằng đây là các đối tượng mã mới trong bài thực hành này. Việc đặt các câu lệnh nhập ở gần đầu notebook giúp mã dễ đọc hơn, vì chỉ cần quét vài dòng đầu tiên là chúng ta có thể biết được những thư viện nào đang được sử dụng.

```
Trong [2]: import statsmodels.api as sm
```

Chúng tôi sẽ cung cấp các thông tin chi tiết liên quan đến các chức năng bên dưới khi cần thiết.

Ngoài việc nhập toàn bộ mô-đun, bạn cũng có thể chỉ nhập một vài mục từ một mô-đun nhất định. Điều này sẽ giúp giữ cho không gian tên được gọn gàng. Chúng ta sẽ sử dụng một vài đối tượng cụ thể từ gói `statsmodels` mà chúng ta nhập khẩu ở đây.

không gian tên
mô hình thống kê

```
Trong [3]: từ statsmodels.stats.outliers_influence \
import variance_inflation_factor as VIF from
statsmodels.stats.anova import anova_lm
```

Vì một trong những câu lệnh nhập khẩu ở trên khá dài, chúng tôi đã chèn dấu xuống dòng \ để dễ đọc hơn.

Chúng ta cũng sẽ sử dụng một số hàm được viết cho các bài thực hành trong cuốn sách này.

Gói ISLP .

```
Trong [4]: from ISLP import load_data from
ISLP.models import (ModelSpec as MS, summarize, poly)
```

Kiểm tra các đối tượng và không gian tên

Hàm `dir()` cung cấp một danh sách các đối tượng trong một không gian tên.

`dir()`

```
Trong [5]: dir()
```

```
Ra[5]: ['Vào',
'MS',
'_',
'__',
'__builtins__',
'__builtins__',
...]
```

```
'poly',
'quit',
'sm',
'summarize']
```

Điều này cho bạn thấy mọi thứ mà `Python` có thể tìm thấy ở cấp cao nhất. Có một số đối tượng như `__builtins__` chứa các tham chiếu đến các hàm tích hợp sẵn như `print()`.

Mỗi đối tượng Python đều có khái niệm riêng về không gian tên, cũng có thể truy cập bằng `'dir()'`. Không gian tên này bao gồm cả các thuộc tính của đối tượng cũng như bất kỳ phương thức nào liên kết với nó. Ví dụ, ta thấy `'sum'` trong danh sách cho một mảng.

```
Trong [6]: A = np.array([3,5,11])
dir(A)
```

```
Out[6]: ...
'strides',
'sum',
'swapaxes',
...
```

Điều này cho thấy đối tượng `A.sum` tồn tại. Trong trường hợp này, nó là một phương thức có thể được sử dụng để tính tổng của mảng `A`, như có thể thấy bằng cách gõ `A.sum?`.

```
Trong [7]: A.sum()
```

```
Ra ngoài[7]: 19
```

3.6.2 Hồi quy tuyến tính đơn giản

Trong phần này, chúng ta sẽ xây dựng các ma trận mô hình (còn được gọi là ma trận thiết kế) bằng cách sử dụng phép biến đổi `ModelSpec()` từ `ISLP.models`.

Chúng ta sẽ sử dụng bộ dữ liệu nhà ở ở `Boston`, có trong gói `ISLP`. Bộ dữ liệu `Boston` ghi lại giá trị trung vị của nhà ở (`medv`) cho 506 khu dân cư xung quanh Boston. Chúng ta sẽ xây dựng một mô hình hồi quy để dự đoán `medv` bằng cách sử dụng 13 biến dự báo như `rmvar` (số phòng trung bình mỗi nhà), `age` (tỷ lệ các đơn vị nhà ở do chủ sở hữu tự ở được xây dựng trước năm 1940) và `lstat` (phần trăm hộ gia đình có tình trạng kinh tế xã hội thấp). Chúng ta sẽ sử dụng `statsmodels` cho nhiệm vụ này, một gói `Python` triển khai một số phương pháp hồi quy thường được sử dụng.

Chúng tôi đã tích hợp một hàm tải dữ liệu đơn giản có tên `load_data()` vào gói `ISLP`: `load_data()`

```
Trong [8]: Boston = load_data("Boston")
Boston.columns
```

```
Out[8]: Index(['crim', 'zn', 'indus', 'chas', 'nox', 'rm', 'age', 'dis', 'rad', 'tax',
'ptratio', 'black', 'lstat', 'medv'], dtype='object')
```

Nhập "Boston?" để tìm hiểu thêm về dữ liệu này.

Chúng ta bắt đầu bằng cách sử dụng hàm `sm.OLS()` để xây dựng mô hình hồi quy tuyến tính đơn giản. Biến phản hồi sẽ là `medv` và `lstat` sẽ là biến dự báo duy nhất. Với mô hình này, chúng ta có thể tự tạo ma trận mô hình bằng tay.

```
Trong [9]: X = pd.DataFrame({'intercept': np.ones(Boston.shape[0]),
                           'lstat': Boston['lstat']})
X[:4]
```

```
Ra ngoài[9]:      chặn lstat
0          1.0 4.98
1          1.0 9.14
2          1.0 4.03
3          1.0 2.94
```

Chúng tôi trích xuất phản hồi và điều chỉnh mô hình.

```
Trong [10]: y = Boston['medv']
model = sm.OLS(y, X)
results = model.fit()
```

Lưu ý rằng `sm.OLS()` không thực hiện việc khớp mô hình; nó chỉ định mô hình, và sau đó Phương thức `model.fit()` thực hiện việc khớp dữ liệu.

Hàm `summarize()` của `ISLP` tạo ra một bảng đơn giản gồm các ước lượng tham số, sai số chuẩn, thống kê t và giá trị p. Hàm này nhận một đối số duy nhất, chẳng hạn như đối tượng `results` được trả về ở đây bởi hàm đó. Phương thức `phù hợp` và trả về bản tóm tắt như vậy.

```
Trong [11]: tóm tắt (kết quả)
```

```
Ra ngoài[11]:          hệ số lỗi chuẩn          t P>|t|
hệ số chặn 34,5538 lstat -0,9500      0,563 61,415      0.0
              0,039 -24,528          0.0
```

Trước khi mô tả các phương pháp khác để làm việc với các mô hình đã được hiệu chỉnh, chúng ta Phác thảo một khuôn khổ tổng quát và hữu ích hơn để xây dựng ma trận mô hình X.

Sử dụng phép biến đổi: Điều chỉnh và biến đổi

Mô hình trên của chúng ta chỉ có một biến dự đoán, và việc xây dựng X khá đơn giản. Trong thực tế, chúng ta thường xây dựng các mô hình với nhiều hơn một biến dự đoán.

Thông thường được chọn từ một mảng hoặc khung dữ liệu. Chúng ta có thể muốn giới thiệu Các phép biến đổi đối với các biến trước khi hiệu chỉnh mô hình, xác định sự tương tác giữa các biến và mở rộng một số biến cụ thể thành các tập hợp.

các biến (ví dụ: đa thức). Gói `sklearn` có một khái niệm đặc biệt cho loại nhiệm vụ này: một phép biến đổi (`transform`). Phép biến đổi là một đối tượng được tạo ra với một số tham số làm đối số. Đối tượng này có hai phương thức chính: `fit()` và `transform()`.

Chúng tôi cung cấp một phương pháp tổng quát để xác định các mô hình và xây dựng ma trận mô hình thông qua phép biến đổi `ModelSpec()` trong thư viện `ISLP`. `ModelSpec()` (được đổi tên thành `MS()` trong phần mở đầu) tạo ra một đối tượng biến đổi, và sau đó một cặp phương thức `transform()` và `fit()` được sử dụng để xây dựng một ma trận mô hình tương ứng.

Trước tiên, chúng tôi mô tả quy trình này cho mô hình hồi quy đơn giản của mình bằng cách sử dụng...

LSTAT là biến dự đoán đơn lẻ trong khung dữ liệu Boston, nhưng sẽ được sử dụng lặp đi lặp lại.

Trong các nhiệm vụ phức tạp hơn trong bài thực hành này và các bài thực hành khác trong cuốn sách này. Trong trường hợp của chúng tôi là phép biến đổi được tạo bởi biểu thức `design = MS(['lstat'])`.

Phương thức `fit()` nhận mảng gốc và có thể thực hiện một số phép tính ban đầu trên đó, như đã được chỉ định trong đối tượng transform. Ví dụ, nó có thể tính toán giá trị trung bình và độ lệch chuẩn để căn giữa và chia tỷ lệ.

Phương thức `transform()` áp dụng phép biến đổi đã được điều chỉnh cho mảng dữ liệu và tạo ra ma trận mô hình.

```
Trong [12]: thiết_kế = MS(['lstat'])
          thiết_kế = thiết_kế.phù_hợp_với_Boston
          X = design.transform(Boston)
          X[:4]
```

```
Ra ngoài[12]:   chặn lstat
                0      1.0 4.98
                1      1.0 9.14
                2      1.0 4.03
                3      1.0 2.94
```

Trong trường hợp đơn giản này, phương thức `fit()` thực hiện rất ít thao tác; nó chỉ đơn giản là kiểm tra rằng Biến 'lstat' được chỉ định trong `thiết_kế` tồn tại ở Boston. Sau đó `transform()` Xây dựng ma trận mô hình với hai cột: hệ số chặn và biến lstat.

Hai thao tác này có thể được kết hợp bằng phương thức `fit_transform()`.

```
Trong [13]: thiết_kế = MS(['lstat'])
          X = design.fit_transform(Boston)
          X[:4]
```

.phù_hợp_
biến_đổi()

```
Ra ngoài[13]:   chặn lstat
                0      1.0 4.98
                1      1.0 9.14
                2      1.0 4.03
                3      1.0 2.94
```

Lưu ý rằng, tương tự như đoạn mã trước đó khi hai bước đã được thực hiện.

Nói riêng, đối tượng `thiết_kế` bị thay đổi do kết quả của thao tác `fit()`.

Sức mạnh của quy trình này sẽ trở nên rõ ràng hơn khi chúng ta tích hợp thêm các hệ thống phức tạp hơn. các mô hình liên quan đến sự tương tác và biến đổi.

Hãy quay lại với mô hình hồi quy đã được hiệu chỉnh của chúng ta. **Kết quả** đối tượng có một số các phương pháp có thể được sử dụng để suy luận. Chúng tôi đã trình bày một hàm

Hàm `summarize()` được sử dụng để hiển thị những điểm chính của sự phù hợp. Để có cái nhìn đầy đủ và chi tiết hơn, hãy sử dụng hàm `summarize()`.

Tóm tắt đầy đủ về sự phù hợp, chúng ta có thể sử dụng phương thức `summary()` (đầu ra).
(không hiển thị).

```
Trong [14]: results.summary()
```

Các hệ số đã được hiệu chỉnh cũng có thể được truy xuất thông qua thuộc tính `params` của `kết quả`.

```
Trong [15]: results.params
```


120

3. Hồi quy tuyến tính

```
Out[15]: chặn lstat      34.553841
          -0.950049
kiểu dữ liệu: float64
```

Phương thức `get_prediction()` có thể được sử dụng để lấy các dự đoán, và `.get_` tạo ra khoảng tin cậy và khoảng dự đoán cho dự đoán của `prediction()`.

`medv` cho các giá trị `lstat` đã cho.

Đầu tiên, chúng ta tạo một khung dữ liệu mới, trong trường hợp này chỉ chứa biến `lstat`, với các giá trị mà chúng ta muốn thực hiện cho biến này.

Các dự đoán. Sau đó, chúng ta sử dụng phương thức `transform()` của `thiết kế` để tạo ra. ma trận mô hình tương ứng.

```
Trong [16]: new_df = pd.DataFrame({'lstat':[5, 10, 15]})
newX = design.transform(new_df)
newX
```

```
Out[16]: chặn lstat
0      1.0      5
1      1.0     10
2      1.0     15
```

Tiếp theo, chúng ta tính toán các dự đoán tại `newX` và xem chúng bằng cách trích xuất. thuộc tính `predicted_mean`.

```
Trong [17]: new_predictions = results.get_prediction(newX);
new_predictions.predicted_mean
```

```
Out[17]: array([29.80359411, 25.05334734, 20.30310057])
```

Chúng ta có thể lập khoảng tin cậy cho các giá trị dự đoán.

```
Trong [18]: new_predictions.conf_int(alpha=0.05)
```

```
Out[18]: array([[29.00741194, 30.59977628],
 [24.47413202, 25.63256267],
 [19.73158815, 20.87461299]])
```

Khoảng dự đoán được tính toán bằng cách đặt `obs=True`:

```
Trong [19]: new_predictions.conf_int(obs=True, alpha=0.05)
```

```
Out[19]: array([[17.56567478, 42.04151344],
 [12.82762635, 37.27906833],
 [ 8.0777421 32.52845905]])
```

Ví dụ, khoảng tin cậy 95% liên quan đến giá trị `lstat` là

10 là (24,47, 25,63), và khoảng dự đoán 95% là (12,82, 37,28). Như

Như dự kiến, khoảng tin cậy và khoảng dự đoán tập trung xung quanh...

Cùng một điểm (giá trị dự đoán là 25,05 cho `medv` khi `lstat` bằng 10), nhưng Loại thứ hai rộng hơn đáng kể.

Tiếp theo, chúng ta sẽ vẽ biểu đồ `medv` và `lstat` bằng cách sử dụng

`DataFrame.plot.scatter()`, và muốn thêm đường hồi quy vào biểu đồ kết quả.

`.plot.scatter()`

Định nghĩa các hàm

Mặc dù gói `ISLP` đã có sẵn chức năng thêm đường vào biểu đồ hiện có, chúng ta sẽ tận dụng cơ hội này để định nghĩa hàm đầu tiên của riêng mình để thực hiện việc đó.

```
Trong [20]: def abline(ax, b, m):
            "Thêm một đường thẳng có độ dốc m và hệ số chặn b vào trục ax" xlim =
            ax.get_xlim() ylim = [m *
            xlim[0] + b, m * xlim[1] + b] ax.plot(xlim, ylim)
```

Một vài điều được minh họa ở trên. Đầu tiên, chúng ta thấy cú pháp để định nghĩa một hàm: `def funcname(...)`. Hàm này có các đối số `ax`, `b`, `m`, trong đó `ax` là đối tượng trục cho một đồ thị hiện có, `b` là điểm cắt trục tung và `m` là độ dốc của đường thẳng mong muốn. Các tùy chọn vẽ đồ thị khác có thể được truyền cho `ax.plot` bằng cách thêm các đối số tùy chọn bổ sung như sau:

```
Trong [21]: def abline(ax, b, m, *args, **kwargs): "Thêm một đường
            thẳng có độ dốc m và điểm cắt b vào trục ax" xlim = ax.get_xlim() ylim = [m
            * xlim[0] + b, m * xlim[1] +
            b] ax.plot(xlim, ylim, *args, **kwargs)
```

Việc thêm `*args` cho phép truyền bất kỳ số lượng đối số không được đặt tên nào cho hàm `abline`, trong khi `**kwargs` cho phép truyền bất kỳ số lượng đối số được đặt tên nào (ví dụ: `linewidth=3`) cho hàm `abline`. Trong hàm của chúng ta, chúng ta truyền các đối số này nguyên văn cho hàm `ax.plot` ở trên. Độc giả quan tâm đến việc tìm hiểu thêm về hàm có thể tham khảo phần định nghĩa hàm trong docs.python.org/tutorial.

Hãy sử dụng hàm mới của chúng ta để thêm đường hồi quy này vào biểu đồ `medv` so với `lstat`.

```
Trong [22]: ax = Boston.plot.scatter('lstat', 'medv') abline(ax,
            results.params[0], results.params[1],
            'r--', linewidth=3)
```

Do đó, lệnh gọi cuối cùng đến `ax.plot()` là `ax.plot(xlim, ylim, 'r--', linewidth=3)`. Chúng tôi đã sử dụng đối số `'r--'` để tạo ra một đường chấm đỏ, và thêm một đối số để làm cho nó có độ rộng là 3. Có một số bằng chứng cho thấy mối quan hệ giữa `lstat` và `medv` không tuyến tính. Chúng ta sẽ tìm hiểu vấn đề này kỹ hơn trong bài thực hành này.

Như đã đề cập ở trên, đã có sẵn một hàm để thêm đường thẳng vào đồ thị – `ax.axline()` – nhưng việc biết cách viết các hàm như vậy sẽ giúp chúng ta tạo ra các hiển thị biểu cảm hơn.

Tiếp theo, chúng ta xem xét một số biểu đồ chẩn đoán, một số trong đó đã được thảo luận trong Phần 3.3.3. Chúng ta có thể tìm thấy các giá trị phù hợp và phần dư của phép phù hợp dưới dạng thuộc tính của đối tượng `kết quả`. Nhiều thước đo ảnh hưởng mô tả mô hình hồi quy được tính toán bằng phương thức `get_influence()`. Vì chúng ta sẽ không sử dụng thành phần `fig` được trả về làm giá trị đầu tiên từ `subplots()`, nên chúng ta chỉ đơn giản là lấy giá trị thứ hai được trả về trong `ax` `.get_influence()` bên dưới.

```
Trong [23]: ax = subplots(figsize=(8,8))[1]
```

```
ax.scatter(results.fittedvalues ax.set_xlabel(' ', results.resid)
Giá trị phù hợp')
ax.set_ylabel('Phần dư')
ax.axhline(0, c='k', ls='--');
```

Chúng ta thêm một đường ngang tại vị trí 0 để tham chiếu bằng phương thức `ax.axhline()` , cho biết đường này nên có màu đen (`c='k'`) và kiểu đường nét đứt (`ls='--'`).
Dựa trên biểu đồ phần dư (không hiển thị), có một số bằng chứng cho thấy của tính phi tuyến tính. Thống kê đòn bẩy có thể được tính toán cho bất kỳ số lượng nào. các bộ dự đoán sử dụng thuộc tính `hat_matrix_diag` của giá trị được trả về bởi Phương thức `get_influence()` .

```
Trong [24]: infl = results.get_influence()
ax = subplots(figsize=(8,8))[1]
ax.scatter(np.arange(X.shape[0]), infl.hat_matrix_diag)
ax.set_xlabel('Chỉ mục')
ax.set_ylabel('Đòn bẩy')
np.argmax(infl.hat_matrix_diag)
```

Ra ngoài[24]: 374

Hàm `np.argmax()` xác định chỉ số của phần tử lớn nhất trong một mảng, tùy chọn được tính toán trên một trục của mảng. Trong trường hợp này, chúng ta đã tối đa hóa trên toàn bộ mảng để xác định quan sát nào có giá trị lớn nhất.
Thống kê đòn bẩy.

3.6.3 Hồi quy tuyến tính bội

Để xây dựng mô hình hồi quy tuyến tính bội bằng phương pháp bình phương tối thiểu, chúng ta Sử dụng lại phép biến đổi `ModelSpec()` để xây dựng ma trận mô hình cần thiết. và phản hồi. Các đối số của `ModelSpec()` có thể khá tổng quát, nhưng trong Trong trường hợp này, chỉ cần một danh sách tên cột là đủ. Chúng ta xem xét sự phù hợp ở đây với hai cột. các biến `lstat` và `tuổi`.

```
Trong [25]: X = MS(['lstat', 'age']).fit_transform(Boston)
modell = sm.OLS(y, X)
results1 = modell.fit()
tóm tắt (kết quả)
```

Ra ngoài[25]:

	hệ số lỗi chuẩn	t	P> t
hệ số chặn	33.2228	lstat -1.0321	0.731 45.458 0.000
			0,048 -21,416 0,000
tuổi	0,0345	0,012	2,826 0,005

Hãy chú ý cách chúng ta đã rút gọn dòng đầu tiên thành một biểu thức ngắn gọn.
Mô tả quá trình xây dựng X.
Bộ dữ liệu `Boston` chứa 12 biến, vì vậy việc xử lý sẽ rất rắc rối.
Phải gõ tất cả những thông tin này để thực hiện hồi quy bằng cách sử dụng tất cả các tham số. các yếu tố dự báo. Thay vào đó, chúng ta có thể sử dụng cách viết tắt sau:

```
Trong [26]: terms = Boston.columns.drop('medv')
các điều khoản
```

.cột.
làm rơi()

```
Out[26]: Index(['crim', 'zn', 'indus', 'chas', 'nox', 'rm', 'age', 'dis',
              'rad', 'tax', 'ptratio', 'lstat'],
              dtype='object')
```

Giờ đây, chúng ta có thể điều chỉnh mô hình với tất cả các biến theo cùng một cách .
công cụ xây dựng ma trận mô hình.

```
Trong [27]: X = MS(terms).fit_transform(Boston)

model = sm.OLS(y, X)
results = model.fit()

tóm tắt (kết quả)
```

Ra ngoài[27]:

	hệ số lỗi chuẩn	t	P> t
chặn 41,6173 tội phạm	-0,1214	4,936 8,431 0,000	
		0,033 -3,678 0,000	
kẽm	0,0470	0,014 3,384 0,001	
indus	0,0135	0,062 0,217 0,829	
chas	2.8400	0,870 3,264 0,001	
nox	-18.7580	3,851 -4,870 0,000	
rm	3.6581	0,420 8,705 0,000	
tuổi	0,0036	0,013 0,271 0,787	
tác	-1,4908	0,202 -7,394 0,000	
rad	0.2894	0,067 4,325 0,000	
thuế	-0,0127	0,004 -3,337 0,001	
ptratio	-0.9375	0,132 -7,091 0,000	
lstat	-0.5520	0,051 -10,897 0,000	

Nếu chúng ta muốn thực hiện hồi quy bằng cách sử dụng tất cả các biến nhưng...
một? Ví dụ, trong kết quả hồi quy ở trên, **tuổi** có giá trị p cao.
Vì vậy, chúng ta có thể muốn chạy hồi quy mà không bao gồm biến dự báo này. Như sau:
Kết quả cú pháp dẫn đến phép hồi quy sử dụng tất cả các biến dự đoán ngoại trừ **tuổi** (đầu ra không phải là...)
(như hình minh họa).

```
Trong [28]: minus_age = Boston.columns.drop(['medv', 'age'])

Xma = MS(minus_age).fit_transform(Boston)

model1 = sm.OLS(y, Xma)

summarize(model1.fit())
```

3.6.4 Kiểm định độ phù hợp đa biến

Chúng ta có thể truy cập các thành phần riêng lẻ của **kết quả** theo tên (`dir(results)`)
(cho chúng ta biết những gì có sẵn). Do đó , **results.rsquared** cung cấp cho chúng ta R2, và
`np.sqrt(results.scale)` cho ta RSE.

Hệ số khuếch đại phương sai (mục 3.3.3) đôi khi hữu ích để đánh giá
ảnh hưởng của hiện tượng đa cộng tuyến trong ma trận mô hình của một mô hình hồi quy. Chúng ta sẽ
Tính toán các hệ số VIF trong mô hình hồi quy đa biến của chúng ta và tận dụng cơ hội này.
Để giới thiệu khái niệm về list comprehension.

danh sách hiểu

Đọc hiểu danh sách

Thường thì chúng ta bắt gặp một chuỗi các đối tượng mà chúng ta muốn biến đổi.
cho một số nhiệm vụ khác. Bên dưới, chúng ta tính toán VIF cho từng đặc trưng trong **X** của chúng ta.
ma trận và tạo ra một khung dữ liệu có chỉ số trùng khớp với các cột của ma trận đó.
X. Khái niệm về list comprehension thường có thể giúp công việc này trở nên dễ dàng hơn.

List comprehensions là một cách đơn giản và mạnh mẽ để tạo danh sách trong Python. các đối tượng. Ngôn ngữ này cũng hỗ trợ hiểu từ điển và hiểu trình tạo , mặc dù những điều này nằm ngoài phạm vi thảo luận ở đây. Hãy xem một ví dụ. Chúng tôi tính toán hệ số VIF cho từng biến trong ma trận mô hình X, bằng cách sử dụng hàm `variance_inflation_factor()`.

Trong [29]:

```
vals = [VIF(X, i)
         for i in range(1, X.shape[1])]
vif = pd.DataFrame({'vif':vals},
                   index=X.columns[1:])
vif
```

phương sai_
lạm phát_
nhân tố()

Ra ngoài[29]:

```
          vif
tôi phạm   1,767
kém        2,298
indus 3.987
chas       1.071
nox        4,369
rm         1,913
tuổi       3.088
tác        3,954
rad        7.445
thuế       9.002

ptratio 1.797
lstat 2.871
```

Hàm `VIF()` nhận hai đối số: một dataframe hoặc mảng, và một chỉ số cột có thể thay đổi. Trong đoạn mã trên, chúng ta gọi hàm `VIF()` trực tiếp cho tất cả các cột. Trong X. Chúng ta đã loại bỏ cột 0 ở trên (hệ số chặn), vì nó không quan trọng. Trong trường hợp này, các hệ số VIF không mấy thú vị.

Các giá trị đối tượng ở trên có thể được tạo ra bằng cách sau:

vòng lặp for:

Trong [30]:

```
vals = []
for i in range(1, X.values.shape[1]):
    vals.append(VIF(X.values, i))
```

List comprehension cho phép chúng ta thực hiện các thao tác lặp đi lặp lại như vậy một cách tuần tự. Cách đơn giản hơn.

3.6.5 Các thuật ngữ tương tác

Việc đưa các thuật ngữ tương tác vào mô hình tuyến tính rất dễ dàng bằng cách sử dụng `ModelSpec()`. Việc bao gồm một bộ giá trị ("`lstat`", "`age`") cho trình tạo ma trận mô hình biết cần bao gồm một thuật ngữ tương tác giữa `lstat` và `tuổi tác`.

Trong [31]:

```
X = MS(['lstat',
        'tuổi',
        ('lstat', 'age')]).fit_transform(Boston)
model2 = sm.OLS(y, X)
tóm tắt(model2.fit())
```

Ra ngoài[31]:

```
          hệ số lỗi chuẩn          t P>|t|
hệ số chặn 36.0885 lstat -1.3921    1.470 24.553 0.000
          0,167 -8,313 0,000
```

```
tuổi -0.0007      0,020 -0,036 0,971
lstat:tuổi 0.0042    0,002 2,244 0,025
```

3.6.6 Biến đổi phi tuyến tính của các biến dự báo

Công cụ xây dựng ma trận mô hình có thể bao gồm các thuật ngữ ngoài tên cột và tương tác. Ví dụ, hàm `poly()` được cung cấp trong ISLP chỉ định rằng các cột biểu diễn các hàm đa thức của đối số đầu tiên của nó là `tuổi` đã được thêm vào ma trận mô hình.

```
Trong [32]: X = MS([poly('lstat', degree=2), 'age']).fit_transform(Boston)
model3 = sm.OLS(y, X)
results3 = model3.fit()
tóm tắt (kết quả3)
```

Ra ngoài[32]:		hệ số	lỗi chuẩn	t	P> t
	hệ số chặn	17.7151	0.781 22.681		0,000
	<code>poly(lstat, degree=2)[0]</code>	-179.2279	6,733 -26,620		0,000
		72.9908	5.482 13.315		0,000
		0,0703	0,011 6.471		0,000

Giá trị p gần bằng 0 liên quan đến số hạng bậc hai (tức là (hàng thứ ba ở trên) cho thấy điều đó dẫn đến một mô hình được cải tiến. Theo mặc định, hàm `poly()` tạo ra một ma trận cơ sở để đưa vào ma trận mô hình, trong đó các cột là các đa thức trực giao, được thiết kế để ổn định và trực giao. các phép tính bình phương tối thiểu có thể.13 Ngoài ra, nếu chúng ta bao gồm một đối số `raw = True` trong lệnh gọi `poly()` ở trên, ma trận cơ sở sẽ bao gồm đơn giản là `lstat` và `lstat**2`. Vì một trong hai cơ sở này biểu diễn bậc hai Đối với đa thức, các giá trị được ước tính sẽ không thay đổi trong trường hợp này, chỉ có các hệ số đa thức thay đổi. Ngoài ra, theo mặc định, các cột được tạo bởi hàm `poly()` không Bao gồm một cột hệ số chặn vì cột đó được `MS()` tự động thêm vào. Chúng tôi sử dụng hàm `anova_lm()` để định lượng thêm mức độ mà Phương pháp khớp bậc hai cho kết quả tốt hơn phương pháp khớp tuyến tính.

```
Trong [33]: anova_lm(results1, results3)
```

Ra ngoài[33]:	df_resid	SSR	df_diff	ss_diff	F	Pr(>F)
0	503.0	19168.13	502.0	0.0	NaN	NaN
1	14165.61		1.0	5002.52	177.28	7.47e-35

Ở đây, `results1` biểu thị mô hình con tuyến tính chứa các biến dự đoán `lstat` và `tuổi tác`, trong khi `results3` tương ứng với mô hình lớn hơn ở trên với một Hệ số bậc hai trong `lstat`. Hàm `anova_lm()` thực hiện kiểm định giả thuyết. kiểm tra so sánh hai mô hình. Giả thuyết null là phương trình bậc hai Thuật ngữ trong mô hình lớn hơn không cần thiết, và giả thuyết thay thế là Điều đó có nghĩa là mô hình lớn hơn vượt trội hơn. Ở đây, chỉ số F là 177,28 và Giá trị p tương ứng bằng 0. Trong trường hợp này, thống kê F là bình phương của giá trị p đó. Thống kê t cho số hạng bậc hai trong tóm tắt mô hình tuyến tính cho `kết quả3` – hậu quả của việc các mô hình lồng nhau này khác nhau một bậc.

13Thực ra, `poly()` là một hàm bao bọc cho hàm chính và độc lập `Poly()`. Điều đó giúp xây dựng ma trận mô hình.

tự do. Điều này cung cấp bằng chứng rất rõ ràng rằng đa thức bậc hai

Trong `lstat` , việc cải thiện mô hình tuyến tính không có gì đáng ngạc nhiên, vì trước đó chúng ta đã tìm thấy bằng chứng về tính phi tuyến tính trong mối quan hệ giữa `medv` và `lstat`.

Hàm `anova_lm()` có thể nhận nhiều hơn hai mô hình lồng nhau làm đầu vào.

Trong trường hợp đó, nó so sánh từng cặp mô hình kế tiếp nhau. Điều đó cũng giải thích tại sao. Tại sao lại có các giá trị NaN ở hàng đầu tiên phía trên, trong khi không có mô hình trước đó? Để so sánh với cái đầu tiên.

```
Trong [34]: ax = subplots(figsize=(8,8))[1]
ax.scatter(results3.fittedvalues ax.set_xlabel(' results3.resid)
Giá trị phù hợp')
ax.set_ylabel('Phần dư')
ax.axhline(0, c='k', ls='--')
```

Chúng ta thấy rằng khi đưa số hạng bậc hai vào mô hình, thì sẽ có

Không có mô hình nào rõ ràng trong phần dư. Để tạo ra một khối lập phương hoặc

Để khớp đa thức bậc cao hơn, chúng ta chỉ cần thay đổi đối số bậc thành...

`đa thức()`.

3.6.7 Các yếu tố dự báo định tính

Ở đây chúng tôi sử dụng dữ liệu về ghế ngồi ô tô trẻ em , được bao gồm trong gói `ISLP` . Chúng tôi sẽ cố gắng dự đoán doanh số bán hàng (doanh số bán ghế ngồi ô tô cho trẻ em) tại 400 địa điểm dựa trên dựa trên một số yếu tố dự báo.

```
Trong [35]: Carseats = load_data('Carseats')
Cột ghế ô tô
```

```
Out[35]: Index(['Sales', 'CompPrice', 'Income', 'Advertising',
              'Dân số', 'Giá cả', 'Vị trí kệ', 'Tuổi', 'Học vấn',
              'Đô thị', 'Mỹ'],
              dtype='object')
```

Dữ liệu về ghế ngồi ô tô bao gồm các yếu tố dự báo định tính như `ShelveLoc`, một chỉ số đánh giá chất lượng vị trí đặt kệ – tức là không gian bên trong một cửa hàng trưng bày ghế ngồi ô tô. Công cụ dự đoán `ShelveLoc` đảm nhận vai trò này.

Ba giá trị có thể là: Xấu, Trung bình và Tốt. Cho một biến định tính.

Ví dụ như `ShelveLoc`, `ModelSpec()` tự động tạo ra các biến giả.

Các biến này thường được gọi là mã hóa one-hot của đặc trưng phân loại. Tổng các cột của chúng bằng một, vì vậy để tránh hiện tượng đa cộng tuyến với hệ số chặn, cột đầu tiên bị loại bỏ. Bên dưới chúng ta thấy cột `ShelveLoc[Bad]` đã bị loại bỏ, vì `Bad` là cấp độ đầu tiên của `ShelveLoc`. Bên dưới chúng ta sẽ đặt một Mô hình hồi quy đa biến bao gồm một số thuật ngữ tương tác.

một nóng
mã hóa

```
Trong [36]: allvars = list(Carseats.columns.drop('Sales'))
y = Carseats['Sales']
final = allvars + [('Thu nhập', 'Quảng cáo'),
                  ('Giá', 'Tuổi')]
X = MS(final).fit_transform(Carseats)
model = sm.OLS(y, X)
tóm tắt(model.fit())
```

Ra ngoài[36]:	hệ số lỗi chuẩn	t	P> t
chặn	6.5756	1.009	6,519
			0,000

Giá so sánh	0,0929	0,004	22,567	0,003	0,000
Thu nhập	0,0109	4,183			0,000
Quảng cáo	0,0702	0,023	3.107		0,002
Dân số	0,0002	0,000	0.433		0.665
Giá	-0,1008	0,007	-13,549		0,000
ShelveLoc[Tốt]	4.8487	0,153	31,724		0,000
ShelveLoc[Trung bình]	1,9533	0.126	15.531		0,000
Tuổi	-0,0579	0,016	-3,633		0,000
Giáo dục	-0,0209	0,020	-1,063		0.288
Đô thị[Có]	0.1402	0.112	1.247		0.213
Mỹ[Có]	-0.1576	0,149	-1,058		0.291
Thu nhập: Quảng cáo	0,0008	0,000	2,698		0,007
Giá:Tuổi	0,0001	0,000	0.801		0.424

Ở dòng đầu tiên phía trên, chúng ta đã biến `allvars` thành một danh sách, để chúng ta có thể thêm các điều khoản tương tác ở hai dòng bên dưới. Công cụ xây dựng ma trận mô hình của chúng tôi đã tạo ra một **Biến giá** `ShelveLoc[Good]` nhận giá trị 1 nếu kệ Vị trí tốt, còn lại là 0. Nó cũng đã tạo ra một `ShelveLoc[Medium]` Biến giá có giá trị bằng 1 nếu vị trí kệ ở mức trung bình, và bằng 0 trong các trường hợp khác. Vị trí kệ không tốt tương ứng với giá trị 0 cho cả hai biến. các biến giá. Thực tế là hệ số cho `ShelveLoc[Good]` trong Kết quả hồi quy dương cho thấy vị trí trưng bày sản phẩm tốt có liên quan đến doanh số bán hàng cao (so với vị trí trưng bày không tốt). Và `ShelveLoc[Medium]` có hệ số dương nhỏ hơn, cho thấy vị trí kệ hàng trung bình dẫn đến doanh số cao hơn so với vị trí kệ hàng kém, nhưng doanh số thấp hơn so với Vị trí đặt kệ tốt.

3.7 Bài tập

Khái niệm

1. Mô tả giả thuyết không (null hypothesis) mà các giá trị p được đưa ra trong Bảng 3.4 áp dụng. Tương ứng. Hãy giải thích những kết luận bạn có thể rút ra dựa trên những điều này. giá trị p. Lời giải thích của bạn nên được diễn đạt dưới dạng doanh số bán hàng, truyền hình, đài phát thanh và báo chí, chứ không phải xét về hệ số của mô hình tuyến tính.
2. Hãy giải thích cẩn thận sự khác biệt giữa bộ phân loại KNN và KNN các phương pháp hồi quy.
3. Giả sử chúng ta có một tập dữ liệu với năm biến dự đoán, X_1 = GPA, X_2 = IQ, X_3 = Cấp độ (1 cho Đại học và 0 cho Trung học), X_4 = Tương tác giữa GPA và IQ, và X_5 = Tương tác giữa GPA và Cấp bậc. Câu trả lời là mức lương khởi điểm sau khi tốt nghiệp (đơn vị nghìn đô la). (tính bằng đô la). Giả sử chúng ta sử dụng phương pháp bình phương nhỏ nhất để khớp mô hình và nhận được $\beta^0 = 50$, $\beta^1 = 20$, $\beta^2 = 0,07$, $\beta^3 = 35$, $\beta^4 = 0,01$, $\beta^5 = 10$.
- (a) Câu trả lời nào sau đây là đúng và tại sao?
- i. Với cùng một giá trị IQ và GPA, học sinh tốt nghiệp trung học phổ thông sẽ kiếm được...

Trung bình, số tiền này nhiều hơn số tiền mà sinh viên tốt nghiệp đại học có được.
- ii. Với cùng một giá trị IQ và GPA, sinh viên tốt nghiệp đại học sẽ kiếm được

Trung bình, số người tốt nghiệp trung học phổ thông có thu nhập cao hơn số người tốt nghiệp trung học.

3. Hồi quy tuyến tính

iii. Với cùng một giá trị IQ và GPA, trung bình, học sinh tốt nghiệp trung học kiểm được nhiều tiền hơn so với sinh viên tốt nghiệp đại học, với điều kiện điểm GPA đủ cao.

iv. Với cùng một giá trị IQ và GPA, trung bình, sinh viên tốt nghiệp đại học kiểm được nhiều tiền hơn so với người tốt nghiệp trung học, với điều kiện GPA đủ cao. (b) Dự đoán

mức lương của một sinh viên tốt nghiệp đại học có IQ là 110 và GPA là 4.0.

(c) Đúng hay sai: Vì hệ số của số hạng tương tác GPA/IQ rất nhỏ, nên có rất ít bằng chứng về hiệu ứng tương tác. Hãy giải thích câu trả lời của bạn.

4. Tôi thu thập một tập dữ liệu ($n = 100$ quan sát) chứa một biến dự báo duy nhất và một biến phản hồi định lượng. Sau đó, tôi áp dụng mô hình hồi quy tuyến tính cho dữ liệu, cũng như một mô hình hồi quy bậc ba riêng biệt, tức là $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$.

(a) Giả sử mối quan hệ thực sự giữa X và Y là tuyến tính, tức là $Y = \beta_0 + \beta_1 X + \epsilon$. Hãy xem xét tổng bình phương phần dư huấn luyện (RSS) cho hồi quy tuyến tính, và cả RSS huấn luyện cho hồi quy bậc ba. Liệu ta có kỳ vọng một giá trị sẽ thấp hơn giá trị kia, liệu chúng sẽ bằng nhau, hay không có đủ thông tin để kết luận? Hãy giải thích câu trả lời của bạn.

(b) Trả lời câu (a) bằng cách sử dụng RSS kiểm tra thay vì RSS

huấn luyện. (c) Giả sử mối quan hệ thực sự giữa X và Y không phải là tuyến tính, nhưng chúng ta không biết nó cách xa tuyến tính bao nhiêu. Hãy xem xét RSS huấn luyện cho hồi quy tuyến tính, và cả RSS huấn luyện cho hồi quy bậc ba. Liệu chúng ta có mong đợi một giá trị sẽ thấp hơn giá trị kia, liệu chúng ta có mong đợi chúng bằng nhau, hay không có đủ thông tin để kết luận? Hãy giải thích câu trả lời của bạn. (d) Trả lời câu (c) bằng

cách sử dụng RSS kiểm tra thay vì RSS huấn luyện.

5. Hãy xem xét các giá trị dự đoán thu được từ việc thực hiện hồi quy tuyến tính không có hệ số chặn. Trong trường hợp này, giá trị dự đoán thứ i có dạng như sau:

$$\hat{y}_i = x_i \hat{\beta},$$

Ở đâu

$$\hat{\beta} = \frac{\sum_{i=1}^N x_i y_i}{\sum_{i=1}^N x_i^2}. \quad (3.38)$$

Hãy chứng minh rằng chúng ta có thể viết

$$\hat{y}_i = \sum_{j=1}^N a_{ij} y_j.$$

Trị tuế nhân tạo là gì?

Lưu ý: Chúng tôi diễn giải kết quả này bằng cách nói rằng các giá trị dự đoán từ hồi quy tuyến tính là tổ hợp tuyến tính của các giá trị phản hồi.

6. Sử dụng (3.4), hãy lập luận rằng trong trường hợp hồi quy tuyến tính đơn giản, đường hồi quy bình phương nhỏ nhất luôn đi qua điểm $(\bar{x}, \bar{y})$.
7. Trong văn bản có khẳng định rằng trong trường hợp hồi quy tuyến tính đơn giản của Y lên X , tổng kê R^2 (3.17) bằng bình phương của hệ số tương quan giữa X và Y (3.18). Hãy chứng minh điều này là đúng. Để đơn giản, bạn có thể giả sử rằng $\bar{x} = \bar{y} = 0$.



Đã áp dụng

8. Câu hỏi này liên quan đến việc sử dụng hồi quy tuyến tính đơn giản trên biến **Auto** tập dữ liệu.

- (a) Sử dụng hàm `sm.OLS()` để thực hiện hồi quy tuyến tính đơn giản với `mpg` là biến phản hồi và `horsepower` là biến dự đoán. Sử dụng hàm `summarize()` để in kết quả. Nhận xét về kết quả đầu ra. Ví dụ:

i. Có mối quan hệ nào giữa biến dự báo và biến kết quả không?

câu trả lời?

ii. Mối quan hệ giữa biến dự báo và biến phản hồi mạnh đến mức nào?

iii. Mối quan hệ giữa biến dự báo và biến phản hồi là gì?

Tích cực hay tiêu cực?

iv. Mức tiêu hao nhiên liệu (`mpg`) dự đoán tương ứng với công suất 98 mã lực là bao nhiêu? Khoảng tin cậy 95% và khoảng dự đoán tương ứng là bao nhiêu?

- (b) Vẽ đồ thị biến phản hồi và biến dự đoán trên một hệ trục tọa độ mới `ax`. Sử dụng phương thức `ax.axline()` hoặc hàm `abline()` được định nghĩa trong bài thực hành để hiển thị đường hồi quy bình phương nhỏ nhất. (c) Tạo một số

đồ thị chẩn đoán về sự phù hợp của hồi quy bình phương nhỏ nhất như đã mô tả trong bài thực hành. Nhận xét về bất kỳ vấn đề nào bạn thấy với sự phù hợp này.

9. Câu hỏi này liên quan đến việc sử dụng hồi quy tuyến tính bội trên dữ liệu. Bộ dữ liệu `tự động`.

- (a) Lập ma trận biểu đồ phân tán bao gồm tất cả các biến. trong tập dữ liệu.

- (b) Tính ma trận tương quan giữa các biến bằng cách sử dụng phương thức `DataFrame.corr()`.

`.corr()`

- (c) Sử dụng hàm `sm.OLS()` để thực hiện hồi quy tuyến tính bội với `mpg` là biến phản hồi và tất cả các biến khác ngoại trừ `name` là biến dự đoán. Sử dụng hàm `summarize()` để in kết quả.

Nhận xét về kết quả đầu ra. Ví dụ:

i. Có mối quan hệ nào giữa các biến dự đoán và biến phản hồi không? Hãy sử dụng hàm `anova_lm()` từ thư viện `statsmodels` để trả lời câu hỏi này.

3. Hồi quy tuyến tính

ii. Những yếu tố dự báo nào có vẻ có mối quan hệ thống kê đáng kể với kết quả?

iii. Hệ số của biến **năm** cho thấy điều gì?

(d) Hãy lập một số biểu đồ chẩn đoán về sự phù hợp của hồi quy tuyến tính như đã mô tả trong bài thực hành. Nhận xét về bất kỳ vấn đề nào bạn thấy với sự phù hợp đó. Biểu đồ phần dư có cho thấy bất kỳ giá trị ngoại lệ nào lớn bất thường không? Biểu đồ đòn bẩy có xác định được bất kỳ quan sát nào có đòn bẩy cao bất thường không?

(e) Hãy thử xây dựng một số mô hình có tương tác như đã mô tả trong bài thực hành. Có tương tác nào có ý nghĩa thống kê không?

(f) Hãy thử một vài phép biến đổi khác nhau của các biến, chẳng hạn như $\log(X)$, $\sqrt{X}$, X^2 . Nhận xét về kết quả bạn thu được.

10. Câu hỏi này cần được trả lời bằng cách sử dụng bộ dữ liệu **Carseats**.

(a) Xây dựng mô hình hồi quy đa biến để dự đoán **Doanh số** dựa trên **Giá cả**, **Khu vực đô thị** và **Hoa Kỳ**.

(b) Giải thích ý nghĩa của từng hệ số trong mô hình. Hãy cẩn thận—một số biến trong mô hình là biến định tính! (c) Viết mô hình dưới dạng phương

trình, lưu ý cách xử lý

các biến định tính một cách chính xác.

(d) Với những biến dự báo nào bạn có thể bác bỏ giả thuyết không $H_0: \beta_j = 0$? (e) Dựa

trên câu trả

lời của bạn cho câu hỏi trước, hãy xây dựng một mô hình nhỏ hơn chỉ sử dụng các biến dự báo mà có bằng chứng về mối liên hệ với kết quả.

(f) Các mô hình trong (a) và (e) phù hợp với dữ liệu tốt đến

mức nào? (g) Sử dụng mô hình từ (e), hãy tính khoảng tin cậy 95% cho hệ số(các hệ số). (h)

Có bằng chứng nào về các giá trị ngoại lệ hoặc các quan sát có tác động lớn trong mô hình từ (e) không?

11. Trong bài toán này, chúng ta sẽ khảo sát thống kê t cho giả thuyết không $H_0: \beta = 0$ trong hồi quy tuyến tính đơn giản không có hệ số chặn. Để bắt đầu, chúng ta tạo ra biến dự đoán **x** và biến phản hồi **y** như sau.

```
rng = np.random.default_rng(1)
x = rng.normal(size=100)
y = 2 * x + rng.normal(size=100)
```

(a) Thực hiện hồi quy tuyến tính đơn giản của **y** theo **x**, không có hệ số chặn. Báo cáo ước lượng hệ số $\hat{\beta}$, sai số chuẩn của ước lượng hệ số này, và thống kê t và giá trị p liên quan đến giả thuyết không $H_0: \beta = 0$. Nhận xét về các kết quả này. (Bạn có thể thực hiện hồi quy không có hệ số chặn bằng cách sử dụng đối số từ khóa **intercept=False** cho **ModelSpec()**.)

- (b) Bây giờ hãy thực hiện hồi quy tuyến tính đơn giản của x theo y mà không có hệ số chặn, và báo cáo ước lượng hệ số, sai số chuẩn của nó, và giá trị thống kê t và giá trị p tương ứng liên quan đến giả thuyết không $H_0: \beta = 0$. Nhận xét về các kết quả này.
- (c) Mối quan hệ giữa các kết quả thu được ở (a) và là gì? (b)?
- (d) Đối với hồi quy của Y lên X mà không có hệ số chặn, thống kê t cho $H_0: \beta = 0$ có dạng $\hat{\beta} / SE(\hat{\beta})$, trong đó $\hat{\beta}$ được cho bởi (3.38), và trong đó



$$SE(\hat{\beta}) = \frac{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2}}{\sqrt{\sum_{i=1}^n x_i^2}}$$

(Các công thức này hơi khác so với các công thức được đưa ra trong Phần 3.1.1 và 3.1.2, vì ở đây chúng ta đang thực hiện hồi quy mà không có hệ số chặn.) Hãy chứng minh bằng đại số và xác nhận bằng số học trong R rằng thống kê t có thể được viết như sau:

$$\frac{(\sqrt{n-1}) \sum_{i=1}^n x_i y_i}{\sqrt{(\sum_{i=1}^n x_i^2)(\sum_{i=1}^n y_i^2) - (\sum_{i=1}^n x_i y_i)^2}}$$

- (e) Dựa vào kết quả từ (d), hãy lập luận rằng thống kê t cho hồi quy y theo x giống với thống kê t cho hồi quy x theo y .
- (f) Trong R, hãy chứng minh rằng khi thực hiện hồi quy với hệ số chặn, thống kê t cho $H_0: \beta_1 = 0$ là như nhau đối với hồi quy của y theo x và hồi quy của x theo y .
12. Bài toán này liên quan đến hồi quy tuyến tính đơn giản không có hệ số chặn.
- (a) Nhớ lại rằng ước lượng hệ số $\hat{\beta}$ cho hồi quy tuyến tính của Y trên X không có hệ số chặn được cho bởi (3.38). Trong trường hợp nào thì ước lượng hệ số cho hồi quy của X trên Y giống với ước lượng hệ số cho hồi quy của Y trên X ?
- (b) Hãy tạo một ví dụ bằng Python với $n = 100$ quan sát trong đó ước lượng hệ số cho hồi quy của X lên Y khác với ước lượng hệ số cho hồi quy của Y lên X .
- (c) Hãy tạo một ví dụ bằng Python với $n = 100$ quan sát trong đó ước lượng hệ số cho hồi quy của X lên Y giống với ước lượng hệ số cho hồi quy của Y lên X .

13. Trong bài tập này, bạn sẽ tạo một số dữ liệu mô phỏng và áp dụng các mô hình hồi quy tuyến tính đơn giản cho chúng. Hãy đảm bảo sử dụng trình tạo số ngẫu nhiên mặc định với hạt giống được đặt là 1 trước khi bắt đầu phần (a) để đảm bảo kết quả nhất quán.

3. Hồi quy tuyến tính

- (a) Sử dụng phương thức `normal()` của bộ tạo số ngẫu nhiên, hãy tạo một vectơ x chứa 100 quan sát được lấy từ phân phối $N(0, 1)$. Vectơ này đại diện cho một đặc trưng, X .
- (b) Sử dụng phương thức `normal()`, hãy tạo một vectơ eps chứa 100 quan sát được lấy từ phân phối $N(0, 0,25)$ – một phân phối chuẩn với trung bình bằng 0 và phương sai bằng 0,25.

- (c) Sử dụng x và eps , hãy tạo một vectơ y theo mô hình.

$$Y = 1 + 0,5X + \epsilon \quad (3.39)$$

Độ dài của vectơ y là bao nhiêu? Giá trị của β_0 và β_1 trong mô hình tuyến tính này là bao nhiêu?

- (d) Tạo biểu đồ phân tán thể hiện mối quan hệ giữa x và y . Hãy bình luận về những gì bạn quan sát được.
- (e) Sử dụng mô hình tuyến tính bình phương tối thiểu để dự đoán y dựa trên x . Nhận xét về mô hình thu được. So sánh $\hat{\beta}_0$ và $\hat{\beta}_1$ với β_0 và β_1 như thế nào?
- (f) Hiển thị đường hồi quy bình phương nhỏ nhất trên biểu đồ phân tán thu được ở (d).
- (g) Vẽ đường hồi quy dân số trên biểu đồ, bằng một màu khác. Sử dụng phương thức `legend()` của trục để tạo chú thích phù hợp. (g) Bây giờ hãy xây dựng một mô hình hồi quy đa thức dự đoán y bằng cách sử dụng x và x^2 . Có bằng chứng nào cho thấy số hạng bậc hai cải thiện độ phù hợp của mô hình không? Giải thích câu trả lời của bạn.
- (h) Lặp lại (a)-(f) sau khi sửa đổi quy trình tạo dữ liệu sao cho dữ liệu có ít nhiễu hơn. Mô hình (3.39) phải giữ nguyên. Bạn có thể làm điều này bằng cách giảm phương sai của phân phối chuẩn được sử dụng để tạo ra số hạng sai số trong (b). Mô tả kết quả của bạn. (i) Lặp lại (a)-(f) sau khi sửa đổi quy trình tạo dữ liệu sao cho dữ liệu có nhiều nhiễu hơn. Mô hình (3.39) phải giữ nguyên. Bạn có thể làm điều này bằng cách tăng phương sai của phân phối chuẩn được sử dụng để tạo ra số hạng sai số trong (b). Mô tả kết quả của bạn. (j) Khoảng tin cậy cho β_0 và β_1 dựa trên tập dữ liệu gốc, tập dữ liệu nhiều hơn và tập dữ liệu ít nhiễu hơn là bao nhiêu? Nhận xét về kết quả của bạn.

14. Bài toán này tập trung vào vấn đề đa cộng tuyến.

- (a) Thực hiện các lệnh sau trong Python:

```
rng = np.random.default_rng(10)
x1 = rng.uniform(0, 1, size=100)
x2 = 0.5 * x1 + rng.normal(size=100) / 10
y = 2 + 2 * x1 + 0.3 * x2 + rng.normal(size=100)
```

Dòng cuối cùng tương ứng với việc tạo ra một mô hình tuyến tính trong đó y là một hàm số của x_1 và x_2 . Hãy viết ra dạng của mô hình tuyến tính đó.

Các hệ số hồi quy là gì?

- (b) Hệ số tương quan giữa x_1 và x_2 là gì? Hãy tạo một biểu đồ phân tán thể hiện mối quan hệ giữa các biến số.
- (c) Sử dụng dữ liệu này, hãy thực hiện hồi quy bình phương tối thiểu để dự đoán y bằng cách sử dụng x_1 và x_2 . Mô tả kết quả thu được. β^0 , β^1 và β^2 là gì? Chúng liên quan như thế nào đến β^0 , β^1 và β^2 thực sự? Bạn có thể bác bỏ giả thuyết không $H_0: \beta^1 = 0$ không? Còn giả thuyết không $H_0: \beta^2 = 0$ thì sao?
- (d) Bây giờ hãy sử dụng hồi quy bình phương tối thiểu để dự đoán y chỉ dựa trên x_1 . Hãy nhận xét về kết quả của bạn. Bạn có thể bác bỏ giả thuyết không $H_0: \beta^1 = 0$ không?
- (e) Bây giờ hãy sử dụng hồi quy bình phương tối thiểu để dự đoán y chỉ dựa trên x_2 . Hãy nhận xét về kết quả của bạn. Bạn có thể bác bỏ giả thuyết không $H_0: \beta^1 = 0$ không?
- (f) Các kết quả thu được trong (c)-(e) có mâu thuẫn với nhau không? Hãy giải thích câu trả lời của bạn.
- (g) Giả sử ta thu được thêm một quan sát nữa, nhưng không may là quan sát này bị đo sai. Ta sử dụng hàm `np.concatenate()` để thêm quan sát bổ sung này vào x_1 , x_2 và y .

`np.concatenate()`

```
x1 = np.concatenate([x1, [0.1]]) x2 =
np.concatenate([x2, [0.8]]) y =
np.concatenate([y, [6]])
```

Hãy điều chỉnh lại các mô hình tuyến tính từ (c) đến (e) bằng cách sử dụng dữ liệu mới này. Quan sát mới này có tác động như thế nào đến từng mô hình?

Trong mỗi mô hình, quan sát này là một điểm ngoại lệ? Một điểm có tầm ảnh hưởng cao? Hay cả hai? Hãy giải thích câu trả lời của bạn.

15. Bài toán này liên quan đến tập dữ liệu **Boston** mà chúng ta đã xem trong bài thực hành của chương này. Bây giờ chúng ta sẽ thử dự đoán tỷ lệ tội phạm bình quân đầu người bằng cách sử dụng các biến khác trong tập dữ liệu này. Nói cách khác, tỷ lệ tội phạm bình quân đầu người là biến phản hồi, và các biến khác là biến dự báo.

- (a) Với mỗi biến dự đoán, hãy xây dựng một mô hình hồi quy tuyến tính đơn giản để dự đoán biến phản hồi. Mô tả kết quả của bạn. Trong những mô hình nào có mối liên hệ có ý nghĩa thống kê giữa biến dự đoán và biến phản hồi? Hãy tạo một số biểu đồ để chứng minh cho nhận định của bạn.
- (b) Hãy xây dựng mô hình hồi quy bội để dự đoán biến phản hồi bằng cách sử dụng tất cả các biến dự báo. Mô tả kết quả của bạn. Với những biến dự báo nào ta có thể bác bỏ giả thuyết không $H_0: \beta_j = 0$? (c) Kết quả của bạn từ (a) so

sánh như thế nào với kết quả từ (b)?

Tạo một đồ thị hiển thị các hệ số hồi quy đơn biến từ (a) trên trục x và các hệ số hồi quy đa biến từ (b) trên trục y . Nghĩa là, mỗi biến dự đoán được hiển thị dưới dạng một điểm duy nhất trên đồ thị. Hệ số của nó trong mô hình hồi quy tuyến tính đơn giản được hiển thị trên trục x , và ước tính hệ số của nó trong mô hình hồi quy tuyến tính đa biến được hiển thị trên trục y .

3. Hồi quy tuyến tính

- (d) Có bằng chứng nào cho thấy mối liên hệ phi tuyến tính giữa bất kỳ biến dự báo nào và biến phản hồi không? Để trả lời câu hỏi này, đối với mỗi biến dự báo X , hãy xây dựng một mô hình có dạng

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \dots$$

4

Phân loại



Mô hình hồi quy tuyến tính được thảo luận trong Chương 3 giả định rằng biến phản hồi Y là biến định lượng. Nhưng trong nhiều trường hợp, biến phản hồi lại là biến định tính. Biến số này mang tính định tính. Ví dụ, màu mắt là biến định tính. Thông thường, các biến định tính được gọi là biến phân loại; chúng ta sẽ sử dụng những biến này.

các thuật ngữ được sử dụng thay thế cho nhau. Trong chương này, chúng ta nghiên cứu các phương pháp dự đoán Phản hồi định tính, một quá trình được gọi là phân loại. Dự đoán phản hồi định tính cho một quan sát có thể được gọi là phân loại.

Quan sát đó, vì nó liên quan đến việc gán quan sát vào một danh mục, hoặc lớp. Mặt khác, thường thì các phương pháp được sử dụng để phân loại trước tiên Dự đoán xác suất quan sát thuộc về từng loại của một biến định tính, làm cơ sở cho việc phân loại.

Theo nghĩa này, chúng cũng hoạt động giống như các phương pháp hồi quy.

Có rất nhiều kỹ thuật phân loại, hay bộ phân loại, mà người ta có thể sử dụng để dự đoán một phản hồi định tính. Chúng ta đã đề cập đến một số kỹ thuật này.

trong Mục 2.1.5 và 2.2.3. Trong chương này, chúng ta sẽ thảo luận về một số phương pháp được sử dụng rộng rãi. Các thuật toán phân loại: hồi quy logistic, phân tích phân biệt tuyến tính, phân tích phân biệt bậc hai, thuật toán Naive Bayes và thuật toán K-nearest neighbors. Phần thảo luận Hồi quy logistic được sử dụng làm điểm khởi đầu cho cuộc thảo luận về các mô hình tuyến tính tổng quát, và đặc biệt là hồi quy Poisson. Chúng ta sẽ thảo luận về...

Các phương pháp phân loại đòi hỏi nhiều tài nguyên máy tính hơn sẽ được trình bày trong các chương sau: bao gồm các mô hình cộng tính tổng quát (Chương 7); cây quyết định, rừng ngẫu nhiên, và tăng cường (Chương 8); và máy vectơ hỗ trợ (Chương 9).

chất lượng

phân loại

bộ phân loại

hậu cần

hồi quy

tuyến tính

phân biệt đối xử

Phân tích

bậc hai

phân biệt đối xử

Phân tích

Bayes ngây thơ

K-gần nhất

hàng xóm

tổng quát

tuyến tính

mô hình

Poisson

hồi quy

4.1 Tổng quan về phân loại

Các bài toán phân loại xảy ra thường xuyên, thậm chí có lẽ còn thường xuyên hơn cả bài toán hồi quy. các vấn đề. Một số ví dụ bao gồm:

136 4. Phân loại

1. Một người đến phòng cấp cứu với một loạt các triệu chứng có thể là do một trong ba bệnh lý sau gây ra.
Người đó mắc phải tình trạng nào trong ba tình trạng trên?
2. Dịch vụ ngân hàng trực tuyến phải có khả năng xác định xem giao dịch được thực hiện trên trang web có phải là gian lận hay không, dựa trên địa chỉ IP của người dùng, lịch sử giao dịch trước đó, v.v.
3. Dựa trên dữ liệu trình tự DNA của một số bệnh nhân mắc và không mắc một bệnh nhất định, một nhà sinh học muốn tìm ra những đột biến DNA nào có hại (gây bệnh) và những đột biến nào không.

Cũng giống như trong bài toán hồi quy, trong bài toán phân loại, chúng ta có một tập hợp các quan sát huấn luyện $(x_1, y_1), \dots, (x_n, y_n)$ mà chúng ta có thể sử dụng để xây dựng một bộ phân loại. Chúng ta muốn bộ phân loại của mình hoạt động tốt không chỉ trên dữ liệu huấn luyện mà còn trên các quan sát kiểm tra không được sử dụng để huấn luyện bộ phân loại.

Trong chương này, chúng ta sẽ minh họa khái niệm phân loại bằng cách sử dụng tập dữ liệu **Default** mô phỏng. Chúng ta quan tâm đến việc dự đoán liệu một cá nhân có vỡ nợ thẻ tín dụng hay không, dựa trên thu nhập hàng năm và số dư thẻ tín dụng hàng tháng. Tập dữ liệu được hiển thị trong Hình 4.1. Ở bảng bên trái của Hình 4.1, chúng ta đã vẽ biểu đồ **thu nhập** hàng năm và **số dư** thẻ tín dụng hàng tháng cho một tập hợp con gồm 10.000 cá nhân.


Những cá nhân vỡ nợ trong một tháng nhất định được hiển thị bằng màu cam, và những người không vỡ nợ được hiển thị bằng màu xanh lam. (Tỷ lệ vỡ nợ chung là khoảng 3%, vì vậy chúng ta chỉ vẽ biểu đồ cho một phần nhỏ những cá nhân không vỡ nợ.) Có vẻ như những cá nhân vỡ nợ có xu hướng có số dư thẻ tín dụng cao hơn những người không vỡ nợ. Ở bảng giữa và bảng bên phải của Hình 4.1, hai cặp biểu đồ hộp được hiển thị. Biểu đồ đầu tiên cho thấy sự phân bố **số dư** được chia theo biến vỡ nợ nhị phân; biểu đồ thứ hai là một biểu đồ tương tự cho **thu nhập**. Trong chương này, chúng ta sẽ học cách xây dựng một mô hình để dự đoán **vỡ nợ** (Y) cho bất kỳ giá trị nào của **số dư** (X_1) và **thu nhập** (X_2). Vì Y không phải là biến định lượng, mô hình hồi quy tuyến tính đơn giản của Chương 3 không phải là lựa chọn tốt: chúng ta sẽ trình bày chi tiết hơn về điều này trong Phần 4.2.

Điều đáng chú ý là Hình 4.1 thể hiện mối quan hệ rất rõ rệt giữa biến dự đoán và biến phản hồi **mặc định**. Trong hầu hết các ứng dụng thực tế, mối quan hệ giữa biến dự đoán và biến phản hồi sẽ không mạnh mẽ đến vậy. Tuy nhiên, để minh họa cho các quy trình phân loại được thảo luận trong chương này, chúng ta sử dụng một ví dụ trong đó mối quan hệ giữa biến dự đoán và biến phản hồi được phóng đại phần nào.

4.2 Tại sao không sử dụng hồi quy tuyến tính?

Chúng tôi đã nêu rằng hồi quy tuyến tính không phù hợp trong trường hợp phản hồi định tính. Tại sao vậy?

Giả sử chúng ta đang cố gắng dự đoán tình trạng sức khỏe của một bệnh nhân trong phòng cấp cứu dựa trên các triệu chứng của cô ấy. Trong ví dụ đơn giản này, có ba chẩn đoán có thể xảy ra: **đột quỵ**, **quá liều thuốc** và...



HÌNH 4.1. Bộ dữ liệu mặc định. Bên trái: Thu nhập hàng năm và hàng tháng

Số dư thẻ tín dụng của một số cá nhân. Những cá nhân đã vỡ nợ.

Các khoản thanh toán bằng thẻ tín dụng của họ được hiển thị bằng màu cam, và những người không thanh toán thì được hiển thị khác.

Màu xanh dương. Trung tâm: Biểu đồ hộp thể hiện số dư theo tình trạng vỡ nợ. Bên phải:

Biểu đồ hộp thể hiện thu nhập theo tình trạng vỡ nợ.

cơ động kinh. Chúng ta có thể xem xét việc mã hóa các giá trị này dưới dạng lưỡng tử như sau:

biến phản hồi tích cực, Y ,

- $Y =$
- 1 nếu bị đột quỵ;
 - 2 nếu dùng thuốc quá liều;
 - 3 nếu bị động kinh.

Sử dụng đoạn mã này, phương pháp bình phương tối thiểu có thể được dùng để xây dựng mô hình hồi quy tuyến tính.

Dự đoán Y dựa trên một tập hợp các biến dự báo $X_1, \dots, X_p$. Thật không may,

Cách mã hóa này ngụ ý một thứ tự về kết quả, đặt tình trạng quá liều thuốc vào vị trí thích hợp.

giữa đột quỵ và cơn động kinh, và khẳng định sự khác biệt

Sự khác biệt giữa đột quỵ và quá liều thuốc cũng giống như sự khác biệt giữa...

Quá liều thuốc và co giật động kinh. Trên thực tế không có quy định cụ thể nào.

Lý do tại sao điều này cần phải xảy ra. Ví dụ, người ta có thể chọn một

việc lập trình cũng hợp lý như nhau,

- $Y =$
- 1 nếu bị động kinh;
 - 2 nếu bị đột quỵ;
 - 3 nếu dùng thuốc quá liều,

Điều này sẽ ngụ ý một mối quan hệ hoàn toàn khác giữa ba điều kiện. Mỗi

cách mã hóa này sẽ tạo ra các kết quả tuyến tính khác nhau về cơ bản.

các mô hình cuối cùng sẽ dẫn đến các bộ dự đoán khác nhau trong quá trình thử nghiệm quan sát.

Nếu các giá trị của biến phản hồi tuân theo một thứ tự tự nhiên, chẳng hạn như nhẹ, vừa và nặng, và chúng tôi cảm nhận được khoảng cách giữa mức độ nhẹ và vừa.

Tương tự như khoảng cách giữa mức độ vừa và nặng, sau đó là mã hóa 1, 2, 3.

Điều đó nghe có vẻ hợp lý. Tuy nhiên, đáng tiếc là nhìn chung không có cách tự nhiên nào để...

Chuyển đổi biến phản hồi định tính có nhiều hơn hai cấp độ thành biến phản hồi định lượng sẵn sàng cho hồi quy tuyến tính.

Đối với phản hồi định tính nhị phân (hai cấp độ), tình hình sẽ tốt hơn. Ví dụ, có thể chỉ có hai khả năng về tình trạng sức khỏe của bệnh nhân: **đột quỵ** và **quá liều thuốc**. Khi đó, chúng ta có thể sử dụng phương pháp biến giả từ Mục 3.3.1 để mã hóa phản hồi như sau:

nhị phân

$$Y = \begin{cases} 0 & \text{nếu bị đột quỵ;} \\ 1 & \text{nếu dùng thuốc quá liều.} \end{cases}$$

Sau đó, chúng ta có thể sử dụng hồi quy tuyến tính để phân tích phản hồi nhị phân này và dự đoán **quá liều thuốc** nếu $Y > 0,5$ và **đột quỵ** nếu ngược lại. Trong trường hợp nhị phân, không khó để chứng minh rằng ngay cả khi ta đảo ngược cách mã hóa ở trên, hồi quy tuyến tính vẫn sẽ cho ra cùng một kết quả dự đoán cuối cùng.

Đối với phản hồi nhị phân với mã hóa 0/1 như trên, hồi quy bằng phương pháp bình phương tối thiểu không phải là hoàn toàn vô lý: có thể chứng minh rằng $\hat{X}\beta$ thu được bằng hồi quy tuyến tính thực chất là ước tính của $\Pr(\text{quá liều thuốc}|X)$ trong trường hợp đặc biệt này. Tuy nhiên, nếu chúng ta sử dụng hồi quy tuyến tính, một số ước tính của chúng ta có thể nằm ngoài khoảng $[0, 1]$ (xem Hình 4.2), khiến chúng khó được diễn giải như xác suất! Tuy nhiên, các dự đoán cung cấp một thứ tự và có thể được diễn giải như các ước tính xác suất thô. Điều thú vị là, hóa ra các phân loại mà chúng ta nhận được nếu sử dụng hồi quy tuyến tính để dự đoán phản hồi nhị phân sẽ giống với quy trình phân tích phân biệt tuyến tính (LDA) mà chúng ta thảo luận trong Phần 4.4.

Tóm lại, có ít nhất hai lý do không nên thực hiện phân loại bằng phương pháp hồi quy: (a) phương pháp hồi quy không thể xử lý phản hồi định tính có nhiều hơn hai lớp; (b) phương pháp hồi quy sẽ không cung cấp ước tính có ý nghĩa về $\Pr(Y|X)$, ngay cả với chỉ hai lớp. Do đó, tốt hơn hết là sử dụng phương pháp phân loại thực sự phù hợp với các giá trị phản hồi định tính. Trong phần tiếp theo, chúng ta sẽ trình bày hồi quy logistic, rất phù hợp với trường hợp phản hồi định tính nhị phân; trong các phần sau, chúng ta sẽ đề cập đến các phương pháp phân loại phù hợp khi phản hồi định tính có hai lớp trở lên.


4.3 Hồi quy Logistic

Hãy xem xét lại tập dữ liệu **Mặc định**, trong đó phản hồi **mặc định** thuộc một trong hai loại: **Có** hoặc **Không**. Thay vì mô hình hóa trực tiếp phản hồi Y này, hồi quy logistic mô hình hóa xác suất Y thuộc về một loại cụ thể.

Đối với dữ liệu **Mặc định**, mô hình hồi quy logistic mô phỏng xác suất vỡ nợ. Ví dụ, xác suất vỡ nợ khi có **số dư** nhất định có thể được viết như sau:

$$\Pr(\text{mặc định} = \text{Có}|\text{số dư}).$$

Giá trị của $\Pr(\text{mặc định} = \text{Có}|\text{số dư})$, mà chúng ta viết tắt là $p(\text{số dư})$, sẽ nằm trong khoảng từ 0 đến 1. Sau đó, với bất kỳ giá trị **số dư** nào, người ta có thể đưa ra dự đoán cho **mặc định**. Ví dụ, người ta có thể dự đoán **mặc định** = **Có**



HÌNH 4.2. Phân loại sử dụng dữ liệu **Mặc định**. Bên trái: Xác suất ước tính

Mặc định sử dụng hồi quy tuyến tính. Một số xác suất ước tính là âm!

Các dấu tích màu cam biểu thị giá trị 0/1 được mã hóa cho **giá trị mặc định** (Không hoặc Có). Bên phải: Dự đoán Xác suất **vỡ nợ** sử dụng hồi quy logistic. Tất cả các xác suất nằm trong khoảng 0. và 1.

đối với bất kỳ cá nhân nào có $p(\text{balance}) > 0,5$. Ngoài ra, nếu một công ty

Nếu muốn thận trọng trong việc dự đoán những cá nhân có nguy cơ vỡ nợ, họ có thể chọn sử dụng ngưỡng thấp hơn, chẳng hạn như $p(\text{balance}) > 0,1$.

4.3.1 Mô hình Logistics

Chúng ta nên mô hình hóa mối quan hệ giữa $p(X) = \Pr(Y=1|X)$ và như thế nào?

X? (Để tiện lợi, chúng ta sử dụng mã hóa chung 0/1 cho phản hồi.)

Trong Phần 4.2, chúng ta đã xem xét việc sử dụng mô hình hồi quy tuyến tính để biểu diễn những xác suất này:

$$p(X) = \beta_0 + \beta_1 X. \quad (4.1)$$

Nếu chúng ta sử dụng phương pháp này để dự đoán **default=Yes** dựa trên **số dư**, thì chúng ta thu được mô hình được hiển thị ở bảng bên trái của Hình 4.2. Ở đây chúng ta thấy Vấn đề với cách tiếp cận này là: đối với số dư gần bằng không, chúng ta dự đoán một Xác suất vỡ nợ âm; nếu chúng ta dự đoán cho các khoản dư rất lớn, chúng ta sẽ nhận được các giá trị lớn hơn 1. Những dự đoán này không hợp lý, vì Dĩ nhiên, xác suất thực sự của việc vỡ nợ, bất kể số dư thế tín dụng là bao nhiêu, phải nằm trong khoảng từ 0 đến 1. Vấn đề này không chỉ riêng đối với việc vỡ nợ tín dụng. dữ liệu. Bất cứ khi nào một đường thẳng được khớp với một phản hồi nhị phân được mã hóa là 0 hoặc 1, về nguyên tắc, chúng ta luôn có thể dự đoán $p(X) < 0$ đối với một số giá trị của X . và $p(X) > 1$ đối với những người khác (trừ khi phạm vi của X bị giới hạn).

Để tránh vấn đề này, chúng ta phải mô hình hóa $p(X)$ bằng một hàm cung cấp Trả về giá trị nằm trong khoảng từ 0 đến 1 cho tất cả các giá trị của X . Nhiều hàm đáp ứng điều này. Mô tả. Trong hồi quy logistic, chúng ta sử dụng hàm logistic,

hậu cần
chức năng

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}. \quad (4.2)$$

Đề phù hợp với mô hình (4.2), chúng tôi sử dụng một phương pháp gọi là khả năng tối đa, phương pháp này

Chúng ta sẽ thảo luận ở phần tiếp theo. Bảng bên phải của Hình minh họa

sự phù hợp của mô hình hồi quy logistic với dữ liệu **Mặc định**. Lưu ý rằng đối với

tối đa
xác suất 4.2

với số dư thấp, chúng tôi hiện dự đoán xác suất vỡ nợ sẽ gần bằng, nhưng không bao giờ bằng Dưới mức đó, bằng không. Tương tự, đối với số dư cao, chúng tôi dự đoán xác suất vỡ nợ. gần bằng một, nhưng không bao giờ vượt quá một. Hàm logistic sẽ luôn tạo ra một đường cong hình chữ S có dạng như vậy, và do đó, bất kể giá trị của X là bao nhiêu, chúng ta sẽ đưa ra một dự đoán hợp lý. Chúng ta cũng thấy rằng mô hình logistic là có khả năng nắm bắt phạm vi xác suất tốt hơn so với hồi quy tuyến tính. mô hình trong biểu đồ bên trái. Xác suất trung bình được ước tính trong cả hai trường hợp là 0,0333 (trung bình trên dữ liệu huấn luyện), giống với giá trị tổng thể. tỷ lệ người vỡ nợ trong tập dữ liệu.

Sau một chút điều chỉnh (4.2), chúng ta thấy rằng

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X} \tag{4.3}$$

Đại lượng $p(X)/[1 - p(X)]$ được gọi là tỷ lệ cược, và có thể nhận bất kỳ giá trị nào giữa 0 và ∞ . Giá trị của tỷ lệ cược gần 0 và ∞ cho thấy xác suất rất thấp.

tỷ lệ cược

và xác suất vỡ nợ rất cao. Ví dụ, trung bình

1 trong 5 người với xác suất 1/4 sẽ vỡ nợ, vì $p(X)=0,2$ ngụ ý rằng
Xác suất là $\frac{0,2}{0,2+0,8}=0,2$. Tương tự, trung bình cứ mười người thì có chín người

tỷ lệ cược 9 sẽ vỡ nợ, vì $p(X)=0,9$ ngụ ý tỷ lệ cược =9.

$$\frac{0,9}{1 - 0,9}$$

Theo truyền thống, tỷ lệ cược được sử dụng thay cho xác suất trong đưa ngựa, vì

Chúng có mối liên hệ tự nhiên hơn với chiến lược cá cược chính xác.

Bằng cách lấy logarit hai vế của (4.3), ta thu được

$$\ln \frac{p(X)}{1 - p(X)} = \beta_0 + \beta_1 X. \tag{4.4}$$

Vế bên trái được gọi là logarit tỷ lệ cược hoặc logit. Chúng ta thấy rằng mô hình hồi quy logistic (4.2) có logit tuyến tính theo X.

tỷ lệ logarit

đăng nhập

Hãy nhớ lại từ Chương 3 rằng trong mô hình hồi quy tuyến tính, β_1 cho biết sự thay đổi trung bình của Y liên quan đến sự tăng một đơn vị của X. Ngược lại, Trong mô hình hồi quy logistic, việc tăng X lên một đơn vị sẽ làm thay đổi logarit của X. tỷ lệ cược bằng β_1 (4.4). Tương đương với việc nhân tỷ lệ cược với e^{β_1} (4.3). Tuy nhiên, vì mối quan hệ giữa $p(X)$ và X trong (4.2) không phải là một đường thẳng, β_1 không tương ứng với sự thay đổi trong $p(X)$ liên quan đến một đơn vị sự tăng lên của X. Lượng mà $p(X)$ thay đổi do sự thay đổi một đơn vị của X phụ thuộc vào giá trị hiện tại của X. Nhưng bất kể giá trị của X là bao nhiêu, nếu β_1 dương thì việc tăng X sẽ dẫn đến việc tăng $p(X)$. và nếu β_1 âm thì việc tăng X sẽ đi kèm với việc giảm $p(X)$. Thực tế là không có mối quan hệ tuyến tính giữa $p(X)$ và X, và thực tế là tốc độ thay đổi của $p(X)$ trên mỗi đơn vị thay đổi của X. Điều này phụ thuộc vào giá trị hiện tại của X, và cũng có thể được nhận thấy bằng cách quan sát. Bảng bên phải của Hình 4.2.

4.3.2 Ước lượng các hệ số hồi quy

Các hệ số β_0 và β_1 trong (4.2) chưa biết và phải được ước tính. dựa trên dữ liệu huấn luyện có sẵn. Trong Chương 3, chúng ta đã sử dụng phương pháp bình phương tối thiểu. phương pháp ước lượng các hệ số hồi quy tuyến tính chưa biết. Mặc dù chúng ta có thể sử dụng phương pháp bình phương tối thiểu (phi tuyến tính) để phù hợp với mô hình (4.4), càng nhiều Phương pháp ước lượng hợp lý tối đa tổng quát được ưu tiên hơn vì nó có các đặc tính thống kê tốt hơn. Ý tưởng cơ bản đằng sau việc sử dụng ước lượng hợp lý tối đa là...

Cách phù hợp với mô hình hồi quy logistic như sau: chúng ta tìm kiếm các ước tính cho β_0 và β_1 sao cho xác suất dự đoán $\hat{p}(x_i)$ về việc vỡ nợ đối với mỗi cá nhân, sử dụng (4.2), tương ứng càng sát càng tốt với tình trạng vỡ nợ quan sát được của cá nhân đó. Nói cách khác, chúng ta cố gắng tìm β^0 và β^1 sao cho khi đưa các ước tính này vào mô hình cho $p(X)$, được đưa ra trong (4.2), sẽ cho ra một số gần bằng một đối với tất cả các cá nhân đã vỡ nợ, và một số gần bằng không đối với tất cả các cá nhân chưa vỡ nợ. Trực giác này có thể được chính thức hóa bằng một phương trình toán học được gọi là hàm khả năng:

$$(\beta_0, \beta_1) = \underset{\text{tối: } y_i=1}{\text{p}(x_i) (1 - \text{p}(x_i))} \quad \text{hàm xác suất} \quad (4.5)$$

Các giá trị ước lượng β^0 và β^1 được chọn để tối đa hóa hàm xác suất này.

Phương pháp ước lượng hợp lý tối đa là một cách tiếp cận rất tổng quát được sử dụng để hiệu chỉnh nhiều mô hình phi tuyến tính mà chúng ta xem xét trong suốt cuốn sách này. Trong bối cảnh hồi quy tuyến tính, phương pháp bình phương nhỏ nhất thực chất là một trường hợp đặc biệt của ước lượng hợp lý tối đa. Chi tiết toán học của ước lượng hợp lý tối đa nằm ngoài phạm vi của cuốn sách này. Tuy nhiên, nhìn chung, hồi quy logistic và các mô hình khác có thể dễ dàng được hiệu chỉnh bằng phần mềm thống kê như R, vì vậy chúng ta không cần phải quan tâm đến các chi tiết của quy trình hiệu chỉnh ước lượng hợp lý tối đa.

Bảng 4.1 trình bày các ước tính hệ số và thông tin liên quan thu được từ việc áp dụng mô hình hồi quy logistic trên dữ liệu **Mặc định** để dự đoán xác suất **mặc định = Có** bằng cách sử dụng **số dư**. Chúng ta thấy rằng $\beta^1 = 0,0055$; điều này cho thấy sự tăng lên của **số dư** có liên quan đến sự tăng lên của xác suất **mặc định**. Cụ thể hơn, sự tăng một đơn vị trong **số dư** có liên quan đến sự tăng lên của logarit tỷ lệ **mặc định** là 0,0055 đơn vị.

Nhiều khía cạnh của kết quả hồi quy logistic được trình bày trong Bảng 4.1 tương tự như kết quả hồi quy tuyến tính của Chương 3. Ví dụ, chúng ta có thể đo lường độ chính xác của các ước lượng hệ số bằng cách tính toán sai số chuẩn của chúng. Thống kê z trong Bảng 4.1 đóng vai trò tương tự như thống kê t trong kết quả hồi quy tuyến tính, ví dụ như trong Bảng 3.1 ở trang 77. Chẳng hạn, thống kê z liên quan đến β_1 bằng $\beta^1/SE(\beta^1)$, và do đó, giá trị tuyệt đối lớn của thống kê z cho thấy bằng chứng chống lại giả thuyết không $H_0: \beta_1 = 0$. Giả thuyết không này ngụ ý rằng $p(X) = 1 + e^{\beta_0}$, nói cách khác, xác suất **vỡ nợ** không phụ thuộc vào **số dư**.

Vì giá trị p liên quan đến **số dư** trong Bảng 4.1 rất nhỏ, chúng ta có thể bác bỏ giả thuyết H_0 . Nói cách khác, chúng ta kết luận rằng thực sự có mối liên hệ giữa **số dư** và xác suất **vỡ nợ**. Hệ số chặn ước tính trong Bảng 4.1 thường không được quan tâm; mục đích chính của nó là điều chỉnh xác suất trung bình phù hợp với tỷ lệ các giá trị 1 trong dữ liệu (trong trường hợp này, là tỷ lệ vỡ nợ tổng thể).

4.3.3 Đưa ra dự đoán

Sau khi các hệ số được ước tính, chúng ta có thể tính toán xác suất **vỡ nợ** cho bất kỳ số dư thế tin dụng nào. Ví dụ, sử dụng các ước tính hệ số được đưa ra trong Bảng 4.1, chúng ta dự đoán xác suất vỡ nợ là...

	Hệ số Sai số chuẩn	Thống kê z	Giá trị p
Cân bằng chặn	10,6513	0,3612	29,5 <0,0001
	0,0055	0,0002	24,9 <0,0001

BẢNG 4.1. Đối với dữ liệu **Mặc định** , hệ số ước tính của mô hình hồi quy logistic dự đoán xác suất vỡ nợ dựa trên **số dư**. Một đơn vị Việc tăng **số dư tài khoản** có liên quan đến việc tăng logarit tỷ lệ vỡ nợ . 0,0055 đơn vị.

	Hệ số Sai số chuẩn	Thống kê z	Giá trị p
Chặn học	3,5041	0,0707	49,55 <0,0001
sinh[Có]	0,4049	0,1150	3,52 0,0004

BẢNG 4.2. Đối với dữ liệu **Mặc định** , các hệ số ước tính của hồi quy logistic Mô hình dự đoán xác suất vỡ nợ dựa trên tình trạng sinh viên. Tình trạng sinh viên được mã hóa dưới dạng biến giả, với giá trị 1 dành cho sinh viên và giá trị 0 dành cho người không phải sinh viên. Đối với người không phải sinh viên, điều này được thể hiện bằng biến **student[Yes]** trong bảng.

Đối với một cá nhân có **số dư** 1.000 đô la là

$$p^{\wedge}(X)=\frac{e^{\beta^{\wedge}0+\beta^{\wedge}1X}}{1+e^{\beta^{\wedge}0+\beta^{\wedge}1X}},=\frac{e^{-10.6513+0.0055\times1,000}}{1+e^{-10.6513+0.0055\times1,000}}=0,00576,$$

thấp hơn 1%. Ngược lại, xác suất vỡ nợ dự đoán cho một Tỷ lệ này đối với cá nhân có số dư 2.000 đô la cao hơn nhiều, và bằng 0,586 hoặc 58,6 %.

Có thể sử dụng các biến dự báo định tính với mô hình hồi quy logistic bằng cách sử dụng phương pháp biến giả từ Mục 3.3.1. Ví dụ, Bộ dữ liệu **mặc định** chứa biến định tính " **sinh viên**". Để phù hợp với một mô hình Đối với trường hợp sử dụng tình trạng sinh viên làm biến dự đoán, chúng ta chỉ cần tạo một biến giả. Biến này nhận giá trị 1 đối với sinh viên và 0 đối với người không phải sinh viên.

Mô hình hồi quy logistic được xây dựng dựa trên dự đoán xác suất vỡ nợ. Thông tin về tình trạng sinh viên có thể được thấy trong Bảng 4.2. Hệ số liên quan Với biến giả, giá trị dương và giá trị p tương ứng có ý nghĩa thống kê. Điều này cho thấy sinh viên có xu hướng có tỷ lệ mặc định cao hơn.

xác suất cao hơn so với người không phải sinh viên:

$$Pr(\text{mặc định}=\text{Có}|\text{sinh viên}=\text{Có})=\frac{e^{-3.5041+0.4049\times1}}{1+e^{-3.5041+0.4049\times1}}=0,0431,$$
$$Pr(\text{mặc định}=\text{Có}|\text{sinh viên}=\text{Không})=\frac{e^{-3.5041+0.4049\times0}}{1+e^{-3.5041+0.4049\times0}}=0,0292.$$

4.3.4 Hồi quy logistic đa biến

Bây giờ chúng ta xem xét bài toán dự đoán phân hồi nhị phân bằng cách sử dụng nhiều thông tin. các yếu tố dự báo. Tương tự như việc mở rộng từ tuyến tính đơn giản sang tuyến tính đa biến. hồi quy trong Chương 3, chúng ta có thể khái quát hóa (4.4) như sau:

$$\frac{p(X)}{1-p(X)}=\beta_0+\beta_1X_1+\cdots+\beta_pX_p,\tag{4.6}$$

trong đó $X=(X_1,\ldots,X_p)$ là p biến dự đoán. Phương trình 4.6 có thể được viết lại như sau:

$$p(X)=\frac{e^{\beta_0+\beta_1X_1+\cdots+\beta_pX_p}}{1+e^{\beta_0+\beta_1X_1+\cdots+\beta_pX_p}}.\tag{4.7}$$


	Hệ số Sai số chuẩn	Thống kê z	Giá trị p
cân bằng chặn	10.8690	0,4923	22,08 <0,0001
	0.0057	0,0002	24,74 <0,0001
thu nhập	0.0030	0,0082	0,37 0,7115
sinh viên[Có]	0.6468	0,2362	2,74 0,0062

BẢNG 4.3. Đối với dữ liệu **Mặc định** , các hệ số ước tính của hồi quy logistic mô hình dự đoán xác suất **vỡ nợ** dựa trên **số dư**, **thu nhập** và **sinh viên** trạng thái. Trạng thái sinh viên được mã hóa dưới dạng biến giả **student[Yes]**, với giá trị có giá trị là 1 đối với sinh viên và 0 đối với người không phải sinh viên. Khi áp dụng mô hình này, **thu nhập** được đo bằng hàng nghìn đô la.

Tương tự như trong Mục **4.3.2**, chúng ta sử dụng phương pháp ước lượng hợp lý tối đa để ước lượng $\beta_0, \beta_1, \dots, \beta_p$.

Bảng **4.3** trình bày các ước tính hệ số cho mô hình hồi quy logistic. sử dụng **số dư tài khoản**, **thu nhập** (tính bằng nghìn đô la) và tình trạng **sinh viên** để Dự đoán xác suất **vỡ nợ**. Có một kết quả đáng ngạc nhiên ở đây. Giá trị p liên quan đến **số dư** và biến giả cho tình trạng **sinh viên** rất nhỏ, cho thấy mỗi biến số này đều có liên quan đến xác suất **vỡ nợ**. Tuy nhiên, hệ số cho biến giả có giá trị âm, cho thấy sinh viên ít có khả năng **vỡ nợ** hơn so với người không phải sinh viên. Ngược lại, hệ số của biến giả lại có giá trị dương trong Bảng **4.2**. Làm thế nào có thể liên kết trạng thái sinh viên với một sự gia tăng xác suất **vỡ nợ** trong Bảng **4.2** và sự giảm xác suất Giá trị mặc định trong Bảng **4.3 là gì?** Phần bên trái của Hình **4.3** minh họa bằng đồ họa cho nghịch lý rõ ràng này. Các đường liền màu cam và xanh lam Biểu đồ thể hiện tỷ lệ **vỡ nợ** trung bình của sinh viên và người không phải sinh viên. như một hàm số của số dư thể tín dụng. Hệ số âm đối với **sinh viên** trong Phân tích hồi quy logistic đa biến cho thấy rằng với một giá trị **cân bằng** cố định Với mức thu nhập và **khả năng trả nợ**, sinh viên ít có khả năng **vỡ nợ** hơn người không phải sinh viên. Thật vậy, Từ bảng bên trái của Hình **4.3** , ta quan sát thấy rằng mặc định của sinh viên là đúng. tỷ lệ này bằng hoặc thấp hơn tỷ lệ **vỡ nợ** xấu của người không phải sinh viên đối với mọi giá trị của **sự cân bằng**. Nhưng những đường đứt đoạn nằm ngang gần đáy của cốt truyện, mà Biểu đồ thể hiện tỷ lệ **vỡ nợ** trung bình của sinh viên và người không phải sinh viên trên tất cả các giá trị **số dư** và **thu nhập**, cho thấy hiệu ứng ngược lại: nhìn chung, sinh viên Tỷ lệ **vỡ nợ** cao hơn tỷ lệ **vỡ nợ** của người không phải sinh viên. Do đó, có là hệ số dương cho **sinh viên** trong hồi quy logistic đơn biến Kết quả được hiển thị trong Bảng **4.2**.

Bảng bên phải của Hình **4.3** giải thích sự khác biệt này. Các biến **"sinh viên"** và **"sự cân bằng"** có mối tương quan với nhau. Sinh viên có xu hướng Điều này dẫn đến việc sinh viên có mức **vỡ nợ** cao hơn, và từ đó làm tăng khả năng **vỡ nợ**. Nói cách khác, sinh viên có nhiều khả năng mắc **vỡ nợ** lớn. Số dư thể tín dụng, như chúng ta đã biết từ bảng bên trái của Hình **4.3**, thường liên quan đến tỷ lệ **vỡ nợ** cao. Do đó, mặc dù Một sinh viên với số dư thể tín dụng nhất định thường sẽ có... Xác suất **vỡ nợ** thấp hơn so với người không phải sinh viên sử dụng cùng loại thể tín dụng. sự cân bằng, thực tế là nhìn chung sinh viên có xu hướng có hạn mức tín dụng cao hơn. số dư **vỡ nợ** có nghĩa là nhìn chung, sinh viên có xu hướng **vỡ nợ** với tỷ lệ cao hơn so với những người không phải sinh viên. Đây là một điểm khác biệt quan trọng đối với một công ty thể tín dụng. đó là việc cố gắng xác định xem họ nên cấp tín chỉ cho ai. Một sinh viên là Rủi ro cao hơn so với người không phải sinh viên nếu không có thông tin về thể tín dụng của sinh viên.



HÌNH 4.3. Các yếu tố gây nhiễu trong dữ liệu **Mặc định**. Bên trái: Tỷ lệ mặc định được hiển thị. Dành cho sinh viên (màu cam) và người không phải sinh viên (màu xanh). Các đường liền nét thể hiện tỷ lệ vỡ nợ, như một hàm số của **sự cân bằng**, trong khi các đường đứt đoạn ngang thể hiện tổng thể. Tỷ lệ vỡ nợ. Bên phải: Biểu đồ hộp thể hiện **số dư tài khoản** của sinh viên (màu cam) và người không phải sinh viên. (màu xanh) được hiển thị.

Số dư tài khoản hiện có. Tuy nhiên, sinh viên đó ít rủi ro hơn so với người không phải sinh viên. Với cùng số dư thẻ tín dụng!

Ví dụ đơn giản này minh họa những nguy hiểm và sự tinh tế liên quan. thực hiện hồi quy chỉ với một biến dự đoán duy nhất khi các biến khác Các biến dự báo cũng có thể liên quan. Tương tự như trong thiết lập hồi quy tuyến tính, Kết quả thu được khi sử dụng một biến dự báo có thể khác biệt đáng kể so với kết quả thu được khi sử dụng nhiều biến dự báo, đặc biệt khi có sự tương quan giữa chúng. các yếu tố dự báo. Nhìn chung, hiện tượng được thể hiện trong Hình 4.3 được gọi là sự nhầm lẫn.

sự nhầm lẫn

Bằng cách thay thế các ước tính cho các hệ số hồi quy từ Bảng 4.3. (4.7), chúng ta có thể đưa ra dự đoán. Ví dụ, một sinh viên có điểm tín chỉ Với số dư thẻ là 1.500 đô la và thu nhập 40.000 đô la, xác suất vỡ nợ ước tính là...

$$\hat{p}(X) = \frac{e^{-10,869 + 0,00574 \times 1.500 + 0,003 \times 40} - 0,6468 \times 1}{1 + e^{-10,869 + 0,00574 \times 1.500 + 0,003 \times 40} - 0,6468 \times 1} = 0,058. \tag{4.8}$$

Một người không phải sinh viên có cùng số dư tài khoản và thu nhập có xác suất vỡ nợ ước tính là

$$\hat{p}(X) = \frac{e^{-10,869 + 0,00574 \times 1.500 + 0,003 \times 40} - 0,6468 \times 0}{1 + e^{-10,869 + 0,00574 \times 1.500 + 0,003 \times 40} - 0,6468 \times 0} = 0,105. \tag{4.9}$$

(Ở đây, chúng ta nhân ước tính hệ số **thu nhập** từ Bảng 4.3 với 40, chứ không phải là 40.000, vì trong bảng đó mô hình được điều chỉnh theo **thu nhập**. (được đo bằng đơn vị 1.000 đô la.)

4.3.5 Hồi quy Logistic đa thức

Đôi khi chúng ta muốn phân loại một biến phản hồi có nhiều hơn hai giá trị. các lớp. Ví dụ, trong Phần 4.2, chúng ta có ba loại tình trạng bệnh lý trong phòng cấp cứu: **đột quỵ**, **quá liều thuốc**, **co giật động kinh**. Tuy nhiên, phương pháp hồi quy logistic mà chúng ta đã thấy trong phần này Chỉ cho phép $K = 2$ lớp cho biến phản hồi.

Hóa ra, có thể mở rộng mô hình hồi quy logistic hai lớp. cách tiếp cận việc thiết lập các lớp $K > 2$. Phần mở rộng này đôi khi được gọi là hồi quy logistic đa biến. Để thực hiện điều này, trước tiên chúng ta chọn một lớp duy nhất để làm cơ sở; không mất tính tổng quát, chúng ta chọn lớp thứ K . lớp cho vai trò này. Sau đó, chúng ta thay thế mô hình (4.7) bằng mô hình

đa thức
hậu cần
hồi quy

$$\Pr(Y = k | X = x) = \frac{e^{\beta_{k0} + \beta_{k1}x_1 + \dots + \beta_{kp}x_p}}{\sum_{l=1}^K e^{\beta_{l0} + \beta_{l1}x_1 + \dots + \beta_{lp}x_p}} \quad (4.10)$$

với $k = 1, \dots, K - 1$ và

$$\Pr(Y = K | X = x) = 1 - \frac{1}{\sum_{l=1}^{K-1} e^{\beta_{l0} + \beta_{l1}x_1 + \dots + \beta_{lp}x_p}}. \quad (4.11)$$

Không khó để chứng minh rằng với $k = 1, \dots, K - 1$,

$$\frac{\Pr(Y = k | X = x)}{\Pr(Y = K | X = x)} = \beta_{k0} + \beta_{k1}x_1 + \dots + \beta_{kp}x_p. \quad (4.12)$$

Lưu ý rằng (4.12) khá giống với (4.6). Phương trình 4.12 cho thấy rằng một khi Một lần nữa, logarit tỷ lệ cược giữa bất kỳ cặp lớp nào đều tuyến tính theo các đặc điểm.

Hóa ra trong (4.10)-(4.12), quyết định xử lý lớp thứ K như Mức cơ sở không quan trọng. Ví dụ, khi phân loại phòng cấp cứu các trường hợp **đột quỵ**, **quá liều thuốc** và **động kinh**, giả sử rằng chúng ta Áp dụng hai mô hình hồi quy logistic đa biến: một mô hình coi **đột quỵ** là nguyên nhân gây ra đột quỵ. mức cơ sở, một trường hợp khác coi **tình trạng quá liều thuốc** là mức cơ sở. Hệ số Các ước tính sẽ khác nhau giữa hai mô hình đã được hiệu chỉnh do sự khác biệt về... lựa chọn đường cơ sở, nhưng các giá trị phù hợp (dự đoán), logarit tỷ lệ chênh lệch giữa Bất kỳ cặp lớp nào, và các kết quả đầu ra chính khác của mô hình sẽ vẫn giữ nguyên.

Tuy nhiên, việc giải thích các hệ số trong mô hình logistic đa thức vẫn còn nhiều hạn chế. Việc xây dựng mô hình hồi quy cần được thực hiện cẩn thận, vì nó gắn liền với sự lựa chọn của mức cơ sở. Ví dụ, nếu ta đặt **cơn động kinh** làm mức cơ sở, Khi đó, chúng ta có thể hiểu $\beta_{stroke0}$ là logarit tỷ lệ khả năng xảy ra **đột quỵ** so với **động kinh**. **cơn động kinh**, với điều kiện $x_1 = \dots = x_p = 0$. Hơn nữa, sự gia tăng một đơn vị Trong X_j có liên quan đến sự gia tăng $\beta_{strokej}$ trong logarit tỷ lệ **mắc đột quỵ** . **cơn động kinh**. Nói cách khác, nếu X_j tăng thêm một đơn vị thì

$$\frac{\Pr(Y = \text{nét vẽ} | X = x)}{\Pr(Y = \text{cơn động kinh} | X = x)}$$

tăng lên bởi $e^{\beta_{strokej}}$.

Chúng tôi sẽ trình bày ngắn gọn một phương pháp mã hóa thay thế cho logistic đa thức. hồi quy, được gọi là mã hóa softmax. Mã hóa softmax tương đương với mã hóa vừa mô tả ở chỗ các giá trị được ước tính, log odds giữa bất kỳ cặp lớp nào, và các kết quả đầu ra chính khác của mô hình sẽ vẫn giữ nguyên. Tương tự, bất kể phương pháp mã hóa nào. Nhưng phương pháp mã hóa softmax được sử dụng rộng rãi trong... một số lĩnh vực trong tài liệu về học máy (và sẽ xuất hiện lại trong...) Chương 10), vì vậy điều đáng lưu ý là. Trong mã hóa softmax, thay vì Thay vì chọn một lớp cơ sở, chúng ta xử lý tất cả K lớp một cách đối xứng, và giả sử rằng với $k = 1, \dots, K$,

softmax

$$\Pr(Y = k | X = x) = \frac{e^{\beta_{k0} + \beta_{k1}x_1 + \dots + \beta_{kp}x_p}}{\sum_{l=1}^K e^{\beta_{l0} + \beta_{l1}x_1 + \dots + \beta_{lp}x_p}}. \quad (4.13)$$

Do đó, thay vì ước tính hệ số cho $K - 1$ lớp, chúng ta thực sự ước tính hệ số cho tất cả K lớp. Không khó để thấy rằng, kết quả của (4.13), tỷ lệ chênh lệch logarit giữa lớp thứ k và lớp thứ k bằng

$$\frac{\Pr(Y = k | X = x)}{\Pr(Y = k | X = x)}$$

nhật ký

$$= (\beta_{k0} - \beta_{k0}) + (\beta_{k1} - \beta_{k1})x_1 + \dots + (\beta_{kp} - \beta_{kp})x_p.$$

(4.14)

4.4 Mô hình tạo sinh cho phân loại

Hồi quy logistic liên quan đến việc mô hình hóa trực tiếp $\Pr(Y = k | X = x)$ bằng cách sử dụng hàm logistic, được đưa ra bởi (4.7) cho trường hợp hai lớp phản hồi. Trong thuật ngữ thống kê, chúng ta mô hình hóa phân phối có điều kiện của phản hồi Y khi biết (các) biến dự đoán X . Bây giờ chúng ta xem xét một cách tiếp cận khác và ít trực tiếp hơn để ước tính các xác suất này. Trong cách tiếp cận mới này, chúng ta mô hình hóa phân phối của các biến dự đoán X một cách riêng biệt trong mỗi lớp phản hồi (tức là cho mỗi giá trị của Y). Sau đó, chúng ta sử dụng định lý Bayes để đảo ngược chúng thành các ước tính cho $\Pr(Y = k | X = x)$. Khi giả định phân phối của X trong mỗi lớp là phân phối chuẩn, hóa ra mô hình này có hình thức rất giống với hồi quy logistic.

Tại sao chúng ta cần một phương pháp khác khi đã có hồi quy logistic?
Có một số lý do:

- Khi có sự phân tách đáng kể giữa hai lớp, các ước lượng tham số cho mô hình hồi quy logistic lại không ổn định một cách đáng ngạc nhiên. Các phương pháp mà chúng ta xem xét trong phần này không gặp phải vấn đề này.
- Nếu phân bố của các biến dự báo X xấp xỉ phân bố chuẩn trong mỗi lớp và kích thước mẫu nhỏ, thì các phương pháp trong phần này có thể chính xác hơn so với hồi quy logistic.
- Các phương pháp trong phần này có thể được mở rộng một cách tự nhiên cho trường hợp có nhiều hơn hai lớp phản hồi. (Trong trường hợp có nhiều hơn hai lớp phản hồi, chúng ta cũng có thể sử dụng hồi quy logistic đa biến từ Phần 4.3.5.)

Giả sử ta muốn phân loại một quan sát vào một trong K lớp, trong đó $K \geq 2$. Nói cách khác, biến phản hồi định tính Y có thể nhận K giá trị khác nhau và không theo thứ tự. Gọi π_k là xác suất tổng quát hoặc xác suất tiên nghiệm rằng một quan sát được chọn ngẫu nhiên thuộc lớp thứ k . Gọi $f_k(X) \equiv \Pr(X | Y = k)$ là hàm mật độ xác suất của X đối với một quan sát thuộc lớp thứ k . Nói cách khác, $f_k(x)$ tương đối lớn nếu có xác suất cao rằng một quan sát trong lớp thứ k có $X \approx x$, và $f_k(x)$ nhỏ nếu rất khó xảy ra trường hợp một quan sát trong lớp thứ k có $X \approx x$. Định lý Bayes phát biểu rằng...

hàm
mật độ
trước

Định
lý Bayes

Về mặt kỹ thuật, định nghĩa này chỉ chính xác nếu X là một biến ngẫu nhiên định tính. Nếu X là biến ngẫu nhiên định lượng, thì $f_k(x)dx$ tương ứng với xác suất X rơi vào một vùng nhỏ dx xung quanh x .

$$\Pr(Y = k | X = x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^K \pi_l f_l(x)}. \quad (4.15)$$

Theo ký hiệu đã sử dụng trước đó, chúng ta sẽ dùng viết tắt $p_k(x)$ =

$\Pr(Y = k | X = x)$; đây là xác suất hậu nghiệm rằng một quan sát $X = x$ thuộc về lớp thứ k . sau

Tức là, đó là xác suất rằng

quan sát thuộc lớp thứ k , với giá trị dự đoán cho điều đó.

quan sát.

Phương trình 4.15 gợi ý rằng thay vì tính toán trực tiếp xác suất hậu nghiệm

xác suất $p_k(x)$ như trong Phần 4.3.1, chúng ta chỉ cần thay thế các ước tính của π_k .

và $f_k(x)$ vào (4.15). Nói chung, việc ước tính π_k rất dễ dàng nếu chúng ta có một giá trị ngẫu nhiên

lấy mẫu từ quần thể: chúng ta chỉ cần tính phần trăm của quá trình huấn luyện.

các quan sát thuộc lớp thứ k . Tuy nhiên, việc ước tính mật độ

Hàm $f_k(x)$ khó hơn nhiều. Như chúng ta sẽ thấy, để ước tính $f_k(x)$,

Thông thường, chúng ta sẽ phải đưa ra một số giả định đơn giản hóa.

Chúng ta biết từ Chương 2 rằng bộ phân loại Bayes, dùng để phân loại một

quan sát x đối với lớp có $p_k(x)$ lớn nhất, có giá trị thấp nhất có thể

Tỷ lệ lỗi trên tổng số tất cả các bộ phân loại. (Tất nhiên, điều này chỉ đúng nếu tất cả các bộ phân loại...)

các điều khoản trong (4.15) được xác định chính xác.) Do đó, nếu chúng ta có thể tìm ra cách để

ước tính $f_k(x)$, sau đó chúng ta có thể thay nó vào (4.15) để xấp xỉ

Bộ phân loại Bayes.

Trong các phần tiếp theo, chúng ta sẽ thảo luận về ba bộ phân loại sử dụng các phương pháp khác nhau.

ước tính của $f_k(x)$ trong (4.15) để xấp xỉ bộ phân loại Bayes: phân tích phân biệt tuyến

tính, phân tích phân biệt bậc hai và Bayes đơn giản.

4.4.1 Phân tích phân biệt tuyến tính cho $p = 1$

Hiện tại, giả sử $p = 1$ – nghĩa là chúng ta chỉ có một biến dự đoán. Chúng ta sẽ

muốn có được ước tính cho $f_k(x)$ mà chúng ta có thể thay vào (4.15) để

ước tính $p_k(x)$. Sau đó, chúng ta sẽ phân loại một quan sát vào lớp mà

$p_k(x)$ lớn nhất. Để ước tính $f_k(x)$, trước tiên chúng ta sẽ đưa ra một số giả định.

về hình dạng của nó.

Cụ thể, chúng ta giả định rằng $f_k(x)$ là phân phối chuẩn hoặc phân phối Gauss. Trong

thiết lập một chiều, mật độ phân phối chuẩn có dạng

Bình thường
Gaussian

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp \left\{ -\frac{1}{2\sigma_k^2} (x - \mu_k)^2 \right\}, \quad (4.16)$$

trong đó μ_k và σ_k^2 là các tham số trung bình và phương sai cho lớp thứ k .

Hiện tại, chúng ta hãy tiếp tục giả định rằng $\sigma_k^2 = \dots = \sigma^2$: tức là, có một sự chia sẻ

Hệ số biến thiên trên tất cả K lớp, để đơn giản, ta có thể ký hiệu là

σ^2 . Thay (4.16) vào (4.15), ta thấy rằng

$$p_k(x) = \frac{\pi_k \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu_k)^2 \right\}}{\sum_{l=1}^K \pi_l \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu_l)^2 \right\}}. \quad (4.17)$$

(Lưu ý rằng trong (4.17), π_k biểu thị xác suất tiên nghiệm rằng một quan sát

(thuộc lớp thứ k , không nên nhầm lẫn với $\pi \approx 3,14159$, hằng số toán học.) Bộ phân loại

Bayes2 liên quan đến việc gán một quan sát

2Hãy nhớ rằng bộ phân loại Bayes gán một quan sát vào lớp mà $p_k(x)$

là lớn nhất. Điều này khác với định lý Bayes trong (4.15), cho phép chúng ta thao tác

phân phối có điều kiện.