

462 10. Học sâu

Với hình dạng đầu vào $(5,3)$, mỗi hàng đại diện cho một phiên bản trễ của ba biến. Lớp `nn.RNN()` cũng mong đợi hàng đầu tiên của mỗi quan sát là sớm nhất về thời gian, vì vậy chúng ta phải đảo ngược thứ tự hiện tại. Do đó, chúng ta lặp qua phạm vi $(5,0,-1)$ bên dưới, đây là một ví dụ về việc sử dụng `slice()` để lập chỉ mục các đối tượng có thể lặp lại. Ký hiệu chung là **bắt đầu:kết thúc:bước**.

```
Trong [99]: ordered_cols = []
for lag in range(5,0,-1): for col in
    cols:
        ordered_cols.append('{0}_{1}'.format(col, lag))
X = X.reindex(columns=ordered_cols)
Cột X
```

```
Out[99]: Index(['DJ_return_5', 'log_volume_5', 'log_volatility_5',
              'DJ_return_4', 'log_volume_4', 'log_volatility_4',
              'DJ_return_3', 'log_volume_3', 'log_volatility_3',
              'DJ_return_2', 'log_volume_2', 'log_volatility_2',
              'DJ_return_1', 'log_volume_1', 'log_volatility_1'], dtype='object')
```

Giờ đây chúng ta sẽ định hình lại dữ liệu.

```
Trong [100]: X_rnn = X.to_numpy().reshape((-1,5,3))
X_rnn.shape
```

```
Out[100]: (6046, 5, 3)
```

Bằng cách chỉ định kích thước đầu tiên là -1, `numpy.reshape()` sẽ suy ra kích thước của nó dựa trên các đối số còn lại.

Giờ chúng ta đã sẵn sàng tiếp tục với mạng RNN, sử dụng 12 đơn vị ẩn và tỷ lệ dropout 10%. Sau khi đi qua mạng RNN, chúng ta trích xuất điểm thời gian cuối cùng dưới dạng `val[:,-1]` trong hàm `forward()` bên dưới. Điểm này được truyền qua lớp dropout 10% và sau đó được làm phẳng thông qua một lớp tuyến tính.

```
Trong [101]: class NYSEModel(nn.Module): def
    __init__(self):
        super(NYSEModel, self).__init__() self.rnn
        = nn.RNN(3, 12,

                batch_first=True) self.dense
        = nn.Linear(12, 1) self.dropout =
        nn.Dropout(0.1) def forward(self, x):
        val, h_n = self.rnn(x) val
        =
        self.dense(self.dropout(val[:,-1])) return
        torch.flatten(val)
nyse_model = NYSEModel()
```

Chúng tôi điều chỉnh mô hình theo cách tương tự như các mạng trước đây. Chúng tôi cung cấp dữ liệu kiểm thử cho hàm **điều chỉnh** như dữ liệu xác thực, để khi theo dõi tiến trình và vẽ biểu đồ hàm lịch sử, chúng ta có thể thấy sự tiến triển trên dữ liệu kiểm thử. Tất nhiên, chúng ta không nên sử dụng điều này làm cơ sở để dừng sớm, vì khi đó hiệu suất kiểm thử sẽ bị sai lệch.

Chúng tôi xây dựng tập dữ liệu huấn luyện tương tự như ví dụ về **Hitters** .

```
Trong [102]: datasets = []
            đối với mặt nạ trong [train, train]:
                X_rnn_t = torch.tensor(X_rnn[mask].astype(np.float32))
                Y_t = torch.tensor(Y[mask].astype(np.float32))
                datasets.append(TensorDataset(X_rnn_t, Y_t))
            nyse_train, nyse_test = datasets
```

Theo thông lệ, chúng ta sẽ xem xét bản tóm tắt.

```
Trong [103]: tóm tắt(nyse_model,
                    input_data=X_rnn_t,
                    col_names=['input_size',
                               'kích_cỡ_đầu_ra',
                               'num_params'])
```

Out[103]:

Lớp (Loại: chỉ số độ sâu)	Hình dạng đầu vào	Hình dạng đầu ra	Tham số #
Mô hình NYSE	[1770, 5, 3]	[1770]	--
RNN: 1-1	[1770, 5, 3]	[1770, 5, 12]	204
Tỷ lệ bỏ học: 1-2	[1770, 12]	[1770, 12]	--
Tuyến tính: 1-3	[1770, 12]	[1770, 1]	13

Tổng số tham số: 217
Các tham số có thể huấn luyện: 217

Chúng tôi lại đưa hai tập dữ liệu vào một mô-đun dữ liệu, với kích thước lô là 64.

```
Trong [104]: nyse_dm = SimpleDataModule(nyse_train,
                                       nyse_test,
                                       num_workers=min(4, max_num_workers),
                                       xác thực = nyse_test,
                                       batch_size=64)
```

Chúng tôi chạy một số dữ liệu qua mô hình của mình để đảm bảo kích thước khớp chính xác.

```
Trong [105]: for idx, (x, y) in enumerate(nyse_dm.train_dataloader()):
            out = nyse_model(x)
            print(y.size(), out.size())
            nếu idx >= 2:
                phá vỡ
```

torch.Size([64]) torch.Size([64])
torch.Size([64]) torch.Size([64])
torch.Size([64]) torch.Size([64])

Chúng ta sẽ làm theo ví dụ trước đó về việc thiết lập một trình huấn luyện cho phép kiểm định hồi quy. Vấn đề đặt ra là yêu cầu tính toán chỉ số R2 ở mỗi chu kỳ.

```
Trong [106]: nyse_optimizer = RMSprop(nyse_model.parameters(),
                                       lr=0.001)
            nyse_module = SimpleModule.regression(nyse_model,
                                                    optimizer=nyse_optimizer,
                                                    metrics={'r2':R2Score()})
```

Việc điều chỉnh mô hình giờ đây hẳn đã trở nên quen thuộc. Kết quả trên dữ liệu thử nghiệm. Chúng rất giống với mô hình AR tuyến tính.

464 10. Học sâu

```
Trong [107]: nyse_trainer = Trainer(deterministic=True,
                                   max_epochs=200,
                                   callbacks=[ErrorTracker()])

nyse_trainer.fit(nyse_module,
                 datamodule=nyse_dm)

nyse_trainer.test(nyse_module,
                  datamodule=nyse_dm)
```

```
Out[107]: [{'test_loss': 0.6141, 'test_r2': 0.4172}]
```

Chúng ta cũng có thể xây dựng một mô hình mà không cần lớp `nn.RNN()` bằng cách chỉ sử dụng lớp `nn.Flatten()` thay thế. Đây sẽ là một mô hình AR phi tuyến tính. Nếu ngoài ra, chúng ta loại bỏ lớp ẩn, điều này sẽ tương đương với mô hình AR tuyến tính trước đó của chúng ta.

Thay vào đó, chúng ta sẽ sử dụng mô hình AR phi tuyến tính với tập hợp đặc trưng `X_day` bao gồm các chỉ báo ngày trong tuần. Để làm được điều đó, trước tiên chúng ta phải tạo tập dữ liệu huấn luyện và kiểm thử cùng với một mô-đun dữ liệu tương ứng. Điều này có vẻ hơi rắc rối, nhưng là một phần của quy trình chung của `torch`.

```
Trong [108]: datasets = []
for mask in [train, train]: X_day_t
    = torch.tensor(
        np.asarray(X_day[mask]).astype(np.float32))
    Y_t = torch.tensor(np.asarray(Y[mask]).astype(np.float32))
    datasets.append(TensorDataset(X_day_t, Y_t)) day_train,
day_test = datasets
```

Việc tạo một mô-đun dữ liệu tuân theo một quy trình quen thuộc.

```
Trong [109]: day_dm = SimpleDataModule(day_train,
                                       day_test,
                                       num_workers=min(4, max_num_workers),
                                       validation=day_test,
                                       batch_size=64)
```

Chúng tôi xây dựng một `NonLinearARModel()` nhận đầu vào là 20 đặc trưng và một lớp ẩn với 32 đơn vị. Các bước còn lại khá quen thuộc.

```
Trong [110]: class NonLinearARModel(nn.Module): def
    __init__(self):
        super(NonLinearARModel, self).__init__() self._forward
        = nn.Sequential(nn.Flatten(), nn.Linear(20, 32), nn.ReLU(),
                        nn.Dropout(0.5),
                        nn.Linear(32,
                                1))

    def forward(self, x):
        trả về torch.flatten(self._forward(x))
```

```
Trong [111]: nl_model = NonLinearARModel()
nl_optimizer = RMSprop(nl_model.parameters(), lr=0.001)
nl_module =
SimpleModule.regression(nl_model,
                        optimizer=nl_optimizer,
                        metrics={'r2': R2Score()})
```

Chúng ta tiếp tục với các bước huấn luyện thông thường, điều chỉnh mô hình và đánh giá lỗi kiểm thử. Ta thấy R2 kiểm thử cải thiện nhẹ so với mô hình AR tuyến tính cũng bao gồm biến `day_of_week`.

```
Trong [112]: nl_trainer = Trainer(deterministic=True,
                                max_epochs=20,
                                callbacks=[ErrorTracker()])
nl_trainer.fit(nl_module, datamodule=day_dm)
nl_trainer.test(nl_module, datamodule=day_dm)
```

```
Out[112]: [{'test_loss': 0.5625, 'test_r2': 0.4662}]
```

10.10 Bài tập

Khái niệm

1. Hãy xem xét một mạng nơ-ron với hai lớp ẩn: $p = 4$ đơn vị đầu vào, 2 đơn vị ở lớp ẩn thứ nhất, 3 đơn vị ở lớp ẩn thứ hai và một đầu ra duy nhất.

(a) Vẽ sơ đồ mạng, tương tự như Hình 10.1 hoặc 10.4. (b) Viết biểu thức cho $f(X)$, giả sử hàm kích hoạt ReLU.

các hàm. Hãy diễn đạt càng rõ ràng càng tốt!

(c) Bây giờ hãy thay một số giá trị vào các hệ số và viết ra giá trị của $f(X)$. (d)

Có bao nhiêu tham số?

2. Hãy xem xét hàm softmax trong (10.13) (xem thêm (4.13) trên trang 145) để mô hình hóa xác suất đa thức.

(a) Trong (10.13), hãy chứng minh rằng nếu chúng ta thêm một hằng số c vào mỗi z_j , khi đó xác suất không thay đổi.

(b) Trong (4.13), hãy chứng minh rằng nếu chúng ta thêm các hằng số $c_j, j = 0, 1, \dots, p$, vào mỗi hệ số tương ứng cho mỗi lớp, thì các dự đoán tại bất kỳ điểm x mới nào cũng không thay đổi.

Điều này cho thấy hàm softmax bị tham số hóa quá mức. Tuy nhiên, việc điều chỉnh và SGD thường ràng buộc các giải pháp sao cho việc tham số hóa quá mức này không phải là vấn đề.

3. Chứng minh rằng logarit khả năng đa thức âm (10.14) tương đương với logarit âm của biểu thức khả năng (4.5) khi có $M = 2$ lớp.

4. Hãy xem xét một mạng CNN nhận vào ảnh xám 32×32 pixel và có một lớp tích chập duy nhất với ba bộ lọc tích chập 5×5 (không có phần đệm biên).

(a) Vẽ sơ đồ cấu trúc của lớp đầu vào và lớp ẩn đầu tiên tương tự như Hình 10.8.

466 10. Học sâu

(b) Mô hình này có bao nhiêu tham số? (c) Giải thích làm

thế nào mô hình này có thể được coi là một mạng nơ-ron truyền thẳng thông thường với các pixel riêng lẻ làm đầu vào, và có các ràng buộc về trọng số trong các đơn vị ẩn. Các ràng buộc đó là gì?

(d) Nếu không có ràng buộc nào, thì mạng nơ-ron truyền thẳng thông thường trong (c) sẽ có bao nhiêu trọng số?

5. Trong Bảng 10.2 ở trang 426, ta thấy thứ tự của ba phương pháp theo sai số tuyệt đối trung bình khác với thứ tự theo tập dữ liệu kiểm tra R2. Tại sao lại như vậy?

Đã áp dụng

6. Xét hàm đơn giản $R(\beta) = \sin(\beta) + \beta/10$.

(a) Vẽ đồ thị của hàm số này trên khoảng $\beta \in [-6, 6]$. (b) Đạo hàm của hàm

số này là gì? (c) Cho $\beta_0 = 2,3$, hãy chạy thuật toán

gradient descent để tìm cực tiểu địa phương của $R(\beta)$ với tốc độ học $p = 0,1$. Hiển thị từng giá trị $\beta_0, \beta_1, \dots$ trên đồ thị của bạn, cũng như kết quả cuối cùng. (d) Lặp lại với $\beta_0 = 1,4$.

7. Huấn luyện một mạng nơ-ron cho dữ liệu **mặc định**. Sử dụng một lớp ẩn duy nhất với 10 đơn vị và chuẩn hóa dropout. Tham khảo các bài thực hành 10.9.1- 10.9.2 để được hướng dẫn. So sánh hiệu suất phân loại của mô hình của bạn với hiệu suất của hồi quy logistic tuyến tính.

8. Từ bộ sưu tập ảnh cá nhân của bạn, hãy chọn 10 hình ảnh về động vật (như chó, mèo, chim, gia súc, v.v.). Nếu chủ thể không chiếm một phần đáng kể của hình ảnh, thì hãy cắt xén ảnh. Bây giờ hãy sử dụng mạng CNN phân loại hình ảnh đã được huấn luyện trước như trong Bài thực hành 10.9.4 để dự đoán lớp của mỗi hình ảnh và báo cáo xác suất cho năm lớp được dự đoán hàng đầu cho mỗi hình ảnh.

9. Áp dụng mô hình tự hồi quy bậc 5 cho dữ liệu **NYSE**, như mô tả trong văn bản và Bài thực hành 10.9.6. Điều chỉnh lại mô hình với một yếu tố 12 cấp độ đại diện cho tháng. Yếu tố này có cải thiện hiệu suất của mô hình không?

10. Trong Mục 10.9.6, chúng ta đã trình bày cách áp dụng mô hình AR tuyến tính cho dữ liệu **NYSE** bằng cách sử dụng hàm `LinearRegression()`. Tuy nhiên, chúng ta cũng đã đề cập rằng chúng ta có thể "làm phẳng" các chuỗi ngắn được tạo ra cho mô hình RNN để áp dụng mô hình AR tuyến tính. Hãy sử dụng phương pháp thứ hai này để áp dụng mô hình AR tuyến tính cho dữ liệu **NYSE**. So sánh hệ số R2 kiểm thử của mô hình AR tuyến tính này với hệ số R2 của mô hình AR tuyến tính mà chúng ta đã áp dụng trong bài thực hành. Ưu điểm/nhược điểm của mỗi phương pháp là gì?

11. Lặp lại bài tập trước, nhưng lần này hãy điều chỉnh mô hình AR phi tuyến tính bằng cách "làm phẳng" các chuỗi ngắn được tạo ra cho mô hình RNN.

12. Hãy xem xét mô hình RNN được huấn luyện cho dữ liệu **NYSE** trong Mục **10.9.6**. Sửa đổi mã để cho phép bao gồm biến **day_of_week** và huấn luyện mô hình RNN.
Tính giá trị R^2 của bài kiểm tra .
13. Lập lại phân tích của Bài tập **10.9.5** trên dữ liệu **IMDb** bằng cách sử dụng mạng nơ-ron có cấu trúc tương tự. Chúng tôi đã sử dụng 16 đơn vị ẩn ở mỗi trong hai lớp ẩn. Khám phá ảnh hưởng của việc tăng số lượng này lên 32 và 64 đơn vị mỗi lớp, có và không có chuẩn hóa dropout 30%.



Phân tích sống sót và dữ liệu bị kiểm duyệt

Trong chương này, chúng ta sẽ xem xét các chủ đề về phân tích sống sót và dữ liệu bị kiểm duyệt. Những vấn đề này phát sinh trong việc phân tích một loại biến kết quả đặc biệt: thời gian cho đến khi một sự kiện xảy ra.

sống sót

Phân tích

bị kiểm duyệt

dữ liệu

Ví dụ, giả sử chúng ta đã tiến hành một nghiên cứu y học kéo dài 5 năm, trong đó bệnh nhân đã được điều trị ung thư. Chúng tôi muốn phù hợp với một mô hình. Để dự đoán thời gian sống sót của bệnh nhân, sử dụng các đặc điểm như các chỉ số sức khỏe ban đầu hoặc loại điều trị. Thoạt nhìn, điều này có vẻ giống như một bài toán hồi quy đã được thảo luận trong Chương 3. Nhưng có một điều quan trọng cần lưu ý. Biến chứng: Hy vọng một số hoặc nhiều bệnh nhân đã sống sót cho đến khi kết thúc nghiên cứu. Thời gian sống sót của bệnh nhân như vậy được gọi là bị kiểm duyệt: chúng ta biết rằng ít nhất là năm năm, nhưng chúng ta không biết giá trị thực sự của nó. Chúng ta biết không muốn loại bỏ nhóm bệnh nhân sống sót này, vì thực tế là họ. Việc sống sót ít nhất năm năm là một thông tin có giá trị. Tuy nhiên, điều đó... Chưa rõ cách sử dụng thông tin này bằng các kỹ thuật đã đề cập. cho đến nay trong sách giáo khoa này.

Mặc dù cụm từ “phân tích sống sót” gợi ý liên tưởng đến một nghiên cứu y học, nhưng ứng dụng của phân tích sống sót lại vượt xa lĩnh vực y học. Ví dụ: Hãy xem xét một công ty muốn mô hình hóa tỷ lệ khách hàng hủy đăng ký dịch vụ. Công ty đó có thể thu thập dữ liệu về... khách hàng trong một khoảng thời gian nhất định, nhằm mục đích mô hình hóa thời gian của mỗi khách hàng. việc hủy bỏ phụ thuộc vào yếu tố nhân khẩu học hoặc các yếu tố dự báo khác. Tuy nhiên, Có lẽ không phải tất cả khách hàng đều đã hủy đăng ký của họ trước thời điểm đó. kết thúc khoảng thời gian này; đối với những khách hàng như vậy, thời gian hủy bỏ là đã bị kiểm duyệt.

Trên thực tế, phân tích khả năng sống sót vẫn có liên quan ngay cả trong các lĩnh vực ứng dụng mà... không liên quan đến thời gian. Ví dụ, giả sử chúng ta muốn mô hình hóa cân nặng của một người. như một hàm của một số biến phụ thuộc, sử dụng tập dữ liệu với các phép đo cho một Một số lượng lớn người. Thật không may, chiếc cân được dùng để cân những người đó lại... Không thể báo cáo trọng lượng vượt quá một con số nhất định. Sau đó, bất kỳ trọng lượng nào mà

Những dữ liệu vượt quá con số đó sẽ bị kiểm duyệt. Các phương pháp phân tích sống sót được trình bày trong chương này có thể được sử dụng để phân tích tập dữ liệu này.

Phân tích sống sót là một chủ đề được nghiên cứu rất kỹ trong thống kê, do tầm quan trọng thiết yếu của nó trong nhiều ứng dụng, cả trong và ngoài lĩnh vực y học. Tuy nhiên, nó lại nhận được khá ít sự chú ý trong cộng đồng máy học.

11.1 Thời kỳ sinh tồn và kiểm duyệt

Đối với mỗi cá nhân, chúng ta giả định rằng có một thời gian sống sót thực sự, T , cũng như một thời gian bị loại trừ thực sự, C . (Thời gian sống sót còn được gọi là thời gian thất bại hoặc thời gian xảy ra sự kiện.) Thời gian sống sót biểu thị thời điểm xảy ra sự kiện quan tâm: ví dụ, thời điểm bệnh nhân tử vong hoặc khách hàng hủy đăng ký. Ngược lại, thời gian bị loại trừ là thời điểm xảy ra việc loại trừ: ví dụ, thời điểm bệnh nhân bỏ cuộc khỏi nghiên cứu hoặc nghiên cứu kết thúc.

thời gian sống sót
thời gian kiểm
duyet
thời gian thất bại
thời gian sự kiện

Chúng ta quan sát thời gian sống sót T hoặc thời gian bị kiểm duyệt C . Cụ thể, chúng ta quan sát biến ngẫu nhiên

$$Y = \min(T,C). \tag{11.1}$$

Nói cách khác, nếu sự kiện xảy ra trước khi bị kiểm duyệt (tức là $T < C$) thì ta quan sát được thời gian sống sót thực sự T ; tuy nhiên, nếu việc kiểm duyệt xảy ra trước sự kiện ($T > C$) thì ta quan sát được thời gian kiểm duyệt. Ta cũng quan sát được một chỉ báo trạng thái.


$$\delta = \begin{cases} 1 & \text{nếu } T \leq C \\ 0 & \text{nếu } T > C. \end{cases}$$

Do đó, $\delta = 1$ nếu ta quan sát thời gian sống sót thực sự, và $\delta = 0$ nếu ta quan sát thời gian bị kiểm duyệt.

Giả sử ta quan sát n cặp (Y, δ) , ký hiệu là $(y_1, \delta_1), \dots, (y_n, \delta_n)$. Hình 11.1 minh họa một ví dụ từ một nghiên cứu y khoa (giả định) trong đó ta quan sát $n = 4$ bệnh nhân trong thời gian theo dõi 365 ngày. Đối với bệnh nhân 1 và 3, ta quan sát thời gian xảy ra sự kiện (như tử vong hoặc tái phát bệnh) $T = t_i$. Bệnh nhân 2 còn sống khi nghiên cứu kết thúc, và bệnh nhân 4 bỏ cuộc giữa chừng, hay bị "mất liên lạc"; đối với những bệnh nhân này, ta quan sát $C = c_i$. Do đó, $y_1 = t_1, y_3 = t_3, y_2 = c_2, y_4 = c_4, \delta_1 = \delta_3 = 1$, và $\delta_2 = \delta_4 = 0$.

11.2 Cái nhìn sâu hơn về kiểm duyệt

Để phân tích dữ liệu sống sót, chúng ta cần đưa ra một số giả định về lý do tại sao hiện tượng kiểm duyệt xảy ra. Ví dụ, giả sử một số bệnh nhân bỏ cuộc sớm khỏi nghiên cứu ung thư vì họ quá yếu. Một phân tích không xem xét lý do tại sao bệnh nhân bỏ cuộc có thể sẽ đánh giá quá cao thời gian sống sót trung bình thực sự. Tương tự, giả sử nam giới bị bệnh nặng có nhiều khả năng bỏ cuộc khỏi nghiên cứu hơn so với những người khác.



HÌNH 11.1. Minh họa dữ liệu sống sót bị kiểm duyệt. Đối với bệnh nhân 1 và 3, sự kiện đã được quan sát. Bệnh nhân 2 còn sống khi nghiên cứu kết thúc. Bệnh nhân 4 đã bỏ cuộc khỏi nghiên cứu.

những phụ nữ bị bệnh rất nặng. Khi đó, việc so sánh thời gian sống sót của nam và nữ có thể dẫn đến kết luận sai lầm rằng nam giới sống lâu hơn nữ giới.

Nhìn chung, chúng ta cần giả định rằng cơ chế kiểm duyệt là độc lập: tùy thuộc vào các đặc điểm, thời gian xảy ra sự kiện T độc lập với thời gian kiểm duyệt C . Hai ví dụ trên vi phạm giả định về kiểm duyệt độc lập. Thông thường, không thể xác định từ chính dữ liệu liệu cơ chế kiểm duyệt có độc lập hay không. Thay vào đó, người ta phải xem xét cẩn thận quá trình thu thập dữ liệu để xác định xem giả định kiểm duyệt độc lập có hợp lý hay không. Trong phần còn lại của chương này, chúng ta sẽ giả định rằng cơ chế kiểm duyệt là độc lập.

Trong chương này, chúng ta tập trung vào hiện tượng kiểm duyệt phải, xảy ra khi $T \geq Y$. , Tức là thời gian xảy ra sự kiện thực tế T ít nhất cũng lớn bằng thời gian quan sát được Y . (Lưu ý rằng $T \geq Y$ là hệ quả của (11.1). Kiểm duyệt phải có tên gọi như vậy vì thời gian thường được hiển thị từ trái sang phải, như trong Hình 11.1.) Tuy nhiên, các loại kiểm duyệt khác cũng có thể xảy ra. Ví dụ, trong kiểm duyệt trái, thời gian xảy ra sự kiện thực sự T nhỏ hơn hoặc bằng thời gian quan sát được Y . Ví dụ, trong một nghiên cứu về thời gian mang thai, giả sử chúng ta khảo sát bệnh nhân 250 ngày sau khi thụ thai, khi một số người đã sinh con. Khi đó, chúng ta biết rằng đối với những bệnh nhân đó, thời gian mang thai là dưới 250 ngày. Tổng quát hơn, kiểm duyệt khoảng đề cập đến trường hợp chúng ta không biết thời gian xảy ra sự kiện chính xác, nhưng chúng ta biết rằng nó nằm trong một khoảng nào đó. Ví dụ, trường hợp này phát sinh nếu chúng ta khảo sát bệnh nhân mỗi tuần một lần để xác định xem sự kiện đã xảy ra hay chưa. Mặc dù kiểm duyệt trái và kiểm duyệt khoảng có thể được xử lý bằng cách sử dụng các biến thể của các ý tưởng được trình bày trong chương này, nhưng trong phần tiếp theo, chúng ta sẽ tập trung cụ thể vào kiểm duyệt phải.

1. Giả định về kiểm duyệt độc lập có thể được nới lỏng phần nào bằng cách sử dụng khái niệm kiểm duyệt không mang tính thông tin; tuy nhiên, định nghĩa về kiểm duyệt không mang tính thông tin quá chuyên sâu đối với cuốn sách này.

11.3 Đường cong sống sót Kaplan-Meier

Đường cong sống sót, hay hàm sống sót, được định nghĩa là

S(t) = Pr(T > t). (11.2)

sống sót
đường cong
chức năng
sinh tồn

Hàm giảm dần này định lượng xác suất sống sót sau thời điểm t. Ví dụ, giả sử một công ty quan tâm đến việc mô hình hóa tỷ lệ khách hàng rời bỏ dịch vụ. Gọi T là thời điểm khách hàng hủy đăng ký dịch vụ của công ty. Khi đó, S(t) biểu thị xác suất khách hàng hủy đăng ký sau thời điểm t. Giá trị của S(t) càng lớn, khả năng khách hàng hủy đăng ký trước thời điểm t càng thấp.

Trong phần này, chúng ta sẽ xem xét nhiệm vụ ước tính đường cong sống sót. Nghiên cứu của chúng tôi được thúc đẩy bởi bộ dữ liệu **BrainCancer**, chứa thời gian sống sót của bệnh nhân mắc u não nguyên phát được điều trị bằng phương pháp xạ trị định vị.² Các biến dự báo là **gtv** (thể tích khối u thô, tính bằng centimet khối); **giới tính** (nam hoặc nữ); **chẩn đoán** (u màng não, u tế bào thần kinh đệm độ thấp, u tế bào thần kinh đệm độ cao hoặc các loại khác); **loc** (vị trí khối u: dưới lều tiểu não hoặc trên lều tiểu não); **ki** (chỉ số Karnofsky); và **stereo** (phương pháp định vị: phẫu thuật xạ trị định vị hoặc xạ trị định vị phân đoạn, viết tắt là SRS và SRT).

Chỉ còn 53 trong số 88 bệnh nhân còn sống khi nghiên cứu kết thúc.

Bây giờ, chúng ta xem xét nhiệm vụ ước tính đường cong sống sót (11.2) cho dữ liệu này. Để ước tính S(20) = Pr(T > 20), xác suất bệnh nhân sống sót ít nhất t = 20 tháng, ta có thể dễ dàng tính toán tỷ lệ bệnh nhân được biết là đã sống sót qua 20 tháng, tức là tỷ lệ bệnh nhân có Y > 20. Kết quả là 48/88, hoặc xấp xỉ 55%. Tuy nhiên, điều này dường như không hoàn toàn chính xác, vì Y và T đại diện cho các đại lượng khác nhau. Cụ thể, 17 trong số 40 bệnh nhân không sống sót đến 20 tháng thực sự bị kiểm duyệt, và phân tích này ngầm giả định rằng T < 20 đối với tất cả những bệnh nhân bị kiểm duyệt đó; tất nhiên, chúng ta không biết liệu điều đó có đúng hay không.

Ngoài ra, để ước tính S(20), chúng ta có thể xem xét tính toán tỷ lệ bệnh nhân có Y > 20 trong số 71 bệnh nhân không bị kiểm duyệt ở thời điểm t = 20; kết quả là 48/71, hoặc xấp xỉ 68%.

Tuy nhiên, điều này cũng không hoàn toàn đúng, vì nó đồng nghĩa với việc hoàn toàn bỏ qua những bệnh nhân bị loại khỏi nghiên cứu trước thời điểm t = 20, mặc dù thời điểm họ bị loại khỏi nghiên cứu có thể cung cấp thông tin hữu ích. Ví dụ, một bệnh nhân bị loại khỏi nghiên cứu ở thời điểm t = 19,9 có khả năng đã sống sót qua thời điểm t = 20 nếu họ không bị loại khỏi nghiên cứu.

Chúng ta đã thấy rằng việc ước tính S(t) trở nên phức tạp do sự hiện diện của dữ liệu bị kiểm duyệt. Bây giờ chúng ta trình bày một phương pháp để khắc phục những thách thức này. Chúng ta ký hiệu d1 < d2 < ... < dK là K thời điểm tử vong duy nhất trong số các bệnh nhân không bị kiểm duyệt, và chúng ta ký hiệu qk là số bệnh nhân đã chết tại thời điểm dk. Đối với k = 1, ..., K, chúng ta ký hiệu rk là số bệnh nhân còn sống.

²Bộ dữ liệu này được mô tả trong bài báo sau: Selingerová et al. (2016) Sự sống sót của bệnh nhân mắc u não nguyên phát: So sánh hai phương pháp thống kê. PLoS One, 11(2):e0148733.

Và trong nghiên cứu ngay trước đó, đây là những bệnh nhân có nguy cơ. Tập hợp các bệnh nhân có nguy cơ tại một thời điểm nhất định được gọi là tập hợp nguy cơ.

tập hợp rủi ro

Theo định luật xác suất toàn phần,³

$$\Pr(T > dk) = \Pr(T > dk | T > dk - 1) \Pr(T > dk - 1) + \Pr(T > dk | T \leq dk - 1) \Pr(T \leq dk - 1).$$

Việc $dk - 1 < dk$ ngụ ý rằng $\Pr(T > dk | T \leq dk - 1) = 0$ (không thể có bệnh nhân nào sống sót quá thời điểm dk nếu họ không sống sót đến thời điểm trước đó là $dk - 1$). Do đó,

$$S(dk) = \Pr(T > dk) = \Pr(T > dk | T > dk - 1) \Pr(T > dk - 1).$$

Khi thay (11.2) vào lại, ta thấy rằng

$$S(dk) = \Pr(T > dk | T > dk - 1) S(dk - 1).$$

Điều này ngụ ý rằng

$$S(dk) = \Pr(T > dk | T > dk - 1) \times \cdots \times \Pr(T > d2 | T > d1) \Pr(T > d1).$$

Bây giờ chúng ta chỉ cần thay thế các ước lượng của từng số hạng ở phía bên phải của phương trình trước đó. Việc sử dụng bộ ước lượng là điều tự nhiên.

$$\Pr(T > dj | T > dj - 1) = (r_j - q_j) / r_j,$$

đó là tỷ lệ những người có nguy cơ gặp sự cố tại thời điểm dj đã sống sót sau thời điểm dj . Điều này dẫn đến công thức ước lượng Kaplan-Meier cho đường cong sống sót:

Kaplan-
Bộ ước
lượng Meier


$$S(dk) = \prod_{j=1}^k \frac{r_j - q_j}{r_j}. \tag{11.3}$$

Đối với thời điểm t nằm giữa dk và $dk+1$, ta đặt $S(t) = S(dk)$. Do đó, đường cong sống sót Kaplan-Meier có dạng bậc thang.


Đường cong sống sót Kaplan-Meier cho dữ liệu **BrainCancer** được hiển thị trong Hình 11.2. Mỗi điểm trên đường cong bậc thang liền nét thể hiện xác suất ước tính sống sót sau thời gian được chỉ định trên trục hoành. Xác suất ước tính sống sót sau 20 tháng là 71%, cao hơn đáng kể so với các ước tính đơn giản là 55% và 68% đã trình bày trước đó.

Việc xây dựng tuần tự ước lượng Kaplan-Meier – bắt đầu từ thời điểm 0 và lập bản đồ các sự kiện quan sát được khi chúng diễn ra theo thời gian – là nền tảng của nhiều kỹ thuật quan trọng trong phân tích sống sót. Chúng bao gồm kiểm định log-rank trong Phần 11.4 và mô hình nguy cơ tỷ lệ của Cox trong Phần 11.5.2.

3. Định luật xác suất toàn phần phát biểu rằng đối với bất kỳ hai sự kiện A và B nào, $\Pr(A) = \Pr(A|B) \Pr(B) + \Pr(A|B^c) \Pr(B^c)$, trong đó B^c là phần bù của sự kiện B, tức là nó là sự kiện mà B không xảy ra.



HÌNH 11.2. Đối với dữ liệu về Ung thư não, chúng tôi hiển thị tỷ lệ sống sót Kaplan-Meier. đường cong (đường cong liền nét), cùng với các dải sai số chuẩn (đường cong nét đứt).



HÌNH 11.3. Đối với dữ liệu Ung thư não, đường cong sống sót Kaplan-Meier cho Hình ảnh hiển thị cả cá thể đực và cái.

11.4 Kiểm định Log-Rank

Chúng ta tiếp tục phân tích dữ liệu về ung thư não đã được giới thiệu trong Phần 11.3. Chúng ta muốn so sánh tỷ lệ sống sót của nam giới với nữ giới.

Hình 11.3 thể hiện đường cong tỷ lệ sống sót Kaplan-Meier cho hai nhóm.

Con cái dường như có sức khỏe tốt hơn một chút cho đến khoảng 50 tháng tuổi, nhưng sau đó thì...

Hai đường cong đều ổn định ở mức khoảng 50%. Làm thế nào chúng ta có thể tiến hành một bài kiểm tra chính thức?

Liệu hai đường cong sống sót có bằng nhau không?

Thoạt nhìn, phép kiểm định t hai mẫu có vẻ là lựa chọn hiển nhiên: chúng ta có thể kiểm tra xem thời gian sống trung bình của các cá thể cái có bằng thời gian sống trung bình của các cá thể khác hay không. thời gian sống sót của nam giới. Nhưng sự hiện diện của việc kiểm duyệt lại tạo ra một vấn đề phức tạp. Để khắc phục thách thức này, chúng ta sẽ tiến hành kiểm định log-rank.

	Nhóm 1		Nhóm 2		Tổng cộng	
Đã chết	q1k		q2k		qk	
Survived	r1k	q1k	r2k	q2k	rk	qk
Tổng cộng	r1k		r2k		rk	

BẢNG 11.1. Trong số các bệnh nhân có nguy cơ tại thời điểm dk, số lượng bệnh nhân sống sót và số người chết trong mỗi nhóm được báo cáo.

Nội dung này xem xét cách các sự kiện trong mỗi nhóm diễn ra tuần tự theo thời gian. Hãy nhớ lại từ Mục 11.3 rằng $d_1 < d_2 < \dots < d_K$ là các trường hợp tử vong duy nhất trong số các bệnh nhân không bị kiểm duyệt, r_k là số bệnh nhân tại nguy cơ tại thời điểm d_k , và q_k là số bệnh nhân đã tử vong tại thời điểm d_k . Chúng tôi xác định rõ hơn r_{1k} và r_{2k} là số lượng bệnh nhân trong nhóm 1 và nhóm 2. Tương ứng, chúng ta định nghĩa q_{1k} và q_{2k} như sau: là số bệnh nhân trong nhóm 1 và nhóm 2, tương ứng, đã tử vong tại thời điểm d_k . Lưu ý rằng $r_{1k} + r_{2k} = r_k$ và $q_{1k} + q_{2k} = q_k$. Tại mỗi thời điểm tử vong d_k , chúng ta lập một bảng thống kê 2×2 có dạng như sau: được hiển thị trong Bảng 11.1. Lưu ý rằng nếu thời điểm tử vong là duy nhất (tức là không có hai trường hợp trùng lặp) (nếu các cá nhân chết cùng một lúc), thì một trong q_{1k} và q_{2k} bằng một, và cái còn lại bằng không. Ý tưởng chính đằng sau thống kê kiểm định log-rank như sau. Theo thứ tự để kiểm tra giả thuyết $H_0 : E(X) = \mu$ đối với một biến ngẫu nhiên X nào đó, một cách tiếp cận là... xây dựng một thống kê kiểm định có dạng

$$W = \frac{\sum_{k=1}^K X_k \mu_k}{\text{Var}(X)}$$

(11.4)

Để xây dựng thống kê kiểm định log-rank, chúng ta tính toán một đại lượng có chính xác dạng (11.4), với $X = \sum_{k=1}^K q_{1k}$, trong đó q_{1k} được cho ở trên của Bảng 11.1.

Cụ thể hơn, nếu không có sự khác biệt về tỷ lệ sống sót giữa hai nhóm các nhóm, và dựa trên tổng hàng và tổng cột trong Bảng 11.1, thì Giá trị kỳ vọng của q_{1k} là

$$\mu_k = \frac{r_{1k}}{r_k} q_k.$$

(11.5)

Vậy giá trị kỳ vọng của $X = \sum_{k=1}^K q_{1k}$ là $\mu = \sum_{k=1}^K \frac{r_{1k}}{r_k} q_k$. Hơn nữa, minh được rằng phương sai của q_{1k} là

$$\text{Var}(q_{1k}) = \frac{q_k(r_{1k}/r_k)(1 - r_{1k}/r_k)(r_k - q_k)}{r_k - 1}.$$

(11.6)

Mặc dù $q_{11}, \dots, q_{1K}$ có thể tương quan với nhau, chúng tôi vẫn ước tính

$$\text{Var} \sum_{k=1}^K q_{1k} \approx \sum_{k=1}^K \text{Var}(q_{1k}) = \sum_{k=1}^K \frac{q_k(r_{1k}/r_k)(1 - r_{1k}/r_k)(r_k - q_k)}{r_k - 1}.$$

(11.7)

4. Kiểm định log-rank còn được gọi là kiểm định Mantel-Haenszel hoặc kiểm định Cochran-Mantel-Bai kiểm tra Haenszel.
Để biết thêm chi tiết, xem Bài tập 7 ở cuối chương này.

Do đó, để tính toán thống kê kiểm định log-rank, chúng ta chỉ cần tiến hành như sau: trong (11.4), với $X = \sum_{k=1}^K q_{1k}$, sử dụng (11.5) và (11.7). Tức là, chúng ta tính toán

$$W = \frac{\sum_{k=1}^K (q_{1k} - \mu_k)}{\sum_{k=1}^K \text{Var}(q_{1k})} = \frac{\sum_{k=1}^K q_{1k} - \frac{\sum_{k=1}^K q_{1k}^2}{\sum_{k=1}^K q_{1k}}}{\sum_{k=1}^K \frac{q_{1k}(r_{1k}/r_k)(1 - r_{1k}/r_k)(r_k - q_k)}{r_k}} \quad (11.8)$$

Khi kích thước mẫu lớn, thống kê kiểm định log-rank W có phân phối chuẩn tắc xấp xỉ; điều này có thể được sử dụng để tính toán giá trị p cho giả thuyết không rằng không có sự khác biệt giữa Đường cong tỷ lệ sống sót ở hai nhóm.⁶

Sở dĩ thời gian sống sót của nữ giới và nam giới trong nghiên cứu Ung thư não. Dữ liệu cho thấy thống kê kiểm định log-rank là $W = 1,2$, tương ứng với giá trị p hai phía là $0,2$ khi sử dụng phân phối giả thuyết không, và giá trị p với hệ số $0,25$ sử dụng phân phối giả thuyết không với 1.000 phép hoán vị. Do đó, chúng ta không thể bác bỏ giả thuyết không có sự khác biệt về đường cong sống sót giữa nữ và nam.

Kiểm định log-rank có liên quan mật thiết đến mô hình rủi ro tỷ lệ của Cox. mà chúng ta sẽ thảo luận trong Phần 11.5.2.

11.5 Mô hình hồi quy với biến phản hồi sống sót

Bây giờ chúng ta xem xét nhiệm vụ điều chỉnh mô hình hồi quy cho dữ liệu về thời gian sống sót. Như trong Phần 11.1, các quan sát có dạng (Y, δ) , trong đó $Y = \min(T, C)$ là thời gian sống sót (có thể bị kiểm duyệt), và δ là một chỉ báo. biến bằng 1 nếu $T \leq C$. Hơn nữa, X là một vectơ của p các đặc điểm. Chúng tôi muốn dự đoán thời gian sống sót thực sự T .

Vì đại lượng quan sát được Y là dương và có thể có chiều dài lớn, nên phải có hướng sang phải. ở phần đuôi, chúng ta có thể bị cám dỗ để sử dụng hồi quy tuyến tính của $\log(Y)$ trên X . Nhưng Như độc giả chắc chắn sẽ đoán được, việc kiểm duyệt lại tạo ra một vấn đề khác vì Thực ra chúng ta quan tâm đến việc dự đoán T chứ không phải Y . Để khắc phục điều này... vì khó khăn, thay vào đó chúng tôi sử dụng cấu trúc tuần tự, tương tự như... các phương pháp xây dựng đường cong sống sót Kaplan-Meier trong Phần 11.3 và Kiểm định log-rank trong Mục 11.4.

11.5.1 Chức năng nguy hiểm

Hàm nguy hiểm hay tỷ lệ nguy hiểm – còn được gọi là lực lượng gây tử vong – được định nghĩa chính thức như sau:

chức năng
nguy hiểm

$$h(t) = \lim_{t \rightarrow 0} \frac{\Pr(t < T \leq t + t \mid T > t)}{t}, \quad (11.9)$$

⁶Ngoài ra, chúng ta có thể ước tính giá trị p thông qua phép hoán vị, sử dụng các ý tưởng sẽ sẽ được trình bày trong Mục 13.5. Phân phối hoán vị được thu được bằng cách ngẫu nhiên Hoán đổi nhãn cho các quan sát trong hai nhóm.

trong đó T là thời gian sống sót (không quan sát được). Đó là tỷ lệ tử vong ngay sau thời gian t , với điều kiện sống sót sau thời gian đó.⁷ Trong (11.9), chúng ta lấy giới hạn khi t tiến đến 0, vì vậy chúng ta có thể coi t là một số cực kỳ nhỏ. Do đó, một cách không chính thức hơn, (11.9) ngụ ý rằng

$$\approx \frac{\Pr(t < T \leq t + t | T > t) h(t)}{t}$$

với một giá trị t nhỏ tùy ý.

Tại sao chúng ta nên quan tâm đến hàm nguy hiểm? Trước hết, nó có liên quan chặt chẽ đến đường cong sống sót (11.2), như chúng ta sẽ thấy tiếp theo. Thứ hai, hóa ra một phương pháp quan trọng để mô hình hóa dữ liệu sống sót như một hàm của các biến độc lập phụ thuộc rất nhiều vào hàm nguy hiểm; chúng ta sẽ giới thiệu phương pháp này – mô hình nguy hiểm tỷ lệ của Cox – trong Phần 11.5.2.

Bây giờ chúng ta xem xét hàm nguy hiểm $h(t)$ chi tiết hơn một chút. Nhớ lại rằng đối với hai sự kiện A và B , xác suất của A khi biết B có thể được biểu thị là $\Pr(A | B) = \Pr(A \cap B) / \Pr(B)$, tức là xác suất cả A và B cùng xảy ra chia cho xác suất B xảy ra. Hơn nữa, hãy nhớ lại từ (11.2) rằng $S(t) = \Pr(T > t)$. Do đó, $\Pr((t < T \leq t + t) \cap (T > t)) / h(t) = \lim_{t \rightarrow 0} \frac{\Pr(T > t)}{\Pr(T > t)}$

$$\begin{aligned} &= \lim_{t \rightarrow 0} \frac{\Pr(t < T \leq t + t) / \Pr(T > t)}{\Pr(T > t)} \\ &= \frac{f(t)}{S(t)}, \end{aligned} \quad (11.10)$$

ở đâu

$$f(t) = \lim_{t \rightarrow 0} \frac{\Pr(t < T \leq t + t)}{t} \quad (11.11)$$

là hàm mật độ xác suất liên quan đến T , tức là nó là tỷ lệ tử vong tức thời tại thời điểm t . Đồng thức thứ hai trong (11.10) sử dụng thực tế là nếu $t < T \leq t + t$ thì phải là trường hợp $T > t$. hàm mật độ
xác suất

Phương trình 11.10 ngụ ý mối quan hệ giữa hàm nguy hiểm $h(t)$, hàm sống sót $S(t)$ và hàm mật độ xác suất $f(t)$. Trên thực tế, đây là ba cách tương đương để mô tả sự phân bố của T .

Xác suất liên quan đến quan sát thứ i là

$$\begin{aligned} L_i &= \frac{f(y_i) \text{ nếu quan sát thứ } i \text{ không bị kiểm duyệt}}{S(y_i) \text{ nếu quan sát thứ } i \text{ bị kiểm duyệt}} \\ &= \frac{f(y_i)}{S(y_i)} \delta_i \cdot \mathbf{1}_{\delta_i = 1} \end{aligned} \quad (11.12)$$

Ý tưởng đằng sau (11.12) như sau: nếu $Y = y_i$ và quan sát thứ i không bị kiểm duyệt, thì xác suất là xác suất chết trong một khoảng thời gian rất nhỏ xung quanh thời điểm y_i . Nếu quan sát thứ i bị kiểm duyệt, thì xác suất

⁷Do t ở mẫu số của (11.9), hàm nguy hiểm là tỷ lệ tử vong chứ không phải xác suất tử vong. Tuy nhiên, giá trị $h(t)$ càng cao thì xác suất tử vong càng cao, giống như giá trị $h(t)$ càng cao thì kết quả có khả năng xảy ra càng nhiều đối với một biến ngẫu nhiên. Thực tế, $h(t)$ là hàm mật độ xác suất cho T với điều kiện $T > t$.

là xác suất sống sót ít nhất cho đến thời điểm y_i . Giả sử rằng n Nếu các quan sát là độc lập, xác suất của dữ liệu có dạng

$$L = \prod_{i=1}^N f(y_i) \delta_i S(y_i) = \prod_{i=1}^N h(y_i) \delta_i S(y_i), \tag{11.13}$$

trong đó đẳng thức thứ hai xuất phát từ (11.10).

Bây giờ chúng ta xem xét nhiệm vụ mô hình hóa thời gian sống sót. Nếu ta giả định sự sống sót theo hàm mũ, tức là hàm mật độ xác suất của sự sống sót thời gian T có dạng $f(t) = \lambda \exp(-\lambda t)$, sau đó ước lượng tham số λ bằng cách tối đa hóa xác suất trong (11.13) là điều đơn giản.9 Ngoài ra, Chúng ta có thể giả định rằng thời gian sống sót được lấy từ một nguồn linh hoạt hơn.

họ phân phối, chẳng hạn như họ Gamma hoặc Weibull. Một ví dụ khác

Một khả năng khác là mô hình hóa thời gian sống sót một cách phi tham số, như đã được thực hiện trong Mục 11.3 sử dụng ước lượng Kaplan-Meier.

Tuy nhiên, điều chúng ta thực sự muốn làm là mô hình hóa thời gian sống sót như sau: một hàm của các biến độc lập. Để làm điều này, thuận tiện nhất là làm việc trực tiếp với hàm nguy hiểm, thay vì hàm mật độ xác suất.10

Một cách tiếp cận khả thi là giả định một dạng hàm cho hàm nguy hiểm $h(t|x_i)$, chẳng hạn như $h(t|x_i) = \exp\{\beta_0 + \beta_j x_{ij}\}$, trong đó β_j là các số mũ

Hàm này đảm bảo rằng hàm nguy hiểm là không âm. Lưu ý rằng

Hàm nguy hiểm theo cấp số mũ là một trường hợp đặc biệt, ở chỗ nó không thay đổi theo thời gian.11 Cho $h(t|x_i)$, chúng ta có thể tính $S(t|x_i)$. Thay các phương trình này vào vào (11.13), sau đó chúng ta có thể tối đa hóa xác suất để ước tính tham số $\beta = (\beta_0, \beta_1, \dots, \beta_p)'$. Tuy nhiên, cách tiếp cận này khá hạn chế, theo nghĩa là nó yêu cầu chúng ta phải đưa ra một giả định rất nghiêm ngặt về dạng của hàm nguy hiểm $h(t|x_i)$. Trong phần tiếp theo, chúng ta sẽ Hãy xem xét một cách tiếp cận linh hoạt hơn nhiều.

11.5.2 Rủi ro tỷ lệ thuận

Giả định về rủi ro tỷ lệ thuận

Giả định về tỷ lệ nguy cơ tương ứng cho rằng:

tỷ lệ
mối nguy hiểm
giả định

$$h(t|x_i) = h_0(t) \exp \sum_{j=1}^p x_{ij} \beta_j \tag{11.14}$$

trong đó $h_0(t) \geq 0$ là một hàm không xác định, được gọi là nguy cơ cơ bản.

Đây là hàm rủi ro cho một cá nhân có các đặc điểm $x_{i1} = \dots = x_{ip} =$


0. Tên gọi “rủi ro tỷ lệ thuận” xuất phát từ thực tế là rủi ro

Hàm dành cho một cá nhân có vectơ đặc trưng x_i là một hàm chưa biết nào đó.

9Xem Bài tập 9.

10. Với mỗi quan hệ chặt chẽ giữa hàm nguy hiểm $h(t)$ và hàm mật độ $f(t)$ được khảo sát trong Bài tập 8, đưa ra một giả định về dạng của hàm nguy hiểm. Chức năng này có liên quan mật thiết đến việc đưa ra giả định về dạng của hàm mật độ, như đã được thực hiện trong đoạn trước.

11Ký hiệu $h(t|x_i)$ cho biết chúng ta hiện đang xem xét hàm nguy hiểm cho quan sát thứ i có điều kiện dựa trên giá trị của các biến độc lập, x_i .



HÌNH 11.4. Trên: Trong một ví dụ đơn giản với $p = 1$ và biến phụ nhị phân.

$x_i \in \{0, 1\}$, hàm nguy cơ logarit và hàm sống sót theo mô hình (11.14) được hiển thị (màu xanh lá cây cho $x_i = 0$ và màu đen cho $x_i = 1$). Do tính tỷ lệ giả định về rủi ro (11.14), các hàm rủi ro logarit khác nhau bởi một hằng số và Các hàm sống sót không giao nhau. Hình dưới: Một lần nữa, chúng ta có một biến nhị phân duy nhất $x_i \in \{0, 1\}$. Tuy nhiên, giả định về nguy cơ tỷ lệ (11.14) không đúng. Các hàm nguy cơ logarit giao nhau, cũng như các hàm sống sót.

$h_0(t)$ nhân với hệ số exp được gọi là $\sum_{j=1}^p x_{ij}\beta_j$. Số lượng exp $\sum_{j=1}^p x_{ij}\beta_j$ là rủi ro tương đối của vectơ đặc trưng $x_i = (x_{i1}, \dots, x_{ip})^T$, so với rủi ro tương đối của vectơ đặc trưng $x_i = (0, \dots, 0)^T$. Điều đó có nghĩa là hàm nguy cơ cơ bản $h_0(t)$ trong (11.14) là Không xác định? Về cơ bản, chúng tôi không đưa ra bất kỳ giả định nào về hình thức chức năng của nó. Chúng ta cho phép xác suất tử vong tức thời tại thời điểm t , với điều kiện là một đã tồn tại ít nhất cho đến thời điểm t , để có thể mang bất kỳ hình thức nào. Điều này có nghĩa là Hàm rủi ro rất linh hoạt và có thể mô hình hóa nhiều loại mối quan hệ khác nhau. mối quan hệ giữa các biến độc lập và thời gian sống sót. Giả định duy nhất của chúng tôi là... Việc tăng một đơn vị x_{ij} tương ứng với việc tăng $h(t|x_i)$ lên một hệ số là $\exp(\beta_j)$.

Một minh họa về giả định rủi ro tỷ lệ (11.14) được đưa ra trong Hình 11.4, trong một thiết lập đơn giản với một biến phụ nhị phân duy nhất $x_i \in \{0, 1\}$ (do đó $p = 1$). Ở hàng trên cùng, giả định về tỷ lệ nguy cơ (11.14) đúng. Do đó, hàm nguy hiểm của hai nhóm là một bội số không đổi của nhau, sao cho trên thang logarit, khoảng cách giữa chúng là hằng số. Hơn nữa, các đường cong tỷ lệ sống sót không bao giờ giao nhau, và trên thực tế, khoảng cách giữa chúng rất lớn. Đường cong tỷ lệ sống sót có xu hướng (ban đầu) tăng dần theo thời gian. Ngược lại, trong hàng dưới cùng, (11.14) không đúng. Chúng ta thấy rằng hàm nguy hiểm logarit Đối với hai nhóm giao nhau, cũng như các đường cong tỷ lệ sống sót.

Mô hình rủi ro tỷ lệ của Cox

Vì dạng của $h_0(t)$ trong giả định rủi ro tỷ lệ (11.14) vì chưa biết nên chúng ta không thể đơn giản cắm $h(t|x_i)$ vào hàm hợp lý (11.13) và sau đó ước tính $\beta = (\beta_1, \dots, \beta_p)'$ bằng phương pháp hợp lý tối đa. Điều kỳ diệu của Mô hình rủi ro tỷ lệ của Cox nằm ở chỗ thực tế có thể ước tính β mà không cần phải xác định dạng của $h_0(t)$.

Của Cox
tỷ lệ
mối nguy hiểm
người mẫu

Để thực hiện điều này, chúng ta sử dụng cùng một logic “tuần tự theo thời gian”. mà chúng tôi đã sử dụng để xây dựng đường cong sống sót Kaplan-Meier và kiểm định log-rank. kiểm tra. Để đơn giản, giả sử không có sự trùng lặp nào giữa các lần thất bại, hoặc tử vong, thời gian: tức là mỗi lần hỏng hóc xảy ra vào một thời điểm riêng biệt. Giả sử rằng $\delta_i = 1$, tức là quan sát thứ i không bị kiểm duyệt, và do đó y_i là thời gian xảy ra lỗi của nó. Khi đó, hàm nguy hiểm cho quan sát thứ i tại thời điểm y_i là $h(y_i|x_i) = h_0(y_i) \exp \sum_{j=1}^p x_{ij}\beta_j$ và tổng nguy cơ tại thời điểm y_i đối với những người có nguy cơ exp quan sát¹² là

$$\sum_{i: y_i \geq y_i} h_0(y_i) \exp \sum_{j=1}^p x_{ij}\beta_j$$

Do đó, xác suất để quan sát thứ i là quan sát bị lỗi tại thời điểm t là xác suất để quan sát đó bị lỗi tại thời điểm t . y_i (trái ngược với một trong những quan sát khác trong tập hợp rủi ro) là

$$\frac{\sum_{i: y_i \geq y_i} h_0(y_i) \exp \sum_{j=1}^p x_{ij}\beta_j}{\sum_{i: y_i \geq y_i} h_0(y_i) \exp \sum_{j=1}^p x_{ij}\beta_j} = \frac{\sum_{i: y_i \geq y_i} \exp \sum_{j=1}^p x_{ij}\beta_j}{\sum_{i: y_i \geq y_i} \exp \sum_{j=1}^p x_{ij}\beta_j} \quad (11.15)$$

Lưu ý rằng hàm nguy cơ cơ sở không xác định $h_0(y_i)$ bị triệt tiêu. Tử số và mẫu số!

Xác suất từng phần đơn giản là tích của các xác suất này trên tất cả các trường hợp. trong số các quan sát không bị kiểm duyệt,

một phần
xác suất

$$PL(\beta) = \prod_{i: \delta_i = 1} \frac{\exp \sum_{j=1}^p x_{ij}\beta_j}{\sum_{i: y_i \geq y_i} \exp \sum_{j=1}^p x_{ij}\beta_j} \quad (11.16)$$

Điều quan trọng là xác suất từng phần vẫn hợp lệ bất kể giá trị thực của $h_0(t)$, giúp mô hình trở nên rất linh hoạt và mạnh mẽ.¹³

Để ước tính β , chúng ta chỉ cần tối đa hóa xác suất một phần (11.16) với liên quan đến β . Cũng như trường hợp hồi quy logistic trong Chương 4, không có lời giải dạng đóng nào, do đó cần phải sử dụng các thuật toán lặp.

Ngoài việc ước tính β , chúng ta cũng có thể thu được các kết quả đầu ra khác của mô hình, Chúng ta đã thấy điều này trong bối cảnh hồi quy bình phương tối thiểu ở Chương 3 và hồi quy logistic. hồi quy trong Chương 4. Ví dụ, chúng ta có thể thu được các giá trị p tương ứng

12Hãy nhớ rằng các quan sát “có nguy cơ” tại thời điểm y_i là những quan sát vẫn còn có nguy cơ Thất bại, tức là những trường hợp chưa thất bại hoặc chưa bị kiểm duyệt trước thời điểm y_i .
13Nhìn chung, xác suất từng phần được sử dụng trong các trường hợp khó tính toán Xác suất đầy đủ cho tất cả các tham số. Thay vào đó, chúng ta chỉ tính xác suất cho... các tham số quan trọng hàng đầu: trong trường hợp này, $\beta_1, \dots, \beta_p$. Có thể chứng minh rằng việc tối đa hóa (11.16) cung cấp các ước tính tốt cho các tham số này.

đối với các giả thuyết không cụ thể (ví dụ : $H_0 : \beta_j = 0$), cũng như khoảng tin cậy liên quan đến các hệ số.

Mối liên hệ với phép kiểm định Log-Rank

Giả sử chúng ta chỉ có một biến dự báo duy nhất ($p = 1$), mà ta giả định là biến nhị phân, tức là $x_i \in \{0, 1\}$. Để xác định xem có sự khác biệt giữa thời gian sống sót của các quan sát trong nhóm $\{i : x_i = 0\}$ và những quan sát trong nhóm $\{i : x_i = 1\}$ hay không, ta có thể xem xét hai cách tiếp cận khả thi:

Phương pháp #1: Áp dụng mô hình rủi ro tỷ lệ Cox và kiểm định giả thuyết không $H_0 : \beta = 0$.
(Vì $p = 1$, nên β là một hằng số.)

Phương pháp #2: Thực hiện kiểm định log-rank để so sánh hai nhóm, như trong Phần 11.4.

Chúng ta nên chọn cái nào?

Thực tế, có một mối quan hệ chặt chẽ giữa hai phương pháp này. Cụ thể, khi áp dụng Phương pháp #1, có một số cách khả thi để kiểm định H_0 . Một trong những cách đó được gọi là kiểm định điểm số. Hóa ra, trong trường hợp chỉ có một biến độc lập nhị phân, kiểm định điểm số cho $H_0 : \beta = 0$ trong mô hình rủi ro tỷ lệ của Cox hoàn toàn bằng với kiểm định log-rank. Nói cách khác, việc chúng ta áp dụng Phương pháp #1 hay Phương pháp #2 đều không quan trọng!

Thông tin chi tiết bổ sung

Cuộc thảo luận về mô hình rủi ro tỷ lệ của Cox đã bỏ qua một vài điểm tinh tế:

- Không có hệ số chặn trong (11.14) cũng như trong các phương trình tiếp theo, bởi vì hệ số chặn có thể được hấp thụ vào nguy cơ bản $h_0(t)$.
- Chúng tôi đã giả định rằng không có thời gian hỏng hóc trùng nhau. Trong trường hợp có sự trùng nhau, dạng chính xác của xác suất một phần (11.16) phức tạp hơn một chút và phải sử dụng một số phép tính gần đúng.
- (11.16) được gọi là xác suất một phần vì nó không chính xác là xác suất. Tức là, nó không tương ứng chính xác với xác suất của dữ liệu theo giả định (11.14). Tuy nhiên, nó là một phép xấp xỉ rất tốt.
- Chúng tôi chỉ tập trung vào việc ước lượng các hệ số $\beta = (\beta_1, \dots, \beta_p)^T$. Tuy nhiên, đôi khi chúng ta cũng có thể muốn ước tính nguy cơ bản $h_0(t)$, chẳng hạn như để ước tính đường cong sống sót $S(t|x)$ cho một cá nhân có vectơ đặc trưng x . Chi tiết nằm ngoài phạm vi của cuốn sách này. Việc ước tính $h_0(t)$ được thực hiện trong gói **lifelines** trong **Python**, mà chúng ta sẽ thấy trong Phần 11.8.

11.5.3 Ví dụ: Dữ liệu về ung thư não

Bảng 11.2 trình bày kết quả của việc áp dụng mô hình rủi ro tỷ lệ thuận vào Dữ liệu về ung thư não , được mô tả ban đầu trong Phần 11.3 .

Cột hệ số hiển thị β^j . Ví dụ, kết quả cho thấy rằng Nguy cơ ước tính đối với bệnh nhân nam là $e^{0,18} = 1,2$ lần so với bệnh nhân nữ.

một bệnh nhân nữ: nói cách khác, với tất cả các đặc điểm khác được giữ nguyên, nam giới Nam giới có nguy cơ tử vong cao gấp 1,2 lần so với nữ giới, tại bất kỳ thời điểm nào.

Tuy nhiên, giá trị p là 0,61, điều này cho thấy sự khác biệt giữa Sự khác biệt giữa nam và nữ không đáng kể.

Ví dụ khác, chúng ta cũng thấy rằng mỗi lần tăng một đơn vị trong Chỉ số Karnofsky tương ứng với hệ số nhân $\exp(0,05) = 0,95$ trong Xác suất tử vong tức thời. Nói cách khác, chỉ số Karnofsky càng cao thì xác suất tử vong càng lớn.

Chỉ số càng cao, thì khả năng tử vong tại bất kỳ thời điểm nào càng thấp. Hiệu ứng này có ý nghĩa thống kê rất cao, với giá trị p là 0,0027.

	Hệ số Sai số chuẩn Thống kê z Giá trị p	
giới	0,18	0,36 0,51 0,61
tính[Nam] chặn đoán[U thần	0,92	0,64 1,43 0,15
kinh đệm độ thấp] chặn đoán[U	2.15	0,45 4,78 0,66 1,35
thần kinh đệm độ cao]	0,89	0,70 0,63 0,02 0,02
chặn đoán[Khác] vị trí[Trên lều tiểu não]	0,44	0,60
kí	-0,05	-3,00 <0,01
gtv	0,03	1,54 0,12
stereo[SRT]	0,18	0,30 0,77

BẢNG 11.2. Kết quả phù hợp của mô hình rủi ro tỷ lệ Cox với Dữ liệu BrainCancer , được mô tả lần đầu tiên trong Phần 11.3. Biến số Chặn đoán được thực hiện định tính với bốn cấp độ: u màng não, u tế bào thần kinh đệm độ thấp, u tế bào thần kinh đệm độ cao. hoặc các biến khác. Các biến sex, loc và stereo là biến nhị phân.


11.5.4 Ví dụ: Dữ liệu xuất bản

Tiếp theo, chúng ta xem xét tập dữ liệu Publication liên quan đến thời gian công bố các bài báo trên tạp chí báo cáo kết quả của các thử nghiệm lâm sàng được tài trợ bởi... Viện Tim, Phổi và Máu Quốc gia.14 Đối với 244 thử nghiệm, thời gian trong Số tháng cho đến khi công bố được ghi nhận. Trong số 244 thử nghiệm, chỉ có 156 thử nghiệm được công bố trong thời gian nghiên cứu; các nghiên cứu còn lại đã bị loại bỏ.

Các biến phụ thuộc bao gồm việc liệu thử nghiệm có tập trung vào một điểm cuối lâm sàng (clind) hay không. liệu thử nghiệm có liên quan đến nhiều trung tâm (đa trung tâm) hay không, cơ chế tài trợ trong Viện Y tế Quốc gia (mech), kích thước mẫu thử nghiệm (sampsize), ngân sách (budget), tác động (impact, liên quan đến số lượng trích dẫn), và Liệu thử nghiệm có cho kết quả tích cực (có ý nghĩa) hay không . Cuối cùng Biến phụ thuộc đặc biệt thú vị, như một số nghiên cứu đã chỉ ra.

Các thử nghiệm tích cực có tỷ lệ công bố cao hơn.

14Bộ dữ liệu này được mô tả trong bài báo sau: Gordon et al. (2013) Ấn phẩm của Các thử nghiệm được tài trợ bởi Viện Tim, Phổi và Máu Quốc gia. Tạp chí New England của Y học, 369(20):1926-1934.



HÌNH 11.5. Đường cong sống sót theo thời gian cho đến khi công bố dữ liệu công bố được mô tả trong Phần 11.5.4, được phân tầng theo việc nghiên cứu có cho kết quả tích cực hay không.

Hình 11.5 thể hiện đường cong Kaplan-Meier về thời gian cho đến khi công bố kết quả, được phân loại dựa trên việc nghiên cứu có cho kết quả tích cực hay không. Chúng ta thấy bằng chứng nhỏ cho thấy thời gian cho đến khi công bố kết quả ngắn hơn đối với các nghiên cứu có kết quả tích cực. Tuy nhiên, phép thử log-rank cho ra giá trị p rất thấp là 0,36.

Giờ đây, chúng ta xem xét một phân tích cẩn thận hơn bằng cách sử dụng tất cả các biến dự báo có sẵn. Kết quả của việc áp dụng mô hình rủi ro tỷ lệ Cox sử dụng tất cả các đặc điểm có sẵn được thể hiện trong Bảng 11.3. Chúng ta thấy rằng khả năng công bố một nghiên cứu có kết quả tích cực cao hơn 1,74 lần so với khả năng công bố một nghiên cứu có kết quả tiêu cực tại bất kỳ thời điểm nào, khi giữ cố định tất cả các biến đồng biến khác. Giá trị p rất nhỏ liên quan đến các biến trong Bảng 11.3 cho thấy kết quả này có ý nghĩa thống kê cao. Điều này rất đáng chú ý, đặc biệt là khi xem xét phát hiện trước đó của chúng ta rằng một thử nghiệm log-rank so sánh thời gian công bố đối với các nghiên cứu có kết quả tích cực so với kết quả tiêu cực cho ra giá trị p là 0,36. Làm thế nào chúng ta có thể giải thích sự khác biệt này? Câu trả lời xuất phát từ thực tế là thử nghiệm log-rank không xem xét bất kỳ biến đồng biến nào khác, trong khi các kết quả trong Bảng 11.3 dựa trên mô hình Cox sử dụng tất cả các biến đồng biến có sẵn. Nói cách khác, sau khi điều chỉnh cho tất cả các biến số phụ khác, thì việc nghiên cứu có cho kết quả tích cực hay không có khả năng dự đoán rất cao thời gian công bố kết quả.

Để hiểu rõ hơn về kết quả này, trong Hình 11.6, chúng tôi hiển thị ước tính các đường cong sống sót liên quan đến kết quả tích cực và tiêu cực, có điều chỉnh cho các biến dự báo khác. Để tạo ra các đường cong sống sót này, chúng tôi đã ước tính tỷ lệ nguy cơ bản đồ $h_0(t)$. Chúng tôi cũng cần chọn các giá trị đại diện cho các biến dự báo khác; chúng tôi đã sử dụng giá trị trung bình cho mỗi biến dự báo, ngoại trừ biến dự báo phân loại *mech*, đối với biến này chúng tôi đã sử dụng danh mục phổ biến nhất (*R01*). Sau khi điều chỉnh cho các biến dự báo khác, giờ đây chúng ta thấy sự khác biệt rõ ràng trong các đường cong sống sót giữa các nghiên cứu có kết quả tích cực so với kết quả tiêu cực.

Những thông tin thú vị khác có thể được rút ra từ Bảng 11.3. Ví dụ, các nghiên cứu có điểm cuối lâm sàng có nhiều khả năng được công bố tại bất kỳ thời điểm nào hơn so với các nghiên cứu có điểm cuối phi lâm sàng. Nguồn tài trợ

	Hệ số	Sai số chuẩn	Thống kê z	Giá trị p
posres[Có]	0.55	0,18	3,02	0,00
multi[Có]	0.15	0,31	0,47	0,64
clinend[Có]	0.51	0,27	1,89	0,06
mech[K01]	1.05	1,06	1,00	0,32
mech[K23]	-0.48	1,05	-0,45	0,65
mech[P01]	-0.31	0,78	-0,40	0,69
mech[P50]	0.60	1,06	0,57	0,57
mech[R01]	0.10	0,32	0,30	0,76
mech[R18]	1.05	1,05	0,99	0,32
mech[R21]	-0.05	1,06	-0,04	0,97
mech[R24,K24]	0.81	1,05	0,77	0,44
mech[R42]	-14.78	3414,38	-0,00	1,00
mech[R44]	-0.57	0,77	-0,73	0,46
mech[RC2]	-14.92	2243,60	-0,01	0,99
mech[U01]	-0.22	0,32	-0,70	0,48
mech[U54]	0.47	1,07	0,44	0,66
kích thước	0.00	0,00	0,19	0,85
mẫu tác	0.00	0,00	1,67	0,09
động ngân sách	0.06	0,01	8,23	0,00

BẢNG 11.3. Kết quả phù hợp của mô hình rủi ro tỷ lệ Cox với Dữ liệu xuất bản, sử dụng tất cả các tính năng có sẵn. Các tính năng `posres`, `multi`, và `clinend` là nhị phân. Đặc điểm `mech` là định tính với 14 cấp độ; nó được mã hóa. Vì vậy, mức cơ sở là `Hợp đồng`.

cơ chế này dường như không liên quan đáng kể đến thời gian cho đến khi ấn phẩm.


11.6 Sự co rút đối với mô hình Cox

Trong phần này, chúng tôi minh họa các phương pháp co ngót được nêu trong Mục 6.2. có thể được áp dụng cho thiết lập dữ liệu sống sót. Đặc biệt, được thúc đẩy bởi Trong công thức “tổn thất + phạt” của Mục 6.2, chúng ta xem xét việc tối thiểu hóa một phiên bản phạt của logarit khả năng xảy ra một phần âm trong (11.16),

$$\log \frac{\prod_{i: \delta_i=1} \prod_{j=1}^p x_{ij} \beta_j}{\prod_{i: y_i \geq y_i \exp \left(\sum_{j=1}^p x_{ij} \beta_j \right)} + \lambda P(\beta)}, \tag{11.17}$$

liên quan đến $\beta = (\beta_1, \dots, \beta_p)^T$. Chúng ta có thể lấy $P(\beta) = \sum_{j=1}^p \beta_j^2$, cái mà tương ứng với hình phạt ridge, hoặc $P(\beta) = \sum_{j=1}^p |\beta_j|$, tương ứng với hình phạt lasso.

Trong (11.17), λ là tham số điều chỉnh không âm; thông thường chúng ta sẽ tối thiểu hóa nó trên một phạm vi giá trị của λ . Khi $\lambda = 0$, thì việc tối thiểu hóa (11.17) là tương đương với việc đơn giản là tối đa hóa xác suất từng phần Cox thông thường (11.16). Tuy nhiên, khi $\lambda > 0$ thì việc tối thiểu hóa (11.17) sẽ cho ra một phiên bản thu nhỏ của các ước tính hệ số. Khi λ lớn, thì việc sử dụng hình phạt ridge sẽ đưa ra các hệ số nhỏ không hoàn toàn bằng không. Ngược lại, đối với một



HÌNH 11.6. Đối với dữ liệu xuất bản, chúng tôi hiển thị các đường cong sống sót theo thời gian. cho đến khi công bố, được phân loại dựa trên việc nghiên cứu có cho kết quả tích cực hay không. sau khi đã điều chỉnh cho tất cả các biến số phụ khác.

Với giá trị λ đủ lớn, việc sử dụng hình phạt lasso sẽ cho ra một số hệ số. có giá trị chính xác bằng không.

Chúng ta sẽ áp dụng mô hình Cox có điều chỉnh bằng lasso cho dữ liệu đã được công bố, được mô tả trong Mục 11.5.4. Đầu tiên, chúng ta chia ngẫu nhiên 244 lượt thử thành các tập huấn luyện và kiểm tra có kích thước bằng nhau. Kết quả kiểm định chéo từ quá trình huấn luyện Các giá trị được hiển thị trong Hình 11.7. “Độ lệch xác suất một phần”, được hiển thị trên Trục y là gấp đôi logarit xác suất từng phần âm được kiểm định chéo; nó đóng vai trò là lỗi kiểm định chéo.15 Lưu ý hình dạng chữ “U” của Độ lệch xác suất từng phần: như chúng ta đã thấy trong các chương trước, lỗi kiểm định chéo được giảm thiểu ở mức độ phức tạp trung bình của mô hình. Cụ thể, điều này xảy ra khi chỉ có hai yếu tố dự báo, ngân sách và tác động, có các hệ số ước tính khác không.

Vậy, làm thế nào để áp dụng mô hình này vào tập dữ liệu thử nghiệm? Điều này đặt ra một câu hỏi... Điểm quan trọng về mặt khái niệm: về bản chất, không có cách nào đơn giản để so sánh. Thời gian sống dự đoán và thời gian sống thực tế trên tập dữ liệu thử nghiệm. Đầu tiên Vấn đề là một số quan sát bị kiểm duyệt, do đó thời gian sống sót thực sự đối với những quan sát đó không được ghi nhận. Vấn đề thứ hai phát sinh.


Từ thực tế là trong mô hình Cox, thay vì dự đoán một thời gian sống sót duy nhất dựa trên vectơ biến x, chúng ta lại ước tính toàn bộ thời gian sống sót. Đường cong S(t|x) là một hàm của t.

Do đó, để đánh giá mức độ phù hợp của mô hình, chúng ta cần áp dụng một phương pháp khác. điều này bao gồm việc phân tầng các quan sát bằng cách sử dụng các ước tính hệ số. Cụ thể, đối với mỗi kết quả kiểm tra, chúng tôi tính toán điểm “rủi ro”.

$$\text{budgeti} \cdot \beta^{\text{budget}} + \text{impacti} \cdot \beta^{\text{impact}},$$

trong đó β^{budget} và β^{impact} là các ước lượng hệ số cho hai đặc điểm này. Từ tập dữ liệu huấn luyện. Sau đó, chúng tôi sử dụng các điểm rủi ro này để phân loại các quan sát dựa trên “mức độ rủi ro” của chúng. Ví dụ, nhóm rủi ro cao bao gồm... các quan sát mà trong đó $\text{budgeti} \cdot \beta^{\text{budget}} + \text{impacti} \cdot \beta^{\text{impact}}$ là lớn nhất; bởi

15. Quá trình kiểm định chéo cho mô hình Cox phức tạp hơn so với mô hình hồi quy tuyến tính hoặc logistic. hồi quy, bởi vì hàm mục tiêu không phải là tổng của các quan sát.



HÌNH 11.7. Đối với dữ liệu xuất bản được mô tả trong Phần 11.5.4, kết quả kiểm định chéo cho mô hình Cox có hình phạt lasso được hiển thị. Trục y hiển thị Độ lệch xác suất từng phần, đóng vai trò như lỗi kiểm định chéo. Trục x hiển thị chuẩn 1 (tức là tổng các giá trị tuyệt đối) của... hệ số của mô hình Cox được điều chỉnh bằng phương pháp lasso với tham số điều chỉnh λ , chia cho Chuẩn 1 của các hệ số của mô hình Cox không bị phạt. Đường nét đứt Biểu thị sai số kiểm định chéo tối thiểu.

(11.14), chúng ta thấy rằng đây là những quan sát mà đối với chúng thì tức thời Xác suất được xuất bản tại bất kỳ thời điểm nào là lớn nhất. Nói cách khác, Nhóm rủi ro cao bao gồm các thử nghiệm có khả năng được công bố sớm hơn. Trên dữ liệu công bố, chúng tôi phân loại các quan sát thành các nhóm khác nhau. chia thành ba nhóm: nguy cơ thấp, trung bình và cao. Các đường cong sống sót thu được cho Mỗi trong ba tầng địa chất được hiển thị trong Hình 11.8. Chúng ta thấy rằng có sự phân tách rõ ràng giữa ba tầng địa chất, và các tầng địa chất đó chính xác. Được sắp xếp theo mức độ rủi ro công bố thấp, trung bình và cao.

11.7 Các chủ đề bổ sung


11.7.1 Diện tích dưới đường cong cho phân tích sống sót

Trong Chương 4, chúng ta đã giới thiệu diện tích dưới đường cong ROC – thường được gọi là “AUC” – như một cách để định lượng hiệu suất của bộ phân loại hai lớp. Xác định điểm số cho quan sát thứ i là ước tính của bộ phân loại.

của $\Pr(Y = 1|X = x_i)$. Hóa ra nếu ta xem xét tất cả các cặp bao gồm một quan sát ở Lớp 1 và một quan sát ở Lớp 2, sau đó tính AUC.

là tỷ lệ các cặp mà điểm số quan sát ở Lớp 1 là 1. vượt quá điểm số quan sát ở Lớp 2.

Điều này gợi ý một cách để khái quát hóa khái niệm AUC cho phân tích sống còn. Chúng tôi tính toán điểm rủi ro ước tính, $\hat{\eta}^i = \beta^1 x_{i1} + \dots + \beta^p x_{ip}$, cho $i = 1, \dots, n$, sử dụng các hệ số của mô hình Cox. Nếu $\hat{\eta}^i > \hat{\eta}^j$, thì mô hình Dự đoán rằng quan sát thứ i có nguy cơ cao hơn quan sát thứ j , và do đó thời gian sống sót t_i sẽ lớn hơn t_j . Vì vậy, nó Thật hấp dẫn khi cố gắng khái quát hóa AUC bằng cách tính tỷ lệ các quan sát mà trong đó $t_i > t_j$ và $\hat{\eta}^i > \hat{\eta}^j$. Tuy nhiên, mọi thứ không hoàn toàn như vậy. Dễ thôi, vì hãy nhớ rằng chúng ta không quan sát $t_1, \dots, t_n$; thay vào đó, chúng ta quan sát



HÌNH 11.8. Đối với dữ liệu **xuất bản** được giới thiệu trong Phần 11.5.4, chúng tôi

Tính toán phân vị thứ ba của "rủi ro" trong tập dữ liệu thử nghiệm bằng cách sử dụng các hệ số ước tính trên tập dữ liệu huấn luyện. Có sự phân tách rõ ràng giữa các đường cong tỷ lệ sống sót thu được.

các thời điểm (có thể bị kiểm duyệt) $y_1, \dots, y_n$, cũng như các chỉ báo kiểm duyệt. $\delta_1, \dots, \delta_n$.

Do đó, chỉ số tương quan Harrell (hay chỉ số C) tính toán...

phần các cặp quan sát mà trong đó $\eta^i > \eta^j$ và $y_i > y_j$:

$$C = \frac{\sum_{\substack{\text{tôi, tôi: } y_i > y_j \\ \text{tôi, tôi: } y_i > y_j}} I(\eta^i > \eta^j) \delta_i}{\sum \delta_i},$$

Của Harrell
sự hòa hợp
chỉ mục

trong đó biến chỉ báo $I(\eta^i > \eta^j)$ bằng một nếu $\eta^i > \eta^j$, và bằng 0 trong các trường hợp khác. Tử số và mẫu số được nhân với sta-since nếu quan sát thứ i không bị kiểm duyệt (tức là nếu $\delta_i = 1$), $y_i > y_j$ ngụ ý rằng $t_i > t_j$. Ngược lại, nếu $\delta_i = 0$, thì $y_i > y_j$ không có nghĩa là $t_i > t_j$.

Chúng tôi đã áp dụng mô hình rủi ro tỷ lệ Cox cho tập dữ liệu huấn luyện.

Dữ liệu **xuất bản** và chỉ số C-index được tính toán trên tập dữ liệu thử nghiệm. Kết quả thu được là: $C = 0,733$. Nói một cách đại khái, khi được chọn ngẫu nhiên hai bài báo từ tập dữ liệu thử nghiệm, Mô hình có thể dự đoán với độ chính xác 73,3%, kết quả này sẽ được công bố đầu tiên.

11.7.2 Lựa chọn thang thời gian

Qua các ví dụ đã xem xét trong chương này, điều đó khá rõ ràng.

Cách xác định thời gian. Ví dụ, trong ví dụ về **Ấn phẩm**, thời điểm bằng không cho

Mỗi bài báo được xác định là thời điểm theo lịch vào cuối nghiên cứu.

và thời gian xảy ra sự cố được định nghĩa là số tháng đã trôi qua.

Từ khi kết thúc nghiên cứu cho đến khi bài báo được xuất bản.

Tuy nhiên, trong các bối cảnh khác, định nghĩa về thời điểm ban đầu và thời điểm xảy ra lỗi lại khác. có thể tinh tế hơn. Ví dụ, khi xem xét mối liên hệ giữa

Trong một nghiên cứu dịch tễ học, người ta có thể xem xét các yếu tố rủi ro và sự xuất hiện của bệnh.

Sử dụng tuổi của bệnh nhân để xác định thời gian, sao cho thời điểm 0 là ngày của bệnh nhân.

ngày sinh. Với lựa chọn này, mối liên hệ giữa tuổi tác và khả năng sống sót không thể

có thể được đo lường; tuy nhiên, không cần điều chỉnh theo tuổi trong phân tích.

Khi xem xét các yếu tố liên quan đến thời gian sống không bệnh (tức là

(khoảng thời gian trôi qua giữa lần điều trị và lần tái phát bệnh), người ta có thể sử dụng ngày điều trị làm mốc thời gian 0.

11.7.3 Các biến phụ thuộc thời gian

Một đặc điểm mạnh mẽ của mô hình rủi ro tỷ lệ là khả năng xử lý các biến phụ thuộc thời gian, tức là các biến dự báo có giá trị có thể thay đổi theo thời gian. Ví dụ, giả sử chúng ta đo huyết áp của một bệnh nhân mỗi tuần trong suốt một nghiên cứu y khoa. Trong trường hợp này, ta có thể coi huyết áp của lần quan sát thứ i không phải là x_i , mà là $x_i(t)$ tại thời điểm t .

Vì xác suất từng phần trong (11.16) được xây dựng tuần tự theo thời gian, việc xử lý các biến phụ thuộc thời gian rất đơn giản. Cụ thể, chúng ta chỉ cần thay thế x_{ij} và x_{ij} trong (11.16) bằng $x_{ij}(y_i)$ và $x_{ij}(y_i)$ tương ứng; đây là các giá trị hiện tại của các biến dự đoán tại thời điểm y_i . Ngược lại, các biến phụ thuộc thời gian sẽ đặt ra một thách thức lớn hơn nhiều trong bối cảnh của một phương pháp tham số truyền thống, chẳng hạn như (11.13).

Một ví dụ về các biến phụ thuộc thời gian xuất hiện trong phân tích dữ liệu từ Chương trình Ghép tim Stanford. Bệnh nhân cần ghép tim được đưa vào danh sách chờ. Một số bệnh nhân được ghép tim, nhưng những người khác đã tử vong trong khi vẫn đang chờ đợi. Mục tiêu chính của phân tích là xác định xem việc ghép tim có liên quan đến thời gian sống sót lâu hơn của bệnh nhân hay không.

Một cách tiếp cận đơn giản sẽ sử dụng một biến cố định để biểu thị tình trạng ghép tạng: tức là, $x_i = 1$ nếu bệnh nhân thứ i đã từng được ghép tạng, và $x_i = 0$ nếu ngược lại. Nhưng cách tiếp cận này bỏ qua thực tế là bệnh nhân phải sống đủ lâu để được ghép tạng, và do đó, trung bình, những bệnh nhân khỏe mạnh hơn sẽ được ghép tạng. Vấn đề này có thể được giải quyết bằng cách sử dụng một biến phụ thuộc thời gian cho việc ghép tạng: $x_i(t) = 1$ nếu bệnh nhân được ghép tạng trước thời điểm t , và $x_i(t) = 0$ nếu ngược lại.

11.7.4 Kiểm tra giả định về tỷ lệ nguy cơ tương ứng

Chúng ta đã thấy rằng mô hình rủi ro tỷ lệ của Cox dựa trên giả định rủi ro tỷ lệ (11.14). Mặc dù kết quả từ mô hình Cox có xu hướng khá ổn định đối với các vi phạm giả định này, nhưng vẫn nên kiểm tra xem nó có đúng hay không. Trong trường hợp đặc điểm định tính, chúng ta có thể vẽ đồ thị hàm rủi ro logarit cho mỗi cấp độ của đặc điểm đó. Nếu (11.14) đúng, thì các hàm rủi ro logarit chỉ nên khác nhau một hằng số, như được thấy trong bảng phía trên bên trái của Hình 11.4. Trong trường hợp đặc điểm định lượng, chúng ta có thể áp dụng cách tiếp cận tương tự bằng cách phân tầng đặc điểm đó.

11.7.5 Cây sinh tồn

Trong Chương 8, chúng ta đã thảo luận về các quy trình học tập linh hoạt và thích ứng như cây quyết định, rừng ngẫu nhiên và thuật toán boosting, được áp dụng trong cả thiết lập hồi quy và phân loại. Hầu hết các phương pháp này có thể được khái quát hóa cho thiết lập phân tích sống sót. Ví dụ, cây quyết định sống sót là một sự sửa đổi của cây phân loại và hồi quy sử dụng tiêu chí phân tách nhằm tối đa hóa sống sót cây cối.

sự khác biệt giữa các đường cong sống sót trong các nút con được tạo ra.
Sau đó, cây sinh tồn có thể được sử dụng để tạo ra các khu rừng sinh tồn ngẫu nhiên.

11.8 Thực hành: Phân tích sống sót

Trong bài thực hành này, chúng tôi thực hiện phân tích khả năng sống sót trên ba tập dữ liệu riêng biệt. Trong Phần 11.8.1, chúng tôi phân tích dữ liệu `BrainCancer` đã được mô tả lần đầu trong Phần 11.3. Trong Phần 11.8.2, chúng tôi xem xét dữ liệu `Publication` từ Phần 11.5.4. Cuối cùng, Phần 11.8.3 khám phá một tập dữ liệu trung tâm cuộc gọi mô phỏng.

Chúng ta bắt đầu bằng cách nhập một số thư viện ở cấp cao nhất này. Điều này giúp mã dễ đọc hơn, vì chỉ cần quét vài dòng đầu tiên của notebook là chúng ta biết được những thư viện nào đang được sử dụng trong notebook này.

```
Trong [1]: from matplotlib.pyplot import subplots import
numpy as np import
pandas as pd from
ISLP.models import ModelSpec as MS from ISLP
import load_data
```

Chúng tôi cũng thu thập các vật tư nhập khẩu mới cần thiết cho phòng thí nghiệm này.

```
Trong [2]: from lifelines import \
(KaplanMeierFitter,
CoxPHFitter)
from lifelines.statistics import \
(logrank_test,
multivariate_logrank_test) from
ISLP.survival import sim_time
```

11.8.1 Dữ liệu về ung thư não

Chúng ta bắt đầu với bộ dữ liệu `BrainCancer`, có trong gói `ISLP`.

```
Trong [3]: BrainCancer = load_data('BrainCancer')
BrainCancer.columns
```

```
Out[3]: Index(['sex', 'diagnosis', 'loc', 'ki', 'gtv', 'stereo', 'status',
'time'], dtype='object')
```

Các hàng thể hiện chỉ số của 88 bệnh nhân, trong khi 8 cột chứa các biến dự báo và biến kết quả. Trước tiên, chúng ta sẽ xem xét sơ lược dữ liệu.

```
Trong [4]: BrainCancer['sex'].value_counts()
```

```
Ra ngoài[4]: Nữ      45
Nam giới    43
Tên: giới tính, kiểu dữ liệu: int64
```

```
Trong [5]: BrainCancer['diagnosis'].value_counts()
```

```
Ra ngoài[5]: U màng não      42
              U thần kinh đệm HG 22
              Khác             14
              U thần kinh đệm LG  9
              Tên: chẩn đoán, kiểu dữ liệu: int64
```

```
Trong [6]: BrainCancer['status'].value_counts()
```

```
Ra[6]: 0 1      53
        35
        Tên: status, dtype: int64
```

Trước khi bắt đầu phân tích, điều quan trọng là phải biết **tình trạng hiện tại** như thế nào. Biến đã được mã hóa. Hầu hết phần mềm sử dụng quy ước rằng **trạng thái**

Giá trị 1 biểu thị một quan sát không bị kiểm duyệt (thường là tử vong), và **giá trị 0** biểu thị trạng thái tương ứng. Ký hiệu này chỉ một quan sát bị kiểm duyệt. Nhưng một số nhà khoa học có thể sử dụng ký hiệu ngược lại. mã hóa. Đối với bộ dữ liệu **Ung thư não**, 35 bệnh nhân đã tử vong trước khi kết thúc.

Nghiên cứu này cho thấy chúng tôi đang sử dụng phương pháp mã hóa thông thường.

Để bắt đầu phân tích, chúng ta sẽ tạo lại đường cong sống sót Kaplan-Meier.

Như minh họa trong Hình 11.2. Gợi ý chính mà chúng ta sẽ sử dụng cho phân tích sống sót là **lifelines**.

Biến **thời gian** tương ứng với yi, thời gian đến sự kiện thứ i (hoặc bị cắt cụt hoặc tử vong). Tham số đầu tiên của **km.fit** là sự kiện đường cứu sinh

Đối số đầu tiên là thời gian, và đối số thứ hai là biến kiểm duyệt, với giá trị 1 biểu thị thời gian thất bại được quan sát. Phương thức **plot()** tạo ra một đường cong sống sót với khoảng tin cậy điểm. Theo mặc định, đây là khoảng tin cậy 90%. .kịch bản()

khoảng thời gian, nhưng điều này có thể được thay đổi bằng cách đặt đối số **alpha** thành một. trừ đi mức độ tin cậy mong muốn.

```
Trong [7]: fig, ax = subplots(figsize=(8,8))
          km = KaplanMeierFitter()
          km_brain = km.fit(BrainCancer['time'], BrainCancer['status'])
          km_brain.plot(label='Ước tính Kaplan-Meier', ax=ax)
```

Tiếp theo, chúng ta tạo ra các đường cong sống sót Kaplan-Meier được phân tầng theo **giới tính**, trong Để tái tạo Hình 11.3, chúng ta thực hiện điều này bằng cách sử dụng phương thức **'groupby()'** của một dataframe. Phương thức này trả về một generator có thể được lặp lại trong... .groupby()

vòng lặp **for**. Trong trường hợp này, các phần tử trong vòng lặp **for** là các bộ hai phần tử đại diện cho các nhóm: mục nhập đầu tiên là giá trị của cột nhóm **giới tính** trong khi

Giá trị thứ hai là khung dữ liệu bao gồm tất cả các hàng trong khung dữ liệu.

khớp với giá trị **giới tính** đó. Chúng ta sẽ muốn sử dụng dữ liệu này bên dưới trong bài kiểm tra log-rank, do đó chúng ta lưu trữ thông tin này trong từ điển **by_sex**. Cuối cùng,

Chúng tôi cũng đã sử dụng khái niệm nội suy chuỗi để tự động gắn nhãn cho các đường khác nhau trong biểu đồ. Nội suy chuỗi là một kỹ thuật mạnh mẽ. sợi dây nội suy

Để định dạng chuỗi ký tự - Python có nhiều cách để thực hiện các thao tác này.

```
Trong [8]: fig, ax = subplots(figsize=(8,8))
          theo giới tính = {}
          for sex, df in BrainCancer.groupby('sex'):
              by_sex[sex] = df
              km_sex = km.fit(df['time'], df['status'])
              km_sex.plot(label='Giới tính=%s' % sex, ax=ax)
```

Như đã thảo luận trong Phần 11.4, chúng ta có thể thực hiện kiểm định log-rank để so sánh.

tỷ lệ sống sót của con đực so với con cái. Chúng tôi sử dụng hàm **logrank_test()** từ logrank_ bài kiểm tra()

Mô -dun `lifelines.statistics` . Hai đối số đầu tiên là sự kiện lần, với lần thứ hai biểu thị sự kiểm duyệt tương ứng (tùy chọn). chỉ báo.

```
Trong [9]: logrank_test(by_sex['Male']['time'],
                      theo giới tính['Nữ']['thời gian'],
                      theo giới tính['Nam']['trạng thái'],
                      by_sex['Female']['status'])
```

```
Ra ngoài[9]:          t_0          -1
              null_distribution chỉ bình phương
              bậc tự do 1
              test_name logrank_test

              test_statistic 1.44          p -log2(p)
                          0.23          2.12
```

Giá trị p thu được là 0,23, cho thấy không có bằng chứng về sự khác biệt. sự sống còn giữa hai giới.

Tiếp theo, chúng ta sử dụng bộ ước lượng `CoxPHFitter()` từ thư viện `lifelines` để hiệu chỉnh các mô hình rủi ro tỷ lệ Cox. Để bắt đầu, chúng ta xem xét một mô hình sử dụng `giới tính`. `CoxPHFitter()` là yếu tố dự báo duy nhất.

```
Trong [10]: coxph = CoxPHFitter # viết tắt
sex_df = BrainCancer[['time', 'status', 'sex']]
model_df = MS(['time', 'status', 'sex'],
              intercept=False).fit_transform(sex_df)
cox_fit = coxph().fit(model_df,
                     'thời gian',
                     'trạng thái')
cox_fit.summary[['coef', 'se(coef)', 'p']]
```

```
Ra ngoài[10]:          hệ số se(hệ số)          p
              biến phụ
              giới tính[Nam] 0.407667 0.342004 0.233263
```

Đối số đầu tiên cần khớp phải là một khung dữ liệu chứa ít nhất các thông tin sau: thời gian sự kiện (thời gian của đối số thứ hai trong trường hợp này), cũng như một biến kiểm duyệt tùy chọn (trạng thái của đối số trong trường hợp này). Lưu ý thêm rằng Mô hình Cox không bao gồm hệ số chặn, đó là lý do tại sao chúng tôi sử dụng... Tham số `'intercept=False'` được truyền cho `'ModelSpec'` ở trên. Phương thức `'summary()'` trả về nhiều cột; chúng tôi đã chọn cách rút gọn đầu ra của nó ở đây. Có thể để thu được kết quả kiểm định tỷ lệ khả năng so sánh mô hình này với mô hình không có Các tính năng như sau:

```
Trong [11]: cox_fit.log_likelihood_ratio_test()
```

```
Out[11]: null_distribution          chỉ bình phương
              degrees_freedom          1
              test_name log-likelihood ratio test

              test_statistic 1.44          p -log2(p)
                          0.23          2.12
```

492 11. Phân tích sống sót và dữ liệu bị kiểm duyệt

Bất kể chúng ta sử dụng phép thử nào, chúng ta đều thấy rằng không có bằng chứng rõ ràng về sự khác biệt về tỷ lệ sống sót giữa nam và nữ. Như chúng ta đã học trong chương này, phép thử điểm số từ mô hình Cox hoàn toàn bằng với thống kê kiểm định hạng logarit!

Bây giờ chúng ta sẽ xây dựng một mô hình sử dụng thêm các biến dự đoán. Trước tiên, chúng ta lưu ý rằng một trong các giá trị **chẩn đoán** bị thiếu, do đó chúng ta loại bỏ quan sát đó trước khi tiếp tục.

```
Trong [12]: cleaned = BrainCancer.dropna() all_MS =
MS(cleaned.columns, intercept=False) all_df =
all_MS.fit_transform(cleaned) fit_all = coxph().fit(all_df,
'time', 'status') fit_all.summary[['coef',
'se(coef)',
'p']]
```

Ra ngoài[12]:

	biến phụ	hệ số se(hệ số)	p
	giới tính[Nam]	0.183748 0.360358 0.610119	
	chẩn đoán[U não LG]	-1.239541 0.579557 0.032454	chẩn đoán[U màng não] -2.154566
		0.450524 0.000002	chẩn đoán[Khác] -1.268870 0.617672 0.039949
	loc[Supratentorial]	0.441195 0.703669 0.530664	
		ki -0,054955 0,018314 0,002693	
	gtv	0.034293 0.022333 0.124660	
	stereo[SRT]	0.177778 0.601578 0.767597	

Biến **chẩn đoán** đã được mã hóa sao cho giá trị cơ sở tương ứng với u tế bào thần kinh đệm độ cao (HG glioma). Kết quả cho thấy nguy cơ liên quan đến HG glioma cao hơn gấp tám lần (tức là $e^{2,15} = 8,62$) so với nguy cơ liên quan đến u màng não (meningioma). Nói cách khác, sau khi điều chỉnh cho các yếu tố dự báo khác, bệnh nhân mắc HG glioma có tỷ lệ sống sót kém hơn nhiều so với những người mắc u màng não. Ngoài ra, giá trị chỉ số Karnofsky (ki) càng lớn thì nguy cơ càng thấp, tức là thời gian sống sót càng dài.

Cuối cùng, chúng ta vẽ biểu đồ đường cong sống sót ước tính cho từng loại chẩn đoán, điều chỉnh theo các biến dự báo khác. Để tạo các biểu đồ này, chúng ta đặt giá trị của các biến dự báo khác bằng giá trị trung bình đối với các biến định lượng và bằng giá trị phổ biến nhất đối với các biến định tính. Để làm điều này, chúng ta sử dụng phương thức **apply()** trên các hàng (tức là **axis=0**) với một hàm **đại diện** kiểm tra xem một cột có phải là biến định tính hay không.

```
Trong [13]: levels = cleaned['diagnosis'].unique() def
representative(series): if
hasattr(series.dtype, 'categories'):
trả về pd.Series.mode(series)
khác:
return series.mean()
modal_data = cleaned.apply(representative, axis=0)
```

Chúng tôi tạo bốn bản sao của cột "Giá trị trung bình" và gán cột **"Chẩn đoán"** cho bốn chẩn đoán khác nhau.

```
Trong [14]: modal_df = pd.DataFrame(
[modal_data.iloc[0] cho _ trong phạm vi (độ dài (mức))])
modal_df['diagnosis'] = levels modal_df
```

Như đã thảo luận trước đó, giá trị p từ việc áp dụng mô hình rủi ro tỷ lệ Cox cho biến **posres** khá lớn, không cung cấp bằng chứng nào.

sự khác biệt về thời gian công bố giữa các nghiên cứu có kết quả dương tính so với

Kết quả tiêu cực.

```
Trong [19]: posres_df = MS(['posres', 'time',
                        'status'],
                        intercept=False).fit_transform(Publication) posres_fit =
coxph().fit(posres_df, 'time', 'status')

posres_fit.summary[['coef', 'se(coef)', 'p']]
```

Ra ngoài[19]:

	hệ số	se(hệ số)	p
biến phụ			
tứ thể	0.148076	0.161625	0.359578

Tuy nhiên, kết quả thay đổi đáng kể khi chúng ta đưa thêm các yếu tố dự đoán khác vào các biến trong mô hình. Ở đây chúng ta loại trừ biến cơ chế tài trợ.

```
Trong [20]: model = MS(Publication.columns.drop('mech'), intercept=False)

coxph().fit(model.fit_transform(Publication),
            'time',
            'status').summary[['coef', 'se(coef)', 'p']]
```

Ra ngoài[20]:

	hệ số	se(hệ số)	p
biến phụ			
tứ thể	0,570774	0,175960	1,179606e-03
đa	-0,040863	0,251194	8,707727e-01
clind	0.546180	0.262001	3.710099e-02
kích thước mẫu	0.000005	0.000015	7.506978e-01
ngân sách	0.004386	0.002464	7.511276e-02
tác động	0.058318	0.006676	2.426779e-18

Chúng ta thấy rằng có một số biến số có ý nghĩa thống kê, bao gồm việc liệu thử nghiệm có tập trung vào một điểm cuối lâm sàng hay không, tác động của nghiên cứu và liệu nghiên cứu đó có kết quả tích cực hay tiêu cực.

11.8.3 Dữ liệu Trung tâm Cuộc gọi

Trong phần này, chúng ta sẽ mô phỏng dữ liệu sống sót bằng cách sử dụng mối quan hệ giữa nguy cơ tích lũy và hàm sống sót đã được tìm hiểu trong Bài tập 8. Dữ liệu mô phỏng của chúng ta sẽ thể hiện thời gian chờ đợi quan sát được (tính bằng giây) của 2.000 khách hàng đã gọi điện đến tổng đài. Trong ngữ cảnh này, hiện tượng cắt cụt dữ liệu xảy ra nếu khách hàng cúp máy trước khi cuộc gọi của họ được trả lời.

Có ba biến độc lập: Nhân viên tổng đài (số lượng nhân viên tổng đài có mặt tại thời điểm gọi điện, có thể từ 5 đến 15), Trung tâm (A, B hoặc C) và Thời gian trong ngày (Sáng, Chiều hoặc Tối). Chúng tôi tạo dữ liệu cho các biến độc lập này sao cho tất cả các khả năng đều có xác suất như nhau: ví dụ, các cuộc gọi vào buổi sáng, buổi chiều và buổi tối đều có xác suất như nhau, và bất kỳ số lượng nhân viên tổng đài nào từ 5 đến 15 đều có xác suất như nhau.

```
Trong [21]: rng = np.random.default_rng(10)
N = 2000

Operators = rng.choice(np.arange(5, 16),
                        N,
                        thay thế=True)
```



```

Trung tâm = rng.choice(['A', 'B', 'C'],
                        N,
                        replace=True)
Thời gian = rng.choice(['Sáng.', 'Chiều.', 'Chiều tối.'],
                        N,
                        replace=True)
D = pd.DataFrame({'Operators': Operators,
                  'Trung tâm': pd.Categorical(Trung tâm),
                  'Thời gian': pd.Categorical(Thời gian)})

```

Sau đó, chúng ta xây dựng ma trận mô hình (bỏ qua hệ số chặn).

```

Trong [22]: model = MS(['Operators',
                      'Trung tâm',
                      'Thời gian'],
                      chặn=False)
X = model.fit_transform(D)

```

Việc xem xét ma trận mô hình X là điều đáng làm, để chúng ta có thể
Hãy chắc chắn rằng chúng ta hiểu cách các biến đã được mã hóa. Theo mặc định,
Các mức độ của biến phân loại được sắp xếp và, như thường lệ, cột đầu tiên
Mã hóa one-hot của biến bị loại bỏ.

```

Trong [23]: X[:5]

```

```

Ra ngoài[23]:      Trung tâm điều hành[B]  Trung tâm[C]  Thời gian[Chăn.]  Thời gian[Sáng.]
0           13           0.0           1.0  0.0  0.0
1           15           0.0           0.0           1.0           0.0
2            7           1.0           0.0           0.0           1.0
3            7           0.0           1.0           0.0           1.0
4           13           0.0           1.0           1.0           0.0

```

Tiếp theo, chúng ta xác định các hệ số và hàm nguy hiểm.

```

Trong [24]: true_beta = np.array([0.04, -0.3, 0, 0.2, -0.2])
true_linpred = X.dot(true_beta)
nguy cơ = lambda t: 1e-5 * t

```

Ở đây, chúng ta đã đặt hệ số liên quan đến **Toán tử** bằng 0,04;
Nói cách khác, mỗi tổng đài viên bổ sung sẽ làm tăng "rủi ro" cuộc gọi được trả
lời lên 0,04 = 1,041 lần, với điều kiện **Trung tâm** và
Các biến **thời gian**. Điều này hợp lý: số lượng người vận hành càng nhiều thì...
Tay phải, thời gian chờ càng ngắn! Hệ số liên quan đến **Trung tâm ==**
B có giá trị -0,3, và **Tâm == A** được coi là đường cơ sở. Điều này có nghĩa là
Nguy cơ cuộc gọi được trả lời tại Trung tâm B thấp hơn 0,74 lần so với nguy cơ cuộc gọi sẽ không được trả lời.
Câu hỏi sẽ được trả lời tại Trung tâm A; nói cách khác, thời gian chờ đợi sẽ lâu hơn một chút.
tại Trung tâm B.

Hãy nhớ lại phần 2.3.7 về việc sử dụng **lambda** để tạo các hàm ngắn.

Ngay lập tức. Chúng ta sử dụng hàm **sim_time()** từ gói **ISLP.survival**. Hàm này sử dụng mối quan hệ giữa hàm sống sót và

sim_time()

Nguy cơ tích lũy $S(t) = \exp(-H(t))$ và dạng cụ thể của hàm nguy cơ tích lũy trong mô hình Cox để mô phỏng dữ liệu dựa trên các giá trị

của bộ dự đoán tuyến tính **true_linpred** và nguy cơ tích lũy. Chúng ta cần để cung cấp hàm nguy cơ tích lũy, điều mà chúng tôi thực hiện ở đây.

```

Trong [25]: cum_hazard = lambda t: 1e-5 * t**2 / 2

```

496 11. Phân tích sống sót và dữ liệu bị kiểm duyệt

Chúng tôi hiện đã sẵn sàng tạo dữ liệu theo mô hình rủi ro tỷ lệ Cox.
mô hình. Chúng tôi giới hạn thời gian tối đa xuống còn 1000 giây để giữ cho quá trình mô phỏng được thực hiện.
Thời gian chờ hợp lý. Hàm `sim_time()` nhận một bộ dự đoán tuyến tính, một
Hàm nguy cơ tích lũy và bộ tạo số ngẫu nhiên.

```
Trong [26]: W = np.array([sim_time(l, cum_hazard, rng)
                        for l in true_linpred])
D['Thời gian chờ'] = np.clip(W, 0, 1000)
```

Bây giờ chúng ta mô phỏng biến kiểm duyệt của mình, trong đó chúng ta giả định 90% của
Các cuộc gọi đã được trả lời (`Thất bại == 1`) trước khi khách hàng cúp máy (`Thất bại == 0`).

```
Trong [27]: D['Failed'] = rng.choice([1, 0],
                                   N,
                                   p=[0.9, 0.1])
D[:5]
```

Ra ngoài[27]:

	Trung tâm điều hành 13	Thời gian chờ đợi	Thất bại
0		C Sau đó. 525.064979	1
1	15	Số chặn. 254,677835	1
2	7	B Morn. 487.739224	1
3	7	C Morn. 308.580292	1
4	13	C Chặn. 154.174608	1

```
Trong [28]: D['Failed'].mean()
```

Out[28]: 0.8985

Bây giờ chúng ta sẽ vẽ biểu đồ đường cong sống sót Kaplan-Meier. Đầu tiên, chúng ta phân nhóm theo `Trung tâm`.

```
Trong [29]: fig, ax = subplots(figsize=(8,8))
theo_trung_tam = {}
for center, df in D.groupby('Center'):
    by_center[center] = df
    km_center = km.fit(df[' Thời gian chờ'], df['Thất bại'])
    km_center.plot(label='Center=%s' % center, ax=ax)
ax.set_title("Xác suất vẫn đang chờ xử lý")
```

Tiếp theo, chúng ta phân loại theo `Thời gian`.

```
Trong [30]: fig, ax = subplots(figsize=(8,8))
theo_thời_gian = {}
for time, df in D.groupby('Time'):
    by_time[time] = df
    km_time = km.fit(df[' Thời gian chờ'], df['Thất bại'])
    km_time.plot(label='Time=%s' % time, ax=ax)
ax.set_title("Xác suất vẫn đang chờ xử lý")
```

Có vẻ như các cuộc gọi tại Trung tâm cuộc gọi B mất nhiều thời gian hơn để được trả lời so với các cuộc gọi khác.
tại Trung tâm A và C. Tương tự, dường như thời gian chờ đợi lâu nhất là ở...
ngắn nhất vào buổi sáng và ngắn nhất vào buổi tối. Chúng ta có thể sử dụng kiểm định log-rank để
Xác định xem những khác biệt này có ý nghĩa thống kê hay không bằng cách sử dụng
hàm `multivariate_logrank_test()`.

```
Trong [31]: multivariate_logrank_test(D[' Thời gian chờ'],
                                   D['Trung tâm'],
                                   D['Thất bại'])
```

```
Ra ngoài[31]:          t_0          -1
               null_distribution      chi bình phương
               degrees_of_freedom test_name      2
               multivariate_logrank_test

               thống kê kiểm định      p -log2(p)
               20,30 <0,005      14,65
```

Tiếp theo, chúng ta xem xét ảnh hưởng của Thời gian.

```
Trong [32]: multivariate_logrank_test(D[' Thời gian chờ'],
                                     D['Thời gian'],
                                     D['Thất bại'])
```

```
Ra ngoài[32]:          t_0          -1
               null_distribution      chi bình phương
               degrees_of_freedom test_name      2
               multivariate_logrank_test

               thống kê kiểm định      p -log2(p)
               49,90 <0,005      35,99
```

Tương tự như trường hợp biến định tính có 2 cấp độ, các kết quả này là:
Tương tự như phép kiểm định tỷ lệ khả năng xảy ra từ mô hình rủi ro tỷ lệ Cox.
Đầu tiên, chúng ta xem xét kết quả dành cho khu vực Trung tâm.

```
Trong [33]: X = MS(['Thời gian chờ',
                  'Thất bại',
                  'Trung tâm'],
                  intercept=False).fit_transform(D)
F = coxph().fit(X, 'Thời gian chờ', 'Thất bại')
F.log_likelihood_ratio_test()
```

```
Out[33]: null_distribution      chi bình phương
         degrees_freedom      2
         test_name log-likelihood ratio test

         thống kê kiểm định      p -log2(p)
         20,58 <0,005      14,85
```

Tiếp theo, chúng ta xem xét kết quả cho yếu tố Thời gian.

```
Trong [34]: X = MS(['Thời gian chờ',
                  'Thất bại',
                  'Thời gian'],
                  intercept=False).fit_transform(D)
F = coxph().fit(X, 'Thời gian chờ', 'Thất bại')
F.log_likelihood_ratio_test()
```

```
Out[34]: null_distribution      chi bình phương
         degrees_freedom      2
         test_name log-likelihood ratio test

         thống kê kiểm định      p -log2(p)
         48,12 <0,005 34,71
```

Chúng tôi nhận thấy sự khác biệt giữa các trung tâm là rất đáng kể, cũng như sự khác biệt giữa các thời điểm trong ngày.
Cuối cùng, chúng tôi áp dụng mô hình rủi ro tỷ lệ của Cox vào dữ liệu.

```
Trong [35]: X = MS(D.columns,
               intercept=False).fit_transform(D) fit_queuing =
               coxph().fit( X,
               'Thời gian chờ',
               'Thất bại')
               fit_queuing.summary[['coef', 'se(coef)', 'p']]
```

Ra ngoài[35]:

	hệ số se(hệ số)	p
biến phụ		
Trung tâm điều	0.043934 0.007520 5.143677e-09	
hành[B]	-0.236059 0.058113 4.864734e-05 Trung tâm[C]	0.012231 0.057518 8.316083e-01
Thời gian[Chẩn.]		
	0,268845 0,057797 3,294914e-06	
Thời gian [Buổi sáng]	-0.148215 0.057334 9.734378e-03	

Giá trị p cho Trung tâm B và thời gian buổi tối rất nhỏ. Rõ ràng là tỷ lệ nguy hiểm – tức là rủi ro tức thời cuộc gọi sẽ được trả lời – tăng lên theo số lượng tổng đài viên. Vì chúng tôi tự tạo ra dữ liệu nên chúng tôi biết rằng các hệ số thực cho **Tổng đài viên**, **Trung tâm = B**, **Trung tâm = C**, **Thời gian = Buổi tối** và **Thời gian = Buổi sáng** lần lượt là 0,04, 0,3, 0, 0,2 và 0,2. Các ước tính hệ số từ mô hình Cox đã được hiệu chỉnh khá chính xác.

11.9 Bài tập

Khái niệm

- 1. Với mỗi ví dụ, hãy cho biết cơ chế kiểm duyệt có độc lập hay không. Giải thích lý do cho câu trả lời của bạn.
 - (a) Trong một nghiên cứu về sự tái phát bệnh, do sự bất cẩn của một nhà khoa học nghiên cứu, tất cả bệnh nhân có số điện thoại bắt đầu bằng số “2” đều bị mất liên lạc.
 - (b) Trong một nghiên cứu về tuổi thọ, lỗi định dạng khiến tất cả các bệnh nhân có độ tuổi trên 99 tuổi bị mất (tức là chúng ta biết rằng những bệnh nhân đó trên 99 tuổi, nhưng chúng ta không biết tuổi chính xác của họ).
 - (c) Bệnh viện A tiến hành một nghiên cứu về tuổi thọ. Tuy nhiên, những bệnh nhân rất ốm thường được chuyển đến Bệnh viện B và không được theo dõi tiếp.
 - (d) Trong một nghiên cứu về thời gian thất nghiệp, những người tìm được việc làm sớm hơn ít có động lực để giữ liên lạc với các nhà nghiên cứu, và do đó có nhiều khả năng bị mất liên lạc trong quá trình theo dõi.
 - (e) Trong một nghiên cứu về thời gian mang thai, phụ nữ sinh non có nhiều khả năng sinh con ở bệnh viện khác với bệnh viện thường xuyên của họ, và do đó có nhiều khả năng bị loại khỏi nghiên cứu hơn so với phụ nữ sinh đủ tháng.

- (f) Một nhà nghiên cứu muốn lập mô hình về số năm học của cư dân một thị trấn nhỏ. Cư dân theo học đại học ngoài thị trấn có nhiều khả năng bị mất liên lạc và cũng có nhiều khả năng theo học cao học hơn so với những người theo học đại học trong thị trấn.
- (g) Các nhà nghiên cứu tiến hành nghiên cứu về thời gian sống không bệnh (tức là thời gian cho đến khi bệnh tái phát sau điều trị). Những bệnh nhân không tái phát trong vòng năm năm được coi là đã khỏi bệnh, và do đó thời gian sống của họ được tính đến năm năm.
- (h) Chúng tôi muốn mô hình hóa thời gian hỏng hóc của một số linh kiện điện. Linh kiện này có thể được sản xuất tại Iowa hoặc Pittsburgh mà chất lượng không có sự khác biệt. Nhà máy ở Iowa mở cửa cách đây năm năm, vì vậy các linh kiện sản xuất tại Iowa được kiểm duyệt trong vòng năm năm. Nhà máy ở Pittsburgh mở cửa cách đây hai năm, vì vậy các linh kiện đó được kiểm duyệt trong vòng hai năm.
- (i) Chúng tôi muốn mô hình hóa thời gian hỏng hóc của một linh kiện điện được sản xuất tại hai nhà máy khác nhau, một trong số đó mở cửa trước nhà máy kia. Chúng tôi có lý do để tin rằng các linh kiện được sản xuất tại nhà máy mở cửa sớm hơn có chất lượng cao hơn.

2. Chúng tôi tiến hành một nghiên cứu với $n = 4$ người tham gia vừa mới mua điện thoại di động, nhằm mô phỏng thời gian cho đến khi cần thay điện thoại. Người tham gia đầu tiên thay điện thoại sau 1,2 năm. Người tham gia thứ hai vẫn chưa thay điện thoại khi kết thúc thời gian nghiên cứu hai năm. Người tham gia thứ ba đổi số điện thoại và không tiếp tục tham gia nghiên cứu (nhưng vẫn chưa thay điện thoại) sau 1,5 năm. Người tham gia thứ tư thay điện thoại sau 0,2 năm.

Đối với mỗi người trong bốn người tham gia ($i = 1, \dots, 4$), hãy trả lời các câu hỏi sau bằng cách sử dụng ký hiệu được giới thiệu trong Phần 11.1:

- (a) Thời gian thay thế điện thoại di động của người tham gia có bị kiểm duyệt không? (b) Giá trị của c_i đã biết chưa, và nếu có thì giá trị đó là bao nhiêu? (c) Giá trị của t_i đã biết chưa, và nếu có thì giá trị đó là bao nhiêu? (d) Giá trị của y_i đã biết chưa, và nếu có thì giá trị đó là bao nhiêu? (e) Giá trị của δ_i đã biết chưa, và nếu có thì giá trị đó là bao nhiêu?

3. Đối với ví dụ trong Bài tập 2, hãy báo cáo các giá trị của K , $d_1, \dots, d_K$, $r_1, \dots, r_K$ và $q_1, \dots, q_K$, trong đó ký hiệu này đã được định nghĩa trong Mục 11.3.

4. Bài toán này sử dụng đường cong sống sót Kaplan-Meier được hiển thị trong Hình 11.9. Dữ liệu thô được sử dụng để vẽ đường cong sống sót này được cung cấp trong Bảng 11.4. Cột biến phụ thuộc trong bảng đó không cần thiết cho bài toán này.

- (a) Xác suất sống sót sau 50 ngày ước tính là bao nhiêu?

Quan sát (Y)	Chỉ số kiểm duyệt (δ)	Biến độc lập (X)
26,5	0,1	1
37.2	11	1
57,3	-0,3	1
90,8	2,8	0
20.2	1.8	0
89,8	0,4	0

BẢNG 11.4. Dữ liệu được sử dụng trong Bài tập 4.

(b) Viết ra biểu thức phân tích cho tỷ lệ sống sót ước tính chức năng. Ví dụ, câu trả lời của bạn có thể là một cái gì đó tương tự như... các dòng của


$$S(t)=\begin{cases} 0,8 & \text{nếu } t < 31 \\ 0,5 & \text{nếu } 31 \leq t < 77 \\ 0,22 & \text{nếu } 77 \leq t. \end{cases}$$

(Phương trình trên chỉ mang tính minh họa: đó không phải là đáp án chính xác!)

5. Vẽ đồ thị hàm sống sót được cho bởi phương trình

$$S(t)=\begin{cases} 0,8 & \text{nếu } t < 31 \\ 0,5 & \text{nếu } 31 \leq t < 77 \\ 0,22 & \text{nếu } 77 \leq t. \end{cases}$$

Câu trả lời của bạn sẽ trông giống như Hình 11.9.



HÌNH 11.9. Đường cong sống sót Kaplan-Meier được sử dụng trong Bài tập 4.

6. Bài toán này sử dụng dữ liệu được hiển thị trong Hình 11.1. Trong khi hoàn thành bài toán này, bạn có thể tham khảo thời gian quan sát như sau: $y_1, \dots, y_4$. Thứ tự của các thời điểm quan sát này có thể được thấy từ Hình 11.1; không cần thiết phải có giá trị chính xác của chúng.

(a) Báo cáo các giá trị của $\delta_1, \dots, \delta_4, K, d_1, \dots, d_K, r_1, \dots, r_K$ và $q_1, \dots, q_K$. Ký hiệu liên quan được định nghĩa trong Mục 11.1 và 11.3.

- (b) Vẽ đồ thị đường cong sống sót Kaplan-Meier tương ứng với tập dữ liệu này. (Bạn không cần sử dụng bất kỳ phần mềm nào để làm điều này – bạn có thể vẽ bằng tay dựa trên kết quả thu được ở phần (a).) (c) Dựa trên đường cong sống sót ước tính ở phần (b), xác suất sự kiện xảy ra trong vòng 200 ngày là bao nhiêu? Xác suất sự kiện không xảy ra trong vòng 310 ngày là bao nhiêu? (d) Viết biểu thức cho đường cong sống sót ước tính từ

(b).

7. Trong bài toán này, chúng ta sẽ suy ra (11.5) và (11.6), cần thiết cho việc xây dựng thống kê kiểm định hạng logarit (11.8). Nhớ lại ký hiệu trong Bảng 11.1.



- (a) Giả sử không có sự khác biệt giữa hàm sống sót của hai nhóm. Khi đó, ta có thể coi q_{1k} là số lần hỏng hóc nếu ta lấy r_{1k} quan sát, không hoàn lại, từ một tập hợp rủi ro gồm r_k quan sát chứa tổng cộng q_k lần hỏng hóc.

(a) Hãy chứng minh rằng q_{1k} tuân theo phân phối siêu hình học. Viết các tham số của phân phối này theo r_{1k}, r_k và q_k. (b) Dựa vào câu trả

lời trước đó và các đặc tính của phân phối siêu hình học, hãy tìm giá trị trung bình và phương sai của q_{1k}?

So sánh câu trả lời của bạn với (11.5) và (11.6).

phân
phối siêu
hình học

8. Nhớ lại rằng hàm sống sót S(t), hàm nguy hiểm h(t) và hàm mật độ f(t) được định nghĩa trong (11.2), (11.9) và (11.11) tương ứng. Hơn nữa, định nghĩa F(t)=1-S(t). Chứng minh rằng các mối quan hệ sau đây đúng:



$$f(t) = dF(t)/dt$$

$$S(t) = \exp \int_0^t h(u) du.$$

9. Trong bài tập này, chúng ta sẽ tìm hiểu những hệ quả của giả định rằng Thời gian sống sót tuân theo phân bố hàm mũ.

- (a) Giả sử thời gian sống sót tuân theo phân phối Exp(λ), sao cho hàm mật độ của nó là f(t) = λ exp(-λt). Sử dụng các mối quan hệ được cung cấp trong Bài tập 8, hãy chứng minh rằng S(t) = exp(-λt). (b) Bây giờ giả sử rằng mỗi trong số n thời gian sống sót độc lập tuân theo phân phối Exp(λ). Hãy viết ra biểu thức cho hàm khả năng (11.13). (c) Chứng minh rằng ước lượng hợp lý tối đa cho λ là

$$\hat{\lambda} = \frac{\sum_{i=1}^N \delta_i}{\sum_{i=1}^N y_i}.$$

- (d) Sử dụng câu trả lời của bạn ở (c) để suy ra ước lượng của tỷ lệ trung bình thời gian sống.

Gợi ý: Đối với (d), hãy nhớ rằng giá trị trung bình của biến ngẫu nhiên Exp(λ) là 1/λ.

502 11. Phân tích sống sót và dữ liệu bị kiểm duyệt

Đã áp dụng

10. Bài tập này tập trung vào dữ liệu về khối u não, được bao gồm trong Thư viện `ISLP`.

(a) Vẽ đường cong sống sót Kaplan-Meier với dải sai số chuẩn ± 1 , sử dụng công cụ ước lượng `KaplanMeierFitter()` trong gói `lifelines`.

(b) Lấy mẫu bootstrap với kích thước $n = 88$ từ các cặp (y_i, δ_i) và tính toán đường cong sống sót Kaplan-Meier thu được. Lặp lại quá trình này $B = 200$ lần. Sử dụng kết quả để ước tính sai số chuẩn của đường cong sống sót Kaplan-Meier tại mỗi thời điểm. So sánh kết quả này với sai số chuẩn thu được trong (a). (c) Xây dựng mô hình rủi ro tỷ lệ Cox sử dụng tất cả các biến dự báo để dự đoán khả năng sống sót. Tóm tắt các phát hiện chính.

(d) Phân tầng dữ liệu theo giá trị của `ki`. (Vì chỉ có một quan sát có `ki==40`, bạn có thể nhóm quan sát đó lại với các quan sát có `ki==60`.) Vẽ đường cong sống sót Kaplan-Meier cho mỗi trong năm tầng, được điều chỉnh theo các biến dự báo khác.

11. Bài tập này sử dụng dữ liệu trong Bảng 11.4.

(a) Tạo hai nhóm quan sát. Trong Nhóm 1, $X < 2$, trong khi ở Nhóm 2, $X \geq 2$. Vẽ đồ thị đường cong sống sót Kaplan-Meier tương ứng với hai nhóm. Hãy chắc chắn ghi nhãn các đường cong để rõ ràng đường cong nào tương ứng với nhóm nào. Quan sát bằng mắt thường, có sự khác biệt nào giữa các đường cong sống sót của hai nhóm không?

(b) Áp dụng mô hình rủi ro tỷ lệ Cox, sử dụng biến chỉ báo nhóm làm biến độc lập. Hệ số ước tính là bao nhiêu? Viết một câu giải thích ý nghĩa của hệ số này, xét về rủi ro hoặc xác suất tức thời của sự kiện. Có bằng chứng nào cho thấy giá trị hệ số thực sự khác không không?

(c) Nhớ lại Mục 11.5.2 rằng trong trường hợp có một biến độc lập nhị phân duy nhất, thống kê kiểm định log-rank phải giống với thống kê điểm số của mô hình Cox. Tiến hành kiểm định log-rank để xác định xem có sự khác biệt giữa các đường cong sống sót của hai nhóm hay không. Giá trị p của thống kê kiểm định log-rank so sánh như thế nào với giá trị p của thống kê điểm số của mô hình Cox từ (b)?

12

Học không giám sát



Phần lớn nội dung cuốn sách này đề cập đến các phương pháp học có giám sát, chẳng hạn như...

hồi quy và phân loại. Trong môi trường học có giám sát, chúng ta thường

Có quyền truy cập vào một tập hợp p đặc trưng $X_1, X_2, \dots, X_p$, được đo trên n quan sát, và một phản hồi Y cũng được đo trên cùng n quan sát đó.

Mục tiêu sau đó là dự đoán Y bằng cách sử dụng $X_1, X_2, \dots, X_p$.

Chương này sẽ tập trung vào học không giám sát, một tập hợp các công cụ thống kê được thiết kế cho trường hợp chúng ta chỉ có một tập hợp các đặc trưng $X_1, X_2, \dots, X_p$ được đo trên n quan sát. Chúng ta không quan tâm đến

trong dự đoán, vì chúng ta không có biến phản hồi Y tương ứng.

Thay vào đó, mục tiêu là khám phá những điều thú vị về các phép đo.

Trên $X_1, X_2, \dots, X_p$. Có cách nào để trực quan hóa dữ liệu một cách hiệu quả không?

Chúng ta phát hiện ra các nhóm nhỏ giữa các biến số hay giữa các quan sát?

Học không giám sát đề cập đến một tập hợp đa dạng các kỹ thuật để trả lời

những câu hỏi như thế này. Trong chương này, chúng ta sẽ tập trung vào hai loại học không giám

sát cụ thể: phân tích thành phần chính, một công cụ

được sử dụng để trực quan hóa dữ liệu hoặc xử lý sơ bộ dữ liệu trước khi áp dụng các kỹ thuật

học có giám sát, và phân cụm, một nhóm phương pháp rộng để khám phá.

Các nhóm con chưa xác định trong dữ liệu.

12.1 Thách thức của học không giám sát

Học có giám sát là một lĩnh vực đã được hiểu rõ. Thực tế, nếu bạn đã đọc...

Nếu bạn đã đọc các chương trước trong cuốn sách này, thì đến giờ bạn hẳn đã có một kiến thức tốt.

Nắm vững kiến thức về học có giám sát. Ví dụ, nếu bạn được yêu cầu dự đoán một

Kết quả nhị phân từ một tập dữ liệu, bạn có một bộ công cụ rất phát triển.

Có sẵn cho bạn (chẳng hạn như hồi quy logistic, phân tích phân biệt tuyến tính,

cây phân loại, máy vectơ hỗ trợ, và nhiều hơn nữa) cũng như một sự rõ ràng

504 12. Học không giám sát

Hiểu biết về cách đánh giá chất lượng của các kết quả thu được (sử dụng phương pháp kiểm định chéo, kiểm định trên tập dữ liệu thử nghiệm độc lập, v.v.).

Ngược lại, học không giám sát thường khó khăn hơn nhiều. Quá trình này có xu hướng chủ quan hơn, và không có mục tiêu đơn giản nào cho việc phân tích, chẳng hạn như dự đoán phản hồi. Học không giám sát thường được thực hiện như một phần của phân tích dữ liệu thăm dò. Hơn nữa, việc đánh giá kết quả thu được từ các phương pháp học không giám sát có thể khó khăn, vì không có cơ chế nào được chấp nhận rộng rãi để thực hiện kiểm định chéo hoặc xác thực kết quả trên một tập dữ liệu độc lập. Lý do cho sự khác biệt này rất đơn giản. Nếu chúng ta xây dựng một mô hình dự đoán bằng kỹ thuật học có giám sát, thì có thể kiểm tra công việc của mình bằng cách xem mô hình dự đoán phản hồi Y tốt như thế nào trên các quan sát không được sử dụng để xây dựng mô hình. Tuy nhiên, trong học không giám sát, không có cách nào để kiểm tra công việc của chúng ta vì chúng ta không biết câu trả lời thực sự - vấn đề này là không giám sát.

phân tích dữ
liệu
thăm dò

Các kỹ thuật học không giám sát ngày càng trở nên quan trọng trong nhiều lĩnh vực. Một nhà nghiên cứu ung thư có thể phân tích mức độ biểu hiện gen ở 100 bệnh nhân ung thư vú. Sau đó, người này có thể tìm kiếm các nhóm nhỏ trong số các mẫu ung thư vú, hoặc trong số các gen, để hiểu rõ hơn về bệnh. Một trang web mua sắm trực tuyến có thể cố gắng xác định các nhóm người mua sắm có lịch sử duyệt web và mua hàng tương tự, cũng như các mặt hàng mà người mua sắm trong mỗi nhóm đặc biệt quan tâm. Sau đó, một người mua sắm cụ thể có thể được ưu tiên hiển thị các mặt hàng mà họ đặc biệt có khả năng quan tâm, dựa trên lịch sử mua hàng của những người mua sắm tương tự. Một công cụ tìm kiếm có thể chọn kết quả tìm kiếm nào sẽ hiển thị cho một cá nhân cụ thể dựa trên lịch sử nhấp chuột của những cá nhân khác có mô hình tìm kiếm tương tự. Những nhiệm vụ học thống kê này, và nhiều nhiệm vụ khác nữa, có thể được thực hiện thông qua các kỹ thuật học không giám sát.

12.2 Phân tích thành phần chính

Các thành phần chính được thảo luận trong Mục 6.3.1 trong bối cảnh hồi quy thành phần chính. Khi đối mặt với một tập hợp lớn các biến tương quan, các thành phần chính cho phép chúng ta tóm tắt tập hợp này bằng một số lượng nhỏ hơn các biến đại diện mà cùng nhau giải thích hầu hết sự biến thiên trong tập hợp ban đầu. Các hướng thành phần chính được trình bày trong Mục 6.3.1 như các hướng trong không gian đặc trưng mà dọc theo đó dữ liệu gốc có độ biến thiên cao. Các hướng này cũng xác định các đường và không gian con càng gần với đám mây dữ liệu càng tốt. Để thực hiện hồi quy thành phần chính, chúng ta chỉ cần sử dụng các thành phần chính làm biến dự báo trong mô hình hồi quy thay cho tập hợp biến lớn ban đầu.

Phân tích thành phần chính (PCA) đề cập đến quá trình tính toán các thành phần chính và việc sử dụng các thành phần này để hiểu dữ liệu. PCA là một phương pháp không giám sát, vì nó chỉ liên quan đến một tập hợp các đặc trưng $X_1, X_2, \dots, X_p$ và không có biến phản hồi Y tương ứng. Ngoài việc tạo ra các biến dẫn xuất để sử dụng trong các bài toán học có giám sát, PCA còn đóng vai trò là công cụ trực quan hóa dữ liệu (trực quan hóa dữ liệu).

phân tích
thành phần
chính

(việc quan sát hoặc trực quan hóa các biến số). Nó cũng có thể được sử dụng như một công cụ để điền dữ liệu thiếu – tức là, để điền các giá trị bị thiếu trong dữ liệu. ma trận.

Bây giờ chúng ta sẽ thảo luận chi tiết hơn về PCA, tập trung vào việc sử dụng PCA như... một công cụ để khám phá dữ liệu không giám sát, phù hợp với chủ đề này. chương.

12.2.1 Thành phần chính là gì?

Giả sử chúng ta muốn trực quan hóa n quan sát với các phép đo trên một

Tập hợp p đặc trưng, $X_1, X_2, \dots, X_p$, như một phần của phân tích dữ liệu thăm dò.

Chúng ta có thể thực hiện điều này bằng cách xem xét các biểu đồ phân tán hai chiều của dữ liệu. mỗi phần tử chứa các phép đo của n quan sát trên hai trong số các phần tử đó.

các đặc điểm. Tuy nhiên, với $p = \frac{P}{2} = p(p-1)/2$ biểu đồ phân tán như vậy; ví dụ, 10 thì có 45 đồ thị! Nếu p lớn thì chắc chắn sẽ không phải vậy.

Có thể xem xét tất cả chúng; hơn nữa, rất có thể không cái nào trong số chúng sẽ

Chúng mang tính thông tin vì mỗi phần chỉ chứa một phần nhỏ của tổng thể.

thông tin có trong tập dữ liệu. Rõ ràng, cần một phương pháp tốt hơn để

trực quan hóa n quan sát khi p lớn. Cụ thể, chúng tôi muốn

Tìm một cách biểu diễn dữ liệu có chiều thấp sao cho nắm bắt được càng nhiều thông tin càng tốt.

càng nhiều thông tin càng tốt. Ví dụ, nếu chúng ta có thể thu được thông tin hai chiều

cách biểu diễn dữ liệu nắm bắt được hầu hết thông tin, sau đó chúng ta

có thể vẽ đồ thị các quan sát trong không gian chiều thấp này.

PCA cung cấp một công cụ để thực hiện chính điều này. Nó tìm ra một biểu diễn có chiều thấp của tập dữ liệu chứa được càng nhiều biến thể càng tốt.

Ý tưởng là mỗi trong số n quan sát tồn tại trong không gian p chiều, nhưng không phải vậy.

Tất cả các khía cạnh này đều thú vị như nhau. PCA tìm kiếm một số lượng nhỏ.

có kích thước càng thú vị càng tốt, trong đó khái niệm thú vị được đo bằng mức độ biến thiên của các quan sát dọc theo mỗi chiều.

chiều. Mỗi chiều được tìm thấy bằng PCA là một tổ hợp tuyến tính.

của các đặc điểm p . Bây giờ chúng ta sẽ giải thích cách thức mà các chiều này,

hoặc các thành phần chính được tìm thấy.

Thành phần chính đầu tiên của một tập hợp các đặc trưng $X_1, X_2, \dots, X_p$ là... tổ hợp tuyến tính chuẩn hóa của các đặc điểm

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \dots + \phi_{p1}X_p \quad (12.1)$$

có phương sai lớn nhất. Thuật ngữ "chuẩn hóa" ở đây có nghĩa là $\sum_{j=1}^p \phi_{j1}^2 = 1$.

Chúng ta gọi các phần tử $\phi_{11}, \dots, \phi_{p1}$ là hệ số tải của thành phần chính thứ nhất; cùng nhau,

các hệ số tải tạo thành vectơ tải thành phần chính, $\phi_1 = (\phi_{11} \ \phi_{21} \ \dots \ \phi_{p1})^T$. Chúng ta ràng

buộc các hệ số tải sao cho

Tổng bình phương của chúng bằng một, vì nếu không thì việc đặt các phần tử này sẽ khác nhau.

có giá trị tuyệt đối lớn tùy ý có thể dẫn đến một giá trị lớn tùy ý.

sự khác biệt.

Cho một tập dữ liệu X có kích thước $n \times p$, làm thế nào để tính thành phần chính thứ nhất?

Vì chúng ta chỉ quan tâm đến phương sai, nên ta giả định rằng mỗi thành phần chính thứ nhất...

Các biến trong X đã được chuẩn hóa để có giá trị trung bình bằng 0 (tức là giá trị trung bình của các cột trong X bằng 0). Sau đó, chúng ta tìm tổ hợp tuyến tính của các biến đó.

các giá trị đặc trưng mẫu của biểu mẫu

$$z_{i1} = \phi_{11}x_{i1} + \phi_{21}x_{i2} + \dots + \phi_{p1}x_{ip} \quad (12.2)$$

đang tải

506 12. Học không giám sát

$j=1$. có phương sai mẫu lớn nhất, tuân theo ràng buộc rằng Nói cách khác, vectơ tải thành phần chính đầu tiên giải quyết vấn đề tối ưu hóa

tối đa hóa $\frac{1}{N} \sum_{i=1}^N \varphi_{j1} x_{ij}$ tùy thuộc vào φ_{j1} $= 1$. (12.3)

Từ (12.2) ta có thể viết mục tiêu trong (12.3) như sau $\frac{1}{N} \sum_{i=1}^N z_{i1}$. Vì $i=1$ $\frac{1}{N} \sum_{i=1}^N x_{ij} = 0$, nên giá trị trung bình của $z_{11}, \dots, z_{n1}$ cũng sẽ bằng 0. Do đó, mục tiêu mà chúng ta đang tối đa hóa trong (12.3) chỉ là phương sai mẫu của n giá trị của z_{11} . Chúng ta gọi $z_{11}, \dots, z_{n1}$ là điểm số của thành phần chính thứ nhất. Bài toán (12.3) có thể được giải quyết thông qua phân tích giá trị riêng, một kỹ thuật chuẩn trong đại số tuyến tính, nhưng chi tiết nằm ngoài phạm vi của cuốn sách này. Có một cách giải thích hình học hay về thành phần chính thứ nhất.

Vectơ tải φ_1 với các phần tử $\varphi_{11}, \varphi_{21}, \dots, \varphi_{p1}$ xác định một hướng trong không gian đặc trưng mà theo đó dữ liệu biến đổi nhiều nhất. Nếu ta chiếu n điểm dữ liệu $x_1, \dots, x_n$ lên hướng này, các giá trị được chiếu chính là điểm số thành phần chính $z_{11}, \dots, z_{n1}$. Ví dụ, Hình 6.14 trên trang 254 hiển thị vectơ tải thành phần chính đầu tiên (đường liền màu xanh lá cây) trên một tập dữ liệu quảng cáo. Trong dữ liệu này, chỉ có hai đặc trưng, và do đó các quan sát cũng như vectơ tải thành phần chính đầu tiên có thể được hiển thị dễ dàng. Như có thể thấy từ (6.19), trong tập dữ liệu đó $\varphi_{11} = 0,839$ và $\varphi_{21} = 0,544$.

Sau khi xác định được thành phần chính thứ nhất Z_1 của các đặc trưng, ta có thể tìm thành phần chính thứ hai Z_2 . Thành phần chính thứ hai là tổ hợp tuyến tính của $X_1, \dots, X_p$ có phương sai lớn nhất trong tất cả các tổ hợp tuyến tính không tương quan với Z_1 . Các điểm số của thành phần chính thứ hai $z_{12}, z_{22}, \dots, z_{n2}$ có dạng như sau:


$z_{i2} = \varphi_{12}x_{i1} + \varphi_{22}x_{i2} + \dots + \varphi_{p2}x_{ip},$ (12.4)

trong đó φ_2 là vectơ tải thành phần chính thứ hai, với các phần tử $\varphi_{12}, \varphi_{22}, \dots, \varphi_{p2}$. Hóa ra việc ràng buộc Z_2 không tương quan với Z_1 tương đương với việc ràng buộc hướng φ_2 vuông góc với hướng φ_1 . Trong ví dụ ở Hình 6.14, các quan sát nằm trong không gian hai chiều (vì $p = 2$), và do đó, một khi chúng ta đã tìm thấy φ_1 , chỉ có một khả năng duy nhất cho φ_2 , được thể hiện bằng đường nét đứt màu xanh lam.

(Từ Mục 6.3.1, chúng ta biết rằng $\varphi_{12} = 0,544$ và $\varphi_{22} = 0,839$.) Nhưng trong một tập dữ liệu lớn hơn với $p > 2$ biến, có nhiều thành phần chính khác nhau và chúng được định nghĩa theo cách tương tự. Để tìm φ_2 , chúng ta giải một bài toán tương tự như (12.3) với φ_2 thay thế φ_1 , và với ràng buộc bổ sung là φ_2 trực giao với φ_1 .

1. Như một phương án thay thế cho phân tích giá trị riêng, một kỹ thuật liên quan gọi là phân tích giá trị đơn có thể được sử dụng. Kỹ thuật này sẽ được tìm hiểu trong bài thực hành ở cuối chương này.

2 Về mặt kỹ thuật, các hướng thành phần chính $\varphi_1, \varphi_2, \varphi_3, \dots$ được xác định bởi chuỗi có thứ tự các vectơ riêng của ma trận $X^T X$, và phương sai của các thành phần là các giá trị riêng. Có tối đa $\min(n - 1, p)$ thành phần chính.



HÌNH 12.1. Hai thành phần chính đầu tiên của dữ liệu **USArrests** .
Tên các tiểu bang màu xanh lam thể hiện điểm số của hai thành phần chính đầu tiên.
Các mũi tên màu cam biểu thị hai vectơ tải trọng thành phần chính đầu tiên (với các trục ở trên cùng và bên phải). Ví dụ, quá trình tải cho **Rape** trên thành phần đầu tiên là 0,54, và hệ số tải của nó trên thành phần chính thứ hai là 0,17 (từ "**Rape**" - **hiếp dâm**).
được đặt ở tâm điểm (0,54, 0,17)). Hình này được gọi là biểu đồ hai chiều (biplot) vì nó hiển thị cả điểm số thành phần chính và hệ số tải thành phần chính.

Sau khi tính toán các thành phần chính, chúng ta có thể vẽ đồ thị của chúng.
đối lập nhau để tạo ra các hình ảnh dữ liệu có chiều thấp hơn.
Ví dụ, ta có thể vẽ đồ thị vectơ điểm số Z1 so với Z2, Z1 so với Z3,
So sánh Z2 với Z3, và cứ thế tiếp tục. Về mặt hình học, điều này tương đương với việc chiếu dữ liệu gốc được chuyển xuống không gian con được tạo bởi ϕ_1 , ϕ_2 và ϕ_3 , và vẽ các điểm dự kiến.
Chúng tôi minh họa việc sử dụng PCA trên tập dữ liệu **USArrests** . Đối với mỗi...
Bộ dữ liệu này bao gồm số vụ bắt giữ tại 50 tiểu bang của Hoa Kỳ.
trên 100.000 cư dân đối với mỗi trong ba loại tội phạm: **Tấn công**, **Giết người** và **Hiếp dâm**.
Chúng tôi cũng ghi lại **UrbanPop** (tỷ lệ phần trăm dân số ở mỗi tiểu bang sống ở UrbanPop) (ở khu vực đô thị). Các vectơ điểm thành phần chính có độ dài $n = 50$,
và các vectơ tải thành phần chính có độ dài $p = 4$. PCA đã được
được thực hiện sau khi chuẩn hóa từng biến để có giá trị trung bình bằng 0 và độ lệch chuẩn

	PC1	PC2
Giết người	0,5358995	0,4181809
Tấn công	0,5831836	0,1879856
UrbanPop	0.2781909	0.8728062
Hiếp dâm	0.5434321	0.1673186

BẢNG 12.1. Các vectơ tải trọng thành phần chính, ϕ_1 và ϕ_2 , cho dữ liệu từ **USArrests** cũng được hiển thị trong Hình 12.1.


độ lệch thứ nhất. Hình 12.1 biểu diễn hai thành phần chính đầu tiên của những điều này. dữ liệu. Hình này thể hiện cả điểm số thành phần chính và dữ liệu. Các vectơ tải được hiển thị trong một biểu đồ hai chiều duy nhất. Các hệ số tải cũng được trình bày trong Bảng 12.2.1.

Trong Hình 12.1, ta thấy rằng vectơ tải trọng đầu tiên đặt xấp xỉ Trọng lượng ngang nhau đối với các tội danh Tấn công, Giết người và Hiếp dâm, nhưng với trọng lượng ít hơn nhiều đối với các tội danh khác. UrbanPop. Do đó, thành phần này tương ứng với một thước đo tổng thể. tỷ lệ tội phạm nghiêm trọng. Vectơ tải trọng thứ hai đặt phần lớn trọng lượng của nó. Trên UrbanPop, trọng lượng được đặt lên ba tính năng còn lại ít hơn nhiều. Do đó, điều này Thành phần này tương ứng gần đúng với mức độ đô thị hóa của tiểu bang. Nhìn chung, chúng ta thấy rằng các biến số liên quan đến tội phạm (Giết người, Tấn công và Hiếp dâm) Chúng nằm gần nhau, và biến UrbanPop thì cách xa nhau. ba biến số còn lại. Điều này cho thấy các biến số liên quan đến tội phạm có mối tương quan với nhau. với nhau—các tiểu bang có tỷ lệ giết người cao thường có tỷ lệ hành hung cao. và tỷ lệ hiếp dâm—và biến số UrbanPop ít tương quan với ba người còn lại.

Chúng ta có thể xem xét sự khác biệt giữa các tiểu bang thông qua hai vectơ điểm thành phần chính được hiển thị trong Hình 12.1. Phần thảo luận của chúng ta về hệ số tải Các vectơ cho thấy rằng các tiểu bang có điểm số dương lớn ở thành phần đầu tiên, chẳng hạn như California, Nevada và Florida, có tỷ lệ tội phạm cao, trong khi Các tiểu bang như North Dakota, với điểm số âm ở phần đầu tiên, có Tỷ lệ tội phạm thấp. California cũng đạt điểm cao ở yếu tố thứ hai. Điều này cho thấy mức độ đô thị hóa cao, trong khi điều ngược lại đúng với các tiểu bang. như Mississippi. Các tiểu bang có điểm gần bằng không ở cả hai thành phần, chẳng hạn như Indiana, Có mức độ tội phạm và đô thị hóa xấp xỉ mức trung bình.

12.2.2 Một cách diễn giải khác về các thành phần chính

Hai vectơ tải trọng thành phần chính đầu tiên trong một tập dữ liệu ba chiều mô phỏng được hiển thị ở bảng bên trái của Hình 12.2; những vectơ này Hai vectơ tải trải dài trên một mặt phẳng mà dọc theo đó các quan sát có Độ lệch chuẩn cao nhất. Trong phần trước, chúng ta đã mô tả các vectơ tải thành phần chính là các hướng trong không gian đặc trưng mà theo đó dữ liệu biến đổi nhiều nhất. và điểm số thành phần chính được thể hiện dưới dạng phép chiếu theo các hướng này. Tuy nhiên, một cách giải thích khác về các thành phần chính cũng có thể là...



HÌNH 12.2. Chín mươi quan sát được mô phỏng trong không gian ba chiều. Các quan sát được hiển thị bằng màu sắc để dễ hình dung. Bên trái: hai quan sát chính đầu tiên. Các hướng của thành phần trải rộng trên mặt phẳng phù hợp nhất với dữ liệu. Mặt phẳng được định vị để giảm thiểu tổng bình phương khoảng cách đến từng điểm. Bên phải: hai vectơ điểm thành phần chính đầu tiên cung cấp tọa độ của hình chiếu 90° Những quan sát trên mặt phẳng.

hữu ích: các thành phần chính cung cấp các bề mặt tuyến tính có chiều thấp mà là gần nhất với các quan sát. Chúng tôi sẽ mở rộng thêm về cách giải thích đó ở đây.³

Vectơ tải trọng thành phần chính thứ nhất có một đặc tính rất đặc biệt:

Đó là đường thẳng trong không gian p chiều gần nhất với n quan sát.

(sử dụng khoảng cách Euclidean bình phương trung bình làm thước đo độ gần). Điều này Cách giải thích có thể được thấy ở bảng bên trái của Hình 6.15; đường nét đứt Các đường kẻ biểu thị khoảng cách giữa mỗi điểm quan sát và đường kẻ xác định.

bằng vectơ tải thành phần chính thứ nhất. Sức hấp dẫn của cách diễn giải liên ngành này rất rõ ràng: chúng ta tìm kiếm một chiều dữ liệu duy nhất nằm càng gần càng tốt. càng sát với tất cả các điểm dữ liệu càng tốt, vì đường thẳng như vậy có khả năng sẽ cung cấp một Bản tóm tắt tất dữ liệu rất tốt.

Khái niệm về các thành phần chính như là các chiều gần nhất với n quan sát không chỉ giới hạn ở thành phần chính đầu tiên. Ví dụ, hai thành phần chính đầu tiên của một tập dữ liệu.

trải rộng trên mặt phẳng gần nhất với n quan sát, xét về giá trị trung bình.

Khoảng cách Euclid bình phương. Một ví dụ được minh họa ở bảng bên trái.

Hình 12.2. Ba thành phần chính đầu tiên của một tập dữ liệu trải rộng siêu mặt phẳng ba chiều gần nhất với n quan sát, và vân vân.

Dựa trên cách giải thích này, điểm số thành phần chính M đầu tiên được tính tổng hợp các vectơ và M vectơ tải thành phần chính đầu tiên cung cấp phép xấp xỉ M chiều tốt nhất (xét theo khoảng cách Euclidean) cho

³Trong phần này, chúng ta tiếp tục giả định rằng mỗi cột của ma trận dữ liệu X có đã được căn giữa để có giá trị trung bình bằng 0 – nghĩa là, giá trị trung bình của cột đã được trừ đi từ mỗi cột.

510 12. Học không giám sát

quan sát thứ i là x_{ij} . Biểu diễn này có thể được viết như sau:

$$x_{ij} \approx \sum_{m=1}^M z_{im} \phi_{jm}. \tag{12.5}$$

Chúng ta có thể trình bày điều này một cách chính thức hơn bằng cách viết ra một bài toán tối ưu hóa. Giả sử ma trận dữ liệu X được căn giữa theo cột. Trong tất cả các phép xấp xỉ có dạng $x_{ij} \approx a_{im} b_{jm}$, ta có thể yêu cầu phép xấp xỉ có... Tổng bình phương phần dư nhỏ nhất:

$$\underset{A \in \mathbb{R}^{n \times M}, B \in \mathbb{R}^{p \times M}}{\text{giảm thiểu}} \sum_{j=1}^p \sum_{i=1}^n x_{ij}^2 - \sum_{m=1}^M a_{im}^2 b_{jm}^2. \tag{12.6}$$

Ở đây, A là ma trận $n \times M$ có phần tử (i, m) là a_{im} , và B là ma trận $p \times M$. phần tử có phần tử (j, m) là b_{jm} .

Có thể chứng minh rằng với bất kỳ giá trị nào của M , các cột của ma trận A^* và B^* giải (12.6) thực chất là M thành phần chính đầu tiên vectơ điểm và tải. Nói cách khác, nếu A^* và B^* giải (12.6), thì $a_{im}^* = z_{im}$ và $b_{jm}^* = \phi_{jm}$.⁴ Điều này có nghĩa là giá trị nhỏ nhất có thể của Mục tiêu trong (12.6) là

$$\sum_{j=1}^p \sum_{i=1}^n x_{ij}^2 - \sum_{m=1}^M z_{im}^2 \phi_{jm}^2. \tag{12.7}$$

Tóm lại, cùng nhau, các vectơ điểm thành phần chính M và M Các vectơ tải trọng thành phần chính có thể cung cấp một phép xấp xỉ tốt cho dữ liệu khi M đủ lớn. Khi $M = \min(n-1, p)$, thì Biểu diễn chính xác: $x_{ij} = \sum_{m=1}^M z_{im} \phi_{jm}$.

12.2.3 Tỷ lệ phương sai được giải thích

Trong Hình 12.2, chúng tôi đã thực hiện phân tích thành phần chính (PCA) trên tập dữ liệu ba chiều (bảng bên trái) và chiếu dữ liệu lên hai thành phần chính đầu tiên. tải các vectơ để có được cái nhìn hai chiều về dữ liệu (tức là các vectơ điểm thành phần chính; bảng bên phải). Chúng ta thấy rằng điều này Việc biểu diễn dữ liệu ba chiều dưới dạng hai chiều đã thành công trong việc nắm bắt mô hình chính trong dữ liệu: màu cam, xanh lá cây và xanh lam. Các quan sát gần nhau trong không gian ba chiều vẫn giữ nguyên. ở gần đó trong biểu diễn hai chiều. Tương tự, chúng ta đã thấy trên Bộ dữ liệu `USArrests` mà chúng ta có thể tóm tắt gồm 50 quan sát và 4 các biến sử dụng chỉ hai vectơ điểm thành phần chính đầu tiên và Hai vectơ tải thành phần chính đầu tiên.

Giờ đây chúng ta có thể đặt ra một câu hỏi tự nhiên: bao nhiêu thông tin trong Một tập dữ liệu nhất định sẽ bị mất đi nếu chiếu các quan sát lên một vài điểm đầu tiên. các thành phần chính? Nghĩa là, bao nhiêu phần trăm phương sai trong dữ liệu không phải là Chúng có nằm trong một vài thành phần chính đầu tiên không? Nói một cách tổng quát hơn, chúng ta là Tôi quan tâm đến việc biết tỷ lệ phương sai được giải thích (PVE) bởi mỗi yếu tố.

tỷ lệ
phương sai
đã giải thích

⁴Về mặt kỹ thuật, lời giải cho (12.6) không phải là duy nhất. Do đó, chính xác hơn là phát biểu như sau: rằng bất kỳ giải pháp nào cho (12.6) đều có thể dễ dàng được chuyển đổi để tạo ra các thành phần chính.

thành phần chính. Tổng phương sai có trong một tập dữ liệu (giả sử các biến đã được chuẩn hóa để có giá trị trung bình bằng 0) được định nghĩa là

$$\text{Var}(X_j) = \frac{1}{n} \sum_{i=1}^N x_{ij}^2, \quad (12.8)$$

và phương sai được giải thích bởi thành phần chính thứ m là

$$\frac{1}{N} \sum_{i=1}^N z_{\phi i}^2 = \frac{1}{N} \sum_{i=1}^N \sum_{p=1}^P \phi_{pm} x_{ij}^2. \quad (12.9)$$

Do đó, PVE của thành phần chính thứ m được cho bởi

$$\frac{\sum_{i=1}^N z_{\phi i}^2}{\sum_{i=1}^N \sum_{j=1}^P x_{ij}^2} = \frac{\sum_{i=1}^N \sum_{j=1}^P \phi_{jm}^2 x_{ij}^2}{\sum_{i=1}^N \sum_{j=1}^P x_{ij}^2}. \quad (12.10)$$

PVE của mỗi thành phần chính là một đại lượng dương. Để tính PVE tích lũy của M thành phần chính đầu tiên, chúng ta chỉ cần cộng (12.10) trên mỗi M PVE đầu tiên. Tổng cộng có $\min(n-1, p)$ thành phần chính và tổng PVE của chúng bằng một.

Trong Mục 12.2.2, chúng ta đã chỉ ra rằng M thành phần chính đầu tiên, bao gồm cả vectơ tải và vectơ điểm, có thể được hiểu là phép xấp xỉ M chiều tốt nhất cho dữ liệu, xét về tổng bình phương phần dư. Hóa ra, phương sai của dữ liệu có thể được phân tích thành phương sai của M thành phần chính đầu tiên cộng với sai số bình phương trung bình của phép xấp xỉ M chiều này, như sau:


$$\underbrace{\frac{1}{n} \sum_{i=1}^N x_{ij}^2}_{\text{Biến thể dữ liệu}} = \underbrace{\frac{1}{N} \sum_{i=1}^N z_{\phi i}^2}_{\text{Biến thể của } M \text{ PC đầu tiên}} + \underbrace{\frac{1}{n} \sum_{i=1}^N \sum_{j=1}^P x_{ij}^2 - \sum_{m=1}^M z_{\phi m}^2}_{\text{Sai số bình phương trung bình (MSE) của phép xấp xỉ } M \text{ chiều}} \quad (12.11)$$

Ba thuật ngữ trong phép phân tích này được thảo luận trong (12.8), (12.9) và (12.7) tương ứng. Vì thuật ngữ đầu tiên được cố định, chúng ta thấy rằng bằng cách tối đa hóa phương sai của M thành phần chính đầu tiên, chúng ta giảm thiểu sai số bình phương trung bình của phép xấp xỉ M chiều, và ngược lại. Điều này giải thích tại sao các thành phần chính có thể được xem như việc giảm thiểu sai số xấp xỉ (như trong Phần 12.2.2) hoặc tối đa hóa phương sai (như trong Phần 12.2.1).

Hơn nữa, chúng ta có thể sử dụng (12.11) để thấy rằng PVE được định nghĩa trong (12.10) bằng

$$1 - \frac{\sum_{j=1}^P \sum_{i=1}^N x_{ij}^2 - \sum_{m=1}^M z_{\phi m}^2}{\sum_{j=1}^P \sum_{i=1}^N x_{ij}^2} = 1 - \frac{\text{RSS}}{\text{TSS}},$$

trong đó TSS biểu thị tổng bình phương các phần tử của X , và RSS biểu thị tổng bình phương dư của phép xấp xỉ M chiều được đưa ra bởi các thành phần chính. Nhớ lại định nghĩa của R^2 từ (3.17), điều này có nghĩa là chúng ta có thể diễn giải PVE là R^2 của phép xấp xỉ cho X được đưa ra bởi M thành phần chính đầu tiên.



HÌNH 12.3. Bên trái: biểu đồ scree thể hiện tỷ lệ phương sai được giải thích bởi mỗi trong bốn thành phần chính trong dữ liệu `USArrests` . Bên phải: tỷ lệ tích lũy của phương sai được giải thích bởi bốn thành phần chính trong dữ liệu. Dữ liệu từ `USArrests` .

Trong dữ liệu `USArrests` , thành phần chính thứ nhất giải thích 62,0% sự biến thiên trong dữ liệu, và thành phần chính tiếp theo giải thích 24,7% của phương sai. Cả hai thành phần chính đầu tiên cùng nhau giải thích gần như tất cả. 87% phương sai trong dữ liệu và hai thành phần chính cuối cùng. chỉ giải thích được 13% phương sai. Điều này có nghĩa là Hình 12.1 cung cấp một Bản tóm tắt dữ liệu khá chính xác chỉ sử dụng hai chiều. PVE của từng thành phần chính, cũng như PVE tích lũy, được hiển thị. Trong Hình 12.3. Phần bên trái được gọi là biểu đồ scree và sẽ được thảo luận chi tiết hơn ở phần sau của chương này.


biểu đồ màn hình

12.2.4 Thêm thông tin về PCA

Điều chỉnh tỷ lệ các biến số

Chúng ta đã đề cập rằng trước khi thực hiện PCA, các biến số nên được căn giữa để có giá trị trung bình bằng 0. Hơn nữa, các kết quả thu được Thời điểm thực hiện PCA cũng sẽ phụ thuộc vào việc các biến số đã được điều chỉnh tỷ lệ riêng lẻ (mỗi giá trị được nhân với một hằng số khác nhau). Điều này nằm trong Ngược lại với một số kỹ thuật học có giám sát và không giám sát khác, chẳng hạn như hồi quy tuyến tính, trong đó việc điều chỉnh tỷ lệ các biến không có tác dụng. (Trong hồi quy tuyến tính, việc nhân một biến với hệ số c sẽ dẫn đến kết quả sau: nhân ước lượng hệ số tương ứng với hệ số 1/c, và do đó sẽ không có tác động đáng kể nào đến mô hình thu được.)

Ví dụ, Hình 12.1 được thu được sau khi hiệu chỉnh tỷ lệ từng biến số. có độ lệch chuẩn bằng một. Điều này được thể hiện trong biểu đồ bên trái trong Hình 12.4. Tại sao việc chuẩn hóa các biến lại quan trọng? Trong dữ liệu này, Các biến số được đo bằng các đơn vị khác nhau; `Giết người`, `Hiếp dâm` và `Tấn công` là được báo cáo dưới dạng số lần xảy ra trên 100.000 người, và `UrbanPop` là Tỷ lệ phần trăm dân số của tiểu bang sống ở khu vực đô thị. Những điều này Bốn biến có phương sai lần lượt là 18,97, 87,73, 6945,16 và 209,5. Do đó, nếu ta thực hiện PCA trên các biến chưa được hiệu chỉnh, thì



HÌNH 12.4. Hai biểu đồ phân tích thành phần chính cho dữ liệu **USArrests**. Bên trái: Tương tự như Hình 12.1, với các biến được điều chỉnh tỷ lệ để có độ lệch chuẩn bằng đơn vị. Bên phải: các thành phần chính sử dụng dữ liệu chưa được hiệu chỉnh. **Assault** có giá trị lớn nhất. tải trọng trên thành phần chính thứ nhất vì nó có phương sai cao nhất trong số các thành phần đó. bốn biến số. Nói chung, việc chuẩn hóa các biến số để có độ lệch chuẩn bằng một được khuyến nghị.

Vectơ tải trọng thành phần chính đầu tiên sẽ có tải trọng rất lớn.

Đối với biến **Tấn công**, vì biến này có phương sai cao nhất. Biểu đồ bên phải trong Hình 12.4 hiển thị hai thành phần chính đầu tiên cho biến này.

Bộ dữ liệu **USArrests**, không điều chỉnh tỷ lệ các biến để có độ lệch chuẩn bằng một. Như dự đoán, vectơ tải trọng thành phần chính đầu tiên đặt gần như toàn bộ trọng lượng của nó tập trung vào **Tấn công**, trong khi thành phần chính thứ hai là... Vector tải đặt gần như toàn bộ trọng lượng của nó lên **UrbanPop**. So sánh điều này ở biểu đồ bên trái, ta thấy rằng việc điều chỉnh tỷ lệ thực sự có ảnh hưởng đáng kể. ảnh hưởng đến kết quả thu được.

Tuy nhiên, kết quả này chỉ đơn thuần là hệ quả của quy mô mà trên đó...

Các biến số đã được đo lường. Ví dụ, nếu **hành vi tấn công** được đo bằng đơn vị. nếu tính theo số lần xảy ra trên 100 người (thay vì số lần xảy ra trên 100.000 người), thì điều này sẽ tương đương với việc chia tất cả các chia các phần tử của biến đó cho 1.000. Sau đó, phương sai của biến đó được tính. sẽ rất nhỏ, và do đó vectơ tải thành phần chính đầu tiên sẽ có giá trị rất nhỏ đối với biến đó. Bởi vì điều đó không mong muốn đối với Các thành phần chính thu được phụ thuộc vào sự lựa chọn tùy ý về tỷ lệ. Thông thường, chúng ta sẽ chuẩn hóa từng biến để có độ lệch chuẩn bằng một trước khi... Thực hiện PCA.

Tuy nhiên, trong một số trường hợp nhất định, các biến số có thể được đo bằng cùng một phương pháp. đơn vị. Trong trường hợp này, chúng ta có thể không muốn chuẩn hóa các biến để có độ lệch chuẩn bằng một trước khi thực hiện PCA. Ví dụ, giả sử rằng Các biến trong một tập dữ liệu nhất định tương ứng với mức độ biểu hiện của p gen. Vì mức độ biểu hiện được đo bằng cùng một "đơn vị" cho mỗi gen, nên chúng ta... có thể chọn không chuẩn hóa các gen để mỗi gen có độ lệch chuẩn bằng một.

Tính độc nhất của các thành phần chính

Về lý thuyết, các thành phần chính không nhất thiết phải là duy nhất, nhưng trong hầu hết các trường hợp thực tế, chúng đều là duy nhất (ngoại trừ việc đảo dấu). Điều này có nghĩa là hai gói phần mềm khác nhau sẽ tạo ra cùng một vectơ tải thành phần chính, mặc dù dấu của các vectơ tải đó có thể khác nhau. Dấu có thể khác nhau vì mỗi vectơ tải thành phần chính xác định một hướng trong không gian p chiều: việc đảo dấu không có tác dụng vì hướng không thay đổi. (Hãy xem Hình 6.14 – vectơ tải thành phần chính là một đường thẳng kéo dài theo cả hai hướng, và việc đảo dấu của nó sẽ không có tác dụng.) Tương tự, các vectơ điểm số là duy nhất ngoại trừ việc đảo dấu, vì phương sai của Z giống với phương sai của $-Z$. Điều đáng chú ý là khi chúng ta sử dụng (12.5) để xấp xỉ x_{ij} , chúng ta nhân zim với φ_{jm} . Do đó, nếu dấu được đảo trên cả vectơ tải và vectơ điểm số, tích cuối cùng của hai đại lượng này không thay đổi.

Quyết định số lượng thành phần chính cần sử dụng

Nhìn chung, một ma trận dữ liệu X kích thước $n \times p$ có $\min(n-1, p)$ thành phần chính khác nhau. Tuy nhiên, chúng ta thường không quan tâm đến tất cả chúng; thay vào đó, chúng ta chỉ muốn sử dụng một vài thành phần chính đầu tiên để trực quan hóa hoặc diễn giải dữ liệu. Trên thực tế, chúng ta muốn sử dụng số lượng thành phần chính tối thiểu cần thiết để hiểu rõ dữ liệu. Cần bao nhiêu thành phần chính? Thật không may, không có câu trả lời duy nhất (hoặc đơn giản!) cho câu hỏi này.

Thông thường, chúng ta quyết định số lượng thành phần chính cần thiết để trực quan hóa dữ liệu bằng cách xem xét biểu đồ scree, chẳng hạn như biểu đồ được hiển thị ở bảng bên trái của Hình 12.3. Chúng ta chọn số lượng thành phần chính tối thiểu cần thiết để giải thích một lượng đáng kể sự biến thiên trong dữ liệu. Điều này được thực hiện bằng cách quan sát biểu đồ scree và tìm kiếm một điểm mà tại đó tỷ lệ phương sai được giải thích bởi mỗi thành phần chính tiếp theo giảm xuống. Sự giảm này thường được gọi là điểm uốn cong trên biểu đồ scree. Ví dụ, bằng cách quan sát Hình 12.3, người ta có thể kết luận rằng một lượng phương sai đáng kể được giải thích bởi hai thành phần chính đầu tiên, và có một điểm uốn cong sau thành phần thứ hai. Xét cho cùng, thành phần chính thứ ba giải thích chưa đến mười phần trăm phương sai trong dữ liệu, và thành phần chính thứ tư giải thích chưa đến một nửa con số đó và do đó về cơ bản là vô giá trị.

Tuy nhiên, loại phân tích trực quan này vốn dĩ mang tính tùy tiện. Thật không may, không có phương pháp khách quan nào được chấp nhận rộng rãi để quyết định số lượng thành phần chính là đủ. Trên thực tế, câu hỏi về số lượng thành phần chính là đủ vốn dĩ không được định nghĩa rõ ràng, và sẽ phụ thuộc vào lĩnh vực ứng dụng cụ thể và tập dữ liệu cụ thể. Trong thực tế, chúng ta thường xem xét một vài thành phần chính đầu tiên để tìm ra các mẫu thú vị trong dữ liệu. Nếu không tìm thấy mẫu thú vị nào trong vài thành phần chính đầu tiên, thì các thành phần chính tiếp theo khó có thể thú vị. Ngược lại, nếu vài thành phần chính đầu tiên thú vị, thì chúng ta thường tiếp tục xem xét các thành phần chính tiếp theo cho đến khi không tìm thấy thêm mẫu thú vị nào nữa. Điều này rõ ràng là một cách tiếp cận chủ quan.