

Cách tiếp cận này phản ánh thực tế rằng PCA thường được sử dụng như một công cụ để phân tích dữ liệu mang tính khám phá.

Mặt khác, nếu chúng ta tính toán các thành phần chính để sử dụng trong phân tích có giám sát, chẳng hạn như hồi quy thành phần chính được trình bày trong Phần 6.3.1, thì có một cách đơn giản và khách quan để xác định số lượng thành phần chính cần sử dụng: chúng ta có thể coi số lượng vectơ điểm thành phần chính được sử dụng trong hồi quy như một tham số điều chỉnh được lựa chọn thông qua kiểm định chéo hoặc một phương pháp tương tự. Sự đơn giản tương đối trong việc lựa chọn số lượng thành phần chính cho một phân tích có giám sát là một biểu hiện của thực tế rằng các phân tích có giám sát có xu hướng được định nghĩa rõ ràng hơn và được đánh giá khách quan hơn so với các phân tích không giám sát.

12.2.5 Các ứng dụng khác của thành phần chính

Chúng ta đã thấy trong Phần 6.3.1 rằng chúng ta có thể thực hiện hồi quy bằng cách sử dụng các vectơ điểm thành phần chính làm đặc trưng. Trên thực tế, nhiều kỹ thuật thống kê, chẳng hạn như hồi quy, phân loại và phân cụm, có thể dễ dàng được điều chỉnh để sử dụng ma trận $n \times M$ có các cột là M p vectơ điểm thành phần chính đầu tiên, thay vì sử dụng toàn bộ ma trận dữ liệu $n \times p$. Điều này có thể dẫn đến kết quả ít nhiễu hơn, vì thường thì tín hiệu (trái ngược với nhiễu) trong một tập dữ liệu tập trung ở một vài thành phần chính đầu tiên của nó.

12.3 Giá trị thiếu và hoàn thiện ma trận

Thường thì các tập dữ liệu có giá trị bị thiếu, điều này có thể gây khó chịu. Ví dụ, giả sử chúng ta muốn phân tích dữ liệu `USArrests` và phát hiện ra rằng 20 trong số 200 giá trị đã bị lỗi ngẫu nhiên và được đánh dấu là thiếu.

Thật không may, các phương pháp học máy thống kê mà chúng ta đã thấy trong cuốn sách này không thể xử lý các giá trị bị thiếu. Vậy chúng ta nên làm thế nào?

Chúng ta có thể loại bỏ các hàng chứa dữ liệu thiếu và thực hiện phân tích dữ liệu trên các hàng đầy đủ. Nhưng điều này có vẻ lãng phí, và tùy thuộc vào tỷ lệ dữ liệu thiếu, có thể không khả thi. Thay vào đó, nếu xij bị thiếu, thì chúng ta có thể thay thế nó bằng giá trị trung bình của cột thứ j (sử dụng các mục không thiếu để tính giá trị trung bình). Mặc dù đây là một chiến lược phổ biến và tiện lợi, nhưng thường thì chúng ta có thể làm tốt hơn bằng cách khai thác mối tương quan giữa các biến.

Trong phần này, chúng tôi trình bày cách sử dụng các thành phần chính để điền vào các giá trị bị thiếu, thông qua một quy trình được gọi là hoàn thiện ma trận. Ma trận đã hoàn thiện sau đó có thể được sử dụng trong một phương pháp học máy thống kê, chẳng hạn như hồi quy tuyến tính hoặc LDA.

Phương pháp này để điền dữ liệu thiếu là phù hợp nếu việc thiếu dữ liệu là ngẫu nhiên. Ví dụ, nó phù hợp nếu cân nặng của bệnh nhân bị thiếu vì pin của cân điện tử đã hết vào thời điểm khám. Ngược lại, nếu cân nặng bị thiếu vì bệnh nhân quá nặng để leo lên cân, thì đây không phải là sự thiếu dữ liệu ngẫu nhiên; sự thiếu dữ liệu này là do nguyên nhân ngẫu nhiên.

quy kết
sự quy kết
ma trận
hoàn thành

mất tích ngẫu
nhiên

Thông tin hữu ích, và phương pháp được mô tả ở đây để xử lý dữ liệu thiếu không phù hợp.

Đôi khi dữ liệu bị thiếu là điều tất yếu. Ví dụ, nếu ta lập một ma trận các đánh giá (trên thang điểm từ 1 đến 5) mà n khách hàng đã dành cho toàn bộ danh mục phim Netflix gồm p bộ phim, thì phần lớn ma trận sẽ bị thiếu, vì không có khách hàng nào xem và đánh giá nhiều hơn một phần rất nhỏ của danh mục. Nếu ta có thể điền các giá trị bị thiếu một cách chính xác, thì ta sẽ có được ý tưởng về suy nghĩ của mỗi khách hàng đối với những bộ phim mà họ chưa xem. Do đó, việc hoàn thiện ma trận có thể được sử dụng để hỗ trợ các hệ thống đề xuất.

người đề xuất
hệ thống

Phân tích thành phần chính với các giá trị bị thiếu

Trong Mục 12.2.2, chúng tôi đã chỉ ra rằng M vectơ điểm thành phần chính đầu tiên và vectơ tải cung cấp phép xấp xỉ “tốt nhất” cho ma trận dữ liệu X, theo nghĩa của (12.6). Giả sử một số quan sát x_{ij} bị thiếu. Bây giờ chúng tôi sẽ chỉ ra cách có thể vừa điền các giá trị bị thiếu vừa giải quyết bài toán thành phần chính cùng một lúc. Chúng tôi quay lại dạng sửa đổi của bài toán tối ưu hóa (12.6),

giảm thiểu

$$\sum_{(i,j) \in \Omega} \|A_{i,:} - \sum_{m=1}^M a_{im} b_{jm}\|_2^2$$

$$A \in \mathbb{R}^{n \times M}, B \in \mathbb{R}^{p \times M}$$

$$x_{ij}$$

$$\sum_{m=1}^M a_{im} b_{jm}$$

$$,$$

$$(12.12)$$

trong đó Ω là tập hợp tất cả các cặp chỉ số (i, j) đã quan sát được, một tập con của $n \times p$ cặp có thể có.

Khi chúng ta giải quyết được vấn đề này:

- Chúng ta có thể ước tính giá trị quan sát bị thiếu x_{ij} bằng cách sử dụng $\hat{x}_{ij} = \sum_{m=1}^M \hat{a}_{im} \hat{b}_{jm}$, trong đó $\hat{a}_{im}$ và $\hat{b}_{jm}$ lần lượt là các phần tử (i, m) và (j, m) của các ma trận $\hat{A}$ và $\hat{B}$ giải (12.12); và
- Chúng ta có thể (xấp xỉ) khôi phục được điểm số thành phần chính M và hệ số tải, như chúng tôi đã làm khi dữ liệu đầy đủ.

Hóa ra việc giải chính xác (12.12) rất khó, không giống như trường hợp dữ liệu đầy đủ: phép phân tích giá trị riêng không còn áp dụng được nữa. Những phương pháp lặp đơn giản trong Thuật toán 12.1, được trình bày trong Phần 12.5.2, thường cung cấp một giải pháp tốt.56

Chúng tôi minh họa Thuật toán 12.1 trên dữ liệu `USArrests`. Có $p = 4$ biến và $n = 50$ quan sát (tiểu bang). Đầu tiên, chúng tôi chuẩn hóa dữ liệu sao cho mỗi biến có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1. Sau đó, chúng tôi chọn ngẫu nhiên 20 trong số 50 tiểu bang, và đối với mỗi tiểu bang này, chúng tôi ngẫu nhiên đặt một trong bốn biến là dữ liệu thiếu. Như vậy, 10% các phần tử của ma trận dữ liệu bị thiếu. Chúng tôi áp dụng Thuật toán 12.1 với $M = 1$ thành phần chính. Hình 12.5 cho thấy sự phục hồi của các phần tử bị thiếu.

⁵Thuật toán này được gọi là “Hard-Impute” trong Mazumder, Hastie, và Tibshirani (2010) “Các thuật toán điều chỉnh phổ để học các ma trận không đầy đủ lớn”, được xuất bản trong Tạp chí Nghiên cứu Học máy, trang 2287-2322.

⁶Mỗi lần lặp của Bước 2 của thuật toán này sẽ làm giảm mục tiêu (12.14). Tuy nhiên, thuật toán không đảm bảo đạt được tối ưu toàn cục của (12.12).

Thuật toán 12.1 Thuật toán lặp để hoàn thành ma trận

1. Tạo một ma trận dữ liệu đầy đủ X^* có kích thước $n \times p$ trong đó phần tử (i, j) bằng

$$x_{ij}^* = \begin{cases} x_{ij} & \text{nếu } (i, j) \in \Omega \\ 0 & \text{nếu } (i, j) \notin \Omega \end{cases}$$

trong đó x_{ij}^* là giá trị trung bình của các giá trị quan sát được cho biến thứ j trong ma trận dữ liệu không đầy đủ X . Ở đây, Ω là chỉ số của các quan sát được ghi nhận trong X .

2. Lặp lại các bước (a)–(c) cho đến khi mục tiêu (12.14) không giảm:

(a) Giải

$$A_{R \times M, B_{R \times M}} \begin{matrix} \text{giảm thiểu} \\ \sum_{j=1}^M x_{ij}^* - \sum_{m=1}^M a_{im} b_{jm} \end{matrix} \quad (12.13)$$

bằng cách tính các thành phần chính của X^* .

(b) Đối với mỗi phần tử $(i, j) \notin \Omega$, đặt $a_{im}^* = \sum_{m=1}^M x_{ij}^* b_{jm}$.

(c) Tính toán mục tiêu


$$\sum_{(i,j) \notin \Omega} \left(\sum_{m=1}^M x_{ij}^* - \sum_{m=1}^M a_{im}^* b_{jm} \right)^2 \quad (12.14)$$

3. Trả về các mục bị thiếu ước tính x_{ij}^* , $(i, j) \notin \Omega$.

Phương pháp này khá chính xác. Sau hơn 100 lần chạy ngẫu nhiên thí nghiệm này, hệ số tương quan trung bình giữa giá trị thực và giá trị được ước tính của các phần tử bị thiếu là 0,63, với độ lệch chuẩn là 0,11. Liệu đây có phải là hiệu suất tốt? Để trả lời câu hỏi này, chúng ta có thể so sánh hệ số tương quan này với kết quả mà chúng ta sẽ nhận được nếu ước tính 20 giá trị này bằng cách sử dụng toàn bộ dữ liệu – tức là, nếu chúng ta chỉ đơn giản tính $x_{ij}^* = z_{i1} \phi_{j1}$, trong đó z_{i1} và ϕ_{j1} là các phần tử của điểm số thành phần chính đầu tiên và vectơ tải của toàn bộ dữ liệu. Việc sử dụng toàn bộ dữ liệu theo cách này dẫn đến hệ số tương quan trung bình là 0,79 giữa giá trị thực và giá trị ước tính cho 20 phần tử này, với độ lệch chuẩn là 0,08. Do đó, phương pháp ước tính của chúng ta hoạt động kém hơn phương pháp sử dụng toàn bộ dữ liệu ($0,63 \pm 0,11$ so với $0,79 \pm 0,08$), nhưng hiệu suất của nó vẫn khá tốt. (Và dĩ nhiên, phương pháp sử dụng toàn bộ dữ liệu không thể áp dụng trong thực tế khi có dữ liệu bị thiếu.)

Hình 12.6 cho thấy thêm rằng Thuật toán 12.1 hoạt động khá tốt trên tập dữ liệu này.


Đây là một tiêu chuẩn vàng không thể đạt được, theo nghĩa là với dữ liệu bị thiếu, chúng ta không thể tính toán các thành phần chính của toàn bộ dữ liệu.



- Dữ liệu **USArrests** chỉ có bốn biến, con số này khá thấp để các phương pháp như Thuật toán 12.1 hoạt động hiệu quả. Vì lý do này, trong ví dụ minh họa này, chúng tôi đã ngẫu nhiên thiết lập tối đa một biến bị thiếu trên mỗi tiểu bang và chỉ sử dụng $M = 1$ thành phần chính.

Hệ thống đề xuất Các dịch vụ

phát trực tuyến kỹ thuật số như Netflix và Amazon sử dụng dữ liệu về nội dung mà khách hàng đã xem trong quá khứ, cũng như dữ liệu từ các khách hàng khác, để đề xuất các nội dung khác cho khách hàng. Ví dụ cụ thể, vài năm trước, Netflix đã yêu cầu khách hàng đánh giá mỗi bộ phim họ đã xem với điểm số từ 1 đến 5. Điều này dẫn đến một ma trận $n \times p$ rất lớn, trong đó phần tử (i, j) là điểm số mà khách hàng thứ i đưa ra cho bộ phim đó.



HÌNH 12.6. Như đã mô tả trong văn bản, trong mỗi 100 lần thử nghiệm, chúng tôi đã bỏ qua 20 các phần tử của tập dữ liệu `USArrests`. Trong mỗi lần thử, chúng tôi đã áp dụng Thuật toán 12.1 với $M = 1$ để điền các phần tử bị thiếu và tính toán các thành phần chính. Bên trái: Điểm thành phần chính đầu tiên được ước tính cho mỗi trong số 50 tiểu bang. (được tính trung bình trên 100 lần thử nghiệm và được hiển thị kèm theo thanh độ lệch chuẩn) được vẽ biểu đồ so với điểm số thành phần chính đầu tiên được tính toán bằng cách sử dụng tất cả dữ liệu. Bên phải: Các hệ số tải thành phần chính được ước tính (trung bình trên 100 lần thử nghiệm và được hiển thị) (với thanh biểu thị độ lệch chuẩn) được vẽ biểu đồ so với thành phần chính thực sự tải trọng.

bộ phim thứ j . Một ví dụ cụ thể ban đầu về ma trận này có $n = 480.189$ khách hàng và $p = 17.770$ bộ phim. Tuy nhiên, trung bình mỗi khách hàng đã xem Khoảng 200 bộ phim, vậy nên 99% ma trận có các phần tử bị thiếu. Bảng 12.2 Hình ảnh minh họa cách bố trí.

Để gợi ý một bộ phim mà một khách hàng cụ thể có thể thích, Netflix sử dụng... Cần tìm cách điền vào các giá trị bị thiếu trong ma trận dữ liệu này. Ý tưởng chính là... Cụ thể như sau: tập hợp các bộ phim mà khách hàng thứ i đã xem sẽ trùng lặp với những gì mà các khách hàng khác đã thấy. Hơn nữa, một số trong số đó Các khách hàng khác sẽ có sở thích xem phim tương tự như khách hàng thứ i . Do đó, có thể sử dụng xếp hạng phim tương tự của những khách hàng có cùng quan điểm. Khách hàng thứ i chưa từng thấy để dự đoán liệu khách hàng thứ i có thích hay không. Những bộ phim đó.

Cụ thể hơn, bằng cách áp dụng Thuật toán 12.1, chúng ta có thể dự đoán khách hàng thứ i - Đánh giá của tomer cho bộ phim thứ j sử dụng $x_{ij} = \sum_{m=1}^M a_{im}^* b_{jm}$. Hơn nữa, ta có thể diễn giải các thành phần M theo thuật ngữ "nhóm" và "thể loại":

- a_{im} thể hiện mức độ gắn bó của người dùng thứ i với nhóm m th clique, trong đó clique là một nhóm khách hàng thích xem phim. thuộc thể loại thứ m ;
- b_{jm} biểu thị mức độ gắn bó của bộ phim thứ j với bộ phim kia. Thể loại m th.

Một số thể loại tiêu biểu bao gồm lãng mạn, miền Tây hoang dã và hành động. Các mô hình thành phần chính tương tự như Thuật toán 12.1 là cốt lõi của nhiều hệ thống đề xuất. Mặc dù các ma trận dữ liệu liên quan là

BẢNG 12.2. Trích đoạn dữ liệu xếp hạng phim của Netflix. Các bộ phim được xếp hạng Từ 1 (tệ nhất) đến 5 (tốt nhất). Ký hiệu $\cdot$ biểu thị giá trị bị thiếu: một bộ phim mà... Khách hàng tương ứng không đánh giá sản phẩm này.

12.4 Phương pháp phân cụm

tìm cách phân chia chúng thành các nhóm riêng biệt sao cho các quan sát bên trong
Mỗi nhóm đều khá giống nhau, trong khi các quan sát ở những nhóm khác nhau lại khác biệt.
Các nhóm khá khác biệt nhau. Tất nhiên, để làm rõ điều này,
Chúng ta cần định nghĩa thế nào là hai hoặc nhiều quan sát được coi là tương tự nhau.

Việc đưa ra quyết định phải dựa trên kiến thức về dữ liệu đang được nghiên cứu.

Ví dụ, giả sử chúng ta có một tập hợp gồm n quan sát, mỗi quan sát có p phần tử.

các đặc điểm. n quan sát có thể tương ứng với các mẫu mô của bệnh nhân.

với bệnh ung thư vú, và các đặc điểm p có thể tương ứng với các phép đo

được thu thập cho mỗi mẫu mô; đây có thể là các phép đo lâm sàng, chẳng hạn như

Chúng có thể là giai đoạn hoặc cấp độ khối u, hoặc cũng có thể là các phép đo biểu hiện gen.

Chúng ta có thể có lý do để tin rằng có sự khác biệt nhất định giữa các yếu tố này.

n mẫu mô; ví dụ, có thể có một vài phân nhóm ung thư vú chưa được biết đến khác nhau. Phân cụm có thể được sử dụng để tìm ra những phân nhóm này.

các nhóm con. Đây là một bài toán không giám sát vì chúng ta đang cố gắng khám phá cấu trúc—trong trường hợp này, các cụm riêng biệt—dựa trên một tập dữ liệu.

Mặt khác, mục tiêu trong các bài toán học có giám sát là cố gắng dự đoán

một số vectơ kết quả như thời gian sống sót hoặc phản ứng với điều trị bằng thuốc.

Cả phân cụm và PCA đều nhằm mục đích đơn giản hóa dữ liệu thông qua một số lượng nhỏ các biến.

Cả hai đều là bản tóm tắt, nhưng cơ chế hoạt động của chúng khác nhau:

- PCA tìm cách biểu diễn dữ liệu quan sát ở dạng có chiều thấp, giải thích được một phần lớn phương sai;
- Phân cụm nhằm mục đích tìm ra các nhóm con đồng nhất trong số các quan sát.

các điều khoản.

Một ứng dụng khác của phân cụm xuất hiện trong lĩnh vực tiếp thị. Chúng ta có thể tiếp cận được một lượng lớn các số liệu đo lường (ví dụ: thu nhập hộ gia đình trung bình, nghề nghiệp, khoảng cách từ khu vực đô thị gần nhất, v.v.) đối với một khu vực lớn. số lượng người. Mục tiêu của chúng tôi là thực hiện phân khúc thị trường bằng cách xác định các nhóm nhỏ người có thể dễ tiếp nhận một hình thức cụ thể hơn. của quảng cáo, hoặc khả năng mua một sản phẩm cụ thể cao hơn. Nhiệm vụ của Phân khúc thị trường thực chất là việc nhóm người dùng lại với nhau thành các cụm. tập dữ liệu.

Vì phân cụm phổ biến trong nhiều lĩnh vực, nên tồn tại rất nhiều phương pháp phân cụm. Trong phần này, chúng ta tập trung vào hai phương pháp có lẽ phổ biến nhất. Các phương pháp phân cụm nổi tiếng nhất: phân cụm K-means và phân cụm phân cấp. Trong phân cụm K-means, chúng ta tìm cách phân chia các quan sát. thành một số cụm được xác định trước. Mặt khác, trong cấu trúc phân cấp Trong phân cụm, chúng ta không biết trước mình muốn có bao nhiêu cụm; trên thực tế, Cuối cùng, chúng ta có được một biểu diễn trực quan dạng cây thể hiện các quan sát, được gọi là Biểu đồ cây (dendrogram) cho phép chúng ta xem ngay các nhóm kết quả thu được cho mỗi số lượng nhóm có thể có, từ 1 đến n. Có những ưu điểm và nhược điểm. những nhược điểm của mỗi phương pháp phân cụm này, mà chúng tôi sẽ nêu bật trong phần tiếp theo. chương này.

Nhìn chung, chúng ta có thể phân nhóm các quan sát dựa trên các đặc điểm trong để xác định các nhóm con trong số các quan sát, hoặc chúng ta có thể phân cụm các đặc điểm dựa trên các quan sát để khám phá các nhóm con trong số đó. các đặc điểm. Trong phần tiếp theo, để đơn giản, chúng ta sẽ thảo luận về việc phân cụm các quan sát dựa trên các đặc điểm, mặc dù điều ngược lại cũng có thể được thực hiện. bằng cách đơn giản là chuyển vị ma trận dữ liệu.

K-means
phân cụm
phân cấp
phân cụm


biểu đồ cây

12.4.1 Phân cụm K-Means

Phân cụm K-means là một phương pháp đơn giản và hiệu quả để phân vùng. Chia tập dữ liệu thành K cụm riêng biệt, không chồng chéo. Để thực hiện thuật toán K-means... Để phân cụm, trước tiên chúng ta phải xác định số lượng cụm mong muốn K; sau đó... Thuật toán K-means sẽ gán mỗi quan sát cho chính xác một trong K phần tử. các cụm. Hình 12.7 hiển thị kết quả thu được từ việc thực hiện thuật toán K-means. phân cụm trên một ví dụ mô phỏng gồm 150 quan sát trong hai kích thước, sử dụng ba giá trị K khác nhau.

Thuật toán phân cụm K-means xuất phát từ một phương pháp đơn giản và trực quan. Bài toán toán học. Chúng ta bắt đầu bằng cách định nghĩa một số ký hiệu. Cho $C_1, \dots, C_K$ ký hiệu các tập hợp chứa chỉ số của các quan sát trong mỗi cụm. Những tập hợp này Các tập hợp thỏa mãn hai tính chất:

1. $C_1 \cap C_2 \cap \dots \cap C_K = \{1, \dots, n\}$. Nói cách khác, mỗi quan sát thuộc ít nhất một trong các cụm K.
2. $C_k \cap C_l = \emptyset$ với mọi $k \neq l$. Nói cách khác, các cụm không chồng chéo: không có quan sát nào thuộc về nhiều hơn một cụm.



HÌNH 12.7. Một tập dữ liệu mô phỏng với 150 quan sát trong không gian hai chiều. Không gian. Các bảng hiển thị kết quả áp dụng thuật toán phân cụm K-means với các giá trị K khác nhau, tức là số lượng cụm. Màu sắc của mỗi quan sát cho biết cụm mà nó được gán bằng thuật toán phân cụm K-means. Lưu ý rằng không có thứ tự nào giữa các cụm, do đó việc tô màu cụm là tùy ý. Các nhãn cụm này không được sử dụng trong quá trình phân cụm; thay vào đó, chúng là kết quả đầu ra của quy trình phân cụm.

Ví dụ, nếu quan sát thứ i nằm trong cụm thứ k , thì $i \in C_k$. Ý tưởng đằng sau thuật toán phân cụm K-means là một phân cụm tốt là một phân cụm mà sự biến thiên trong cụm càng nhỏ càng tốt. Sự biến thiên trong cụm đối với cụm C_k là một thước đo $W(C_k)$ về mức độ khác biệt giữa các quan sát trong một cụm. Do đó, chúng ta muốn giải quyết vấn đề này.

$$\underset{C_1, \dots, C_K}{\text{giảm thiểu}} \quad W(C_k) = \sum_{i \in C_k} \|x_i - \mu_k\|^2 \quad (12.15)$$

Nói cách khác, công thức này cho biết chúng ta muốn phân chia các quan sát thành K cụm sao cho tổng biến thiên trong mỗi cụm, tính tổng trên tất cả K cụm, là nhỏ nhất có thể.

Giải (12.15) có vẻ là một ý tưởng hợp lý, nhưng để thực hiện được, chúng ta cần xác định sự biến đổi trong cụm. Có nhiều cách khả thi để định nghĩa khái niệm này, nhưng lựa chọn phổ biến nhất liên quan đến khoảng cách Euclidean bình phương. Tức là, chúng ta định nghĩa

$$W(C_k) = \frac{1}{|C_k|} \sum_{i,j \in C_k} \|x_i - x_j\|^2 \quad (12.16)$$

trong đó $|C_k|$ biểu thị số lượng quan sát trong cụm thứ k . Nói cách khác, sự biến thiên trong cụm thứ k là tổng của tất cả các khoảng cách Euclidean bình phương từng cặp giữa các quan sát trong cụm thứ k , chia cho tổng số lượng quan sát trong cụm thứ k .

Kết hợp (12.15) và (12.16) ta có bài toán tối ưu xác định

Phân cụm K-means,

giảm thiểu

$C_1, \dots, C_K$

$$\sum_{k=1}^K \frac{1}{|C_k|} \sum_{i \in C_k} \sum_{j=1}^P (x_{ij} - x_{kj}^*)^2 \quad (12.17)$$

Bây giờ, chúng ta muốn tìm một thuật toán để giải (12.17) – tức là một phương pháp phân chia các quan sát thành K cụm sao cho mục tiêu của (12.17) được tối thiểu hóa. Trên thực tế, đây là một vấn đề rất khó giải quyết chính xác, vì có gần K^n cách để phân chia n quan sát thành K cụm. Đây là một con số khổng lồ trừ khi K và n rất nhỏ! May mắn thay, một thuật toán rất đơn giản có thể được chứng minh là cung cấp một điểm tối ưu cục bộ – một giải pháp khá tốt – cho bài toán tối ưu hóa K-means (12.17). Cách tiếp cận này được trình bày trong Thuật toán 12.2.

Thuật toán 12.2 Phân cụm K-Means

1. Gán ngẫu nhiên một số từ 1 đến K cho mỗi quan sát.
Chúng đóng vai trò là các phân nhóm ban đầu cho các quan sát.
2. Lặp lại cho đến khi việc phân bổ cụm không còn thay đổi nữa:

(a) Đối với mỗi trong số K cụm, hãy tính tâm cụm. Tâm cụm thứ k là vectơ gồm p giá trị trung bình của các đặc trưng cho các quan sát trong cụm thứ k.


(b) Gán mỗi quan sát vào cụm có tâm cụm gần nhất (trong đó "gần nhất" được định nghĩa bằng khoảng cách Euclidean).

Thuật toán 12.2 được đảm bảo sẽ làm giảm giá trị của mục tiêu (12.17) ở mỗi bước. Để hiểu lý do tại sao, đẳng thức sau đây sẽ giúp làm sáng tỏ:

$$\frac{1}{|C_k|} \sum_{i \in C_k} \sum_{j=1}^P (x_{ij} - x_{kj}^*)^2 = \sum_{i \in C_k} \sum_{j=1}^P (x_{ij} - \bar{x}_{kj})^2 + \sum_{i \in C_k} \sum_{j=1}^P (x_{ij} - \bar{x}_{kj})^2$$

$$(12.18)$$

trong đó $\bar{x}_{kj} = \frac{1}{|C_k|} \sum_{i \in C_k} x_{ij}$ là giá trị trung bình của đặc trưng j trong cụm C_k . Trong Bước 2(a), giá trị trung bình của cụm cho mỗi đặc trưng là các hằng số làm giảm thiểu tổng bình phương độ lệch, và trong Bước 2(b), việc phân bổ lại các quan sát chỉ có thể cải thiện (12.18). Điều này có nghĩa là khi thuật toán được chạy, việc phân cụm thu được sẽ liên tục được cải thiện cho đến khi kết quả không còn thay đổi; mục tiêu của (12.17) sẽ không bao giờ tăng lên. Khi kết quả không còn thay đổi, một điểm tối ưu cục bộ đã đạt được. Hình 12.8 cho thấy sự tiến triển của thuật toán trên ví dụ minh họa từ Hình 12.7. Thuật toán phân cụm K-means lấy tên từ thực tế là ở Bước 2(a), tâm của các cụm được tính bằng giá trị trung bình của các quan sát được gán cho mỗi cụm. Vì thuật toán K-means tìm kiếm điểm tối ưu cục bộ chứ không phải toàn cục, nên kết quả thu được sẽ phụ thuộc vào việc gán cụm ban đầu (ngẫu nhiên) cho mỗi quan sát trong Bước 1 của Thuật toán 12.2. Vì lý do này, điều quan trọng là phải chạy thuật toán nhiều lần từ các điểm gán ngẫu nhiên khác nhau.



HÌNH 12.8. Sự tiến triển của thuật toán K-means trên ví dụ về Hình 12.7 với $K=3$. Góc trên bên trái: các quan sát được hiển thị. Góc trên ở giữa: trong Bước 1 của thuật toán, mỗi quan sát được gán ngẫu nhiên vào một cụm. Bên phải: ở Bước 2(a), tâm của các cụm được tính toán. Chúng được hiển thị dưới dạng hình lớn các đĩa màu. Ban đầu, tâm của chúng gần như trùng nhau hoàn toàn vì Việc phân bổ cụm ban đầu được chọn ngẫu nhiên. Góc dưới bên trái: trong Bước 2(b), mỗi quan sát được gán cho tâm trọng lực gần nhất. Tâm dưới: Bước 2(a) là Thực hiện lại một lần nữa, dẫn đến việc xác định các tâm cụm mới. Góc dưới bên phải: kết quả Kết quả thu được sau mười lần lặp.

cấu hình ban đầu. Sau đó, người ta chọn giải pháp tốt nhất, tức là giải pháp mà... Mục tiêu (12.17) là nhỏ nhất. Hình 12.9 hiển thị các điểm tối ưu cục bộ thu được bằng cách chạy thuật toán phân cụm K-means sáu lần bằng cách sử dụng sáu giá trị ban đầu khác nhau. Phân bổ cụm, sử dụng dữ liệu mẫu từ Hình 12.7. Trong trường hợp này, Phương pháp phân cụm tốt nhất là phương pháp có giá trị mục tiêu là 235,8. Như chúng ta đã thấy, để thực hiện phân cụm K-means, chúng ta phải quyết định cách thức... Chúng ta kỳ vọng sẽ có nhiều cụm trong dữ liệu. Vấn đề lựa chọn K còn xa mới là vấn đề chính. Đơn giản. Vấn đề này, cùng với những cân nhắc thực tế khác phát sinh trong Việc thực hiện phân cụm K-means được đề cập trong Mục 12.4.3.




HÌNH 12.9. Thuật toán phân cụm K-means được thực hiện sáu lần trên dữ liệu từ Hình 12.7 với $K = 3$, mỗi lần với một sự phân bố ngẫu nhiên khác nhau của các quan sát trong Bước 1 của thuật toán K-means. Phía trên mỗi biểu đồ là giá trị của mục tiêu (12.17). Ba điểm tối ưu cục bộ khác nhau đã được thu được, một trong số đó Kết quả là giá trị mục tiêu nhỏ hơn và mang lại sự phân tách tốt hơn giữa các yếu tố các cụm. Những cụm được đánh dấu màu đỏ đều đạt được giải pháp tốt nhất giống nhau, với một Giá trị mục tiêu là 235,8.

12.4.2 Phân cụm phân cấp

Một nhược điểm tiềm tàng của thuật toán phân cụm K-means là nó đòi hỏi chúng ta phải Xác định trước số lượng cụm K . Phân cụm phân cấp là một phương pháp thay thế không yêu cầu chúng ta phải cam kết với một số lượng cụm cụ thể. Lựa chọn K . Phân cụm phân cấp có ưu điểm vượt trội so với K-means. phân cụm vì nó tạo ra một biểu đồ dạng cây hấp dẫn của Các quan sát, được gọi là biểu đồ cây (dendrogram).

Trong phần này, chúng tôi mô tả phương pháp phân cụm từ dưới lên hoặc phân cụm kết hợp . Đây là loại phân cụm phân cấp phổ biến nhất, và đề cập đến thực tế là biểu đồ cây (thường được mô tả như một cây lộn ngược; xem Hình 12.11) được xây dựng bắt đầu từ lá và kết hợp các cụm lại với nhau cho đến thân cây. Chúng ta sẽ bắt đầu bằng việc thảo luận về cách diễn giải biểu đồ cây.

từ dưới lên
kết tụ



HÌNH 12.10. Bốn mươi lăm quan sát được tạo ra trong không gian hai chiều. Trên thực tế có ba lớp khác nhau, được thể hiện bằng các màu sắc riêng biệt. Tuy nhiên, chúng ta sẽ coi các nhãn lớp này là không xác định và sẽ tìm cách phân cụm các quan sát nhằm mục đích xác định các lớp từ dữ liệu.


và sau đó thảo luận về cách thức thực hiện phân cụm phân cấp trên thực tế – tức là, Cách thức xây dựng biểu đồ cây.

Giải thích biểu đồ cây (Dendrogram)

Chúng ta bắt đầu với tập dữ liệu mô phỏng được hiển thị trong Hình 12.10, bao gồm: 45 quan sát trong không gian hai chiều. Dữ liệu được tạo ra từ một mô hình ba lớp; nhãn lớp thực cho mỗi quan sát được hiển thị trong màu sắc khác biệt. Tuy nhiên, giả sử dữ liệu được quan sát mà không có nhãn lớp, và chúng tôi muốn thực hiện phân cụm phân cấp của dữ liệu. Phân cụm phân cấp (với liên kết hoàn chỉnh, sẽ được thảo luận sau) cho ra kết quả được hiển thị ở bảng bên trái của Hình 12.11. Làm thế nào chúng ta có thể Hãy giải thích biểu đồ cây này?

Trong bảng bên trái của Hình 12.11, mỗi nhánh của biểu đồ cây đại diện cho một trong 45 quan sát trong Hình 12.10. Tuy nhiên, khi chúng ta di chuyển Trên ngọn cây, một số lá bắt đầu hợp nhất thành cành. Những cành này tương ứng với... Những quan sát tương tự nhau. Khi chúng ta di chuyển lên cao hơn trên cây, Các cành cây tự hợp nhất, hoặc với lá hoặc với các cành khác. Điều này xảy ra sớm hơn. (ở phần dưới của cây) sự hợp nhất xảy ra khi các nhóm quan sát càng giống nhau. Mặt khác, các quan sát hợp nhất muộn hơn (gần ngọn cây) có thể khá khác biệt. Trên thực tế, câu nói này có thể được làm cho chính xác hơn: với bất kỳ hai quan sát nào, ta có thể tìm điểm đó trong Cây mà tại đó các nhánh chứa hai quan sát đó được hợp nhất lần đầu tiên. Chiều cao của sự hợp nhất này, được đo trên trục dọc, cho biết như thế nào Hai quan sát này khác nhau. Do đó, các quan sát hợp nhất ở mức độ rất nhỏ. Phần dưới của cây khá giống nhau, trong khi các quan sát Các nhánh gần ngọn cây sẽ có xu hướng khác biệt đáng kể.

Điều này làm nổi bật một điểm rất quan trọng trong việc giải thích biểu đồ cây phân nhánh, đó là: thường bị hiểu sai. Hãy xem xét bảng bên trái của Hình 12.12, bảng đó Hình ảnh này thể hiện một biểu đồ cây đơn giản thu được từ việc phân cụm theo thứ bậc chín.



HÌNH 12.11. Bên trái: biểu đồ cây thu được từ việc phân cụm theo thứ bậc.

Dữ liệu từ Hình 12.10 với liên kết hoàn chỉnh và khoảng cách Euclidean. Trung tâm:

Biểu đồ cây từ bảng bên trái, được cắt ở độ cao chín (được biểu thị bằng dấu chấm).

(đường nét đứt). Đường cắt này tạo ra hai cụm riêng biệt, được hiển thị bằng các màu khác nhau.

Bên phải: biểu đồ cây từ bảng bên trái, giờ đã được cắt ở độ cao năm. Điều này

Kết quả cắt tạo ra ba cụm riêng biệt, được hiển thị bằng các màu khác nhau. Lưu ý rằng màu sắc

Các biến này không được sử dụng trong phân cụm, mà chỉ được sử dụng cho mục đích hiển thị trong hình này.

quan sát. Có thể thấy rằng quan sát 5 và 7 khá giống nhau.

Chúng hợp nhất ở điểm thấp nhất trên biểu đồ cây. Quan sát 1 và 6 cũng khá giống nhau. Tuy nhiên, thật hấp dẫn khi...

nhưng không đúng khi kết luận từ hình vẽ rằng quan sát 9 và 2 là khá giống nhau vì chúng đều nằm gần nhau.

khác trên biểu đồ cây. Trên thực tế, dựa trên thông tin có trong

Trong biểu đồ cây, quan sát số 9 không giống với quan sát số 2 hơn là...

Điều này tương ứng với các quan sát 8, 5 và 7. (Có thể thấy điều này ở bảng bên phải) (như trong Hình 12.12, hiển thị dữ liệu thô.) Nói một cách toán học, có $2n - 1$ cách sắp xếp lại cây phân nhánh, trong đó n

là số lượng lá. Điều này là do tại mỗi điểm $n - 1$, nơi mà

Trong trường hợp hợp nhất, vị trí của hai nhánh hợp nhất có thể được hoán đổi cho nhau.

mà không ảnh hưởng đến ý nghĩa của biểu đồ cây. Do đó, chúng ta không thể

Rút ra kết luận về sự tương đồng giữa hai quan sát dựa trên các đặc điểm của chúng.

khoảng cách dọc theo trục ngang. Thay vào đó, chúng ta rút ra kết luận về

Sự tương đồng giữa hai quan sát dựa trên vị trí trên trục dọc.

nơi các nhánh chứa hai quan sát đó được hợp nhất đầu tiên.

Giờ đây, khi đã hiểu cách diễn giải bảng bên trái của Hình 12.11, chúng ta có thể chuyển sang vấn đề xác định các cụm dựa trên cơ sở đó.

của một biểu đồ cây. Để làm điều này, chúng ta thực hiện một đường cắt ngang qua...

Biểu đồ cây phân nhánh, như được hiển thị ở phần giữa và bên phải của Hình 12.11.

Các tập hợp quan sát riêng biệt bên dưới đường cắt có thể được hiểu là các cụm.


Trong bảng giữa của Hình 12.11, cắt biểu đồ cây ở một độ cao

Chín kết quả được chia thành hai nhóm, hiển thị bằng các màu khác nhau. Ở bên phải

Trên bảng điều khiển, việc cắt biểu đồ cây ở độ cao năm sẽ tạo ra ba cụm.

Có thể thực hiện thêm các thao tác cắt khi đi xuống biểu đồ cây để thu được bất

kỳ số lượng cụm nào, từ 1 (tương ứng với không có thao tác cắt) đến n .



HÌNH 12.12. Minh họa cách diễn giải chính xác biểu đồ cây với chín quan sát trong không gian hai chiều. Bên trái: biểu đồ cây được tạo bằng khoảng cách Euclidean và liên kết hoàn chỉnh. Quan sát 5 và 7 khá giống nhau, cũng như quan sát 1 và 6. Tuy nhiên, quan sát 9 không giống quan sát 2 hơn so với các quan sát 8, 5 và 7, mặc dù quan sát 9 và 2 nằm gần nhau về khoảng cách ngang. Điều này là do các quan sát 2, 8, 5 và 7 đều hợp nhất với quan sát 9 ở cùng một độ cao, xấp xỉ 1,8. Bên phải: dữ liệu thô được sử dụng để tạo biểu đồ cây có thể được sử dụng để xác nhận rằng, quả thực, quan sát 9 không giống quan sát 2 hơn so với các quan sát 8, 5 và 7.

(tương ứng với một đường cắt ở độ cao 0, sao cho mỗi quan sát nằm trong một cụm riêng biệt). Nói cách khác, độ cao của đường cắt trên biểu đồ cây đóng vai trò tương tự như K trong thuật toán phân cụm K -means: nó kiểm soát số lượng cụm thu được.

Hình 12.11 do đó làm nổi bật một khía cạnh rất hấp dẫn của phân cụm phân cấp: một biểu đồ cây duy nhất có thể được sử dụng để thu được bất kỳ số lượng cụm nào. Trên thực tế, người ta thường nhìn vào biểu đồ cây và chọn bằng mắt một số lượng cụm hợp lý, dựa trên chiều cao của sự hợp nhất và số lượng cụm mong muốn. Trong trường hợp của Hình 12.11, người ta có thể chọn hai hoặc ba cụm. Tuy nhiên, thường thì việc lựa chọn điểm cắt biểu đồ cây không rõ ràng.

Thuật ngữ "phân cấp" đề cập đến thực tế là các cụm thu được bằng cách cắt biểu đồ cây ở một độ cao nhất định nhất thiết phải lồng nhau trong các cụm thu được bằng cách cắt biểu đồ cây ở bất kỳ độ cao nào lớn hơn. Tuy nhiên, trên một tập dữ liệu bất kỳ, giả định về cấu trúc phân cấp này có thể không thực tế. Ví dụ, giả sử các quan sát của chúng ta tương ứng với một nhóm nam và nữ, được chia đều giữa người Mỹ, người Nhật và người Pháp. Chúng ta có thể tưởng tượng một kịch bản trong đó sự phân chia tốt nhất thành hai nhóm có thể chia những người này theo giới tính, và sự phân chia tốt nhất thành ba nhóm có thể chia họ theo quốc tịch. Trong trường hợp này, các cụm thực sự không lồng nhau, theo nghĩa là sự phân chia tốt nhất thành ba nhóm không phải là kết quả của việc lấy sự phân chia tốt nhất thành hai nhóm và chia nhỏ một trong những nhóm đó. Do đó, tình huống này không thể được thể hiện tốt bằng phân cụm phân cấp. Do những tình huống như vậy, phân cụm phân cấp đôi khi có thể cho kết quả kém hơn (tức là kém chính xác hơn) so với phân cụm K -means với cùng một số lượng cụm.

Thuật toán 12.3 Phân cụm phân cấp

- 1. Bắt đầu với n quan sát và một thước đo (chẳng hạn như khoảng cách Euclidean) của tất cả các độ khác biệt từng cặp $d_{ij} = n(n-1)/2$. Coi mỗi quan sát như một cụm riêng biệt.
- 2. Với $i = n, n-1, \dots, 2$:
 - (a) Kiểm tra tất cả các điểm khác biệt giữa các cụm theo từng cặp trong số i cụm và xác định cặp cụm ít khác biệt nhất (tức là giống nhau nhất). Hợp nhất hai cụm này. Độ khác biệt giữa hai cụm này cho biết vị trí đặt điểm hợp nhất trên biểu đồ cây.
 - (b) Tính toán độ khác biệt giữa các cụm theo từng cặp trong số $i-1$ cụm còn lại.

Thuật toán phân cụm phân cấp

Biểu đồ phân cụm phân cấp được tạo ra thông qua một thuật toán cực kỳ đơn giản. Chúng ta bắt đầu bằng cách định nghĩa một số thước đo độ khác biệt giữa mỗi cặp quan sát. Thông thường, khoảng cách Euclidean được sử dụng; chúng ta sẽ thảo luận về việc lựa chọn thước đo độ khác biệt này sau trong chương này. Thuật toán tiến hành lặp đi lặp lại. Bắt đầu từ dưới cùng của biểu đồ phân cụm, mỗi trong số n quan sát được coi là một cụm riêng biệt. Hai cụm giống nhau nhất sau đó được hợp nhất để tạo ra $n-1$ cụm. Tiếp theo, hai cụm giống nhau nhất lại được hợp nhất một lần nữa, để tạo ra $n-2$ cụm. Thuật toán tiếp tục theo cách này cho đến khi tất cả các quan sát thuộc về một cụm duy nhất và biểu đồ phân cụm hoàn chỉnh. Hình 12.13 mô tả một vài bước đầu tiên của thuật toán, với dữ liệu từ Hình 12.12. Tóm lại, thuật toán phân cụm phân cấp được trình bày trong Thuật toán 12.3.

Thuật toán này có vẻ khá đơn giản, nhưng một vấn đề chưa được giải quyết. Hãy xem bảng phía dưới bên phải trong Hình 12.13. Làm thế nào chúng ta xác định rằng cụm $\{5, 7\}$ nên được hợp nhất với cụm $\{8\}$? Chúng ta có khái niệm về sự khác biệt giữa các cặp quan sát, nhưng làm thế nào để định nghĩa sự khác biệt giữa hai cụm nếu một hoặc cả hai cụm chứa nhiều quan sát? Khái niệm về sự khác biệt giữa một cặp quan sát cần được mở rộng thành một cặp nhóm quan sát. Sự mở rộng này đạt được bằng cách phát triển khái niệm liên kết, định nghĩa sự khác biệt giữa hai nhóm quan sát. Bốn loại liên kết phổ biến nhất—hoàn chỉnh, trung bình, đơn lẻ và trọng tâm—được mô tả ngắn gọn trong Bảng 12.3. Liên kết trung bình, hoàn chỉnh và đơn lẻ là phổ biến nhất trong giới thống kê. Liên kết trung bình và hoàn chỉnh thường được ưa chuộng hơn liên kết đơn lẻ, vì chúng có xu hướng tạo ra biểu đồ cây cân bằng hơn. Liên kết trọng tâm thường được sử dụng trong hệ gen học, nhưng có một nhược điểm lớn là có thể xảy ra hiện tượng đảo ngược, trong đó hai cụm được hợp nhất ở độ cao thấp hơn bất kỳ cụm riêng lẻ nào trong biểu đồ cây. Điều này có thể dẫn đến khó khăn trong việc trực quan hóa cũng như trong việc giải thích biểu đồ cây. Sự khác biệt được tính toán trong Bước 2(b)

liên kết

đảo ngược

Liên kết	Mô tả: Độ khác
Hoàn thành	biệt tối đa giữa các cụm. Tính toán tất cả các độ khác biệt từng cặp giữa các quan sát trong cụm A và các quan sát trong cụm B, và ghi lại độ khác biệt lớn nhất trong số đó.
Đơn	Độ khác biệt tối thiểu giữa các cụm. Tính toán tất cả các độ khác biệt từng cặp giữa các quan sát trong cụm A và các quan sát trong cụm B, và ghi lại độ khác biệt nhỏ nhất trong số này. Liên kết đơn có thể dẫn đến các cụm mở rộng, kéo dài, trong đó các quan sát đơn lẻ được hợp nhất từng cái một.
Trung bình	Độ khác biệt trung bình giữa các cụm. Tính toán tất cả các độ khác biệt từng cặp giữa các quan sát trong cụm A và các quan sát trong cụm B, và ghi lại giá trị trung bình của các độ khác biệt này.
Tâm trọng tâm	Sự khác biệt giữa tâm cụm của cụm A (một vectơ trung bình có độ dài p) và tâm cụm của cụm B. Liên kết tâm cụm có thể dẫn đến các đảo ngược không mong muốn.

BẢNG 12.3. Tóm tắt bốn loại liên kết được sử dụng phổ biến nhất trong phân cụm phân cấp.

Tính hiệu quả của thuật toán phân cụm phân cấp sẽ phụ thuộc vào loại liên kết được sử dụng, cũng như vào việc lựa chọn thước đo độ khác biệt. Do đó, biểu đồ cây kết quả thường phụ thuộc khá nhiều vào loại liên kết được sử dụng, như được thể hiện trong Hình 12.14.


Lựa chọn thước đo độ khác biệt

Cho đến nay, các ví dụ trong chương này đã sử dụng khoảng cách Euclidean làm thước đo độ khác biệt. Nhưng đôi khi các thước đo độ khác biệt khác có thể được ưu tiên hơn. Ví dụ, khoảng cách dựa trên tương quan coi hai quan sát là tương tự nhau nếu các đặc điểm của chúng có tương quan cao, ngay cả khi các giá trị quan sát có thể cách xa nhau về khoảng cách Euclidean. Đây là một cách sử dụng tương quan bất thường, thường được tính toán giữa các biến; ở đây nó được tính toán giữa các hồ sơ quan sát cho mỗi cặp quan sát. Hình 12.15 minh họa sự khác biệt giữa khoảng cách Euclidean và khoảng cách dựa trên tương quan. Khoảng cách dựa trên tương quan tập trung vào hình dạng của các hồ sơ quan sát hơn là độ lớn của chúng.

Việc lựa chọn thước đo độ khác biệt rất quan trọng, vì nó ảnh hưởng mạnh mẽ đến biểu đồ cây kết quả. Nói chung, cần chú ý cẩn thận đến loại dữ liệu đang được phân cụm và câu hỏi khoa học đang được nghiên cứu. Những yếu tố này sẽ quyết định loại thước đo độ khác biệt nào được sử dụng cho phân cụm phân cấp.

Ví dụ, hãy xem xét một nhà bán lẻ trực tuyến quan tâm đến việc phân nhóm người mua sắm dựa trên lịch sử mua sắm trước đây của họ. Mục tiêu là xác định các nhóm nhỏ người mua sắm tương tự nhau, để những người mua sắm trong mỗi nhóm nhỏ có thể được hiển thị các mặt hàng và quảng cáo mà họ đặc biệt quan tâm. Giả sử dữ liệu có dạng ma trận, trong đó các hàng là người mua sắm và các cột là các mặt hàng có sẵn để mua; các phần tử của ma trận dữ liệu cho biết số lần một người mua sắm cụ thể đã mua một mặt hàng.

12.4 Phương pháp phân cụm 531



HÌNH 12.13. Minh họa một vài bước đầu tiên của quá trình phân cấp.

thuật toán phân cụm, sử dụng dữ liệu từ Hình 12.12, với liên kết hoàn chỉnh và khoảng cách Euclidean. Góc trên bên trái: ban đầu có chín cụm riêng biệt. {1}, {2}, ..., {9}. Phía trên bên phải: hai cụm gần nhau nhất, {5} và {7}, được hợp nhất thành một cụm duy nhất. Dưới cùng bên trái: hai cụm gần nhau nhất, {6} và {1} được hợp nhất thành một cụm duy nhất. Phía dưới bên phải: hai cụm gần nhau nhất bằng cách sử dụng liên kết hoàn chỉnh, {8} và cụm {5, 7}, Chúng hợp nhất thành một cụm duy nhất.

mặt hàng đã cho (ví dụ: 0 nếu người mua chưa từng mua mặt hàng này, 1 nếu...)

(Người mua hàng đã mua sản phẩm đó một lần, v.v.) Loại thước đo sự khác biệt nào?

Nên sử dụng phương pháp nào để phân cụm người mua sắm? Nếu sử dụng khoảng cách Euclidean thì sao?

Những người mua sắm chỉ mua rất ít mặt hàng nói chung (tức là người dùng không thường xuyên)

Các trang web mua sắm trực tuyến sẽ được nhóm lại với nhau. Điều này có thể không mong muốn. Mặt khác, nếu sử dụng khoảng cách dựa trên tương quan, thì người mua sắm


có sở thích tương tự (ví dụ: những người mua sắm đã mua mặt hàng A và B nhưng...)

Các mặt hàng C hoặc D sẽ không bao giờ được nhóm lại với nhau, ngay cả khi một số người mua sắm có Những người có sở thích này mua sắm với số lượng lớn hơn những người khác. Do đó, đối với

Trong ứng dụng này, khoảng cách dựa trên tương quan có thể là lựa chọn tốt hơn.

Ngoài việc lựa chọn cẩn thận thước đo khác biệt được sử dụng, người ta còn phải...

Cũng cần xem xét liệu các biến có nên được chuẩn hóa để có độ lệch chuẩn bằng một trước khi tính toán sự khác biệt giữa các quan sát hay không. Để minh họa điểm này, chúng ta tiếp tục với ví dụ mua sắm trực tuyến...



HÌNH 12.14. Phương pháp liên kết trung bình, liên kết đầy đủ và liên kết đơn được áp dụng cho một tập dữ liệu ví dụ. Phương pháp liên kết trung bình và liên kết đầy đủ có xu hướng tạo ra các cụm cân bằng hơn.

như đã mô tả ở trên. Một số mặt hàng có thể được mua thường xuyên hơn những mặt hàng khác; ví dụ, một người mua sắm có thể mua mười đôi tất mỗi năm, nhưng rất hiếm khi mua máy tính. Do đó, những mặt hàng mua với tần suất cao như tất có xu hướng ảnh hưởng lớn hơn đến sự khác biệt giữa các người mua sắm, và do đó ảnh hưởng đến sự phân cụm cuối cùng thu được, so với những mặt hàng mua hiếm như máy tính.


Điều này có thể không mong muốn. Nếu các biến được chuẩn hóa để có độ lệch chuẩn bằng một trước khi tính toán sự khác biệt giữa các quan sát, thì trên thực tế, mỗi biến sẽ được coi trọng như nhau trong quá trình phân cụm phân cấp được thực hiện. Chúng ta cũng có thể muốn chuẩn hóa các biến để có độ lệch chuẩn bằng một nếu chúng được đo trên các thang đo khác nhau; nếu không, việc lựa chọn đơn vị (ví dụ: centimet so với ki-lô-mét) cho một biến cụ thể sẽ ảnh hưởng lớn đến thước đo sự khác biệt thu được. Không có gì đáng ngạc nhiên khi việc có nền chuẩn hóa các biến trước khi tính toán thước đo sự khác biệt hay không phụ thuộc vào ứng dụng cụ thể. Một ví dụ được thể hiện trong Hình 12.16. Chúng ta lưu ý rằng vấn đề có nên chuẩn hóa các biến trước khi thực hiện phân cụm hay không cũng áp dụng cho thuật toán phân cụm K-means.

12.4.3 Các vấn đề thực tiễn trong phân cụm

Phân cụm có thể là một công cụ rất hữu ích cho việc phân tích dữ liệu trong môi trường không giám sát. Tuy nhiên, có một số vấn đề phát sinh khi thực hiện phân cụm. Chúng tôi mô tả một số vấn đề này ở đây.

Những quyết định nhỏ nhưng mang lại hậu quả lớn.

Để thực hiện phân cụm, cần phải đưa ra một số quyết định.



HÌNH 12.15. Ba quan sát với các phép đo trên 20 biến số là

Như hình minh họa, quan sát 1 và 3 có giá trị tương tự nhau đối với mỗi biến số, do đó khoảng cách Euclidean giữa chúng nhỏ. Tuy nhiên, chúng có tương quan rất yếu, nên khoảng cách dựa trên tương quan giữa chúng lớn. Mặt khác, quan sát 1 và 2 có giá trị khá khác nhau đối với mỗi biến số, do đó khoảng cách Euclidean giữa chúng lớn. Nhưng chúng có tương quan cao, nên khoảng cách dựa trên tương quan giữa chúng nhỏ.


- Liệu các quan sát hoặc đặc điểm có nên được chuẩn hóa theo một cách nào đó trước khi sử dụng không? Ví dụ, có thể các biến số cần được hiệu chỉnh để có độ lệch chuẩn bằng một.
- Trong trường hợp phân cụm phân cấp,
 - Nên sử dụng thước đo độ khác biệt nào?
 - Nên sử dụng loại liên kết nào?
 - Chúng ta nên cắt biểu đồ cây ở vị trí nào để thu được các cụm?
- Trong trường hợp phân cụm K-means, chúng ta nên tìm bao nhiêu cụm trong dữ liệu?

Mỗi quyết định này đều có thể tác động mạnh mẽ đến kết quả đạt được.

Trên thực tế, chúng ta thử một vài lựa chọn khác nhau và tìm kiếm giải pháp hữu ích hoặc dễ hiểu nhất. Với các phương pháp này, không có câu trả lời đúng duy nhất-bất kỳ giải pháp nào làm nổi bật được một số khía cạnh thú vị của dữ liệu đều nên được xem xét.

Xác thực các cụm thu được Bất cứ

khí nào thực hiện phân cụm trên một tập dữ liệu, chúng ta sẽ tìm thấy các cụm. Nhưng điều chúng ta thực sự muốn biết là liệu các cụm đã tìm thấy có đại diện cho các nhóm con thực sự trong dữ liệu hay chúng chỉ đơn giản là kết quả của việc phân cụm nhiều. Ví dụ, nếu chúng ta thu được một tập hợp các quan sát độc lập, thì liệu những quan sát đó cũng sẽ hiển thị cùng một tập hợp các cụm hay không? Đây là một câu hỏi khó trả lời. Có một số kỹ thuật để gán giá trị p cho một cụm nhằm đánh giá xem liệu có nhiều hơn hay không.



HÌNH 12.16. Một nhà bán lẻ trực tuyến đa dạng bán hai mặt hàng: tất và máy tính. Bên trái: hiển thị số lượng tất và máy tính được mua bởi tám người mua sắm trực tuyến. Mỗi người mua sắm được hiển thị bằng một màu khác nhau. Nếu quan sát chéo... Sự khác biệt được tính toán bằng cách sử dụng khoảng cách Euclidean trên các biến thô, sau đó Số lượng tất mà một cá nhân mua sẽ quyết định sự khác biệt thu được, còn số lượng máy tính mua sẽ có ít ảnh hưởng. Điều này có thể không mong muốn, vì (1) máy tính đắt hơn tất và do đó Các nhà bán lẻ trực tuyến có thể quan tâm hơn đến việc khuyến khích người mua sắm mua máy tính. hơn tất, và (2) sự khác biệt lớn về số lượng tất được mua bởi hai Người mua sắm có thể cung cấp ít thông tin hơn về sở thích mua sắm tổng thể của người mua sắm. Chênh lệch không đáng kể về số lượng máy tính được mua. Trung tâm: giống nhau Dữ liệu được hiển thị sau khi đã chia tỷ lệ cho mỗi biến số bằng độ lệch chuẩn của nó. Bây giờ thì... Hai sản phẩm sẽ có tác động tương đương đến sự khác biệt giữa các quan sát. đã thu được. Bên phải: dữ liệu tương tự được hiển thị, nhưng giờ trực y biểu thị Số tiền đã trả mà mỗi người mua sắm trực tuyến chi tiêu cho tất và máy tính. Kể từ Máy tính đắt hơn nhiều so với tất, giờ thì đến lịch sử mua máy tính. Điều này sẽ thúc đẩy sự khác biệt giữa các quan sát thu được.

bằng chứng cho thấy cụm này nhiều hơn so với dự đoán do ngẫu nhiên. Tuy nhiên, Hiện vẫn chưa có sự đồng thuận về một phương pháp tối ưu duy nhất. Thông tin chi tiết hơn có thể được tìm thấy tại đây. có thể tìm thấy trong ESL.⁸

Các yếu tố cần xem xét khác trong phân cụm

Cả thuật toán K-means và phân cụm phân cấp đều sẽ gán mỗi quan sát vào một nhóm nhất định. một cụm. Tuy nhiên, đôi khi điều này có thể không phù hợp. Ví dụ, giả sử rằng hầu hết các quan sát thực sự thuộc về một số ít (không rõ) các nhóm con, và một tập hợp con nhỏ của các quan sát khá khác biệt với nhau và với tất cả các quan sát khác. Sau đó, vì thuật toán K-means và phân cụm phân cấp buộc mọi quan sát phải vào một cụm, nên Các cụm dữ liệu tìm thấy có thể bị biến dạng nghiêm trọng do sự hiện diện của các giá trị ngoại lệ. không thuộc bất kỳ nhóm nào. Mô hình hỗn hợp là một cách tiếp cận hấp dẫn. để xử lý sự hiện diện của các giá trị ngoại lệ như vậy. Điều này tạo nên một sự mềm mại. phiên bản của thuật toán phân cụm K-means, và được mô tả trong ESL.

⁸ESL: Các yếu tố của học thống kê, của Hastie, Tibshirani và Friedman.

Ngoài ra, các phương pháp phân cụm nhìn chung không mấy mạnh mẽ trước những thay đổi trong dữ liệu. Ví dụ, giả sử chúng ta phân cụm n quan sát, rồi lại phân cụm các quan sát đó một lần nữa sau khi loại bỏ ngẫu nhiên một tập con của n quan sát. Người ta hy vọng rằng hai tập hợp cụm thu được sẽ khá giống nhau, nhưng thường thì không phải vậy!

Một cách tiếp cận thận trọng để diễn giải kết quả phân cụm

Chúng tôi đã mô tả một số vấn đề liên quan đến phân cụm. Tuy nhiên, phân cụm có thể là một công cụ thống kê rất hữu ích và hợp lệ nếu được sử dụng đúng cách. Chúng tôi đã đề cập rằng những quyết định nhỏ trong cách thực hiện phân cụm, chẳng hạn như cách chuẩn hóa dữ liệu và loại liên kết được sử dụng, có thể ảnh hưởng lớn đến kết quả. Do đó, chúng tôi khuyến nghị thực hiện phân cụm với các lựa chọn khác nhau cho các tham số này và xem xét toàn bộ tập kết quả để xem những mẫu nào xuất hiện một cách nhất quán. Vì phân cụm có thể không mạnh mẽ, chúng tôi khuyến nghị phân cụm các tập con của dữ liệu để đánh giá độ mạnh mẽ của các cụm thu được. Quan trọng nhất, chúng ta phải cẩn thận về cách báo cáo kết quả của phân tích phân cụm. Những kết quả này không nên được coi là chân lý tuyệt đối về một tập dữ liệu. Thay vào đó, chúng nên là điểm khởi đầu cho việc phát triển một giả thuyết khoa học và nghiên cứu sâu hơn, tốt nhất là trên một tập dữ liệu độc lập.

12.5 Thực hành: Học không giám sát

Trong bài thực hành này, chúng ta sẽ trình bày về PCA và phân cụm trên một số tập dữ liệu. Cũng như các bài thực hành khác, chúng ta sẽ nhập một số thư viện ở cấp độ cao nhất này. Điều này giúp mã dễ đọc hơn, vì chỉ cần quét vài dòng đầu tiên của notebook là chúng ta có thể biết được những thư viện nào đang được sử dụng.

```
Trong [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt from
statsmodels.datasets import get_rdataset from
sklearn.decomposition import PCA from
sklearn.preprocessing import StandardScaler from ISLP import
load_data
```

Chúng tôi cũng thu thập các vật tư nhập khẩu mới cần thiết cho phòng thí nghiệm này.

```
Trong [2]: từ sklearn.cluster import \
(KMeans,
AgglomerativeClustering) từ
scipy.cluster.hierarchy import \
(dendrogram,
cut_tree)
from ISLP.cluster import compute_linkage
```

12.5.1 Phân tích thành phần chính

Trong bài thực hành này, chúng ta sẽ thực hiện phân tích thành phần chính (PCA) trên tập dữ liệu `USArrests` trong môi trường tính toán R. Chúng ta sẽ truy xuất dữ liệu bằng cách sử dụng hàm `get_rdataset()`, hàm này có thể lấy dữ liệu từ các tập tin cần thiết.

```
get_
rdataset()
```

536 12. Học không giám sát

Dữ liệu từ nhiều gói R tiêu chuẩn.
Các hàng của tập dữ liệu chứa 50 tiểu bang, được sắp xếp theo thứ tự bảng chữ cái.

```
Trong [3]: USArrests = get_rdataset('USArrests').data
          Hoa Kỳ bắt giữ
```

Ra ngoài[3]:

	Giết người	Tấn công	UrbanPop	Hiếp dâm
Alabama	13.2	236	48	21.2
Alaska	10.0	263	80	44.5
Arizona	8.1	294		31.0
...	...	...	...	...
Wisconsin	2.6	53	66	10.8
Wyoming	6.8	161	60	15.6

Các cột của tập dữ liệu chứa bốn biến.

```
Trong [4]: USArrests.columns
```

```
Out[4]: Index(['Murder', 'Assault', 'UrbanPop', 'Rape'],
              dtype='object')
```

Trước tiên, chúng ta sẽ xem xét sơ lược dữ liệu. Chúng ta nhận thấy rằng các biến số có
có nghĩa là hoàn toàn khác biệt.

```
Trong [5]: USArrests.mean()
```

Ra ngoài[5]:

Giết người	7.788
Tấn công	170.760
UrbanPop	65.540
Loại	21.232

dữ liệu hiếp dâm: float64

DataFrame có một số phương pháp hữu ích để tính toán các tổng theo cột. Chúng ta cũng có
thể kiểm tra phương sai của bốn biến bằng cách sử dụng...
Phương thức var() .

```
Trong [6]: USArrests.var()
```

Ra ngoài[6]:

Giết người	18.970465
Tấn công	6945.165714
UrbanPop	209.518776
Loại	87.729159

dữ liệu hiếp dâm: float64

Không có gì đáng ngạc nhiên khi các biến số cũng có phương sai rất khác nhau.
Biến **UrbanPop** đo lường tỷ lệ phần trăm dân số ở mỗi tiểu bang.
sống ở khu vực đô thị, con số này không thể so sánh với số lượng của
Số vụ hiếp dâm ở mỗi tiểu bang trên 100.000 người. PCA tìm kiếm các biến dẫn xuất.
Điều đó giải thích phần lớn sự biến thiên trong tập dữ liệu. Nếu chúng ta không hiệu chỉnh tỷ lệ...
các biến trước khi thực hiện PCA, thì các thành phần chính sẽ
chủ yếu bị chi phối bởi biến **Assault** , vì nó có giá trị lớn nhất.
sự khác biệt. Vì vậy, nếu các biến được đo bằng các đơn vị khác nhau hoặc có sự biến thiên lớn.
Về mặt thang đo, nên chuẩn hóa các biến số để có được tiêu chuẩn.
Độ lệch chuẩn thứ nhất trước khi thực hiện PCA. Thông thường, chúng ta đặt giá trị trung bình bằng không.
cũng vậy.

Việc điều chỉnh tỷ lệ này có thể được thực hiện thông qua phép biến đổi `StandardScaler()` đã được nhập ở trên. Đầu tiên, chúng ta **điều chỉnh** tỷ lệ, tính toán các giá trị trung bình và độ lệch chuẩn cần thiết, sau đó áp dụng nó vào dữ liệu của chúng ta bằng phương thức `transform`. Như trước đây, chúng ta kết hợp các bước này bằng phương thức `fit_transform()`.

```
Trong [7]: scaler = StandardScaler(with_std=True,
                                với_mean=True)
USArrests_scaled = scaler.fit_transform(USArrests)
```

Sau khi đã chuẩn hóa dữ liệu, chúng ta có thể tiến hành phân tích thành phần chính bằng cách sử dụng phép biến đổi `PCA()` từ gói `sklearn.decomposition`.

PCA()

```
Trong [8]: pcaUS = PCA()
```

(Theo mặc định, phép biến đổi `PCA()` sẽ căn giữa các biến để chúng có giá trị trung bình bằng 0, mặc dù nó không điều chỉnh tỷ lệ cho chúng.) Phép biến đổi `pcaUS` có thể được sử dụng để tìm các **điểm số** PCA được trả về bởi hàm `fit()`. Sau khi phương thức `fit` được gọi, đối tượng `pcaUS` cũng chứa một số đại lượng hữu ích.

```
Trong [9]: pcaUS.fit(USArrests_scaled)
```

Sau khi hiệu chỉnh, thuộc tính `mean_` tương ứng với giá trị trung bình của các biến. Trong trường hợp này, vì chúng ta đã căn giữa và chuẩn hóa dữ liệu bằng hàm `scaler()` nên tất cả các giá trị trung bình sẽ bằng 0.

```
Trong [10]: pcaUS.mean_
```

```
Out[10]: array([-0.,  0., -0.,  0.])
```

Điểm số có thể được tính toán bằng cách sử dụng phương thức `transform()` của `pcaUS` sau khi Nó đã phù hợp.

```
Trong [11]: scores = pcaUS.transform(USArrests_scaled)
```

Chúng ta sẽ vẽ biểu đồ các điểm số này ở phần dưới. Thuộc tính `components_` cung cấp hệ số tải thành phần chính: mỗi hàng của `pcaUS.components_` chứa vectơ hệ số tải thành phần chính tương ứng.

```
Trong [12]: pcaUS.components_
```

```
Out[12]: array([[ 0.53589947,  0.58318363,  0.27819087,  0.54343209], [ 0.41818087,
  0.1879856 , -0.87280619, -0.16731864], [-0.34123273, -0.26814843,
 -0.37801579,  0.81777791], [ 0.6492278
    , -0.74340748,  0.13387773,  0.08902432]])
```

Biểu đồ hai chiều (biplot) là một phương pháp trực quan hóa phổ biến được sử dụng với PCA. Nó không được tích hợp sẵn như một phần tiêu chuẩn của `sklearn`, mặc dù có các gói Python tạo ra loại biểu đồ này. Ở đây, chúng ta sẽ tạo một biểu đồ hai chiều đơn giản bằng tay.

```
Trong [13]: i, j = 0, 1 # các thành phần nào fig, ax =
plt.subplots(1, 1, figsize=(8, 8)) ax.scatter(scores[:,0],
scores[:,1]) ax.set_xlabel('PC%d' % (i+1))
ax.set_ylabel('PC%d' % (j+1)) for k in
range(pcaUS.components_.shape[1]):
```

```
ax.arrow(0, 0, pcaUS.components_[i,k], pcaUS.components_[j,k])
ax.text(pcaUS.components_[i,k],
        pcaUS.components_[j,k],
        USArrests.columns[k])
```

Hãy lưu ý rằng hình này là hình phản chiếu của Hình 12.1 qua trục y.

Hãy nhớ rằng các thành phần chính chỉ duy nhất khi thay đổi dấu, vì vậy chúng ta có thể tái tạo hình đó bằng cách đảo dấu của tập hợp điểm số và hệ số tải thứ hai. Chúng ta cũng tăng độ dài của các mũi tên để nhấn mạnh hệ số tải.

```
Trong [14]: scale_arrow = s_ = 2
scores[:,1] *= -1
pcaUS.components_[1] *= -1 # lật trục y fig, ax =
plt.subplots(1, 1, figsize=(8, 8)) ax.scatter(scores[:,0],
scores[:,1]) ax.set_xlabel('PC%d' % (i+1))
ax.set_ylabel('PC%d' % (j+1)) for k
in range(pcaUS.components_.shape[1]):

    ax.arrow(0, 0, s_*pcaUS.components_[i,k], s_*pcaUS.components_[
        j,k])
    ax.text(s_*pcaUS.components_[i,k],
            s_*pcaUS.components_[j,k],
            USArrests.columns[k])
```

Độ lệch chuẩn của điểm số thành phần chính như sau:

```
Trong [15]: Score.std(0, ddof=1)
```

```
Out[15]: array([1.5909, 1.0050, 0.6032, 0.4207])
```

Độ lệch chuẩn của mỗi điểm số có thể được trích xuất trực tiếp từ đối tượng `pcaUS` thông qua thuộc tính `explained_variance_`.

```
Trong [16]: pcaUS.explained_variance_
```

```
Out[16]: array([2.5309, 1.01      , 0.3638, 0.177 ])
```

Tỷ lệ phương sai được giải thích bởi mỗi thành phần chính (PVE) được lưu trữ dưới dạng `explained_variance_ratio_`:

```
Trong [17]: pcaUS.explained_variance_ratio_
```

```
Out[17]: array([0.6201, 0.2474, 0.0891, 0.0434])
```

Ta thấy rằng thành phần chính đầu tiên giải thích 62,0% phương sai trong dữ liệu, thành phần chính tiếp theo giải thích 24,7% phương sai, và cứ thế tiếp tục. Ta có thể vẽ biểu đồ PVE được giải thích bởi mỗi thành phần, cũng như PVE tích lũy. Trước tiên, ta vẽ biểu đồ tỷ lệ phương sai được giải thích.

```
Trong [18]: %%bất hình,
trục = plt.subplots(1, 2, figsize=(15, 6)) ticks =
np.arange(pcaUS.n_components_)+1 ax = axes[0] ax.plot(ticks,

    pcaUS.explained_variance_ratio_,
    marker='o')
```

```
ax.set_xlabel('Thành phần chính');
ax.set_ylabel('Tỷ lệ phương sai được giải thích')
ax.set_ylim([0,1])
ax.set_xticks(ticks)
```

Hãy chú ý đến việc sử dụng `%%capture`, thao tác này ngăn chặn việc hiển thị một phần của nội dung. Hình ảnh hoàn chỉnh.

```
Trong [19]: ax = trục[1]
ax.plot(ticks,
        pcaUS.explained_variance_ratio_.cumsum(),
        marker='o')
ax.set_xlabel('Thành phần chính')
ax.set_ylabel('Tỷ lệ tích lũy của phương sai được giải thích')
ax.set_ylim([0, 1])
ax.set_xticks(ticks)
```

Kết quả tương tự như hình 12.3. Lưu ý rằng phương pháp `Hàm cumsum()` tính tổng tích lũy của các phần tử trong một vectơ số. Ví dụ:

```
Trong [20]: a = np.array([1,2,8,-3])
np.cumsum(a)
```

Out[20]: array([1, 3, 11, 8])

12.5.2 Hoàn thành ma trận

Chúng tôi sẽ tái hiện lại phân tích đã được thực hiện trên dữ liệu `USArrests` trong Mục 12.3.

Chúng ta đã thấy trong Phần 12.2.2 rằng việc giải quyết bài toán tối ưu hóa (12.6) trên Ma trận dữ liệu X đã được căn giữa tương đương với việc tính toán M thành phần chính đầu tiên. các thành phần của dữ liệu. Chúng tôi sử dụng dữ liệu `USArrests` đã được hiệu chỉnh và căn giữa của mình như là X bên dưới. Phân tích giá trị đơn (SVD) là một thuật toán tổng quát để giải (12.6).

```
Trong [21]: X = USArrests_scaled
U, D, V = np.linalg.svd(X, full_matrices=False)
Hành chữ U, hình chữ D, hình chữ V
```

Out[21]: ((50, 4), (4,), (4, 4))

Hàm `np.linalg.svd()` trả về ba thành phần, U , D và V . V tương đương với ma trận tải từ (ma trận các thành phần chính (lên đến thành một sự đảo dấu không quan trọng). Việc sử dụng tùy chọn `full_matrices=False` đảm bảo Đối với ma trận cao, hình dạng của U giống với hình dạng của X .

```
Trong [22]: V
```

Out[22]: array([[-0.53589947, -0.58318363, -0.27819087, -0.54343209],
 [0.41818087, 0.1879856 , -0.87280619, -0.16731864],
 [-0.34123273, -0.26814843, -0.37801579, 0.81777791],
 [0.6492278 , -0.74340748, 0.13387773, 0.08902432]])

tổng tích lũy()

số ít
giá trị giảm
bổ cục
svd()

np.linalg.svd()

540 12. Học không giám sát

Trong [23]: `pcaUS.components_`

```
Out[23]: array([[ 0.53589947, 0.58318363, 0.27819087, 0.54343209], [ 0.41818087,
 0.1879856 , -0.87280619, -0.16731864], [-0.34123273, -0.26814843,
-0.37801579, 0.81777791], [ 0.6492278
, -0.74340748, 0.13387773, 0.08902432]])
```

Ma trận U tương ứng với phiên bản chuẩn hóa của ma trận điểm PCA (mỗi cột được chuẩn hóa để có tổng bình phương bằng một). Nếu ta nhân mỗi cột của U với phần tử tương ứng của D , ta sẽ thu được chính xác điểm PCA (ngoại trừ sự đảo dấu không đáng kể).

Trong [24]: `(U * D[Không có,:])[:3]`

```
Out[24]: array([[ -0.9856, 1.1334, -0.4443, 0.1563], [-1.9501,
 1.0732, 2.04 , -0.4386], [-1.7632, -0.746 ,
 0.0548, -0.8347]])
```

Trong [25]: `điểm số[:3]`

```
Out[25]: array([[ 0.9856, -1.1334, -0.4443, 0.1563], [ 1.9501,
-1.0732, 2.04 , -0.4386], [ 1.7632, 0.746 ,
 0.0548, -0.8347]])
```

Mặc dù có thể thực hiện thí nghiệm này bằng cách sử dụng bộ ước lượng `PCA()`, nhưng ở đây chúng tôi sử dụng hàm `np.linalg.svd()` để minh họa cách sử dụng của nó.

Bây giờ chúng ta loại bỏ ngẫu nhiên 20 mục trong ma trận dữ liệu 50×4 . Chúng ta làm điều này bằng cách trước tiên chọn ngẫu nhiên 20 hàng (trạng thái), sau đó chọn ngẫu nhiên một trong bốn mục trong mỗi hàng. Điều này đảm bảo rằng mỗi hàng có ít nhất ba giá trị được quan sát.

```
Trong [26]: n_omit = 20
np.random.seed(15)
r_idx = np.random.choice(np.arange(X.shape[0]),
                          n_omit,
                          replace=False)
c_idx = np.random.choice(np.arange(X.shape[1]),
                          n_omit,
                          replace=True)

Xna = X.copy()
Xna[r_idx, c_idx] = np.nan
```

Ở đây, mảng `r_idx` chứa 20 số nguyên từ 0 đến 49; điều này thể hiện các trạng thái (hàng của X) được chọn để chứa các giá trị bị thiếu. Và `c_idx` chứa 20 số nguyên từ 0 đến 3, thể hiện các đặc trưng (cột trong X) chứa các giá trị bị thiếu cho mỗi trạng thái được chọn.

Bây giờ chúng ta sẽ viết một số mã để triển khai Thuật toán 12.1. Trước tiên, chúng ta viết một hàm nhận vào một ma trận và trả về một giá trị xấp xỉ của ma trận đó bằng cách sử dụng hàm `svd()`. Hàm này sẽ cần thiết trong Bước 2 của Thuật toán 12.1.

```
Trong [27]: def low_rank(X, M=1):
    U, D, V = np.linalg.svd(X)
    L = U[:, :M] * D[None, :M]
    return L.dot(V[:, :M])
```

Để thực hiện Bước 1 của thuật toán, chúng ta khởi tạo $\hat{X}$ – đây là $\hat{X}$ trong Thuật toán 12.1 – bằng cách thay thế các giá trị bị thiếu bằng giá trị trung bình cột của các mục không bị thiếu. Các giá trị này được lưu trữ trong $\bar{X}$ bên dưới sau khi chạy `np.nanmean()` trên trục hàng. Chúng ta tạo một bản sao để khi gán các giá trị `np.nanmean()` cho $\hat{X}$ bên dưới, chúng ta không ghi đè lên các giá trị trong X_{na} .

```
Trong [28]: Xhat = Xna.copy()
Xbar = np.nanmean(Xhat, axis=0)
Xhat[r_idx, c_idx] = Xbar[c_idx]
```

Trước khi bắt đầu Bước 2, chúng ta sẽ thiết lập hệ thống để đo lường tiến độ của...

các phiên bản của chúng tôi:

```
Trong [29]: ngưỡng = 1e-7
rel_err = 1
count = 0

issmiss = np.isnan(Xna) mssold =
np.mean(Xhat[ issmiss]**2) mss0 =
np.mean(Xna[ issmiss]**2)
```

Ở đây, `issmiss` là một ma trận logic có cùng kích thước với X_{na} ; một phần tử nhất định được coi là `True` nếu phần tử ma trận tương ứng bị thiếu. Ký hiệu `issmiss` phủ định vectơ boolean này. Điều này hữu ích vì nó cho phép chúng ta truy cập cả các mục bị thiếu và không bị thiếu. Chúng ta lưu trữ giá trị trung bình của bình phương các phần tử không bị thiếu trong `mss0`. Chúng ta lưu trữ sai số bình phương trung bình của các phần tử không bị thiếu của phiên bản cũ của $\hat{X}$ trong `mssold` (hiện tại trùng với `mss0`). Chúng ta dự định lưu trữ sai số bình phương trung bình của các phần tử không bị thiếu của phiên bản hiện tại của $\hat{X}$ trong `mss`, và sau đó sẽ lặp lại Bước 2 của Thuật toán 12.1 cho đến khi sai số tương đối, được định nghĩa là $(mssold - mss) / mss0$, giảm xuống dưới `thresh = 1e-7`.

9

Trong Bước 2(a) của Thuật toán 12.1, chúng ta xấp xỉ $\hat{X}$ bằng cách sử dụng `low_rank()`; chúng ta gọi đây là $\hat{X}_{app}$. Trong Bước 2(b), chúng ta sử dụng $\hat{X}_{app}$ để cập nhật các ước tính cho các phần tử trong $\hat{X}$ bị thiếu trong X_{na} . Cuối cùng, trong Bước 2(c), chúng ta tính toán sai số tương đối. Ba bước này được chứa trong vòng lặp `while` sau :

```
Trong [30]: trong khi rel_err > thresh:
    đếm += 1 # Bước
    2(a)
    Xapp = hạng thấp (Xhat, M=1)
    # Bước 2(b)
    Xhat[issmiss] = Xapp[issmiss]
    # Bước 2(c) mss
    = np.mean(((Xna - Xapp)[ issmiss])**2) rel_err = (mssold - mss) /
    mss0 mssold = mss

    print("Lần lặp: {0}, MSS:{1:.3f}, Lỗi tương đối {2:.2e}" .format(count, mss,
        rel_err))
```

Thuật toán 12.1 cho chúng ta biết phải lặp lại Bước 2 cho đến khi (12.14) không còn giảm nữa. Việc xác định xem (12.14) có giảm hay không chỉ yêu cầu chúng ta theo dõi `mssold - mss`. Tuy nhiên, trên thực tế, chúng ta theo dõi $(mssold - mss) / mss0$ thay vì: điều này giúp cho số lần lặp cần thiết để Thuật toán 12.1 hội tụ không phụ thuộc vào việc chúng ta có nhân dữ liệu thô X với một hệ số không đổi hay không.

542 12. Học không giám sát

Lần lặp: 1, MSS:0.395, Sai số tương đối 5.99e-01
 Lần lặp: 2, MSS:0.382, Sai số tương đối 1.33e-02
 Lần lặp: 3, MSS:0.381, Sai số tương đối 1.44e-03
 Lần lặp: 4, MSS:0.381, Sai số tương đối 1.79e-04
 Lần lặp: 5, MSS:0.381, Sai số tương đối 2.58e-05
 Lần lặp: 6, MSS:0.381, Sai số tương đối 4.22e-06
 Lần lặp: 7, MSS:0.381, Sai số tương đối 7.65e-07
 Lần lặp: 8, MSS:0.381, Sai số tương đối 1.48e-07
 Lần lặp: 9, MSS:0.381, Sai số tương đối 2.95e-08

Ta thấy rằng sau tám lần lặp, sai số tương đối đã giảm xuống dưới ngưỡng $= 1e-7$, và do đó thuật toán kết thúc. Khi điều này xảy ra, sai số bình phương trung bình của các phần tử không thiếu bằng 0,381.

Cuối cùng, chúng tôi tính toán hệ số tương quan giữa 20 giá trị được gán và các giá trị thực tế:

```
Trong [31]: np.corrcoef(Xapp[ismiss], X[ismiss])[0,1]
```

```
Out[31]: 0.711
```

Trong bài thực hành này, chúng tôi đã tự triển khai Thuật toán 12.1 nhằm mục đích giảng dạy. Tuy nhiên, người đọc nào muốn áp dụng phương pháp hoàn thành ma trận vào dữ liệu của mình có thể tìm đến các triển khai Python chuyên biệt hơn.

12.5.3 Phân cụm

Phân cụm K-Means

Hàm ước lượng `sklearn.cluster.KMeans()` thực hiện phân cụm K-means trong Python. Chúng ta bắt đầu với một ví dụ mô phỏng đơn giản, trong đó thực sự có hai cụm trong dữ liệu: 25 quan sát đầu tiên có sự thay đổi trung bình so với 25 quan sát tiếp theo. Kmeans()

```
Trong [32]: np.random.seed(0); X
           = np.random.standard_normal((50,2)); X[:25,0] +=
           3; X[:25,1] -= 4;
```

Bây giờ chúng ta tiến hành phân cụm K-means với $K = 2$.

```
Trong [33]: kmeans = KMeans(n_clusters=2,
                           random_state=2,
                           n_init=20).fit(X)
```

Chúng tôi chỉ định `random_state` để đảm bảo kết quả có thể tái tạo được. Thông tin phân cụm của 50 quan sát được chứa trong `kmeans.labels_`.

```
Trong [34]: kmeans.labels_
```

```
Out[34]: array([1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 1,
                1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
                0, 0], dtype=int32)
```

Thuật toán phân cụm K-means đã phân tách hoàn hảo các quan sát thành hai cụm mặc dù chúng ta không cung cấp bất kỳ thông tin nhóm nào cho hàm `KMeans()`. Chúng ta có thể vẽ biểu đồ dữ liệu, với mỗi quan sát được tô màu theo cụm mà nó được phân loại.

```
Trong [35]: fig, ax = plt.subplots(1, 1, figsize=(8,8))
ax.scatter(X[:,0], X[:,1], c=kmeans.labels_) ax.set_title(" Kết
quả phân cụm K-Means với K=2");
```

Ở đây, các quan sát có thể dễ dàng được biểu diễn trên đồ thị vì chúng là dữ liệu hai chiều. Nếu có nhiều hơn hai biến, chúng ta có thể thực hiện phân tích thành phần chính (PCA) và biểu diễn hai vectơ điểm thành phần chính đầu tiên để thể hiện các cụm.

Trong ví dụ này, chúng ta biết rằng thực sự có hai cụm vì chúng ta đã tạo ra dữ liệu. Tuy nhiên, đối với dữ liệu thực tế, chúng ta không biết số lượng cụm thực sự, cũng như liệu chúng có tồn tại một cách chính xác hay không. Thay vào đó, chúng ta có thể đã thực hiện phân cụm K-means trên ví dụ này với $K = 3$.

```
Trong [36]: kmeans = KMeans(n_clusters=3,
                           random_state=3,
                           n_init=20).fit(X)
fig, ax = plt.subplots(figsize=(8,8)) ax.scatter(X[:,0],
X[:,1], c=kmeans.labels_) ax.set_title(" Kết quả phân cụm K-Means
với K=3");
```

Khi $K = 3$, thuật toán phân cụm K-means sẽ chia hai cụm. Chúng ta đã sử dụng đối số `n_init` để chạy thuật toán K-means với 20 lần gán cụm ban đầu (mặc định là 10). Nếu sử dụng giá trị `n_init` lớn hơn một, thì thuật toán phân cụm K-means sẽ được thực hiện bằng cách sử dụng nhiều lần gán ngẫu nhiên trong Bước 1 của Thuật toán 12.2, và hàm `KMeans()` sẽ chỉ báo cáo kết quả tốt nhất. Ở đây chúng ta so sánh việc sử dụng `n_init=1` với `n_init=20`.

```
Trong [37]: kmeans1 = KMeans(n_clusters=3,
                           random_state=3,
                           n_init=1).fit(X)
kmeans20 = KMeans(n_clusters=3,
                  random_state=3,
                  n_init=20).fit(X);
kmeans1.inertia_, kmeans20.inertia_
```

```
Ra[37]: (78.06, 75.04)
```

Lưu ý rằng `kmeans.inertia_` là tổng bình phương trong cụm, mà chúng ta tìm cách giảm thiểu bằng cách thực hiện phân cụm K-means (12.17).

Chúng tôi đặc biệt khuyến nghị luôn chạy thuật toán phân cụm K-means với giá trị `n_init` lớn, chẳng hạn như 20 hoặc 50, vì nếu không, có thể thu được điểm tối ưu cục bộ không mong muốn.

Khi thực hiện phân cụm K-means, ngoài việc sử dụng nhiều cách gán cụm ban đầu, điều quan trọng là phải thiết lập một hạt giống ngẫu nhiên bằng cách sử dụng đối số `random_state` cho hàm `KMeans()`. Bằng cách này, các cách gán cụm ban đầu ở Bước 1 có thể được sao chép và kết quả đầu ra của K-means sẽ hoàn toàn có thể tái tạo được.

Phân cụm phân cấp

Lớp `AgglomerativeClustering()` từ gói `sklearn.cluster` triển khai thuật toán phân cụm phân cấp. Vì tên của nó khá dài, chúng ta sử dụng ký hiệu viết tắt `HClust` cho thuật ngữ phân cụm phân cấp. Lưu ý rằng điều này sẽ không thay đổi.

Kết tụ
Phân cụm()

Kiểu trả về khi sử dụng phương pháp này sẽ khác, vì vậy các thể hiện vẫn sẽ thuộc lớp `AgglomerativeClustering`. Trong ví dụ sau, chúng ta sử dụng dữ liệu từ bài thực hành trước để vẽ biểu đồ cây phân cụm phân cấp bằng cách sử dụng phân cụm liên kết hoàn chỉnh, liên kết đơn và liên kết trung bình với khoảng cách Euclidean làm thước đo độ khác biệt. Chúng ta bắt đầu bằng cách phân cụm các quan sát bằng cách sử dụng liên kết hoàn chỉnh.

```
Trong [38]: HClust = Phân cụm kết hợp
hc_comp = HClust(distance_threshold=0, n_clusters=None,
                 linkage='complete')

hc_comp.fit(X)
```

Thao tác này tính toán toàn bộ biểu đồ cây. Chúng ta cũng có thể dễ dàng thực hiện thao tác tương tự. Phân cụm phân cấp với liên kết trung bình hoặc liên kết đơn thay thế:

```
Trong [39]: hc_avg = HClust(distance_threshold=0,
                          n_clusters=None,
                          linkage='average');
hc_avg.fit(X)
hc_sing = HClust(distance_threshold=0, n_clusters=None,
                 linkage='single');

hc_sing.fit(X);
```

Để sử dụng ma trận khoảng cách được tính toán trước, chúng tôi cung cấp thêm một đối số `'metric="precomputed"'`. Trong đoạn mã bên dưới, bốn dòng đầu tiên tính toán ma trận khoảng cách từng cặp 50×50 .

```
Trong [40]: D = np.zeros((X.shape[0], X.shape[0])); for i in
range(X.shape[0]):
    x_ = np.multiply.outer(np.ones(X.shape[0]), X[i])
    D[i] = np.sqrt(np.sum((X - x_)**2, 1)); hc_sing_pre =
HClust(distance_threshold=0, n_clusters=None,
       metric='precomputed',
       linkage='single')

hc_sing_pre.fit(D)
```

Chúng tôi sử dụng hàm `dendrogram()` từ `scipy.cluster.hierarchy` để vẽ biểu đồ cây. Tuy nhiên, hàm `dendrogram()` yêu cầu một biểu diễn ma trận liên kết của quá trình phân cụm, điều mà hàm `AgglomerativeClustering()` không cung cấp, nhưng có thể được tính toán. Hàm `compute_linkage()` trong gói `ISLP.cluster` được cung cấp cho mục đích này.

biểu đồ cây ()

tính toán_
liên kết()
Cụm ISLP

Giờ chúng ta có thể vẽ biểu đồ cây. Các số ở dưới cùng của biểu đồ xác định từng quan sát. Hàm `dendrogram()` có một phương pháp mặc định để tô màu các nhánh khác nhau của cây, gợi ý một đường cắt được xác định trước của cây ở một độ sâu cụ thể. Chúng ta muốn ghi đè lên giá trị mặc định này bằng cách đặt ngưỡng là vô hạn. Vì chúng ta muốn hành vi này áp dụng cho nhiều biểu đồ cây, chúng ta lưu trữ các giá trị này trong một từ điển `cargs` và truyền chúng dưới dạng đối số từ khóa bằng cách sử dụng ký hiệu `**cargs`.

```
Trong [41]: cargs = {'color_threshold':-np.inf,
                  'above_threshold_color':'black'} linkage_comp
= compute_linkage(hc_comp) fig, ax = plt.subplots(1,
1, figsize=(8, 8))
```

```
biểu đồ cây (liên kết_comp,
              ax=ax,
              **cargs);
```

Chúng ta có thể muốn tô màu các nhánh cây phía trên và phía dưới một ngưỡng cắt khác nhau. Điều này có thể đạt được bằng cách thay đổi `color_threshold` . Chúng ta hãy cắt cây ở độ cao 4, tô màu đen cho các đoạn nối hợp nhất ở trên độ cao 4.

```
Trong [42]: fig, ax = plt.subplots(1, 1, figsize=(8, 8)) dendrogram(linkage_comp,

                        ax=ax,
                        color_threshold=4,
                        above_threshold_color='black');
```

Để xác định nhãn cụm cho mỗi quan sát liên quan đến một lát cắt nhất định của biểu đồ cây, chúng ta có thể sử dụng hàm `cut_tree()` từ `scipy.cluster.hierarchy`: cắt cây()

```
Trong [43]: cut_tree(linkage_comp, n_clusters=4).T
```

```
Out[43]: array([[0, 1, 0, 0, 1, 1, 0, 1, 0, 0, 2, 0, 0, 0, 1, 1, 0, 0, 1, 0, 0, 2, 0, 2, 3, 2, 3, 3, 3, 2, 3,
                3, 3, 3, 2, 3, 3, 3, 3, 3, 3, 3]])
```

Điều này cũng có thể đạt được bằng cách cung cấp đối số `n_clusters` cho hàm `HClust()`; Tuy nhiên, mỗi lần cắt sẽ yêu cầu tính toán lại quá trình phân cụm. Tương tự, cây có thể được cắt theo ngưỡng khoảng cách bằng cách sử dụng đối số `distance_threshold` cho hàm `HClust()` hoặc `height` cho hàm `cut_tree()`.

```
Trong [44]: cut_tree(linkage_comp, height=5)
```

```
Out[44]: array([[0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 1, 1, 2, 1, 2, 2, 2, 1, 2, 2,
                2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2]])
```

Để chuẩn hóa các biến trước khi thực hiện phân cụm phân cấp của Trong các quan sát này, chúng tôi sử dụng `StandardScaler()` như trong ví dụ PCA của chúng tôi:

```
Trong [45]: scaler = StandardScaler()
X_scale = scaler.fit_transform(X) hc_comp_scale =
HClust(distance_threshold=0,
        n_clusters=None,
        linkage='complete').fit(X_scale) linkage_comp_scale
= compute_linkage(hc_comp_scale) fig, ax = plt.subplots(1, 1, figsize=(8, 8))
dendrogram(linkage_comp_scale , ax=ax, **cargs) ax.set_title("Phân cụm
phân cấp với các đặc trưng được chia tỷ lệ");
```

Khoảng cách dựa trên tương quan giữa các quan sát có thể được sử dụng để phân cụm. Tương quan giữa hai quan sát đo lường sự tương đồng của các giá trị đặc trưng của chúng.¹⁰ Với n quan sát, ma trận tương quan $n \times n$

¹⁰Giá sử mỗi quan sát có p đặc điểm, mỗi đặc điểm là một giá trị số duy nhất. Chúng ta đo lường sự tương đồng giữa hai quan sát như vậy bằng cách tính hệ số tương quan của p cặp số này.

546 12. Học không giám sát

Sau đó, nó có thể được sử dụng như một ma trận tương đồng (hoặc ái lực), tức là một trừ đi ma trận tương quan sẽ là ma trận khác biệt được sử dụng để phân cụm.

Lưu ý rằng việc sử dụng hệ số tương quan chỉ có ý nghĩa đối với dữ liệu có ít nhất ba đặc trưng, vì hệ số tương quan tuyệt đối giữa bất kỳ hai quan sát nào có phép đo trên hai đặc trưng luôn bằng một. Do đó, chúng ta sẽ phân cụm một tập dữ liệu ba chiều.

```
Trong [46]: X = np.random.standard_normal((30, 3))
corD = 1 - np.corrcoef(X) hc_cor =
HClust(linkage='complete', distance_threshold=0,
        n_clusters=None,
        metric='precomputed')
        hc_cor.fit(corD) linkage_cor =
compute_linkage(hc_cor)
fig, ax = plt.subplots(1, 1, figsize=(8, 8))
dendrogram(linkage_cor , ax=ax, **cargs) ax.set_title("Complete
Linkage with Correlation-Based Dissimilarity

");
```

12.5.4 Ví dụ về dữ liệu NCI60

Các kỹ thuật không giám sát thường được sử dụng trong phân tích dữ liệu bộ gen. Đặc biệt, PCA và phân cụm phân cấp là những công cụ phổ biến. Chúng tôi minh họa các kỹ thuật này trên dữ liệu vi mảng tế bào ung thư NCI60 , bao gồm 6830 phép đo biểu hiện gen trên 64 dòng tế bào ung thư.

```
Trong [47]: NCI60 = load_data('NCI60') nci_labels =
NCI60['labels'] nci_data = NCI60['data']
```

Mỗi dòng tế bào được dán nhãn với một loại ung thư. Chúng tôi không sử dụng các loại ung thư này trong quá trình thực hiện PCA và phân cụm, vì đây là các kỹ thuật không giám sát. Nhưng sau khi thực hiện PCA và phân cụm, chúng tôi sẽ kiểm tra xem mức độ phù hợp giữa các loại ung thư này với kết quả của các kỹ thuật không giám sát đó.

Dữ liệu có 64 hàng và 6830 cột.

```
Trong [48]: nci_data.shape
```

Ra ngoài[48]: (64, 6830)

Chúng ta bắt đầu bằng việc kiểm tra các loại ung thư đối với các dòng tế bào.

```
Trong [49]: nci_labels.value_counts()
```

Ra[49]: nhãn

NSCLC	9
THẦN	9
U hắc tố	8
NHÚ HOA	7
DAI TRỰC TRẮNG	7
BỆNH BẠCH CẦU	6
BƯỚNG TRỨNG	6

```

TUYẾN TIẾN LIỆT      5 2
K562A-repro          1
K562B-repro          1
MCF7A-repro          1
MCF7D-repro          1
KHÔNG RÕ             1
kiểu dữ liệu: int64
```

Phân tích thành phần chính (PCA) trên dữ liệu NCI60

Đầu tiên, chúng tôi thực hiện phân tích thành phần chính (PCA) trên dữ liệu sau khi chuẩn hóa các biến (gen) để có độ lệch chuẩn bằng một, mặc dù ở đây người ta có thể lập luận một cách hợp lý rằng tốt hơn là không nên chuẩn hóa các gen vì chúng được đo bằng cùng một đơn vị.

```
Trong [50]: scaler = StandardScaler() nci_scaled
           = scaler.fit_transform(nci_data) nci_pca = PCA() nci_scores =
           nci_pca.fit_transform(nci_scaled)
```

Bây giờ chúng ta sẽ vẽ biểu đồ một vài vectơ điểm thành phần chính đầu tiên để trực quan hóa dữ liệu. Các quan sát (dòng tế bào) tương ứng với một loại ung thư nhất định sẽ được vẽ bằng cùng một màu, để chúng ta có thể thấy mức độ tương đồng giữa các quan sát trong cùng một loại ung thư.

```
Trong [51]: cancer_types = list(np.unique(nci_labs))
           nci_groups = np.array([cancer_types.index(lab) for lab in
                                   nci_labs.values]) fig, axes =
           plt.subplots(1, 2, figsize=(15,6)) ax = axes[0]

           ax.scatter(nci_scores[:,0],
                       nci_scores[:,1],
                       c=nci_groups,
                       marker='o', s=50)


           ax.set_xlabel('PC1'); ax.set_ylabel('PC2') ax = axes[1]

           ax.scatter(nci_scores[:,0],
                       nci_scores[:,2],
                       c=nci_groups,
                       marker='o',
                       s=50)
           ax.set_xlabel('PC1'); ax.set_ylabel('PC3');
```

Các đồ thị kết quả được thể hiện trong Hình 12.17. Nhìn chung, các dòng tế bào tương ứng với cùng một loại ung thư có xu hướng có giá trị tương tự nhau trên một vài vectơ điểm thành phần chính đầu tiên. Điều này cho thấy các dòng tế bào từ cùng một loại ung thư có xu hướng có mức độ biểu hiện gen khá giống nhau.

Chúng ta cũng có thể vẽ biểu đồ phần trăm phương sai được giải thích bởi các thành phần chính cũng như phần trăm phương sai tích lũy được giải thích. Điều này tương tự như các biểu đồ chúng ta đã thực hiện trước đó cho dữ liệu `USArrests` .

```
Trong [52]: fig, axes = plt.subplots(1, 2, figsize=(15,6)) ax = axes[0] ticks =
           np.arange(nci_pca.n_components_)+1
```



HÌNH 12.17. Hình chiếu của 60 dòng tế bào ung thư NCI lên ba mặt phẳng đầu tiên. Các thành phần chính (nói cách khác, điểm số của ba thành phần chính đầu tiên). Nhìn chung, các quan sát thuộc về một loại ung thư duy nhất có xu hướng nằm gần nhau trong không gian chiều thấp này. Điều đó là không thể để trực quan hóa dữ liệu mà không cần sử dụng phương pháp giảm chiều như PCA, vì dựa trên tập dữ liệu đầy đủ, có thể có các biểu đồ phân tán, $\frac{6,830}{2}$ những không có biểu đồ nào trong số đó. Điều đó hẳn sẽ rất hữu ích.


```
ax.plot(ticks,
        nci_pca.explained_variance_ratio_,
        marker='o')
ax.set_xlabel('Thành phần chính');
ax.set_ylabel('PVE')
ax = trục[1]
ax.plot(ticks,
        nci_pca.explained_variance_ratio_.cumsum(),
        marker='o');
ax.set_xlabel('Thành phần chính')
ax.set_ylabel('PVE tích lũy');
```

Các đồ thị kết quả được thể hiện trong Hình 12.18.

Chúng ta thấy rằng, nhìn chung, bảy thành phần chính đầu tiên giải thích được khoảng... 40% sự biến động trong dữ liệu. Đây không phải là một tỷ lệ biến động lớn. Tuy nhiên, khi nhìn vào biểu đồ scree plot, chúng ta thấy rằng trong khi mỗi trong bảy điểm đầu tiên Các thành phần chính giải thích một lượng lớn phương sai, do đó có một sự giảm đáng kể về phương sai được giải thích bởi các thành phần chính tiếp theo. Tức là, có một khúc cua trong biểu đồ sau khoảng thành phần chính thứ bảy. Điều này cho thấy việc kiểm tra có thể không mang lại nhiều lợi ích. Hơn bảy thành phần chính (mặc dù ngay cả khi xem xét bảy thành phần chính) Các thành phần chính có thể khó xác định).

Phân nhóm các quan sát từ dữ liệu NCI60.

Chúng tôi hiện tiến hành phân cụm phân cấp các dòng tế bào trong dữ liệu NCI60. Sử dụng các phương pháp liên kết hoàn chỉnh, đơn lẻ và trung bình. Một lần nữa, mục tiêu là tìm ra để xác định xem các quan sát có phân nhóm thành các loại ung thư riêng biệt hay không. Khoảng cách Euclidean được sử dụng làm thước đo độ khác biệt. Đầu tiên, chúng ta viết một Hàm ngắn để tạo ra ba biểu đồ cây.



HÌNH 12.18. PVE của các thành phần chính của tế bào ung thư NCI60

Bộ dữ liệu vi mảng đường thẳng. Bên trái: hiển thị PVE của mỗi thành phần chính.

Bên phải: hiển thị PVE tích lũy của các thành phần chính. Tổng cộng, tất cả các thành phần chính giải thích 100% phương sai.

```
Trong [53]: def plot_nci(linkage, ax, cut=-np.inf):
    cargs = {'above_threshold_color': 'black',
             'ngưỡng màu': 'cát'}
    hc = HClust(n_clusters=None,
               distance_threshold=0,
               linkage=linkage.lower()).fit(nci_scaled)
    liên_kết_ = tính_toán_liên_kết(hc)
    biểu_đồ_cây(liên_kết_,
                ax=ax,
                nhãn = np.asarray(nci_labs),
                leaf_font_size=10,
                **cargs)
    ax.set_title('%s Linkage' % linkage)
    trả_về_hc
```

Hãy cùng vẽ biểu đồ kết quả của chúng ta.

```
Trong [54]: fig, axes = plt.subplots(3, 1, figsize=(15,30))
ax = axes[0]; hc_comp = plot_nci('Complete', ax)
ax = axes[1]; hc_avg = plot_nci('Trung bình', ax)
ax = axes[2]; hc_sing = plot_nci('Single', ax)
```

Kết quả được thể hiện trong Hình 12.19. Chúng ta thấy rằng sự lựa chọn liên kết

Điều này chắc chắn ảnh hưởng đến kết quả thu được. Thông thường, liên kết đơn sẽ có xu hướng để tạo ra các cụm kéo theo: các cụm rất lớn mà các quan sát riêng lẻ được gắn vào từng cái một.


Mặt khác, liên kết hoàn chỉnh và trung bình

có xu hướng tạo ra các cụm cân đối và hấp dẫn hơn. Vì lý do này, việc hoàn thành

và liên kết trung bình thường được ưa chuộng hơn liên kết đơn. Rõ ràng tế bào

Các đường biểu hiện trong cùng một loại ung thư có xu hướng tập trung lại với nhau, mặc dù...

Phân cụm không phải lúc nào cũng hoàn hảo. Chúng ta sẽ sử dụng phương pháp phân cụm phân cấp liên kết hoàn chỉnh cho các phân tích tiếp theo.



HÌNH 12.19. Dữ liệu vi màng dòng tế bào ung thư NCI60 , được phân cụm với Phương pháp liên kết trung bình, liên kết hoàn chỉnh và liên kết đơn, sử dụng khoảng cách Euclidean làm thước đo độ khác biệt. Liên kết hoàn chỉnh và liên kết trung bình có xu hướng tạo ra các cụm có kích thước đồng đều. trong khi liên kết đơn có xu hướng tạo ra các cụm mở rộng mà các lá đơn lẻ nằm trong đó. Được hợp nhất từng cái một.

Chúng ta có thể cắt biểu đồ cây ở độ cao sao cho thu được một số lượng cụm nhất định, chẳng hạn như bốn cụm:

```
Trong [55]: linkage_comp = compute_linkage(hc_comp)
comp_cut = cut_tree(linkage_comp , n_clusters=4).reshape(-1)
pd.crosstab(nci_labs['label'],
            pd.Series(comp_cut.reshape(-1), name='Complete'))
```

Có một số quy luật rõ ràng. Tất cả các dòng tế bào ung thư bạch cầu đều nằm trong một cụm, trong khi các dòng tế bào ung thư vú lại phân bố rải rác trên ba cụm khác nhau.

Chúng ta có thể vẽ một đường cắt trên biểu đồ cây để tạo ra bốn cụm này:

```
Trong [56]: fig, ax = plt.subplots(figsize=(10,10))
plot_nci('Complete', ax, cut=140)
ax.axhline(140, c='r', linewidth=4);
```

Hàm `axhline()` vẽ một đường thẳng nằm ngang trên bất kỳ hệ trục tọa độ hiện có nào. Tham số `140` vẽ một đường thẳng nằm ngang ở độ cao `140` trên biểu đồ cây; đây là độ cao tạo ra bốn cụm riêng biệt. Rất dễ dàng để kiểm chứng rằng các cụm kết quả giống với các cụm mà chúng ta thu được trong hàm `comp_cut`.

Trước đó, trong Mục 12.4.2, chúng tôi đã khẳng định rằng phân cụm K-means và phân cụm phân cấp với việc cắt biểu đồ cây để thu được cùng số lượng cụm có thể cho ra kết quả rất khác nhau. Vậy kết quả phân cụm phân cấp NCI60 này so sánh như thế nào với kết quả thu được nếu chúng ta thực hiện phân cụm K-means với $K = 4$?

```
Trong [57]: nci_kmeans = KMeans(n_clusters=4,
                               random_state=0,
                               n_init=20).fit(nci_scaled)
pd.crosstab(pd.Series(comp_cut, name='HClust'),
            pd.Series(nci_kmeans.labels_, name='K-means'))
```

```
Out[57]: K-means      0  1  2  3
HClust
0  28  3  9  0
1  7000
2  0008
3  0900
```

Chúng ta thấy rằng bốn cụm thu được bằng phương pháp phân cụm phân cấp và phân cụm K-means có phần khác nhau. Trước hết, chúng ta lưu ý rằng nhãn trong hai phương pháp phân cụm là tùy ý. Nghĩa là, việc hoán đổi mã định danh của cụm không làm thay đổi kết quả phân cụm. Ở đây, ta thấy Cụm 3 trong phân cụm K-means giống hệt với cụm 2 trong phân cụm phân cấp. Tuy nhiên, các cụm khác lại khác nhau: ví dụ, cụm 0 trong phân cụm K-means chứa một phần các quan sát được gán cho cụm 0 bởi phân cụm phân cấp, cũng như tất cả các quan sát được gán cho cụm 1 bởi phân cụm phân cấp.

Thay vì thực hiện phân cụm phân cấp trên toàn bộ ma trận dữ liệu, chúng ta cũng có thể thực hiện phân cụm phân cấp trên một vài vectơ điểm thành phần chính đầu tiên, coi những thành phần đầu tiên này như một phiên bản ít nhiễu hơn của dữ liệu.

552 12. Học không giám sát

```

Trong [58]: hc_pca = HClust(n_clusters=None,
                        distance_threshold=0,

                        linkage='complete' ).fit(nci_scores[:, :5])

linkage_pca = compute_linkage(hc_pca) fig, ax =
plt.subplots(figsize=(8,8)) dendrogram(linkage_pca,
labels=np.asarray(nci_labels),
    leaf_font_size=10,

    ax=ax,
    **cargs)
ax.set_title("Phân cụm phân cấp trên năm vectơ điểm đầu tiên") pca_labels =
pd.Series(cut_tree(linkage_pca, n_clusters=4).reshape(-1),
    name='Complete-PCA')
    pd.crosstab(nci_labels['label'],
pca_labels)

```

12.6 Bài tập

Khái niệm

1. Bài toán này liên quan đến thuật toán phân cụm K-means.



(a) Chứng minh (12.18).

(b) Dựa trên đẳng thức này, hãy lập luận rằng thuật toán phân cụm K-means (Thuật toán 12.2) làm giảm mục tiêu (12.17) ở mỗi lần lặp.

2. Giả sử chúng ta có bốn quan sát, từ đó ta tính toán ma trận độ khác biệt, được cho bởi

$$\begin{matrix}
 & 0.30.40.7 \\
 0.30.50.8 & \\
 0.40.50.45 & \\
 0.70.80.45 &
 \end{matrix}$$

Ví dụ, sự khác biệt giữa quan sát thứ nhất và thứ hai là 0,3, và sự khác biệt giữa quan sát thứ hai và thứ tư là 0,8.

(a) Dựa trên ma trận độ khác biệt này, hãy phác thảo biểu đồ cây (dendrogram) thu được từ việc phân cụm theo thứ bậc bốn quan sát này bằng phương pháp liên kết hoàn chỉnh. Hãy chắc chắn chỉ ra trên biểu đồ độ cao mà tại đó mỗi sự hợp nhất xảy ra, cũng như các quan sát tương ứng với mỗi nhánh trong biểu đồ cây.

(b) Lặp lại (a), lần này sử dụng phương pháp phân cụm liên kết đơn. (c)

Giả sử ta cắt biểu đồ cây thu được ở (a) sao cho tạo ra hai cụm. Những quan sát nào nằm trong mỗi cụm?

(d) Giả sử ta cắt biểu đồ cây thu được ở (b) sao cho tạo thành hai cụm. Những quan sát nào nằm trong mỗi cụm?

(e) Chương này có đề cập rằng tại mỗi điểm hợp nhất trong biểu đồ cây, vị trí của hai cụm được hợp nhất có thể được hoán đổi mà không làm thay đổi ý nghĩa của biểu đồ cây. Hãy vẽ một biểu đồ cây tương đương với biểu đồ cây trong (a), trong đó hai hoặc nhiều nhánh lá được định vị lại, nhưng ý nghĩa của biểu đồ cây vẫn giữ nguyên.

3. Trong bài toán này, bạn sẽ thực hiện phân cụm K-means thủ công, với $K = 2$, trên một ví dụ nhỏ gồm $n = 6$ quan sát và $p = 2$ đặc trưng. Các quan sát như sau.

Quan sát.	X1	X2	1	14
2	13			
3	04	4	51	5 62 6
40				

(a) Vẽ biểu đồ các quan sát. (b)

Gán ngẫu nhiên một nhãn cụm cho mỗi quan sát. Bạn có thể sử dụng hàm `np.random.choice()` để thực hiện việc này. Báo cáo các nhãn cụm cho mỗi quan sát.

(c) Tính toán tâm cụm cho mỗi cụm. (d) Gán mỗi quan

sát cho cụm gần nhất với nó, dựa trên khoảng cách Euclidean. Báo cáo nhãn cụm cho mỗi quan sát.

(e) Lặp lại (c) và (d) cho đến khi các kết quả thu được không còn

thay đổi nữa. (f) Trong biểu đồ của bạn từ (a), hãy tô màu các quan sát theo Đã thu được nhãn cụm.

4. Giả sử với một tập dữ liệu cụ thể, ta thực hiện phân cụm phân cấp bằng phương pháp liên kết đơn và phương pháp liên kết hoàn chỉnh. Ta thu được hai biểu đồ cây.

(a) Tại một điểm nhất định trên biểu đồ cây liên kết đơn, các cụm {1, 2, 3} và {4, 5} hợp nhất. Trên biểu đồ cây liên kết đầy đủ, các cụm {1, 2, 3} và {4, 5} cũng hợp nhất tại một điểm nhất định.

(a) Tại một điểm nhất định trên biểu đồ cây liên kết đơn, các cụm {5} và {6} hợp nhất. Trên biểu đồ cây liên kết hoàn chỉnh, các cụm {5} và {6} cũng

hợp nhất tại một điểm nhất định. Sự hợp nhất nào sẽ xảy ra ở vị trí cao hơn trên cây, hay chúng sẽ hợp nhất ở cùng một độ cao, hay không có đủ thông tin để xác định?

5. Hãy mô tả bằng lời kết quả mà bạn mong đợi nếu thực hiện phân cụm K-means đối với tám người mua sắm trong Hình 12.16, dựa trên việc họ mua tất và máy tính, với $K = 2$. Đưa ra ba câu trả lời, mỗi câu trả lời cho một trong các thang đo biến được hiển thị. Giải thích.

554 12. Học không giám sát

6. Chúng ta đã thấy trong Phần 12.2.2 rằng các vectơ tải và điểm thành phần chính cung cấp một phép xấp xỉ cho ma trận, theo nghĩa của (12.5). Cụ thể, các vectơ điểm và tải thành phần chính giải quyết bài toán tối ưu hóa được đưa ra trong (12.6).

Bây giờ, giả sử rằng M vectơ điểm thành phần chính $z_{im}, m = 1, \dots, M$, đã được biết. Sử dụng (12.6), hãy giải thích rằng mỗi trong số M vectơ tải thành phần chính đầu tiên $w_{jm}, m = 1, \dots, M$, có thể thu được bằng cách thực hiện p phép hồi quy tuyến tính bình phương tối thiểu riêng biệt. Trong mỗi phép hồi quy, các vectơ điểm thành phần chính là các biến dự đoán, và một trong các đặc trưng của ma trận dữ liệu là biến phản hồi.

Đã áp dụng

7. Trong chương này, chúng ta đã đề cập đến việc sử dụng khoảng cách dựa trên tương quan và khoảng cách Euclidean làm thước đo độ khác biệt cho phân cụm phân cấp. Thực tế cho thấy hai thước đo này gần như tương đương: nếu mỗi quan sát được chuẩn hóa để có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1, và nếu ta gọi r_{ij} là hệ số tương quan giữa quan sát thứ i và quan sát thứ j , thì đại lượng $1 - r_{ij}$ tỷ lệ thuận với bình phương khoảng cách Euclidean giữa quan sát thứ i và quan sát thứ j .

Dữ liệu về các vụ bắt giữ tại Mỹ cho thấy tỷ lệ này vẫn đúng.

Gợi ý: Khoảng cách Euclidean có thể được tính bằng cách sử dụng hàm `pairwise_distances()` từ mô-đun `sklearn.metrics`, và hệ số tương quan giữa các cặp có thể được tính bằng cách sử dụng hàm `np.corrcoef()`. `distances()`

8. Trong Mục 12.2.3, công thức tính PVE đã được đưa ra trong Phương trình 12.10.

Chúng ta cũng thấy rằng PVE có thể được tính bằng cách sử dụng thuộc tính `explained_variance_ratio_` của bộ ước lượng `PCA()` đã được hiệu chỉnh.

Trên dữ liệu `USArrests`, hãy tính PVE theo hai cách:

- (a) Sử dụng giá trị `explained_variance_ratio_` của bộ ước lượng `PCA()` đã được hiệu chỉnh, như đã thực hiện trong Phần 12.2.3. (b)

Bằng cách áp dụng trực tiếp Phương trình 12.10. Các hệ số tải được lưu trữ dưới dạng thuộc tính `components_` của bộ ước lượng `PCA()` đã được hiệu chỉnh. Sử dụng các hệ số tải đó trong Phương trình 12.10 để thu được PVE.

Hai phương pháp này sẽ cho kết quả như nhau.

Gợi ý: Bạn chỉ nhận được kết quả giống nhau ở (a) và (b) nếu sử dụng cùng một bộ dữ liệu trong cả hai trường hợp. Ví dụ, nếu ở (a) bạn đã thực hiện `PCA()` bằng cách sử dụng các biến đã được căn giữa và chuẩn hóa, thì bạn phải căn giữa và chuẩn hóa các biến trước khi áp dụng Phương trình 12.10 trong (b).

9. Hãy xem xét dữ liệu `USArrests`. Bây giờ chúng ta sẽ thực hiện phân cụm phân cấp trên các tiểu bang.

- (a) Sử dụng phân cụm phân cấp với liên kết hoàn chỉnh và Khoảng cách Euclidean, phân cụm các tiểu bang.
- (b) Vẽ biểu đồ cây ở độ cao sao cho tạo ra ba cụm riêng biệt. Các bang nào thuộc cụm nào?

(c) Phân cụm các tiểu bang theo thứ bậc bằng cách sử dụng liên kết hoàn chỉnh và khoảng cách Euclidean, sau khi chuẩn hóa các biến để có độ lệch chuẩn bằng một.

(d) Việc chuẩn hóa các biến có tác động như thế nào đến kết quả phân cụm phân cấp thu được? Theo bạn, có nên chuẩn hóa các biến trước khi tính toán sự khác biệt giữa các quan sát không?

Hãy đưa ra lý do giải thích cho câu trả lời của bạn.

10. Trong bài toán này, bạn sẽ tạo dữ liệu mô phỏng, sau đó thực hiện phân tích thành phần chính (PCA) và phân cụm K-means trên dữ liệu đó.

(a) Tạo một tập dữ liệu mô phỏng với 20 quan sát trong mỗi ba lớp (tức là tổng cộng 60 quan sát) và 50 biến.

Gợi ý: Có một số hàm trong `Python` mà bạn có thể sử dụng để tạo dữ liệu. Một ví dụ là phương thức `normal()` của hàm `random()` trong thư viện `'numpy'`; phương thức `uniform()` là một lựa chọn khác. Hãy nhớ thêm một sự dịch chuyển trung bình vào các quan sát trong mỗi lớp để có ba lớp khác biệt.

(b) Thực hiện phân tích thành phần chính (PCA) trên 60 quan sát và vẽ biểu đồ hai vectơ điểm thành phần chính đầu tiên. Sử dụng màu khác nhau để chỉ ra các quan sát trong mỗi ba lớp. Nếu ba lớp xuất hiện tách biệt trong biểu đồ này, hãy tiếp tục sang

phần (c). Nếu không, hãy quay lại phần (a) và sửa đổi mô phỏng để có sự tách biệt rõ ràng hơn giữa ba lớp. Không tiếp tục sang phần (c) cho đến khi ba lớp thể hiện ít nhất một số sự tách biệt trong hai vectơ điểm thành phần chính đầu tiên.

(c) Thực hiện phân cụm K-means các quan sát với $K = 3$.

Các cụm dữ liệu thu được từ thuật toán phân cụm K-means so sánh như thế nào với nhãn lớp thực tế?

Gợi ý: Bạn có thể sử dụng hàm `pd.crosstab()` trong `Python` để so sánh nhãn lớp thực với nhãn lớp thu được bằng cách phân cụm. Hãy cẩn thận khi diễn giải kết quả: Phân cụm K-means sẽ đánh số các cụm một cách tùy ý, vì vậy bạn không thể chỉ đơn giản kiểm tra xem nhãn lớp thực và nhãn phân cụm có giống nhau hay không. (d) Thực hiện phân cụm K-means với $K = 2$. Mô tả kết quả của bạn. (e) Bây giờ hãy thực hiện phân

cụm K-means với $K = 4$ và mô tả kết quả của bạn.

kết quả.

(f) Bây giờ hãy thực hiện phân cụm K-means với $K = 3$ trên hai vectơ điểm thành phần chính đầu tiên, thay vì trên dữ liệu thô.

Tức là, thực hiện phân cụm K-means trên ma trận 60×2 , trong đó cột đầu tiên là vectơ điểm thành phần chính thứ nhất và cột thứ hai là vectơ điểm thành phần chính thứ hai. Nhận xét về kết quả.

(g) Sử dụng bộ ước lượng `StandardScaler()`, thực hiện phân cụm K-means với $K = 3$ trên dữ liệu sau khi chuẩn hóa mỗi biến để có độ lệch chuẩn bằng một. So sánh kết quả này với kết quả thu được trong (b) như thế nào? Giải thích.

11. Viết một hàm **Python** để thực hiện việc hoàn thành ma trận như trong Thuật toán 12.1 và như đã nêu trong Mục 12.5.2. Trong mỗi lần lặp, Hàm này cần theo dõi sai số tương đối, cũng như số lần lặp. Quá trình lặp nên tiếp tục cho đến khi sai số tương đối nhỏ.

đủ hoặc cho đến khi đạt đến số lần lặp tối đa nào đó (đặt một (giá trị mặc định cho số lượng tối đa này). Hơn nữa, cần phải có Có thể thêm tùy chọn in ra tiến độ của mỗi lần lặp.

Hãy kiểm tra hàm của bạn trên tập dữ liệu **Boston**. Trước tiên, hãy chuẩn hóa các đặc trưng. để có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1 bằng cách sử dụng Hàm **StandardScaler()**. Chạy thử nghiệm trong đó bạn chọn ngẫu nhiên loại bỏ ngày càng nhiều (và lồng nhau) quan sát từ 5% đến 30%, với các bước tăng 5%. Áp dụng Thuật toán 12.1 với $M = 1, 2, \dots, 8$. Hiển thị sai số xấp xỉ theo tỷ lệ các quan sát bị thiếu và giá trị của M , được tính trung bình trên 10. các lần lặp lại thí nghiệm.

12. Trong Mục 12.5.2, Thuật toán 12.1 đã được triển khai bằng cách sử dụng Hàm **svd()** từ mô-đun **np.linalg**. Tuy nhiên, xét đến mối liên hệ giữa hàm **svd()** và bộ ước lượng **PCA()** đã được nêu bật trong bài thực hành, chúng ta cũng có thể đã triển khai thuật toán này. sử dụng **PCA()**.

Hãy viết một hàm để triển khai Thuật toán 12.1 sử dụng **PCA()**. thay vì sử dụng **svd()**.

13. Trên trang web của cuốn sách, www.statlearning.com, Có một tập dữ liệu biểu hiện gen (**Ch12Ex13.csv**) bao gồm 40 mẫu mô với Đo lường trên 1.000 gen. 20 mẫu đầu tiên là từ người khỏe mạnh. 20 người còn lại thuộc nhóm bệnh nhân, trong khi 20 người kia thuộc nhóm bệnh nhân mắc bệnh.

- Tải dữ liệu bằng cách sử dụng **pd.read_csv()**. Bạn sẽ cần phải chọn **Tiêu đề = Không có**.
- Áp dụng phân cụm phân cấp cho các mẫu bằng cách sử dụng khoảng cách dựa trên tương quan và vẽ biểu đồ cây. Các gen có tách biệt nhau không? Bạn có thể chia các mẫu thành hai nhóm không? Kết quả của bạn có phụ thuộc vào... Loại liên kết được sử dụng là gì?
- Cộng sự của bạn muốn biết những gen nào khác biệt nhiều nhất. giữa hai nhóm. Hãy đề xuất một cách để trả lời câu hỏi này. và áp dụng nó ở đây.

13



Kiểm tra nhiều lần

Cho đến nay, sách giáo khoa này chủ yếu tập trung vào ước lượng và người anh em họ gần gũi của nó, dự đoán. Trong chương này, chúng ta sẽ tập trung vào kiểm định giả thuyết, vốn là chìa khóa để thực hiện suy luận. Chúng tôi nhắc lại với người đọc rằng suy luận đã được thảo luận ngắn gọn trong Chương 2.

Trong khi Mục 13.1 cung cấp một bài tổng quan ngắn gọn về giả thuyết không, giá trị p , thống kê kiểm định và các ý tưởng quan trọng khác trong kiểm định giả thuyết, chương này giả định rằng người đọc đã từng tiếp xúc với các chủ đề này trước đây. Đặc biệt, chúng ta sẽ không tập trung vào lý do tại sao hoặc cách thức tiến hành kiểm định giả thuyết – một chủ đề mà có thể (và đã) viết cả một cuốn sách! Thay vào đó, chúng ta sẽ giả định rằng người đọc quan tâm đến việc kiểm định một tập hợp các giả thuyết không cụ thể và có một kế hoạch cụ thể trong đầu về cách tiến hành các kiểm định và thu được giá trị p .

Phần lớn sự nhấn mạnh trong thống kê cổ điển tập trung vào việc kiểm định một giả thuyết không duy nhất, chẳng hạn như H_0 : huyết áp dự kiến của chuột trong nhóm đối chứng bằng huyết áp dự kiến của chuột trong nhóm điều trị. Tất nhiên, chúng ta có lẽ muốn phát hiện ra rằng có sự khác biệt giữa huyết áp trung bình ở hai nhóm. Nhưng vì những lý do sẽ được làm rõ sau, chúng ta xây dựng một giả thuyết không tương ứng với việc không có sự khác biệt.

Trong bối cảnh hiện đại, chúng ta thường phải đối mặt với lượng dữ liệu khổng lồ, và do đó có thể muốn kiểm tra rất nhiều giả thuyết không.

Ví dụ, thay vì chỉ kiểm định H_0 , chúng ta có thể muốn kiểm định m giả thuyết không, $H_{01}, \dots, H_{0m}$, trong đó H_{0j} : giá trị kỳ vọng của chỉ số sinh học thứ j ở nhóm chuột đối chứng bằng giá trị kỳ vọng của chỉ số sinh học thứ j ở nhóm chuột điều trị. Khi tiến hành kiểm định đa giả thuyết, chúng ta cần hết sức cẩn thận trong cách diễn giải kết quả để tránh bác bỏ sai quá nhiều giả thuyết không.

Chương này thảo luận về các phương pháp cổ điển cũng như hiện đại hơn để tiến hành kiểm thử đa biến trong môi trường dữ liệu lớn. Trong Phần 13.2, chúng tôi nêu bật những thách thức liên quan đến kiểm thử đa biến. Các giải pháp cổ điển cho những thách thức này

Các thách thức được trình bày trong Phần 13.3, và các giải pháp hiện đại hơn. trong Mục 13.4 và 13.5.

Cụ thể, Mục 13.4 tập trung vào tỷ lệ phát hiện sai. Khái niệm về tỷ lệ phát hiện sai xuất hiện từ những năm 1990. Nó nhanh chóng trở nên phổ biến trong sự phổ biến vào đầu những năm 2000, khi các bộ dữ liệu quy mô lớn bắt đầu xuất hiện. về hệ gen học. Các tập dữ liệu này độc đáo không chỉ vì quy mô lớn của chúng. kích thước,1 nhưng cũng bởi vì chúng thường được thu thập cho mục đích khám phá : các nhà nghiên cứu đã thu thập các tập dữ liệu này để kiểm tra một số lượng lớn của các giả thuyết không, chứ không chỉ một số lượng rất nhỏ các giả thuyết được xác định trước. giả thuyết không. Ngày nay, tất nhiên, các tập dữ liệu khổng lồ được thu thập mà không cần giả thuyết không được xác định trước trong hầu hết mọi lĩnh vực. Như chúng ta sẽ thấy, Tỷ lệ phát hiện sai hoàn toàn phù hợp với thực tế hiện đại ngày nay.

Chương này tập trung chủ yếu vào kỹ thuật thống kê cổ điển về Giá trị p, được sử dụng để định lượng kết quả của các bài kiểm định giả thuyết. Vào thời điểm đó Kể từ khi viết cuốn sách này (năm 2020), giá trị p gần đây đã trở thành chủ đề được bình luận rộng rãi trong cộng đồng nghiên cứu khoa học xã hội, đến mức độ... Một số tạp chí khoa học xã hội thậm chí còn cấm sử dụng... Tóm lại, giá trị p! Chúng ta chỉ cần nhận xét rằng, khi được hiểu và áp dụng đúng cách, giá trị p là một công cụ mạnh mẽ để đưa ra các kết luận suy luận. Kết luận rút ra từ dữ liệu của chúng tôi.

13.1 Tổng quan nhanh về kiểm định giả thuyết

Kiểm định giả thuyết cung cấp một khuôn khổ thống kê chặt chẽ để trả lời Những câu hỏi đơn giản dạng "có hay không" về dữ liệu, ví dụ như sau:

- 1. Hệ số thực βj trong hồi quy tuyến tính của Y theo X1,...,Xp có phải là...? bằng không?2
- 2. Có sự khác biệt nào về huyết áp dự kiến ở chuột thí nghiệm không? ở nhóm đối chứng và chuột thí nghiệm ở nhóm điều trị?3

Trong Mục 13.1.1, chúng ta sẽ xem xét ngắn gọn các bước liên quan đến kiểm định giả thuyết. Mục 13.1.2 sẽ thảo luận về các loại sai lầm khác nhau mà có thể xảy ra trong quá trình kiểm định giả thuyết.

13.1.1 Kiểm định giả thuyết

Việc tiến hành kiểm định giả thuyết thường diễn ra theo bốn bước. Đầu tiên, chúng ta xác định giả thuyết null và giả thuyết thay thế. Tiếp theo, chúng ta xây dựng thống kê kiểm định. Điều đó tóm tắt sức mạnh của bằng chứng chống lại giả thuyết không. Chúng ta sau đó tính giá trị p, giá trị này định lượng xác suất đã đạt được

Dữ liệu microarray được xem là "dữ liệu lớn" vào thời điểm đó, mặc dù theo tiêu chuẩn hiện nay, Nhân này nghe có vẻ cổ điển: một tập dữ liệu microarray có thể được (và thường được) lưu trữ trong một Bảng tính Microsoft Excel!

2. Bài kiểm tra giả thuyết này đã được thảo luận ở trang 76 của Chương 3.

3. "Nhóm điều trị" là nhóm chuột được nhận phương pháp điều trị thử nghiệm, còn "nhóm đối chứng" là nhóm chuột không được nhận phương pháp điều trị đó.

một giá trị tương đương hoặc cực đoan hơn của thống kê kiểm định dưới giả thuyết không. Cuối cùng, dựa trên giá trị p , chúng ta quyết định có bác bỏ giả thuyết không hay không. Bây giờ chúng ta sẽ thảo luận ngắn gọn từng bước này.

Bước 1: Xác định giả thuyết không và giả thuyết thay thế

Trong kiểm định giả thuyết, chúng ta chia thế giới thành hai khả năng: giả thuyết không và giả thuyết thay thế. Giả thuyết không, được ký hiệu là H_0 , là trạng thái niềm tin mặc định về thế giới. Ví dụ, các giả thuyết không liên quan đến hai câu hỏi được nêu ra trước đó trong chương này như sau:

- 1. Hệ số thực β_j trong hồi quy tuyến tính của Y theo $X_1, \dots, X_p$ bằng không.
- 2. Không có sự khác biệt giữa huyết áp dự kiến của chuột trong nhóm đối chứng và nhóm điều trị.

Giả thuyết không về bản chất khá nhàm chán: nó có thể đúng, nhưng chúng ta có thể hy vọng rằng dữ liệu sẽ cho thấy điều ngược lại.

Giả thuyết thay thế, được ký hiệu là H_a , biểu thị một điều gì đó khác biệt và không ngờ tới: ví dụ, có sự khác biệt giữa huyết áp dự kiến của chuột trong hai nhóm. Thông thường, giả thuyết thay thế chỉ đơn giản khẳng định rằng giả thuyết không không đúng: nếu giả thuyết không nói rằng không có sự khác biệt giữa A và B , thì giả thuyết thay thế nói rằng có sự khác biệt giữa A và B .


Điều quan trọng cần lưu ý là quá trình xử lý H_0 và H_a không đối xứng. Giả thuyết H_0 được coi là trạng thái mặc định của thế giới, và chúng ta tập trung vào việc sử dụng dữ liệu để bác bỏ H_0 . Nếu chúng ta bác bỏ H_0 , điều này sẽ cung cấp bằng chứng ủng hộ giả thuyết thay thế (H_a). Chúng ta có thể coi việc bác bỏ H_0 như việc khám phá ra điều gì đó về dữ liệu của mình: cụ thể là, chúng ta đang phát hiện ra rằng H_0 không đúng! Ngược lại, nếu chúng ta không bác bỏ H_0 , thì kết quả của chúng ta sẽ mơ hồ hơn: chúng ta sẽ không biết liệu chúng ta không bác bỏ H_0 là do kích thước mẫu quá nhỏ (trong trường hợp đó, việc kiểm tra lại H_0 trên một tập dữ liệu lớn hơn hoặc chất lượng cao hơn có thể dẫn đến việc bác bỏ), hay liệu chúng ta không bác bỏ H_0 là vì H_0 thực sự đúng.

Bước 2: Xây dựng thống kê kiểm định

Tiếp theo, chúng ta muốn sử dụng dữ liệu của mình để tìm bằng chứng ủng hộ hoặc phản bác giả thuyết không. Để làm được điều này, chúng ta phải tính toán một thống kê kiểm định, được ký hiệu là T , tóm tắt mức độ phù hợp của dữ liệu với H_0 . Cách chúng ta xây dựng T phụ thuộc vào bản chất của giả thuyết không mà chúng ta đang kiểm định.

Để cụ thể hơn, hãy đặt $x_1, \dots, x_{n_t}$ ký hiệu x_t là các phép đo huyết áp của chuột n_t trong nhóm điều trị, và $x_{c_1}, \dots, x_{c_{n_c}}$ là các phép đo huyết áp của chuột n_c trong nhóm đối chứng, và $\mu_t = E(X_t)$, $\mu_c = E(X_c)$. Để kiểm tra $H_0 : \mu_t = \mu_c$, chúng ta sử dụng thống kê t hai mẫu được định nghĩa như sau :

⁴ H_0 được phát âm là "H naught" hoặc "H zero".



HÌNH 13.1. Hàm mật độ cho phân phối $N(0, 1)$, với đường thẳng đứng biểu thị giá trị 2,33.

1% diện tích dưới đường cong nằm ở

bên phải đường thẳng đứng, vì vậy chỉ có 2% khả năng quan sát được giá trị $N(0, 1)$

lớn hơn 2,33 hoặc nhỏ hơn -2,33. Do đó, nếu một thống kê kiểm định có giá trị lớn hơn 2,33 hoặc nhỏ hơn -2,33.

Nếu phân phối chuẩn $N(0, 1)$, thì thống kê kiểm định quan sát được là $T = 2,33$ dẫn đến giá trị p là 0,02.

$$T = \frac{\bar{\mu}^t - \bar{\mu}^c}{S \sqrt{\frac{1}{nt} + \frac{1}{nc}}} \quad (13.1)$$

trong đó $\bar{\mu}^t = \frac{1}{nt} \sum_{i=1}^{nt} x_{t_{i_{\text{tot}}}}$, $\bar{\mu}^c = \frac{1}{nc} \sum_{i=1}^{nc} x_{c_i}$ và

$$S = \sqrt{\frac{(nt-1)s_t^2 + (nc-1)s_c^2}{nt + nc - 2}} \quad (13.2)$$

là một ước lượng của độ lệch chuẩn gộp của hai mẫu. Ở đây,

s_t^2 và s_c^2 là các ước lượng không thiên lệch về phương sai của huyết áp trong

lần lượt là nhóm điều trị và nhóm đối chứng. Một giá trị (tuyệt đối) lớn của

T cung cấp bằng chứng chống lại $H_0: \mu_t = \mu_c$, và do đó cung cấp bằng chứng ủng hộ giả thuyết này.

của $H_a: \mu_t \neq \mu_c$.

Bước 3: Tính giá trị p

Trong phần trước, chúng ta đã lưu ý rằng giá trị tuyệt đối lớn của thống kê t hai mẫu cung cấp bằng chứng chống lại giả thuyết H_0 . Điều này đặt ra câu hỏi: làm thế nào "Lớn" nghĩa là lớn? Nói cách khác, có bao nhiêu bằng chứng chống lại giả thuyết H_0 được cung cấp với một giá trị nhất định của thống kê kiểm định?

Khái niệm về giá trị p cung cấp cho chúng ta một cách để chính thức hóa cũng như trả lời câu hỏi này. Giá trị p được định nghĩa là xác suất quan sát được một thống kê kiểm định bằng hoặc cực đoan hơn thống kê quan sát được, trong điều kiện giả định rằng H_0 thực sự đúng. Do đó, giá trị p nhỏ cung cấp bằng chứng chống lại H_0 .

5. Thống kê t có tên gọi như vậy vì, dưới giả thuyết H_0 , nó tuân theo phân phối t -phân bố.

6. Lưu ý rằng (13.2) giả định rằng nhóm kiểm soát và nhóm điều trị có phương sai bằng nhau. Nếu không có giả định này, (13.2) sẽ có dạng hơi khác.

Để làm rõ điều này, giả sử $T = 2,33$ đối với thống kê kiểm định trong (13.1). Khi đó, chúng ta có thể hỏi: xác suất quan sát được giá trị T lớn như vậy là bao nhiêu, nếu thực sự H_0 đúng? Hóa ra, dưới H_0 , phân phối của T trong (13.1) xấp xỉ theo phân phối $N(0, 1)$ – tức là phân phối chuẩn với trung bình 0 và phương sai 1. Phân phối này được hiển thị trong Hình 13.1. Chúng ta thấy rằng phần lớn – 98% – của phân phối $N(0, 1)$ nằm giữa $-2,33$ và $2,33$. Điều này có nghĩa là dưới H_0 , chúng ta chỉ mong đợi thấy giá trị $|T|$ lớn như vậy trong 2% trường hợp.

Do đó, giá trị p tương ứng với $T = 2,33$ là 0,02.

Phân bố của thống kê kiểm định dưới giả thuyết H_0 (còn được gọi là phân bố dưới giả thuyết không của thống kê kiểm định) sẽ phụ thuộc vào chi tiết của loại giả thuyết không đang được kiểm định và loại thống kê kiểm định được sử dụng. Nói chung, hầu hết các thống kê kiểm định thường được sử dụng đều tuân theo một phân bố thống kê quen thuộc dưới giả thuyết không – chẳng hạn như phân bố chuẩn, phân bố t , phân bố χ^2 hoặc phân bố F – với điều kiện kích thước mẫu đủ lớn và một số giả định khác được đáp ứng.

Thông thường, hàm R được sử dụng để tính toán thống kê kiểm định sẽ sử dụng phân phối giả thuyết không này để xuất ra giá trị p . Trong Phần 13.5, chúng ta sẽ xem xét một phương pháp ước tính phân phối giả thuyết không của thống kê kiểm định bằng cách sử dụng phương pháp lấy mẫu lại; trong nhiều trường hợp hiện nay, đây là một lựa chọn rất hấp dẫn, vì nó tận dụng được sự sẵn có của các máy tính tốc độ cao để tránh phải đưa ra những giả định có thể gây ra vấn đề về dữ liệu.

Giá trị p có lẽ là một trong những khái niệm được sử dụng và lạm dụng nhiều nhất trong toàn bộ thống kê. Cụ thể, đôi khi người ta nói rằng giá trị p là xác suất mà H_0 đúng, tức là giả thuyết không đúng. Điều này không chính xác!

Cách giải thích duy nhất và chính xác của giá trị p là tỷ lệ thời gian mà chúng ta dự kiến sẽ thấy giá trị cực đoan như vậy của thống kê kiểm định nếu chúng ta lặp lại thí nghiệm nhiều lần, với điều kiện giả thuyết H_0 đúng.

Ở Bước 2, chúng ta đã tính toán một thống kê kiểm định và nhận thấy rằng giá trị tuyệt đối lớn của thống kê kiểm định cung cấp bằng chứng chống lại giả thuyết H_0 . Ở Bước 3, thống kê kiểm định được chuyển đổi thành giá trị p , với các giá trị p nhỏ cung cấp bằng chứng chống lại H_0 . Vậy thì, chúng ta đã đạt được điều gì bằng cách chuyển đổi thống kê kiểm định từ Bước 2 thành giá trị p ở Bước 3? Để trả lời câu hỏi này, giả sử một nhà phân tích dữ liệu tiến hành một kiểm định thống kê và báo cáo thống kê kiểm định là $T = 17,3$. Liệu điều này có cung cấp bằng chứng mạnh mẽ chống lại H_0 ? Không thể biết được nếu không có thêm thông tin: cụ thể, chúng ta cần phải biết

⁷Chính xác hơn, giả sử các quan sát được lấy từ phân phối chuẩn, thì T tuân theo phân phối t với $nt + nc - 2$ bậc tự do. Với điều kiện $nt + nc - 2$ lớn hơn khoảng 40, điều này được xấp xỉ rất tốt bởi phân phối $N(0, 1)$.

Trong Phần 13.5, chúng ta sẽ xem xét một cách tiếp cận khác, thường hấp dẫn hơn, để xấp xỉ phân phối chuẩn của T , tránh đưa ra những giả định khắt khe về dữ liệu.

8. Giá trị p một phía là xác suất nhìn thấy giá trị cực đoan như vậy của thống kê kiểm định; ví dụ: xác suất nhìn thấy thống kê kiểm định lớn hơn hoặc bằng $T = 2,33$.

Giá trị p hai phía là xác suất nhìn thấy giá trị cực đoan như vậy của thống kê kiểm định tuyệt đối; ví dụ: xác suất nhìn thấy thống kê kiểm định lớn hơn hoặc bằng 2,33 hoặc nhỏ hơn hoặc bằng -2,33. Khuyến nghị mặc định là báo cáo giá trị p hai phía thay vì giá trị p một phía, trừ khi có lý do rõ ràng và thuyết phục rằng chỉ một chiều của thống kê kiểm định mới có ý nghĩa khoa học.

		Sự thật	
		H0	Ha
Phán quyết	Bác bỏ H0	Lỗi loại I	Chính xác
	Không bác bỏ H0	Chính xác	Lỗi loại II

BẢNG 13.1. Tóm tắt các kịch bản có thể xảy ra khi kiểm định giả thuyết không H0. Sai lầm loại I còn được gọi là dương tính giả, và sai lầm loại II là âm tính giả.

Giá trị nào của thống kê kiểm định nên được kỳ vọng, dưới giả thuyết H0. Đây chính xác là điều mà giá trị p cung cấp cho chúng ta. Nói cách khác, giá trị p cho phép chúng ta chuyển đổi thống kê kiểm định, được đo trên một thang đo tùy ý và khó hiểu, thành một con số nằm giữa 0 và 1 có thể dễ hiểu hơn.

Bước 4: Quyết định có bác bỏ giả thuyết null hay không Sau khi đã

tính toán giá trị p tương ứng với H0, điều còn lại là chúng ta quyết định có bác bỏ H0 hay không. (Thông thường chúng ta không nói về việc “chấp nhận” H0: thay vào đó, chúng ta nói về việc “không bác bỏ” H0.) Giá trị p nhỏ cho thấy rằng giá trị lớn như vậy của thống kê kiểm định khó có thể xảy ra dưới giả thuyết H0, và do đó cung cấp bằng chứng chống lại H0. Nếu giá trị p đủ nhỏ, thì chúng ta sẽ muốn bác bỏ H0 (và do đó, thực hiện một “phát hiện”). Nhưng nhỏ đến mức nào là đủ nhỏ để bác bỏ H0?

Hóa ra câu trả lời cho câu hỏi này phụ thuộc rất nhiều vào quan điểm của người nhìn nhận, hay cụ thể hơn là của nhà phân tích dữ liệu. Giá trị p càng nhỏ, bằng chứng chống lại giả thuyết H0 càng mạnh. Trong một số lĩnh vực, người ta thường bác bỏ H0 nếu giá trị p nhỏ hơn 0,05; điều này có nghĩa là, nếu H0 đúng, chúng ta sẽ chỉ thấy giá trị p nhỏ như vậy không quá 5% thời gian.⁹ Tuy nhiên, trong các lĩnh vực khác, cần có bằng chứng thuyết phục hơn nhiều: ví dụ, trong một số lĩnh vực vật lý, người ta thường chỉ bác bỏ H0 nếu giá trị p nhỏ hơn 10⁻⁹!

Trong ví dụ minh họa ở Hình 13.1, nếu ta sử dụng ngưỡng 0,05 làm điểm cắt để bác bỏ giả thuyết null, thì ta sẽ bác bỏ giả thuyết null. Ngược lại, nếu ta sử dụng ngưỡng 0,01, thì ta sẽ không bác bỏ giả thuyết null. Những ý tưởng này sẽ được trình bày chi tiết hơn ở phần tiếp theo.

13.1.2 Lỗi loại I và lỗi loại II

Nếu giả thuyết không đúng, thì ta nói đó là giả thuyết không đúng; ngược lại, đó là giả thuyết không sai. Ví dụ, nếu ta kiểm định H0 : $\mu_t = \mu_c$ như trong Mục 13.1.1, và thực sự không có sự khác biệt về huyết áp trung bình của quần thể chuột trong nhóm điều trị và chuột trong nhóm đối chứng, thì H0 là đúng; ngược lại, nó là sai. Tất nhiên, chúng ta không biết trước liệu H0 là đúng hay sai: đó là lý do tại sao chúng ta cần tiến hành kiểm định giả thuyết!

giả thuyết
không đúng
giả thuyết
không sai

Mặc dù ngưỡng 0,05 để bác bỏ giả thuyết H0 rất phổ biến trong một số lĩnh vực khoa học, chúng tôi khuyên không nên tuân thủ một cách mù quáng theo lựa chọn tùy ý này. Hơn nữa, nhà phân tích dữ liệu thường nên báo cáo giá trị p, chứ không chỉ báo cáo xem nó có vượt quá một ngưỡng giá trị cụ thể hay không.

Bảng 13.1 tóm tắt các kịch bản có thể xảy ra liên quan đến việc kiểm định giả thuyết. Sau khi Bảng thống kê giả thuyết ¹⁰ kiểm định giả thuyết được thực hiện, hàng của bảng sẽ hiển thị kết quả. không H_0 đã biết (dựa trên việc chúng ta có bác bỏ H_0 hay không); tuy nhiên, chúng ta không thể biết mình đang ở cột nào . Nếu chúng ta bác bỏ H_0 khi H_0 sai (tức là khi H_0 đúng), hoặc nếu chúng ta không bác bỏ H_0 khi nó đúng, thì chúng ta đã có kết quả đúng. Tuy nhiên, nếu chúng ta bác bỏ H_0 một cách sai lầm khi H_0 thực sự đúng, thì chúng ta đã mắc lỗi loại I. Tỷ lệ lỗi loại I được định nghĩa là xác suất mắc lỗi loại I khi H_0 đúng , tức là xác suất bác bỏ H_0 một cách sai lầm. Nói cách khác, nếu chúng ta không bác bỏ H_0 khi H_0 thực sự sai, thì chúng ta đã mắc lỗi loại II. Độ mạnh của kiểm định giả thuyết được định nghĩa là xác suất không mắc lỗi loại II khi H_0 đúng, tức là xác suất bác bỏ H_0 một cách chính xác.

Lỗi loại I
Tỷ lệ lỗi loại I

Lỗi II
lỗi
quyền lực

Lý tưởng nhất là chúng ta muốn cả tỷ lệ lỗi loại I và lỗi loại II đều nhỏ. Nhưng trên thực tế, điều này rất khó đạt được! Thường có sự đánh đổi: chúng ta có thể giảm thiểu sai lầm loại I bằng cách chỉ bác bỏ H_0 nếu chúng ta hoàn toàn chắc chắn rằng nó không đúng; tuy nhiên, điều này sẽ dẫn đến sự gia tăng sai lầm loại II. Hoặc, chúng ta có thể giảm thiểu sai lầm loại II bằng cách bác bỏ H_0 ngay cả khi có bằng chứng khiêm tốn cho thấy nó không đúng, nhưng điều này sẽ khiến sai lầm loại I lớn. Trên thực tế, chúng ta thường coi sai lầm loại I "nghiêm trọng" hơn sai lầm loại II, bởi vì sai lầm loại I liên quan đến việc tuyên bố một phát hiện khoa học không chính xác. Do đó, khi thực hiện kiểm định giả thuyết, chúng ta thường yêu cầu tỷ lệ sai lầm loại I thấp – ví dụ, tối đa $\alpha = 0,05$ – trong khi cố gắng giảm thiểu sai lầm loại II (hoặc tương đương, tăng độ mạnh của kiểm định).

Hóa ra có mối tương quan trực tiếp giữa ngưỡng giá trị p khiến chúng ta bác bỏ giả thuyết H_0 và tỷ lệ sai lầm loại I. Bằng cách chỉ bác bỏ H_0 khi giá trị p nhỏ hơn α , chúng ta đảm bảo rằng tỷ lệ sai lầm loại I sẽ nhỏ hơn hoặc bằng α .

13.2 Thách thức của việc kiểm thử đa lớp

Trong phần trước, chúng ta đã thấy rằng việc bác bỏ H_0 nếu giá trị p nhỏ hơn (ví dụ) 0,01 cung cấp cho chúng ta một cách đơn giản để kiểm soát lỗi loại I đối với H_0 ở mức ý nghĩa 0,01: nếu H_0 đúng, thì xác suất chúng ta bác bỏ nó không quá 1%. Nhưng bây giờ giả sử chúng ta muốn kiểm định m giả thuyết không, $H_{01}, \dots, H_{0m}$. Liệu việc đơn giản bác bỏ tất cả các giả thuyết không mà giá trị p tương ứng nhỏ hơn (ví dụ) 0,01 có đủ không? Nói cách khác, nếu chúng ta bác bỏ tất cả các giả thuyết không mà giá trị p nhỏ hơn 0,01, thì chúng ta nên dự kiến sẽ mắc bao nhiêu lỗi loại I?

Bước đầu tiên để trả lời câu hỏi này, hãy xem xét một nhà môi giới chứng khoán muốn thu hút khách hàng mới bằng cách thuyết phục họ về hoạt động giao dịch của mình.

¹⁰Có những điểm tương đồng giữa Bảng 13.1 và Bảng 4.6, liên quan đến kết quả của bộ phân loại nhị phân. Cụ thể, hãy nhớ lại từ Bảng 4.6 rằng kết quả dương tính giả xảy ra khi dự đoán nhãn dương (không rỗng) trong khi nhãn thực tế là âm (rỗng). Điều này có liên quan chặt chẽ đến lỗi loại I, xảy ra khi bác bỏ giả thuyết không trong khi thực tế giả thuyết không đúng.

Sự nhảy bèn. Cô ấy nói với 1.024 (1.024 = 210) khách hàng tiềm năng rằng cô ấy có thể dự đoán chính xác liệu giá cổ phiếu của Apple sẽ tăng hay giảm trong 10 ngày liên tiếp. Có 210 khả năng giá cổ phiếu của Apple có thể thay đổi như thế nào trong 10 ngày này. Vì vậy, cô ấy gửi email cho mỗi khách hàng một trong 210 khả năng đó. Phần lớn khách hàng tiềm năng của cô ấy sẽ thấy rằng dự đoán của nhà môi giới chứng khoán không tốt hơn so với sự ngẫu nhiên (và nhiều người thậm chí còn thấy chúng tệ hơn cả sự ngẫu nhiên). Nhưng một chiếc đồng hồ hồng vẫn đúng giờ hai lần một ngày, và một trong những khách hàng tiềm năng của cô ấy sẽ thực sự ấn tượng khi thấy rằng dự đoán của cô ấy đã đúng trong cả 10 ngày! Và như vậy, nhà môi giới chứng khoán có thêm một khách hàng mới.

Chuyện gì đã xảy ra ở đây? Liệu người môi giới chứng khoán này có thực sự hiểu được liệu giá cổ phiếu của Apple sẽ tăng hay giảm không? Không. Vậy thì, làm thế nào mà bà ta lại có thể dự đoán chính xác giá cổ phiếu của Apple trong suốt 10 ngày liên tiếp? Câu trả lời là cô ấy đã đưa ra rất nhiều phỏng đoán, và một trong số đó tình cờ lại hoàn toàn chính xác.

Điều này liên quan đến kiểm định đa biến như thế nào? Giả sử chúng ta tung 1.024 đồng xu công bằng¹¹, mỗi đồng 10 lần. Khi đó, chúng ta sẽ kỳ vọng (trung bình) một đồng xu sẽ ra toàn mặt sấp. (Xác suất để bất kỳ đồng xu nào ra toàn mặt sấp là $1/2^{10} = 1/1.024$. Vì vậy, nếu chúng ta tung 1.024 đồng xu, thì trung bình chúng ta kỳ vọng một đồng xu sẽ ra toàn mặt sấp.) Nếu một trong những đồng xu của chúng ta ra toàn mặt sấp, thì chúng ta có thể kết luận rằng đồng xu đó không công bằng. Trên thực tế, một kiểm định giả thuyết tiêu chuẩn cho giả thuyết không rằng đồng xu đó là công bằng sẽ dẫn đến giá trị p nhỏ hơn 0,002!

¹² Nhưng sẽ là không chính xác nếu kết

luận rằng đồng xu không công bằng: trên thực tế, giả thuyết không vẫn đúng, và chúng ta chỉ tình cờ nhận được mười mặt đười liên tiếp một cách ngẫu nhiên.

Những ví dụ này minh họa thách thức chính của việc kiểm định đa biến: khi kiểm định một số lượng lớn giả thuyết null, chắc chắn chúng ta sẽ nhận được một số giá trị p rất nhỏ do ngẫu nhiên. Nếu chúng ta đưa ra quyết định về việc bác bỏ từng giả thuyết null mà không tính đến thực tế là chúng ta đã thực hiện một số lượng lớn các phép thử, thì cuối cùng chúng ta có thể bác bỏ một số lượng lớn các giả thuyết null đúng – tức là, mắc một số lượng lớn lỗi loại I.

kiểm tra
nhiều lần

Vấn đề nghiêm trọng đến mức nào? Hãy nhớ lại phần trước rằng nếu ta bác bỏ một giả thuyết không duy nhất, H_0 , nếu giá trị p của nó nhỏ hơn, chẳng hạn, $\alpha = 0,01$, thì có 1% khả năng bác bỏ sai nếu H_0 thực sự đúng.

Vậy nếu ta kiểm tra m giả thuyết không, $H_{01}, \dots, H_{0m}$, tất cả đều đúng thì sao? Xác suất bác bỏ bất kỳ giả thuyết null nào là 1%; do đó, chúng ta dự kiến sẽ bác bỏ sai khoảng $0,01 \times m$ giả thuyết null. Nếu $m = 10.000$, điều đó có nghĩa là chúng ta dự kiến sẽ bác bỏ sai 100 giả thuyết null một cách ngẫu nhiên! Đó là rất nhiều lỗi loại I.

Điểm mấu chốt của vấn đề là như sau: việc bác bỏ giả thuyết null nếu giá trị p nhỏ hơn α sẽ kiểm soát xác suất bác bỏ sai giả thuyết null đó ở mức α . Tuy nhiên, nếu ta làm điều này với m giả thuyết null, thì khả năng bác bỏ sai ít nhất một trong m giả thuyết null sẽ cao hơn đáng kể!

11. Đồng xu công bằng là đồng xu có xác suất xuất hiện mặt ngửa hoặc mặt sấp như nhau.
12.Hãy nhớ rằng giá trị p là xác suất quan sát được dữ liệu ít nhất ở mức cực đoan này, theo giả thuyết không. Nếu đồng xu là công bằng, thì xác suất quan sát được ít nhất mười mặt đười là $(1/2)^{10} = 1/1.024 < 0,001$. Do đó, giá trị p là $2/1.024 < 0,002$, vì đây là xác suất quan sát được mười mặt ngửa hoặc mười mặt đười.

	H0 là Đúng H0 là Sai Tổng		
Bác bỏ H0	V	S	R
Không bác bỏ H0	U	W m	R
Tổng cộng	m0	m m0 m	

BẢNG 13.2. Tóm tắt kết quả kiểm định m giả thuyết không. Một giả thuyết đã cho Giả thuyết không (null hypothesis) hoặc đúng hoặc sai, và một phép kiểm định giả thuyết không đó có thể là... Từ chối hoặc không từ chối nó. Trên thực tế, các giá trị riêng lẻ của V , S, U và W là chưa rõ. Tuy nhiên, chúng ta có thể truy cập vào $V + S = R$ và $U + W = m$ R, điều này và lần lượt là số lượng giả thuyết không bị bác bỏ và không bị bác bỏ.

Chúng tôi sẽ điều tra vấn đề này một cách chi tiết hơn và đề xuất giải pháp cho nó trong... Mục 13.3.

13.3 Tỷ lệ lỗi chung của nhóm

Trong các phần tiếp theo, chúng ta sẽ thảo luận về việc kiểm định nhiều giả thuyết trong khi Kiểm soát xác suất mắc ít nhất một lỗi loại I.

13.3.1 Tỷ lệ lỗi chung của cả nhóm là gì?

Hãy nhớ rằng tỷ lệ sai lầm loại I là xác suất bác bỏ H0 nếu H0 là đúng. Đúng vậy. Tỷ lệ lỗi toàn bộ nhóm (FWER) khái quát hóa khái niệm này cho tập hợp m giả thuyết không, $H_{01}, \dots, H_{0m}$, và được định nghĩa là xác suất có nguy cơ mắc ít nhất một lỗi loại I. Để diễn đạt ý tưởng này một cách chính thức hơn, hãy xem xét Bảng 13.2, tóm tắt các kết quả có thể xảy ra khi thực hiện m bài kiểm định giả thuyết. Ở đây, V biểu thị số lỗi loại I (cũng như (được gọi là kết quả dương tính giả hoặc phát hiện sai), S là số lượng kết quả dương tính thật, U là số lượng kết quả âm tính thật và W là số lỗi loại II. (còn được gọi là kết quả âm tính giả). Khi đó, tỷ lệ lỗi tổng thể được tính bằng

về mặt gia đình
tỷ lệ lỗi


$$FWER = \Pr(V \geq 1). \tag{13.3}$$

Chiến lược bác bỏ bất kỳ giả thuyết không nào mà giá trị p nhỏ hơn α (tức là kiểm soát lỗi loại I cho mỗi giả thuyết null ở mức α) dẫn đến đến FWER của

$$\begin{aligned} FWER(\alpha) &= \Pr(V \geq 1) \\ &= 1 - \Pr(\text{không bác bỏ sai bất kỳ giả thuyết null nào}) \\ &= 1 - \Pr_{j=1}^m \{ \text{Không bác bỏ giả thuyết } H_{0j} \text{ một cách sai lầm} \}. \end{aligned} \tag{13.4}$$

Nhớ lại kiến thức xác suất cơ bản rằng nếu hai sự kiện A và B độc lập với nhau, Khi đó $\Pr(A \cap B) = \Pr(A) \Pr(B)$. Vì vậy, nếu chúng ta thực hiện thêm điều này thì... giả định mạnh mẽ rằng m bài kiểm tra là độc lập và tất cả m đều không các giả thuyết là đúng thì

$$FWER(\alpha) = 1 - \prod_{j=1}^m (1 - \alpha) = (1 - \alpha)^m. \tag{13.5}$$



HÌNH 13.2. Tỷ lệ lỗi tổng thể của nhóm, là hàm số của số lượng
Các giả thuyết được kiểm định (hiển thị trên thang logarit), với ba giá trị của α : $\alpha = 0,05$ (màu cam), $\alpha = 0,01$ (màu xanh lam) và $\alpha = 0,001$ (màu tím). Đường nét đứt biểu thị $0,05$. Ví dụ, để kiểm soát FWER ở mức $0,05$ khi kiểm tra $m = 50$ đối với giả thuyết không, chúng ta phải kiểm soát lỗi loại I cho mỗi giả thuyết không ở mức độ $\alpha = 0,001$.

Do đó, nếu chúng ta chỉ kiểm tra một giả thuyết không, thì $\text{FWER}(\alpha) = 1 - (1 - \alpha)^1 = \alpha$, do đó tỷ lệ lỗi loại I và FWER bằng nhau. Tuy nhiên, nếu chúng ta thực hiện $m = 100$ bài kiểm tra độc lập, thì $\text{FWER}(\alpha) = 1 - (1 - \alpha)^{100}$. Ví dụ, việc lấy $\alpha = 0,05$ dẫn đến FWER là $1 - (1 - 0,05)^{100} = 0,994$. Trong các trường hợp khác nói cách khác, chúng ta gần như chắc chắn sẽ mắc ít nhất một lỗi loại I!

Hình 13.2 hiển thị (13.5) cho các giá trị khác nhau của m , số giả thuyết, và α , sai số loại I. Chúng ta thấy rằng việc đặt $\alpha = 0,05$ dẫn đến FWER cao ngay cả với m vừa phải. Với $\alpha = 0,01$, chúng ta không thể kiểm tra thêm được nữa. Ít hơn năm giả thuyết không trước khi FWER vượt quá $0,05$. Chỉ dành cho trường hợp rất hiếm. Với các giá trị nhỏ, chẳng hạn như $\alpha = 0,001$, chúng ta mới có thể đảm bảo FWER nhỏ. Ít nhất là đối với m có kích thước trung bình.

Bây giờ chúng ta sẽ quay lại ví dụ trong Phần 13.1.1, trong đó chúng ta hãy xem xét việc kiểm định một giả thuyết không duy nhất có dạng $H_0: \mu = \mu_0$ bằng cách sử dụng một Thống kê t hai mẫu. Hãy nhớ lại từ Hình 13.1 rằng để đảm bảo Nếu sai số loại I không vượt quá $0,02$, chúng ta sẽ quyết định có nên thực hiện điều đó hay không. Bác bỏ giả thuyết H_0 bằng cách sử dụng điểm cắt $2,33$ (tức là chúng ta bác bỏ H_0 nếu $|T| \geq 2,33$). Bây giờ, Nếu chúng ta muốn kiểm định 10 giả thuyết null bằng cách sử dụng thống kê t hai mẫu thì sao? thay vì chỉ một? Chúng ta sẽ thấy trong Phần 13.3.2 rằng chúng ta có thể đảm bảo rằng FWER không vượt quá $0,02$ khi chỉ bác bỏ giả thuyết null. trong đó giá trị p nhỏ hơn $0,002$. Điều này tương ứng với mức độ chính xác cao hơn nhiều. ngưỡng cắt nghiêm ngặt là $3,09$ (tức là chúng ta chỉ nên bác bỏ H_{0j} nếu thống kê kiểm định của nó nhỏ hơn $3,09$) $|T_j| \geq 3,09$, với $j = 1, \dots, 10$). Nói cách khác, kiểm soát FWER ở mức α đặt ra một tiêu chuẩn cao hơn nhiều, xét về bằng chứng cần thiết để bác bỏ bất kỳ giả thuyết không nào, thay vì chỉ đơn thuần kiểm soát lỗi loại I. đối với mỗi giả thuyết không ở mức α .