

Quản lý Trung bình, x̄ Độ lệch chuẩn, thống kê st giá trị p											
Một	3.0	7.4	2.86	Hai	-0.1	6.9	-0.10	Ba	2.8	7.5	2.62
0.53	Năm	0.3	6.8	0.31				Bốn	0.5	6.7	0.006
											0.918
											0.012
											0.601
											0.756

BẢNG 13.3. Hai cột đầu tiên tương ứng với giá trị trung bình mẫu và mẫu độ lệch chuẩn của tỷ lệ lợi nhuận vượt trội, trong khoảng thời gian n = 50 tháng, đối với Năm-nhà quản lý đầu tiên trong tập dữ liệu của Quỹ . Hai cột cuối cùng cung cấp thống kê t. ($\sqrt{n} \cdot X/S$) và giá trị p tương ứng để kiểm định H0j : $\mu_j = 0$, giả thuyết không Điều đó có nghĩa là lợi nhuận trung bình (của toàn bộ dân số) đối với người quản lý quỹ đầu cơ thứ j bằng không.

13.3.2 Các phương pháp kiểm soát tỷ lệ lỗi tổng thể

Trong phần này, chúng ta sẽ điểm qua một số phương pháp để kiểm soát FWER. Chúng tôi sẽ minh họa các phương pháp này trên tập dữ liệu của Quỹ , tập dữ liệu này ghi lại... Tỷ lệ lợi nhuận vượt trội hàng tháng của 2.000 nhà quản lý quỹ trên n = 50 tháng.13 Bảng 13.3 cung cấp số liệu thống kê tóm tắt có liên quan cho năm tháng đầu tiên. các nhà quản lý.

Trước tiên, chúng tôi trình bày phương pháp Bonferroni và quy trình giảm dần của Holm, đây là những phương pháp rất tổng quát để kiểm soát FWER. có thể áp dụng bất cứ khi nào giá trị mp đã được tính toán, bất kể về hình thức của giả thuyết không, việc lựa chọn thống kê kiểm định, hoặc (Sự) độc lập của các giá trị p. Sau đó, chúng ta sẽ thảo luận ngắn gọn về phương pháp Tukey. và phương pháp của Scheffé nhằm minh họa thực tế rằng, trong một số tình huống nhất định, các phương pháp chuyên biệt hơn để kiểm soát FWER có thể được áp dụng. Ưu tiên hơn.

Phương pháp Bonferroni

Như trong phần trước, giả sử chúng ta muốn kiểm tra $H_{01}, \dots, H_{0m}$. Gọi A_j ký hiệu sự kiện chúng ta mắc lỗi loại I đối với giả thuyết không thứ j. với $j = 1, \dots, m$. Sau đó

$$\begin{aligned} \text{FWER} &= \text{Xác suất (bác bỏ sai ít nhất một giả thuyết null)} \\ &= \Pr(\bigcup_{j=1}^m A_j) \\ &\leq \sum_{j=1}^m \Pr(A_j). \end{aligned} \tag{13.6}$$

Trong (13.6), bất đẳng thức xuất phát từ thực tế rằng đối với bất kỳ hai sự kiện A nào và B, $\Pr(A \cup B) \leq \Pr(A) + \Pr(B)$, bất kể A và B có tồn tại hay không. độc lập. Phương pháp Bonferroni, hay hiệu chỉnh Bonferroni, thiết lập ngưỡng để bác bỏ mỗi kiểm định giả thuyết là α/m , sao cho $\Pr(A_j) \leq \alpha/m$. Phương trình 13.6 ngụ ý rằng

$$\text{FWER}(\alpha/m) \leq m \times \frac{\alpha}{m} = \alpha,$$

13. Lợi nhuận vượt trội tương ứng với lợi nhuận bổ sung mà người quản lý quỹ đạt được ngoài mức lợi nhuận thông thường. Lợi nhuận tổng thể của thị trường. Vì vậy, nếu thị trường tăng 5% trong một khoảng thời gian nhất định và Nếu người quản lý quỹ đạt được tỷ suất lợi nhuận 7%, thì lợi nhuận vượt trội của họ sẽ là 7% - 5% = 2%.

Vì vậy, quy trình này kiểm soát FWER ở mức α . Ví dụ, để kiểm soát FWER ở mức 0,1 trong khi kiểm định $m = 100$ giả thuyết null, quy trình Bonferroni yêu cầu chúng ta kiểm soát lỗi loại I cho mỗi giả thuyết null ở mức $0,1/100 = 0,001$, tức là bác bỏ tất cả các giả thuyết null có giá trị p nhỏ hơn 0,001.

Bây giờ chúng ta xem xét tập dữ liệu **Quỹ** trong Bảng 13.3. Nếu chúng ta kiểm soát sai số loại I ở mức $\alpha = 0,05$ cho từng nhà quản lý quỹ riêng biệt, thì chúng ta sẽ kết luận rằng nhà quản lý thứ nhất và thứ ba có lợi nhuận vượt mức khác không đáng kể; nói cách khác, chúng ta sẽ bác bỏ $H_{01} : \mu_1 = 0$ và $H_{03} : \mu_3 = 0$. Tuy nhiên, như đã thảo luận trong các phần trước, quy trình này không tính đến thực tế là chúng ta đã kiểm định nhiều giả thuyết, và do đó nó sẽ dẫn đến FWER lớn hơn 0,05. Nếu thay vào đó chúng ta muốn kiểm soát FWER ở mức 0,05, thì bằng cách sử dụng hiệu chỉnh Bonferroni, chúng ta phải kiểm soát lỗi loại I cho từng nhà quản lý riêng lẻ ở mức $\alpha/m = 0,05/5 = 0,01$. Do đó, chúng ta sẽ chỉ bác bỏ giả thuyết null đối với nhà quản lý đầu tiên, vì giá trị p cho tất cả các nhà quản lý khác đều vượt quá 0,01. Hiệu chỉnh Bonferroni giúp chúng ta yên tâm rằng chúng ta không bác bỏ sai quá nhiều giả thuyết null, nhưng với một cái giá: chúng ta bác bỏ ít giả thuyết null, và do đó thường sẽ mắc khá nhiều lỗi loại II.

Phương pháp hiệu chỉnh Bonferroni là phương pháp hiệu chỉnh bội số được biết đến rộng rãi nhất và được sử dụng phổ biến nhất trong toàn bộ thống kê. Sự phổ biến của nó phần lớn là do nó rất dễ hiểu và dễ thực hiện, và cũng do nó kiểm soát thành công lỗi loại I bất kể m phép thử giả thuyết có độc lập hay không. Tuy nhiên, như chúng ta sẽ thấy, nó thường không phải là phương pháp mạnh nhất hay tốt nhất để hiệu chỉnh bội số kiểm định. Cụ thể, phương pháp hiệu chỉnh Bonferroni có thể khá bảo thủ, theo nghĩa là FWER thực thường thấp hơn đáng kể so với FWER danh nghĩa (hoặc mục tiêu); điều này là do bất đẳng thức trong (13.6). Ngược lại, một quy trình ít bảo thủ hơn có thể cho phép chúng ta kiểm soát FWER trong khi bác bỏ nhiều giả thuyết null hơn, và do đó mắc ít lỗi loại II hơn.

Quy trình giảm dần của Holm

Phương pháp Holm, còn được gọi là quy trình giảm dần của Holm hoặc phương pháp Holm-Bonferroni, là một phương pháp thay thế cho quy trình Bonferroni. Phương pháp Holm kiểm soát FWER, nhưng ít bảo thủ hơn Bonferroni, theo nghĩa là nó sẽ bác bỏ nhiều giả thuyết null hơn, thường dẫn đến ít lỗi loại II hơn và do đó có sức mạnh lớn hơn. Quy trình được tóm tắt trong Thuật toán 13.1. Bằng chứng cho thấy phương pháp này kiểm soát FWER tương tự, nhưng phức tạp hơn một chút so với lập luận trong (13.6) rằng phương pháp Bonferroni kiểm soát FWER. Điều đáng chú ý là trong quy trình Holm, ngưỡng mà chúng ta sử dụng để bác bỏ mỗi giả thuyết null – $p(L)$ trong Bước 5 – thực sự phụ thuộc vào giá trị của tất cả m giá trị p . (Xem định nghĩa của L trong (13.7).) Điều này trái ngược với quy trình Bonferroni, trong đó để kiểm soát FWER ở mức α , chúng ta bác bỏ bất kỳ giả thuyết null nào mà giá trị p nhỏ hơn α/m , bất kể các giá trị p khác. Phương pháp của Holm không đưa ra giả định độc lập nào về m bài kiểm tra giả thuyết và mạnh hơn phương pháp Bonferroni một cách đồng nhất – nó sẽ

Phương
pháp của Holm

Thuật toán 13.1 Quy trình giảm dần của Holm để kiểm soát FWER

1. Xác định α , mức độ mà bạn muốn kiểm soát FWER.
2. Tính giá trị $p, p_1, \dots, p_m$, cho m giả thuyết không.
 $H_{01}, \dots, H_{0m}$.
3. Sắp xếp các giá trị p sao cho $p(1) \leq p(2) \leq \dots \leq p(m)$.
4. Định nghĩa

$$L = \min j : p(j) > m \frac{\alpha}{j} \quad (13.7)$$

5. Bác bỏ tất cả các giả thuyết không H_{0j} mà $p_j < p(L)$.

Phương pháp này luôn bác bỏ ít nhất số lượng giả thuyết không bằng phương pháp Bonferroni – và do đó, nó luôn được ưu tiên sử dụng.


Giờ đây, chúng ta xem xét việc áp dụng phương pháp của Holm cho năm nhà quản lý quỹ đầu tiên trong tập dữ liệu **Quỹ** ở Bảng 13.3, đồng thời kiểm soát FWER ở mức 0,05. Các giá trị p được sắp xếp là $p(1) = 0,006$, $p(2) = 0,012$, $p(3) = 0,601$, $p(4) = 0,756$ và $p(5) = 0,918$. Thủ tục Holm bác bỏ hai giả thuyết không đầu tiên, bởi vì $p(1) = 0,006 < 0,05/(5 + 1) = 0,01$ và $p(2) = 0,012 < 0,05/(5 + 1) = 0,0125$, nhưng $p(3) = 0,601 > 0,05/(5 + 1) = 0,0167$, điều này ngụ ý rằng $L = 3$. Chúng tôi nhận thấy rằng, trong trường hợp này, phương pháp Holm mạnh hơn phương pháp Bonferroni: phương pháp Holm bác bỏ giả thuyết null đối với người quản lý thứ nhất và thứ ba, trong khi phương pháp Bonferroni chỉ bác bỏ giả thuyết null đối với người quản lý thứ nhất.

Hình 13.3 minh họa phương pháp Bonferroni và Holm trên ba tập dữ liệu mô phỏng trong một thiết lập liên quan đến $m = 10$ phép kiểm định giả thuyết, trong đó $m_0 = 2$ giả thuyết null là đúng. Mỗi bảng hiển thị mười giá trị p tương ứng, được sắp xếp từ nhỏ nhất đến lớn nhất, và được vẽ trên thang logarit. Tám điểm màu đỏ đại diện cho các giả thuyết null sai, và hai điểm màu đen đại diện cho các giả thuyết null đúng. Chúng ta muốn kiểm soát FWER ở mức 0,05. Quy trình Bonferroni yêu cầu chúng ta bác bỏ tất cả các giả thuyết null có giá trị p nhỏ hơn 0,005; điều này được biểu thị bằng đường ngang màu đen. Quy trình Holm yêu cầu chúng ta bác bỏ tất cả các giả thuyết null nằm dưới đường màu xanh lam. Đường màu xanh lam luôn nằm trên đường màu đen, vì vậy Holm sẽ luôn bác bỏ nhiều phép kiểm định hơn Bonferroni; vùng giữa hai đường tương ứng với các giả thuyết chỉ bị Holm bác bỏ. Ở hình bên trái, cả Bonferroni và Holm đều bác bỏ thành công bảy trong tám giả thuyết null sai. Ở hình giữa, Holm bác bỏ thành công cả tám giả thuyết null sai, trong khi Bonferroni không bác bỏ được một giả thuyết. Ở hình bên phải, Bonferroni chỉ bác bỏ ba giả thuyết null sai, trong khi Holm bác bỏ cả tám. Cả Bonferroni và Holm đều không mắc lỗi loại I nào trong các ví dụ này.

Hai trường hợp đặc biệt: Phương pháp Tukey và phương pháp Scheffé

Phương pháp Bonferroni và phương pháp Holm có thể được sử dụng trong hầu hết mọi trường hợp mà chúng ta muốn kiểm soát FWER cho m giả thuyết null: chúng






HÌNH 13.3. Mỗi bảng hiển thị, cho một mô phỏng riêng biệt, các giá trị p đã được sắp xếp cho các bài kiểm tra $m = 10$ giả thuyết không. Các giá trị p tương ứng với $m_0 = 2$ giả thuyết không đúng được hiển thị bằng màu đen, và phần còn lại được hiển thị bằng màu đỏ. Khi kiểm soát FWER ở mức $0,05$, phương pháp Bonferroni bác bỏ tất cả các giả thuyết null nằm dưới đường màu đen, và phương pháp Holm bác bỏ tất cả các giả thuyết null nằm dưới đường màu xanh. Vùng giữa đường màu xanh và đường màu đen biểu thị các giả thuyết null bị bác bỏ bằng phương pháp Holm nhưng không bị bác bỏ bằng phương pháp Bonferroni. Ở bảng giữa, phương pháp Holm bác bỏ nhiều hơn một giả thuyết null so với phương pháp Bonferroni. Ở bảng bên phải, nó bác bỏ nhiều hơn năm giả thuyết null.

Không nên đưa ra bất kỳ giả định nào về bản chất của giả thuyết null, loại thống kê kiểm định được sử dụng, hoặc tính (độc lập) của các giá trị p . Tuy nhiên, trong một số trường hợp rất cụ thể, chúng ta có thể đạt được độ mạnh cao hơn bằng cách kiểm soát FWER bằng các phương pháp phù hợp hơn với nhiệm vụ đang thực hiện. Phương pháp của Tukey và phương pháp của Scheffé là hai ví dụ như vậy.

Bảng 13.3 cho thấy rằng đối với tập dữ liệu *Quỹ*, *Quản lý Một* và *Hai* có sự khác biệt lớn nhất về lợi nhuận trung bình mẫu của họ. Phát hiện này có thể thúc đẩy chúng ta kiểm tra giả thuyết không $H_0: \mu_1 = \mu_2$, trong đó μ_j là lợi nhuận trung bình (của quần thể) đối với người quản lý quỹ thứ j . Một bài kiểm tra t hai mẫu (13.1) cho H_0 cho ra giá trị p là $0,0349$, cho thấy bằng chứng khiêm tốn chống lại H_0 . Tuy nhiên, giá trị p này gây hiểu nhầm, vì chúng ta đã quyết định so sánh lợi nhuận trung bình của *Quản lý Một* và *Hai* chỉ sau khi đã xem xét lợi nhuận của tất cả năm người quản lý; điều này về cơ bản tương đương với việc đã thực hiện $m = 5 \times (5 - 1)/2 = 10$ bài kiểm tra giả thuyết và chọn bài kiểm tra có giá trị p nhỏ nhất. Điều này cho thấy rằng để kiểm soát FWER ở mức $0,05$, chúng ta nên thực hiện hiệu chỉnh Bonferroni cho $m = 10$ bài kiểm tra giả thuyết, và do đó chỉ nên bác bỏ giả thuyết không mà giá trị p nhỏ hơn $0,005$. Nếu chúng ta làm như vậy, thì chúng ta sẽ không thể bác bỏ giả thuyết không rằng *Quản lý Một* và *Quản lý Hai* có hiệu suất làm việc giống hệt nhau.

Tuy nhiên, trong trường hợp này, hiệu chỉnh Bonferroni thực sự hơi quá khắt khe, vì nó không xem xét thực tế là $m = 10$ bài kiểm định giả thuyết đều có mối liên hệ nhất định: ví dụ, *Quản lý Hai* và *Quản lý Năm* có lợi nhuận trung bình tương tự nhau, cũng như *Quản lý Hai* và *Quản lý Bốn*; điều này đảm bảo rằng lợi nhuận trung bình của *Quản lý Bốn* và *Quản lý Năm* là tương tự nhau. Nói cách khác, các giá trị m_p cho m phép so sánh từng cặp không độc lập.

Do đó, cần phải có khả năng kiểm soát FWER theo cách thức phù hợp.



HÌNH 13.4. Mỗi bảng hiển thị, cho một mô phỏng riêng biệt, các giá trị đã được sắp xếp. Giá trị p cho các bài kiểm tra $m = 15$ giả thuyết, tương ứng với các bài kiểm tra từng cặp cho Sự bằng nhau của $G = 6$ có nghĩa là. Các giả thuyết không đúng $\mu_0 = 10$ được hiển thị bằng màu đen. và phần còn lại được tô màu đỏ. Khi kiểm soát FWER ở mức 0,05, Bonferroni Quy trình này bác bỏ tất cả các giả thuyết không nằm dưới đường kẻ đen, trong khi Tukey thì không. Nó loại bỏ tất cả những giá trị nằm dưới đường màu xanh. Do đó, phương pháp của Tukey có phần hơi khác biệt. Độ mạnh cao hơn phương pháp Bonferroni. Kiểm soát lỗi loại I mà không cần Điều chỉnh cho kiểm định đa biến bao gồm việc loại bỏ tất cả những kết quả nằm dưới mức màu xanh lá cây. đường kẻ.

ít bảo thủ hơn. Đây chính xác là ý tưởng đằng sau phương pháp Tukey: khi thực hiện $m = G(G - 1)/2$ phép so sánh từng cặp của G giá trị trung bình, nó cho phép cho phép chúng ta kiểm soát FWER ở mức α trong khi bác bỏ tất cả các giả thuyết không. trong đó giá trị p nhỏ hơn α_T , với một số $\alpha_T > \alpha/m$.

Tukey's
phương pháp

Hình 13.4 minh họa phương pháp Tukey trên ba bộ dữ liệu mô phỏng trong một Thiết lập với $G = 6$ có nghĩa là, với $\mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5 = \mu_6$. Do đó, trong số $m = G(G - 1)/2 = 15$ giả thuyết không có dạng $H_0 : \mu_j = \mu_k$, Mười câu đúng và năm câu sai. Trong mỗi bảng, giả thuyết không đúng được thể hiện. Các mục được hiển thị bằng màu đen, còn các mục sai được hiển thị bằng màu đỏ. Các đường ngang Điều này cho thấy phương pháp của Tukey luôn dẫn đến số lượng bác bỏ ít nhất bằng nhau. như phương pháp Bonferroni. Ở bảng bên trái, Tukey đã bác bỏ chính xác hai giả thuyết. nhiều giả thuyết không hơn so với phương pháp Bonferroni.

Bây giờ, giả sử chúng ta xem xét lại dữ liệu trong Bảng 13.3 và nhận thấy rằng Quản lý Một và Quản lý Ba có lợi nhuận trung bình cao hơn Quản lý Ba. Hai, bốn và năm. Điều này có thể thúc đẩy chúng ta kiểm tra giả thuyết không.

$$H_0 : \frac{1}{2}(\mu_1 + \mu_3) = (\mu_2 + \frac{1}{4}\mu_4 + \mu_5). \tag{13.8}$$

(Nhớ rằng μ_j là lợi nhuận trung bình của quần thể đối với người quản lý quỹ phòng hộ thứ j .) Hóa ra chúng ta có thể kiểm tra (13.8) bằng cách sử dụng một biến thể của kiểm định t hai mẫu được trình bày trong (13.1), dẫn đến giá trị p là 0,004. Điều này cho thấy bằng chứng mạnh mẽ về sự khác biệt giữa Người quản lý Một và Ba So với các quản lý số Hai, số Bốn và số Năm. Tuy nhiên, có một vấn đề: chúng tôi quyết định kiểm tra giả thuyết không trong (13.8) chỉ sau khi xem qua dữ liệu trong Bảng 13.3. Nói một cách nào đó, điều này có nghĩa là chúng tôi đã tiến hành nhiều lần. kiểm tra. Trong trường hợp này, sử dụng phương pháp Bonferroni để kiểm soát FWER ở mức α .

sẽ yêu cầu ngưỡng giá trị p là α/m , đối với một giá trị cực lớn của m .

Phương pháp của Scheffé được thiết kế chính xác cho trường hợp này. Nó cho phép chúng ta tính toán giá trị αS sao cho bác bỏ giả thuyết không H_0 trong (13.8) nếu Giá trị p nhỏ hơn αS sẽ kiểm soát lỗi loại I ở mức α . Hóa ra là Ví dụ về Quỹ , để kiểm soát sai số loại I ở mức $\alpha = 0,05$, chúng ta phải đặt $\alpha S = 0,002$. Do đó, chúng ta không thể bác bỏ H_0 trong (13.8), mặc dù giá trị p rất nhỏ là $0,004$. Một lợi thế quan trọng của Phương pháp của Scheffé là chúng ta có thể sử dụng cùng ngưỡng $\alpha S = 0,002$ này để thực hiện so sánh từng cặp bất kỳ sự phân chia nào của các nhà quản lý thành hai nhóm. các nhóm: ví dụ, chúng ta cũng có thể kiểm tra $H_0: \frac{1}{3}(\mu_1 + \mu_2 + \mu_3) = (\mu_4 \frac{1}{2} \mu_5)$ và $H_0: \frac{1}{4}(\mu_1 + \mu_2 + \mu_3 + \mu_4) = \mu_5$ sử dụng cùng ngưỡng $0,002$, không cần phải điều chỉnh thêm cho việc kiểm định đa biến.

Của Scheffé
phương pháp

Tóm lại, phương pháp Holm và phương pháp Bonferroni rất giống nhau. Các phương pháp chung để hiệu chỉnh kiểm định đa biến có thể được áp dụng trong mọi trường hợp. Tuy nhiên, trong một số trường hợp đặc biệt, các thủ tục mạnh mẽ hơn để hiệu chỉnh kiểm định đa biến có thể được sử dụng để kiểm soát FWER trong khi đạt được công suất cao hơn (tức là ít phát sinh lỗi Type II hơn). lỗi) nhiều hơn so với việc sử dụng phương pháp Holm hoặc Bonferroni. Trong phần này, Chúng tôi đã minh họa hai ví dụ như vậy.


13.3.3 Sự đánh đổi giữa FWER và công suất

Nhìn chung, có sự đánh đổi giữa ngưỡng FWER mà chúng ta lựa chọn, và khả năng bác bỏ giả thuyết không của chúng ta. Hãy nhớ rằng sức mạnh được định nghĩa là... bằng số lượng giả thuyết null sai mà chúng ta bác bỏ chia cho tổng số số lượng giả thuyết null sai, tức là $S/(m - m_0)$ sử dụng ký hiệu của Bảng 13.2. Hình 13.5 minh họa kết quả của một thiết lập mô phỏng liên quan đến m giả thuyết không, trong đó 90% là đúng và 10% còn lại là sai; Công suất được hiển thị dưới dạng hàm của FWER. Trong mô phỏng cụ thể này, Khi thiết lập $m = 10$, FWER là $0,05$ tương ứng với công suất khoảng 60%. Tuy nhiên, khi m tăng lên, công suất giảm xuống. Với $m = 500$, Độ mạnh của phép thử nhỏ hơn $0,2$ ở mức FWER là $0,05$, do đó chúng ta đã bác bỏ thành công giả thuyết này. Chỉ có 20% giả thuyết null sai.

Hình 13.5 cho thấy việc kiểm soát FWER là hợp lý khi m có giá trị nhỏ, chẳng hạn như 5 hoặc 10. Tuy nhiên, đối với $m = 100$ hoặc $m = 1.000$, Việc cố gắng kiểm soát FWER sẽ khiến việc bác bỏ gần như không thể thực hiện được. bất kỳ giả thuyết không sai nào. Nói cách khác, sức mạnh sẽ cực kỳ thấp.

Tại sao lại như vậy? Hãy nhớ rằng, sử dụng ký hiệu trong Bảng 13.2, thì FWER được định nghĩa là $\Pr(V \geq 1)$ (13.3). Nói cách khác, việc kiểm soát FWER ở mức α đảm bảo rằng nhà phân tích dữ liệu rất khó có khả năng (với) xác suất không quá α để bác bỏ bất kỳ giả thuyết không đúng nào, tức là có bất kỳ kết quả dương tính giả nào. Để thực hiện đúng cam kết này khi m là Nếu quy mô dữ liệu lớn, nhà phân tích dữ liệu có thể buộc phải bác bỏ rất ít giả thuyết không, hoặc thậm chí có thể không có gì cả (vì nếu $R = 0$ thì V cũng $= 0$; xem Bảng 13.2).

14Thực tế, việc tính toán giá trị “chính xác” của m khá phức tạp và nằm ngoài phạm vi của cuốn sách này.



HÌNH 13.5. Trong một thiết lập mô phỏng trong đó 90% trong số m giả thuyết không là đúng vậy, chúng tôi hiển thị sức mạnh (tỷ lệ giả thuyết null sai mà chúng tôi đã thành công) (bác bỏ) như một hàm của tỷ lệ lỗi tổng thể. Các đường cong tương ứng với $m = 10$ (màu cam), $m = 100$ (màu xanh lam) và $m = 500$ (màu tím). Khi giá trị của m tăng lên khi tăng lên, công suất giảm xuống. Đường chấm dọc biểu thị FWER của 0,05.

Điều này không thú vị về mặt khoa học và thường dẫn đến công suất rất thấp.

như trong Hình 13.5.

Trên thực tế, khi m lớn, chúng ta có thể chấp nhận một vài sai sót nhỏ. những mặt tích cực, nhằm mục đích tạo ra nhiều khám phá hơn, tức là bác bỏ nhiều hơn giả thuyết không. Đây là động lực đằng sau tỷ lệ phát hiện sai. mà chúng tôi sẽ trình bày tiếp theo.

13.4 Tỷ lệ phát hiện sai

13.4.1 Trực giác về tỷ lệ phát hiện sai

Như chúng ta vừa thảo luận, khi m lớn, thì việc cố gắng ngăn chặn bất kỳ sai sót nào là không thể.

Các tiêu chí dương tính (như trong kiểm soát FWER) quá khắt khe. Thay vào đó, chúng ta có thể...

cố gắng đảm bảo tỷ lệ dương tính giả (V) trên tổng số dương tính ($V +$) thấp.

$S = R$ đủ thấp để hầu hết các giả thuyết không bị bác bỏ đều

Không phải là kết quả dương tính giả. Tỷ lệ V/R được gọi là tỷ lệ phát hiện sai (FDP).

SAI
khám phá
tỷ lệ

Có thể bạn sẽ muốn yêu cầu nhà phân tích dữ liệu kiểm soát FDP:

Hãy đảm bảo rằng không quá 20% số giả thuyết null bị bác bỏ là

kết quả dương tính giả. Tuy nhiên, trên thực tế, việc kiểm soát FDP là điều không thể.

Đây là một nhiệm vụ khó khăn đối với nhà phân tích dữ liệu, vì cô ấy không có cách nào chắc chắn,

trên bất kỳ tập dữ liệu cụ thể nào, giả thuyết nào là đúng và giả thuyết nào là sai. Điều này rất

Tương tự như việc nhà phân tích dữ liệu có thể kiểm soát FWER, tức là cô ấy

có thể đảm bảo rằng $\Pr(V \geq 1) \leq \alpha$ cho bất kỳ α nào được chỉ định trước, nhưng cô ấy không thể

đảm bảo rằng $V = 0$ trên bất kỳ tập dữ liệu cụ thể nào (ngoại trừ trường hợp không bác bỏ)

bất kỳ giả thuyết không nào, tức là đặt $R = 0$).

Do đó, thay vào đó chúng tôi kiểm soát tỷ lệ phát hiện sai (FDR)¹⁵, được định nghĩa là

BẢNG

$$FDR = E(FDP) = E(V / R) . \quad (13.9)$$

phát
hiện sai lầm
tỷ lệ

Khi chúng ta kiểm soát tỷ lệ sai sót giả (FDR) ở mức (ví dụ) $q = 20\%$, chúng ta đang bác bỏ càng nhiều giả thuyết null càng tốt trong khi đảm bảo rằng trung bình không quá 20% trong số các giả thuyết null bị bác bỏ đó là dương tính giả .

Trong định nghĩa của FDR trong (13.9), kỳ vọng được tính trên quần thể mà từ đó dữ liệu được tạo ra. Ví dụ, giả sử chúng ta kiểm soát FDR cho m giả thuyết null ở mức $q = 0,2$. Điều này có nghĩa là nếu chúng ta lặp lại thí nghiệm này rất nhiều lần, và mỗi lần kiểm soát FDR ở mức $q = 0,2$, thì chúng ta nên kỳ vọng rằng, trung bình, 20% các giả thuyết null bị bác bỏ sẽ là dương tính giả. Trên một tập dữ liệu nhất định, tỷ lệ dương tính giả trong số các giả thuyết bị bác bỏ có thể lớn hơn hoặc nhỏ hơn 20%.

Cho đến nay, chúng ta đã lý giải việc sử dụng FDR từ góc độ thực tiễn, bằng cách lập luận rằng khi m lớn, việc kiểm soát FWER quá khắt khe và sẽ không dẫn đến “đủ” những khám phá. Một lý do khác để sử dụng FDR là nó phù hợp với cách thức thu thập dữ liệu thường thấy trong các ứng dụng hiện đại. Khi các tập dữ liệu tiếp tục tăng về kích thước trong nhiều lĩnh vực khác nhau, việc tiến hành một số lượng lớn các thử nghiệm giả thuyết cho mục đích khám phá, thay vì xác nhận, ngày càng trở nên phổ biến. Ví dụ, một nhà nghiên cứu gen có thể giải trình tự bộ gen của những cá nhân mắc và không mắc một tình trạng bệnh lý cụ thể nào đó, và sau đó, đối với mỗi trong số 20.000 gen, kiểm tra xem các biến thể trình tự trong gen đó có liên quan đến tình trạng bệnh lý đang quan tâm hay không. Điều này tương đương với việc thực hiện $m = 20.000$ thử nghiệm giả thuyết. Phân tích này mang tính chất khám phá, theo nghĩa là nhà nghiên cứu không có bất kỳ giả thuyết cụ thể nào trong đầu; Thay vào đó, cô ấy muốn xem liệu có bằng chứng khiêm tốn nào cho thấy mối liên hệ giữa mỗi gen và bệnh hay không, với kế hoạch điều tra thêm bất kỳ gen nào mà có bằng chứng như vậy. Cô ấy có thể sẵn sàng chấp nhận một số lượng dương tính giả trong tập hợp các gen mà cô ấy sẽ điều tra thêm; do đó, FWER không phải là lựa chọn thích hợp. Tuy nhiên, cần có một số hiệu chỉnh cho việc kiểm định đa biến: sẽ không phải là một ý tưởng hay nếu cô ấy chỉ đơn giản điều tra tất cả các gen có giá trị p nhỏ hơn (ví dụ) 0,05, vì chúng ta có thể kỳ vọng 1.000 gen sẽ có giá trị p nhỏ như vậy chỉ do ngẫu nhiên, ngay cả khi không có gen nào liên quan đến bệnh (vì $0,05 \times 20.000 = 1.000$). Việc kiểm soát FDR cho phân tích thăm dò của cô ấy ở mức 20% đảm bảo rằng - trung bình - không quá 20% số gen mà cô ấy điều tra thêm là dương tính giả.

Cần lưu ý rằng, không giống như giá trị p , trong đó ngưỡng 0,05 thường được coi là tiêu chuẩn tối thiểu về bằng chứng cho kết quả “tích cực”, và ngưỡng 0,01 hoặc thậm chí 0,001 được coi là thuyết phục hơn nhiều, không có ngưỡng tiêu chuẩn nào được chấp nhận cho việc kiểm soát FDR. Thay vào đó, việc lựa chọn ngưỡng FDR thường phụ thuộc vào ngữ cảnh, hoặc thậm chí phụ thuộc vào tập dữ liệu. Ví dụ, nhà nghiên cứu gen trong ví dụ trước có thể tìm cách kiểm soát FDR ở ngưỡng 10% nếu kế hoạch theo dõi tiếp theo...

¹⁵Nếu $R = 0$, thì ta thay tỷ lệ V/R bằng 0 để tránh tính $0/0$. Về mặt hình thức, $FDR = E(V / R | R > 0) Pr(R > 0)$.

Phân tích tiếp theo tốn nhiều thời gian hoặc chi phí. Thay vào đó, ngưỡng lớn hơn nhiều là 30% có thể phù hợp nếu cô ấy dự định thực hiện phân tích tiếp theo với chi phí thấp.

13.4.2 Quy trình Benjamini-Hochberg

Giờ đây, chúng ta tập trung vào nhiệm vụ kiểm soát tỷ lệ sai sót giả (FDR): tức là, quyết định bác bỏ giả thuyết null nào trong khi đảm bảo rằng FDR, $E(V/R)$, nhỏ hơn hoặc bằng một giá trị q được xác định trước. Để làm được điều này, chúng ta cần một cách nào đó để liên kết các giá trị $p, p_1, \dots, p_m$, từ m giả thuyết null với giá trị FDR mong muốn, q . Hóa ra, một quy trình rất đơn giản, được trình bày trong Thuật toán 13.2, có thể được sử dụng để kiểm soát FDR.

Thuật toán 13.2 Quy trình Benjamini-Hochberg để kiểm soát tỷ lệ sai sót giả (FDR)

- 1. Xác định q , mức độ mà bạn muốn kiểm soát FDR.
- 2. Tính giá trị $p, p_1, \dots, p_m$, cho m giả thuyết không $H_{01}, \dots, H_{0m}$.
- 3. Sắp xếp các giá trị p_j sao cho $p(1) \leq p(2) \leq \dots \leq p(m)$.
- 4. Định nghĩa

$$L = \max\{j : p(j) < qj/m\}.$$
 (13.10)

- 5. Bác bỏ tất cả các giả thuyết không H_{0j} mà $p_j \leq p(L)$.

Thuật toán 13.2 được gọi là quy trình Benjamini-Hochberg. Điểm mấu chốt của quy trình này nằm ở (13.10). Ví dụ, hãy xem xét lại năm nhà quản lý đầu tiên trong tập dữ liệu Quỹ, được trình bày trong Bảng 13.3. (Trong ví dụ này, $m = 5$, mặc dù thông thường chúng ta kiểm soát FDR trong các thiết lập liên quan đến số lượng giả thuyết null lớn hơn nhiều.) Chúng ta thấy rằng $p(1) = 0,006 < 0,05 \times 1/5$, $p(2) = 0,012 < 0,05 \times 2/5$, $p(3) = 0,601 > 0,05 \times 3/5$, $p(4) = 0,756 > 0,05 \times 4/5$ và $p(5) = 0,918 > 0,05 \times 5/5$. Do đó, để kiểm soát FDR ở mức 5%, chúng ta bác bỏ giả thuyết null rằng nhà quản lý quỹ thứ nhất và thứ ba hoạt động không tốt hơn so với ngẫu nhiên.

Benjamini-
Thủ tục
Hochberg


Miễn là các giá trị p_j độc lập hoặc chỉ phụ thuộc nhẹ, sau đó quy trình Benjamini-Hochberg đảm bảo rằng

$$FDR \leq q.$$

Nói cách khác, quy trình này đảm bảo rằng, trung bình, không quá một phần q trong số các giả thuyết null bị bác bỏ là dương tính giả. Điều đáng chú ý là điều này đúng bất kể có bao nhiêu giả thuyết null đúng, và bất kể sự phân bố của các giá trị p đối với các giả thuyết null sai.

Do đó, phương pháp Benjamini-Hochberg cung cấp cho chúng ta một cách rất dễ dàng để xác định, với một tập hợp các giá trị p_j , những giả thuyết không nào cần bác bỏ để kiểm soát FDR ở bất kỳ mức độ q nào được xác định trước.

16Tuy nhiên, bằng chứng đó nằm ngoài phạm vi của cuốn sách này.



HÌNH 13.6. Mỗi bảng hiển thị cùng một tập hợp gồm $m = 2.000$ giá trị p được sắp xếp theo thứ tự. đối với dữ liệu của *Quý*. Các đường màu xanh lá cây biểu thị ngưỡng giá trị p tương ứng để kiểm soát FWER, thông qua quy trình Bonferroni, ở mức $\alpha = 0.05$ (bên trái), $\alpha = 0.1$ (giữa), và $\alpha = 0.3$ (phải). Các đường màu cam biểu thị ngưỡng giá trị p tương ứng với kiểm soát FDR, thông qua Benjamini-Hochberg, ở mức $q = 0.05$ (bên trái), $q = 0.1$ (giữa) và $q = 0.3$ (phải). Khi FDR được kiểm soát ở mức $q = 0.1$, 146 giả thuyết null bị bác bỏ (ở giữa); các giá trị p tương ứng được hiển thị màu xanh lam. Khi FDR được kiểm soát ở mức $q = 0.3$, có 279 giả thuyết không bị bác bỏ (bên phải); các giá trị p tương ứng được hiển thị bằng màu xanh lam.

Có sự khác biệt cơ bản giữa phương pháp Bonferroni của Mục 13.3.2 và quy trình Benjamini-Hochberg. Trong Bonferroni quy trình, nhằm kiểm soát FWER cho m giả thuyết không ở mức độ α , chúng ta chỉ cần bác bỏ các giả thuyết null mà giá trị p nhỏ hơn α/m . Ngưỡng α/m này không phụ thuộc vào bất cứ điều gì về dữ liệu. (vượt quá giá trị của m), và chắc chắn không phụ thuộc vào giá trị p bản thân chúng. Ngược lại, ngưỡng bác bỏ được sử dụng trong phương pháp Benjamini-Quy trình Hochberg phức tạp hơn: chúng ta bác bỏ tất cả các giả thuyết không cho trong đó giá trị p nhỏ hơn hoặc bằng giá trị p nhỏ thứ L , tức là L tự nó là một hàm của tất cả các giá trị p , như trong (13.10). Do đó, khi thực hiện quy trình Benjamini-Hochberg, chúng ta không thể lên kế hoạch trước. Chúng ta sẽ sử dụng ngưỡng nào để bác bỏ giá trị p ; trước tiên chúng ta cần xem xét dữ liệu của mình. Ví dụ, về mặt trừu tượng, không có cách nào để biết liệu chúng ta có bác bỏ hay không. giả thuyết không tương ứng với giá trị p là 0.01 khi sử dụng FDR. Ngưỡng 0.1 với $m = 100$; câu trả lời phụ thuộc vào giá trị của m 1 giá trị p khác. Thuộc tính này của quy trình Benjamini-Hochberg Điều này cũng tương tự với quy trình Holm, vốn cũng liên quan đến dữ liệu phụ thuộc. Ngưỡng giá trị p .

Hình 13.6 hiển thị kết quả của việc áp dụng phương pháp Bonferroni và Benjamini-Hochberg trên tập dữ liệu của *Quý*, sử dụng toàn bộ tập hợp $m = 2.000$ các nhà quản lý quỹ, trong đó năm người đầu tiên được hiển thị trong Bảng 13.3. Khi Mức FWER được kiểm soát ở mức 0.3 bằng phương pháp Bonferroni, chỉ có một giả thuyết null bị bác bỏ; nghĩa là, chúng ta chỉ có thể kết luận rằng một nhà quản lý quỹ duy nhất là Vượt trội hơn thị trường. Điều này bất chấp thực tế là một phần đáng kể của

Khoảng 2.000 nhà quản lý quỹ dường như đã vượt trội hơn thị trường mà không cần hiệu chỉnh cho kiểm định đa biến – ví dụ, 13 trong số họ có giá trị p dưới 0,001. Ngược lại, khi kiểm soát FDR ở mức 0,3, chúng ta có thể kết luận rằng 279 nhà quản lý quỹ đang vượt trội hơn thị trường: chúng ta kỳ vọng rằng không quá khoảng $279 \times 0,3 = 83,7\%$ trong số các nhà quản lý quỹ này có hiệu suất tốt chỉ do may mắn. Như vậy, chúng ta thấy rằng kiểm soát FDR nhẹ nhàng hơn – và mạnh mẽ hơn – so với kiểm soát FWER, theo nghĩa là nó cho phép chúng ta bác bỏ nhiều giả thuyết không hơn, với cái giá là số lượng dương tính giả nhiều hơn đáng kể.

Phương pháp Benjamini-Hochberg đã tồn tại từ giữa những năm 1990. Mặc dù đã có rất nhiều bài báo được công bố kể từ đó để xuất các phương pháp thay thế để kiểm soát FDR có thể hoạt động tốt hơn trong các tình huống cụ thể, phương pháp Benjamini-Hochberg vẫn là một phương pháp rất hữu ích và được áp dụng rộng rãi.

13.5 Phương pháp lấy mẫu lại đối với giá trị p và tỷ lệ phát hiện sai

Cho đến nay, phần thảo luận trong chương này giả định rằng chúng ta quan tâm đến việc kiểm định một giả thuyết không H_0 cụ thể bằng cách sử dụng một thống kê kiểm định T , có một số phân phối đã biết (hoặc được giả định) dưới H_0 , chẳng hạn như phân phối chuẩn, phân phối t , phân phối χ^2 hoặc phân phối F . Điều này được gọi là phân phối không lý thuyết. Chúng ta thường dựa vào sự có sẵn của phân phối không lý thuyết để thu được giá trị p liên quan đến thống kê kiểm định của chúng ta. Thật vậy, đối với hầu hết các loại giả thuyết không mà chúng ta có thể quan tâm đến việc kiểm định, một phân phối không lý thuyết đều có sẵn, miễn là chúng ta sẵn sàng đưa ra những giả định nghiêm ngặt về dữ liệu của mình.

phân phối
không
lý thuyết

Tuy nhiên, nếu giả thuyết không H_0 hoặc thống kê kiểm định T của chúng ta có phần bất thường, thì có thể không có phân phối không lý thuyết nào khả dụng. Hoặc, ngay cả khi tồn tại một phân phối không lý thuyết, chúng ta vẫn có thể thận trọng khi dựa vào nó, có lẽ vì một số giả định cần thiết để nó đúng đã bị vi phạm. Ví dụ, có thể kích thước mẫu quá nhỏ.

Trong phần này, chúng tôi trình bày một khung lý thuyết để thực hiện suy luận trong bối cảnh này, tận dụng khả năng của các máy tính tốc độ cao để xấp xỉ phân phối chuẩn của T , và từ đó thu được giá trị p. Mặc dù khung lý thuyết này rất tổng quát, nhưng nó cần được cụ thể hóa cẩn thận cho một vấn đề cụ thể cần quan tâm. Do đó, trong phần tiếp theo, chúng tôi xem xét một ví dụ cụ thể trong đó chúng tôi muốn kiểm tra xem trung bình của hai biến ngẫu nhiên có bằng nhau hay không, bằng cách sử dụng kiểm định t hai mẫu.

Phần thảo luận này khó hơn các phần trước trong chương này và có thể được bỏ qua một cách an toàn bởi người đọc nếu chỉ cần sử dụng phân phối giả thuyết để tính giá trị p cho thống kê kiểm định của mình.

13.5.1 Phương pháp lấy mẫu lại đối với giá trị p

Chúng ta quay lại ví dụ ở Mục 13.1.1, trong đó chúng ta muốn kiểm tra xem liệu Giá trị trung bình của biến ngẫu nhiên X bằng giá trị trung bình của biến ngẫu nhiên Y , tức là $H_0: E(X) = E(Y)$, so với giả thuyết thay thế $H_a: E(X) \neq E(Y)$. Cho trước n_X quan sát độc lập từ X và n_Y quan sát độc lập từ Y , thống kê T hai mẫu có dạng

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s_X^2}{n_X} + \frac{s_Y^2}{n_Y}}} \quad (13.11)$$

trong đó $\bar{X} = \frac{1}{n_X} \sum_{i=1}^{n_X} x_i$, $\bar{Y} = \frac{1}{n_Y} \sum_{i=1}^{n_Y} y_i$ và $s_X^2 = \frac{1}{n_X-1} \sum_{i=1}^{n_X} (x_i - \bar{X})^2$, $s_Y^2 = \frac{1}{n_Y-1} \sum_{i=1}^{n_Y} (y_i - \bar{Y})^2$, x_i và y_i là các ước lượng không thiên lệch về phương sai trong hai nhóm.

Giá trị tuyệt đối lớn của T cung cấp bằng chứng chống lại giả thuyết H_0 .

Nếu n_X và n_Y lớn thì T trong (13.11) xấp xỉ tuân theo $N(0, 1)$ phân phối. Nhưng nếu n_X và n_Y nhỏ, thì trong trường hợp không có sự phân phối mạnh mẽ Giả định về phân bố của X và Y là chúng ta không biết phân bố lý thuyết của T .

¹⁷ Trong trường hợp này, hóa ra chúng ta có thể Xấp xỉ phân bố chuẩn của T bằng cách sử dụng phương pháp lấy mẫu lại, hay cụ thể hơn là phương pháp hoán vị.

hoán vị lấy
mẫu lại

Để làm điều này, chúng ta tiến hành một thí nghiệm giả định. Nếu H_0 đúng, sao cho $E(X) = E(Y)$, và chúng ta đưa ra giả định mạnh hơn rằng các phân phối của X và Y giống nhau, do đó sự phân bố của T không thay đổi khi hoán đổi. So sánh một số quan sát trong X với các quan sát trong Y , sau đó tiến hành kiểm tra.

Thống kê T trong (13.11) được tính toán dựa trên dữ liệu hoán đổi này có cùng Phân phối theo T dựa trên dữ liệu gốc. Điều này chỉ đúng nếu H_0 được thỏa mãn và sự phân bố của X và Y là như nhau.

Điều này cho thấy rằng để xấp xỉ phân bố chuẩn của T , Chúng ta có thể áp dụng phương pháp sau. Ta hoán vị ngẫu nhiên $n_X + n_Y$ quan sát B lần, với một giá trị lớn của B , và mỗi lần chúng ta tính toán (13.11). Chúng ta ký hiệu $T_1, \dots, T_B$ là các giá trị của (13.11) trên hoán vị dữ liệu. Chúng có thể được xem như một phép xấp xỉ của phân phối chuẩn của T dưới giả thuyết H_0 . Nhớ lại rằng theo định nghĩa, giá trị p là xác suất của quan sát thấy thống kê kiểm định ít nhất ở mức cực đoan này dưới giả thuyết H_0 . Do đó, để tính giá trị p cho T , chúng ta có thể đơn giản tính toán

$$\text{giá trị } p = \frac{1}{B} \sum_{b=1}^B 1(T_b \geq |T|), \quad (13.12)$$

tỷ lệ các tập dữ liệu được hoán vị mà giá trị của thống kê kiểm định Giá trị này ít nhất cũng cực đoan như giá trị quan sát được trên dữ liệu gốc. Điều này Quy trình được tóm tắt trong Thuật toán 13.3.

¹⁷Nếu chúng ta giả sử rằng X và Y được phân phối chuẩn, thì T trong (13.11) tuân theo Phân phối t với $n_X + n_Y - 2$ bậc tự do dưới giả thuyết H_0 . Tuy nhiên, trên thực tế, Việc phân bố các biến ngẫu nhiên hiếm khi được biết đến, vì vậy có thể nên thực hiện... một phương pháp lấy mẫu lại thay vì đưa ra những giả định mạnh mẽ và không có cơ sở. Nếu Kết quả của phương pháp lấy mẫu lại không phù hợp với kết quả của giả định lý thuyết. Nếu phân phối chuẩn không có sai số, thì kết quả của phương pháp lấy mẫu lại sẽ đáng tin cậy hơn.

Thuật toán 13.3 Lấy mẫu lại giá trị p cho phép kiểm định t hai mẫu

- 1. Tính T, được định nghĩa trong (13.11), trên dữ liệu gốc $x_1, \dots, x_N$ và $y_1, \dots, y_N$.
 - 2. Với $b = 1, \dots, B$, trong đó B là một số lớn (ví dụ: $B = 10.000$):
 - (a) Hoán vị ngẫu nhiên $N_X + N_Y$ quan sát. Gọi quan sát đầu tiên là N_X và các quan sát hoán vị $x_1, \dots, x_{N_X}$ quan sát N_X , quan sát còn lại là N_Y .
sát $y_1, \dots, y_{N_Y}$ (b) Tính T_b .
- (13.11) trên dữ liệu hoán vị $x_1, \dots, x_{N_X}$ và gọi kết quả là T_b . N_X và $y_1, \dots, y_{N_Y}$.
3. Giá trị p được đưa ra bởi
$$\frac{1}{B} \sum_{b=1}^B 1(T_b \geq T)$$
.

Chúng tôi thử nghiệm quy trình này trên tập dữ liệu Khan, bao gồm các phép đo biểu hiện của 2.308 gen trong bốn phân nhóm u tế bào máu tròn nhỏ, một loại ung thư thường gặp ở trẻ em. Tập dữ liệu này là một phần của gói ISLR2. Chúng tôi chỉ tập trung vào hai phân nhóm có nhiều dữ liệu quan sát nhất: u cơ vân (rhabdomyosarcoma) ($N_X = 29$) và u lympho Burkitt ($N_Y = 25$).

Một phép kiểm định t hai mẫu cho giả thuyết không rằng giá trị biểu hiện trung bình của gen thứ 11 bằng nhau ở hai nhóm cho kết quả $T = 2,09$. Sử dụng phân phối không lý thuyết, là phân phối t52 (vì $N_X + N_Y - 2 = 52$), ta thu được giá trị p là 0,041. (Lưu ý rằng phân phối t52 hầu như không thể phân biệt được với phân phối $N(0, 1)$). Nếu thay vào đó ta áp dụng Thuật toán 13.3 với $B = 10.000$, thì ta thu được giá trị p là 0,042.

Hình 13.7 hiển thị phân bố giả thuyết, phân bố giả thuyết lấy mẫu lại và giá trị thực tế của thống kê kiểm định ($T = 2,09$) cho gen này. Trong ví dụ này, chúng ta thấy sự khác biệt rất nhỏ giữa các giá trị p thu được bằng cách sử dụng phân bố giả thuyết và phân bố giả thuyết lấy mẫu lại.


Ngược lại, Hình 13.8 cho thấy một tập hợp kết quả tương tự đối với gen thứ 877. Trong trường hợp này, có sự khác biệt đáng kể giữa phân bố giả thuyết và phân bố giả thuyết lấy mẫu lại, dẫn đến sự khác biệt giữa các giá trị p của chúng.

Nhìn chung, trong các trường hợp có kích thước mẫu nhỏ hơn hoặc phân bố dữ liệu lệch nhiều hơn (khiến phân bố giả thuyết không chính xác hơn), sự khác biệt giữa giá trị p lấy mẫu lại và giá trị p lý thuyết sẽ có xu hướng rõ rệt hơn. Trên thực tế, sự khác biệt đáng kể giữa phân bố giả thuyết lấy mẫu lại và phân bố giả thuyết trong Hình 13.8 là do một quan sát duy nhất trong gen thứ 877 nằm rất xa các quan sát khác, dẫn đến phân bố rất lệch.


13.5.2 Phương pháp lấy mẫu lại đối với tỷ lệ phát hiện sai

Giả sử chúng ta muốn kiểm soát tỷ lệ sai sót giả (FDR) cho m giả thuyết không, $H_01, \dots, H_0m$, trong trường hợp không có phân phối lý thuyết nào khả dụng, hoặc đơn giản là chúng ta muốn tránh sử dụng phân phối lý thuyết.





HÌNH 13.7. Gen thứ 11 trong tập dữ liệu *Khan* có giá trị thống kê kiểm định là $T = 2,09$. Phân bố lý thuyết và phân bố chuẩn khi lấy mẫu lại của nó gần như giống hệt nhau. Giá trị p lý thuyết bằng 0,041 và giá trị p lấy mẫu lại bằng 0,042.



HÌNH 13.8. Gen thứ 877 trong tập dữ liệu *Khan* có giá trị thống kê kiểm định là $T = 0,57$. Phân bố lý thuyết và phân bố chuẩn khi lấy mẫu lại của nó khá khác nhau. Giá trị p lý thuyết bằng 0,571, và giá trị p lấy mẫu lại bằng 0,673.

phân phối. Như trong Mục 13.5.1, chúng tôi sử dụng thống kê t hai mẫu cho mỗi giả thuyết, dẫn đến các thống kê kiểm định $T_1, \dots, T_m$. Chúng ta có thể đơn giản là tính giá trị p cho mỗi trong số m giả thuyết không, như trong Phần 13.5.1, và sau đó áp dụng quy trình Benjamini-Hochberg của Mục 13.4.2 cho những giá trị p này. Tuy nhiên, hóa ra chúng ta có thể làm điều này một cách trực tiếp hơn, theo cách đó, thậm chí không cần phải tính giá trị p.

Hãy nhớ lại từ Mục 13.4 rằng FDR được định nghĩa là $E(V/R)$, sử dụng ký hiệu trong Bảng 13.2. Để ước tính FDR thông qua lấy mẫu lại, chúng tôi trước tiên hãy thực hiện phép tính gần đúng sau:

$$\text{FDR} = E \left[\frac{V}{R} \right] \approx \frac{E(V)}{R}. \quad (13.13)$$

Bây giờ giả sử chúng ta bác bỏ bất kỳ giả thuyết không nào mà thống kê kiểm định vượt quá c về giá trị tuyệt đối. Sau đó tính R ở mẫu số trên vế phải của (13.13) rất đơn giản: $R = \sum_{j=1}^m 1(|T_j| \geq c)$.

Tuy nhiên, từ số $E(V)$ ở phía bên phải của (13.13) khó hơn. Đây là số lượng dương tính giả dự kiến liên quan đến việc bác bỏ bất kỳ giả thuyết không nào mà thống kê kiểm định vượt quá c về giá trị tuyệt đối. Có nguy cơ nói điều hiển nhiên, việc ước tính V rất khó khăn vì chúng ta không biết giả thuyết nào trong số $H_{01}, \dots, H_{0m}$ thực sự đúng, và do đó chúng ta không biết giả thuyết bị bác bỏ nào là dương tính giả. Để khắc phục vấn đề này, chúng ta sử dụng phương pháp lấy mẫu lại, trong đó chúng ta mô phỏng dữ liệu theo $H_{01}, \dots, H_{0m}$, và sau đó tính toán các thống kê kiểm định thu được. Số lượng thống kê kiểm định được lấy mẫu lại vượt quá c cung cấp ước tính của V .

Cụ thể hơn, trong trường hợp thống kê t hai mẫu (13.11) cho mỗi giả thuyết không $H_{01}, \dots, H_{0m}$, chúng ta có thể ước tính $E(V)$ như sau. Gọi $x(j), \dots, x(j)$ và $y(j), \dots, y(j)$ là dữ liệu liên quan đến giả thuyết không thứ j , $j = 1, \dots, m$. Chúng ta hoán vị ngẫu nhiên $n_X + n_Y$ quan sát này, sau đó tính toán thống kê t trên dữ liệu đã hoán vị. Đối với dữ liệu đã hoán vị này, chúng ta biết rằng tất cả các giả thuyết không $H_{01}, \dots, H_{0m}$ đều đúng; do đó, số lượng thống kê t đã hoán vị vượt quá ngưỡng c về giá trị tuyệt đối cung cấp một ước tính cho $E(V)$. Ước tính này có thể được cải thiện hơn nữa bằng cách lặp lại quá trình hoán vị B lần, với giá trị B lớn, và lấy trung bình các kết quả.

Thuật toán 13.4 mô tả chi tiết quy trình này.¹⁸ Nó cung cấp cái được gọi là ước tính thay thế của FDR, bởi vì phép xấp xỉ trong (13.13) cho phép chúng ta ước tính FDR bằng cách thay R vào mẫu số và ước tính cho $E(V)$ vào tử số.

Chúng tôi áp dụng phương pháp lấy mẫu lại cho FDR từ Thuật toán 13.4, cũng như phương pháp Benjamini-Hochberg từ Thuật toán 13.2 sử dụng giá trị p lý thuyết, cho $m = 2.308$ gen trong tập dữ liệu Khan. Kết quả được thể hiện trong Hình 13.9. Chúng ta thấy rằng với một số lượng giả thuyết bị bác bỏ nhất định, các giá trị FDR ước tính gần như giống hệt nhau đối với hai phương pháp.

Chúng ta bắt đầu phần này bằng cách lưu ý rằng để kiểm soát FDR cho m phép thử giả thuyết bằng cách sử dụng phương pháp lấy mẫu lại, chúng ta có thể đơn giản tính toán m giá trị p lấy mẫu lại như trong Phần 13.5.1, và sau đó áp dụng quy trình Benjamini-Hochberg của Phần 13.4.2 cho các giá trị p này. Hóa ra nếu chúng ta định nghĩa giá trị p lấy mẫu lại thứ j là

$$p_j = \frac{\sum_{j=1}^m \sum_{b=1}^B 1(\lvert T_{jb} \rvert \geq \lvert T_j \rvert)}{Bm} \tag{13.14}$$

đối với $j = 1, \dots, m$, thay vì như trong (13.12), thì việc áp dụng quy trình Benjamini-Hochberg cho các giá trị p được lấy mẫu lại này hoàn toàn tương đương với Thuật toán 13.4. Lưu ý rằng (13.14) là một phương án thay thế cho (13.12) nhằm tổng hợp thông tin từ tất cả m bài kiểm tra giả thuyết để xấp xỉ phân phối null.

13.5.3 Khi nào thì các phương pháp lấy mẫu lại hữu ích?

Trong Phần 13.5.1 và 13.5.2, chúng tôi đã xem xét việc kiểm định giả thuyết không có dạng $H_0 : E(X) = E(Y)$ bằng cách sử dụng thống kê t hai mẫu (13.11), đối với đó chúng tôi

¹⁸Để triển khai Thuật toán 13.4 một cách hiệu quả, cần sử dụng cùng một tập hợp hoán vị trong Bước 2(b)i. Nên được sử dụng cho tất cả m giả thuyết không.

Thuật toán 13.4 Chèn FDR cho phép kiểm định T hai mẫu

1. Chọn một ngưỡng c , trong đó $c > 0$.
2. Với $j = 1, \dots, m$:

(a) Tính $T(j)$, thống kê t hai mẫu (13.11) cho null giả thuyết H_0j dựa trên dữ liệu gốc, $x(j)_1, \dots, x(j)_n$ và $y(j)_1, \dots, y(j)_n$.

(b) Đối với $b=1, \dots, B$, trong đó B là một số lớn (ví dụ: $B = 10.000$):

i. Hoán vị ngẫu nhiên $nX + nY$ quan sát. Gọi quan sát đầu tiên là... nX quan sát $x(j)_1, \dots, x(j)_n$, và gọi các quan sát còn lại là $y(j)_1, \dots, y(j)_n$.


ii. Tính (13.11) trên dữ liệu hoán vị $x(j)_1, \dots, x(j)_n$ và $y(j)_1, \dots, y(j)_n$ và gọi kết quả là $T(j), b$.

3. Tính $R = \sum_{j=1}^m 1(T(j) \geq c)$.

4. Tính $V = \frac{\sum_{b=1}^B \sum_{j=1}^m 1(T(j), b \geq c)}{B}$.

5. Tỷ lệ sai sót giả ước tính liên quan đến ngưỡng c là V/R .
- Đã xấp xỉ phân phối chuẩn thông qua phương pháp lấy mẫu lại. Chúng ta đã thấy rằng Việc sử dụng phương pháp lấy mẫu lại đã cho chúng tôi kết quả khác biệt đáng kể so với... sử dụng phương pháp giá trị p lý thuyết trong Hình 13.8, nhưng không sử dụng trong Hình 13.7. Nhìn chung, có hai trường hợp mà phương pháp lấy mẫu lại được áp dụng. Đặc biệt hữu ích:
1. Có lẽ không có phân phối chuẩn lý thuyết nào khả dụng. Đây có thể là trong trường hợp bạn đang kiểm tra giả thuyết không H_0 bất thường, hoặc sử dụng một Thống kê kiểm định bất thường T .

2. Có thể có một phân phối null lý thuyết, nhưng các giả định cần thiết cho tính hợp lệ của nó không được đáp ứng. Ví dụ, thống kê t hai mẫu trong (13.11) chỉ tuân theo phân phối $t_{nX+nY-2}$ nếu Các quan sát được phân bố chuẩn. Hơn nữa, nó tuân theo một quy luật nào đó. Phân phối $N(0, 1)$ chỉ áp dụng khi nX và nY khá lớn. Nếu dữ liệu là không tuân theo phân phối chuẩn và nX và nY nhỏ, thì các giá trị p được sử dụng của phân phối giả thuyết không sẽ không hợp lệ (tức là chúng sẽ không) (kiểm soát lỗi loại I một cách thích hợp).
- Nói chung, nếu bạn có thể tìm ra cách lấy mẫu lại hoặc hoán vị... Bạn có thể sắp xếp các quan sát của mình để tạo ra dữ liệu tuân theo phân phối chuẩn, sau đó tính toán giá trị p hoặc ước tính FDR bằng cách sử dụng các biến thể của Thuật toán 13.3 và 13.4. Trong nhiều tình huống thực tế, điều này cung cấp một Công cụ mạnh mẽ để kiểm định giả thuyết khi không có sẵn các phương pháp kiểm định giả thuyết có sẵn, hoặc khi các giả định chính làm nền tảng cho các bài kiểm tra mặc định đó bị vi phạm.



HÌNH 13.9. Đối với $j = 1, \dots, m = 2308$, chúng tôi đã kiểm định giả thuyết không rằng đối với gen thứ j trong tập dữ liệu **Khan**, mức độ biểu hiện trung bình trong u lympho Burkitt bằng mức độ biểu hiện trung bình trong u cơ vằn ác tính. Đối với mỗi giá trị của k từ 1 đến 2308, trục y hiển thị ước tính FDR liên quan đến việc bác bỏ giả thuyết không tương ứng với k giá trị p nhỏ nhất. Đường cong nét đứt màu cam thể hiện FDR thu được bằng quy trình Benjamini-Hochberg, trong khi đường cong liền màu xanh lam thể hiện FDR thu được bằng phương pháp lấy mẫu lại của Thuật toán 13.4, với $B = 10000$. Có rất ít sự khác biệt giữa hai ước tính FDR này. Theo cả hai ước tính, việc bác bỏ giả thuyết không đối với 500 gen có giá trị p nhỏ nhất tương ứng với tỷ lệ sai sót giả (FDR) khoảng 17,7%.

13.6 Thực hành: Kiểm tra nhiều lần

Chúng tôi bao gồm các mã hàng nhập khẩu thông thường đã xuất hiện trong các phòng thí nghiệm trước đây.

```
Trong [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm from ISLP
import load_data
```

Chúng tôi cũng thu thập các vật tư nhập khẩu mới cần thiết cho phòng thí nghiệm này.

```
Trong [2]: from scipy.stats import \
    (ttest_1samp,
     ttest_rel,
     ttest_ind, t
     as t_dbn) from
statsmodels.stats.multicomp import \ pairwise_tukeyhsd
from
statsmodels.stats.multitest import \ multipletests as
mult_test
```

13.6.1 Ôn tập về kiểm định giả thuyết

Chúng ta bắt đầu bằng cách thực hiện một số kiểm định t một mẫu. Đầu tiên, chúng ta tạo ra 100 biến, mỗi biến gồm 10 quan sát. 50 biến đầu tiên có giá trị trung bình là 0,5 và phương sai là 1, trong khi các biến còn lại có giá trị trung bình là 0 và phương sai là 1.

```
Trong [3]: rng = np.random.default_rng(12)
X = rng.standard_normal((10, 100)) true_mean
= np.array([0.5]*50 + [0]*50)
X += true_mean[None,:]
```

584 13. Kiểm tra nhiều lần

Đầu tiên, chúng ta sử dụng hàm `ttest_1samp()` từ mô-đun `scipy.stats` để kiểm định $H_0 : \mu_1 = 0$, giả thuyết không rằng biến đầu tiên có giá trị trung bình bằng không. `ttest_1samp()`

```
Trong [4]: result = ttest_1samp(X[:,0], 0)
          result.pvalue
```

Out[4]: 0.931

Giá trị p là 0,931, không đủ thấp để bác bỏ giả thuyết null ở mức ý nghĩa $\alpha = 0,05$. Trong trường hợp này, $\mu_1 = 0,5$, do đó giả thuyết null là sai. Vì vậy, chúng ta đã mắc lỗi loại II khi không bác bỏ giả thuyết null trong trường hợp giả thuyết null là sai.

Bây giờ chúng ta kiểm định giả thuyết $H_{0,j} : \mu_j = 0$ cho $j = 1, \dots, 100$. Chúng ta tính 100 giá trị p, sau đó xây dựng một vectơ ghi lại xem giá trị p thứ j nhỏ hơn hoặc bằng 0,05 hay không (trong trường hợp đó chúng ta bác bỏ $H_{0,j}$), hoặc lớn hơn 0,05 (trong trường hợp đó chúng ta không bác bỏ $H_{0,j}$), cho $j = 1, \dots, 100$.

```
Trong [5]: p_values = np.empty(100)
          for i in range(100):
              p_values[i] = ttest_1samp(X[:,i], 0).pvalue
          decision = pd.cut(p_values, [0, 0.05, 1],
                           labels=['Reject H0',
                                   'Không bác bỏ H0'])
          sự_thật = pd.Categorical(true_mean == 0,
                                  categories=[True, False],
                                  ordered=True)
```

Vì đây là tập dữ liệu mô phỏng, chúng ta có thể tạo một bảng 2×2 tương tự như Bảng 13.2.

```
Trong [6]: pd.crosstab(decision,
                      truth,
                      rownames=['Decision'],
                      colnames=['H0'])
```

Ra ngoài[6]:

	H0	Đúng Sai
Phản quyết		
Bác bỏ H0	5	15
Không bác bỏ H0	45	35

Do đó, ở mức $\alpha = 0,05$, chúng ta bác bỏ 15 trong số 50 giả thuyết null sai và bác bỏ không chính xác 5 trong số các giả thuyết null đúng. Sử dụng ký hiệu từ Phần 13.3, ta có $V = 5$, $S = 15$, $U = 45$ và $W = 35$. Chúng ta đã đặt $\alpha = 0,05$, có nghĩa là chúng ta kỳ vọng sẽ bác bỏ khoảng 5% các giả thuyết null đúng. Điều này phù hợp với bảng 2×2 ở trên, cho thấy chúng ta đã bác bỏ $V = 5$ trong số 50 giả thuyết null đúng.

Trong mô phỏng trên, đối với giả thuyết không sai, tỷ lệ giữa giá trị trung bình và độ lệch chuẩn chỉ là $0,5/1 = 0,5$. Điều này cho thấy tín hiệu khá yếu và dẫn đến số lượng lỗi loại II cao.

Thay vào đó, chúng ta hãy mô phỏng dữ liệu với tín hiệu mạnh hơn, sao cho tỷ lệ giữa giá trị trung bình và độ lệch chuẩn đối với các giả thuyết không sai bằng 1. Chúng ta chỉ mắc 10 lỗi loại II.

```

Trong [7]: true_mean = np.array([1]*50 + [0]*50)
X = rng.standard_normal((10, 100))
X += true_mean[None,:] for i in
range(100): p_values[i] =
    ttest_1samp(X[:,i], 0).pvalue decision = pd.cut(p_values,

            [0, 0.05, 1],
            labels=['Bác bỏ H0',
                    'Không bác bỏ H0'])
sự thật = pd.Categorical(true_mean == 0, categories=[True,
            False], ordered=True)

pd.crosstab(decision, truth,

            rownames=['Decision'],
            colnames=['H0'])

```

```

Ra ngoài[7]:
            H0      Đúng Sai
Phân quyết
    Bác bỏ H0          2      40
Không bác bỏ H0      48      10

```

13.6.2 Tỷ lệ lỗi theo nhóm

Nhớ lại từ (13.5) rằng nếu giả thuyết null đúng với mỗi m phép thử giả thuyết độc lập, thì FWER bằng $1 - (1 - \alpha)^m$. Chúng ta có thể sử dụng biểu thức này để tính FWER cho $m = 1, \dots, 500$ và $\alpha = 0,05, 0,01$ và $0,001$. Chúng ta vẽ đồ thị FWER cho các giá trị α này để tái tạo Hình 13.2.

```

Trong [8]: m = np.linspace(1, 501) fig, ax
= plt.subplots() [ax.plot(m, 1 -
(1 - alpha)**m,
        label=r'$\alpha$=%s' %
        str(alpha)) for alpha in [0.05, 0.01, 0.001]]
ax.set_xscale('log') ax.set_xlabel('Số lượng giả
thuyết') ax.set_ylabel(' Tỷ
lệ lỗi toàn bộ nhóm ') ax.legend() ax.axhline(0.05,
c='k', ls='--');

```

Như đã thảo luận trước đó, ngay cả với các giá trị m vừa phải như 50, FWER vẫn vượt quá 0,05 trừ khi α được đặt ở giá trị rất thấp, chẳng hạn như 0,001. Tất nhiên, vấn đề khi đặt α ở giá trị thấp như vậy là chúng ta có khả năng mắc một số lỗi loại II: nói cách khác, sức mạnh của chúng ta rất thấp.

Chúng tôi tiến hành kiểm định t một mẫu cho mỗi trong năm nhà quản lý đầu tiên trong tập dữ liệu *Quỹ*, nhằm kiểm định giả thuyết không rằng lợi nhuận trung bình của nhà quản lý quỹ thứ j bằng không, $H_{0,j} : \mu_j = 0$.

```

Trong [9]: Fund = load_data('Fund')
fund_mini = Fund.iloc[:, :5]
fund_mini_pvals = np.empty(5) for i in
range(5):

```

```
fund_mini_pvals[i] = ttest_1samp(fund_mini.iloc[:,i], 0).pvalue
fund_mini_pvals
```

```
Out[9]: array([0.006, 0.918, 0.012, 0.601, 0.756])
```

Giá trị p thấp đối với Quản lý số Một và số Ba, và cao đối với các quản lý còn lại. ba người quản lý. Tuy nhiên, chúng ta không thể đơn giản bác bỏ H_0 ,1 và H_0 ,3, vì Điều này sẽ không tính đến việc chúng tôi đã thực hiện nhiều lần thử nghiệm. Thay vào đó, chúng tôi sẽ tiến hành phương pháp Bonferroni và phương pháp Holm để kiểm soát FWER.

Để thực hiện điều này, chúng ta sử dụng hàm `multipletests()` từ mô-đun `statsmodels` (viết tắt là `mult_test()`). Với các giá trị p đã cho, đối với các phương pháp như...

Theo Holm và Bonferroni, hàm này xuất ra các giá trị p đã được điều chỉnh, có thể được coi là một tập hợp các giá trị p mới đã được hiệu chỉnh cho nhiều yếu tố khác nhau.

Kiểm tra. Nếu giá trị p điều chỉnh cho một giả thuyết nhất định nhỏ hơn hoặc bằng

nếu α bằng 0, thì giả thuyết đó có thể bị bác bỏ trong khi vẫn duy trì FWER là

không quá α . Nói cách khác, đối với các phương pháp như vậy, giá trị p đã điều chỉnh

Kết quả từ hàm `multipletests()` có thể được so sánh đơn giản với

FWER mong muốn để xác định xem có nên bác bỏ từng trường hợp hay không.

giả thuyết. Sau này chúng ta sẽ thấy rằng chúng ta có thể sử dụng cùng một hàm để kiểm soát Cả FDR nữa.

Hàm `mult_test()` nhận giá trị p và một đối số phương thức.

như một đối số `alpha` tùy chọn. Nó trả về các quyết định (từ chối ở bên dưới) như sau:

cũng như các giá trị p đã điều chỉnh (`bonf`).

```
Trong [10]: reject, bonf = mult_test(fund_mini_pvals, method = "bonferroni")[:2]
           từ chối
```

```
Out[10]: array([ Đúng, Sai, Sai, Sai, Sai])
```

Giá trị p của `bonf` chỉ đơn giản là giá trị `fund_mini_pvalues` nhân với 5 và được làm tròn xuống nhỏ hơn hoặc bằng 1.

```
Trong [11]: bonf, np.minimum(fund_mini_pvals * 5, 1)
```

```
Out[11]: (array([0.03, 1.      , 0.06,      , 1.   ]),
          array([0.03, 1.      , 0.06, 1.   , 1.   ]))
```

Do đó, bằng cách sử dụng phương pháp Bonferroni, chúng ta có thể bác bỏ giả thuyết không chỉ đối với Quản lý số Một trong khi kiểm soát FWER ở mức 0,05.

Ngược lại, khi sử dụng phương pháp của Holm, các giá trị p đã điều chỉnh cho thấy rằng Chúng ta có thể bác bỏ giả thuyết không đối với Quản lý Một và Quản lý Ba ở mức FWER của 0,05.

```
Trong [12]: mult_test(fund_mini_pvals, method = "holm", alpha=0.05)[:2]
```

```
Out[12]: (array([ True, False,  True, False, False]),
          mảng([0.03, 1.      , 0.05, 1.      , 1.   ]))
```

Như đã thảo luận trước đó, người quản lý số một dường như thể hiện khả năng làm việc đặc biệt tốt.

Trong khi đó, người quản lý số Hai lại có hiệu suất làm việc kém.

nhiều bài
kiểm tra()

đã điều chỉnh
giá trị p

```
Trong [13]: fund_mini.mean()
```

```
Ra[13]: Quản lý1 Quản      3.0
        lý2 -0.1
        Quản lý 3 2.8
        Quản lý4      0,5
        Quản lý5      0,3
        kiểu dữ liệu: float64
```

Liệu có bằng chứng nào cho thấy sự khác biệt đáng kể về hiệu suất giữa các yếu tố này không?
Hai người quản lý? Chúng ta có thể kiểm tra điều này bằng cách thực hiện kiểm định t-test cặp đôi
sử dụng hàm `ttest_rel()` từ `scipy.stats`:

kiểm định t-test cặp đôi
`ttest_rel()`

```
Trong [14]: ttest_rel(fund_mini['Manager1'],
                    fund_mini['Manager2']).pvalue
```

```
Out[14]: 0.038
```

Kết quả kiểm định cho ra giá trị p là 0,038, cho thấy sự khác biệt có ý nghĩa thống kê.
sự khác biệt.

Tuy nhiên, chúng tôi quyết định chỉ thực hiện thử nghiệm này sau khi xem xét dữ liệu.
và lưu ý rằng Quản lý Một và Quản lý Hai có điểm trung bình cao nhất và thấp nhất.
các buổi biểu diễn. Theo một nghĩa nào đó, điều này có nghĩa là chúng ta đã ngầm thực hiện các buổi biểu diễn.
 $\frac{5}{2} = 5(5 - 1)/2 = 10$ bài kiểm tra giả thuyết, thay vì chỉ một bài như đã thảo luận.
trong Mục 13.3.2. Do đó, chúng tôi sử dụng hàm `pairwise_tukeyhsd()` từ `statsmodels.stats.multicomp`
để áp dụng phương pháp Tukey nhằm điều chỉnh.
để kiểm định đa biến. Hàm này nhận đầu vào là mô hình hồi quy ANOVA đã được hiệu chỉnh, về cơ bản
chỉ là một mô hình hồi quy tuyến tính trong đó tất cả các biến đều được kiểm định đa biến.
Các biến dự báo mang tính định tính. Trong trường hợp này, biến phản hồi bao gồm giá trị hàng tháng.
Lợi nhuận vượt trội mà mỗi nhà quản lý đạt được, và hệ số dự báo cho biết
Người quản lý tương ứng với mỗi khoản hoàn trả.


từng cặp_
`tukeyhsd()`
ANOVA

```
Trong [15]: trả về = np.hstack([fund_mini.iloc[:,i] cho i trong phạm vi(5)])
managers = np.hstack([[i+1]*50 for i in range(5)])
tukey = pairwise_tukeyhsd(returns, managers)
print(tukey.summary())
```

So sánh đa cặp các giá trị trung bình - Tukey HSD, FWER=0,05
=====

nhóm1	nhóm2	trung bình	khác biệt	p-adj	thấp hơn	trên từ chối
1	2	-3.1	0.1862	-6.9865	0.7865	Sai
1	3	-0.2	0.9999	-4.0865	3.6865	Sai
1	4	-2.5	0.3948	-6.3865	1.3865	Sai
1	5	-2.7	0.3152	-6.5865	1.1865	Sai
2	3	2.9	0.2453	-0.9865	6.7865	Sai
2	4	0.6	0.9932	-3.2865	4.4865	Sai
2	5	0.4	0.9986	-3.4865	4.2865	Sai
3	4	-2.3	0.482	-6.1865	1.5865	Sai
3	5	-2.5	0.3948	-6.3865	1.3865	Sai
4	5	-0.2	0.9999	-4.0865	3.6865	Sai

Hàm `pairwise_tukeyhsd()` cung cấp khoảng tin cậy cho
sự khác biệt giữa mỗi cặp quản lý (cấp dưới và cấp trên), cũng như



HÌNH 13.10. Khoảng tin cậy 95% cho mỗi nhà quản lý trên dữ liệu *Quỹ*, sử dụng phương pháp Tukey để điều chỉnh cho việc kiểm định đa biến. Tất cả các khoảng tin cậy đều chồng chéo nhau, do đó không có sự khác biệt nào giữa các nhà quản lý là có ý nghĩa thống kê khi kiểm soát FWER ở mức 0,05.

Giá trị p. Tất cả các đại lượng này đã được điều chỉnh cho việc kiểm định đa biến.

Lưu ý rằng giá trị p cho sự khác biệt giữa Quản lý Một và Quản lý Hai đã tăng từ 0,038 lên 0,186, do đó không còn bằng chứng rõ ràng về sự khác biệt giữa hiệu suất của các quản lý. Chúng ta có thể vẽ biểu đồ khoảng tin cậy cho các so sánh từng cặp bằng cách sử dụng phương thức `plot_simultaneous()` của `tukey`. Bất kỳ cặp khoảng nào không chồng chéo nhau đều cho thấy sự khác biệt có ý nghĩa thống kê ở mức danh nghĩa 0,05. Trong trường hợp này, không có sự khác biệt nào được coi là có ý nghĩa thống kê như đã báo cáo trong bảng trên.

```
Trong [16]: fig, ax = plt.subplots(figsize=(8,8))
           tukey.plot_simultaneous(ax=ax);
```

Kết quả có thể được thấy trong Hình 13.10.

13.6.3 Tỷ lệ phát hiện sai

Bây giờ chúng ta tiến hành kiểm định giả thuyết cho tất cả 2.000 nhà quản lý quỹ trong tập dữ liệu *Fund*. Chúng ta thực hiện kiểm định t một mẫu cho giả thuyết $H_{0,j} : \mu_j = 0$, trong đó nêu rằng lợi nhuận trung bình của nhà quản lý quỹ thứ j bằng không.

```
Trong [17]: fund_pvalues = np.empty(2000)
           for i, manager in enumerate(Fund.columns): fund_pvalues[i] =
               ttest_1samp(Fund[manager], 0).pvalue
```

Có quá nhiều nhà quản lý để có thể xem xét việc kiểm soát FWER. Thay vào đó, chúng ta tập trung vào việc kiểm soát FDR: tức là tỷ lệ dự kiến các giả thuyết null bị bác bỏ thực chất là dương tính giả.

19Theo truyền thống, biểu đồ này hiển thị các khoảng cho mỗi hiệu số cặp. Với nhiều nhóm, việc hiển thị một khoảng cho mỗi nhóm sẽ thuận tiện và tương đương hơn, như được thực hiện ở đây. Bằng cách "lấy hiệu" tất cả các cặp khoảng thời gian được hiển thị ở đây, bạn sẽ thu được đồ thị truyền thống.

Hàm `multipletests()` (viết tắt là `mult_test()`) có thể được sử dụng để thực hiện quy trình Benjamini-Hochberg.

```
Trong [18]: fund_qvalues = mult_test(fund_pvalues, method = "fdr_bh")[1]
           fund_qvalues[:10]
```

```
Out[18]: array([0.09, 0.99, 0.12, 0.92, 0.96, 0.08, 0.08, 0.08, 0.08, 0.08])
```

Các giá trị q do phương pháp Benjamini-Hochberg đưa ra có thể được hiểu là ngưỡng FDR nhỏ nhất mà tại đó chúng ta sẽ bác bỏ một giả thuyết null cụ thể. Ví dụ, giá trị q là 0,1 cho biết chúng ta có thể bác bỏ giả thuyết null tương ứng ở mức FDR từ 10% trở lên, nhưng không thể bác bỏ giả thuyết null ở mức FDR dưới 10%.

giá trị q

Nếu ta kiểm soát FDR ở mức 10%, thì ta có thể bác bỏ giả thuyết $H_{0,j} : \mu_j = 0$ đối với bao nhiêu nhà quản lý quỹ?

```
Trong [19]: (fund_qvalues <= 0.1).sum()
```

```
Ra ngoài[19]: 146
```

Chúng tôi nhận thấy rằng 146 trong số 2.000 nhà quản lý quỹ có giá trị q dưới 0,1; do đó, chúng tôi có thể kết luận rằng 146 nhà quản lý quỹ này đã vượt trội hơn thị trường với tỷ lệ FDR là 10%. Chỉ khoảng 15 (10% trong số 146) nhà quản lý quỹ này có khả năng là những phát hiện sai lệch.

Ngược lại, nếu chúng ta sử dụng phương pháp Bonferroni để kiểm soát FWER ở mức $\alpha = 0,1$, thì chúng ta sẽ không bác bỏ được bất kỳ giả thuyết null nào!

```
Trong [20]: (fund_pvalues <= 0.1 / 2000).sum()
```

```
Ra [20]: 0
```

Hình 13.6 hiển thị các giá trị p được sắp xếp, $p(1) \leq p(2) \leq \dots \leq p(2000)$, cho tập dữ liệu `Fund`, cũng như ngưỡng bác bỏ của quy trình Benjamini-Hochberg. Nhớ lại rằng quy trình Benjamini-Hochberg xác định giá trị p lớn nhất sao cho $p(j) < qj/m$, và bác bỏ tất cả các giả thuyết mà giá trị p nhỏ hơn hoặc bằng $p(j)$. Trong đoạn mã bên dưới, chúng tôi tự triển khai quy trình Benjamini-Hochberg để minh họa cách thức hoạt động của nó. Đầu tiên, chúng tôi sắp xếp các giá trị p . Sau đó, chúng tôi xác định tất cả các giá trị p thỏa mãn $p(j) < qj/m$ (`sorted_set_`). Cuối cùng, `selected_` là một mảng boolean cho biết giá trị p nào nhỏ hơn hoặc bằng giá trị p lớn nhất trong `sorted_[sorted_set_]`. Do đó, `selected_` lập chỉ mục các giá trị p bị bác bỏ bởi quy trình Benjamini-Hochberg.

```
Trong [21]: sorted_ = np.sort(fund_pvalues) m
           = fund_pvalues.shape[0] q =
           0.1
           sorted_set_ = np.where(sorted_ < q * np.linspace(1, m, m) / m)[0] if
           sorted_set_.shape[0] > 0:
               selected_ = fund_pvalues < sorted_[sorted_set_].max() sorted_set_ =
               np.arange(sorted_set_.max()) else:

           selected_ = []
           sorted_set_ = []
```

590 13. Kiểm tra nhiều lần

Chúng tôi sẽ tái hiện lại phần giữa của Hình 13.6.

```
Trong [22]: fig, ax = plt.subplots()
ax.scatter(np.arange(0, sorted_.shape[0]) + 1,
           đã sắp xếp_, s=10)
ax.set_yscale('log')
ax.set_xscale('log')
ax.set_ylabel('Giá trị P')
ax.set_xlabel('Chỉ mục')
ax.scatter(sorted_set_+1, sorted_[sorted_set_], c='r', s=20)
ax.axline((0, 0), (1,q/m), c='k', ls='--', linewidth=3);
```

13.6.4 Phương pháp lấy mẫu lại

Ở đây, chúng tôi triển khai phương pháp lấy mẫu lại để kiểm định giả thuyết bằng cách sử dụng bộ dữ liệu Khan, mà chúng tôi đã nghiên cứu trong Phần 13.5. Đầu tiên, chúng tôi hợp nhất Dữ liệu huấn luyện và kiểm tra, dẫn đến các quan sát trên 83 bệnh nhân. cho 2.308 gen.

```
Trong [23]: Khan = load_data('Khan')
D = pd.concat([Khan['xtrain'], Khan['xtest']])
D['Y'] = pd.concat([Khan['ytrain'], Khan['ytest']])
D['Y'].value_counts()
```

```
Ra[23]: 2 4      29
        25
        3      18
        1      11
Tên: Y, kiểu dữ liệu: int64
```

Có bốn loại ung thư. Đối với mỗi gen, chúng tôi so sánh mức độ biểu hiện trung bình ở loại thứ hai (u cơ vằn ác tính) với mức độ biểu hiện trung bình ở loại thứ ba. Lớp thứ tư (U lympho Burkitt). Thực hiện xét nghiệm hai mẫu tiêu chuẩn. Kiểm định t sử dụng hàm `ttest_ind()` từ `scipy.stats` trên gen thứ 11 cho ra giá trị thống kê kiểm định là -2,09 và giá trị p tương ứng là 0,0412, cho thấy bằng chứng khiếm tốn về sự khác biệt trong mức độ biểu hiện trung bình giữa hai loại ung thư. các loại.

`ttest_ind()`

```
Trong [24]: D2 = D[lambda df:df['Y'] == 2]
D4 = D[lambda df:df['Y'] == 4]
gen_11 = 'G0011'
được quan sátT, pvalue = ttest_ind(D2[gen_11],
                                   D4[gen_11],
                                   equal_var=True)
quan sát đượcT, giá trị p
```

```
Out[24]: (-2.094, 0.041)
```

Tuy nhiên, giá trị p này dựa trên giả định rằng, dưới giả thuyết không có sự khác biệt giữa hai nhóm, thống kê kiểm định tuân theo một phân phối t với $29 + 25 - 2 = 52$ bậc tự do. Thay vì sử dụng phân phối giả thuyết này, chúng ta có thể chia ngẫu nhiên 54 bệnh nhân. chia thành hai nhóm gồm 29 và 25 người, và tính toán một thống kê kiểm định mới. Theo Giả thuyết không có sự khác biệt giữa các nhóm, thống kê kiểm định mới này phải có cùng phân phối với thống kê ban đầu của chúng ta. Lập lại điều này

Việc thực hiện quy trình 10.000 lần cho phép chúng ta xấp xỉ phân bố chuẩn của thống kê kiểm định. Chúng ta tính toán tỷ lệ thời gian mà thống kê kiểm định quan sát được vượt quá thống kê kiểm định thu được thông qua lấy mẫu lại.

```
Trong [25]: B = 10000
Tnull = np.empty(B)
D_ = np.hstack([D2[gene_11], D4[gene_11]]) n_ =
D2[gene_11].shape[0]
D_null = D_.copy() for
b in range(B):
    rng.shuffle(D_null)
    ttest_ = ttest_ind(D_null[:n_],
                      D_null[n_:],
                      equal_var=True)
    Tnull[b] = ttest_.statistic
(np.abs(Tnull) > np.abs(observedT)).mean()
```

Out[25]: 0.0398

Phân số này, 0,0398, là giá trị p dựa trên phương pháp lấy mẫu lại của chúng tôi. Nó gần như giống hệt với giá trị p là 0,0412 thu được bằng cách sử dụng phân bố giả thuyết ban đầu. Chúng ta có thể vẽ biểu đồ tần suất của các thống kê kiểm định dựa trên phương pháp lấy mẫu lại để tái tạo lại Hình 13.7.

```
Trong [26]: fig, ax = plt.subplots(figsize=(8,8))
ax.hist(Tnull,
        bins=100,
        density=True,
        facecolor='y',
        label='Null')
xval = np.linspace(-4.2, 4.2, 1001)
ax.plot(xval,
        t_dbn.pdf(xval, D_.shape[0]-2), c='r')

ax.axvline(observedT,
          c='b',
          label='Observed')

ax.legend()
ax.set_xlabel(" Phân phối rỗng của thống kê kiểm định");
```

Phân bố chuẩn dựa trên phương pháp lấy mẫu lại gần như giống hệt với phân bố chuẩn lý thuyết, được hiển thị bằng màu đỏ.

Cuối cùng, chúng ta sẽ triển khai phương pháp lấy mẫu lại FDR bằng plugin được nêu trong Thuật toán 13.4. Tùy thuộc vào tốc độ máy tính của bạn, việc tính toán FDR cho tất cả 2.308 gen trong tập dữ liệu Khan có thể mất một thời gian. Do đó, chúng ta sẽ minh họa phương pháp này trên một tập con ngẫu nhiên gồm 100 gen. Đối với mỗi gen, trước tiên chúng ta tính toán thống kê kiểm định quan sát được, sau đó tạo ra 10.000 thống kê kiểm định được lấy mẫu lại. Quá trình này có thể mất vài phút để chạy. Nếu bạn đang vội, bạn có thể đặt B bằng một giá trị nhỏ hơn (ví dụ: B=500).

```
Trong [27]: m, B = 100, 10000
idx = rng.choice(Khan['xtest'].columns, m, replace=False)
T_vals = np.empty(m)
Tnull_vals = np.empty((m, B))

for j in range(m): col
    = idx[j]
```

```

T_vals[j] = ttest_ind(D2[col], D4[col],
                      equal_var=True).statistic D_ =
np.hstack([D2[col], D4[col]])
D_null = D_.copy() for
b in range(B):
    rng.shuffle(D_null)
    ttest_ = ttest_ind(D_null[:n_],
                      D_null[n_:],
                      equal_var=True)
    Tnull_vals[j,b] = ttest_.statistic

```

Tiếp theo, chúng ta tính toán số lượng giả thuyết null bị bác bỏ R , số lượng dương tính giả ước tính V và FDR ước tính, cho một loạt các giá trị ngưỡng c trong Thuật toán 13.4. Các giá trị ngưỡng được chọn bằng cách sử dụng giá trị tuyệt đối của các thống kê kiểm định từ 100 gen.

```

Trong [28]: cutoffs = np.sort(np.abs(T_vals))
FDRs, Rs, Vs = np.empty((3, m)) for j in
range(m): R =
    np.sum(np.abs(T_vals) >= cutoffs[j])
    V = np.sum(np.abs(Tnull_vals) >= cutoffs[j]) / B Rs[j] = R Vs[j]
    = V FDRs[j]
    = V / R

```

Giờ đây, với bất kỳ tỷ lệ FDR nào, chúng ta đều có thể tìm ra các gen sẽ bị loại bỏ. Ví dụ, với mức FDR được kiểm soát ở mức 0,1, chúng ta bác bỏ 15 trong số 100 giả thuyết null. Trung bình, chúng ta kỳ vọng khoảng một hoặc hai gen trong số này (tức là 10% của 15) là những phát hiện sai. Ở mức FDR là 0,2, chúng ta có thể bác bỏ giả thuyết null đối với 28 gen, trong đó chúng ta kỳ vọng khoảng sáu gen là những phát hiện sai.

Biến `idx` lưu trữ thông tin về các gen được bao gồm trong 100 gen được chọn ngẫu nhiên của chúng ta. Hãy xem xét các gen có giá trị FDR ước tính nhỏ hơn 0,1.

```

Trong [29]: sorted(idx[np.abs(T_vals) >= cutoffs[FDRs < 0.1].min()])

```

Ở ngưỡng FDR là 0,2, nhiều gen hơn được chọn, nhưng đổi lại sẽ có sự giảm sút. Tỷ lệ phát hiện sai dự kiến cao hơn.

```

Trong [30]: sorted(idx[np.abs(T_vals) >= cutoffs[FDRs < 0.2].min()])


```

Dòng lệnh tiếp theo tạo ra Hình 13.11, tương tự như Hình 13.9, ngoại trừ việc nó chỉ dựa trên một tập hợp con của các gen.

```

Trong [31]: fig, ax = plt.subplots()
ax.plot(Rs, FDRs, 'b', linewidth=3)
ax.set_xlabel("Số lần từ chối") ax.set_ylabel("Tỷ lệ phát hiện sai");

```



HÌNH 13.11. Tỷ lệ phát hiện sai ước tính so với số lượng giả thuyết null bị bác bỏ, đối với 100 gen được chọn ngẫu nhiên từ tập dữ liệu [Khan](#).

13.7 Bài tập

Khái niệm

- Giả sử chúng ta kiểm định m giả thuyết không, tất cả đều đúng. Chúng ta kiểm soát sai số loại I cho mỗi giả thuyết không ở mức α . Đối với mỗi câu hỏi phụ, hãy giải thích câu trả lời của bạn.

(a) Tổng cộng, chúng ta dự kiến sẽ mắc bao nhiêu lỗi loại I? (b) Giả

sử m bài kiểm tra mà chúng ta thực hiện là độc lập.

Tỷ lệ sai sót tổng thể liên quan đến m phép thử này là bao nhiêu?

Gợi ý: Nếu hai sự kiện A và B độc lập, thì $\Pr(A \cap B) = \Pr(A) \Pr(B)$. (c)

Giả sử $m = 2$,

và giá trị p của hai phép thử có tương quan dương, sao cho nếu một giá trị nhỏ thì giá trị kia cũng có xu hướng nhỏ, và nếu một giá trị lớn thì giá trị kia cũng có xu hướng lớn. Tỷ lệ sai sót tổng thể liên quan đến các phép thử $m = 2$ này so sánh về mặt định tính như thế nào với câu trả lời trong (b) với $m = 2$?

Gợi ý: Đầu tiên, giả sử hai giá trị p có tương quan hoàn hảo. (d) Giả sử

lại rằng $m = 2$, nhưng bây giờ các giá trị p cho hai bài kiểm tra có tương quan nghịch, sao cho nếu một giá trị lớn thì giá trị kia sẽ có xu hướng nhỏ. Tỷ lệ lỗi tổng thể liên quan đến các bài kiểm tra $m = 2$ này so sánh về mặt định tính như thế nào với câu trả lời trong (b) với $m = 2$?

Gợi ý: Đầu tiên, giả sử rằng bất cứ khi nào một giá trị p nhỏ hơn α , thì giá trị p còn lại sẽ lớn hơn α . Nói cách khác, chúng ta không bao giờ có thể bác bỏ cả hai giả thuyết null.

2. Giả sử chúng ta kiểm định m giả thuyết và kiểm soát sai số loại I đối với
- Mỗi giả thuyết ở mức α . Giả sử rằng tất cả các giá trị m_p đều độc lập và tất cả các giả thuyết không đều đúng.
- (a) Giả sử biến ngẫu nhiên A_j bằng 1 nếu giả thuyết không thứ j là bị từ chối, và 0 trong các trường hợp khác. Phân bố của A_j là gì ?
- (b) Phân bố của (c) Độ lệch chuẩn của $\sum_{j=1}^m A_j$?
- số lỗi loại I là bao nhiêu?
Chúng ta sẽ làm gì?
3. Giả sử chúng ta kiểm định m giả thuyết không và kiểm soát sai số loại I cho
- Giả thuyết không thứ j ở mức ý nghĩa α_j , với $j = 1, \dots, m$. Hãy lập luận rằng
- Tỷ lệ sai sót trong toàn bộ nhóm không lớn hơn $\sum_{j=1}^m \alpha_j$.

Giá trị p của giả thuyết null	
H01 0.0011	
H02 0,031	
H03 0.017	
H04 0.32	
H05 0.11	
H06 0.90	
H07 0.07	
H08 0.006	
H09 0.004	
H10 0.0009	

BẢNG 13.4. Giá trị p cho Bài tập 4.

4. Giả sử chúng ta kiểm định $m = 10$ giả thuyết và thu được các giá trị p được hiển thị. trong Bảng 13.4.
- (a) Giả sử chúng ta muốn kiểm soát sai số loại I cho mỗi giá trị null. giả thuyết null ở mức ý nghĩa $\alpha = 0,05$. Chúng ta sẽ sử dụng giả thuyết null nào? từ chối?
- (b) Bây giờ giả sử chúng ta muốn kiểm soát FWER ở mức $\alpha = 0,05$. Chúng ta sẽ bác bỏ giả thuyết không nào? Hãy giải thích câu trả lời của bạn.
- (c) Bây giờ giả sử chúng ta muốn kiểm soát FDR ở mức $q = 0,05$. Chúng ta sẽ bác bỏ giả thuyết không nào? Hãy giải thích câu trả lời của bạn.
- (d) Bây giờ giả sử chúng ta muốn kiểm soát FDR ở mức $q = 0,2$. Chúng ta sẽ bác bỏ giả thuyết không nào? Hãy giải thích câu trả lời của bạn.
- (e) Trong số các giả thuyết không bị bác bỏ ở mức FDR $q = 0,2$, có khoảng bao nhiêu giả thuyết là dương tính giả? Hãy giải thích câu trả lời của bạn.
5. Đối với bài toán này, bạn sẽ tự đặt ra các giá trị p dẫn đến một kết quả nhất định.
- Số Lượng từ chối khi sử dụng phương pháp Bonferroni và Holm.
- (a) Cho ví dụ về năm giá trị p (tức là năm số nằm giữa 0 và 1 (mà, cho mục đích của bài toán này, chúng ta sẽ hiểu là giá trị p) mà cả phương pháp Bonferroni và phương pháp Holm đều cho kết quả chính xác.

Bác bỏ chính xác một giả thuyết không khi kiểm soát FWER ở mức 0,1.

- (b) Bây giờ hãy đưa ra ví dụ về năm giá trị p mà tại đó phương pháp Bonferroni bác bỏ một giả thuyết null và phương pháp Holm bác bỏ nhiều hơn một giả thuyết null ở mức ý nghĩa 0,1.

6. Đối với mỗi trong ba bảng ở Hình 13.3, hãy trả lời các câu hỏi sau:
câu hỏi:

- (a) Có bao nhiêu kết quả dương tính giả, âm tính giả, dương tính thật, âm tính thật, lỗi loại I và lỗi loại II phát sinh khi áp dụng phương pháp Bonferroni để kiểm soát FWER ở mức $\alpha = 0,05$?
- (b) Có bao nhiêu kết quả dương tính giả, âm tính giả, dương tính thật, âm tính thật, lỗi loại I và lỗi loại II phát sinh khi áp dụng quy trình Holm để kiểm soát FWER ở mức $\alpha = 0,05$?
- (c) Tỷ lệ phát hiện sai liên quan đến việc sử dụng phương pháp Bonferroni để kiểm soát FWER ở mức $\alpha = 0,05$ là bao nhiêu? (d) Tỷ lệ phát hiện sai liên quan đến việc sử dụng phương pháp Holm để kiểm soát FWER ở mức $\alpha = 0,05$ là bao nhiêu?
- (e) Câu trả lời cho (a) và (c) sẽ thay đổi như thế nào nếu thay vào đó chúng ta sử dụng phương pháp Bonferroni để kiểm soát FWER ở mức $\alpha = 0,001$?

Đã áp dụng

7. Bài toán này sử dụng bộ dữ liệu **Carseats** trong gói **ISLP**.

- (a) Đối với mỗi biến định lượng trong tập dữ liệu, ngoại trừ **Doanh số**, hãy xây dựng một mô hình tuyến tính để dự đoán **Doanh số** dựa trên biến định lượng đó. Hãy báo cáo giá trị p liên quan đến các hệ số của các biến. Nghĩa là, đối với mỗi mô hình có dạng $Y = \beta_0 + \beta_1 X + \epsilon$, hãy báo cáo giá trị p liên quan đến hệ số β_1 . Ở đây, Y đại diện cho **Doanh số** và X đại diện cho một trong các biến định lượng khác.
- (b) Giả sử chúng ta kiểm soát sai số loại I ở mức $\alpha = 0,05$ đối với các giá trị p thu được trong (a). Chúng ta bác bỏ giả thuyết không nào? (c) Bây giờ giả sử chúng ta kiểm soát FWER ở mức 0,05 đối với các giá trị p . Chúng ta bác bỏ giả thuyết không nào?
- (d) Cuối cùng, giả sử chúng ta kiểm soát FDR ở mức 0,2 đối với các giá trị p . Chúng ta bác bỏ giả thuyết không nào?

8. Trong bài toán này, chúng ta sẽ mô phỏng dữ liệu từ $m = 100$ nhà quản lý quỹ.

```
rng = np.random.default_rng(1) n, m =
20, 100 X =
rng.normal(size=(n, m))
```

Các số liệu này thể hiện tỷ lệ lợi nhuận phần trăm của mỗi nhà quản lý quỹ cho mỗi khoản mục. trong khoảng thời gian $n = 20$ tháng. Chúng tôi muốn kiểm tra giả thuyết không rằng mỗi Tỷ lệ lợi nhuận của người quản lý quỹ có giá trị trung bình của quần thể bằng... số không. Lưu ý rằng chúng tôi đã mô phỏng dữ liệu theo cách mà mỗi quỹ Tỷ lệ lợi nhuận của người quản lý có giá trị trung bình của toàn bộ quần thể bằng không; trong các trường hợp khác Nói cách khác, tất cả m giả thuyết không đều đúng.

- (a) Tiến hành kiểm định t một mẫu cho mỗi nhà quản lý quỹ và vẽ biểu đồ. Biểu đồ tần suất của các giá trị p thu được.
- (b) Nếu chúng ta kiểm soát lỗi loại I cho mỗi giả thuyết không ở mức $\alpha = 0,05$, thì chúng ta bác bỏ bao nhiêu giả thuyết null?
- (c) Nếu chúng ta kiểm soát FWER ở mức $0,05$, thì có bao nhiêu giả thuyết null... Chúng ta bác bỏ những giả thuyết nào?
- (d) Nếu ta kiểm soát FDR ở mức $0,05$, thì ta sẽ bác bỏ bao nhiêu giả thuyết không?
- (e) Bây giờ giả sử chúng ta "chọn lọc" 10 nhà quản lý quỹ có hiệu suất tốt nhất trong dữ liệu của chúng ta. Nếu chúng ta kiểm soát FWER chỉ cho những người này Nếu ta kiểm soát tỷ lệ sai sót giả (FDR) chỉ cho 10 nhà quản lý quỹ ở mức $0,05$, thì ta sẽ bác bỏ bao nhiêu giả thuyết null? nếu các nhà quản lý ở cấp độ $0,05$, thì chúng ta có bao nhiêu giả thuyết không? từ chối?
- (f) Giải thích tại sao phân tích trong (e) lại gây hiểu nhầm.
Gợi ý: Các phương pháp tiêu chuẩn để kiểm soát FWER và FDR giả định rằng tất cả các giả thuyết null được kiểm định đều được điều chỉnh cho tính đa bội, và không có sự "chọn lọc" các giá trị p nhỏ nhất. Điều đó đã xảy ra. Vậy điều gì sẽ xảy ra nếu chúng ta chọn lọc?

Mục lục

độ chính xác, 415 kích hoạt, 400 hàm kích hoạt, 401 cộng, 11, 94-98, 110-111 tính cộng, 305, 306 R2 hiệu chỉnh , 87, 231, 232, 236- 238 Bộ dữ liệu quảng cáo , 15, 16, 19, 69, 71-73, 77, 78, 80, 82, 83, 85, 87-90, 95, 96 , 109- 111 phân cụm kết hợp, 525 Tiêu chí thông tin Akaike, 87, 231, 232, 236-238 giả thuyết thay thế, 76, 559 phân tích phương sai, 312 ANOVA, 587 diện tích dưới đường cong, 155, 486- 487 đôi số, 40 mảng, 42 thuộc tính, 42 AUC, 155 Bộ dữ liệu tự động , 12, 66, 98-101, 129, 197, 202-207, 327, 398 tự tương quan, 421 tự hồi quy, 423 trực, 48 lắp đặt lại, 307, 328	lan truyền ngược, 429 lựa chọn từng bước ngược, 87, 234-235 túi n- gram, 415 túi tử, 414 bagging, 11, 24, 331, 343-346, 354, 360-361 BART, 343, 350, 353, 354, 362- 363 đường cơ sở, 93, 145, 161 hàm cơ sở, 293-294, 296 Bộ phân loại Bayes, 35-37, ranh giới quyết định 147 , lỗi 148 , 35-37 Định lý Bayes, 146, 250 Bayesian, 250-251, 353 Cây hồi quy cộng tính Bayes, 331, 343, 350, 350, 353, 354, 362-363 Tiêu chí thông tin Bayesian, 87, 231, 232, 236-238 Thủ tục Benjamini-Hochberg, 575- 577 Phân phối Bernoulli, 172 lựa chọn tập con tốt nhất, 231, 246 độ lệch, 31- 34, 74, 90, 159, 405 phân tích độ lệch-phương sai, 32
--	--

sự đánh đổi, [31-34](#), [38](#), [111-112](#),
[157](#), [159](#), [163](#), [164](#), [242](#),
[254](#), [263](#), [266](#), [301](#), [336](#),
[376](#), [385](#)

hai chiều, [425](#)

Bộ dữ liệu [chia sẻ xe đạp](#) , [12](#), 167-172 nhị
phân, [27](#), [138](#) biểu
đồ hai chiều, [507](#), [508](#)

Phương pháp Bonferroni, [575-577](#), [585](#)

Boolean, [53](#), [176](#)

boosting, [11](#), [24](#), [331](#), [343](#), [347-350](#) ,
[354](#), 361-362

bootstrap, [11](#), [201](#), [212-214](#), [343](#)

Bộ dữ liệu [Boston](#) , [12](#), [67](#), [117](#), [122](#),
[133](#), [199](#), [227](#), [287](#), [327](#),
[364](#), [556](#)

phân cụm từ dưới lên, [525](#) biểu
đồ hộp, [62](#)

Bộ dữ liệu [BrainCancer](#) , [12](#), [472-](#) [474](#),
[476](#), nhánh [482](#) ,

giai đoạn khởi
động [333](#) , [352](#)

Chỉ số C, [487](#)

Bộ dữ liệu [Caravan](#) , [12](#), [184](#), [366](#)

Bộ dữ liệu ghế ô tô , [12](#), [126](#), [130](#), [364](#) phân

loại, 2, [27](#) dữ liệu bị
kiểm duyệt, 469-502 kiểm duyệt
độc lập, [471](#)

 khoảng, [471](#) bên trái,
 [471](#) cơ chế, [471](#)
 không cung
 cấp thông tin, [471](#)
 bên phải, [471](#) thời gian,
 [470](#) quy tắc
 chuỗi, [429](#)

kênh, [407](#)

Bộ dữ liệu [CIFAR100](#) , [406](#), [409-411](#), [448](#),
[449](#) phân

loại, 2, [11](#), [27](#), [34-39](#), [135-199](#) , 367-382

 tỷ lệ lỗi, [338](#)

 cây, [337-341](#), 355-
 358 bộ phân loại, [135](#) phân

tích cụm, 25-26

phân cụm, 4, [25-26](#), 520-535

kết hợp, [525](#)

từ dưới lên, [525](#)

phân cấp, [521](#), 525-535

K-means, [11](#), 521-524

Kiểm định Cochran-Mantel-Haenszel, hệ số
[475](#) , [71](#)

Bộ dữ liệu [đại học](#) , [12](#), [65](#), [286](#), [328](#) hiện
tượng đa cộng tuyến, 106-

110 phép nối, [41](#) xác
suất có điều kiện, [35](#) khoảng tin
cậy, [75-76](#), [90](#), [110](#), [292](#) yếu tố gây nhiễu, [144](#)
 ma

trận nhầm lẫn, [153](#),
[176](#) liên tục, [2](#) đường đồng mức, [246](#)

biểu đồ đường
đồng mức, [50](#) độ
tương phản, [94](#) hàm
tiện ích, [53](#) bộ
lọc tích chập, [407](#) lớp tích chập,
[407](#) mạng nơ-ron tích chập ,
[406-413](#)

tương quan, [79](#), [82-83](#), [530](#) dữ
liệu đếm, [167](#), [170](#)

Mô hình rủi ro tỷ lệ của Cox, [480](#), 483-
 486

Cp, [87](#), [231](#), [232](#), 236-238

Bộ dữ liệu [tín dụng](#) , [12](#), [91](#), [92](#), [94](#),
[97](#), [98](#), 106-109

entropy chéo, [405](#)

kiểm định chéo, [11](#), [31](#), [34](#), [201-211](#) ,
[231](#), [252](#), [270](#) k-fold,
 206-209 loại bỏ
 một phần tử, 204-206 lời
nguyên của chiều không gian, [115](#), [193](#),
 [266](#)

tăng cường dữ liệu, khung dữ
liệu [411](#) , [55](#)

Bộ dữ liệu

[Quảng cáo](#), [15](#), [16](#), [19](#) , 69, 71-73,
 [77](#), [78](#), [80](#), [82](#), [83](#), [85](#), [87-](#)
 [90](#), [95](#), [96](#), [109-111](#)

 Ô tô, [12](#), [66](#), [98-101](#), [129](#), [197](#), [202-](#)
 [207](#), [327](#), [398](#)

 Chia sẻ xe đạp, [12](#), 167-172

Boston, 12, 67, 117, 122, 133, 199, 227, 287, 327, 364, 556 Ung thư não, 12, 472-474, 476, 482 Đoàn lữ hành , 12.184.366 Ghế ô tô, 12, 126, 130, 364 CIFAR100, 406, 409-411, 448, 449 Cao đẳng, 12, 65, 286, 328 Tín dụng, 12, 91, 92, 94, 97, 98, 106-109 Mặc định, 12, 136-139, 141-144 , 152-156, 160, 161, 225, 226, 466 Quy, 12, 567-570, 572, 575, 576, 585, 588, 589 Tim, 339, 340, 344-347, 352, 353, 382, 383 Người đánh bóng: 12, 332, 333, 336, 338, 339, 366, 425, 426, 437, 446 IMDb, 413, 415, 416, 418, 420, 437, 458, 467 Thu nhập, 16-18, 21-23 Khan, 12, 579-581, 583, 590, 593 MNIST, 402-404, 406, 430, 431, 441, 444, 445, 448 NCI60, 4, 5, 12, 546, 548-550 NYSE, 12, 422-424, 466, 467 OJ, 12, 365, 398 Danh mục đầu tư, 12 Ấn phẩm, 12, 482-487 Siêu thị, 2, 3, 12, 173, 184, 196 USArrests, 12, 507, 508, 510, 512, 513, 515, 516, 518, 519 Tiền lương, 1, 2, 8, 9, 12, 290, 291, 293, 295, 297-300, 302-306 , 309, 315, 327 Hàng tuần, 12, 196, 226 kiểu dữ liệu, 42 hàm quyết định, 387 cây quyết định, 11, 331-342 học sâu, 399	Bộ dữ liệu mặc định , 12, 136-139, 141-144 , 152-156, 160 , 161, 225, 226, 466 bậc tự do, 30, 266, 295, 296, 301 biểu đồ cây, 521, 525-530 hàm mật độ, 146 biến phụ thuộc , 15 đạo hàm, 296, 300 lớp dò, 410 độ lệch, 232 từ điển, 66 giảm chiều, 230, 253-262 hàm phân biệt, 149 phương pháp phân biệt, 146-161 độ khác biệt, 530-532 khoảng cách dựa trên tương quan, 530-532, 554 Euclidean, 509, 522, 523, 529- 532 giảm kép, 431-435 phân phối mũ kép, 251 bó học, 406, 431 biến giả, 91-94, 138, 142, 292 dừng sớm, 430 bậc tự do hiệu quả, 301 phân tích giá trị riêng, 506, 516 khuỷu tay, 548 nhúng, 418 lớp nhúng, 419 tập hợp, 343-354 entropy, 337-339, 363 kỷ nguyên, 430 lỗi không thể rút gọn, 17, 30 tỷ lệ, 34 có thể rút gọn, 17 số hạng, 16 Khoảng cách Euclidean, 509, 522, 523, 529-532, 554 thời gian sự kiện, 470 ngoại lệ, 45 giá trị kỳ vọng, 18 phân tích dữ liệu thăm dò, 504 hàm mũ, 173 họ hàm mũ, 173 Thống kê F, 84
--	---

yếu tố, [92](#)
giai thừa, [170](#)
thời gian thất bại,
[470](#)
tỷ lệ phát hiện sai, [155](#), [573](#) tỷ lệ phát
hiện, [558](#), [573-577](#), 579-582 âm tính,
[155](#) , [562](#)
dương tính, 155, 562 ,
[563](#) tỷ lệ dương tính, [155](#),
[156](#), [382](#) tỷ lệ lỗi theo họ, [565-573](#),
[577](#) đặc trưng, [15](#) bản đồ đặc trưng, [406](#) lựa
chọn đặc
trưng, [230](#) tạo đặc
trưng, [414](#) mạng nơ-ron
truyền thẳng, [400](#)
hình, [48](#) phù hợp , [21](#) giá trị phù hợp, [101](#)
làm phẳng,
[424](#)
linh hoạt, [21](#) dấu
phẩy động, [43](#) lựa
chọn từng bước
tiền, [86](#), [87](#), [233-234](#),
[268](#) hàm, [40](#)

Bộ dữ liệu quỳ , [12](#), [567-570](#), [572](#), [575](#),
[576](#), [585](#), [588](#), [589](#)

Gamma, [173](#)
Phân phối Gauss (chuẩn), [146](#), [147](#), [150](#), [172](#), [561](#)
mô hình cộng tính tổng
quát, 5, [24](#), [162](#), [289](#), [290](#), [305-309](#), [319](#)

mô hình tuyến tính tổng quát, 5, [135](#),
[167-174](#), [217](#)
mô hình sinh, 146-161
Chỉ số Gini, [337-339](#), [345](#), [346](#), [363](#)
điểm cực tiểu toàn cục,
[427](#) độ dốc, [428](#)
phương pháp giảm độ dốc, [427](#)

Chỉ số tương quan của Harrell, [487](#) hàm
nguy cơ, 476-478 đường cơ sở,
[478](#) tỷ lệ nguy
cơ, [476](#)
Bộ dữ liệu tim , [339](#), [340](#), [344-347](#),
[352](#), [353](#), [382](#), [383](#)
bản đồ nhiệt,
[50](#) trợ giúp, [311](#)

phương sai không đồng nhất, [103](#),
[168](#) lớp ẩn, [400](#) đơn
vị ẩn, [400](#) phân cụm
phân cấp, 525-530 biểu đồ cây, 525-
528 đảo ngược, [529](#) liên
kết, 529-530
nguyên tắc phân
cấp, [96](#) chiều cao, [86](#), [234](#),
[263](#) tổn thất bản lề, [385](#)

Bộ dữ liệu người đánh bóng , [12](#), [332](#),
[333](#), [336](#), [338](#), [339](#), [366](#),
[425](#), [426](#), [437](#),
[446](#) bộ giữ lại, [202](#)
Phương pháp Holm, [568](#), [576](#), [585](#) phân
phối siêu hình học, [501](#) siêu tham số, [187](#)
siêu mặt phẳng, 367-372 kiểm
định giả thuyết, [76-77](#), [84](#),
[103](#), 558-583

Bộ dữ liệu IMDb , [413](#), [415](#), [416](#), [418](#),
[420](#), [437](#), [458](#), [467](#)
phép nội suy, [515](#)
Bộ dữ liệu thu nhập , [16-18](#), 21-23
gia tăng, [60](#)
biến độc lập, [15](#) có thể lặp
chỉ mục , [186](#)
hàm chi thị, [292](#) suy luận,
[17](#), [18](#) tích vô
hướng, [379](#), [380](#) lớp đầu
vào, [400](#) biến đầu
vào, [15](#) tích phân,
[301](#) tương tác,
[70](#), [89](#), [95-98](#), [110-111](#) , [308](#) hệ số chặn,
[71](#), [72](#)
nội suy, [432](#) khả
năng giải thích,
[229](#) nghịch đảo, [529](#) lỗi
không thể giảm
thiểu, [17](#), [36](#), [90](#), [110](#) bộ lặp, [312](#)

phân phối chung, [158](#)

Phân cụm K-means, [11](#), 521-524
K-hàng xóm gần nhất, [135](#), 164-167 bộ
phân loại, [11](#), 36-37
hồi quy, 111-115

Đường cong sống sót Kaplan-Meier, 472-474 ,
483 hạt
nhân, 379-382, 384, 394 tuyến
tính, 380 phi
tuyến tính, 377-382 đa
thức, 380, 382 xuyên tâm,
381-383, 390 ước lượng
mật độ hạt nhân, 159 từ khóa, 46

Bộ dữ liệu Khan , 12, 579-581, 583, 590,
593 nút,
290, 294, 296-299

1 chuẩn, 244 2
chuẩn, 242 độ
trễ, 422
Phân phối Laplace, 251 lasso,
11, 24, 244-251, 265-266, 336 , 385, 484
leaf, 333, 526
tốc độ học, 429
bình phương nhỏ nhất,
5, 21, 71-72, 140, 141, 229 line, 73
weighted,
103
level, 92
leverage,
104-106 hàm likelihood,
141 tuyến tính, 2, 69-115 tổ
hợp tuyến tính, 128,
230, 253,
505
phân tích phân biệt tuyến tính, 5, 11,
135, 138, 147-155, 164-167 ,
377, 382 hạt
nhân tuyến tính, 380
mô hình tuyến tính, 20, 69-115
hồi quy tuyến tính, 5, 11, 69-115, 172-173

nhiều, 80-90 đơn
giản, 70-80 hàm
liên kết, 172, 173 liên kết,
529-530, 548 trung bình,
529-530 trọng tâm,
529-530 hoàn chỉnh,
526, 529-530 đơn lẻ, 529-530
danh sách, 41 hiểu
danh
sách, 123 cục tiểu cục bộ, 427

hồi quy cục bộ, 290 log
odds, 145 kiểm
định log-rank, 474-476, 483 hàm
logistic, 139 hồi quy
logistic, 5, 11, 25 , 135 , 138-144, 164-
167 , 172-173, 308-309, 377 ,
384-385 đa thức, 145, 163 bội
số,
142-144 logit, 140 hàm mất
mát, 300, 385 chiều
thấp, 262

Mạng nơ-ron hồi quy LSTM, 420

hiệu ứng chính, 96
phiếu bầu đa số, 344
Mallow's Cp, 87, 231, 232, 236- 238

Kiểm định Mantel-Haenszel, biên
độ 475 , phân phối
biên 370, 385 , 158
Chuỗi Markov Monte Carlo, 353 hoàn thành
ma trận, 515 phép nhân ma
trận, 10 bộ phân loại biên độ
tối đa, 367-372 siêu
mặt phẳng, 370 xác suất
tối đa, 139-141, 143,
170 sai số bình phương trung bình, 28 lưới,
53
phương pháp, 43 lô nhỏ, 429
lỗi phân
loại sai, 35
thiếu ngẫu nhiên,
515 dữ liệu thiếu, 56, 515-520
lựa chọn hỗn hợp, 87

Bộ dữ liệu MNIST , 402-404, 406, 430, 431,
441, 444, 445, 448
đánh giá mô hình, 201 lựa chọn
mô hình, 201 mô-đun, 42 đa
cộng tuyến,
108, 266 hồi quy logistic đa thức,
145, 163 kiểm định đa biến, 557-583 học đa
nhiệm, 403 phân phối Gaussian đa
biến, 150

phân phối chuẩn đa biến, 150

Naive Bayes, 135, 158-161, 164-167

không gian tên, 116
spline tự nhiên, 297, 298, 301, 317

Bộ dữ liệu NCI60 , 4, 5, 12, 546, 548-550

phân phối nhị thức âm, 173
giá trị dự đoán âm, 155, 156
mạng nơ-ron, 5, 399

nút nội bộ, 333
độ tinh khiết, 337-

339 đầu cuối , 333

nhiều, 21, 252
phi tuyến tính, 2,

11, 289-329
ranh giới quyết định, 377-382
hạt nhân, 377-382
phi tham số, 20, 22-23, 111-115 , 193
phân phối chuẩn (Gaussian), 146, 147, 150, 172, 476, 561
số tay, 40
giả thuyết không, 152
phân phối, 561, 578
giả thuyết, 76, 559
mô hình, 87, 231, 245
tỷ lệ không, 186

Bộ dữ liệu NYSE , 12, 422-424, 466, 467

Nguyên tắc dao cạo Occam, tỷ lệ cược 426 , 140, 145, 195

Tập dữ liệu OJ , 12, 365, 398
mã hóa one-hot, 92, 126, 403

quy tắc sai số chuẩn, 240
một-đối-tất cả, 384
một-đối-một, 384
một-đối-phần còn lại, 384
siêu mặt phẳng phân tách tối ưu, 370
lạc quan về lỗi huấn luyện, 30
biến phân loại có thứ tự, 315
trực giao, 257, 506
cơ sở, 125 ngoài túi, 345
ngoại lệ, 103-104
biến đầu ra, 15
quá tham số, 465
phân tán quá mức, 172

quá khớp, 21, 23, 25, 30-31, 88, 152, 233, 371

giá trị p, 77, 82, 560-562, 578-579
đã điều chỉnh, 586
gói, 42
tham số, 71
tham số, 20-22, 111-115
bình phương tối thiểu từng phần, 254, 260-262, 282
xác suất từng phần, 480

thuật toán đường dẫn, 249

hoán vị, 578
phương pháp hoán vị, 577-582
vuông góc, 257

Phân phối Poisson, 169, 172

Hồi quy Poisson, 135, 167-173
hạt nhân đa thức, 380, 382

hồi quy, 98-99, 289-292, 294-295
gộp, 410
đường hồi quy dân số , 73

Tập dữ liệu danh mục đầu tư , 12
giá trị dự đoán dương, 155, 156
phân phối hậu nghiệm, 251
chế độ , 251
xác suất, 147
sức mạnh, 108, 155, 563

độ chính xác, 155
dự đoán, 17
khoảng, 90, 110

biến dự báo, 15

thành phần chính, 505

phân tích, 11, 254-260, 504-515
vectơ tải, 505, 506
giá trị thiểu, 515-520
tỷ lệ phương sai được giải thích, 510-515, 547
hồi quy, 11, 254-260, 280-282 , 504, 515
vectơ điểm số, 506
biểu đồ scree, 514-515

phân phối tiên nghiệm, 251
xác suất, 146
hàm mật độ xác suất, 477, 478

dự báo, giả
 định rủi ro tỷ lệ 230 ,
 478
 cắt tia, 336 độ
 phức tạp chi phí, 336 mất
 xích yếu nhất, 336
 Bộ dữ liệu xuất bản , 12, 482-
 487
 Các đối tượng và hàm Python %capture,
 458 iloc[], 58
 loc[], 57

 AgglomerativeClustering(), 543 anova(),
 313
 anova_lm(), 125,
 129, 312, 313 axhline(), 122, 551

 axline(), 121, 129, 329
 BART(), 362 biplot, 537
 boot_SE(), 223
 boxplot(), 62,
 66 bs(), 315, 327
 BSpline(), 315 clone(),
 222 columns.drop(),
 122 compute_linkage(),
 544
 confusion_table(), 176
 contour(), 50 corr(), 129, 174
 cost_complexity_pruning_path(),

 357
 CoxPHFitter(), 491
 cross_val_predict(), 270
 cross_validate(), 218, 219,
 226
 cumsum(), 539
 cut_tree(), 545
 data.frame(), 227
 Dataset, 440
 decision_function(), 392
 DecisionTreeClassifier(), 354,
 355
 DecisionTreeRegressor(), 354 def,
 121
 dendrogram(), 544
 describe(), 62, 66
 dir(), 116
 drop(), 179
 dropna(), 56, 268, 461
 DTC(), xem DecisionTreeClassifier()
 DTR(), xem DecisionTreeRegressor()
 dtype, 43
 ElasticNetCV(), 279
 enumerate(), 217
 export_text(), 356
 export_tree(), 365
 fit(), 118, 181, 218
 fit_transform(), 119
 for, 59
 GaussianNB(), 182
 GBR(), xem GradientBoosting-
 Regressor()
 get_dummies(), 461
 get_influence(), 121
 get_prediction(), 120, 314
 get_rdataset(), 535
 glm(), 313
 glob(), 437
 GradientBoostingClassifier(),
 361
 GradientBoostingRegressor(), 354,
 361
 GridSearchCV(), 276
 groupby(), 490
 hist(), 62
 iloc[], 58, 59
 import, 42
 imshow(), 50, 449
 ISLP.bart, 362
 ISLP.cluster, 544
 json, 437
 KaplanMeierFitter(), 502
 keras, 437
 KFold(), 219
 KMeans(), 542, 543
 Kmeans(), 542
 KNeighborsClassifier(), 183
 lambda, 58
 LDA(), xem LinearDiscriminant-
 Analysis()
 legend(), 132
 lifelines, 490
 LinearDiscriminantAnalysis(), 174,
 179
 LinearGAM(), 317
 LinearRegression(), 280

load_data(), 117
 loc[], 58, 59, 177
 log_loss(), 355
 LogisticGAM(), 323
 logrank_test(), 490
 lowess(), 324
 matplotlib, 48
 max(), 66
 mean(), 48
 median(), 197
 min(), 66
 MNIST(), 444
 ModelSpec(), 116-118, 122, 124, 267 MS(),
 xem ModelSpec()
 mult_test(), xem multiplereports()
 multiplereports(), 586
 multiplereports(), 583, 589
 multivariate_logrank_test(), 496

 NaturalSpline(), 317, 319
 ndim, 42
 nn.RNN(), 461
 normal(), 132, 286, 555
 np, xem numpy
 np.all(), 54, 180
 np.allclose(), 190
 np.any(), 54
 np.arange(), 51
 np.argmax(), 122
 np.array(), 42
 np.concatenate(), 133
 np.corrcoef(), 46, 554
 np.empty(), 224
 np.isnan(), 268
 np.ix_(), 53
 np.linalg.svd(), 539
 np.linspace(), 50
 np.logspace(), 318
 np.mean(), 47, 176
 np.nan, 60
 np.nanmean(), 541
 np.percentile(), 228
 np.power(), 219
 np.random.choice(), 553
 np.random.default_rng(), 46, 47
 np.random.normal(), 45
 np.sqrt(), 45
 np.squeeze(), 457
 np.std(), 47
 np.sum(), 43
 np.var(), 47
 np.where(), 180
 ns(), 317
 numpy, 42, 555
 os.chdir(), 55
 outer(), 219
 pairwise_distances(), 554
 pairwise_tukeyhsd(), 587
 pandas, 55
 params, 175
 partial(), 222, 269
 PCA(), 280, 537, 540, 554
 pd, xem pandas
 pd.crosstab(), 555
 pd.cut(), 315
 pd.get_dummies(), 314
 pd.plotting.scatter_matrix(), 62
 pd.qcut(), 314, 315
 pd.read_csv(), 55, 556
 pd.Series(), 62
 Pipeline(), 275
 plot(), 48, 61, 356, 490
 plot.scatter(), 120
 plot_gam(), 321
 plot_svm(), 398
 PLSRegression(), 282
 poly(), 125, 313, 327
 predict(), 175, 178, 181, 216 , 218 , 323, 358
 predict_survival_function(), 493

 print(), 40
 pvalues, 175
 pygam, 307, 317
 pytorch_lightning, 435
 QDA(), xem Phân tích phân biệt bậc hai
 (QuadraticDiscriminant-Analysis)
 QuadraticDiscriminantAnalysis(), 174, 181
 random(), 555
 RandomForestRegressor(), 354, 360

 read_image(), 436
 reindex(), 461
 reshape(), 43

trả về, 198
 RF(), xem RandomForestRegressor() rng,
 xem np.random.default_rng()
 rng.choice(), 60
 rng.standard_normal(), 60
 roc_curve(), 392
 RocCurveDisplay.from_estimator(),
 387
 savefig(), 50
 scatter(), 49, 61
 scipy.interpolate, 315
 score(), 218, 461
 seed_everything(), 436
 set_index(), 57
 set_title(), 49
 set_xlabel(), 49
 set_xscale(), 198
 set_ylabel(), 49
 set_yscale(), 198
 shape, 43
 ShuffleSplit(), 219
 sim_time(), 495
 SimpleDataModule(), 441
 SimpleModule.classification(), 446

 SimpleModule.regression(), 442

 skl, xem sklearn.linear_model
 skl.ElasticNet(), 273, 277
 skl.ElasticNet.path, 274
 skl.ElasticNet.path(), 273
 sklearn, 118, 181
 sklearn.ensemble, 360
 sklearn.linear_model, 267
 sklearn.model_selection, 267
 sklearn_selected(), 269
 sklearn_selection_path(), 270

 sklearn_sm(), 218
 skm, xem sklearn.model_selection
 skm.cross_val_predict(), 271
 skm.KFold(), 271
 skm.ShuffleSplit(), 272
 slice(), 51, 462
 sm, xem statsmodels
 sm.GLM(), 174, 192, 226
 sm.Logit(), 174
 sm.OLS(), 118, 129, 174, 319

 StandardScaler(), 185, 438,
 537, 555
 statsmodels, 116, 173
 std(), 186
 Stepwise(), 269
 str.contains(), 59
 subplots(), 48
 sum(), 43, 268
 summarize(), 118, 129, 223,
 226
 summary(), 119, 322, 587
 super(), 440
 SupportVectorClassifier(), 387,
 389-391, 393
 SupportVectorRegression(), 394

 SVC(), xem SupportVector-
 Classifier()
 svd(), 539
 SVR(), xem SupportVector-
 Hồi quy()
 TensorDataset(), 441
 to_numpy(), 437
 torch, 435
 torchinfo, 436
 torchmetrics, 436
 torchvision, 436
 ToTensor(), 444
 train_test_split(), 186, 216
 transform(), 118, 119
 ttest_1samp(), 584
 ttest_ind(), 590
 ttest_rel(), 587
 tuple, 43
 uniform(), 555
 value_counts(), 66
 var(), 536
 variance_inflation_factor(), 116,
 124
 VIF(), xem variance_inflation-
 _factor()
 trong đó(),
 355 zip(), 60, 312

 giá trị q,
 589 bậc hai,
 98 phân tích phân biệt bậc hai, 4,
 135, 156-157, 164-167

máy 372-377 , 5, 11, 24, 377-386

hồi quy, 386 phân tích sống

sốt, 469-502 đường cong, 472, 483 hàm số, 472 thời gian, 470

hiệp lực, 70, 89, 95-98, 110-111 hệ thống, 16

phân phối t, 77, 165 thống kê t, 76 kiểm định t

một mẫu, 583, 584, 588 ghép đôi, 587 hai mẫu, 559, 570, 571, 577- 581, 584, 590

thai kiểm tra

lỗi, 35, 37, 176

MSE, 28-32 quan sát, 28 tập hợp, 30

thống kê, 559 phân phối giả thuyết, 577 chuỗi thời gian, 101 tổng bình phương, 79 theo dõi, 102 huấn luyện, 21 dữ liệu huấn luyện, 20

lỗi, 35, 37, 176

MSE, 28-31 máy biến áp, 311 cây, 331-342 phương pháp dựa trên cây, 331 âm tính thật, 155 dương tính thật, 155 tỷ lệ dương tính thật, 155, 156, 382 cơ sở công suất bị cắt cụt, 296

Phương pháp Tukey, 571, 585, 587 tham số điều chỉnh, 187, 240, 484 kiểm định t hai mẫu, 474

Lỗi loại I, 155, 562-565 Tỷ lệ lỗi loại I: 563

Lỗi loại II, 155, 563, 568, 584

học không giám sát, 25-27, 255, 260, 503-552

Bộ dữ liệu USArrests , 12, 507, 508 , 510 , 512, 513, 515, 516, 518, 519

tập hợp xác thực, phương pháp 202 , biến 202-204 , biến phụ thuộc 15 , biến giả 15 , tầm quan trọng 91-94, 97-98 , biến độc lập 346, 360 , chỉ số 15 , đầu vào 35 , đầu ra 15 , định tính 15 , lựa chọn 91-94, 97-98 , phương sai 86, 230, 244 , hệ số lạm phát 18, 31-34, 159 , hệ số lạm phát 108-110, 123

mô hình hệ số thay đổi, 305

Bộ dữ liệu tiền lương , 1, 2, 8, 9, 12, 290, 291 , 293, 295, 297-300, 302-306, 309, 315, 327 người học yếu, 343 cắt tủa liên kết yếu nhất, 336

Bộ dữ liệu hàng tuần , 12, 196, 226

đóng băng trọng lượng, 412, 419

chia sẻ trọng lượng, 418

bình phương nhỏ nhất có trọng số, 103, 304 trọng lượng, 404 có thay thế, 214

hiệp phương sai trong lớp, 150 bao bọc, 217