



MACHINE LEARNING FUNDAMENTALS

Huỳnh Nhật Toàn - DSC


Mục tiêu: Giúp cho các bạn có kiến thức nền tảng về khoa học dữ liệu, hiểu được quy trình và có thể tự tin xây dựng những mô hình ML



Data Science Center

Explained

What you need to know



1. Giới thiệu về machine learning và quy trình?

2. Demo + linear regression

3. Regression


4. Classification

5. Dimensionality Reduction

What is machine learning?

[Machine Learning is the] field of study that gives computers the ability to learn without being explicitly programmed.

—Arthur Samuel, 1959



Why use machine learning?




Figure 1-1. The traditional approach





Figure 1-2. The Machine Learning approach

Example of application?



Spam filters



Face recognition



customer segmentation


MACHINE LEARNING MODEL



Linear regression

Mouse weight (g)	9	18	21	31	42	50	52	56	61
Mouse size (mm)	15	28	12	37	35	32	53	49	?

Mouse size



$$Mouse_size = a * Mouse_weight + b$$

$$y = ax + b$$

Mouse weight

Phương trình Linear regression

$$\text{Mouse_size} = a * \text{Mouse_weight} + b \quad (y = ax + b)$$


Trong đó:

- Mouse_size là biến phụ thuộc (outcome).
- Mouse_weight là biến độc lập (predictor).
- a là độ dốc của đường thẳng (slope hay coefficients).
- b là hệ số chặn trục (intercept).


Đối với nhiều biến độc lập (đa biến), mô hình có thể mở rộng thành:

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n$$

Ở đây, $x_1, x_2, \dots, x_n$ là các biến độc lập và $b_0, b_1, b_2, \dots, b_n$ là các hệ số tương ứng.



Second, measure the distance from the line to the data, square each distance, and then add them up.




With the new line,
measure the
residuals, square
them, and then sum
up the squares.


$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Trong đó:

- n là số lượng mẫu.
- y_i là giá trị thực.
- $\hat{y}_i$ là giá trị dự đoán.



Quy trình huấn luyện machine learning model



Business understanding (Hiểu nghiệp vụ)

Xác định mục đích

Khách hàng muốn đạt được điều gì?

- ✓ Giảm chi phí
- ✓ Tùy chỉnh phân khúc khách hàng
- ✓ Lập kế hoạch chi phí cho quảng cáo
- ✓ Ngăn ngừa gian lận
- ✓ Đề xuất sản phẩm cho khách hàng
- ✓ ...

Hiểu

- **Hiểu** những tiêu chí để đạt được mục đích.
- **Liệt kê** các giả định, điều kiện ràng buộc, và các yếu tố quan trọng.
- **Xác định** các mục tiêu thứ yếu và cạnh tranh.
- **Nghiên cứu** các giải pháp hiện có (nếu có).

Đối chiếu

- **Mục tiêu nghiệp vụ** → **Mục tiêu kỹ thuật**
 - ✓ Nêu mục tiêu của dự án về **mặt kỹ thuật**.
 - ✓ Khoa học dữ liệu sẽ đóng vai trò gì trong dự án
 - ✓ Xây dựng một kịch bản thành công.

Data Preparation (Chuẩn bị dữ liệu)

NHẬN ĐỊNH

- Nguồn dữ liệu, **định dạng**
- Sơ đồ quan hệ giữa các thực thể
- Xác định các dữ liệu **liên quan**
- Ghi lại những dữ liệu **không có sẵn**
- Bao lâu sẽ có đủ dữ liệu cần

THU THẬP

- Truy cập hoặc thu thập tất cả dữ liệu liên quan ở nguồn dữ liệu trung tâm
- **Kiểm tra** và **kiểm thử** chất lượng dữ liệu

ĐÁNH GIÁ

- Làm quen và hiểu dữ liệu
- Nghiên cứu **tính thời vụ**.
- Phát hiện **lỗi**.
- Kiểm tra **các giả thuyết**.
- Xem xét **phân phối dữ liệu**.

NHIỆM VỤ

- Tạo một bộ dữ liệu phân tích (Analysis Dataset)

Data munging (Tiền xử lý dữ liệu)

- **Số liệu thống kê mô tả**
Descriptive statistics
- **Phân tích sự tương quan**
Correlation analysis
- **Xử lý các giá trị bị thiếu**
Impute missing values
- **Cắt bớt các giá trị ngoại lệ**
Trim extreme values
- **Xử lý phân loại các thuộc tính**
Process categorical attributes
- **Biến đổi thuộc tính (square, log, etc.)** Transformations
- **Đa cộng tuyến: giảm dư thừa**
Multicollinearity: reduce redundancy
- **Tạo các thuộc tính bổ sung**
Create additional feature
- **Tương tác**
- **Chuẩn hóa dữ liệu**
Normalization (scaling)

Data munging (Tiền xử lý dữ liệu)


Time
Spent

80%


20%

Data
Munging

Model
Building




Model training (Huấn luyện mô hình)




Thử nhiều hơn một
mô hình Machine
Learning



Tinh chỉnh các
tham số mô hình.



Đánh giá hiệu suất
các mô hình




Tránh Over-
fitting.

Model Evaluation (Đánh giá mô hình)


MODEL SELECTION

- Luật Parsimony: Đơn giản là tốt hơn
- Thời gian thực thi
- Độ phức tạp của việc triển khai mô hình

ASSESSMENT



PRESENTATION



Model Deployment (Triển khai mô hình)

- Quy trình triển khai một mô hình chạy thực tế
- Scoring code, hoặc publish mô hình dưới dạng web service
- Tài liệu mô tả mô hình (Thông số kỹ thuật)
- Reproducibility
- Model Persistence vs. Model Transience

Model Tracking (Theo dõi mô hình)

THEO DÕI

- Hiệu suất mô hình theo thời gian
- Phân phối kết quả dự đoán


BẢO TRÌ

- Lên kế hoạch bảo trì mô hình
- Thêm dữ liệu từ những nguồn mới
- Kiểm soát các phiên bản của mô hình

KIỂM THỬ

- Thiết kế thực nghiệm (A/B tests, Fractional Factorial)

Tóm tắt lại quy trình



DEMO



Yêu Cầu Bài Toán

Bạn sẽ xây dựng một mô hình dự đoán giá nhà trung bình cho mỗi khu vực ở California dựa trên các đặc điểm như dân số, thu nhập trung bình ...

Dữ liệu này dựa trên dữ liệu điều tra dân số California năm 1990, tuy không mới nhưng vẫn phù hợp để học Machine Learning.

Khu vực được gọi là "district" và là đơn vị địa lý nhỏ nhất mà Cục Điều tra Dân số Hoa Kỳ công bố dữ liệu mẫu (thường có dân số từ 600 đến 3.000 người).




Thu thập dữ liệu


- longitude
- latitude
- housing_median_age
- total_rooms
- population
- households
- median_income
- ocean_proximity
- total_bedrooms

⇒ median_house_value

Target



longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximity
-122.23	37.88	41	880	129	322	126	8.3252	452600	NEAR BAY
-122.22	37.86	21	7099	1106	2401	1138	8.3014	358500	NEAR BAY
-122.24	37.85	52	1467	190	496	177	7.2574	352100	NEAR BAY
-122.25	37.85	52	1274	235	558	219	5.6431	341300	NEAR BAY
-122.25	37.85	52	1627	280	565	259	3.8462	342200	NEAR BAY
-122.25	37.85	52	919	213	413	193	4.0368	269700	NEAR BAY
-122.25	37.84	52	2535	489	1094	514	3.6591	299200	NEAR BAY
-122.25	37.84	52	3104	687	1157	647	3.12	241400	NEAR BAY
-122.26	37.84	42	2555	665	1206	595	2.0804	226700	NEAR BAY





Vì sao mô hình machine learning có khả năng học từ dữ liệu ?

Ví dụ: Mô hình Linear regression


Làm thế nào để tìm được hệ số của phương trình đường thẳng vẽ ra khớp với dữ liệu đã cho?

When we fit a line with **Linear Regression**, we optimize the **Intercept** and **Slope**.






...and someone tells us
that they weigh **1.5**...




...we can use the line to
predict that they will be
1.9 tall.


$$\text{Predicted Height} = \text{intercept} + \text{slope} \times \text{Weight}$$



So let's learn how **Gradient Descent** can fit a line to data by finding the optimal values for the **Intercept** and the **Slope**.




$$\text{Predicted Height} = \text{intercept} + \boxed{\text{slope}} \times \text{Weight}$$




So for now, let's just plug in
the **Least Squares** estimate
for the **Slope, 0.64**.

$$\text{Predicted Height} = 0 + 0.64 \times \text{Weight}$$




And that gives us the equation for this line.



In this example, we will evaluate how well this line fits the data with the **Sum of the Squared Residuals**.

NOTE: In Machine Learning lingo, The Sum of the Squared Residuals is a type of **Loss Function**.

Sum of squared residuals = 1.1^2




Here's the square of
the first residual...


$$\text{Residual} = 1.4 - 0.32 = \mathbf{1.1}$$

$$\text{Predicted Height} = 0 + 0.64 \times 0.5 = 0.32$$



Sum of squared residuals = $1.1^2 + 0.4^2$



Sum of squared residuals = $1.1^2 + 0.4^2 + 1.3^2$





$$\text{Sum of squared residuals} = 1.1^2 + 0.4^2 + 1.3^2 = 3.1$$









However, if the
Intercept = 0.25...



...then we would get
this point on the
graph.





And if the
Intercept = 0.5...









...then we would get
this point.





And for increasing values for the **Intercept**, we get these points.




And for increasing values for the **Intercept**, we get these points.




Sum of squared residuals = $(1.4 - (\text{intercept} + 0.64 \times 0.5))^2$



$$\begin{aligned}\text{Sum of squared residuals} &= (1.4 - (\text{intercept} + 0.64 \times \mathbf{0.5}))^2 \\ &+ (1.9 - (\text{intercept} + 0.64 \times \mathbf{\text{weight}}))^2\end{aligned}$$




...which comes
from the equation
for the line...




Sum of squared residuals = $(1.4 - (\text{intercept} + 0.64 \times 0.5))^2$

+ $(1.9 - (\text{intercept} + 0.64 \times 2.3))^2$

+ $(3.2 - (\text{intercept} + 0.64 \times \text{weight}))^2$



...which comes
from the equation
for the line...




Sum of squared residuals = $(1.4 - (\text{intercept} + 0.64 \times 0.5))^2$

+ $(1.9 - (\text{intercept} + 0.64 \times 2.3))^2$


+ $(3.2 - (\text{intercept} + 0.64 \times 2.9))^2$

Thus, we now
have an equation
for this curve...



Sum of squared residuals = $(1.4 - (\text{intercept} + 0.64 \times 0.5))^2$
+ $(1.9 - (\text{intercept} + 0.64 \times 2.3))^2$
+ $(3.2 - (\text{intercept} + 0.64 \times 2.9))^2$

...and we can take the derivative of this function and determine the slope at any value for the **Intercept**.




Logistic regression


Bài toán

Ngân hàng bạn đang làm có chương trình cho vay ưu đãi cho các đối tượng mua chung cư. Tuy nhiên gần đây có một vài chung cư rất hấp dẫn (giá tốt, vị trí đẹp,...) nên lượng hồ sơ người nộp cho chương trình ưu đãi tăng đáng kể. Bình thường bạn có thể duyệt 10-20 hồ sơ một ngày để quyết định hồ sơ có được cho vay hay không, tuy nhiên gần đây bạn nhận được 1000-2000 hồ sơ mỗi ngày. Bạn không thể xử lý hết hồ sơ và bạn cần có một giải pháp để có thể dự đoán hồ sơ mới là có nên cho vay hay không.

Sau khi phân tích thì bạn nhận thấy là hai yếu tố chính quyết định đến việc được vay tiền đó là mức lương và thời gian công tác. Đây là dữ liệu bạn có từ trước đến nay:

Lương	Thời gian làm việc	Cho vay
10	1	1
5	2	1
...	...	1
8	0.1	0
7	0.15	0
...	...	0






Xét đường thẳng $W2 = a \cdot W1 + b$

Gọi $f = W2 + a \cdot W1 + b$ thì đường thẳng chia mặt phẳng thành 2 miền,

- 1 miền hàm f có giá trị dương,
- 1 miền hàm f có giá trị âm
- giá trị f các điểm trên đường thẳng bằng 0

Ví dụ, xét đường thẳng $W2 = 3 - W1$, hàm $f = W2 - 3 + W1$.

- Tại điểm $A(1,3) \Rightarrow f = 3 - 3 + 1 = 1 > 0$
- Tại điểm $B(2,1)$ nằm trên đường thẳng $\Rightarrow f = 2 - 3 + 1 = 0$
- Tại điểm $C(1,1) \Rightarrow f = 1 - 3 + 1 = -1 < 0$




Khi thay giá trị của các điểm vào hàm đường thẳng thì :

- + Điểm nằm dưới đường thẳng có giá trị âm
- + Điểm nằm trên đường thẳng có giá trị dương
- + Điểm cách đường thẳng càng gần thì trị tuyệt đối của f càng nhỏ
- + Điểm cách đường thẳng càng xa thì trị tuyệt đối của f càng xa

Hàm sigmoid

Giờ mình cần tìm xác suất của hồ sơ mới nên cho vay. Hay giá trị của hàm cần trong khoảng $[0,1]$. Rõ ràng là giá trị của phương trình đường thẳng như bài trước có thể ra ngoài khoảng $[0,1]$ nên cần một hàm mới luôn có giá trị trong khoảng $[0,1]$. Đó là hàm sigmoid.



Đồ thị hàm sigmoid

Nhận xét:

- Hàm số liên tục, nhận giá trị thực trong khoảng $(0,1)$.
- Hàm có đạo hàm tại mọi điểm (để áp dụng gradient descent)

Phương trình Logistic regression

Model

Với dòng thứ i trong bảng dữ liệu, gọi $x_1^{(i)}$ là lương và $x_2^{(i)}$ là thời gian làm việc của hồ sơ thứ i .

$$\hat{y}_i = \sigma(w_0 + w_1 * x_1^{(i)} + w_2 * x_2^{(i)}) = \frac{1}{1 + e^{-(w_0 + w_1 * x_1^{(i)} + w_2 * x_2^{(i)})}}$$

Loss function

Giờ cũng cần một hàm để đánh giá độ tốt của model. Như bài trước là $\hat{y}$ càng gần y càng tốt, giờ cũng vậy:

- Nếu hồ sơ thứ i là cho vay, tức $y_i = 1$ thì ta cũng mong muốn $\hat{y}_i$ càng gần 1 càng tốt hay model dự đoán xác suất người thứ i được vay vốn càng cao càng tốt.
- Nếu hồ sơ thứ i không được vay, tức $y_i = 0$ thì ta cũng mong muốn $\hat{y}_i$ càng gần 0 càng tốt hay model dự đoán xác suất người thứ i được vay vốn càng thấp càng tốt

Với mỗi điểm $(x^{(i)}, y_i)$, gọi hàm loss function

$$L = -(y_i * \log(\hat{y}_i) + (1 - y_i) * \log(1 - \hat{y}_i))$$

Hàm loss function trên toàn bộ dữ liệu

$$J = - \sum_{i=1}^N (y_i * \log(\hat{y}_i) + (1 - y_i) * \log(1 - \hat{y}_i))$$

Ưu điểm và nhược điểm


Ưu Điểm	Nhược Điểm
Dễ hiểu và triển khai	Giới hạn với phân phối không tuyến tính
Tính toán nhanh	Dễ bị ảnh hưởng bởi nhiễu hoặc biến động
Dễ diễn giải	Khả năng dự đoán không cao khi có quá nhiều biến
Xử lý tốt với dữ liệu có tính tuyến tính	Không linh hoạt với các mô hình phức tạp hơn


Decision Tree (Classification)




Loves Popcorn	Loves Soda	Age	Loves Cool As Ice
Yes	Yes	7	No
Yes	No	12	No
No	Yes	18	Yes
No	Yes	35	Yes
Yes	Yes	38	Yes
Yes	No	50	No
No	No	83	No

...to build this
Classification Tree...








Looking at the two little trees, we see that neither one does a perfect job predicting who *will* and who *will not* **Love Cool As Ice.**






One of the most popular methods is called **Gini Impurity**, but there are also fancy sounding methods like **Entropy** and **Information Gain**.





To calculate the **Gini Impurity** for **Loves Popcorn**, we start by calculating the **Gini Impurity** for the individual **Leaves**.






Gini Impurity for a Leaf = $1 - (\text{the probability of "Yes"})^2 - (\text{the probability of "No"})^2$

$$= 1 - \left(\frac{1}{1+3}\right)^2 - \left(\frac{3}{1+3}\right)^2$$

$$= 0.375$$

And when we do the math, we get **0.375**.



Gini Impurity for a Leaf = $1 - (\text{the probability of "Yes"})^2 - (\text{the probability of "No"})^2$


$$= 1 - \left(\frac{2}{2+1}\right)^2 - \left(\frac{1}{2+1}\right)^2$$

$$= 0.444$$

And when we do the math we get **0.444**.




We start by calculating the weight for the **Leaf** on the left.



Total **Gini Impurity** = weighted average of **Gini Impurities** for the **Leaves**



And when we do the math, we get **0.405**.




Total **Gini Impurity** = weighted average of **Gini Impurities** for the **Leaves**

$$= \left(\frac{4}{4+3} \right) 0.375 + \left(\frac{3}{4+3} \right) 0.444$$

$$= 0.405$$




Gini Impurity for Loves Popcorn = 0.405



Likewise, the **Gini Impurity for Loves Soda** is **0.214**.


Gini Impurity for Loves Soda = 0.214






Lastly, we calculate the **Gini Impurity** values for each average age.

	Age	Loves Cool As Ice	
	7	No	
9.5	12	No	Gini Impurity = 0.429
15	18	Yes	Gini Impurity = 0.343
26.5	35	Yes	Gini Impurity = 0.476
36.5	38	Yes	Gini Impurity = 0.476
44	50	No	Gini Impurity = 0.343
66.5	83	No	Gini Impurity = 0.429






	Age	Loves Cool As Ice
	7	No
9.5	12	No
15	18	Yes
26.5	35	Yes
36.5	38	Yes
44	50	No
66.5	83	No





	Age	Loves Cool As Ice
9.5	7	No
15	12	No
26.5	18	Yes
36.5	35	Yes
44	38	Yes
66.5	50	No
	83	No

Gini Impurity = 0



$$\text{Total Gini Impurity} = \left(\frac{1}{1+6}\right) 0 + \left(\frac{6}{1+6}\right) 0.5 = 0.429$$

...and we get **0.429**.




Gini Impurity for Loves Popcorn = 0.405

And because **Loves Soda** has the lowest the **Gini Impurity** overall...


Gini Impurity for Loves Soda = 0.214

Gini Impurity for Age < 15 = 0.343





Loves Popcorn	Loves Soda	Age	Loves Cool As Ice
Yes	Yes	7	No
Yes	No	12	No
No	Yes	18	Yes
No	Yes	35	Yes
Yes	Yes	38	Yes
Yes	No	50	No
No	No	83	No



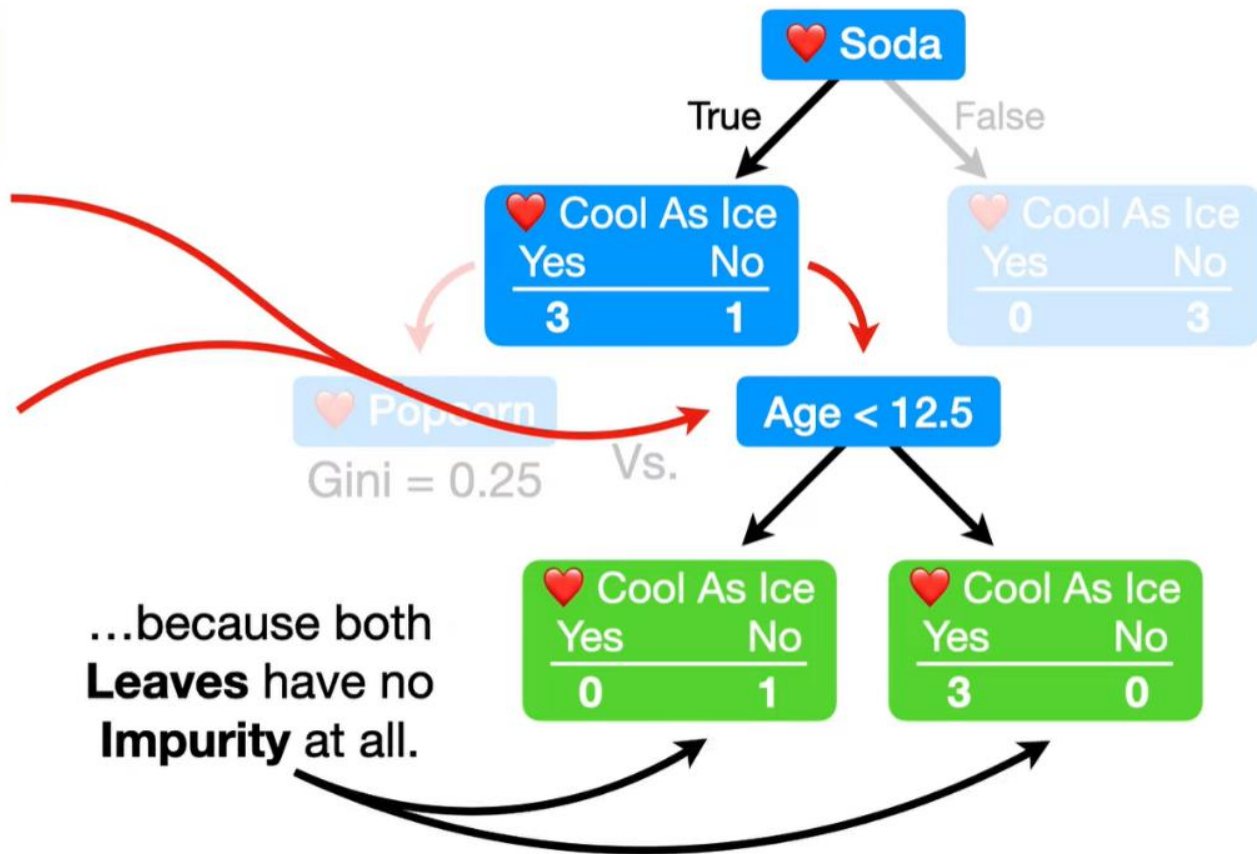


Loves Popcorn	Loves Soda	Age	Loves Cool As Ice
Yes	Yes	7	No
Yes	No	12	No
No	Yes	18	Yes
No	Yes	35	Yes
Yes	Yes	38	Yes
Yes	No	50	No
No	No	83	No

12.5

26.5


36.5




...because both **Leaves** have no **Impurity** at all.



Loves Popcorn	Loves Soda	Age	Loves Cool As Ice
Yes	Yes	7	No
Yes	No	12	No
No	Yes	18	Yes
No	Yes	35	Yes
Yes	Yes	38	Yes
Yes	No	50	No
No	No	83	No






We need to assign output values for each **Leaf**.



Loves Popcorn	Loves Soda	Age	Loves Cool As Ice
Yes	Yes	7	No
Yes	No	12	No
No	Yes	18	Yes
No	Yes	35	Yes
Yes	Yes	38	Yes
Yes	No	50	No
No	No	83	No




**Double
BAM!!!**



Loves Popcorn	Loves Soda	Age	Loves Cool As Ice
Yes	Yes	15	???




...then we run the data down our tree.



Ưu điểm và nhược điểm

Ưu Điểm	Nhược Điểm
Dễ hiểu và diễn giải	Dễ bị overfitting nếu không kiểm soát
Xử lý dữ liệu có cả biến định lượng và biến phân loại	Khá nhạy cảm với biến nhất định trong dữ liệu
Không cần chuẩn hóa dữ liệu	Có thể không tạo ra dự đoán tốt với dữ liệu mới
Có khả năng xử lý tốt các mối quan hệ phi tuyến tính giữa các biến	


K-means (Clustering)





Nếu bạn có hai điểm trong không gian n chiều, ví dụ điểm A có các tọa độ $(x_1, x_2, \dots, x_n)$ và điểm B có các tọa độ $(y_1, y_2, \dots, y_n)$, thì khoảng cách Euclid giữa chúng được tính bằng công thức:


$$\text{Khoảng cách Euclid} = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2}$$


$$\text{Khoảng cách Euclid (2 chiều)} = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

















Tóm tắt thuật toán K-mean

Đầu vào: Dữ liệu $\mathbf{X}$ và số lượng cluster cần tìm K .

Đầu ra: Các center $\mathbf{M}$ và label vector cho từng điểm dữ liệu $\mathbf{Y}$.

1. Chọn K điểm bất kỳ làm các center ban đầu.
2. Phân mỗi điểm dữ liệu vào cluster có center gần nó nhất.
3. Nếu việc gán dữ liệu vào từng cluster ở bước 2 không thay đổi so với vòng lặp trước nó thì ta dừng thuật toán.
4. Cập nhật center cho từng cluster bằng cách lấy trung bình cộng của tất cả các điểm dữ liệu đã được gán vào cluster đó sau bước 2.
5. Quay lại bước 2.


Ưu điểm và nhược điểm

Ưu Điểm	Nhược Điểm
Dễ triển khai và hiệu quả	Phụ thuộc vào việc chọn số cụm (clusters) ban đầu
Hiệu suất tốt với dữ liệu lớn	Nhạy cảm với dữ liệu nhiễu và giá trị khởi tạo ban đầu
Phù hợp với dữ liệu có cấu trúc đồng nhất	Không thể xử lý tốt với các cụm có kích thước và hình dạng không đồng nhất
Đơn giản và dễ hiểu	Có thể dẫn đến kết quả khác nhau với mỗi lần chạy

Một số thuật toán phân cụm khác

- **Hierarchical Clustering:** Xây dựng cây phân cấp của các nhóm bằng cách liên tục gom nhóm các điểm dữ liệu có đặc tính tương tự nhau lại với nhau.
- **DBSCAN** (Density-Based Spatial Clustering of Applications with Noise): Phân loại các điểm dữ liệu dựa trên mật độ, tìm các vùng có mật độ cao của dữ liệu và phân tách chúng bằng các khu vực có mật độ thấp hơn.
- **Mean Shift:** Di chuyển trung bình của các điểm dữ liệu đến vị trí mà chúng có mật độ cao nhất trong không gian dữ liệu.
- **Gaussian Mixture Models (GMM):** Giả định rằng dữ liệu được tạo ra từ nhiều phân phối Gaussian khác nhau và cố gắng phân loại chúng.
- **Spectral Clustering:** Sử dụng phổ của ma trận tương đồng của dữ liệu để phân cụm chúng.
- **Affinity Propagation:** Sử dụng truyền đạt tin nhắn giữa các điểm dữ liệu để xác định các nhóm.

PCA (Dimensionality Reduction)



Hình 4: PCA dưới góc nhìn Thống kê. PCA có thể được coi là phương pháp đi tìm một hệ cơ sở trực chuẩn đóng vai trò một phép xoay, sao cho trong hệ cơ sở mới này, phương sai theo một số chiều nào đó là rất nhỏ, và ta có thể bỏ qua.