
TRÍ TUỆ NHÂN TẠO

Machine Learning

Phần 2 — Data Visualization

Biên soạn:

ĐẶNG TẤN QUÍ

SĐT: 0377 122 210

2026

Mục lục

Lời nói đầu	3
1 Data Visualization — Trực quan hoá dữ liệu	4
1.1 Data Visualization là gì?	4
1.2 Tầm quan trọng trong Machine Learning	4
1.3 Thư viện Python phổ biến	4
1.4 Các loại trực quan hoá	5
1.5 Kỹ thuật trực quan hoá	5
1.5.1 Univariate: hiểu từng thuộc tính độc lập	5
1.5.2 Multivariate: tương tác nhiều biến	9
2 Histograms — Biểu đồ tần suất	11
2.1 Histogram trong Python	12
2.2 Ví dụ — Histogram cơ bản	12
2.3 Ví dụ — Histogram nhiều tập dữ liệu	13
3 Density Plots — Biểu đồ mật độ	14
3.1 Density plot trong Python	14
3.2 Ví dụ — Density plot đơn	14
3.3 Ví dụ — Density plot nhiều tập	15
4 Box and Whisker Plots — Biểu đồ hộp và râu	16
4.1 Boxplot trong Python	17
4.2 Ví dụ — Boxplot theo loài	17
5 Correlation Matrix Plot — Ma trận tương quan	18
5.1 Ma trận tương quan trong Python	18
5.2 Ví dụ — Heatmap tương quan	19
6 Scatter Matrix Plot — Ma trận scatter	20
6.1 Scatter matrix trong Python	20
6.2 Ví dụ — pairplot với màu theo loài	21

Lời nói đầu

Nguồn

Tài liệu biên soạn và dịch đầy đủ từ Tutorialspoint Machine Learning — mục Data Visualization: https://www.tutorialspoint.com/machine_learning/machine_learning_data_visualization.htm.

Cách dùng

- Đọc sau phần Basic (đặc biệt bài Data Understanding).
- Mỗi chương có ví dụ Python (Matplotlib, Seaborn, Pandas, scikit-learn).

Đặng Tấn Quý

1 Data Visualization — Trực quan hoá dữ liệu

Vì sao trực quan hoá quan trọng trong ML

Trực quan hoá dữ liệu là khía cạnh quan trọng của học máy vì giúp phân tích và truyền đạt pattern, xu hướng và insight trong dữ liệu. Việc tạo biểu diễn đồ họa giúp nhận ra quan hệ có thể không thấy được khi chỉ nhìn dữ liệu thô.

1.1 Data Visualization là gì?

Định nghĩa

Trực quan hoá dữ liệu là biểu diễn đồ họa của dữ liệu và thông tin. Với trực quan hoá, ta quan sát được hình dạng dữ liệu và mức độ tương quan giữa các thuộc tính — đây là cách nhanh nhất để xem feature có “khớp” với đầu ra hay không.

1.2 Tầm quan trọng trong Machine Learning

Bốn vai trò chính

- **Khám phá dữ liệu:** nhận diện pattern, tương quan, outlier; phát hiện missing, mâu thuẫn, chất lượng kém.
- **Chọn đặc trưng (feature selection):** biểu đồ quan hệ với biến mục tiêu giúp giữ biến có sức dự đoán, loại biến nhiễu.
- **Đánh giá mô hình:** ROC, đường precision–recall, ma trận nhầm lẫn để hiểu accuracy, precision, recall, F1.
- **Truyền đạt insight:** scatter, line chart, bar chart giúp người không kỹ thuật hiểu kết quả phức tạp.

1.3 Thư viện Python phổ biến

Matplotlib

Matplotlib là một trong các package Python phổ biến nhất cho trực quan hoá. Thư viện đa nền tảng, vẽ biểu đồ 2D từ mảng dữ liệu; API hướng đối tượng, nhúng được vào ứng dụng GUI (PyQt, WxPython, Tkinter). Dùng được trong shell Python/IPython, Jupyter Notebook và máy chủ web.

Seaborn

Seaborn là thư viện Python mã nguồn mở (BSD) cung cấp API cấp cao để trực quan hoá dữ liệu.

Plotly


Plotly là công ty kỹ thuật (Montreal) phát triển công cụ phân tích và trực quan (Dash, Chart Studio), kèm API đồ thị mã nguồn mở cho Python, R, MATLAB, JavaScript, ...

Bokeh

Bokeh trực quan hoá bằng HTML và JavaScript (khác Matplotlib/Seaborn vẽ trên canvas backend). Rất hữu ích khi xây dashboard web tương tác.

1.4 Các loại trực quan hoá**Phân loại**

- **Biểu đồ một biến (Univariate Plots):** histogram, density plot, boxplot — xem từng thuộc tính độc lập.
- **Biểu đồ đa biến (Multivariate Plots):** ma trận tương quan, scatter matrix — xem tương tác giữa các thuộc tính.

Tổng quan kỹ thuật trực quan**1.5 Kỹ thuật trực quan hoá****1.5.1 Univariate: hiểu từng thuộc tính độc lập****Ba kỹ thuật univariate trong Python**

Histogram, Density Plots, Box and Whisker Plots (boxplot).

Ví dụ — Histogram

Histogram

Histogram gom dữ liệu vào các **bin** — cách nhanh nhất để hình dung phân phối từng thuộc tính.


Đặc điểm histogram

- Cho biết **số quan sát** trong mỗi bin.
- Từ hình dạng bin suy ra phân phối: Gaussian, lệch (skewed), exponential, ...
- Giúp phát hiện outlier có thể.

Code histogram (NumPy + Matplotlib)

```
import matplotlib.pyplot as plt
import numpy as np
# Generate some random data
data = np.random.randn(1000)
# Create the histogram
plt.hist(data, bins=30, color='skyblue', edgecolor='black')
plt.xlabel('Values')
plt.ylabel('Frequency')
plt.title('Histogram Example')
plt.show()
```

Output (số ngẫu nhiên có thể khác nhẹ mỗi lần chạy):



Ví dụ — Density Plot


Density plot

Giống histogram nhưng có **đường cong mượt** trên đỉnh mỗi bin — có thể coi là dạng “histogram trừu tượng”.

Code density plot (Seaborn, Iris)

```
import seaborn as sns
import matplotlib.pyplot as plt
# Load a sample dataset
df = sns.load_dataset("iris")
# Create the density plot
sns.kdeplot(data=df, x="sepal_length", fill=True)
# Add labels and title
plt.xlabel("Sepal Length")
plt.ylabel("Density")
plt.title("Density Plot of Sepal Length")
# Show the plot
plt.show()
```

Output:



Ví dụ — Box and Whisker Plot

Boxplot

Boxplot (box and whisker) tóm tắt phân phối **một biến**: median, tứ phân vị, độ trải, outlier.


Thành phần boxplot

- Đường giữa hộp: **median**.
- Hộp: khoảng **25%–75%** (IQR).
- Râu (whiskers): độ trải dữ liệu “điển hình”.
- Điểm ngoài râu: **outlier** (thường $> 1,5 \times \text{IQR}$ so với biên hộp).

Code boxplot đơn giản

```
import matplotlib.pyplot as plt
# Sample data
data = [10, 15, 18, 20, 22, 25, 28, 30, 32, 35]
# Create a figure and axes
fig, ax = plt.subplots()
# Create the boxplot
ax.boxplot(data)
# Set the title
ax.set_title('Box and Whisker Plot')
# Show the plot
plt.show()
```

Output:



1.5.2 Multivariate: tương tác nhiều biến

Hai kỹ thuật multivariate

Correlation Matrix Plot, Scatter Matrix Plot.

Ví dụ — Correlation Matrix Plot


Ma trận tương quan

Tương quan đo mức biến thiên đồng bộ giữa hai biến. Ma trận tương quan cho biết cặp nào tương quan cao/thấp.

Code heatmap tương quan

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
# Sample data
data = {'A': [1, 2, 3, 4, 5],
        'B': [5, 4, 3, 2, 1],
        'C': [2, 3, 1, 4, 5]}
df = pd.DataFrame(data)
# Calculate the correlation matrix
c_matrix = df.corr()
# Create a heatmap
sns.heatmap(c_matrix, annot=True, cmap='coolwarm')
plt.title("Correlation Matrix")
plt.show()
```

Output (ma trận đối xứng: góc dưới trái trùng góc trên phải):



Ví dụ — Scatter Matrix Plot


Scatter matrix

Scatter matrix cho thấy một biến bị ảnh hưởng thế nào bởi biến khác — quan hệ qua các điểm trên hai trục. Khái niệm gần với biểu đồ đường nhưng dùng điểm thay vì nối đường.

Code scatter matrix (Pandas + sklearn Iris)

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn import datasets
# Load the iris dataset
iris = datasets.load_iris()
df = pd.DataFrame(iris.data, columns=iris.feature_names)
# Create the scatter matrix plot
pd.plotting.scatter_matrix(df, diagonal='hist', figsize=(8, 7))
plt.show()
```

Output:



2 Histograms — Biểu đồ tần suất

Histogram

Histogram là biểu diễn dạng cột (giống biểu đồ cột) của **phân phối** một biến. Nó cho biết **tần suất** (số lần xuất hiện) của từng giá trị (hoặc khoảng giá trị). Trục x : miền giá trị; trục y : tần suất hoặc số đếm; **chiều cao cột** = số điểm rơi vào khoảng đó.

Histogram dùng để làm gì?

Histogram hữu ích khi nhận diện pattern: **độ lệch** (skewness), **số đỉnh** (modality), **điểm kỳ dị** (outlier).

- **Skewness**: mức bất đối xứng của phân phối.
- **Modality**: số “đỉnh” trên phân phối.
- **Outlier**: điểm nằm ngoài vùng giá trị điển hình.

2.1 Histogram trong Python

Thư viện và dataset ví dụ

Python có Matplotlib, Seaborn, Plotly, Bokeh. Ví dụ dưới dùng **Matplotlib** và dataset **Breast Cancer** từ scikit-learn: 30 feature, 569 mẫu; mô tả đặc tính tế bào ung thư vú và nhân ác tính/lành tính.

2.2 Ví dụ — Histogram cơ bản

Import và histogram mean radius

```
import matplotlib.pyplot as plt
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()
```


```
import matplotlib.pyplot as plt
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()
```

```
plt.figure(figsize=(7.2, 3.5))
plt.hist(data.data[:,0], bins=20)
plt.xlabel('Mean Radius')
plt.ylabel('Frequency')
plt.show()
```

Dùng `hist()` của Matplotlib; `bins=20` chia miền giá trị thành 20 khoảng; `xlabel/ylabel` gắn nhãn trục.

Đọc biểu đồ

Phân phối mean radius gần **chuẩn**, đỉnh khoảng 12–14.

Output**2.3 Ví dụ — Histogram nhiều tập dữ liệu****So sánh hai nhóm**

Có thể chồng hai histogram để so sánh phân phối — ví dụ mean radius giữa mẫu ác tính và lành tính.

Hai histogram chồng nhau

```
import matplotlib.pyplot as plt
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()


plt.figure(figsize=(7.2, 3.5))
plt.hist(data.data[data.target==0,0], bins=20, alpha=0.5, label='Malignant')
plt.hist(data.data[data.target==1,0], bins=20, alpha=0.5, label='Benign')
plt.xlabel('Mean Radius')
plt.ylabel('Frequency')
plt.legend()
plt.show()
```

Gọi `hist()` hai lần; `alpha=0.5` để cột trong suốt, không che khuất hoàn toàn; `legend()` thêm chú thích. Trong scikit-learn, `target==0` là ác tính (malignant), `target==1` là lành tính (benign) — theo nhãn dataset.

Nhận xét

Hai phân phối **khác nhau**: nhóm ác tính có tần suất cao hơn ở mean radius lớn.

Output



3 Density Plots — Biểu đồ mật độ

Density plot

Density plot (biểu đồ mật độ) thể hiện **hàm mật độ xác suất** (PDF) của biến liên tục. Giống histogram nhưng thay cột bằng **đường cong mượt** biểu diễn mật độ xác suất. Trục x : miền giá trị; trục y : mật độ xác suất.

Ứng dụng

Hữu ích khi xem skewness, modality, outlier — tương tự histogram nhưng dễ so sánh hình dạng phân phối khi chồng nhiều đường.

3.1 Density plot trong Python

Thư viện và dataset

Ví dụ dùng **Seaborn** và dataset Breast Cancer (30 feature, 569 mẫu) từ scikit-learn.

3.2 Ví dụ — Density plot đơn

Import và kdeplot

```
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()
```

```
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()


plt.figure(figsize=(7.2, 3.5))
sns.kdeplot(data.data[:,0], fill=True)
plt.xlabel('Mean Radius')
plt.ylabel('Density')
plt.show()
```

kdeplot() ước lượng mật độ (KDE); fill=True tô vùng dưới đường (thay cho tham số shade=True đã lỗi thời trong Seaborn cũ).

Đọc biểu đồ

PDF mean radius gần chuẩn, đỉnh khoảng 12–14.

Output (kdeplot)



3.3 Ví dụ — Density plot nhiều tập

So sánh ác tính / lành tính

```
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()

plt.figure(figsize=(7.5, 3.5))
sns.kdeplot(data.data[data.target==0,0], fill=True, label='Malignant')
sns.kdeplot(data.data[data.target==1,0], fill=True, label='Benign')
plt.xlabel('Mean Radius')
plt.ylabel('Density')
```


```
plt.legend()  
plt.show()
```

Hai lần kdeplot với label; legend() phân biệt đường.

Nhận xét

Đường mật độ nhóm ác tính **lệch phải** hơn — mean radius trung bình cao hơn.

Output



4 Box and Whisker Plots — Biểu đồ hộp và râu

Boxplot (Box and Whisker Plot)

Boxplot là biểu diễn đồ họa tóm tắt dữ liệu bằng **năm số thống kê**: giá trị nhỏ nhất, tứ phân vị thứ nhất (Q1), median, tứ phân vị thứ ba (Q3), giá trị lớn nhất (trong phạm vi “râu” chuẩn).

Cấu trúc boxplot

- **Hộp (box)**: khoảng liên tứ phân vị (IQR) từ Q1 đến Q3.
- **Râu (whiskers)**: kéo từ hộp tới giá trị cao/thấp nhất còn nằm trong $1,5 \times \text{IQR}$ tính từ biên hộp.
- **Điểm ngoài râu**: outlier.

4.1 Boxplot trong Python

Dataset Iris

Ví dụ dùng **Iris** (scikit-learn): 150 hoa, 4 đo (sepal length/width, petal length/width), 3 loài Setosa, Versicolor, Virginica.

4.2 Ví dụ — Boxplot theo loài

Nạp dữ liệu

```
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_iris
iris = load_iris()
data = iris.data
target = iris.target
```

Boxplot sepal length theo species

```
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_iris
iris = load_iris()
data = iris.data
target = iris.target


plt.figure(figsize=(7.5, 3.5))
sns.boxplot(x=target, y=data[:, 0])
plt.xlabel('Species')
plt.ylabel('Sepal Length (cm)')
plt.show()
```

Trục x : chỉ số loài (0, 1, 2); trục y : sepal length (cm).

Đọc biểu đồ

Setosa có sepal length **ngắn hơn** Versicolor và Virginica (median và IQR thấp hơn). Versicolor và Virginica có median và độ trải tương tự. Setosa hầu như không có outlier; Versicolor và Virginica có vài điểm ngoài râu.

Output



5 Correlation Matrix Plot — Ma trận tương quan

Correlation matrix plot

Ma trận tương quan là biểu diễn đồ họa của **tương quan cặp** giữa các biến trong dataset. Mỗi ô (hoặc heatmap) cho biết hệ số tương quan giữa hai biến; đường chéo thường thể hiện phân phối từng biến (tùy công cụ).

Hệ số tương quan

Do mức **quan hệ tuyến tính** giữa hai biến, trong khoảng $[-1, 1]$:

- $+1$: tương quan dương hoàn hảo (biến này tăng thì biến kia tăng).
- -1 : tương quan âm hoàn hảo.
- 0 : không có tương quan tuyến tính (trong ý nghĩa hệ số Pearson).

5.1 Ma trận tương quan trong Python

Dataset Iris

Ví dụ dùng Iris (scikit-learn): 150 mẫu, 4 feature, 3 loài.

5.2 Ví dụ — Heatmap tương quan

Code đầy đủ (Pandas + Seaborn)

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris

iris = load_iris()
data = pd.DataFrame(iris.data, columns=iris.feature_names)
target = iris.target


corr = data.corr()
sns.set(style='white')
mask = np.zeros_like(corr, dtype=bool)
mask[np.triu_indices_from(mask)] = True
f, ax = plt.subplots(figsize=(11, 9))
cmap = sns.diverging_palette(220, 10, as_cmap=True)
sns.heatmap(corr, mask=mask, cmap=cmap, vmax=.3, center=0,
            square=True, linewidths=.5, cbar_kws={"shrink": .5})
plt.show()
```

`corr()` trên DataFrame; mask che tam giác trên để tránh lặp; heatmap tô màu theo hệ số.

Đọc biểu đồ

- sepal width và petal length: tương quan âm vừa ($\approx -0,37$).
- petal length và petal width: tương quan dương mạnh ($\approx 0,96$).
- sepal length và petal length: tương quan dương ($\approx 0,87$).

Output



6 Scatter Matrix Plot — Ma trận scatter

Scatter Matrix Plot

Scatter Matrix Plot (còn gọi **Pair Plot**) là biểu diễn quan hệ giữa **nhiều biến** cùng lúc. Mỗi ô là scatter plot của một **cặp feature**; đường chéo có thể hiển thị phân phối từng biến.

Vai trò trong ML

Công cụ hữu ích để trực quan hoá tương quan giữa các feature, hỗ trợ feature engineering và hiểu cấu trúc dữ liệu trước khi huấn luyện.

6.1 Scatter matrix trong Python

Dataset và thư viện

Ví dụ dùng **Iris** qua Seaborn: 4 feature (sepal/petal length/width), 150 mẫu, 3 loài Setosa, Versicolor, Virginica. Seaborn xây trên Matplotlib, API gọn cho pair plot.

6.2 Ví dụ — pairplot với màu theo loài

Code

```
import seaborn as sns
import pandas as pd
import matplotlib.pyplot as plt

# load iris dataset
iris = sns.load_dataset('iris')

# create scatter matrix plot
sns.pairplot(iris, hue='species')


# show plot
plt.show()
```

`load_dataset('iris')` nạp bảng Iris có cột `species`. `pairplot(..., hue='species')` tô màu điểm theo loài.

Đọc biểu đồ

Ma trận gồm scatter từng cặp feature; màu theo loài giúp thấy cụm tách biệt (ví dụ Setosa tách rõ ở nhiều cặp biến).

Output



Pandas scatter_matrix

Ngoài `sns.pairplot`, có thể dùng `pd.plotting.scatter_matrix` với tham số `diagonal='hist'`.