
TRÍ TUỆ NHÂN TẠO

Machine Learning

Phần 4 — Regression Analysis

Biên soạn:

ĐẶNG TẤN QUÍ

SĐT: 0377 122 210

2026

Mục lục

Lời nói đầu	4
1 Phân tích hồi quy (Regression Analysis)	5
1.1 Thuật ngữ	5
1.2 Cách hồi quy hoạt động	5
1.3 Các loại hồi quy trong học máy	6
1.3.1 Hồi quy tuyến tính (Linear Regression)	6
1.3.2 Hồi quy logistic (Logistic Regression)	6
1.3.3 Hồi quy đa thức (Polynomial Regression)	7
1.3.4 Hồi quy Lasso (Lasso Regression)	7
1.3.5 Hồi quy Ridge (Ridge Regression)	7
1.3.6 Hồi quy cây quyết định (Decision Tree Regression)	8
1.3.7 Hồi quy Random Forest (Random Forest Regression)	8
1.3.8 Hồi quy vectơ hỗ trợ (Support Vector Regression)	8
1.4 Hai loại mô hình hồi quy (đơn và đa biến)	9
1.5 Chọn mô hình hồi quy tốt nhất	9
1.6 Metric đánh giá hồi quy	9
1.7 Ứng dụng hồi quy trong học máy	10
1.8 Xây dựng mô hình hồi quy trong Python	10
2 Hồi quy tuyến tính (Linear Regression)	12
2.1 Dữ liệu ví dụ (một feature)	12
2.2 Quan hệ tuyến tính dương và âm	13
2.3 Hai loại hồi quy tuyến tính	13
2.3.1 Hồi quy tuyến tính đơn	14
2.3.2 Hồi quy tuyến tính đa biến	14
2.4 Cách hoạt động	14
2.5 Hàm giả thuyết	14
2.6 Đường khớp tốt nhất	15
2.7 Hàm mất mát	15
2.8 Gradient descent	15
2.9 Giả định mô hình	15
2.10 Metric đánh giá	16
2.11 Ứng dụng, ưu điểm và thách thức	16
3 Hồi quy tuyến tính đơn (Simple Linear Regression)	16
3.1 Cách hoạt động	17
3.2 Giả định	17
3.3 Triển khai Python	18
4 Hồi quy tuyến tính đa biến (Multiple Linear Regression)	21
4.1 Giả định	22
4.2 Triển khai Python	22
4.3 Ứng dụng và thách thức	23
4.4 So sánh đơn và đa biến	24

5 Hồi quy đa thức (Polynomial Regression)	24
5.1 Phương trình	25
5.2 Cách hoạt động	25
5.3 Triển khai Python	25

Đặng Tấn Quý

Lời nói đầu

Nguồn

Tài liệu biên soạn và dịch đầy đủ từ Tutorialspoint Machine Learning — mục Regression Analysis: https://www.tutorialspoint.com/machine_learning/machine_learning_regression_analysis.htm.

Cách dùng

- Đọc sau phần Statistics và Data Visualization.

Dặng Tấn Quý

1 Phân tích hồi quy (Regression Analysis)

Phân tích hồi quy

Kỹ thuật thống kê dự đoán **giá trị số liên tục** dựa trên quan hệ giữa biến độc lập và biến phụ thuộc.

Mục tiêu: vẽ đường/đường cong khớp dữ liệu tốt nhất và ước lượng ảnh hưởng của biến này lên biến kia.

Vai trò trong học máy

Hồi quy là **học có giám sát**: mô hình học từ feature (độc lập) và target (phụ thuộc, số liên tục) để dự đoán trên dữ liệu mới.

Ứng dụng: dự báo, phân tích dự đoán, tối ưu kinh doanh, kinh tế, tài chính.

1.1 Thuật ngữ

Thuật ngữ thường gặp

- **Biến độc lập** (predictor, biến dự báo, feature): dùng để dự đoán giá trị biến phụ thuộc.
- **Biến phụ thuộc** (target, biến mục tiêu): biến cần dự đoán.
- **Đường hồi quy**: đường thẳng / đường cong phù hợp nhất với dữ liệu.
- **Quá khớp (Overfitting)** (phương sai cao): mô hình tốt trên tập huấn luyện nhưng kém trên tập kiểm tra.
- **Thiếu khớp (Underfitting)** (độ lệch cao): mô hình kém cả trên tập huấn luyện.
- **Điểm ngoại lai (Outlier)**: điểm không theo quy luật chung; giá trị cực cao hoặc cực thấp.
- **Đa cộng tuyến (Multicollinearity)**: các biến độc lập tương quan cao với nhau.

1.2 Cách hồi quy hoạt động

Quy trình

Thuật toán hồi quy được huấn luyện trên tập có nhãn (feature + target).

Trong huấn luyện, mô hình học quan hệ giữa feature và target; sau đó dự đoán giá trị mới từ quan hệ đã học.

1.3 Các loại hồi quy trong học máy

Cách phân loại và các loại thường dùng

Nói chung, các phương pháp hồi quy được phân loại dựa trên ba tiêu chí: số biến độc lập, kiểu biến phụ thuộc, và hình dạng đường hồi quy.

1.3.1 Hồi quy tuyến tính (Linear Regression)

Hồi quy tuyến tính

Hồi quy tuyến tính là mô hình hồi quy được dùng phổ biến nhất trong học máy. Đây là mô hình thống kê phân tích **quan hệ tuyến tính** giữa biến phụ thuộc với một tập biến độc lập cho trước.

Quan hệ tuyến tính và hai nhánh

Quan hệ tuyến tính giữa các biến nghĩa là: khi giá trị của một hoặc nhiều biến độc lập thay đổi (tăng hoặc giảm), giá trị biến phụ thuộc cũng thay đổi tương ứng (tăng hoặc giảm).

Hồi quy tuyến tính chia thành hai nhánh con:

- **Hồi quy tuyến tính đơn** (simple linear regression): chỉ dùng **một** biến độc lập (predictor) để dự đoán biến phụ thuộc.
- **Hồi quy tuyến tính đa biến** (multiple linear regression): nhiều biến độc lập được dùng để dự đoán biến phụ thuộc.

1.3.2 Hồi quy logistic (Logistic Regression)

Hồi quy logistic

Hồi quy logistic là thuật toán học máy phổ biến, dùng để dự đoán **xác suất** một sự kiện xảy ra.

Mô hình và hàm sigmoid

Hồi quy logistic là mô hình tuyến tính tổng quát (generalized linear model) trong đó biến mục tiêu tuân theo phân phối Bernoulli. Thuật toán dùng hàm logistic hoặc hàm logit để học quan hệ giữa biến độc lập (predictors) và biến phụ thuộc (target).

Biến phụ thuộc được ánh xạ qua hàm sigmoid của các biến độc lập. Hàm sigmoid cho xác suất trong khoảng $[0, 1]$; giá trị xác suất này được dùng để ước lượng giá trị biến phụ thuộc.

Ứng dụng chính

Hồi quy logistic chủ yếu dùng cho **bài toán phân loại nhị phân**: biến mục tiêu là phân loại với hai lớp. Mô hình ước lượng xác suất của biến mục tiêu khi biết các feature đầu

vào, rồi dự đoán lớp có xác suất cao nhất.

1.3.3 Hồi quy đa thức (Polynomial Regression)

Hồi quy đa thức

Polynomial Linear Regression là phân tích hồi quy trong đó quan hệ giữa biến độc lập và biến phụ thuộc được mô hình hóa bằng hàm đa thức bậc n . Hồi quy đa thức cho phép bất quan hệ phức tạp hơn so với quan hệ tuyến tính trong hồi quy đơn và hồi quy tuyến tính đa biến thuần túy.

Đặc điểm

Hồi quy đa thức là một trong các hồi quy **phi tuyến** được dùng rộng rãi nhất. Có thể mô hình hóa quan hệ phi tuyến giữa predictor và target; đồng thời **nhạy hơn với outlier** so với hồi quy tuyến tính.

1.3.4 Hồi quy Lasso (Lasso Regression)

Hồi quy Lasso

Hồi quy Lasso là kỹ thuật **chuẩn hóa** (regularization): thêm hình phạt (penalty) để tránh overfitting và cải thiện độ chính xác mô hình hồi quy.

L1 và trường hợp dùng

Lasso thực hiện **chuẩn hóa L1**: sửa hàm mất mát bằng cách cộng thêm lượng co (shrinkage) bằng **tổng giá trị tuyệt đối** của các hệ số.
Hồi quy Lasso thường dùng khi xử lý dữ liệu **chiều cao** (nhiều feature) và dữ liệu có **tương quan cao** giữa các biến.

1.3.5 Hồi quy Ridge (Ridge Regression)

Hồi quy Ridge

Hồi quy Ridge là kỹ thuật thống kê trong học máy nhằm **ngăn overfitting** trên mô hình hồi quy tuyến tính.

L2 và trường hợp dùng

Ridge là chuẩn hóa **L2**: sửa hàm mất mát / cost bằng cách cộng penalty bằng **bình phương độ lớn** của các hệ số.
Ridge giúp giảm độ phức tạp mô hình và cải thiện độ dự đoán. Phù hợp khi mô hình có nhiều tham số với trọng số lớn, và với tập dữ liệu có **số feature lớn hơn số quan sát**.

Đa cộng tuyến

Ridge cũng giúp xử lý **đa cộng tuyến** — tình huống các biến độc lập phụ thuộc lẫn nhau.

1.3.6 Hồi quy cây quyết định (Decision Tree Regression)

Hồi quy cây quyết định

Hồi quy cây quyết định dùng thuật toán cây quyết định để dự đoán **giá trị số**. Cây quyết định là thuật toán học có giám sát, dùng được cho cả phân loại và hồi quy.

Cách hoạt động

Trong hồi quy, cây dùng để dự đoán biến liên tục. Cách hoạt động: chia dữ liệu thành các tập con nhỏ hơn theo giá trị feature đầu vào, gán mỗi tập con một giá trị số; quá trình lặp dần xây dựng cây quyết định.

Cây khớp các hồi quy tuyến tính cục bộ để xấp xỉ đường cong; mỗi lá (leaf) biểu diễn một giá trị số. Thuật toán cố gắng **giảm MSE** tại mỗi nút con — đo mức dự đoán lệch so với target gốc.

Ứng dụng

Dự đoán giá cổ phiếu, hành vi khách hàng, v.v.

1.3.7 Hồi quy Random Forest (Random Forest Regression)

Hồi quy Random Forest

Hồi quy Random Forest là thuật toán học có giám sát dùng **tập hợp** (ensemble) nhiều cây quyết định để dự đoán biến mục tiêu liên tục.

Bagging

Kỹ thuật **bagging**: chọn ngẫu nhiên các tập con dữ liệu huấn luyện để xây từng cây nhỏ; các mô hình nhỏ được kết hợp thành Random Forest và xuất ra **một** giá trị dự đoán. Cách này giúp tăng độ chính xác và **giảm phương sai** nhờ kết hợp dự đoán từ nhiều cây.

1.3.8 Hồi quy vectơ hỗ trợ (Support Vector Regression)

SVR

Support Vector Regression (SVR) là thuật toán học máy dùng máy vectơ hỗ trợ (SVM) để giải bài toán hồi quy. SVR có thể học quan hệ **phi tuyến** giữa dữ liệu đầu vào (feature) và đầu ra (target).

Ưu điểm

Xử lý được quan hệ tuyến tính và phi tuyến trong tập dữ liệu; **chịu outlier** tốt; có độ chính xác dự đoán cao.

1.4 Hai loại mô hình hồi quy (đơn và đa biến)**Mô hình hồi quy đơn (Simple regression model)**

Đây là mô hình hồi quy cơ bản nhất: dự đoán được tạo từ **một** feature đơn biến (univariate) của dữ liệu.

Mô hình hồi quy đa biến (Multiple regression model)

Như tên gọi, trong mô hình này dự đoán được tạo từ **nhiều** feature của dữ liệu.

1.5 Chọn mô hình hồi quy tốt nhất**Cách chọn mô hình**

Có thể xét các yếu tố: metric hiệu năng, độ phức tạp mô hình, khả năng giải thích (interpretability), v.v. Đánh giá mô hình bằng các metric như MSE, MAE, R^2 , v.v. So sánh hiệu năng của các mô hình khác nhau (hồi quy tuyến tính, cây quyết định, random forest, v.v.) và chọn mô hình có metric cao nhất, độ phức tạp thấp nhất, và dễ giải thích nhất (trong phạm vi phù hợp bài toán).

1.6 Metric đánh giá hồi quy**Metric đánh giá hồi quy**

- Mean Absolute Error (MAE): Trung bình của **giá trị tuyệt đối** hiệu giữa giá trị dự đoán và giá trị thực.
- Mean Squared Error (MSE): Trung bình của **bình phương** hiệu giữa giá trị thực và giá trị ước lượng.
- Median Absolute Error: Trung vị của hiệu tuyệt đối giữa giá trị dự đoán và giá trị thực.
- Root Mean Squared Error (RMSE): Căn bậc hai của MSE.
- R^2 (coefficient of determination): Điểm tốt nhất có thể là 1,0; có thể **âm** vì mô hình có thể tệ hơn mức tùy ý so với baseline đơn giản.
- MAPE (Mean Absolute Percentage Error): Dạng phần trăm tương đương của MAE.

1.7 Ứng dụng hồi quy trong học máy

Ứng dụng hồi quy trong học máy

- Dự báo / phân tích dự đoán (Forecasting or Predictive analysis): Một trong những ứng dụng quan trọng của hồi quy là dự báo. Ví dụ: dự báo GDP, giá dầu, hoặc nói chung các dữ liệu định lượng thay đổi theo thời gian.
- Tối ưu hóa (Optimization): Hồi quy giúp tối ưu quy trình kinh doanh. Ví dụ: quản lý cửa hàng có thể lập mô hình thống kê để hiểu giờ cao điểm khách đến.
- Hiệu chỉnh sai lầm (Error correction): Trong kinh doanh, ra quyết định đúng quan trọng ngang với tối ưu quy trình. Hồi quy hỗ trợ ra quyết định đúng và **hiệu chỉnh** các quyết định đã triển khai.
- Kinh tế (Economics): Hồi quy là công cụ được dùng nhiều nhất trong kinh tế: dự đoán cung, cầu, tiêu dùng, đầu tư tồn kho, v.v.
- Tài chính (Finance): Công ty tài chính muốn giảm rủi ro danh mục và hiểu yếu tố ảnh hưởng khách hàng — có thể mô hình hóa bằng hồi quy.

1.8 Xây dựng mô hình hồi quy trong Python

Cách xây dựng mô hình hồi quy

Có thể xây mô hình hồi quy từ đầu bằng Python; thư viện Scikit-learn cũng dùng được để xây mô hình hồi quy.

Ví dụ dưới đây xây mô hình hồi quy cơ bản: khớp một đường thẳng với dữ liệu.

Bước 1: Import các gói Python

Để xây mô hình hồi quy bằng scikit-learn, cần import scikit-learn cùng các gói khác:

```
import numpy as np
from sklearn import linear_model
import sklearn.metrics as sm
import matplotlib.pyplot as plt
```

Bước 2: Nạp dataset

Sau khi import, cần dataset để xây mô hình dự đoán hồi quy. Có thể lấy từ dataset của sklearn hoặc nguồn khác tùy nhu cầu.

```
from sklearn.datasets import make_regression
X, y = make_regression(n_samples=100, n_features=1, noise=15, random_state=42)
```

Bước 3: Chia tập huấn luyện và kiểm tra

Cần kiểm thử trên dữ liệu chưa thấy, nên chia dataset thành tập huấn luyện và tập kiểm tra.

```
training_samples = int(0.6 * len(X))
testing_samples = len(X) - training_samples
X_train, y_train = X[:training_samples], y[:training_samples]
X_test, y_test = X[training_samples:], y[training_samples:]
```

Bước 4: Huấn luyện và dự đoán

Sau khi chia dữ liệu, xây mô hình bằng `LinearRegression()` của Scikit-learn:

```
reg_linear = linear_model.LinearRegression()
reg_linear.fit(X_train, y_train)
y_test_pred = reg_linear.predict(X_test)
```

Bước 5: Vẽ đồ thị

Sau dự đoán, có thể vẽ và trực quan hóa:

```
plt.scatter(X_test, y_test, color='red')
plt.plot(X_test, y_test_pred, color='black', linewidth=2)
plt.xticks(())
plt.yticks(())
plt.show()
```

Bước 6: Tính hiệu năng

Tính hiệu năng mô hình bằng các metric:

```
print("Regressor model performance:")
print("Mean absolute error(MAE) =",
      round(sm.mean_absolute_error(y_test, y_test_pred), 2))
print("Mean squared error(MSE) =",
      round(sm.mean_squared_error(y_test, y_test_pred), 2))
print("Median absolute error =",
      round(sm.median_absolute_error(y_test, y_test_pred), 2))
print("Explain variance score =",
      round(sm.explained_variance_score(y_test, y_test_pred), 2))
print("R2 score =",
      round(sm.r2_score(y_test, y_test_pred), 2))
```

Output mẫu:

```
Regressor model performance:
Mean absolute error(MAE) = 1.78
Mean squared error(MSE) = 3.89
Median absolute error = 2.01
Explain variance score = -0.09
```

R2 score = -0.09

2 Hồi quy tuyến tính (Linear Regression)

Hồi quy tuyến tính

Mô hình thống kê phân tích **quan hệ tuyến tính** giữa biến phụ thuộc và một hoặc nhiều biến độc lập. Khi biến độc lập thay đổi, biến phụ thuộc thay đổi tương ứng theo quy luật tuyến tính.

Trong học máy

Dự đoán giá trị số liên tục từ quan hệ tuyến tính đã học; dùng trong mô hình dự báo, tài chính, đánh giá rủi ro.


2.1 Dữ liệu ví dụ (một feature)

Bảng minh họa

Diện tích (ft², feature X) và giá nhà (target Y): mô hình dùng X để dự đoán Y .

Đường hồi quy


Đường thẳng thể hiện quan hệ giữa biến phụ thuộc và độc lập.



2.2 Quan hệ tuyến tính dương và âm


Quan hệ dương

Cả hai biến cùng tăng (hoặc cùng giảm).



Quan hệ âm


Biến độc lập tăng, biến phụ thuộc giảm (bài gốc ghi nhầm chữ “positive”).



2.3 Hai loại hồi quy tuyến tính

1. **Đơn biến** (Simple): một X .
2. **Đa biến** (Multiple): nhiều $X_1, \dots, X_p$.

2.3.1 Hồi quy tuyến tính đơn



$$\hat{Y} = w_0 + w_1 X + \epsilon$$

- Y : target; X : feature; w_0 : hệ số chặn; w_1 : độ dốc; ϵ : sai số.

2.3.2 Hồi quy tuyến tính đa biến

$$\hat{Y} = w_0 + w_1 X_1 + w_2 X_2 + \dots + w_p X_p + \epsilon$$

2.4 Cách hoạt động

Ba bước chính

1. **Giả thuyết:** quan hệ tuyến tính giữa đầu vào và đầu ra.
2. **Hàm mất mát:** đo sai số dự đoán (MSE, MAE, ...).
3. **Tối ưu:** cập nhật tham số đến khi mất mát nhỏ.


2.5 Hàm giả thuyết

$$\hat{Y} = w_0 + w_1 X \quad (\text{đơn biến})$$

$$\hat{Y} = w_0 + w_1 X_1 + \dots + w_p X_p \quad (\text{đa biến})$$

2.6 Đường khớp tốt nhất

Đường hồi quy tốt nhất khi sai số giữa giá trị thực và dự đoán là nhỏ nhất (trung bình).



2.7 Hàm mất mát

MSE (phổ biến)

$$J(w_0, w_1) = \frac{1}{2n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2, \quad \hat{Y}_i = w_0 + w_1 X_i$$

2.8 Gradient descent

Cập nhật tham số

$$w_0 \leftarrow w_0 - \alpha \frac{\partial J}{\partial w_0}, \quad w_1 \leftarrow w_1 - \alpha \frac{\partial J}{\partial w_1}$$

với α là learning rate. Lặp đến khi thay đổi w_0, w_1 không đáng kể.

2.9 Giả định mô hình

Giả định

- Ít hoặc không đa cộng tuyến.
- Ít tự tương quan trong phần dư.

- Quan hệ giữa response và feature là **tuyến tính**.

Vì phạm giả định có thể làm ước lượng chệch hoặc kém hiệu quả.

2.10 Metric đánh giá

R^2 , MSE, RMSE, MAE

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}, \quad \text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\text{RMSE} = \sqrt{\text{MSE}}, \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

2.11 Ứng dụng, ưu điểm và thách thức

Ứng dụng

Mô hình dự báo (bất động sản), chọn feature, dự báo tài chính, quản trị rủi ro.

Ưu điểm

Dễ giải thích, huấn luyện nhanh, nền tảng phân tích dự đoán, đơn giản và hiệu quả tính toán.

Thách thức

Overfitting, đa cộng tuyến, ảnh hưởng outlier; với dữ liệu phi tuyến có thể cần **hồi quy đa thức**.


3 Hồi quy tuyến tính đơn (Simple Linear Regression)

Hồi quy tuyến tính đơn

Phương pháp học có giám sát dùng **một** biến độc lập để dự đoán biến phụ thuộc; mô hình quan hệ tuyến tính giữa hai biến. Khi thuật toán hồi quy tuyến tính chỉ có một feature $\Rightarrow$ hồi quy đơn; nhiều feature $\Rightarrow$ hồi quy đa biến.

Biến độc lập và phụ thuộc

- **Độc lập** (predictor): trục ngang; ví dụ số năm kinh nghiệm.
- **Phụ thuộc** (response): trục dọc; ví dụ lương.



Mô hình

$$Y = w_0 + w_1 X + \epsilon$$

3.1 Cách hoạt động

Tìm đường khớp tốt nhất

Giả thuyết: $\hat{Y} = w_0 + w_1 X$. Không gian giả thuyết là tập mọi đường thẳng với (w_0, w_1) khác nhau. Khởi tạo tham số, dự đoán, tính mất mát (thường MSE), tối ưu (thường gradient descent).

$$J(w_0, w_1) = \frac{1}{2n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

3.2 Giả định

Giả định cổ điển

- **Tuyến tính:** scatter plot gần đường thẳng.
- **Phương sai đồng nhất** (homoscedasticity).
- **Độc lập:** quan sát không phụ thuộc lẫn nhau.
- **Chuẩn phần dư:** histogram phần dư gần chuẩn.

3.3 Triển khai Python

Dataset Salary_Data.csv

30 mẫu: YearsExperience (feature), Salary (target). File: data/Salary_Data.csv.

Bước 1 — Chuẩn bị dữ liệu

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd

dataset = pd.read_csv('data/Salary_Data.csv')
X = dataset.iloc[:, :-1].values # YearsExperience
y = dataset.iloc[:, -1].values # Salary
print(dataset.head())
```

Kiểm tra tuyến tính

```
plt.scatter(X, y, color="green")
plt.title("Salary vs Experience")
plt.xlabel("Years of Experience")
plt.ylabel("Salary (INR)")
plt.show()
```



Chia train/test (80/20)

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=0)
```

Bước 2 — Huấn luyện

```
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

Bước 3 — Dự đoán trên tập kiểm tra

```
y_pred = regressor.predict(X_test)
df = pd.DataFrame({'Actual Values': y_test, 'Predicted Values': y_pred})
print(df)
```

Bước 4 — Đánh giá

```
from sklearn.metrics import mean_squared_error, mean_absolute_error,
    r2_score
import numpy as np


y_pred = regressor.predict(X_test)
print("MSE:", mean_squared_error(y_test, y_pred))
print("RMSE:", np.sqrt(mean_squared_error(y_test, y_pred)))
print("MAE:", mean_absolute_error(y_test, y_pred))
print("R2:", r2_score(y_test, y_pred))
```

Output trong bài gốc

Bài gốc in MSE/MAE cực nhỏ do lỗi code (dùng `mean_squared_error` cho cả RMSE và có thể nhầm tập). Code trên dùng `np.sqrt` cho RMSE là đúng.


Bước 5 — Trực quan tập huấn luyện

```
y_pred_train = regressor.predict(X_train)
plt.scatter(X_train, y_train, color="green", label="actual")
plt.scatter(X_train, y_pred_train, color="blue", label="predicted")
plt.plot(X_train, y_pred_train, color="red")
plt.xlabel("Years of Experience")
plt.ylabel("Salary (INR)")
plt.legend()
plt.show()
```



Bước 6 — Trực quan tập kiểm tra

```
y_pred = regressor.predict(X_test)
plt.scatter(X_test, y_test, color="green", label="test actual")
plt.scatter(X_test, y_pred, color="blue", label="test predicted")
plt.plot(X_test, y_pred, color="red")
plt.legend()
plt.show()
```



4 Hồi quy tuyến tính đa biến (Multiple Linear Regression)

Hồi quy tuyến tính đa biến (MLR)

Thuật toán học có giám sát mô hình quan hệ giữa **một** biến phụ thuộc liên tục và **nhiều** biến độc lập. Biến phân loại (ví dụ **State**) cần mã hóa số trước khi đưa vào mô hình tuyến tính.

So với hồi quy đơn

MLR là mở rộng của hồi quy đơn: dự đoán bằng hai hoặc nhiều feature.

Phương trình

Với n quan sát, p feature:

$$h(x_i) = w_0 + w_1x_{i1} + w_2x_{i2} + \dots + w_px_{ip}$$

Có phần dư:

$$y_i = h(x_i) + e_i, \quad e_i = y_i - h(x_i)$$

4.1 Giả định

Giả định MLR

1. Tuyến tính giữa target và predictor.
2. Các quan sát độc lập.
3. Phương sai phần dư đồng nhất (homoscedasticity).
4. Phần dư gần phân phối chuẩn.
5. Không đa cộng tuyến mạnh giữa feature.
6. Không tự tương quan phần dư.
7. Giá trị biến độc lập cố định giữa các mẫu lặp.

4.2 Triển khai Python

Dataset data.csv

50 dòng: R&D Spend, Administration, Marketing Spend, State, Profit. Ví dụ dưới bỏ State như bài gốc (đơn giản hóa).

Bước 1 — Chuẩn bị

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

dataset = pd.read_csv('data/data.csv')
X = dataset[['R&D Spend', 'Administration', 'Marketing Spend']]
y = dataset['Profit']
print(X.head())
print(y.head())
```

Chia train/test (20% test)

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=0)
```

Bước 2 — Huấn luyện

```
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

Bước 3 — Kiểm tra

```
y_pred = regressor.predict(X_test)
df = pd.DataFrame({'Real Values': y_test.values,
                   'Predicted Values': y_pred})
print(df)
```

Bước 4 — Metric

```
from sklearn.metrics import mean_squared_error, mean_absolute_error,
    r2_score
import numpy as np

mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)
print("MSE:", mse)
print("RMSE:", rmse)
print("MAE:", mae)
print("R2:", r2)
```

Đọc $R^2 \approx 0,96$ (bài gốc)

Khoảng 96% biến thiên của Profit được giải thích bởi ba feature đầu vào (trên tập kiểm tra của ví dụ gốc).

Bước 5 — Dự đoán điểm mới

```
new_data = [[166343.2, 136787.8, 461724.1]]
profit = regressor.predict(new_data)
print(profit)
```

Hệ số và chặn

```
print("coefficients:", regressor.coef_)
print("intercept:", regressor.intercept_)
```

Kiểm tra tay: Profit $\approx w_0 + w_1X_1 + w_2X_2 + w_3X_3$.

4.3 Ứng dụng và thách thức**Ứng dụng**

Tài chính, marketing, bất động sản, y tế, kinh tế, khoa học xã hội.

Thách thức

Đa cộng tuyến, overfitting/underfitting, phi tuyến, outlier, dữ liệu thiếu.

4.4 So sánh đơn và đa biến


Tiêu chí	Đơn biến	Đa biến
Số biến độc lập	1	≥ 2
Phương trình	$y = w_0 + w_1x$	$y = w_0 + \sum w_jx_j$
Độ phức tạp	Thấp hơn	Cao hơn
Giải thích hệ số	Dễ hơn	Khó hơn

5 Hồi quy đa thức (Polynomial Regression)**Hồi quy đa thức**

Mô hình quan hệ giữa biến độc lập và phụ thuộc bằng **đa thức bậc n** , vượt qua giới hạn tuyến tính của hồi quy đơn/đa biến tuyến tính thuần.

Khi nào dùng?

Dữ liệu **phi tuyến** không khớp đường thẳng; hồi quy tuyến tính bỏ sót pattern cong.



5.1 Phương trình

Đa thức bậc n

$$y = w_0 + w_1x + w_2x^2 + \dots + w_nx^n + \epsilon$$

Bậc 2 (parabol):

$$y = w_0 + w_1x + w_2x^2 + \epsilon$$

5.2 Cách hoạt động

Biến đổi feature

Tạo feature $x, x^2, \dots, x^n$ từ x gốc, rồi huấn luyện `LinearRegression` trên không gian mở rộng — tương tự MLR nhưng các cột đa thức phụ thuộc cùng một x đầu vào.

5.3 Triển khai Python

ice_cream_selling_data.csv


49 mẫu: Temperature, IceCreamSales. File: data/ice_cream_selling_data.csv.

Bước 1 — Nạp và trực quan

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.preprocessing import PolynomialFeatures

data = pd.read_csv('data/ice_cream_selling_data.csv')
X = data.iloc[:, 0].values.reshape(-1, 1)
y = data.iloc[:, 1].values

plt.scatter(X, y, color="green")
plt.xlabel("Temperature (C)")
plt.ylabel("Ice Cream Sales (units)")
plt.title("Original Data")
plt.show()
```



Đặc trưng đa thức bậc 2

```
degree = 2
poly_features = PolynomialFeatures(degree=degree)
X_poly = poly_features.fit_transform(X)
```

Bước 2 — Huấn luyện

```
from sklearn.linear_model import LinearRegression
lr_model = LinearRegression()
lr_model.fit(X_poly, y)
```

Bước 3 — Dự đoán

```
y_pred = lr_model.predict(X_poly)
df = pd.DataFrame({'Actual Values': y, 'Predicted Values': y_pred})
print(df.head())
```


Bước 4 — R^2

```
from sklearn.metrics import r2_score
print("R2:", r2_score(y, y_pred))
```

Bài gốc: $R^2 \approx 0,932$ — khoảng 93% biến thiên được giải thích.

Bước 5 — Vẽ đường cong hồi quy

```
plt.scatter(X, y, color="green")
plt.plot(X, y_pred, color='red',
         label=f'Polynomial Regression (degree={degree})')
plt.xlabel("Temperature (C)")
plt.ylabel("Ice Cream Sales (units)")
plt.legend()
plt.show()
```

**Dự đoán nhiệt độ mới**

```
X_new = np.array([[1.9929]])
X_new_poly = poly_features.transform(X_new)
print(lr_model.predict(X_new_poly))
```

Bậc đa thức

Bậc quá cao dễ overfitting; nên thử cross-validation hoặc regularization khi mở rộng thực tế.