

Dặng Tấn Quý

Mục lục

Đặng Tấn Quý

Lời nói đầu

Tài liệu thuộc **Nhóm 5 — Xác suất và thống kê**, biên soạn theo cùng triết lý với giáo án Đại số tuyến tính: học để *hiểu* và *dùng*, không chỉ để ghi nhớ công thức.

1. **Động cơ trước định nghĩa.** Mỗi phần lớn mở bằng ô **Động cơ học** — câu hỏi thực tế hoặc bài toán mẫu cần khái niệm đó.
2. **Trực giác trước công thức.** Ô **Ý nghĩa & Trực giác** giải thích “công thức đang nói gì” (xác suất = tần suất dài hạn, kỳ vọng = trung bình có trọng số, v.v.).
3. **Ví dụ có kiểm tra.** Ô **Ví dụ** nên tự làm trước khi đọc lời giải; phần thống kê ứng dụng cần gắn dữ liệu số cụ thể.
4. **Tổng kết cuối mỗi chương.** Ô **Tổng kết chương** liệt kê kết quả phải nhớ và liên kết sang phần sau.
5. **Phân tầng theo môn.** X1–X3 là nền; X4–X5 nâng cao lý thuyết; X6–X8 chuyên sâu (đa biến, Bayes, quá trình ngẫu nhiên).

Cách đọc: Động cơ → Định nghĩa / Định lý → Ví dụ → Ý nghĩa → Tổng kết. Với môn thống kê, luôn hỏi: *mẫu là gì, tham số nào chưa biết, giả thuyết H_0 là gì.*

1 Mở đầu

Động cơ — Mở đầu

Dữ liệu thường có nhiều biến cùng lúc. Thống kê đa biến tìm cấu trúc ẩn (thành phần chính, nhân tố), phân nhóm (cụm), hoặc phân loại (phân biệt).

Dặng Tấn Quý

2 Phân phối chuẩn nhiều chiều

Động cơ — Phân phối chuẩn nhiều chiều

Nền xác suất cho vectơ ngẫu nhiên và ma trận hiệp phương sai.

Định nghĩa

$\mathbf{X} = (X_1, \dots, X_p)^T \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right).$$

Tính chất

- Mọi tổ hợp tuyến tính $\mathbf{a}^T \mathbf{X} \sim \mathcal{N}(\mathbf{a}^T \boldsymbol{\mu}, \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a})$.
- Phân phối biên: $X_i \sim \mathcal{N}(\mu_i, \sigma_{ii})$.
- Không tương quan $\Leftrightarrow$ độc lập (đặc trưng của chuẩn).
- $(\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim \chi^2(p)$.

Phân phối Wishart

Nếu $\mathbf{X}_i \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ iid thì: $\mathbf{W} = \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^T \sim W_p(n-1, \boldsymbol{\Sigma})$.

Hotelling T^2

$T^2 = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^T \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)$. Dưới $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$:

$$\frac{n-p}{(n-1)p} T^2 \sim F(p, n-p).$$

Tổng kết: Phân phối chuẩn nhiều chiều

1. Nắm lại các **định nghĩa** và **công thức** cốt lõi trong mục “Phân phối chuẩn nhiều chiều”.
2. Tự làm lại ít nhất một ví dụ (nếu có) hoặc áp dụng công thức vào một tình huống số.
3. Ghi chú điều kiện áp dụng (giả thiết độc lập, phân phối chuẩn, n đủ lớn, v.v.).

3 Phân tích thành phần chính (PCA)

Động cơ — Phân tích thành phần chính (PCA)

Giảm chiều nhưng giữ tối đa phương sai — trực quan hóa và tiền xử lý.

Định nghĩa

PCA tìm các tổ hợp tuyến tính $Y_k = \mathbf{a}_k^T \mathbf{X}$ sao cho $\text{Var}(Y_k)$ lớn nhất, các Y_k không tương quan.

Định lý

Thành phần chính thứ k ứng với **trị riêng** λ_k và **vectơ riêng** $\mathbf{a}_k$ của Σ (hoặc $\mathbf{S}$), $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$:

$$\text{Var}(Y_k) = \lambda_k, \quad \text{Tỉ lệ giải thích} = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}.$$

Thực hành PCA

1. Chuẩn hóa dữ liệu (trung bình 0, phương sai 1) nếu các biến khác đơn vị.
2. Chéo hóa ma trận hiệp phương sai (hoặc tương quan) mẫu.
3. Chọn số thành phần: scree plot, tỉ lệ phương sai tích lũy $\geq 80\%$.
4. Giải thích: xem loading (hệ số trong $\mathbf{a}_k$) để hiểu ý nghĩa thành phần.

Tổng kết: Phân tích thành phần chính (PCA)

1. Nắm lại các **định nghĩa** và **công thức** cốt lõi trong mục “Phân tích thành phần chính (PCA)”.
2. Tự làm lại ít nhất một ví dụ (nếu có) hoặc áp dụng công thức vào một tình huống số.
3. Ghi chú điều kiện áp dụng (giả thiết độc lập, phân phối chuẩn, n đủ lớn, v.v.).

4 Phân tích nhân tố (Factor Analysis)

Động cơ — Phân tích nhân tố (Factor Analysis)

Mô hình hóa biến quan sát bằng ít nhân tố tiềm ẩn.

Định nghĩa

Mô hình: $\mathbf{X} - \boldsymbol{\mu} = \mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon}$, với $\mathbf{F}$ (m nhân tố chung), $\boldsymbol{\varepsilon}$ (nhiều riêng), $\mathbf{L}$ (ma trận tải $p \times m$).

$\boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}^T + \boldsymbol{\Psi}$, $\boldsymbol{\Psi} = \text{diag}(\psi_1, \dots, \psi_p)$.

Ước lượng và xoay

- Ước lượng $\mathbf{L}$: phương pháp thành phần chính, hoặc MLE.
- **Xoay nhân tố**: Varimax (trực giao), Promax (xiên) — dễ giải thích hơn.
- **Điểm nhân tố**: ước lượng $\hat{\mathbf{F}}$ cho từng quan sát.

Tổng kết: Phân tích nhân tố (Factor Analysis)

1. Nắm lại các **định nghĩa** và **công thức** cốt lõi trong mục “Phân tích nhân tố (Factor Analysis)”.
2. Tự làm lại ít nhất một ví dụ (nếu có) hoặc áp dụng công thức vào một tình huống số.
3. Ghi chú điều kiện áp dụng (giả thiết độc lập, phân phối chuẩn, n đủ lớn, v.v.).

5 Phân tích phân biệt và phân cụm

Động cơ — Phân tích phân biệt và phân cụm

Hai hướng: có nhãn (phân loại) vs không nhãn (gom cụm).

Tổng kết: Phân tích phân biệt và phân cụm

1. Nắm lại các **định nghĩa** và **công thức** cốt lõi trong mục “Phân tích phân biệt và phân cụm”.
2. Tự làm lại ít nhất một ví dụ (nếu có) hoặc áp dụng công thức vào một tình huống số.
3. Ghi chú điều kiện áp dụng (giả thiết độc lập, phân phối chuẩn, n đủ lớn, v.v.).

5.1 Phân tích phân biệt (Discriminant Analysis)

LDA (Linear Discriminant Analysis)

Phân loại $\mathbf{x}$ vào nhóm k cực đại hóa:

$$\delta_k(\mathbf{x}) = \mathbf{x}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln \pi_k,$$

với $\pi_k = P(\text{nhóm } k)$. Giả sử Σ chung.

QDA (Quadratic DA)

Nói lỏng: mỗi nhóm có Σ_k riêng. Biên phân loại là bậc hai.

5.2 Phân cụm (Clustering)

K-means

1. Chọn K tâm ban đầu.
2. Gán mỗi điểm vào cụm gần nhất.
3. Cập nhật tâm = trung bình cụm.
4. Lặp đến hội tụ. Cực tiểu $\sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$.

Phân cụm phân cấp

- **Agglomerative** (bottom-up): ghép dần.
- **Divisive** (top-down): tách dần.
- Liên kết: single, complete, average, Ward.
- Kết quả: dendrogram.

Chọn số cụm

- Phương pháp khuỷu tay (elbow method).
- Silhouette score.
- Gap statistic.